

Fundamentos de Ecologia Numérica

Disciplina de Ecologia Numérica do Curso de Ciências Biológicas
do Campus V da UEPB

Prof. Elvio S. F. Medeiros Laboratório de Ecologia
Universidade Estadual da Paraíba
Campus V, João Pessoa, PB

Last updated: 24/07/2026 15:19:51

Contents

1	Apresentação	13
1.1	Motivação	14
1.2	Plano de estudo	14
1.3	Organização do livro	15
1.4	Como estudar por esse livro?	16
1.5	Como citar esse livro	16
1.6	Download da versão impressa	17
I	I. INTRODUÇÃO	19
2	Ferramentas	21
2.1	Instalação do R e RStudio	22
2.2	Criando uma conta no GitHub	23
2.3	Fluxo básico: Stage , Commit e Push	28
2.4	Modelo de site	29
	Material de apoio	29
	Apêndices	29
	Sites consultados	29
	Leitura suplementar	29
	Referências	29

3	Introdução ao R/RStudio	31
3.1	Pré-requisitos	31
3.2	Principais conceitos	31
3.3	O que é o R Studio?	33
3.4	O essencial	35
3.5	Mensagens de erro e avisos no R	37
3.6	Prefira sempre códigos e scripts do que mouse e menus de janelas no R	38
3.7	Preparação dos arquivos	40
3.8	Conclusão	44
3.9	Sequência típica na preparação e análise de dados	44
3.10	Material de apoio	45
3.11	TESTE SEUS CONHECIMENTOS	45
	Apêndices	45
	Sites consultados	45
	Leitura suplementar	45
	Referências	46
 II	 II. TEORIA	 47
 4	 Teoria 1 - Introdução à Análise Multivariada de Dados (AMD)	 49
 5	 Teoria 2 - Tipos de dados usados em AMD	 51
 6	 Teoria 3 - Relativizações e transformações de dados	 53
	Referências	53
 III	 III. BASES DE DADOS	 55
 7	 Bases de dados. Dados do PPBio Semiárido	 57
7.1	Sobre os dados do PPBio	57
7.2	Arquivos disponíveis	60
	Referências	64

<i>CONTENTS</i>	5
8 Base de dados I - Peixes	67
8.1 Introdução	68
8.2 Codificação das variáveis	72
8.3 Amostragem dos dados	72
8.4 Análises estatísticas	77
8.5 Discussão	78
Apêndices	80
Referências	83
9 Base de dados II - Habitat	85
RESUMO	86
9.1 Introdução	87
9.2 Codificação para variáveis	89
9.3 Área de estudo e amostragem dos dados	92
9.4 Análises estatísticas	93
9.5 Resultados	93
9.6 Discussão	98
Referências	101
IV IV. ESTATÍSTICAS DESCRITIVAS	103
10 R Módulo 1 - Sintaxe e Tipos de dados no R	105
10.1 O que é um <code>script</code> e qual sua diferença para um <code>código</code> ?	106
10.2 Tipos e estruturas de dados no R	109
10.3 Tipos e estruturas de dados no R	112
10.4 Tipos de dados no R	113
10.5 Estruturas de dados no R	115
10.6 Pacotes (<code>packages</code>)	132
10.7 Como pedir ajuda?	133
10.8 Work flow	136
Apêndices	137
Sites consultados	138

Script limpo	138
Referências	142
11 R Módulo 2 - Importando planilhas de dados	143
11.1 Sobre os dados do PPBio	144
11.2 Importando a planilha de trabalho	146
11.3 Organização básica	146
11.4 Importando a planilha	148
11.5 Importando .ods do LibreOffice Calc	152
11.6 Manipulando matrizes de dados	153
Apêndices	160
Script limpo	160
Referências	166
12 R Módulo 3.1 - Estatísticas descritivas e normalidade	167
12.1 Sobre os dados	168
12.2 Organização básica	168
12.3 Importando a planilha	170
12.4 Averiguando normalidade	174
12.5 Tabela de frequências e gráfico <i>stem-and-leaf</i>	174
12.6 Assimetria e curtose	178
12.7 Gráficos de histograma e boxplot	179
12.8 Gráfico de probabilidade normal (<i>Normal probability plot</i> ou <i>Normal Q-Q plot</i>)	185
12.9 Sumário estatístico geral	187
12.10 Estatística de Shapiro-Wilk	187
12.11 Estatística de Kolmogorov-Smirnov, com nível de significância de Lilliefors	188
12.12 Transformação de variáveis e outros tipos de conjuntos de dados	190
Apêndices	193
Sites consultados	193
Script limpo	193
Referências	195

13 R Módulo 3.2 - Testes estatísticos	197
13.1 Sobre os dados	198
13.2 Organização básica	200
13.3 Importando a planilha	200
13.4 REINÍCIO	204
13.5 Averiguando normalidade	204
13.6 Histograma e boxplot	207
13.7 Sumário estatístico geral	209
13.8 Testando normalidade	210
13.9 Transformando os dados	214
13.10 Comparando médias	215
13.11 Testes t (t -tests)	218
13.12 Teste entre três médias ($ANOVA$)	224
13.13 $ANOVA$ Two-Way, teste entre grupos e dois fatores ($Factorial$ $ANOVA$)	234
13.14 Técnicas não-paramétricas	245
13.15 Material de apoio	250
13.16 TESTE SEUS CONHECIMENTOS	250
Apêndices	250
Sites para consulta	250
Script limpo	250
Referências	259
14 Correlação e Regressão	261
14.1 Sobre os dados	261
14.2 Organização básica	262
14.3 Importando a planilha	262
14.4 Correlação	264
14.5 Correlação simples (bivariada)	268
14.6 Correlação parcial	273
14.7 Regressão simples	274
14.8 Gráfico de dispersão ($scatterplot$)	283

Apêndices	286
Sites para consulta	286
Script limpo	286
Referências	286
15 Regressão múltipla	287
15.1 Organização básica	290
15.2 Sobre os dados	293
15.3 Organização básica	294
15.4 Regressão Múltipla Simultânea	325
15.5 Regressão Múltipla Hierárquica	330
15.6 Regressão Múltipla <i>Stepwise</i>	334
Apêndices	348
Sites para consulta	348
Script limpo	349
Referências	349
16 Modelos lineares generalizados (GLMs)	351
16.1 Organização básica	358
Apêndices	371
Sites para consulta	371
Script limpo	371
Referências	371
17 R Módulo 4.1 - Estrutura da comunidade	373
17.1 Sobre os dados	373
17.2 Organização básica	374
17.3 Importando a planilha	375
17.4 REINÍCIO	377
17.5 Transpor a matriz para trabalhar com as espécies	377
17.6 Calculando os descritores da comunidade	383
17.7 Índices de Diversidade	389

17.8	Gráficos descritivos	410
17.9	Distribuição de abundância	411
17.10	Curva de rarefação	413
17.11	Curva de acumulação de espécies	421
17.12	Plot indivíduos	425
17.13	Riqueza rarefacionada	426
	Apêndices	428
	Sites consultados	441
	Script limpo	441
	Referências	450
18	R Modulo 4.2 - Decomposição da diversidade	453
18.1	Sobre os dados	453
18.2	REINÍCIO 1	457
18.3	Análise de Espécies Compartilhadas	457
18.4	REINÍCIO 2	458
18.5	Táxons compartilhados pelas duas bases de dados	460
18.6	REINÍCIO 3	461
18.7	REINÍCIO 4	464
18.8	Encontrando espécies exclusivas	464
18.9	Espécies exclusivas para 2 LINHAS OU 2 GRUPOs - Baseado na soma dos grupos (#FUNCIONA)	465
18.10	Encontrando espécies compartilhadas ENTRE DOIS (OU MAIS) GRUPOS	466
18.11	Diagrama de Venn	467
18.12	Usando o pacote VennDiagram	469
18.13	Diagrama de Venn - BASEADO EM PALAVRAS	479
18.14	PARTIÇÃO DA DIVERSIDADE	483
18.15	Extrair valores do objeto part - geral	483
18.16	Definir função para adicionar significância	483
18.17	Criar dataframe com todas as informações	484
18.18	Exibir a tabela	484

Apêndices	488
Referências	488
19 R Módulo 4.3 - Estrutura do habitat	491
19.1 Sobre os dados	491
19.2 Organização básica	491
19.3 Importando a planilha	492
19.4 Reset point	494
19.5 Correlograma e remoção de variáveis redundantes ou desnecessárias	494
19.6 Deletando variáveis colineares	500
19.7 Somando variáveis redundantes	501
19.8 Tabela de dados ambientais	504
Apêndices	507
Sites consultados	507
Script limpo	507
Referências	507
V V. ANÁLISES MULTIVARIADAS	509
20 R Modulo 5 - Relativizações e transformações	511
20.1 Organização básica	512
20.2 Tamanho da matriz	515
20.3 REINÍCIO 1	517
20.4 Cálculo da matriz de distâncias	518
20.5 Distribuição de frequência da matriz de distâncias	521
20.6 Distribuição de frequências da matriz de distâncias	523
20.7 Relativizando e transformando a base de dados	525
20.8 REINÍCIO 2	530
Apêndices	530
Script limpo	533
Referências	537

21 R Módulo 6 - Análise de outliers baseada no desvio padrão do centróide	539
21.1 Sobre os dados do PPBio	539
21.2 Organização básica	541
21.3 Reset point	548
21.4 Cálculo de matriz de distâncias Euclidiana (<code>euclid</code>)	551
21.5 Calculando o centróide da matriz de distâncias <code>euclid</code>	554
21.6 Distribuição de frequências da matriz de distâncias <code>euclid</code>	555
21.7 Procurando outliers	556
21.8 Lista final de outliers	567
21.9 Particionando a matriz	568
21.10 Exportando a matrix final de trabalho	572
Apêndices	574
Script limpo	574
Referências	580
 22 R Módulo 7 - Análise de Classificação Hierárquica - SAHN	 583
22.1 Organização básica	584
22.2 REINÍCIO	587
22.3 Nomenclatura das matrizes em AMD	587
22.4 <i>Cluster</i> 1: Piloto automático	587
22.5 <i>Cluster</i> 2: Criando a matriz de distâncias Euclidiana	597
22.6 <i>Cluster</i> 3: Relativização pelo total da coluna	601
22.7 <i>Cluster</i> 4: Transformação pelo arcoseno da raiz quadrada	602
22.8 <i>Cluster</i> 5: Controle total dos parâmetros	603
22.9 Construindo uma prancha de gráficos comparativos	612
22.10 Construindo <code>heatmaps</code>	613
Apêndices	620
Sites consultados	620
Script limpo	621
Referências	626

23 R Módulo 8 - Análise de Classificação Não-hierárquica - K-Means	627
23.1 Organização básica	628
23.2 REINÍCIO 1	629
23.3 Classificação	630
23.4 Histórico das fusões	632
23.5 Algoritmo k-means - Versão simplificada	633
23.6 REINÍCIO 2	634
23.7 Determinando o número ideal de clusteres	637
Apêndices	644
Sites para consulta	644
Referências	645
 VI VI. INFORMAÇÕES GERAIS	 647
24 Nomenclatura das matrizes em AMD	649
24.1 Grupos taxonômicos	649
24.2 Tipos de matrizes	649
24.3 Abreviações	652
24.4 Bases de dados para download	652

Chapter 1

Apresentação

Bem-vindo à disciplina de Ecologia Numérica. A base desta disciplina está no uso de técnicas multivariadas de classificação e ordenação, como são usadas em ecologia e gestão de recursos. Todos os textos e aulas foram elaborados para serem complementados pela Bibliografia Básica e pelo Material de Apoio (ver subsequentemente). Usaremos o software RStudio!, desenvolvido por R STUDIO TEAM (2022).

Embora seja necessário algum conhecimento matemático e uma base em bioestatística, estes assuntos não têm uma abordagem basicamente matemática e o material de apoio será usado para revisar temas de outras disciplinas. Os procedimentos são explicados em termos de fórmulas e algoritmos e o aluno obterá pelo menos uma compreensão intuitiva do que os métodos envolvem. Para aqueles com mais interesse nos temas tratados, a bibliografia básica oferece maior profundidade. A Ecologia Numérica é a ferramenta básica do biólogo no tocante à análise quantitativa de quaisquer tipos de dados. Ela cobre, além dos assuntos abordados nessa disciplina, áreas de rápido desenvolvimento de análise temporal e espacial. Esperamos que, ao concluir esta disciplina, o texto seja de valor duradouro em seu trabalho profissional.

Os softwares disponíveis para análise multivariada são diversos. A maioria dos pacotes maiores tem algumas das rotinas padrão, mas um software especializado, como o R/RStudio, também é necessário para fazer o melhor uso dos avanços recentes em aplicações ecológicas. O R é um ambiente e uma linguagem de programação gratuita e de “código aberto”. Veremos mais sobre isso subsequentemente.

1.1 Motivação

Este é um site experimental da disciplina de graduação de Ecologia Numérica do Curso de Ciências Biológicas da Universidade Estadual da Paraíba.

O site experimental da disciplina de Ecologia Numérica da UEPB é uma plataforma criada com o objetivo de apresentar exemplos didáticos aos alunos, explorando diferentes conceitos e técnicas utilizadas na análise de dados em Ecologia. É importante destacar que os exemplos apresentados no site podem conter imprecisões ou códigos demasiado extensos (aparentemente desnecessários para um ecólogo e programador de R mais experiente), mas isso é proposital, pois a finalidade é oferecer um material didático para os alunos, que possa facilitar a compreensão dos conceitos abordados durante as aulas. Dessa forma, o site é uma ferramenta complementar às aulas presenciais, que busca fornecer exemplos práticos e didáticos para os estudantes de Ecologia Numérica da UEPB.

Como mencionado, a finalidade é didática e de apresentar o tema seguindo passo-a-passo e contextualizando com dados ecológicos reais. Por isso, além das informações sobre o conteúdo do site experimental da disciplina de ecologia numérica da UEPB, é importante destacar que qualquer erro ou problema relacionado ao site pode ser reportado ao responsável pelo site.

É fundamental que os usuários do site compreendam que plágio e outras formas de má conduta acadêmica são inaceitáveis e podem ter sérias consequências. O responsável pelo site se compromete a remover qualquer conteúdo ofensivo ou sem citar a devida fonte consultada, que possa ter sido publicado erroneamente ou por engano.

1.2 Plano de estudo

O objetivo principal é familiarizar-se com o uso do RStudio para que você possa executar as operações básicas com confiança. Você aprenderá como instalar o software, importar e exportar dados, exibi-los em forma de planilha, modificá-los das principais formas e exibir informações básicas. Além disso, você também aprenderá a exportar resultados para permitir a apresentação e análises posteriores em outros pacotes estatísticos. Ao ler os artigos de revisão em *Leitura Suplementar*, você será apresentado a algumas das diversidades do trabalho multivariado e as críticas que têm recebido na ecologia, mas também um excelente exemplo de uma análise multivariada cuidadosamente descrita. Ele leva você através da configuração objetiva, seleção de caracteres e codificação de dados, em seguida, em várias análises e, em seguida, o desenho de conclusões apropriadas.

Portanto, para obter o máximo benefício, recomenda-se que você faça o seguinte:

leia a o conteúdo Teórico inteiro sobre conceitos-chave minuciosamente;
 leia e estude todo o Material de Apoio disponível do Google Sala de Aula;
 complete os exemplos e tutorias passo-a-passo (quando houver);
 leia os artigos introdutórios na Leitura Suplementar (esse passo não é obrigatório nem necessário para completar o curso;
 participe e tire dúvidas no Chat da disciplina no Google Sala de Aula;
 complete os Exemplos aplicados;
 avalie sua compreensão dos materiais, usando os quizzes, que são perguntas de múltipla escolha baseadas no Google Sala de Aula.

Conforme você avança ao longo da disciplina, concentre-se mais no fluxo de procedimentos para entrada (input) e modificação de dados, em vez de nos detalhes das opções e saídas (outputs). Eles sempre podem ser consultados quando necessário, aqui ou no sistema de ajuda do R/RStudio.

Os scripts do R/RStudio documentam o histórico de sua análise. Também é aconselhável, ao fazer uma análise, registrar notas adicionais sobre a interpretação da análise (usando #). Isso também pode ser feito diretamente nos arquivos de resultados.

Ao completar a **PARTE I** o aluno deve ser capaz de:

- instalar o R e RStudio
- decidir a melhor forma de preparar seus dados em vários formatos (.xlsx, .csv, etc)
- configurar diretórios de projetos
- importar, modificar e exportar seus dados
- preparar um arquivo de nome de espécies
- particionar arquivos de dados em subconjuntos
- considerar o tratamento de valores faltantes
- exportar resultados para outros softwares para análise e apresentação
- salvar e documentar um arquivo de resultados

Ao estudar cada módulo, concentre-se mais no fluxo dos procedimentos para entrada e modificação de dados, em vez dos detalhes das opções. Estes podem sempre ser revisados quando necessário, aqui ou nos materiais de apoio. A janela do Console ou (“Work Area”) documenta o histórico de sua análise. Também é aconselhável ao fazer uma análise, registrar e fazer anotações adicionais sobre sua interpretação da análise etc. Isso pode ser feito diretamente na janela de **Scripts**.

1.3 Organização do livro

Este livro é organizado em **SEIS** partes:

Na primeira parte (**PARTE I**), o livro é apresentado, bem como suas ferramentas.

Na PARTE II, são apresentadas as BASES TEÓRICAS fundamentais sobre ecologia numérica e análise multivariada.

Na PARTE III, é apresentada a fundamentação teórica para o entendimento das BASES DE DADOS que são trabalhados ao longo das PARTES IV e V e execução das estatísticas descritas.

Na PARTE IV, são apresentados os primeiros Módulos do RStudio sobre ESTATÍSTICAS DESCRITIVAS EM ECOLOGIA DE COMUNIDADES, na forma de tutoriais discutidos, que podem ser executados passo-a-passo sobre .

Na PARTE V, são apresentados os Módulos do RStudio mais avançados, sobre TÉCNICAS DE ANÁLISE MULTIVARIADA EM ECOLOGIA DE COMUNIDADES.

Por fim, na PARTE VI, são apresentadas INFORMAÇÕES GERAIS de apoio para o melhor entendimento do conteúdo, como uma lista geral das tabelas usadas na PARTE IV, um glossário de termos, bibliografia geral, entre outras fontes de informação.

1.4 Como estudar por esse livro?

Simples! Siga a sequência que é apresentada.

- Estude a teoria (PARTE II), certifique-se de que entende os conceitos e é capaz de tomar decisões fundamentadas na teoria. Revise/relembre do Ensino Médio a matemática necessária (Conjuntos, Matriz, Álgebra, Teorema de Pitágoras, etc.).
- Leia a fundamentação das bases de dados que usará subsequentemente (PARTE III). Mas lembre, você não precisa ser especialista nos grupos taxonômicos apresentados aqui como exemplo. O ecólogo trabalha com dados, e eles falam por si só.
- Parta para a ação (PARTES IV e V), comece com os primeiros módulos do R, siga as instruções passo-a-passo, execute linha por linha de código, atente para os resultados.
- Consulte os detalhes e referências apresentados na PARTE VI.

1.5 Como citar esse livro

Medeiros, E. S. F. (data de acesso). “Fundamentos de Ecologia Numérica.” Bookdown.org. Laboratório de Ecologia, Universidade Estadual Da Paraíba, Campus V, João Pessoa, PB. https://elviomedeiros.github.io/Fundamentos_de_Ecologia_Numerica/index.html.

1.6 Download da versão impressa

Baixar site em PDF

Part I

I. INTRODUÇÃO

Chapter 2

Ferramentas

RESUMO

Ferramentas como Git (software de controle de versões), GitHub (plataforma online que hospeda repositórios Git) e Zotero (software de gerenciamento e compartilhamento de referências bibliográficas) desempenham um papel central na **ciência aberta**, especialmente no que diz respeito à **reprodutibilidade** e à **replicabilidade** dos estudos. Essas plataformas contribuem diretamente para a transparência do processo científico ao permitir que dados, códigos, metodologias e referências sejam organizados, documentados e compartilhados de forma acessível (SILVEIRA et al., 2023). Outra ferramenta que usaremos é o *Ambiente de Desenvolvimento Integrado (IDE)* para a linguagem R, o RStudio (R STUDIO TEAM, 2022). Uma introdução detalhada sobre o R (R DEVELOPMENT CORE TEAM, 2017) e RStudio é apresentada no próximo capítulo Introdução ao R/RStudio.

No caso do Git e do GitHub, sua principal contribuição está no controle de versão

Table 2.1: Resumo esquemático em forma de tabela com as principais dimensões da Ciência Aberta (Baseado em @silveira2023).

Dimensão	Significado	Exemplo
Publicações abertas	Tornar artigos científicos acessíveis sem barreiras de assinatura	Revistas de acesso aberto
Dados abertos	Compartilhar bases de dados para reutilização e validação	Repositórios de dados, como Zenodo
Software aberto	Disponibilizar código e ferramentas de forma livre	GitHub, pacotes R/Python
Infraestruturas abertas	Plataformas e serviços que suportam práticas abertas	Repositórios institucionais
Avaliação aberta	Transparência nos processos de revisão por pares	Peer review aberto, como eprints
Engajamento público	Participação da sociedade na produção científica	Ciência cidadã, projetos de ciência aberta
Educação aberta	Recursos educacionais livres e acessíveis	MOOCs, materiais didáticos
Políticas e governança	Normas e diretrizes que incentivam a abertura	Planos de dados abertos

e na rastreabilidade das alterações em projetos de pesquisa. Cada modificação em scripts, conjuntos de dados ou documentos pode ser registrada com precisão, incluindo informações sobre quem realizou a alteração, quando e por quê. Isso cria um histórico auditável que permite a outros pesquisadores compreenderem todas as etapas do desenvolvimento de um estudo. Como resultado, torna-se mais viável reproduzir os resultados originais utilizando os mesmos métodos e procedimentos, o que é essencial para validar descobertas científicas. Além disso, o uso dessas ferramentas facilita a colaboração entre pesquisadores, mesmo em contextos distribuídos geograficamente. Projetos podem ser desenvolvidos coletivamente, com contribuições revisadas e integradas de forma estruturada. Isso reduz inconsistências e melhora a qualidade geral da pesquisa.

O Zotero atua na organização e gestão de referências bibliográficas, assegurando que as fontes utilizadas sejam corretamente registradas e facilmente recuperáveis. Ele também permite o compartilhamento de bibliotecas entre grupos de pesquisa, promovendo alinhamento teórico e metodológico. Ao tornar explícitas as bases conceituais de um estudo, o Zotero contribui para que outros pesquisadores possam compreender, verificar e replicar os fundamentos da pesquisa.

Em conjunto, essas ferramentas fortalecem práticas científicas mais abertas, confiáveis e verificáveis, pilares fundamentais da ciência aberta.

2.1 Instalação do R e RStudio

2.1.1 R base

1. O primeiro passo é entrar na página do projeto CRAN (Comprehensive R Archive Network) (<https://www.r-project.org/>).
2. Do lado esquerdo da página clique sobre o link CRAN abaixo de Download.
3. Uma nova página com uma série de links irá se abrir. Esses links são chamados de “espelhos” e servem para que você possa escolher o local mais próximo de onde você está para fazer o download do programa. Escolha um espelho no Brasil.
3. Na seção Download and Install R, clique sobre o link **Download R for Windows** para baixar a versão para esse sistema... (MacOS??... o que é isso?)
4. Clique sobre o link **base**.
5. Clique sobre o link **Download R 4.x.x for Windows** para fazer o download do arquivo R.exe.
6. A instalação segue o formato padrão de instalação de programas no Windows, e portanto não são necessários maiores detalhes.

2.1.2 RStudio

1. Para baixar o RStudio entre no endereço (<https://posit.co/download/rstudio-desktop/>)
2. Clique no link **Products > RStudio**
3. Selecione a versão Desktop.
4. Clique em **DOWNLOAD RSTUDIO DESKTOP**
5. Será exibida uma página com a recomendação para você baixar o RStudio FREE versão mais recente - Windows
6. Clicando nesse link, você irá baixar o arquivo RStudio atual (.exe)
7. Depois é só clicar e instalar da forma convencional do Windows.

Após a instalação, você pode abrir o RStudio pelo seu respectivo ícone, e o RStudio estará pronto para ser utilizado. O R base continuará instalado mas será acessado pelo RStudio. Não o desinstale.

2.1.3 RStudio na nuvem


Usar o RStudio Cloud (<https://login.rstudio.cloud/>) é uma opção para quem não quer instalar a versão para PC. O RStudio Cloud é uma plataforma online que fornece um ambiente de desenvolvimento integrado para o R, permitindo que os usuários executem análises, desenvolvam código e colaborem com outras pessoas, sem a necessidade de instalar o R e o RStudio em seus próprios computadores. É uma solução conveniente e acessível, especialmente para iniciantes ou usuários que desejam compartilhar projetos e colaborar de forma eficiente.

2.2 Criando uma conta no GitHub


1. Primeiro instale o Git a partir desse site <https://git-scm.com/>. O Git fará a ponte entre o Github e o RStudio.
2. Acesse o site oficial do GitHub em <https://github.com/> e faça o cadastro. Você vai precisar confirmar por e-mail. **Anote seu e-mail e login de cadastro.**

2.2.1 Criando um repositório no Github

1. Faça login no GitHub
2. No canto superior direito, navegue até o seu perfil (**Profile**): https://github.com/seu_nome



3. Seleccione Repository > New



4. Preencha os campos:

Repository name: nome_do_projeto

Description (opcional)

Public (público)

Marque **Add a README**


Escolha uma licença (GNU)

Clique em **Create repository**

5. Abra o repositório criado, em **Settings**, vá em **Pages**

Na opção **Branch**, escolha as opções **main** e **/docs**.

Clique em **Save**




6. Volte no repositório e escolha **About** (símbolo da engrenagem)

Dê uma descrição do repositório

Marque a opção **Use your GitHub Pages website**

Insira dois ou três tópicos

Save changes



2.2.2 Criando um Controle de Versões no RStudio

No RStudio siga as seguintes opções:

File > New Project > Version Control > Git

Para incluir a opção Repository URL você precisará voltar no seu repositório do Github:

1. Volte no seu repositório do Github e clique em Code
2. Copie o HTTPS
3. Volte no RStudio e cole em Repository URL
4. O Project directory name é preenchido automaticamente com o nome do seu projeto
5. Em Create project as subdirectory of escolha a pasta local onde será mantido seu projeto.
6. Marque a opção Open in new session
7. Clique em Create Project

Após esse passos o RStudio abrirá uma nova sessão com seu projeto. Esse projeto estará vinculado ao Git e Github. O RStudio vai criar uma subpasta com o seu projeto (nome do repositório) na pasta que você definir em Project directory name.

2.2.3 Ativação do Git no RStudio

Para ativar Git no RStudio, abra o RStudio, vá em **Tools > Global Options > Git/SVN** e marque **Enable version control interface**

2.2.4 Configurando usuário e e-mail do Git, no RStudio

Instale o pacote `usethis`:

```
install.packages("usethis")
```

Depois configure:

```
usethis::use_git_config(  
  user.name = "github_login",  
  user.email = "seu_email_cadastrado"  
)  
usethis::git_sitrep()
```

Também é possível configurar pelo Terminal do RStudio:

```
git config --global user.name "Github_login"  
git config --global user.email "email@exemplo.com"
```

2.3 Fluxo básico: Stage, Commit e Push

Depois que você cria o seu projeto no RStudio, ele cria novos arquivos (por exemplo, o arquivo do projeto, `.Rproj`, entre outros). O seu RStudio fica diferente do seu repositório do Github. Esses arquivos existem apenas no computador local e ainda não estão no Github. É necessário levar essas mudanças para o Github.



NOTA

Se você não consegue visualizar a extensão dos seus arquivos (exemplo, arquivo **.Rproj**) veja o tópico [visualizar extensões de arquivos](#) do Capítulo [Introdução ao R/RStudio](#)

Para enviar as alterações ao GitHub:

Depois de alterar qualquer arquivo do seu projeto, vá até a aba *Git* no canto superior direito do RStudio. Ali aparecerão todos os arquivos modificados. Marque aqueles que deseja enviar para o GitHub — esse passo corresponde ao **Stage** dos arquivos, ou seja, selecionar os arquivos que farão parte do próximo **Commit**. Em seguida, clique em **Commit**.

Isso abrirá uma janela para você escrever a mensagem do commit. Escreva uma mensagem descrevendo as alterações realizadas (por exemplo, “primeiro commit”)

Depois de escrever a mensagem, clique novamente em **Commit**. Nesse momento, as alterações ficam registradas localmente no seu computador (na pasta do seu projeto do RStudio). Finalizado o commit, clique em **Push** para enviar tudo ao repositório remoto no GitHub.

Depois disso, abra o repositório no GitHub pelo navegador e atualize a página para conferir se os arquivos e alterações realmente foram enviados. Se o processo ocorreu corretamente, os arquivos atualizados e a nova mensagem de commit já aparecerão no histórico do repositório.

2.4 Modelo de site

Agora baixe esse arquivo `_quarto.ZIP` e descompacte-o. Nele há um conjunto de arquivos que cria um site provisório, a partir de onde você construirá seu relatório da disciplina.

Copie todos os arquivos da pasta descompactada para dentro da pasta do seu projeto no RStudio.

Atualize seu repositório do Github, com as opções **Stage**, **Commit** e **Push**, como descrito anteriormente. Na mensagem de commit escreva “site provisório”.

Material de apoio

Apêndices

Sites consultados

Leitura suplementar

Referências

Chapter 3

Introdução ao R/RStudio

RESUMO

LEGENDRE; LEGENDRE (1998) alertam o ecologista numérico sobre as armadilhas do uso de computadores - que **a computabilidade não garante (i) que os dados satisfaçam o método e (ii) que os resultados sejam interpretados corretamente em termos ecológicos.** A isso, infelizmente, deve ser adicionada a advertência adicional de que os computadores não negam a necessidade de verificar a exatidão dos cálculos.

A conclusão desta disciplina ajudará a evitar essas armadilhas, fornecendo a você as habilidades para aplicar essas técnicas com sucesso para o avanço da ciência e do gerenciamento de nossos recursos naturais. Espero que com a conclusão dessa disciplina o aluno possa evitar essas armadilhas e possua as habilidades para aplicar essas técnicas com sucesso para avançar na sua área de atuação.

3.1 Pré-requisitos

Familiaridade básica com computadores, tipos de arquivos (.xlsx, .docx, etc), processadores de texto e planilhas é necessária aqui. Espera-se que você seja capaz de compreender estatísticas univariadas básicas.

3.2 Principais conceitos

3.2.1 O ambiente de programação do R

O programa R oferece uma poderosa ferramenta para manipulação, análise e visualização de dados, e nos últimos anos tornou-se muito popular entre os

ecologistas (e não apenas eles). Ele oferece grande liberdade e permite que você faça o que quiser com seus dados, o que não é o caso de softwares clicáveis como SAS, SPSS ou STATISTICA, entre outros. No entanto, ele também surge com uma curva de aprendizado íngreme, tendo em vista sua linguagem baseada em S/S-Plus, e um certo nível de frustração por conta de mensagens de erro frequentes. A menor imprecisão na digitação do código impede que ele seja executado, e gasto de tempo na busca do erro. Isso, em parte, estimula a “copia-cola” de scripts prontos, levando o usuário a executar análises sem saber o que está fazendo. Exceto pelo livro de Jean Valentin (VALENTIN, 2000), a grande maioria dos textos impressos em ecologia numérica são em inglês. Assim como inúmeros tutoriais em inglês pela internet (veja Introduction to R for Ecologists de David Zelený. Em português temos o excelente livro on-line Análises Ecológicas no R de SILVA et al. (2022).

O R não é um software do tipo aplicativo, é um ambiente de programação com um conjunto integrado de ferramentas de software para manipulação de dados, cálculo e apresentação gráfica. A linguagem R foi elaborada inicialmente com o objetivo específico de análises de dados, na qual muitas técnicas estatísticas, clássicas e modernas, podem ser implementadas, entre outras coisas não tão estatísticas. Algumas dessas técnicas estão implementadas no ambiente básico do R (“R base”), mas muitas estão implementadas em pacotes adicionais (“packages”).

O ambiente R foi desenvolvido baseado na linguagem S, no final da década de 90 início dos anos 2000. A sua estrutura de código aberto (que vem da linguagem S) e de software público e gratuito atraiu um grande número de desenvolvedores, sendo que há hoje inúmeros pacotes para o R (veja Introdução ao R para Análise de Dados em Consultoria Ambiental).

Para um excelente minicurso introdutório sobre o R clique aqui.

“Uma das coisas mais importantes que você pode fazer é dedicar um tempo para aprender uma linguagem de programação de verdade [e aprender a base teórica e estatística]. Aprender a programar é como aprender outro idioma: exige tempo e treinamento, e não há resultados práticos imediatos. Mas se você supera essa primeira subida íngreme da curva de aprendizado, os ganhos como cientista são enormes. Programar não vai apenas livrar você da camisa de força dos pacotes estatísticos, mas também irá aguçar suas habilidades analíticas e ampliar os horizontes de modelagem ecológica e estatística.”

— (Nicholas J. Gotelli em GOTELLI; ELLISON (2011))

Os softwares disponíveis para análise multivariada são diversificados. A maioria dos pacotes tem algumas das análises padrão, mas o R é necessário para fazer o melhor uso dos recentes avanços em aplicações ecológicas. A literatura,


por outro lado, alerta o ecologista numérico para as armadilhas do uso de computadores. A computação não garante (i) que os dados satisfaçam o método, e (ii) que os resultados sejam interpretados corretamente em termos ecológicos. Para isso, é necessária uma base teórica forte além de que os computadores não negam a necessidade de verificar a correção dos cálculos. Uma das ferramentas mais populares para análise de dados no R é o RStudio, uma interface de desenvolvimento integrada (IDE) que oferece recursos avançados para desenvolvimento, depuração e gerenciamento de projetos em R. Embora o RStudio seja uma ferramenta poderosa para análise de dados, é importante lembrar que a análise multivariada não depende apenas do software utilizado, mas também de uma base teórica forte e de verificação da correção dos cálculos. Além disso, a literatura alerta que o uso de computadores não garante a adequação dos dados ao método e a interpretação correta dos resultados em termos ecológicos. Portanto, é importante combinar o uso de ferramentas como o RStudio com uma sólida formação teórica e verificação rigorosa dos resultados.

3.3 O que é o R Studio?

O RStudio é um ambiente integrado de desenvolvimento (IDE) para a linguagem de programação R, projetado para ajudar os usuários a trabalhar com dados de forma mais eficiente e produtiva (Figura 3.1). Ele oferece uma ampla variedade de recursos e ferramentas para análise de dados, incluindo edição de código, visualização de gráficos, depuração, gerenciamento de projetos e colaboração. O RStudio é gratuito e de código aberto, disponível para Windows, Mac e Linux, e é usado por uma comunidade crescente de cientistas de dados, pesquisadores, analistas e desenvolvedores em todo o mundo. Ele oferece suporte para várias bibliotecas e pacotes do R, incluindo o *tidyverse*, que é uma coleção popular de pacotes para manipulação de dados e visualização. Com o RStudio, os usuários podem facilmente importar, manipular e visualizar dados, executar análises estatísticas e criar visualizações gráficas interativas. Além disso, o RStudio oferece a possibilidade de publicar relatórios e apresentações dinâmicas em diversos formatos, como HTML, PDF e Word, facilitando a comunicação e colaboração entre os usuários.

3.3.1 Licença de software

A licença de uso do RStudio depende da versão do software que está sendo utilizada. O RStudio oferece duas versões principais: a versão gratuita e a versão paga, conhecida como RStudio Pro. A versão gratuita do RStudio é licenciada sob a licença AGPLv3, o que significa que é um software de código aberto e livremente distribuível. Isso permite que os usuários baixem, modifiquem e distribuam o código-fonte do RStudio gratuitamente. No entanto, o uso comercial do RStudio sob a licença AGPLv3 pode ter algumas limitações, como a



O fato de o R ser um software de código aberto (**open source**) permite uma enorme quantidade de pacotes disponíveis. Como o código do R é público, qualquer pesquisador, programador ou instituição pode desenvolver novas funções, corrigir problemas, criar ferramentas especializadas e compartilhar pacotes com a comunidade.

Por essa razão, existem milhares de pacotes disponíveis para áreas muito diferentes, como:

Ecologia; Genética; Epidemiologia; Economia; Geoprocessamento; Aprendizado de máquina; Visualização de dados, e etc.

Grande parte desses pacotes é distribuída gratuitamente por repositórios como o CRAN (R CRAN) (R DEVELOPMENT CORE TEAM, 2017)).

Assim, o caráter aberto do R contribui diretamente para sua rápida expansão e para a formação de uma comunidade científica muito ativa.

3.3.2 R base vs. RStudio

O RStudio oferece diversas vantagens em relação ao uso do R base. Algumas dessas vantagens incluem:

1. Interface amigável: o RStudio possui uma interface gráfica amigável e intuitiva, com recursos como realce de sintaxe, sugestões de código e facilidade na navegação entre arquivos, o que torna o processo de desenvolvimento mais fácil e produtivo.
2. Facilidade de gerenciamento de projetos: o RStudio oferece ferramentas para gerenciamento de projetos, que permitem aos usuários organizar e controlar arquivos e scripts em um ambiente centralizado.
3. Depuração eficiente: o RStudio oferece recursos de depuração integrados, como pontos de interrupção e rastreamento de variáveis, que facilitam a identificação e correção de erros no código.
4. Suporte para colaboração: o RStudio permite que múltiplos usuários colaborem em um projeto, com recursos como controle de versão integrado e ferramentas para compartilhamento de código.
5. Integração com outras ferramentas: o RStudio integra-se com diversas ferramentas populares de análise de dados, como o Git e o LaTeX, permitindo uma maior eficiência e produtividade no processo de análise e geração de relatórios.

Essas são apenas algumas das vantagens que o RStudio oferece em relação ao R. É importante notar que, embora o RStudio seja uma ferramenta poderosa para análise de dados, ele não substitui a necessidade de conhecimento em R e estatística para obter resultados precisos e significativos.

3.4 O essencial

3.4.1 Interface do usuário

Uma interface de programa estatístico é uma ferramenta que permite que os usuários interajam com uma linguagem de programação de maneira mais amigável e visual. Essas interfaces geralmente apresentam uma interface gráfica do usuário (GUI) que oferece um ambiente integrado para a análise de dados. Os usuários podem importar dados, criar visualizações, executar análises

estatísticas e gerar relatórios. As interfaces de programa estatístico podem variar desde aplicativos de desktop autônomos até plug-ins para aplicativos de planilha, e muitos são desenvolvidos para atender a necessidades específicas de usuários em áreas como finanças, pesquisa médica, ciências sociais e outras. Essas interfaces tornam a análise de dados mais acessível a uma gama mais ampla de usuários, independentemente de sua experiência em programação ou estatística.

Linguagens de programação estatística de código aberto tem sido amplamente usadas em análises de dados e pesquisa em todo o mundo. Suas interfaces ou GUIs, embora poderosas, podem ser um pouco intimidadoras para novos usuários, uma vez que é necessário habilidades de programação básicas.

3.4.2 Interface do usuário do RStudio

A interface de usuário do RStudio é composta por várias janelas e painéis que permitem a interação com o R de forma organizada e intuitiva. A janela principal é dividida em quatro painéis (Figura 3.2):




Figure 3.2: Interface do usuário do ambiente integrado de desenvolvimento (IDE) RStudio para a linguagem de programação R com os termos em inglês e em português. O operador de atribuição (`<-`), um dos operadores mais utilizados no R pode ser chamado pela combinação `alt + -` (alt e a tecla menos).

Editor de código: é onde o usuário pode criar, editar e salvar scripts R. O editor fornece recursos como destaque de sintaxe, indentação automática, autocompletar e outras ferramentas úteis para a programação.

Console: é onde o usuário pode digitar comandos diretamente no R e ver a saída correspondente. É aqui que a maior parte da interação com o R ocorre.

Arquivos/Plots/Pacotes/Ajuda: este painel pode ser dividido em quatro subpainéis, cada um dos quais mostra uma guia diferente. O painel de arquivos permite a navegação pelos arquivos e pastas do computador. O painel de plots mostra gráficos gerados no R. O painel de pacotes permite a instalação, atualização e carregamento de pacotes do R. O painel de ajuda exibe informações sobre funções e pacotes do R.

Ambiente/Histórico/Git/Conexões: este painel também pode ser dividido em quatro subpainéis. O painel de ambiente exibe informações sobre variáveis e funções criadas no R. O painel de histórico mostra os comandos recentes digitados no console. O painel de Git permite que o usuário integre o RStudio com um repositório Git para controle de versão. O painel de conexões permite a conexão com bancos de dados e outros recursos externos.

A interface de usuário do RStudio também inclui uma barra de ferramentas na parte superior da janela, que fornece acesso rápido a comandos e recursos comuns. Além disso, há uma barra de menus padrão que permite o acesso a todas as opções e recursos do RStudio. No geral, a interface de usuário do RStudio é altamente personalizável e pode ser configurada para atender às necessidades específicas do usuário.

3.5 Mensagens de erro e avisos no R

No contexto da linguagem de programação R, mensagens de erro (errors) e mensagens de aviso (warnings) que aparecem em vermelho no painel de console. Elas são formas de feedback do sistema que indicam problemas ou situações potencialmente problemáticas durante a execução do código. Aqui está uma breve explicação de cada um:

1. Erro (Error):

- Um erro ocorre quando algo no código não está correto ou não pode ser executado como esperado.
- Isso pode ser causado por sintaxe incorreta, uso incorreto de funções, operações inválidas, referências a objetos que não existem, entre outros problemas.
- Quando ocorre um erro, a execução do código é interrompida e uma mensagem de erro é exibida no console em vermelho, indicando o tipo de erro e, muitas vezes, a linha onde ocorreu.

2. Aviso (Warning):

- Não indica erro. Um aviso é emitido quando algo no código pode resultar em um comportamento indesejado ou em resultados inesperados, mas não interrompe necessariamente a execução do código.

- Os avisos geralmente indicam situações que merecem atenção, como conversões de tipos de dados que podem perder informações ou funções que estão sendo usadas de maneira que pode levar a resultados questionáveis.
- Os avisos são exibidos em vermelho no console e fornecem informações sobre a natureza do aviso e, possivelmente, como abordá-lo.

É importante prestar atenção a mensagens de erro e avisos, pois eles fornecem insights sobre problemas em seu código ou potenciais fontes de comportamento inesperado. Resolver erros é fundamental para que o código funcione conforme o esperado. Embora os avisos não interrompam a execução, investigá-los pode ajudar a evitar problemas futuros ou melhorar a qualidade do código.

3.6 Prefira sempre códigos e scripts do que mouse e menus de janelas no R

Optar pelo uso de scripts e comandos de teclado no R, em vez das opções baseadas em mouse e menus das janelas, oferece várias vantagens significativas para quem está envolvido em análises de dados e programação. Aqui estão algumas justificativas para essa abordagem:

1. **Reprodutibilidade:** O uso de scripts permite que todas as etapas de análise e manipulação de dados sejam documentadas em um único lugar. Isso facilita a reexecução de todo o processo, tornando a análise reprodutível e permitindo que outras pessoas compreendam e validem o trabalho realizado.
2. **Automação:** Comandos de script podem ser facilmente repetidos ou adaptados para diferentes conjuntos de dados. Isso possibilita a automação de tarefas complexas, economizando tempo e reduzindo a possibilidade de erros manuais.
3. **Flexibilidade:** Enquanto as opções de mouse e menus podem ser limitadas em termos das ações específicas que permitem, os scripts oferecem uma flexibilidade muito maior. Você pode personalizar cada etapa do processo de análise de acordo com suas necessidades específicas.
4. **Eficiência:** A digitação de comandos é geralmente mais rápida do que navegar por menus e clicar em botões, especialmente quando se trata de tarefas repetitivas e/ou complexas.
5. **Controle total:** Ao utilizar scripts, você tem controle total sobre cada etapa do processo. Isso é particularmente importante em análises estatísticas, onde pequenas variações nos parâmetros podem ter um grande impacto nos resultados.

3.6. PREFIRA SEMPRE CÓDIGOS E SCRIPTS DO QUE MOUSE E MENUS DE JANELAS NO R39

6. **Aprendizado contínuo:** Escrever e modificar scripts permite um maior aprendizado e domínio da linguagem R. Conforme você ganha experiência, poderá realizar análises mais sofisticadas e explorar recursos avançados.
7. **Portabilidade:** Scripts podem ser facilmente compartilhados com outros pesquisadores ou colegas, independentemente do sistema operacional utilizado. Isso torna a colaboração mais fluida e ajuda a evitar problemas de compatibilidade.
8. **Melhor entendimento:** Ao escrever e ler scripts, você desenvolve uma compreensão mais profunda dos processos que está realizando. Isso é importante para identificar possíveis erros e interpretar corretamente os resultados.
9. **Documentação clara:** Ao escrever um script, você pode adicionar comentários explicativos que descrevem cada passo e sua lógica. Isso resulta em uma documentação clara e autoexplicativa do trabalho realizado.
10. **Consistência:** O uso de scripts promove a adoção de práticas consistentes em toda a análise, reduzindo a chance de erros causados por abordagens diferentes em momentos distintos.

Em resumo, a abordagem baseada em scripts e comandos de teclado oferece mais controle, flexibilidade, eficiência e reprodutibilidade, tornando-a a escolha preferida para profissionais que buscam análises de dados precisas, consistentes e de alta qualidade no ambiente R.

3.6.1 Projetos

Um ‘Projeto’ no RStudio é um conjunto de dados e arquivos de resultados associados entre si, junto com as opções e configurações no momento em que o Projeto foi salvo pela última vez. Quando você abre um projeto, esses arquivos são abertos e suas opções e configurações são restauradas da última vez. Você só pode ter um projeto aberto por vez, mas pode alternar facilmente entre eles abrindo um projeto salvo. Um projeto pode ter mais de um arquivo de dados associado. Se você tiver um projeto aberto e abrir ou criar qualquer arquivo nele, o projeto será considerado modificado. Ao sair do RStudio ou abrir um novo projeto, será perguntado se deseja salvar o projeto modificado. Para melhor gerenciamento de dados, você pode manter seus arquivos de projeto em seus próprios diretórios, separados do software RStudio. Ele lembra o nome do caminho completo para cada projeto. Os detalhes de como o RStudio gerencia diretórios e definições de gerenciamento de arquivos são fornecidos no sistema de Ajuda. Você pode redefinir o diretório padrão (working directory) para que o RStudio navegue até o diretório que você escolheu e abra os arquivos ou projetos que você encontrará no diretório escolhido.

3.6.2 Nomes de arquivos

Alguns dos tipos de extensão de arquivos que podem ser criados ou manipulados no RStudio incluem:

Arquivos de script: São arquivos de texto contendo código R, com extensões de arquivo como `.R`, `.Rmd`, `.Rnw`, `.Rhistory`, entre outros.

Arquivos de dados: São arquivos contendo dados que podem ser lidos e manipulados com o R, como `.csv`, `.txt`, `.xls`, `.xlsx`, `.rda`, `.rdata`, entre outros.

Arquivos de pacotes: São arquivos compactados que contêm código, documentação e dados necessários para um pacote do R, com extensão `.tar.gz`.

Arquivos de imagem: São arquivos de imagem gerados a partir de gráficos criados no R, com extensões como `.pdf`, `.png`, `.jpeg`, `.bmp`, entre outros.

Arquivos de projeto: São arquivos que contêm todas as informações necessárias para reproduzir um projeto R, incluindo arquivos de script, dados e outros recursos, com extensão `.Rproj`.

Esses são apenas alguns dos tipos de arquivos que podem ser usados ou gerados no RStudio. O RStudio também oferece suporte a muitos outros tipos de arquivos, como arquivos de ajuda, arquivos de instalação de pacotes, entre outros.

3.7 Preparação dos arquivos


Arquivos de dados multivariados são geralmente maiores e mais complexos do que outros, portanto, é necessário cuidado extra. Eles podem ser preparados de duas maneiras principais. A primeira forma é como a matriz completa de valores (`.xlsx`), onde cada linha mostra os valores de cada coluna. Isso é bom quando há poucos zeros. É assim que uma planilha funciona. A outra maneira, preferida pelos ecologistas para seus dados de espécies, é registrar apenas os valores diferentes de zero para cada espécie. Cada linha, representando uma unidade de amostragem, é então lida como uma lista de verificação ou registro quadrat. Este formato compacto (`.csv` ou `tab delimited`) é muito mais eficiente quando o tamanho da matriz de dados é muito grande. O RStudio considera as linhas no arquivo de dados como as unidades de amostragem e as colunas como as variáveis. Dependendo de quantos existem, pode ser mais conveniente inserir seus dados ao contrário e, em seguida, transpô-los para o RStudio. Veremos como fazer isso mais tarde.

3.7.1 Visualizar extensões de arquivos

Se você não está vendo as extensões (tipos de arquivos) no seu computador, siga os passos a seguir (no Windows 11) ou faça os ajustes para sua versão de Sistema Operacional.

No Windows Explorer (Explorador de Arquivos), clique no menu **Visualizar** no topo (se não estiver visível, clique nos três pontinhos ...), escolha a opção **Mostrar** e selecione **Extensões de nomes de arquivos**.

Como alternativa, no Explorador de Arquivos, clique no menu de três pontos (...) > **Opções** > guia **Modo de Exibição**, depois desmarque **Ocultar extensões para tipos de arquivo conhecidos**.



3.7.2 Formatos de arquivo de dados

Você pode usar qualquer editor de texto, processador de texto ou planilha para construir sua planilha de dados, embora seja recomendado o uso do Excel. No entanto, a entrada de dados no RStudio deve ser feita dentro do ambiente R por linha de comando. Os dados podem ser preparados no formato de planilha (spreadsheet), mas você deve seguir o formato cuidadosamente para saber onde e como colocar as informações nas células da planilha.

A seguir é apresentada a estrutura básica de uma matriz comunitária e como importar um arquivo XLS/XLSX para o RStudio usando a programação R (Figura 3.3). Como tudo no R, existem várias formas para se ler os arquivos Excel. Usaremos primeiro pacote `readxl` (que já vem instalado com o R base) (veja <https://www.tutorialkart.com/r-tutorial/r-read-excel-xls-xlsx/>)




Figure 3.3: Usaremos uma matriz multivariada (sítios x espécies, matriz comunitária) do PPBio. Identifique na figura abaixo os elementos que compõem uma matriz multivariada

3.7.3 O arquivo de espécies

Ao usar o formato de dados compacto, você viu que as variáveis (colunas) são numeradas, não nomeadas. Portanto, para aplicar um nome a eles, você precisa criar um arquivo de texto separado que contenha os códigos e nomes. Isso é mais útil quando as variáveis são espécies, uma vez que você pode ter um único arquivo de espécie que se aplica a todos os seus arquivos de dados e aos projetos.

O arquivo de espécies também inclui o nome completo da espécie, que é usado em alguns arquivos de resultados. Esta facilidade é obviamente muito útil para registro de campo quando você pode identificar a maioria das espécies. Leve a lista de espécies com você e apenas escreva o número do código em sua folha de dados. Observe também os seguintes guias de formato e regras para o arquivo de espécies.

Nomes de código curtos são recomendados para reduzir a superimposição de nomes em quaisquer resultados gráficos.

Os registros podem estar em qualquer ordem neste arquivo. (No entanto, você achará útil manter as espécies em ordem alfabética porque a maior parte dos outputs é ordenada pela sequência de espécies em seu arquivo de espécies.).

3.7.4 Formato de valores separados por vírgula (.csv)

Um arquivo ASCII de valores separados por vírgula (formato *.csv) também pode ser usado para importar / exportar dados do RStudio. Este formato de arquivo requer uma formatação muito cuidadosa.

3.7.5 Editando a matriz de dados

O RStudio fornece uma plethora de formas para edição de matrizes. Isso é mais útil para pequenas correções. Essas edições são salvas no formato de planilha para que você possa alternar entre a edição do arquivo e o software de planilha. Use a planilha para uma edição mais extensa de suas matrizes. Você pode fazer operações do tipo matriz facilmente na janela principal. A exclusão de linhas ou colunas, transformações e transposição e multiplicação de matrizes estão disponíveis com linhas de comando.

3.7.6 Arquivos de resultados

Para manter um registro completo de suas análises, é melhor anexar arquivos de resultados sucessivos a um arquivo de scripts nomeado. Faça isso salvando o arquivo de resultado e, então, após cada operação sucessiva, selecione Salvar script. Você também deve adquirir o hábito de inserir um título descritivo significativo (usando #) para cada análise. Isso fornece documentação adicional

de sua análise e aparece no script. As tabelas no arquivo de resultado são construídas com espaços, não tabulações. Portanto, o alinhamento das colunas no RStudio e nos processadores de texto só é obtido selecionando uma fonte de pitch-fixa, como Courier. Sendo arquivos de texto simples, você também pode pesquisar ou editar arquivos de resultados e scripts usando o R ou qualquer editor de texto.

Você pode exportar seus arquivos de resultado para sua planilha.

3.7.7 Gráficos

Você pode salvar imagens gráficas do RStudio como metarquivos do Windows (.wmf) ou metarquivos aprimorados (*.emf), usando linhas de comando ou a interface gráfica. Um gráfico salvo dessa forma é uma imagem vetorial que pode ser aberta em um pacote gráfico ou colada em processadores de texto e redimensionada ou editada sem perda de detalhes. No entanto, certifique-se de não alterar a proporção de aspecto ao redimensionar. Se o formato *.emf não for lido corretamente por seu outro software, tente salvar o gráfico no formato .wmf.

3.8 Conclusão

Foram apresentadas as três primeiras etapas da sequência abaixo, incluindo a preparação da importantíssima matriz de dados e como importá-la e exportá-la. Resumir os dados e decidir sobre o tratamento dos valores ausentes é um primeiro passo para a familiarização com conjuntos de dados multivariados.

3.9 Sequência típica na preparação e análise de dados

Para realizar uma análise multivariada, precisamos seguir uma sequência de etapas analíticas, como a seguir:

1. Entrada de dados e verificação de erros
Crie os arquivos de dados e espécies usando sua planilha ou editor de texto ou banco de dados. Verifique e archive uma cópia do seu arquivo de dados limpo.
2. Crie o arquivo de planilha .xlsx
Faça isso salvando a planilha ou importando outros formatos para o RStudio. Verifique se há erros de importação. Faça resumos para reproduzir seus registros de unidade de amostragem para dupla verificação.

3. Examine a estrutura básica dos dados
Use os comandos de sumários para examinar os valores de linha e coluna
4. Faça uma Análise de Outliers
Procure outliers. Examine as relações entre curvas de espécies e espécie-área.
5. Decida se/e como modificar os dados
Mesclar, particionar, transformar, podar, transpor matriz etc.
6. Fazer análises, ordenar e classificar (grupos)
Cada análise pode exigir o carregamento de várias matrizes principais e secundárias
7. Inspeccionar os resultados (gráficos e arquivos de resultados)

Salve e imprima os resultados

3.10 Material de apoio

3.11 TESTE SEUS CONHECIMENTOS



NOTA

Baixe esse arquivo de apoio (LISTA) e responda às questões. Se achar necessário, insira “chunks” de scripts do R, prints de tela ou cópias de gráficos, resultados ou mensagens de erro.

Apêndices

Sites consultados

Como importar dados do Excel para o R: [<https://youtu.be/U6ksXvvY6Q0>]

Como exportar dados do R para o Excel: [https://youtu.be/a7EJE_2mtGk]

Leitura suplementar

A multivariate analysis on spatiotemporal evolution of Covid-19 in Brazil (<https://doi.org/10.1016/j.idm.2020.08.012>)

Genetic markers in the playground of multivariate analysis (<https://www.nature.com/articles/hdy2008130>)

Referências

Part II

II. TEORIA

Chapter 4

Teoria 1 - Introdução à Análise Multivariada de Dados (AMD)

Introdução à Análise Multivariada de Dados (AMD)

Chapter 5

Teoria 2 - Tipos de dados usados em AMD

Tipos de dados usados em AMD

Apresentação

Os conjuntos de dados multivariados em ecologia são inerentemente grandes e de estrutura complexa. Existem várias maneiras de representá-los e, mais importante do que com estatísticas univariadas, decisões conscientes devem ser feitas sobre quais subconjuntos vamos analisar. Essas decisões refletem as perguntas que estamos fazendo. Há também a necessidade de considerar se quaisquer transformações e/ou padronizações precisam ser aplicadas antes da análise adequada. Novamente, essas operações de dados são influenciadas pelas perguntas que estamos fazendo. O que exatamente constitui o conjunto de ferramentas que chamamos de **análise multivariada** depende da disciplina em que se trabalha. Isso decorre da natureza dos dados comumente disponíveis para análise e do tipo de perguntas feitas em cada disciplina. Na ecologia, como em outras disciplinas, um conjunto dessas técnicas foi altamente ajustado para auxiliar na exploração de dados. A maioria deles se encaixa na rubrica de classificação ou ordenação.

Chapter 6

Teoria 3 - Relativizações e transformações de dados

Relativizações e transformações de dados

Apresentação

Referências

Part III

III. BASES DE DADOS

Chapter 7

Bases de dados. Dados do PPBio Semiárido

Exemplos de conjunto de dados ecológicos do Programa de Pesquisa em Biodiversidade (PPBio) do Semiárido

RESUMO

Para entender a distribuição das espécies de peixes e seu uso de habitat, uma série de variáveis ambientais foram avaliadas como preditores da composição e riqueza da assembleia de peixes em sistemas aquáticos tropicais semiáridos. Nós pesquisamos a composição de espécies de assembleias de peixes em sistemas aquáticos semiáridos e estabelecemos seu grau de associação com a estrutura do habitat aquático. Os locais consistiam em trechos de riachos com fluxo de água superficial, poças temporárias isoladas e reservatórios artificiais (açudes). A amostragem de peixes foi realizada em quatro ocasiões durante as estações chuvosa (abril e junho de 2006) e seca (setembro e dezembro de 2006).

Palavras-chave: rios intermitentes, reservatórios, conservação, composição de substratos.

7.1 Sobre os dados do PPBio

Usaremos ao longo desse livro dados que fazem parte de um estudo mais amplo sobre ecologia de rios do semiárido, coletados no Programa de Pesquisa em Biodiversidade - PPBio (Veja Programa de Pesquisa em Biodiversidade – PPBio).

Nesta base de dados estão armazenadas informações sobre diversos grupos taxonômicos distribuídos em diversas unidades amostrais (UA's ou sítios),

como peixes, macroinvertebrados bentônicos, quironomídeos e zooplâncton, além de dados do habitat, como variáveis físicas e químicas, morfologia do habitat, composição do substrato, estrutura de habitat marginal, entre outros (FIGUEIREDO et al., 2015; MEDEIROS et al., 2010; MEDEIROS et al., 2011; MEDEIROS et al., 2024; MEDEIROS; SILVA; RAMOS, 2008). Veja a seção Arquivos disponíveis a seguir, para baixar as bases de dados para esse curso.

Parte desses dados está armazenada em planilhas de Excel `ppbio**.xlsx` (Figura 7.1). Essas matrizes de dados são descritas na Tabela 7.1. As planilhas `ppbio**.xlsx` contém vários tipos de dados arranjados em matrizes $n \times m$ que incluem dados de abundância de espécies em diferentes unidades amostrais (UA's), dados da estrutura do habitat físico, e variáveis em escala de bacia hidrográfica, dados de contagem de indivíduos ajustados para Captura Por Unidade de Esforço (CPUE), etc (Figura 7.1).

#	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	S-RO	ap-divis	as-bimac	as-fasci	ch-bimac	cl-ocula	cl-orien	co-macro	co-heter	cr-menet	cu-legid	cy-gilbe	ga-brasi	he-margi	ho-malab	hyp-pusar	le-metan	le-plau
2	S-A2A1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	S-R-CC1	0	99	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
4	S-R-CT1	0	194	55	0	0	5	0	1	14	0	0	3	1	1	9	0	3
5	S-R-CP1	0	19	0	0	0	0	0	0	0	0	0	0	0	5	2	0	0
6	S-A-TA1	0	23	1	13	0	0	0	0	0	0	0	0	0	0	0	0	0
7	S-R-CT2	0	142	3	3	0	89	0	0	4	0	0	0	1	17	17	43	0
8	S-R-CP2	0	5	1	0	40	9	0	0	0	0	0	0	10	2	0	3	0
9	S-A-TA2	0	46	0	178	0	0	0	0	0	0	0	0	0	2	0	0	0
10	S-R-CT3	0	206	64	0	0	25	0	0	8	0	0	1	0	31	11	0	2
11	S-R-CP3	0	16	0	0	13	24	0	0	0	0	0	0	4	0	0	1	0
12	S-A-TA3	0	234	7	238	0	0	2	0	0	0	0	0	0	20	0	0	0
13	S-R-CT4	0	0	1	0	0	5	0	0	1	0	50	3	1	4	3	0	0
14	S-R-CP4	0	0	0	0	11	6	0	0	0	0	0	0	2	0	0	2	0
15	S-A-TA4	0	394	0	273	0	0	0	0	1	0	0	1	0	9	0	0	0
16	B-A-AU1	0	12	0	0	0	0	0	0	0	0	0	190	0	0	0	0	0
17	B-R-ET1	0	3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
18	B-A-GU1	0	2	2	0	0	0	0	0	0	0	0	7	0	0	0	0	0
19	B-R-FC1	5	44	0	0	2	0	0	0	0	0	0	8	0	0	0	2	0
20	B-A-AU2	0	99	0	0	0	0	0	0	0	0	0	67	0	1	0	0	0
21	B-A-GU2	0	0	0	0	0	0	0	0	0	0	0	23	0	0	0	0	0
22	B-R-FC2	22	75	7	0	4	0	0	0	0	21	0	16	0	2	1	0	0
23	B-A-AU3	0	511	0	0	0	0	0	0	0	0	0	145	0	0	0	0	0
24	B-A-GU3	0	6	0	0	0	0	0	0	0	0	0	32	0	0	0	0	0
25	B-R-FC4	0	7	17	0	0	0	0	0	0	0	81	5	0	1	0	0	0
26	B-A-AU4	0	235	0	0	0	0	0	0	0	0	0	509	0	0	0	0	0
27	B-A-GU4	0	13	0	0	0	0	0	0	0	0	0	10	0	0	0	0	0

Figure 7.1: Parte da planilha de dados brutos do PPBio.

Por exemplo, essa é a **matriz bruta de dados**, porque os valores ainda não foram ajustados para os valores de Captura Por Unidade de Esforço (CPUE), nem foram relativizados ou transformados. Outros tipos de arquivos existem sobre esses dados (Tabela 7.1).

Várias das espécies nessa matriz tem grande importância ecológica, como é o caso de *Astyanax bimaculatus*¹ (Figura 7.2), que é muito comum em rios intermitentes e serve de alimento para predadores maiores (SILVA; DUARTE; MEDEIROS, 2018) como a espécie *Hoplias malabaricus*² (Figura 7.3) (SILVA et al., 2010).

Outras espécies como *Apareiodon hasemani*³ (Figura 7.4 tem importância trófica por estar na base da cadeia alimentar, enquanto espécies da família Lori-

¹A etimologia do gênero *Astyanax* vem da mitologia Grega. Heitor personagem da “Ilíada”, tinha um filho chamado Astíanax.

²Do Grego, *hoplon*, arma ou armadura, em referência aos dentes caniniformes muito desenvolvidos, e forte estrutura óssea na cabeça.

³A etimologia do nome *Apareiodon* vem do Grego, *a*, sem, *pareia*, lateral ou bochecha, e *odous* dentição, em referência a ausência de dentes laterais no aparato bucal dessa espécie.”



Figure 7.2: **Astyanax bimaculatus**, a espécie mais comum da matriz de dados ppbio. Peru, by Eakins, R. Fonte: <<https://www.fishbase.se/summary/Astianax-bimaculatus.html>>



Figure 7.3: **Hoplias malabaricus**, espécie que cresce para se tornar um importante predador. Brazil, by Roselet, F.F.G. Fonte: <<https://www.fishbase.se/summary/Hoplias-malabaricus.html>>

cariidae, como *Pseudancistrus genisetiger*⁴ (Figura 7.5), tem importância para taxonomia.



Figure 7.4: *Apareiodon sp.*, importante espécie bentopelágica das bacias dos rios Jaguaribe e Paraíba. Brazil, by Ramos, T.P.A. Fonte: <<https://www.fishbase.se/summary/Apareiodon-davisi.html>>

As planilhas `ppbio**.xlsx` contém o delineamento amostral de um dos estudos do Projeto PPBio (Figura 7.6). Nas linhas são apresentadas as abreviações dos nomes das unidades amostrais (UA's) e nas colunas são apresentados os nomes abreviados das espécies - temos portando uma matriz comunitária (Tabela 7.1). No corpo da planilha temos os valores para o tipo de dados amostrado. Quantitativo, semi-quantitativo ou qualitativo.

Qual desses tipos de dados você acha que é apresentado na planilha?

7.2 Arquivos disponíveis

A seguir, apresento uma tabela com as informações essenciais sobre as matrizes de dados que serão utilizadas ao longo deste livro (Tabela 7.1). Nela, estão descritos os diferentes tipos de matrizes, suas finalidades analíticas e o tipo de dado para cada uma delas. Essas informações servirão de referência para compreender a origem, a estrutura e o tratamento recomendado para os dados empregados nas análises subsequentes.

⁴A etimologia do nome *Pseudancistrus* vem do Grego, *pseudes*, falso, e *agkistron*, gancho, em referência a falsos ganchos presentes na cabeça em algumas espécies do gênero.



Figure 7.5: *Pseudancistrus genisetiger*, uma espécie endêmica das bacias hidrográficas do nordeste. By Medeiros, E.S.F. Fonte: Arquivo pessoal

Você pode baixar essas matrizes clicando no link para o arquivo em **.xlsx** na coluna **Arquivo**. Ao visualizar a matriz que deseja baixar, clique em **Arquivo > Baixar > Microsoft Excel (.xlsx)**. Atente para a pasta onde seu computador baixa o arquivo desejado, você vai precisar dessa informação depois.

ou

Table 7.2: Matrizes disponíveis para análises, com suas descrições e tipos de dados recomendados.

Arquivo	Tipo de matriz	Descrição	Tipo de dados
ppbio06c-peixes.xlsx ppbio06c-peixes.ods	Matriz comunitária	O arquivo ppbio06 traz os dados brutos contendo 26 localidades $\times$ 35 espécies.	Contagens de indivíduos amplitude de variação; recomenda-se matriz rela
ppbio06p-peixes.xlsx	Matriz comunitária	Dados particionados contendo 24 localidades $\times$ 35 espécies.	Contagens de indivíduos amplitude de variação; recomenda-se matriz rela
ppbio06p-amb.xlsx	Matriz ambiental	26 localidades $\times$ 35 variáveis ambientais.	Variáveis em diferentes u recomenda-se transforma reescalonamento.
ppbio06-grupos.xlsx ppbio06cpue- peixes.xlsx	Matriz de grupos Matriz comunitária	Grupos amostrais utilizados nas análises. Abundâncias ajustadas pela CPUE.	Dados categóricos. Densidades de indivíduos recomenda-se matriz rela




Figure 7.6: Associação entre a planilha de dados brutos do PPBio e o delineamento amostral do estudo.

7.2.1 Codificação das variáveis

Os arquivos da base de dados do projeto são fornecidos em formato Excel (.xlsx). Por exemplo, o arquivo `ppbio06-*.xlsx`, traz os dados brutos que serão usados nas análises. A matriz de dados brutos contém mais de 20 localidades (m=linhas ou objetos) em estações do ano diferentes, e cerca de 35 espécies (n=colunas ou atributos), antes de qualquer modificação. Portanto é uma matriz bruta. Os valores são contagens de indivíduos, e apresentam uma alta amplitude de variação, portanto, o uso de uma matriz relativizada é sugerido (Tabela 7.1). Nos nomes dos objetos e dos atributos são codificados de acordo com a tabela mostrada na Figura 7.7.

Espécies de peixes	Sítios e período de amostragem
ap-davis: <i>Apareiodon hasemani</i> as-bimac: <i>Astyanax bimaculatus</i> as-fasci: <i>Astyanax fasciatus</i> ch-bimac: <i>Characidium bimaculatum</i> ci-ocela: <i>Cichla ocellaris</i> ci-orien: <i>Cichlasoma orientale</i> co-macro: <i>Colossoma macropomum</i> co-hetero: <i>Compsura heterura</i> cr-menez: <i>Crenicichla menezesi</i> cu-lepid: <i>Curimatella lepidura</i> cy-gilbe: <i>Cyphocharax Gilbert</i> ge-brasi: <i>Geophagus brasiliensis</i> he-margi: <i>Hemigrammus marginatus</i> ho-malab: <i>Hoplias malabaricus</i> hy-pusar: <i>Hypostomus pusarum</i> le-melan: <i>Leporinus melanopleura</i> le-piau: <i>Leporinus piau</i> le-taeni: <i>Leporinus taeniatus</i> mo-costa: <i>Moenkhausia costae</i> mo-lepid: <i>Moenkhausia sp1</i> or-nilot: <i>Oreochromis niloticus</i> pa-manag: <i>Parachromis managuensis</i> pimel-sp: <i>Pimelodella enochi</i> po-retic: <i>Poecilia reticulata</i> po-vivip: <i>Poecilia vivipara</i> pr-brevi: <i>Prochilodus brevis</i> ps-losango: <i>branquinha</i> ps-rhomb: <i>Psectrogaster rhomboides</i> ps-genise: <i>Pseudancistrus papariae</i> se-heter: <i>Serrapinnus heterodon</i> se-plaba: <i>Serrapinnus plaba</i> se-spilo: <i>Serrasalmus rhombeus</i> st-noton: <i>Steindachnerina notonota</i> sy-marmo: <i>Synbranchus marmoratus</i> te-chalc: <i>Tetragopterus chalcus</i> tr-signa: <i>Triportheus signatus</i>	Nos códigos dos sítios está o desenho amostral. Duas áreas, ao norte o Seridó (S) e ao sul Buíque (B). Em cada área existem dois tipos de ambiente, açude (A) e rio (R). Ao norte estão três sítios, TA, CP e CT, e ao sul três sítios, PC, MU e GU. Em cada sítio há quatro amostragens por ano, trimestre 1, 2, 3 e 4. Resumo: S: Seridó B: Buíque A: Açude R: Rio TA: Açude Recanto CP: Riacho Cipó CT: Riacho Catureré PC: Riacho Poço da Cruz MU: Açude Mulungu GU: Açude Gurjão 1: 1o. trimestre 2: 2o. trimestre 3: 3o. trimestre 4: 4o. Trimestre Exemplo: A amostra S-R-CP-1 representa, a região Seridó (S), um ambiente de rio (R), o sítio riacho Cipó (CP), no primeiro trimestre do ano (1).

Figure 7.7: Codificação para as variáveis, espécies de peixes, sítios de amostragem e período de amostragem

7.2.2 Abreviações

No interesse de sistematizar o código R das várias matrizes que são comumente usadas em uma AMD, a tabela 7.3, a seguir, resume seus tipos e abreviações.

```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

Referências

Table 7.1: Matrizes disponíveis para análises, com suas descrições e tipos de dados recomendados.

Arquivo	Tipo de matriz	Descrição	Tipo de dados
ppbio06c-peixes.xlsx ppbio06c-peixes.ods	Matriz comunitária	O arquivo ppbio06 traz os dados brutos que serão usados nas análises. A matriz de dados brutos contendo 26 localidades em estações do ano diferentes (objetos) x 35 espécies (atributos), antes de qualquer modificação.	Contagens de indivíduos com alta amplitude de variação, sugerido uso de matriz relativizada.
ppbio06p-peixes.xlsx	Matriz comunitária	O arquivo ppbio06 traz os dados particionados que serão usados nas análises. A matriz de dados contendo 24 localidades em estações do ano diferentes (objetos) x 35 espécies (atributos), antes de qualquer modificação.	Contagens de indivíduos com alta amplitude de variação, sugerido uso de matriz relativizada.
ppbio06p-amb.xlsx	Matriz ambiental	O arquivo traz os dados brutos que serão usados nas análises. A matriz de dados brutos contendo 26 localidades em estações diferentes (objetos) x 35 variáveis ambientais (atributos) medidas em diferentes escalas espaciais, antes de qualquer modificação.	Unidades de medição diferentes (cm, m, °C, mg/L, etc.), com alta amplitude de variação, sugerido uso de matriz transformada e/ou reescalada.
ppbio06-grupos.xlsx	Matriz de grupos	O arquivo ppbio06 traz os dados brutos que serão usados nessa análise. A matriz de dados brutos contendo 26 locais/ocasiões	Contagens de indivíduos com alta amplitude de variação, sugerido uso de matriz

Table 7.3: Nomenclatura das matrizes em AMD em relação aos atributos das colunas e suas abreviações nos códigos do R.

Nome	Atributos (colunas)	Abreviação no R
Matriz comunitaria	Os atributos são táxons ou OTU's (Unidades Taxonômicas Operacionais) (ex. espécies, gêneros, morfotipos)	m_com
Matriz ambiental	Os atributos são dados ambientais e variáveis físicas e químicas (ex. pH, condutividade, temperatura)	m_amb
Matriz de habitat	Os atributos são elementos da estrutura do habitat (ex. macrófitas, algas, pedras, lama, etc)	m_hab
Matriz bruta	Os atributos ainda não receberam nenhum tipo de tratamento estatístico (valores brutos, como coletados)	m_bruta
Matriz transposta	Os atributos foram transpostos para as linhas	m_t
Matriz relativizada	Os atributos foram relativizados por um critério de tamanho ou de variação (ex. dividir os valores de cada coluna pela soma)	m_rel, m_relcol, m_rellin
Matriz transformada	Foi aplicado um operador matemático a todos os atributos (ex. raiz quadrada, log)	m_trns, m_log10, m_asrq
Matriz de distâncias	Matriz de m x m similaridades ou de distâncias (ex. Euclidiana, Manhattan, Bray-Curtis, etc)	m_dists, m_euclid, m_bray
Matriz de trabalho	Qualquer matriz que seja o foco da análise atual (ex. comunitária, relativizada, etc)	m_trab
Matriz particionada	Foram removidas linhas ou colunas (ex. linhas que são outliers e espécies zeradas)	m_part
Base de dados	Arquivo do Excel planilhado a partir de dados de campo ou de laboratório. Será manejada e particionada no R, para criar a Matriz bruta	ppbio06.xlsx, zoore- bio.xlsx, ben- tos06.xlsx

Chapter 8

Base de dados I - Peixes

Estrutura da Comunidade: Peixes no semiárido

Apresentação

Exemplo de conjunto de dados ecológicos do Programa de Pesquisa em Biodiversidade (PPBio) do Semiárido. Ano de 2006. Peixes¹.

Autor:

- Prof. Elvio S. F. Medeiros
- Laboratório de Ecologia
- Universidade Estadual da Paraíba
- Campus V, João Pessoa, PB

Para entender a distribuição das espécies de peixes e seu uso de habitat, uma série de variáveis ambientais foram avaliadas como preditores da composição e riqueza da assembleia de peixes em sistemas aquáticos tropicais semiáridos. Nós pesquisamos a composição de espécies de assembleias de peixes em sistemas aquáticos semiáridos e estabelecemos seu grau de associação com a estrutura do habitat aquático. Os locais consistiam em trechos de riachos com fluxo de água superficial, poças temporárias isoladas e reservatórios artificiais (açudes). A amostragem de peixes foi realizada em quatro ocasiões durante as estações chuvosa (abril e junho de 2006) e seca (setembro e dezembro de 2006).

Texto modificado de MEDEIROS et al. (2024): Environmental variables as predictors of fish community composition in semiarid aquatic systems. *Acta Limnologica Brasiliensia*, 2024, vol. 36, e4. <https://doi.org/10.1590/S2179-975X3023>. ISSN 2179-975X on-line version. Tradução: Google Translator.

¹Projeto financiado pelo CNPq/UEPB/DCR Proc.350082/2006-5, UEPB/FAPESQ Proc.68.0006/2006.0 e Projeto de Pesquisa em Biodiversidade do Semiárido (PPBio Semi-Árido)

Elvio Sergio Figueredo Medeiros¹, Marcio Joaquim da Silva², Telton Pedro Anselmo Ramos² e Robson Tamar Costa Ramos^{1,3}

¹ Grupo Ecologia de Rios do Semiárido, Universidade Estadual da Paraíba, Depto. de Biologia. Campus V. CEP 58070-450 João Pessoa - PB. Brazil.

² Universidade Federal do Rio Grande do Norte, Depto. de Biologia, Centro de Biociências, CEP 59078-900 – Natal - RN. ³ Laboratório de Sistemática e Morfologia de Peixes, Universidade Federal da Paraíba, Depto. de Sistemática e Ecologia, CCEN, CEP 58059-900, João Pessoa - PB.

- Autor correspondente: Dr. Elvio Medeiros <https://orcid.org/0000-0002-7472-8147>. Universidade Estadual da Paraíba, João Pessoa - Paraíba – Brasil - CEP 58.070-450. E-mail: elviomedeiros@servidor.uepb.edu.br

RESUMO

Para compreender a distribuição das espécies de peixes e o uso do habitat, uma série de variáveis ambientais foram avaliadas como preditores da composição de montagem de peixes e riqueza em sistemas aquáticos semiáridos tropicais. Pesquisamos a composição das espécies de conjuntos de peixes em sistemas aquáticos semiáridos e estabelecemos seu grau de associação com a estrutura do habitat aquático. Os locais consistiam em córregos com fluxo de água superficial, piscinas temporárias isoladas e reservatórios feitos pelo homem. A amostragem de peixes foi realizada em quatro ocasiões durante as estações úmidas (abril e junho de 2006) e secas (setembro e dezembro de 2006). A regressão múltipla de tepwise mostrou que as variáveis morfométricas, largura de alcance do córrego, comprimento do córrego e elevação explicaram 75,6% da variação da riqueza dos peixes. Cobertura de macrófitas e vegetação pendente somado ao poder preditivo da equação do modelo, onde o modelo final explicou 86,9% da variação da riqueza dos peixes. A Análise de Correspondência Canônica mostrou uma relação significativa entre os dados de composição do peixe e a morfologia do local (altitude, inclinação do banco e profundidade litorânea). Entre a qualidade da água, a composição do habitat e as variáveis substrato, temperatura, areia e cascalho apresentaram maior correlação com os eixos CCA. Esses resultados indicam que as comunidades de peixes assumem diferentes estruturas e composições em diferentes tipos de habitat, de acordo com a heterogeneidade ambiental nos sistemas aquáticos de terra seca.

Palavras-chave: fluxos intermitentes, reservatórios, conservação, composição de substratos.

8.1 Introdução

Padrões de distribuição de espécies de peixes dentro dos ecossistemas são frequentemente explicados em termos da estrutura do habitat disponível (Jun-

queira et al., 2016). O habitat é frequentemente relatado como estruturas subaquáticas físicas, como rochas, madeira submersa, macrófitas, algas, etc, e como cobertura (ou proteção aérea) fornecida por características litorâneas, que incluem vegetação costeira ou troncos pendurados nas margens do córrego (Stewart-Koster et al., 2007). Indiscutivelmente, a qualidade e a quantidade do habitat afetam a estrutura e a composição das comunidades de peixes (Vono e Barbosa, 2001), por mudanças nas profundidades da água, velocidade e, consequentemente, tipo substrato, características litorâneas (como vegetação suspensa) e estruturas subaquáticas (Stewart-Koster et al., 2007, Medeiros e Arthington, 2011). Comumente, esses fatores são integrados e os habitats tendem a variar e segregar-se em manchas hierárquicas discretas (Frissell et al., 1986). Apesar disso, o habitat físico dos sistemas aquáticos de água doce em todo o mundo foi degradado ou modificado pelas atividades humanas (Hall et al., 2002). Tal interferência muitas vezes resulta da conversão de sistemas lóticos em lênticos, que mudam a dinâmica do habitat e seu funcionamento (Bunn e Arthington, 2002).

Uma série de estudos relacionam a estrutura da comunidade biótica (número de espécies e distribuição de abundância) e o habitat marginal físico. Tais estudos mostram que tipos de habitat mais complexos fornecem condições favoráveis para os peixes, como substrato de crescimento, locais de desova, bem como alimentos e proteção contra predação (Pusey e Arthington, 2003, Cucherousset et al., 2007, Jeffres et al., 2008) e, portanto, uma maior diversidade de microhabitats associados às características litorâneas tem sido ligada a uma maior diversidade de espécies (Casatti et al., 2012). Como resultado, o fato de diferentes espécies de peixes apresentarem preferências particulares para diferentes tipos de habitat, cria padrões locais de composição de conjuntos de espécies (Junqueira et al., 2016). No entanto, o que leva a presença de espécies a tipos específicos de habitat muitas vezes não é claro.

Nos sistemas de riacho em regiões secas, espera-se que suas amplas variações espaciais e temporais levem a habitats físicos variáveis e, portanto, padrões específicos de estrutura de habitat (Hodges e Magoulick, 2011). Espera-se que a riqueza e a composição dos peixes sigam tais mudanças. Nesses sistemas, o habitat físico é espacial e temporalmente dinâmico devido à interação da morfologia do canal de córrego (por exemplo, largura, profundidade e substrato) e da variabilidade hidrológica (Medeiros et al., 2008, Farias et al., 2012). O estado do habitat físico a um determinado alcance será, portanto, influenciado por fatores que operam em diferentes escalas (Meninos e Thoms, 2006). No nível de captação, geomorfologia e clima afetam hidrologia, deposição de sedimentos, insumos de nutrientes e morfologia do canal (Davies et al., 2000, Mugodo et al., 2006). A nível local, características físicas e químicas da água, o uso da terra e o manejo da terra influenciarão o habitat de alcance do córrego (Hodges e Magoulick, 2011).

É importante ressaltar que a relação entre variáveis de habitat físico e riqueza e distribuição de espécies de peixes tem sido investigada em sistemas lúdicos e

loticos tropicais (por exemplo, Vono e Barbosa, 2001, Casatti et al., 2012), mas essa relação para as comunidades de peixes semiáridos permanece amplamente desconhecida. Este trabalho mede a riqueza de peixes e a composição de espécies em diversos habitats aquáticos em córregos intermitentes do Semiárido Brasil, a fim de avaliar a composição das espécies de conjuntos de peixes e estabelecer seu grau de associação com a estrutura do habitat aquático. Temos a hipótese de que a fauna de peixes é irregular com as montagens representando características locais do habitat e que as variáveis ambientais serão elementos importantes explicando a distribuição de peixes.

8.1.1 Desenho Amostral

Este estudo foi realizado na região semiárida brasileira, em bacias hidrográficas que fluem através de uma floresta aberta arbustiva seca decidual (a “Caatinga”). A amplitude térmica é baixa na área de estudo, com médias variando de aproximadamente 25 a 30 °C, e a precipitação média anual varia entre 600 e 1100 mm. As altitudes variam entre 100 e 1000 m (Figura 8.1).




Figure 8.1: Área de estudo mostrando os estados do Rio Grande do Norte (RN), Paraíba (PB), Pernambuco (PE) e Alagoas (AL), principais sistemas fluviais e pontos de amostragem na região semiárida do Brasil. TA, açude Recanto; CP, riacho Cipó; CT, riacho Catureré; PC, riacho Poço da Cruz; MU, açude Mulungu e GU, açude Gurjão.

Duas regiões de importância biológica (**Seridó, S** e **Buíque, B**) foram escolhidas e nelas, **seis locais** ou sítios de coleta (**TA, CP, CT, PC, MU, e GU**) foram selecionados para representar ambientes Unidades Amostrais de

ambientes temporários naturais e artificiais típicos (Figura 8.1 e Figura 8.6).

Os locais consistiam em trechos de **riachos (-R)** com fluxo de água superficial (durante a estação chuvosa) ou poças temporárias isoladas (durante a estação seca) e **reservatórios ou açudes (-A)** artificiais criados a partir do represamento de riachos. A amostragem foi realizada durante o ano de 2006 em **quatro ocasiões** durante as estações chuvosa (**abril, 1 e junho, 2**) e seca (**setembro, 3 e dezembro, 4**) (Figura 8.1 e Figura 8.6).

Várias das espécies desse estudo tem grande importância ecológica, como é o caso de *Astyanax bimaculatus*² (Figura 8.2), que é muito comum em rios intermitentes e serve de alimento para predadores maiores como a espécie *Hoplias malabaricus*³ (Figura 8.3).



Figure 8.2: **Astyanax bimaculatus**, a espécie mais comum da matriz de dados ppbio. Peru, by Eakins, R. Fonte: <<https://www.fishbase.se/summary/Astianax-bimaculatus.html>>

Outras espécies como *Apareiodon hasemani*⁴ (Figura 8.4 tem importância trófica por estar na base da cadeia alimentar, enquanto espécies da família Loricariidae, como *Pseudancistrus genisetiger*⁵ (Figura 8.5), tem importância para

²A etimologia do gênero *Astyanax* vem da mitologia Grega. Heitor personagem da “Ilíada”, tinha um filho chamado Astíanax.

³Do Grego, *hoplon*, arma ou armadura, em referência aos dentes caniniformes muito desenvolvidos, e forte estrutura óssea na cabeça.

⁴A etimologia do nome *Apareiodon* vem do Grego, *a*, sem, *pareia*, lateral ou bochecha, e *odous* dentição, em referência a ausência de dentes laterais no aparato bucal dessa espécie.

⁵A etimologia do nome *Pseudancistrus* vem do Grego, *pseudes*, falso, e *agkistron*, gancho, em referência a falsos ganchos presentes na cabeça em algumas espécies do gênero.



Figure 8.3: **Hoplias malabaricus**, espécie que cresce para se tornar um importante predador. Brazil, by Roselet, F.F.G. Fonte: <<https://www.fishbase.se/summary/Hoplias-malabaricus.html>>

taxonomia.

8.2 Codificação das variáveis

Os arquivos da base de dados do projeto são fornecidos em formato Excel (.xlsx). Por exemplo, o arquivo `ppbio06*-peixes.xlsx`, traz os dados brutos que serão usados nas análises. A matriz de dados brutos contém mais de 20 localidades (n =linhas ou objetos) em estações do ano diferentes, e cerca de 35 espécies (m =colunas ou atributos), antes de qualquer modificação. Portanto é uma matriz bruta. Os valores são contagens de indivíduos, e apresentam uma alta amplitude de variação, portanto, o uso de uma matriz relativizada é sugerido. Nos nomes dos objetos e dos atributos são codificados de acordo com a tabela mostrada na Figura 8.6.

8.3 Amostragem dos dados

As coletas de peixes foram realizadas utilizando-se quatro tipos diferentes de equipamentos de amostragem, durante o dia, e de acordo com Medeiros et al (2010):



Figure 8.4: **Apareiodon sp.**, importante espécie bentopelágica das bacias dos rios Jaguaribe e Paraíba. Brazil, by Ramos, T.P.A. Fonte: <<https://www.fishbase.se/summary/Apareiodon-davisi.html>>



Figure 8.5: **Pseudancistrus genisetiger**, uma espécie endêmica das bacias hidrográficas do nordeste. By Medeiros, E.S.F. Fonte: Arquivo pessoal

Espécies de peixes	Sítios e período de amostragem
ap-davis: Apareiodon hasemani as-bimac: Astyanax bimaculatus as-fasci: Astyanax fasciatus ch-bimac: Characidium bimaculatum ci-ocela: Cichla ocellaris ci-orien: Cichlasoma orientale co-macro: Colossoma macropomum co-hetero: Compsura heterura cr-menez: Crenicichla menezesi cu-lepid: Curimatella lepidura cy-gilbe: Cyphocharax Gilbert ge-brasi: Geophagus brasiliensis he-margi: Hemigrammus marginatus ho-malab: Hoplias malabaricus hy-pusar: Hypostomus pusarum le-melan: Leporinus melanopleura le-piau: Leporinus piau le-taeni: Leporinus taeniatus mo-costa: Moenkhausia costae mo-lepid: Moenkhausia sp1 or-nilot: Oreochromis niloticus pa-manag: Parachromis managuensis pimel-sp: Pimelodella enochi po-retic: Poecilia reticulata po-vivip: Poecilia vivipara pr-brevi: Prochilodus brevis ps-losango: branquinha ps-rhomb: Psectrogaster rhomboides ps-genise: Pseudancistrus papariae se-heter: Serrapinnus heterodon se-piaba: Serrapinnus piaba se-spilo: Serrasalmus rhombeus st-noton: Steindachnerina notonota sy-marmo: Synbranchus marmoratus te-chalc: Tetragonopterus chalcus tr-signa: Triportheus signatus	Nos códigos dos sítios está o desenho amostral. Duas áreas, ao norte o Seridó (S) e ao sul Buíque (B). Em cada área existem dois tipos de ambiente, açude (A) e rio (R). Ao norte estão três sítios, TA, CP e CT, e ao sul três sítios, PC, MU e GU. Em cada sítio há quatro amostragens por ano, trimestre 1, 2, 3 e 4. Resumo: S: Seridó B: Buíque A: Açude R: Rio TA: Açude Recanto CP: Riacho Cipó CT: Riacho Catureré PC: Riacho Poço da Cruz MU: Açude Mulungu GU: Açude Gurjão 1: 1o. trimestre 2: 2o. trimestre 3: 3o. trimestre 4: 4o. Trimestre Exemplo: A amostra S-R-CP-1 representa, a região Seridó (S), um ambiente de rio (R), o sítio riacho Cipó (CP), no primeiro trimestre do ano (1).

Figure 8.6: Codificação para as variáveis, espécies de peixes, sítios de amostragem e período de amostragem.

Environmental variables as predictors of fish community...

Table 2. Abundance, percentage and frequency of occurrence (F.O.) of species collected in the study sites in the semi-arid region of Brazil. Seridô stream (SE), Cipó stream (CI) and Recanto reservoir (RE) (Piranhas-Açu catchment), Escama-Peixe stream (EP Moxotó River), Mulungu reservoir (MU, Ipanema River) and Salobro reservoir (SA, Una River).

	SE	CI	RE	EP	MU	SA	%	F.O.
Characiformes								
Curimatidae								4.1
<i>Curimatella lepidura</i> (Eigenmann & Eigenmann, 1889)	0	0	0	21	0	0	0.2	4.3
<i>Psectrogaster rhomboides</i> Eigenmann & Eigenmann, 1889	1	0	0	0	0	0	0.01	4.3
<i>Steindachnerina notonota</i> (Miranda-Ribeiro, 1937)	205	0	0	0	0	0	2.3	17.4
<i>Cyphocharax gilbert</i> (Quoy & Gaimard, 1824)	50	0	0	81	0	0	1.5	8.7
Parodontidae								0.3
<i>Apareiodon hasemani</i> Eigenmann, 1916	0	0	0	27	0	0	0.3	8.7
Prochilodontidae								3.1
<i>Prochilodus brevis</i> Steindachner, 1874	243	5	6	15	1	0	3.1	47.8
Anostomidae								0.2
<i>Leporinus plau</i> Fowler, 1941	6	6	2	1	0	0	0.2	34.8
<i>Leporinus melanopleura</i> Günther, 1864	0	0	0	2	0	0	0.02	4.3
<i>Leporinus taeniatus</i> Lütken, 1875	0	0	0	1	0	0	0.01	4.3
Crenuchidae								8.1
<i>Characidium bimaculatum</i> Fowler, 1941	3	0	702	0	0	0	8.1	21.7
Characidae								36.6
<i>Astyanax bimaculatus</i> (Linnaeus, 1758)	542	40	697	126	857	21	26.1	87.0
<i>Astyanax fasciatus</i> (Cuvier, 1819)	123	1	8	24	0	2	1.8	43.5
<i>Colossoma macropomum</i> (Cuvier 1816) *	0	0	2	0	0	0	0.02	4.3
<i>Compsura heterura</i> Eigenmann, 1915	1	0	0	0	0	0	0.01	4.3
<i>Hemigrammus marginatus</i> Ellis, 1911	2	0	0	0	0	0	0.02	8.7
<i>Moenkhausia costae</i> (Steindachner, 1907)	0	0	0	1	0	0	0.01	4.3
<i>Moenkhausia</i> sp.	40	0	0	0	0	0	0.5	8.7
<i>Serrapinnus heterodon</i> (Eigenmann, 1915)	141	17	4	134	0	0	3.4	43.5
<i>Serrapinnus piaba</i> (Lütken, 1875)	68	0	0	0	0	0	0.8	4.3
<i>Serrasalminus rhombeus</i> (Linnaeus, 1766)	1	0	0	0	0	0	0.01	4.3
<i>Tetragonopterus chalcus</i> Spix & Agassiz, 1829	0	0	0	134	0	0	1.5	8.7
<i>Triplotheus signatus</i> (Garman, 1890)	181	0	0	27	0	0	2.4	26.1
Erythrinidae								1.2
<i>Hoplias malabaricus</i> (Bloch, 1794)	53	21	31	3	1	0	1.2	60.9
Siluriformes								
Loricariidae								0.8
<i>Hypostomus pusarum</i> (Starks, 1913)	66	4	0	1	0	0	0.8	30.4
<i>Pseudoclinostomus papariae</i> Fowler 1941	1	0	0	0	0	0	0.01	4.3
Heptapteridae								0.1
<i>Pimelodella enochi</i> Fowler, 1941	6	0	0	0	0	0	0.1	4.3
Cyprinodontiformes								
Poeciliidae								15.2
<i>Poecilia reticulata</i> Peters, 1860 *	25	0	0	0	322	0	4.0	21.7
<i>Poecilia vivipara</i> Bloch & Schneider, 1801	622	137	0	0	219	0	11.2	47.8
Synbranchiformes								
Synbranchidae								0.01
<i>Synbranchus marmoratus</i> Bloch, 1785	0	1	0	0	0	0	0.01	4.3
Perciformes								
Cichlidae								30.4
<i>Cichla ocellaris</i> Bloch & Schneider, 1801 *	0	64	0	6	0	0	0.8	21.7
<i>Cichlasoma orientale</i> Kullander, 1983	104	39	0	0	0	0	1.6	30.4
<i>Crenicichla menezesi</i> Ploeg, 1991	27	0	1	0	0	0	0.3	21.7
<i>Geophagus brasiliensis</i> (Quoy & Gaimard, 1824)	7	0	1	29	911	72	11.7	65.2
<i>Oreochromis niloticus</i> (Linnaeus, 1758) *	324	0	1	79	19	415	9.6	69.6
<i>Parachromis managuensis</i> (Günther, 1867) *	0	0	0	0	0	553	6.3	17.4
Total	2842	335	1455	712	2330	1063		

* = Non-native species.

Acta Limnologica Brasiliensia, 2024, vol. 36, e4

Figure 8.7: Tabela 1. Abundância, percentual e frequência de ocorrência (F.O.) de espécies coletadas nos locais de estudo (codificados conforme a Figura reffig:301comcodes) no semiárido do Brasil. = Espécies não nativas.

- uma rede de arrasto curta (4 m de comprimento, 1,5 m de malha de altura e 5 mm),
- uma rede de arrasto longa (20 m de comprimento, 2 m de altura e 12 mm de malha),
- um conjunto de redes de espera (30 m de comprimento e 1,5 m de altura divididas em três painéis de 10 m de 35, 45 e 55 mm de malha), e
- uma rede de tarrafa (2,4 m de altura e 12 mm de malha).

O esforço de captura foi semelhante em ocasiões e locais de amostragem, e medido em horas (para o método passivo), representando o número de horas das redes de espera na água, ou réplicas (para métodos ativos), representando o número de arrastos (para redes de arrasto) ou o número de lançamentos (para a tarrafa) (Medeiros et al., 2010). Os arrastos foram semelhantes em todas as ocasiões e locais de amostragem, sendo aproximadamente 10 m de comprimento para a grande rede de arrasto e 3 a 5 m de comprimento para a rede de arrasto curta.

Os peixes capturados foram eutanasiados em solução de eugenol (Resolução Normativa CONCEA nº 37, de 15.02.2018) fixados em formalina a 10% neutralizada com tetraborato de sódio e posteriormente transferidos para solução de 75% de etanol. Os espécimes foram tratados de acordo com as normas brasileiras de curadoria científica (Malabarba e Reis, 1987) e os peixes foram coletados sob a licença nº 032DIFAP/IBAMA do Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis (032DIFAP/IBAMA) de 23 de março de 2006. A triagem e identificação dos espécimes foram realizadas no Laboratório de Morfologia e Taxonomia de Peixes da Universidade Federal da Paraíba. Os espécimes-testemunho foram depositados após identificação na Coleta Ictiológica da mesma instituição.

Além da estrutura da comunidade, a estrutura física do habitat foi medida como,

- (1) variáveis físicas e químicas,
- (2) a morfologia do fluxo,
- (3) composição do substrato, e
- (4) estrutura de habitat.

As variáveis físicas e químicas foram medidas utilizando-se equipamentos portáteis para pH (TECNOPON MPA-210), condutividade (S/cm) (TECNOPON MCS-150), oxigênio dissolvido (mg/L) e temperatura (°C) (Lutron DO-5510). A transparência (cm) foi medida utilizando-se um disco secchi, e a velocidade da água (m/s) foi estimada usando o método flutuante (Maitland, 1990). O alcance do córrego ou morfologia do local foi avaliado pela largura média (cm) e profundidade (cm) retiradas de três transectos colocados ao longo do alcance do córrego, piscina ou reservatório. A composição do substrato e a

estrutura do habitat foram estimadas em 9 a 12 pontos de pesquisa de 1 m² medidos nas margens (ver Medeiros et al., 2008). Em cada ponto de pesquisa, foram estimadas as proporções (%) da composição de sedimentos (classificados como lama, areia, cascalho e seixos) e estruturas litorâneas e subaquáticas (por exemplo, macrófitas, capim, vegetação submersa, vegetação suspensa, folhoso, algas e galhos) (Pusey et al., 2004, Medeiros et al., 2008).

8.4 Análises estatísticas

Foram realizadas análises estatísticas univariadas sobre riqueza e abundância. A abundância foi padronizada por Unidade de Esforço de Captura (CPUE), onde o número de peixes capturados foi dividido pelo número de horas ou réplicas de cada técnica amostral em cada ocasião amostral e local (a partir de agora denominado abundância CPUE) (Medeiros et al., 2010). A riqueza dos peixes foi corrigida utilizando-se análises rarefação para o número médio de indivíduos de todas as ocasiões de amostragem utilizando PRIMER-e 5.0 (Clarke e Gorley, 2001). A abundância CPUE e a riqueza rarefacionada foram comparadas entre os locais de estudo usando a ANOVA one-way seguida de comparações múltiplas pós-hoc usando o teste HSD de Tukey ($\alpha=0,05$) (Zar, 1999). A abundância CPUE foi transformada pela raiz quadrada, e as variáveis ambientais foram $\log_{10}(x+1)$ transformadas para aumentar a normalidade e a homogeneidade das variâncias (Sokal e Rohlf, 1969, Maltchik et al., 2010). A correlação entre a riqueza rarefacionada e a abundância CPUE (variáveis dependentes) com a estrutura de habitat (variáveis independentes) foi avaliada utilizando-se a regressão múltipla (RM) com “forward selection”, onde as variáveis são inseridas no modelo com base na significância (probabilidade) do valor F (Sheridan e Lyndall, 2001, Maltchik et al., 2010).

Os padrões de variação na composição da comunidade de peixes entre os locais foram avaliados utilizando-se de Escalonamento Multidimensional Não-Métrico (NMDS), com base na distância relativizada de Bray-Curtis da matriz de dados transformada pelo arco-seno da raiz quadrada. O Procedimento de Permutação Multiresposta (MRPP) (Biondini et al., 1985, McCune e Grace, 2002) foi utilizado para testar a significância das diferenças na composição dos peixes entre locais/ocasiões de amostragem. O valor de “A” é apresentado como medida do grau de homogeneidade entre os grupos em comparação com a expectativa aleatória. Utilizou-se a Análise de Espécies Indicadoras (ISA) para determinar quais espécies foram indicadores significativos dos locais. O Valor Indicativo (IV) para cada espécie foi calculado utilizando-se o método de Dufrene e Legendre (1997). Este valor é testado para significância usando o teste de Monte Carlo (999 permutações). Para estabelecer correlações multivariadas entre a composição dos peixes e as variáveis ambientais, foi realizada uma Análise de Correspondência Canônica (CCA) (McCune e Grace, 2002). A matriz de dados foi centrada e normalizada, e as correlações testadas pelo teste de Monte Carlo com 999 permutações. As variáveis ambientais foram transformadas pelo

$\log_{10}(x+1)$ (Maltchik et al., 2010). As análises estatísticas ($\alpha=0,05$) foram realizadas no PC-ORD 7.0 (McCune e Mefford, 1999).

8.5 Discussão

A riqueza das espécies e a composição comunitária dos peixes observados no presente estudo estão de acordo com outros estudos realizados no semiárido do Brasil (Medeiros e Maltchik, 2001a, Medeiros et al., 2010) com a família Characidae sendo a mais representativa em termos de riqueza e abundância. Somado ao fato de que a ordem Characiformes inclui um grande número de espécies de peixes do semiárido brasileiro (Rosa et al., 2003), a maioria das espécies de Characidae observadas no presente estudo são de pequeno porte com taxas relativamente altas de fecundidade e crescimento (Medeiros e Maltchik, 2000, 2001b) e generalistas em hábitos alimentares e no uso de habitat (Silva et al., 2010, Silva, 2012). Em comparação com outros sistemas de rios secos, os locais de estudo mostraram águas bem oxigenadas, transparentes e relativamente quentes ao longo do período de estudo (ver, por exemplo, Medeiros e Arthington, 2011). A morfologia do alcance do rio variou principalmente de acordo com a natureza do local de estudo, fluxo, piscina isolada ou reservatório, e o habitat aquático era diversificado com uma gama de elementos de habitat disponíveis para colonização pela biota aquática. Os córregos e piscinas de fluxo apresentaram uma maior variedade de elementos de habitat marginal e composição de substratos quando comparados aos reservatórios. Estudos no Semiárido Brasil têm demonstrado que o habitat aquático tende a ser mais rico em córregos, quando comparado aos reservatórios e defende que essa riqueza em estruturas subaquáticas e a natureza mais variável dos córregos intermitentes melhorem a diversidade de peixes (Medeiros et al., 2006, Medeiros et al., 2008).

A regressão múltipla mostrou que o rio atinge morfologia e a estrutura do habitat teve a maioria das variáveis explicando a riqueza dos peixes. O fato de que a morfologia do local é um fator importante que explica a riqueza dos peixes (principalmente largura, comprimento e elevação) indica que esses fatores espaciais estão associados a diferentes faixas de variáveis ambientais que suportam um número de espécies de peixes. Isso é apoiado pelas análises multivariadas que mostraram forte segregação espacial da comunidade de peixes em padrões de montagem espacial. Foi demonstrado que diferentes conjuntos de espécies de peixes exibem preferências por tipos específicos de habitat (Martin-Smith, 1998). No presente estudo, a ausência de fluxo de água na maioria dos locais e a falta de conectividade longitudinal levaram a condições ambientais específicas, segregando assim a comunidade de peixes aos padrões locais de composição das espécies. Portanto, na ausência de fluxo de água, espera-se que a comunidade de peixes assuma diferentes composições entre os tipos de habitat (ou seja, fluxo de vazão de córrego, piscina e reservatório) de acordo com a heterogeneidade ambiental. Isso é ainda mais apoiado pela riqueza significativamente diferente entre os locais, principalmente no que diz respeito aos córregos Seridó (SE) e

Escama-Peixe (EP), que apresentaram maior riqueza média. Os resultados de abundância são menos conclusivos, uma vez que a ANOVA não mostrou diferença significativa entre os locais e a regressão múltipla relatou apenas oxigênio dissolvido e vegetação pendente como preditores importantes da abundância de peixes. As abundâncias naturais de peixes nos sistemas aquáticos semiáridos brasileiros variam muito, tanto espacialmente quanto temporalmente (Medeiros et al., 2010). Isso provavelmente está associado ao movimento de indivíduos dentro de pequenos trechos do rio e entre áreas mais rasas e mais profundas em piscinas ou reservatórios maiores durante inundações (Medeiros e Arthington, 2008), bem como com padrões de recrutamento e desova de peixes (Medeiros e Maltchik, 2000).

A importância da vegetação ribeirinha e sua influência no habitat aquático é bem reconhecida (Gregory et al., 1991), pois contribui com sombra e estruturas subaquáticas para refúgio de peixes, bem como locais de desova (Pusey e Arthington, 2003). No presente estudo, variáveis associadas à presença de vegetação ribeirinha foram importantes preditores da riqueza dos peixes (vegetação pendente) e associadas à composição da montagem (detritos lenhosos e temperatura da água). Essas variáveis provavelmente estão contribuindo com condições ambientais adequadas aos peixes, bem como criando embalagens locais de condições ambientais que contribuem com a segregação espacial observada na comunidade de peixes. A presença de macrófitos aquáticos em locais de reservatórios e córregos e sua importância como preditores para a riqueza e composição de espécies também é uma indicação do papel desempenhado pelas estruturas de habitat subaquático na criação de habitats locais espacialmente segregados disponíveis para uso de peixes (Xie et al., 2001). O habitat pode ser visto como um quadro onde variáveis ambientais afetam comunidades biológicas (Southwood, 1977). No entanto, em sistemas hidrológicamente variáveis, a variabilidade do fluxo tem sido sugerida como um grande eixo influenciando no modelo de habitat (Minshall, 1988, Poff e Ward, 1989). Os sistemas aquáticos de terra seca no Brasil são altamente variáveis no que diz respeito à presença e magnitude do fluxo de água (Maltchik e Florin, 2002) e, embora os resultados indiquem que a estrutura do habitat e da morfologia do local são importantes preditores da fauna de peixes, o modelo de habitat é multidimensional (Southwood, 1977) e as diversas variáveis ambientais medidas interagem entre si. Nos sistemas semiáridos do Brasil, a estrutura do habitat está sendo conduzida por muitos componentes em diferentes escalas (Medeiros et al., 2008), onde o papel das características de captação e morfologia local aumentaria na predominância em suas respectivas escalas. Isso destaca a importância da ligação entre a estrutura do habitat e a diversidade biótica no nível do habitat local.

Alterações nos padrões naturais de vazão de água com base na construção de reservatórios e açudes, decorrentes das políticas de gestão atuais dos sistemas semiáridos aquáticos no Brasil, modificam as características hidrológicas dos córregos intermitentes altamente variáveis (Leal et al., 2005, Maltchik e Medeiros, 2006). Com as mudanças na dinâmica natural do fluxo de água vêm também mudanças na estrutura de montagem de macrófitas, dinâmica de nutrientes e

conectividade longitudinal, todas associadas à conversão de sistemas loticos para lenticos (Bunn e Arthington, 2002). Os dados do presente estudo mostram que essas modificações afetarão as comunidades de peixes (riqueza e composição), uma vez que variáveis altamente associadas ao fluxo de água, como largura de alcance do córrego, cobertura de macrofito, vegetação suspensa e concentração de oxigênio dissolvida foram importantes preditores da montagem de peixes. Portanto, a modificação dos padrões naturais de vazão da água e promoção de condições lenéticas tem o potencial de interferir na fauna de peixes, favorecendo espécies mais oportunistas mais adaptadas a condições de fluxo. Isso é corroborado pelo fato de que os locais dos reservatórios apresentaram menos espécies indicadoras que foram introduzidas principalmente, como *Poecilia reticulata* e *Parachromis managuensis*, ou tipicamente lenticas como *Geophagus brasiliensis*.

O presente estudo mostra que as comunidades de peixes assumem diferentes estruturas e composições em diferentes tipos de habitat, de acordo com a heterogeneidade ambiental associada à natureza do habitat (reservatórios, córregos e piscinas). A riqueza e a composição dos peixes foram influenciadas principalmente por dois conjuntos de variáveis ambientais, sendo morfologia do local e características do habitat. O primeiro conjunto de variáveis relaciona-se com os níveis hierárquicos espaciais de captação, uma vez que o comprimento e a elevação do rio estão tipicamente associados à hierarquia do rio. O segundo conjunto de variáveis é tipicamente local, com estruturas subaquáticas sendo resultado de processos locais como o fluxo de água de alcance do rio e o uso da terra/vegetação ribeirinha.

Apêndices

8.5.1 Tabelas e Figuras

Tabela 1. Abundância, percentual e frequência de ocorrência (F.O.) de espécies coletadas nos locais de estudo (codificados conforme a Figura 8.6) no semiárido do Brasil. * = Espécies não nativas.”

Tabela 2. Variáveis ambientais (average $\pm$ SD) coletadas nos locais de estudo no semiárido do Brasil.

Tabela 3. São apresentadas as variáveis ambientais e a composição dos peixes no presente estudo (apenas variáveis correlacionadas com um determinado eixo são mostradas).

Figura 1. Área de estudo mostrando os estados do Rio Grande do Norte (RN), Paraíba (PB), Pernambuco (PE) e Alagoas (AL), principais sistemas fluviais e locais de amostragem no semiárido do Brasil. TA, açude Recanto; CP, riacho Cipó; CT, riacho Catureré; PC, riacho Poço da Cruz; MU, açude Mulungu e GU, açude Gurjão.

Environmental variables as predictors of fish community...

Table 2. Abundance, percentage and frequency of occurrence (F.O.) of species collected in the study sites in the semi-arid region of Brazil. Scridó stream (SE), Cipó stream (CI) and Recanto reservoir (RE) (Piranhas-Açu catchment), Escama-Feixe stream (EF, Moxotó River), Mulungu reservoir (MU, Ipanema River) and Salobro reservoir (SA, Una River).

	SE	CI	RE	EP	MU	SA	%	F.O.
Characiformes								
Curimatidae								4.1
<i>Curimatella lepidura</i> (Eigenmann & Eigenmann, 1889)	0	0	0	21	0	0	0.2	4.3
<i>Psectrogaster rhomboides</i> Eigenmann & Eigenmann, 1889	1	0	0	0	0	0	0.01	4.3
<i>Steindachnerina notonota</i> (Miranda-Ribeiro, 1937)	205	0	0	0	0	0	2.3	17.4
<i>Cyphocharax gilbert</i> (Quoy & Gaimard, 1824)	50	0	0	81	0	0	1.5	8.7
Parodontidae								0.3
<i>Apareiodon hasemani</i> Eigenmann, 1916	0	0	0	27	0	0	0.3	8.7
Prochilodontidae								3.1
<i>Prochilodus brevis</i> Steindachner, 1874	243	5	6	15	1	0	3.1	47.8
Anostomidae								0.2
<i>Leporinus piau</i> Fowler, 1941	6	6	2	1	0	0	0.2	34.8
<i>Leporinus melanopleura</i> Günther, 1864	0	0	0	2	0	0	0.02	4.3
<i>Leporinus taeniatus</i> Lütken, 1875	0	0	0	1	0	0	0.01	4.3
Crenuchidae								8.1
<i>Characidium bimaculatum</i> Fowler, 1941	3	0	702	0	0	0	8.1	21.7
Characidae								36.6
<i>Astyanax bimaculatus</i> (Linnaeus, 1758)	542	40	697	126	857	21	26.1	87.0
<i>Astyanax fasciatus</i> (Cuvier, 1819)	123	1	8	24	0	2	1.8	43.5
<i>Colossoma macropomum</i> (Cuvier 1816) *	0	0	2	0	0	0	0.02	4.3
<i>Compsura heterura</i> Eigenmann, 1915	1	0	0	0	0	0	0.01	4.3
<i>Hemigrammus marginatus</i> Ellis, 1911	2	0	0	0	0	0	0.02	8.7
<i>Moenkhausia costae</i> (Steindachner, 1907)	0	0	0	1	0	0	0.01	4.3
<i>Moenkhausia</i> sp.	40	0	0	0	0	0	0.5	8.7
<i>Serrapinnus heterodon</i> (Eigenmann, 1915)	141	17	4	134	0	0	3.4	43.5
<i>Serrapinnus piaba</i> (Lütken, 1875)	68	0	0	0	0	0	0.8	4.3
<i>Serrasalminus rhombus</i> (Linnaeus, 1766)	1	0	0	0	0	0	0.01	4.3
<i>Tetragonopterus chalcus</i> Spix & Agassiz, 1829	0	0	0	134	0	0	1.5	8.7
<i>Triporthus signatus</i> (Garman, 1890)	181	0	0	27	0	0	2.4	26.1
Erythrinidae								1.2
<i>Hoplias malabaricus</i> (Bloch, 1794)	53	21	31	3	1	0	1.2	60.9
Siluriformes								
Loricariidae								0.8
<i>Hypostomus puseum</i> (Starks, 1913)	66	4	0	1	0	0	0.8	30.4
<i>Pseudancistrus papariae</i> Fowler 1941	1	0	0	0	0	0	0.01	4.3
Heptapteridae								0.1
<i>Pimelodella enochi</i> Fowler, 1941	6	0	0	0	0	0	0.1	4.3
Cyprinodontiformes								
Poeciliidae								15.2
<i>Poecilia reticulata</i> Peters, 1860 *	25	0	0	0	322	0	4.0	21.7
<i>Poecilia vivipara</i> Bloch & Schneider, 1801	622	137	0	0	219	0	11.2	47.8
Synbranchiformes								
Synbranchidae								0.01
<i>Synbranchius marmoratus</i> Bloch, 1785	0	1	0	0	0	0	0.01	4.3
Perciformes								
Cichlidae								30.4
<i>Cichla ocellaris</i> Bloch & Schneider, 1801 *	0	64	0	6	0	0	0.8	21.7
<i>Cichlasoma orientale</i> Kullander, 1983	104	39	0	0	0	0	1.6	30.4
<i>Crenicichla menezesi</i> Ploeg, 1991	27	0	1	0	0	0	0.3	21.7
<i>Geophagus brasiliensis</i> (Quoy & Gaimard, 1824)	7	0	1	29	911	72	11.7	65.2
<i>Oreochromis niloticus</i> (Linnaeus, 1758) *	324	0	1	79	19	415	9.6	69.6
<i>Parachromis managuensis</i> (Günther, 1867) *	0	0	0	0	0	553	6.3	17.4
Total	2842	335	1455	712	2330	1063		

* = Non-native species.

	CI	SE	RE	SA	MU	EP
Morfologia						
Comprimento do rio (km)	83.1	163.2	110.2	212.7	214.0	196.8
Elevação (m)	169.0	226.0	270.0	713.0	725.0	402.0
Velocidade da água (m/s)	0,04 (±0,1)	0,1 (±0,1)	0,03 (±0,1)	0.0	0.0	0.0
Inclinação máxima da margem	60.0	30.0	60.0	30.0	30.0	90.0
Profundidade máxima (cm)	67,8 (±8,2)	98,8 (±16,6)	117,0 (±27,9)	65,0 (±4,2)	124,0 (±18,8)	95,0 (±15,0)
Profundidade da margem (cm)	33,3 (±9,3)	53,3 (±24,9)	36,3 (±13,8)	6,7 (±1,5)	30,4 (±8,5)	50,7 (±1,9)
Largura do trecho (m)	15,4 (±3,4)	11,8 (±7,1)	90,5 (±13,7)	313,7 (±17,4)	247,8 (±15,8)	25,6 (±5,0)
Qualidade da água						
Temperatura da água (°C)	30,4 (±3,3)	31,4 (±2,1)	31,6 (±2,7)	26,7 (±2,8)	27,7 (±2,0)	29,0 (±0,1)
Oxigênio dissolvido (mg/L)	4,9 (±1,6)	6,0 (±0,5)	7,1 (±2,5)	6,1 (±3,3)	5,1 (±2,3)	5,2 (±0,3)
Transparência (cm)	42,3 (±15,6)	30,8 (±16,4)	67,4 (±16,3)	42,1 (±13,7)	60,8 (±20,7)	37,4 (±10,9)
Composição do habitat (%)						
Cobertura de macrófitas	0.0	2.1 (±4.2)	35,7 (±21,1)	12,8 (±22,6)	0.0	0.0
Capim na margem	5.8 (±11.7)	11.1 (±10.4)	2.1 (±4.0)	5.2 (±6.5)	34,5 (±22,3)	0,7 (±1,2)
Vegetação submersa	0,8 (±1,5)	2,5 (±5,0)	4,2 (±8,3)	7,3 (±12,5)	11,2 (±17,4)	0.0
Vegetação marginal	17.1 (±15.5)	0.0	10,4 (±15,8)	0,9 (±1,6)	0.0	0.0
Serapilheira	1,5 (±0,6)	0,4 (±0,4)	6,5 (±11,5)	0.0	1,9 (±2,1)	0,4 (±0,1)
Alga	21,4 (±2,9)	5,1 (±3,6)	17,7 (±11,3)	17,3 (±3,1)	7,8 (±5,5)	0,1 (±0,1)
Massas de raízes	2,3 (±2,3)	0.0	0.0	0.0	0.0	0.0
Galhos	4,7 (±1,3)	2,6 (±1,3)	7,2 (±2,1)	0,9 (±0,7)	15,5 (±0,4)	1,1 (±0,8)
Composição do substrato (%)						
Lama	17,8 (±21,7)	66,4 (±22,5)	48,1 (±32,2)	94,4 (±4,6)	52,7 (±32,1)	40,5 (±7,7)
Areia	60,0 (±27,5)	23,7 (±16,2)	45,5 (±36,1)	3,9 (±2,0)	45,1 (±33,0)	55,6 (±7,6)
Cascalho	9,2 (±0,0)	0.0	4,3 (±0,7)	1,7 (±0,4)	0.0	2,7 (±1,9)
Pedras	10,5 (±9,9)	6,3 (±9,2)	0.0	0.0	1,0 (±1,2)	0,4 (±0,5)
Rochas	2,5 (±5,0)	2,8 (±3,9)	0,0 (±0,0)	0.0	1,3 (±2,5)	0,8 (±0,7)
Base rochosa	0.0	0,8 (±1,7)	2,1 (±4,2)	0.0	0.0	0.0

	Eixo 1	Eixo 2	Eixo 3
Autovalores	0.744	0.677	0.637
Teste de Monte Carlo	0.005	0.001	0.002
Variância nos dados das espécies			
% variância explicada	13.6	12.4	11.6
Correlações entre espécies e meio ambiente	1.000	1.000	1.000
Teste de Monte Carlo	0.001	0.001	0.001
Correlações intra-definidas			
Morfologia			
Comprimento do rio	-0.380	-0.498	0.304
Altitude	-0.377	-0.772	-0.172
Velocidade da água	0.318	0.252	0.456
Inclinação do banco	-0.712	0.266	-0.396
Profundidade litorânea	-0.117	0.709	0.378
Largura	-0.054	-0.674	-0.443
Qualidade da água			
Temperatura	0.238	0.586	-0.014
Composição do habitat			
Macrófitos	0.383	0.138	-0.417
Escombros	0.469	0.044	-0.022
Composição de substrato			
Areia	-0.294	0.487	-0.179
Cascalho	-0.347	0.083	-0.556






Figura 2. Os resultados da NMDS para a composição dos peixes em todo o estudo chegam ao semiárido do Brasil. Vetores (caixa de entrada) mostram taxa correlacionada ($r^2 > 0,2$) com amostras em espaço de ordenação. As letras após os códigos do site indicam ocasião de amostragem (A=Abril, J=Junho, S=Setembro e D=Dezembro).

Figura 3. Biplot de CCA mostrando a composição de conjuntos de peixes nos locais e ocasiões de amostragem () e as variáveis ambientais explicativas definidas pela CCA.

Referências



Chapter 9

Base de dados II - Habitat

Estrutura do Habitat: Variáveis ambientais no semiárido

Apresentação

Exemplo de conjunto de dados ecológicos do Programa de Pesquisa em Biodiversidade (PPBio) do Semiárido. Ano de 2006. Estrutura do habitat¹.

Autor:

- Prof. Elvio S. F. Medeiros
- Laboratório de Ecologia
- Universidade Estadual da Paraíba
- Campus V, João Pessoa, PB

Para entender a distribuição das espécies de peixes e seu uso de habitat, uma série de variáveis ambientais foram avaliadas como preditores da composição e riqueza da assembleia de peixes em sistemas aquáticos tropicais semiáridos. Nós pesquisamos a composição de elementos físicos, químicos e da estrutura do habitat associados a assembleias de peixes em sistemas aquáticos semiáridos e estabelecemos seu grau de associação. Os locais consistiam em trechos de riachos com fluxo de água superficial, poças temporárias isoladas e reservatórios artificiais (açudes). A amostragem de elementos do habitat foi feita associada a amostragem da comunidade de peixes e zooplâncton em quatro ocasiões durante as estações chuvosa (abril e junho de 2006) e seca (setembro e dezembro de 2006).

Texto modificado de MEDEIROS; SILVA; RAMOS (2008): Application of catchment- and local-scale variables for aquatic habitat characterization

¹Projeto financiado pelo CNPq/UEPB/DCR Proc.350082/2006-5, UEPB/FAPESQ Proc.68.0006/2006.0 e Projeto de Pesquisa em Biodiversidade do Semiárido (PPBio Semi-Árido).

and assessment in the Brazilian semi-arid region. *Neotropical Biology and Conservation*, 2008, vol. 3, n. 1, p. 13-20. <https://revistas.unisinos.br/index.php/neotropical/article/view/5440>. Tradução: Google Translator.

Elvio Sergio Figueredo Medeiros^{1,4}, Marcio Joaquim da Silva², e Robson Tamar Costa Ramos^{1,3}

¹ Grupo Ecologia de Rios do Semiárido, Universidade Estadual da Paraíba, Depto. de Biologia. Campus V. CEP 58070-450 João Pessoa - PB. Brazil.

² Universidade Federal do Rio Grande do Norte, Depto. de Biologia, Centro de Biociências, CEP 59078-900 – Natal - RN. ³ Laboratório de Sistemática e Morfologia de Peixes, Universidade Federal da Paraíba, Depto. de Sistemática e Ecologia, CCEN, CEP 58059-900, João Pessoa - PB.

- Autor correspondente: Dr. Elvio Medeiros <https://orcid.org/0000-0002-7472-8147>. Universidade Estadual da Paraíba, João Pessoa - Paraíba – Brasil - CEP 58.070-450. E-mail: elviomedeiros@servidor.uepb.edu.br

⁴Os autores agradecem a Telton Ramos e Virginia Diniz (UEPB) pela assistência em campo e ao CNPq/UEPB/DCR pela bolsa concedida a ESFM (350082/2006-5). Esta pesquisa contou com o apoio da UEPB/FAPESQ (68.0006/2006.0) e do Projeto de Pesquisa em Biodiversidade do Semiárido (PPBio Semi-Árido).

RESUMO

O estado do habitat físico é influenciado por fatores que atuam em diversas escalas, como a geomorfologia, o clima, o regime hidrológico, o uso da terra e a qualidade da água. Este trabalho quantifica a diversidade e a disponibilidade do habitat físico em sistemas aquáticos naturais e artificiais no semiárido do Brasil, com o objetivo de levantar variáveis físicas em escala local e de bacia de drenagem, e analisar sua importância na composição de uma estrutura básica para a caracterização e avaliação desses ambientes. Este estudo foi desenvolvido nas regiões de Seridó/Borborema e Buíque/Vale do Ipojuca. Estas áreas são consideradas de extrema importância biológica e são identificadas como prioritárias para a conservação da Caatinga. Os resultados mostram que o habitat aquático no semiárido brasileiro é diverso e dinâmico, compreendendo um conjunto amplo de elementos disponíveis para a colonização pelos organismos. Os rios mostraram uma gama de elementos do habitat marginal e da composição do substrato igual ou superior àquela dos reservatórios. Além disso, a composição do habitat variou entre os dois tipos de ambiente estudados (rios/reservatórios) e com as estações do ano (seca/chuvosa). Os resultados apresentados têm implicações importantes para a conservação dos ambientes aquáticos do semiárido. Tendo em vista que o habitat físico é a estrutura básica para a colonização por parte dos organismos aquáticos, os mecanismos potenciais que mantêm a biodiversidade aquática ocorrem nos vários níveis da bacia de drenagem. Portanto,

é fundamental identificar os componentes, ao longo dos sistemas ripários, que são vitais na manutenção da sua integridade biológica.

Palavras-chave: rios intermitentes, reservatórios, conservação, composição de substratos

9.1 Introdução

Córregos intermitentes no semiárido brasileiro são características paisagísticas distintivas, existindo como cursos d'água secos durante a maior parte do ano. Maltchik e Medeiros (2006) reconheceram que os extremos de inundação e seca são impulsionadores de importantes processos que mantêm a diversidade dentro desses sistemas. Portanto, as medidas de conservação no semiárido brasileiro devem incluir a manutenção do regime de fluxo natural dos sistemas aquáticos, para garantir a sobrevivência das espécies em longo prazo (Maltchik e Medeiros, 2006). No entanto, as medidas de conservação também devem levar em conta a composição e diversidade do habitat aquático disponível, pois o habitat físico é o quadro de colonização pela fauna aquática (eg Martin-Smith, 1998). Além disso, o estado deste espaço vital influenciará a estrutura biótica e a organização dentro dos sistemas aquáticos (Mugodo et al., 2006). O estado do habitat físico, nomeadamente composição e diversidade, é influenciado por factores que operam a várias escalas espaciais e temporais (Boys e Thoms, 2006). Ao nível da bacia, a geomorfologia e o clima influenciarão o habitat à escala de alcance, afectando a hidrologia, sedimentação, aportes de nutrientes e morfologia do canal (Davies et al., 2000; Mugodo et al., 2006). No nível local, o uso e manejo da terra também influenciarão o habitat em escala de alcance do córrego (Richards et al., 1996).

Os métodos de avaliação do habitat físico disponíveis para os organismos aquáticos fornecem ferramentas importantes para vários aspectos da gestão e conservação do rio e, portanto, os procedimentos usados para avaliar o habitat devem ser ecologicamente e geomorfologicamente significativos (Thomson et al., 2001). Apesar disso, métodos de avaliação de habitats precisam ser desenvolvidos e testados em sistemas aquáticos semiáridos do Brasil, pois não são tão bem desenvolvidos quanto os métodos usados para avaliar outros aspectos da condição dos rios, como a qualidade da água. A avaliação do habitat é de grande utilidade para prever a distribuição potencial de espécies-chave, como peixes (Boys e Thoms, 2006) e invertebrados (Richards et al., 1997), com base em suas necessidades de habitat. Além disso, o habitat observado e potencial (ou previsto) pode ser comparado com os requisitos de habitat de uma espécie para avaliar a necessidade de manejo do habitat e a saúde geral do ecossistema com base nas necessidades da biota aquática (Maddock, 1999).

Este trabalho mede a diversidade e disponibilidade do habitat físico em sistemas aquáticos naturais e artificiais no nordeste do Brasil. Este artigo tem como objetivo levantar variáveis físicas em escala local e de captação e avaliar

sua importância como marco básico para caracterização e avaliação de habitats aquáticos em duas áreas do semiárido brasileiro.

9.1.1 Desenho Amostral

Este estudo foi realizado na região semiárida brasileira, em bacias hidrográficas que fluem através de uma floresta aberta arbustiva seca decidual (a “Caatinga”). A amplitude térmica é baixa na área de estudo, com médias variando de aproximadamente 25 a 30 °C, e a precipitação média anual varia entre 600 e 1100 mm. As altitudes variam entre 100 e 1000 m (Figura 9.1 e Figura 9.2).




Figure 9.1: Área de estudo mostrando os estados do Rio Grande do Norte (RN), Paraíba (PB), Pernambuco (PE) e Alagoas (AL), principais sistemas fluviais e pontos de amostragem na região semiárida do Brasil. TA, açude Recanto; CP, riacho Cipó; CT, riacho Catureré; PC, riacho Poço da Cruz; MU, açude Mulungu e GU, açude Gurjão.

Dois regiões de importância biológica (**Seridó, S** e **Buíque, B**) foram escolhidas e nelas, **seis locais** ou sítios de coleta (**TA, CP, CT, PC, MU, e GU**) foram selecionados para representar ambientes Unidades Amostrais de ambientes temporários naturais e artificiais típicos (Figura 9.1 e Figura 9.4).

Os locais consistiam em trechos de **riachos (-R)** com fluxo de água superficial (durante a estação chuvosa) ou poças temporárias isoladas (durante a estação seca) e **reservatórios ou açudes (-A)** artificiais criados a partir do represamento de riachos. A amostragem foi realizada durante o ano de 2006 em **quatro ocasiões** durante as estações chuvosa (**abril, 1** e **junho, 2**) e seca (**setembro, 3** e **dezembro, 4**) (Figura 9.1 e Figura 9.4).

Table 1. General characteristics of the study sites. *A-priori* criteria for grouping habitat structure in the DCA are indicated with a (*).

Sample sites	Area *	Catchment Basin	River	Stream site location	Habitat type *	Position
1 CT	Seridó/Borborema	Piranhas-Açu	Seridó	Seridó River	Stream	06° 36' 30.24" S 36° 46' 57.18" W
2 CP	Seridó/Borborema	Piranhas-Açu	Sabugi	Cipó Stream	Stream	06° 38' 39.42" S 37° 10' 30.84" W
3 TA	Seridó/Borborema	Piranhas-Açu	Espinharas	Recanto Stream	Reservoir	07° 00' 18.06" S 37° 23' 28.20" W
4 PC	Buíque/Vale do Ipojuca	São Francisco	Moxotó	Escama Peixe Stream	Stream	08° 30' 55.74" S 37° 42' 58.44" W
5 MU	Buíque/Vale do Ipojuca	São Francisco	Ipanema	Mulungu Stream	Reservoir	08° 37' 35.94" S 37° 07' 44.40" W
6 GU	Buíque/Vale do Ipojuca	Una	Una	Salobro Stream	Reservoir	08° 39' 04.26" S 36° 34' 57.24" W

Figure 9.2: Características gerais dos locais de estudo. Os critérios a priori para agrupar a estrutura do habitat no DCA são indicados com um (*).

9.1.2 Sobre os dados do PPBio

A planilha **ppbio** contém os dados das variáveis ambientais em diferentes unidades amostrais (UA's) (Figura 9.3) (Veja Programa de Pesquisa em Biodiversidade – PPBio). Essa é a **matriz bruta de dados**, porque os valores ainda não foram ajustados (não foram relativizados ou transformados). Outros tipos de arquivos existem para os dados do PPBio (7.2), que fazem parte de um estudo mais amplo sobre ecologia de rios do semiárido.

	s.mud	s.sand	s.silic	s.grav	s.cobles	s.rocks	s.bedrock	m.elev	m.river	m.stream	m.distance	m.distance	m.maxslope	m.maxslope	m.habitat	m.width	a.velocity	a.temp	a.do	a.transp	
S-R-CF1	65	30	0	0	1,666667	0	3,333333	226	163,2	163,2	84,45	217,15	30	106	81,33333	29,64	0,166667	32,9	6,51	46	
S-R-CF1	16,66667	70	5	5	3,333333	0	0	169	83,05	13,55	6,15	185,55	60	60	22,66667	17,24	0,159151	35,2	6,863333	26	
S-R-TA1	81,66666	8,333333	1,666667	0	0	0	8,333333	270	110,2	37,1	8,85	254,55	60	154	54,66667	102	0,1	34	4,82	61	
S-R-CF2	60	40	0	0	0	0	0	226	163,2	163,2	84,45	217,15	30	106	87	16,1	0,125	32	5,375	44	
S-R-CF2	0,666667	87,66666	3,333333	3,333333	5	0	0	169	83,05	13,55	6,15	185,55	60	68	31,66667	18,47	0	29	3,015	33	
S-R-TA2	5	95	0	0	0	0	0	270	110,2	37,1	8,85	254,55	60	118	37,66667	100	0	29	5	90	
S-R-CF3	65,55556	23,11111	0	0	0	8,333333	0	226	163,2	163,2	84,45	217,15	30	110	32,33333	6,2	0	28,66667	6	17,33333	
S-R-CF3	48,75	22,5	10	10	8,75	0	0	169	83,05	13,55	6,15	185,55	60	79	32,66667	15,1	0	29,66667	5	50,33333	
S-R-TA3	46,66667	40	6,666667	6,666667	0	0	0	270	110,2	37,1	8,85	254,55	60	109	22,33333	88	0	34	9	16,66667	
S-R-CF4	95	1,833333	0	0	0,333333	2,833333	0	226	163,2	163,2	84,45	217,15	30	74	32,33333	5,4	0	32,6	6	16	
S-R-CF4	5	90	0	0	0	25	30	0	169	83,05	13,55	6,15	185,55	60	64	49,33333	10,7	0	27,6	4,9	60
S-R-TA4	59,14286	38,71429	1,142857	0	0	0	0	270	110,2	37,1	8,85	254,55	60	87	30,33333	72,2	0	29,33333	9,433333	67	
S-A-AU1	33,33333	65	0	0	1,666667	0	0	725	214,02	19,83333	7,583333	290,8767	30	152	32,66667	270	0	29,83333	5,666667	48	
S-A-GU1	96,66666	3,333333	0	0	0	0	0	713	212,6667	32,33333	10,16667	203,8333	30	60	4,166667	330	0	29,23333	5,166667	25,66667	
S-R-PC2	39	56	3	0	1	1	0	402	196,8333	13,75	11,41667	401,6667	90	110	49,33333	29,6	0	29	5,635	50	
S-A-AU2	20,6	77	0	0	2,4	0	0	725	214,02	19,83333	7,583333	290,8767	30	115	22	247,63	0	29	1,815	43	
S-A-AU2	98	1	0	0	0	0	0	713	212,6667	32,33333	10,16667	203,8333	30	69	7	321	0	29	1,85	55	
S-R-PC3	33,66667	63	3,333333	0	0	0	0	402	196,8333	13,75	11,41667	401,6667	90	80	50	27,5	0	29	5	32,33333	
S-A-AU3	65	35	0	0	0	0	0	725	214,02	19,83333	7,583333	290,8767	30	117	25,66667	234,53	0	26	5,7	63	
S-A-GU3	87,77778	6,666667	3,333333	2,222222	0	0	0	713	212,6667	32,33333	10,16667	203,8333	30	68	6,833333	314,2	0	24	8,8	51,66667	
S-R-PC4	48,875	47,875	1,875	0	0,125	1,25	0	402	196,8333	13,75	11,41667	401,6667	90	95	52,83333	20	0	28,85	5,1	30	
S-A-AU4	91,77778	3,222222	0	0	0	5	0	725	214,02	19,83333	7,583333	290,8767	30	112	41,33333	239	0	25,95	7,3	49	
S-A-GU4	95,16666	3,416667	1,333333	0,083333	0	0	0	713	212,6667	32,33333	10,16667	203,8333	30	61	4,666667	289,5	0	24,7	8,75	36	

Figure 9.3: Parte da planilha de dados brutos do PPBio para o habitat.

9.2 Codificação para variáveis

Os arquivos da base de dados do projeto são fornecidos em formato Excel (.xlsx). Por exemplo, o arquivo **ppbio06*-habitat.xlsx**, traz os dados brutos que serão usados nas análises. A matriz de dados brutos contém mais de 20 localidades (n=linhas ou objetos) em estações do ano diferentes, e cerca de 30 variáveis ambientais (m=colunas ou atributos), antes de qualquer modificação. Portanto é uma matriz bruta. Os valores incluem diversos tipos de variáveis medidas em unidades diferentes (% , °C, mg/L, etc), e apresentam uma alta amplitude de variação, portanto, a aplicação de uma transformação é recomendado (Figura 9.3). Nos nomes dos objetos e dos atributos são codificados de acordo com a tabela mostrada na Figura 9.4.

Variáveis da estrutura do habitat (Atributos)	Sítios e períodos de amostragem (Objetos)
Habitat marginal (% de cobertura) Gramma litorânea Macrófitas Algas aderidas (a um substrato) Algas filamentosas Vegetação pendente (encobrindo a margem) Vegetação (terrestre) submersa Galhos pequenos (<2 cm de diâmetro) Galhos grandes (>2 cm de diâmetro) Liteira ou folhigo (submerso) Massas de raízes Composição do substrato (% de cobertura) Lama (ou silte) Areia Seixos Cascalho pequeno (<2 cm) Cascalho grande (>2 cm) Rochas Rocha mãe Qualidade da água Velocidade da água (m/s) Temperatura (°C) Oxigênio dissolvido (mg/L) Transparência (cm) de Secchi Agrupamentos a-priori Por tipo de ambiente: Rio / Reservatórios Por área de estudo: Seridó / Buíque Por estação: Chuvosa / Seca Escala das variáveis Escala de bacia e morfologia (escala regional) Comprimento total da bacia (km) Comprimento do riacho do sítio amostrado (km) Distância do sítio para a nascente do rio (km) Distância do sítio para a foz do rio (km) Elevação (= altitude) (m.a.n.m.) Escala de sítio e morfologia (escala local) Declive da margem (graus) Largura do trecho amostrado (m) Profundidade na margem do trecho amostrado (cm) Profundidade máxima no trecho amostrado (cm) Escala de sítio e qualidade da água (escala local) Velocidade da água (m/s) Oxigênio Dissolvido (mg/L) Temperatura (°C) Transparência da água (cm)	Nos códigos dos sítios está o desenho amostral. Duas áreas, ao norte o Seridó (S) e ao sul Buíque (B). Em cada área existem dois tipos de ambiente, açude (A) e rio (R). Ao norte estão três sítios, TA, CP e CT, e ao sul três sítios, PC, MU e GU. Em cada sítio há quatro amostragens por ano, trimestre 1, 2, 3 e 4. Resumo: S: Seridó B: Buíque A: Açude R: Rio TA: Açude Recanto (RE) CP: Riacho Cipó (CI) CT: Riacho Catureré (SE) PC: Riacho Poço da Cruz (EP) MU: Açude Mulungu (MU) GU: Açude Gurjão (SA) 1: 1o. trimestre (Abr/Chuvoso) 2: 2o. trimestre (Jun/Chuvoso) 3: 3o. trimestre (Set/Seco) 4: 4o. trimestre (Dez/Seco) Exemplo: A amostra S-R-CP-1 representa, a região Seridó (S), um ambiente de rio (R), o sítio riacho Cipó (CP), no primeiro trimestre do ano (1).

Figure 9.4: Codificação para as variáveis ambientais descritoras da estrutura do habitat (atributos) e os sítios e períodos de amostragem (objetos).




Figure 9.5: Imagem representativa da codificação das variáveis, para a medição da estrutura do habitat (atributos).

9.3 Área de estudo e amostragem dos dados

Este estudo foi realizado em duas áreas diferentes do semiárido brasileiro: Seridó/Borborema e Buíque/Vale do Ipojuca (conforme Tabarelli e Silva, 2003) (Tabela 1; Figura 1). Essas áreas são classificadas como de extrema importância biológica e foram identificadas como áreas prioritárias para conservação da biodiversidade na Caatinga por Silva et al. (2003), por apresentarem alta diversidade de espécies e serem ricas em endemismos. A área do Seridó está localizada no sul do Rio Grande do Norte (RN) e norte da Paraíba (PB) entre Patos e Caicó (Figura 9.1). A temperatura média anual é de 30,7°C, com máxima média mensal em outubro (31,0°C) e mínima média em fevereiro (29,3°C). A precipitação concentra-se entre janeiro e abril, com 350 a 800 mm por ano e média anual de 600 mm (Amorim et al., 2005). A altitude no Seridó varia entre 100 e 800 m (Governo do Estado da Paraíba, 1985). A área de Buíque está localizada no entorno da cidade de Buíque no centro de Pernambuco (PE) (Figura 9.1). A temperatura média anual e a precipitação são 25°C e 1095,9 mm, respectivamente. As chuvas concentram-se entre abril e junho. Altitude varia entre 800 e 1000 m (Rodal et al., 1998).

Dentro de cada área de estudo, três locais foram selecionados para representar ambientes típicos artificiais e naturais temporários e semipermanentes (Tabela 1). Os locais consistiam em trechos de córregos, geralmente de 100 a 500 m de comprimento, e reservatórios artificiais criados a partir de represamento de córregos. A amostragem foi realizada durante um ano em quatro ocasiões durante as estações chuvosa (abril e junho de 2006) e seca (setembro e dezembro de 2006). Variáveis de escala de alcance de captação e córrego foram selecionadas com base nas características locais e em Pusey et al. (2004) (entre outros, Richards et al., 1996; Davies et al., 2000; Thomson et al., 2001; Mugodo et al., 2006). As variáveis de escala de captação foram quantificadas com base nas características topográficas gerais da área de estudo e nas características da bacia hidrográfica usando mapas topográficos 1:500.000, imagens de satélite e receptor GPS. As variáveis do local em escala de alcance apresentam características morfométricas e de qualidade (físico-químicas) da água. A estrutura do habitat compreendeu (i) elementos marginais subaquáticos e litorâneos (representando a abundância de elementos marginais de microhabitat) e (ii) a composição do substrato.

A qualidade da água em escala de alcance, a estrutura do habitat e algumas das características morfométricas foram estimadas em pontos de levantamento de um metro quadrado e distribuídas em categorias. Normalmente, 3 a 12 pontos de pesquisa aleatórios foram avaliados dentro de cada trecho de rio ou reservatório. A composição do substrato e os elementos do habitat foram estimados como sua contribuição proporcional ao perímetro molhado do local. Para a avaliação da morfologia do local, a largura foi medida com fita métrica para distâncias de até 100 m e receptor de satélite GPS para distâncias maiores. A profundidade foi medida com um bastão a distâncias aproximadamente equivalentes ao longo de um transecto para representar a profundidade do habitat (profundidade média

dos primeiros 3 m das margens) e a profundidade máxima. A velocidade da água foi medida usando o método de flutuação (Maitland, 1990). A inclinação da margem foi estimada visualmente e alocada em categorias de inclinação (< 30°, 30-60° e 60-90°). A temperatura da água (°C) e o oxigênio dissolvido (mg/l) foram medidos com um medidor de oxigênio (Lutron DO-5510), e a transparência (cm) foi medida com um disco Secchi.

9.4 Análises estatísticas

A variação na composição do habitat entre os locais e as ocasiões de amostragem foi investigada usando a Análise de Correspondência Destendida (DCA) dos dados padronizados transformados em arcsine-squareroot. O Multi-Response Permutation Procedure (MRPP) (Biondini et al., 1985; McCune e Grace, 2002) foi usado para testar diferenças na composição de habitats entre as duas áreas de estudo (Seridó e Buíque), tipos de habitats (córrego e reservatório) e estações do ano (chuvoso e seco). Para todas as análises de MRPP, a concordância dentro do grupo corrigida pela chance (A) é apresentada como uma medida do grau de homogeneidade dentro do grupo, em comparação com a expectativa aleatória. Onde o MRPP detectou diferenças significativas, uma análise adicional foi realizada para revelar quais elementos particulares do habitat contribuíram significativamente como a fonte da diferença na composição do habitat, usando a Análise de Espécies Indicadoras de McCune e Mefford (1999). Os Valores Indicadores (IV) foram calculados pelo método de Dufrene e Legendre (1997). Estes foram testados para significância estatística ($p < 0,05$) usando uma técnica de Monte Carlo com 1000 corridas. A influência das variáveis de alcance e escala de captação na estrutura do habitat foi avaliada usando a Análise de Correspondência Canônica (CCA) seguindo McCune e Grace (2002). Os dados foram centralizados e normalizados e testados com randomização de Monte Carlo (100 corridas). Todas as estatísticas foram realizadas em PC-ORD 4.27 (McCune e Mefford, 1999).

9.5 Resultados

A estrutura do habitat para todos os locais de estudo consistiu geralmente em plantas C4 crescendo nas margens do litoral (nomeadamente gramíneas), macrófitas aquáticas, incluindo plantas flutuantes (geralmente *Salvinia* sp., *Pistia* sp. e *Azolla* sp.), plantas emergentes (*Nymphaea* spp.) e plantas submersas (*Ceratophyllum* sp. e *Egeria* sp.) e algas (aderidas ao substrato e filamentosas) (Figura 9.6). Vegetação ciliar pendendo, restos lenhosos, serapilheira e massas de raízes também estiveram presentes nos locais estudados.

A composição do substrato foi composta principalmente de lama e areia, com menor contribuição de seixos, pedras e cascalho (Figura 9.6). A diversidade

Table 2. Percentages ($\pm$ standard deviation) of the habitat elements of both marginal elements and substrate composition occupying the marginal wetted perimeter of the study sites and average water quality parameters.

Habitat elements	Average(SD)	Minimum-maximum
Marginal habitat		
Littoral grass	10.3 (± 15.8)	0-54.0
Macrophytes	8.8 (± 17.7)	0-54.8
Attached algae	6.5 (± 14.2)	0-50.0
Filamentous algae	5.6 (± 10.5)	0-33.3
Overhanging vegetation	4.9 (± 10.7)	0-33.3
Submerged vegetation	4.5 (± 9.6)	0-36.6
Small debris (<2 cm diameter)	3.5 (± 3.3)	0-10.0
Large debris (>2 cm diameter)	2.0 (± 4.5)	0-20.0
Leaf litter	1.8 (± 4.9)	0-23.7
Root masses	0.4 (± 1.2)	0-5.0
Substrate composition		
Mud	53.9 (± 31.9)	0.7-98.0
Sand	38.2 (± 29.5)	1.8-95.0
Cobbles	3.1 (± 6.5)	0-25.0
Small gravel (<2 cm)	1.8 (± 2.6)	0-10.0
Rocks	1.2 (± 2.8)	0-10.0
Large gravel (>2 cm)	1.2 (± 2.6)	0-10.0
Bedrock	0.5 (± 1.8)	0-8.3
Water quality		
Temperature ($^{\circ}\text{C}$)	29.5 (± 2.9)	24.0-35.2
Dissolved oxygen (mg/l)	5.8 (± 2.0)	1.8-9.4
Transparency (cm)	47.2 (± 19.5)	16.0-90.0

Figure 9.6: Percentagens ($\pm$ desvio padrão) dos elementos do habitat de ambos os elementos marginais e composição do substrato que ocupam o perímetro molhado marginal dos locais de estudo e parâmetros médios de qualidade da água.

de estruturas de habitat foi geralmente maior nos locais dos rios, na área do Seridó e durante a estação chuvosa, apesar de uma maior riqueza de elementos de habitat nos locais dos reservatórios (Figura 9.7). A composição do substrato também foi mais diversa e rica nos locais do rio e na área do Seridó, enquanto o substrato foi mais rico e diversificado durante a estação seca (Figura 9.7). A análise de correspondência sem tendência (Figura 9.8) mostrou que as diferenças na estrutura do habitat foram significativas apenas entre os locais de riachos e reservatórios (MRPP, $A = 0,06$, $p = 0,03$) e estações (MRPP, $A = 0,06$, $p = 0,03$).

Table 3. Diversity and richness of habitat elements in study sites across habitat types, study area and seasons.

Habitat elements	A-priori groups	Richness (R)	Shannon's Diversity (H)
Marginal habitat			
Habitat type	River	4.4 (± 2.3)	0.942 (± 0.501)
	Reservoir	4.7 (± 1.6)	0.937 (± 0.397)
	Seridó	5.2 (± 2.2)	1.040 (± 0.539)
Area	Buíque	3.8 (± 1.4)	0.829 (± 0.283)
	Wet	5.3 (± 2.1)	1.083 (± 0.463)
Season	Dry	3.8 (± 1.6)	0.808 (± 0.389)
Substrate composition			
Habitat type	River	4.3 (± 0.8)	0.857 (± 0.289)
	Reservoir	3.0 (± 0.9)	0.497 (± 0.300)
	Seridó	3.9 (± 0.9)	0.801 (± 0.348)
Area	Buíque	3.3 (± 1.1)	0.525 (± 0.283)
	Wet	3.5 (± 1.2)	0.607 (± 0.333)
Season	Dry	3.8 (± 0.9)	0.727 (± 0.354)

Figure 9.7: Diversidade e riqueza de elementos do habitat em locais de estudo em todos os tipos de habitat, área de estudo e estações do ano.

Diferenças na estrutura do habitat entre as duas áreas de estudo não foram significativas (MRPP, $A = 0,01$, $p = 0,26$). A análise do valor indicador mostrou que os elementos importantes que separam esses grupos foram macrófitas para reservatórios ($IV = 53,2$, $p = 0,01$) e areia e pedras para locais fluviais ($IV = 61,8$, $p = 0,02$ e $IV = 82,6$, $p = 0,002$, respectivamente). Importantes características de habitat que separam as estações foram vegetação submersa ($IV = 48,4$, $0,01$) e vegetação pendente ($IV = 48,9$, $p = 0,02$) para a estação chuvosa. Nenhum elemento do substrato foi significativamente importante na separação dos locais de acordo com as estações do ano (Figura 9.8).

A análise de correspondência canônica mostrou que as variáveis de alcance e escala de captação não estavam fortemente correlacionadas, exceto para a distância do local à nascente do rio e comprimento do córrego da localização do local (correlação de Pearson = 0,965), elevação e comprimento do rio principal (Correlação de Pearson = 0,853) e elevação e largura do local (correlação de Pearson = 0,906). A variância total dos dados ("inércia") foi de 1,19. A variância total explicada pela CCA foi de 46,2%, sendo a maior parte dessa variação explicada pelo primeiro eixo (18,4%) (Figura 9.9. No entanto, os eixos 2 e 3




Figure 2. DCA results for habitat composition across the study sites. Insert box shows habitat elements correlated ($r^2 > 0.2$) with sampling sites/occasions in ordination space (denoted by vectors). The direction and length of vectors indicate strength of correlation. See Table 2 for full names of habitat elements. Sites (S1-S6) are coded as per Table 1 and sampling occasion. Abbreviations: APR, April; JUN, June; SEP, September; DEC, December.

Figure 9.8: Resultados da DCA para a composição do habitat nos locais de estudo. A caixa de inserção mostra elementos de habitat correlacionados ($r^2 > 0,2$) com locais/ocasiões de amostragem no espaço de ordenação (indicados por vetores). A direção e o comprimento dos vetores indicam a força da correlação. Consulte a Tabela 2 para obter os nomes completos dos elementos do habitat. Os locais (S1-S6) são codificados de acordo com a Tabela 1 e a ocasião da amostragem. Abreviaturas: APR, abril; JUN, junho; SET, setembro; DEZ, dezembro.

não podem ser desconsiderados, pois também explicaram parte substancial da variação do conjunto de dados. Os resultados da análise mostram uma relação significativa entre os dados de estrutura do habitat e as variáveis de alcance e escala de captação, com o autovalor do primeiro eixo muito alto para ser esperado por acaso (Figura 9.9, valores de p para autovalor e correlação para o primeiro eixo = 0,01). O primeiro eixo foi fortemente correlacionado com variáveis morfológicas da escala de captação, nomeadamente comprimento do rio principal, elevação e a distância altamente correlacionada do local à nascente do rio e comprimento do córrego da localização do local. O primeiro eixo também foi correlacionado com a inclinação da margem, uma variável morfológica da escala de alcance. Eixos 2 e 3 foram correlacionados com variáveis de escala de alcance de morfologia (largura do local, eixo 2) e qualidade da água (velocidade da água e oxigênio dissolvido, eixo 3) (Figura 9.9).

Table 4. Axis summary statistics of Canonical Correspondence Analysis for habitat structure and catchment- and reach-scale variables.

	Axis 1	Axis 2	Axis 3
Eigenvalue	0.220	0.179	0.153
Variance in species data			
% of variance explained	18.4	15.0	12.8
Cumulative % explained	18.4	33.4	46.2
Pearson Correlation, Spp-Envt	0.990	0.935	0.948
Kendall (Rank) Corr., Spp-Envt	0.905	0.771	0.771
Total variance ("inertia")	1.19		

Table 5. Correlations for catchment- and reach-scale variables with the ordination axes after Canonical Correspondence Analysis.

		Correlations		
Catchment scale morphology	Variable	Axis 1	Axis 2	Axis 3
	River length	-0.792	-0.177	0.142
	Length of stream of site location	-0.416	-0.120	-0.051
	Distance of site from source	-0.465	0.085	-0.082
	Distance of site from mouth	-0.266	0.021	-0.010
	Elevation	-0.553	-0.300	0.251
Reach scale morphology	Margin slope	0.595	0.159	-0.317
	Site width	-0.295	-0.520	0.329
	Habitat depth	0.024	0.346	0.035
	Maximum depth	-0.154	-0.070	0.355
Reach scale water quality	Velocity	0.132	0.047	0.423
	Dissolved Oxygen	-0.026	-0.238	-0.595
	Temperature	0.324	-0.080	0.320
	Transparency	0.098	-0.281	0.091

Figure 9.9: Estatísticas de sumário dos eixos da Análise de Correspondência Canônica para a estrutura do habitat e variáveis de escala de captação e alcance. Correlações para variáveis de escala de captação e alcance com os eixos de ordenação após Análise de Correspondência Canônica.

A Figura 9.10 indica que o eixo 1 representa um gradiente de sítios com estrutura de habitat influenciada por variáveis de escala de captação e o eixo 2 representa

sítios influenciados por variáveis de escala de alcance.




Figure 3. Biplot of ordination sites (Δ) (based on CCA) in the catchment- and reach-scale variables space, as defined by CCA. Vectors represent river length (RIVER), distance of site from source (DISTSOUR), elevation, margin slope (SLOPE) and site width (WIDTH). (+) indicates position of habitat elements in the ordination space.

Figure 9.10: Biplot de locais de ordenação (Δ) (com base na estrutura do habitat) na bacia e alcance- variáveis de escala espaço, conforme definido pelo CCA. Os vetores representam o comprimento do rio (RIVER), distância do local da fonte (DISTSOUR), elevação, inclinação da margem (SLOPE) e largura do local (WIDTH). (+) indica a posição dos elementos do habitat no espaço de ordenação.

9.6 Discussão

O presente estudo mostrou que o habitat aquático no semiárido brasileiro é diversificado e dinâmico, com uma gama de elementos de habitat disponíveis para colonização pela biota aquática. Sítios de riachos apresentaram uma composição de substrato e elementos de habitats marginais semelhante a maior quando comparados a reservatórios, e a composição do habitat variou com o tipo de habitat

(rio/reservatório) e estações (seco/úmido). Mudanças sazonais nas características físicas de ambientes variáveis foram relatadas para regiões secas em outros lugares es (Mackey, 1991; Davis et al., 2002). Essas mudanças geralmente estão associadas a flutuações nos níveis de água e morfologia do habitat (Osborne et al., 1987; Medeiros, 2005). No presente estudo, as variações sazonais do nível da água e do regime hidrológico influenciaram a morfometria e a estrutura do habitat dos locais de estudo. Dadas as características lóicas dos locais de riachos, areia e seixos foram as características de habitat mais importantes neste tipo de habitat, pois espera-se que substratos finos como lama sejam realizados durante as inundações. A Figura 2 também dá indicação de que rochas, cascalho e algas anexadas eram elementos importantes de habitat em locais de riachos. Já os reservatórios foram caracterizados principalmente pela presença de macrófitas, vegetação submersa e, em menor grau, lama. O fato de as macrófitas aquáticas não terem sido elementos importantes na definição de habitat nos córregos intermitentes estudados está relacionado aos extremos de inundação durante o período úmido. Maltchik e Pedro (2001) e Pedro et al. (2006) constataram que a inundação limitou a ocorrência de macrófitas aquáticas em riachos no semiárido brasileiro, onde as comunidades de macrófitas aquáticas sujeitas a inundação apresentaram menor riqueza de espécies do que as comunidades sem inundações. Os ciclos secos e úmidos em riachos semiáridos do nordeste do Brasil são caracterizados por extremos de inundações e secas e considerados como os mais importantes impulsionadores da estrutura da comunidade nesses sistemas (Maltchik e Medeiros, 2001; Maltchik e Florin, 2002). Os resultados do presente estudo mostram que os ciclos seco e úmido também desempenham um papel importante na estrutura do habitat, uma vez que a composição do habitat marginal e do substrato foram diferentes entre as estações. Curiosamente, o habitat marginal foi mais diverso durante a estação chuvosa do que durante a estação seca. Esse resultado discorda de outros estudos sobre estrutura de habitat em sistemas temporários ou semipermanentes (por exemplo, Kennard, 1995; Medeiros, 2005), que constataram que a riqueza e a diversidade de estruturas de habitat foram maiores durante a estação seca, quando a água recua níveis provocam a exposição de estruturas físicas anteriormente submersas, como galhos e troncos. Os dados apresentados neste estudo indicam um efeito oposto, pois a vegetação submersa e a vegetação pendente foram elementos característicos do habitat durante a estação chuvosa. Dado o aumento da área dos sistemas aquáticos durante o período úmido, a vegetação que outrora ocupou as margens secas do litoral de rios e reservatórios é inundada, agregando ainda mais complexidade ao habitat. Além disso, à medida que os riachos inundados atingem suas margens, o contato com a vegetação ciliar atinge seu máximo, aumentando ainda mais a complexidade do habitat (por exemplo, Pusey e Arthington, 2003). Como indicado pela alta importância da vegetação pendente durante a estação chuvosa, proximidade com a vegetação ciliar gera sombra, limitando o crescimento de macrófitas, mas acrescenta elementos ao habitat litorâneo como massas de raízes, serrapilheira e detritos. A composição do substrato, por outro lado, é mais provável de ser descoberta durante a estação seca, mais importante ainda nos riachos intermitentes, onde características como pedras e cascalho

tendem a ser mais frequentes em trechos mais profundos.

Apesar das diferenças na diversidade e riqueza de elementos de habitat entre Seridó e Buíque, a estrutura de habitat não foi diferente entre as duas áreas de estudo. Como o desenho amostral não é equilibrado (dois reservatórios na área do Buíque e apenas um na área do Seridó), a diversidade e a riqueza de elementos do habitat tendem a ser maiores no Seridó, devido à dominância de sites do tipo riacho nessa região. Pensa-se que os sistemas lóticos são organizados como uma hierarquia aninhada, tanto temporal quanto espacialmente (Johnson et al., 1995; Poff, 1997). Em uma hierarquia aninhada, processos de grande escala, como clima e geomorfologia, definem níveis mais altos de organização dos aspectos físicos e biológicos (por exemplo, morfologia do rio, regime de fluxo, pool de espécies) do ecossistema fluvial (Johnson et al., 1995). Esses níveis mais altos de organização influenciam fatores físicos e biológicos em uma variedade de escalas espaciais e temporais mais baixas, que podem ser particularmente relevantes para sistemas semiáridos (Poff, 1997; Maltchik e Medeiros, 2006). Portanto, em escalas temporais e espaciais relativamente curtas (ou seja, durante as estações secas e úmidas e através de bacias hidrográficas ou trechos de rios), vários fatores podem influenciar as variações no habitat físico disponível para os colonizadores.

No contexto do presente estudo, a Análise de Correspondência Canônica identificou vários níveis de variáveis de captação e alcance de riachos correlacionados com a estrutura do habitat. Ao nível da bacia, as variáveis que representam a ordem do riacho, como comprimento do rio, comprimento do córrego da localização do local e distância do local da fonte, foram importantes determinantes da estrutura do habitat. Na escala de alcance do córrego, a estrutura do habitat foi relacionada com a inclinação da margem e a largura do local, enquanto a profundidade não foi um determinante importante da estrutura do habitat. Como todas as variáveis de habitat foram medidas nas margens, não se deve esperar que a profundidade geral do local seja um elemento importante que afete a estrutura do habitat (a profundidade média foi de $34,4 \pm 19,4$ cm). Entretanto, a inclinação e a largura podem afetar o habitat físico através de sua influência no grau de conectividade entre o habitat aquático e terrestre. É importante lembrar que a declividade foi medida nas margens, compreendendo a porção terrestre das margens. Os parâmetros de qualidade da água em escala local também foram considerados importantes descritores da estrutura do habitat, principalmente aqueles associados ao conteúdo de oxigênio dissolvido na água (nomeadamente, oxigênio dissolvido e velocidade da água). Embora a temperatura e a transparência também possam estar relacionadas ao oxigênio dissolvido, a primeira foi relativamente constante em todos os locais de estudo (a temperatura média da água foi de $29,5 \pm 2,9$ °C) e a última (estimada a partir das profundidades de Secchi) foi muito alta em todas as áreas de estudo, como com médias por local variando de 16 a 90 cm. O modelo de habitat foi sugerido como uma estrutura onde fatores bióticos influenciam a biota (Southwood, 1977). Em ecossistemas de riachos, a inundação e a variabilidade do fluxo têm sido sugeridas como os principais eixos no modelo de habitat (Minshall,

1988; Poff e Ward, 1989). Embora os resultados apresentados neste estudo indiquem que as variações sazonais associadas ao regime de inundação e fluxo são elementos importantes que afetam a estrutura do habitat, há indícios de que o modelo de habitat pode ser multidimensional. Nos sistemas semiáridos do Brasil, a estrutura do habitat está sendo impulsionada por muitos componentes em diferentes níveis, onde o papel das características de captação e morfologia local e variáveis de água aumentariam em predominância em suas respectivas escalas. Isto realça a importância da ligação entre a estrutura do habitat e a diversidade biótica a nível local e regional.

O presente estudo mostra que a estrutura do habitat em sistemas semiáridos no nordeste do Brasil é composta por uma gama de elementos que variam de acordo com o tipo de habitat e estação do ano, enquanto a heterogeneidade do habitat foi mais forte nas escalas local e de captação do que entre áreas de captação. Portanto, vários níveis da hierarquia de captação são importantes para a estrutura do habitat, desde variáveis de escala de captação, como tamanho e elevação do rio, até características locais, como largura, inclinação e oxigênio dissolvido na água. Tais feições devem ser avaliadas e utilizadas como uma estrutura básica para caracterização e avaliação de habitats aquáticos no semiárido brasileiro. Os resultados apresentados têm implicações para a conservação e manejo dos sistemas semiáridos brasileiros. Dado que o habitat é a estrutura básica para a colonização de organismos aquáticos, os mecanismos potenciais que mantêm a diversidade biótica estão em todos os níveis da bacia hidrográfica. É fundamental, portanto, identificar as partes dos ecossistemas ribeirinhos que são vitais para a manutenção de sua saúde.

Referências

Part IV

IV. ESTADÍSTICAS DESCRITIVAS

Chapter 10

R Módulo 1 - Sintaxe e Tipos de dados no R

Apresentação

O R é uma **linguagem de expressão** com uma sintaxe muito simples (veja VENABLES; SMITH; R CORE TEAM (2026)). Ela é sensível a maiúsculas e minúsculas, como a maioria dos pacotes baseados em UNIX, então **A** e **a** são símbolos diferentes e se refeririam a variáveis diferentes. O conjunto de símbolos que podem ser usados nos nomes do R depende do sistema operacional e do país em que o R está sendo executado (tecnicamente, da localidade em uso). Normalmente, todos os símbolos alfanuméricos são permitidos (e em alguns países isso inclui letras acentuadas), além de `.` e `_`, com a restrição de que um nome deve começar com `.` ou uma letra, e se começar com `.`, o segundo caractere não deve ser um dígito. Os nomes são efetivamente ilimitados em comprimento.

ATENÇÃO

Evite usar nomes longos e complicados

Comandos elementares consistem em expressões ou atribuições. Se uma **expressão** for dada como um comando, ela é avaliada, impressa (a menos que seja especificamente tornada invisível) e o valor é perdido. Uma **atribuição** também avalia uma expressão e passa o valor para uma variável, mas o resultado não é automaticamente impresso.

Os comandos são separados por um ponto e vírgula (`;`) ou por uma nova linha (**Enter**). Comandos elementares podem ser agrupados em uma única expressão composta por chaves (`{` and `}`).

Comentários podem ser colocados em quase qualquer lugar, começando com uma marca de hash (`#`), e tudo até o final da linha é um comentário.

Se um comando não estiver completo no final de uma linha, o R fornecerá um prompt diferente, por padrão `+` (ao invés do tradicional `>`, nas linhas seguintes e continuará a ler a entrada até que o comando seja sintaticamente completo. Este prompt pode ser alterado pelo usuário. Geralmente, omitiremos o prompt de continuação e indicaremos a continuação apenas recuando.

As linhas de comando digitadas no console são limitadas a cerca de 4095 bytes (não caracteres).

No R, uma linguagem de programação amplamente utilizada para análise de dados e estatísticas, os tipos e estruturas de dados desempenham um papel fundamental na manipulação e organização das informações.

10.1 O que é um script e qual sua diferença para um código?

Em programação R, tanto “código” quanto “script” se referem a sequências de instruções escritas na linguagem de programação R (veja também Snippet e chunk). No entanto, há uma diferença sutil em como esses termos são geralmente usados:

1. Código:

Em R, “código” geralmente se refere a linhas individuais ou blocos de instruções de programação R que realizam tarefas ou operações específicas. O código pode ser escrito de forma interativa em um console R ou dentro de um arquivo de script. O código pode consistir em declarações simples, como atribuir valores a variáveis, realizar cálculos, definir funções ou chamar funções de pacotes.

2. Script:

Um “script” em R refere-se a um arquivo contendo uma série de instruções de código R. Scripts R são essencialmente arquivos de texto contendo uma sequência de comandos e declarações R que podem ser executados em conjunto. Os scripts R permitem que os usuários organizem seu código em unidades reutilizáveis e estruturadas. Os scripts R geralmente têm a extensão de arquivo “.R”.

Em resumo, enquanto “código” se refere a instruções individuais de programação R, “script” se refere a um arquivo contendo uma coleção de código R, geralmente usado para executar tarefas ou análises maiores de forma estruturada e organizada.

Terminologia de comandos no R

Como você já deve ter percebido, uma grande parte da sua interação com o R é feita por comandos ou **funções**, onde cada função realiza um determinado papel. Seja comandar o R a mostrar uma variável recém criada, função `print()`, seja para informar o resultado de uma operação, função `log()`.

Uma **função** vem sempre seguida de parênteses `()` (no formato, `função(x)`), dentro dos quais colocamos os **argumentos** da função. Os argumentos, por sua vez, devem ser separados por vírgula `,`. Os argumentos são informações adicionais que especificam certas particularidades para serem executadas pelas **funções**.

Usando a função `log()` como exemplo, temos:

```
log(x=20, base=10)
```

```
## [1] 1.30103
```

O argumento `x=` indica de qual valor queremos o log e o argumento `base=` indica qual base para o logaritmo o R vai usar.

Ou, em um segundo caso, podemos ter simplesmente a função sem nenhuma indicação de argumento:

```
log(20)
```

```
## [1] 2.995732
```

```
sqrt(25)
```

```
## [1] 5
```

Muitas funções possuem opções padrões (*default*) para alguns de seus argumentos. No caso do `log`, se não for dado nenhum argumento o **default** do R é usar o log natural do valor entre parêntesis.

Vários termos se misturam no R, sobre o que são comandos. Aqui seguiremos a seguinte terminologia (VENABLES; SMITH; R CORE TEAM, 2026):

Comando: É qualquer instrução que você dá para o R executar.

```
x <- 5
```

Aqui o comando é “atribuir 5 ao objeto `x`”.

Função: É um bloco de código que executa uma tarefa específica. No R, funções têm parênteses.

```
sum(c(1,2,3))
```

A função `sum()` calcula a soma.

Parâmetro: É o nome de uma entrada que a função aceita.

```
sample(x, size, replace)
#?sample
```

Aqui `x`, `size` e `replace` são parâmetros da função `sample()`.

Argumento: É o valor que você passa para um parâmetro.

```
sample(x = c(0,1,5), size = 10, replace = TRUE)
```

`c(0,1,5)` é o argumento para o parâmetro `x`. 10 é o argumento para `size` e `TRUE` é o argumento para `replace`.

Termo	O que é	Exemplo
Comando	Instrução para o R	<code>x <- 5</code>
Função	Código que executa tarefa	<code>sum()</code>
Parâmetro	Nome da entrada da função	<code>size</code> em <code>sample()</code>
Argumento	Valor passado ao parâmetro	10 em <code>size = 10</code>



IMPORTANTE

Relembre o Essencial de R no Capítulo de Introdução ao R/RStudio.

**IMPORTANTE**

Para definições operacionais dos comandos no R vá nos Apêndices do Capítulo Introdução ao R/RStudio e veja a seção Terminologia de comandos no R.

10.2 Tipos e estruturas de dados no R

No R, uma linguagem de programação amplamente utilizada para análise de dados e estatísticas, os tipos e estruturas de dados desempenham um papel fundamental na manipulação e organização das informações. Você vai conhecer esses tipos de estruturas de dados a seguir, mas antes se familiarize com como o R funciona.

Para começar a usar o R e analisar os dados do Projeto PPBio, abra o RStudio, verifique sua interface (Figura 10.1) e siga as instruções a seguir.




Figure 10.1: Interface típica do RStudio e nome dos painéis ou janelas.

Agora você pode começar a escrever seu código no console. Digite “Início do R Módulo” no console clique em Run (no canto superior direito do painel de edição de código) ou **Ctrl+Enter** e veja o que acontece:

```
"Início do R Módulo"
```

```
## [1] "Início do R Módulo"
```

O R mostra o que você escreveu, e apresenta este [1] do lado. Isso significa que seu resultado foi apresentado na primeira linha. Como você pode ver, o R imprime de volta (no Console) o resultado de comandos que você dá. Você agora pode tentar as operações básicas.

```
600+66
```

```
## [1] 666
```

```
y <- 600+66
```

Como mostrado acima, caso você queira guardar um valor, pode-se atribuí-lo a um objeto. Nesse caso, `y`.

Cálculos repetitivos podem ser automatizados usando um `loop`.

```
x <- 10
x
for (i in 1:5) {x+1->x
  print(x)}
x
```

```
## [1] 10
## [1] 11
## [1] 12
## [1] 13
## [1] 14
## [1] 15
## [1] 15
```

Aqui o número 1 foi somado cinco vezes ao valor de `x` que foi armazenado cada vez como `x` (substituindo o valor anterior) até chegar em 15. Na prática o R calculou $10+1=11$, $11+1=12$, $12+1=13$, $13+1=14$, $14+1=15$.

Note que o `:` foi usado para produzir uma seqüência de números de 1 a 5.

```
1:5
```

```
## [1] 1 2 3 4 5
```

O R usa os seguintes símbolos para as operações básicas:

```
`+` Adição
`-` Subtração
`/` Divisão
`*` Multiplicação
`^` Potência
`sqrt` Raiz quadrada (função)
`log` Logaritmo (função)
```

Por exemplo:

```
# Log
x <- 25
y <- log(x)
y <- log(x, base = exp(1)) #função exponencial, inversa do log
z <- log10(x)
z <- log(x, 10)
# Inverso
exp(y)
exp(1)^y
10^z

#Raiz quadrada
w <- sqrt(x)
# Inverso
w^2
```

```
## [1] 25
## [1] 25
## [1] 25
## [1] 25
```

Teste agora outras possibilidades com as operações básicas (veja BEASLEY (2004) pags 7-10 para outros exemplos de cálculos básicos).

Você já deve estar percebendo o potencial da programação em R como ferramenta para aprender estatística ou análise de dados, duas áreas com muita demanda de profissionais.

Em sua apostila “*Conversando com o R usando 57 palavras*”, MELO (2014) ressalta que a programação em R “ajuda no sentido de prover métodos para

resolvermos um problema ou entendermos uma análise”. Isso porque, primeiro, temos que reunir os elementos fundamentais e informações necessários, depois identificar e dar nomes a esses elementos, para apenas depois disso, decompor nosso problema em suas partes e, finalmente, colocar essas partes em sequência lógica.

A forma linear (passo-a-passo), mas hierarquicamente estruturada, da programação em R, permite uma construção intuitiva e lógica do raciocínio associado a cada análise, que, com o tempo, se torna parte cotidiano das nossas análises de dados. Assim como, na Língua Portuguesa, aprendemos o alfabeto, depois as palavras e eventualmente conversamos sem precisar pensar sobre a gramática e construção das frases.

10.3 Tipos e estruturas de dados no R

O R oferece uma variedade de tipos e estruturas de dados que permitem aos cientistas de dados e analistas manipular e organizar informações de forma eficiente. A escolha da estrutura de dados correta depende das necessidades específicas de análise e do tipo de dados que você está lidando.

1. Tipos de Dados Básicos:

- **Numéricos:** Representam valores numéricos, como inteiros ou números de ponto flutuante.
- **Caracteres:** Armazenam texto e são usados para representar sequências de caracteres.
- **Lógicos:** Armazenam valores lógicos (TRUE ou FALSE), úteis para expressar afirmações condicionais.
- **Complexos:** Armazenam números complexos.

2. Vetores:

- Os vetores são a estrutura de dados mais básica no R.
- Eles podem conter elementos de um único tipo de dado (exemplo: vetor numérico, de caracteres ou lógico).
- Os vetores são criados usando a função `c()`.

3. Matrizes:

- Matrizes são vetores bidimensionais, onde os elementos são organizados em linhas e colunas.
- Todos os elementos de uma matriz devem ser do mesmo tipo de dado.
- Matrizes podem ser criadas usando a função `matrix()`.

4. Data Frames:

- Data frames são estruturas de dados tabulares semelhantes a planilhas ou tabelas de banco de dados.

- Cada coluna de um data frame pode conter um tipo de dado diferente.
- Data frames são amplamente usados para armazenar e manipular conjuntos de dados.
- São frequentemente criados com funções como `data.frame()` ou lidos de arquivos externos.

5. Fatores:

- Fatores são usados para representar variáveis categóricas ou de fatores.
- São úteis para análises estatísticas e gráficos.
- Podem ser criados com a função `factor()`.

6. Listas:

- Listas são estruturas de dados flexíveis que podem conter elementos de diferentes tipos.
- Os elementos de uma lista podem ser acessados por meio de índices ou nomes.
- Listas são criadas usando a função `list()`.

7. Arrays:

- Arrays são estruturas multidimensionais que podem conter elementos de um único tipo de dado.
- São semelhantes às matrizes, mas podem ter mais de duas dimensões.
- Arrays são criados com a função `array()`.

8. Tabelas Hash:

- Tabelas hash são estruturas de dados que associam chaves a valores.
- Não são nativas do R, mas podem ser implementadas com pacotes como o `hash`.

10.4 Tipos de dados no R

10.4.1 Variáveis e tipos básicos de dados

Veja a Figura 10.2.

1. Tipos de Dados Básicos:

- **Numéricos:** Representam valores numéricos, como inteiros ou números de ponto flutuante.
- **Caracteres:** Armazenam texto e são usados para representar sequências de caracteres.
- **Lógicos:** Armazenam valores lógicos (TRUE ou FALSE), úteis para expressar afirmações condicionais.

- **Complexos:** Armazenam números complexos.

Para guardar os valores em uma variável em R, usamos `<-` (operador de atribuição). Neste caso, o print automático não ocorre, e caso queira checar qual é o valor daquela variável, basta digitar seu nome novamente, ou utilizar o comando `print(nome_da_variavel)`.

Vejamos:

```
a <- 5 + 3
a
print(a)
class(a)
```

```
## [1] 8
## [1] 8
## [1] "numeric"
```

Criamos um **objeto** do R chamado **a** que armazena o resultado de 5+3. Objetos são palavras ou letras às quais são atribuídos dados. A atribuição possibilita a manipulação de dados ou armazenamento dos resultados de análises (SILVA et al., 2022).

O objeto **a** é uma variável numérica, como você pode ver ao usar a função `class()`. Se quiser trabalhar com inteiros (**integer**), você deve defini-los como **integer**, através da função `as.integer()`, ou alternativamente, para criar explicitamente um integer, você precisa usar o sufixo **L**.

Vejamos:

```
var1 <- 3
var2 <- as.integer(3)
class(var1)
class(var2)
y <- 5L
typeof(y) #tipo interno básico usado pelo R para armazenar o
↪ objeto `y`
```

```
## [1] "numeric"
## [1] "integer"
## [1] "integer"
```

A função `class()` tem o mesmo efeito que a função `mode()`. Faça o teste.

Em R, os dados também podem ser do tipo `character`, que é uma variável de texto (em outras linguagens pode ser conhecida como `string`) e `logical` (que em outras linguagens pode ser conhecida como `boolean`), e que assume os valores `TRUE` ou `FALSE`.

Exemplos:

```
b <- "Ola mundo"
c <- TRUE
class(b)
class(c)
```

```
## [1] "character"
## [1] "logical"
```

10.5 Estruturas de dados no R

Agora vamos falar das estruturas de dados no R (Figura 10.3).

10.5.1 2. Vetores:

- Os vetores são a estrutura de dados mais básica no R.
- Eles podem conter elementos de um único tipo de dado (exemplo: numérico, caracteres ou lógico).
- Os vetores são criados usando a função `c()`.

Como já foi dito, os vetores são uma sequência simples de elementos do mesmo tipo. Quando definimos uma variável como fizemos anteriormente, é criado um vetor com um elemento (vetor numérico, vetor de caractere, etc.).

O R opera em **estruturas de dados nomeadas**. A estrutura mais simples é o **vetor numérico**, que é uma entidade única consistindo de uma coleção ordenada de números. Para configurar um vetor chamado `x`, por exemplo, consistindo de cinco números, a saber, 1.4, 6.5, 3, 4 e 71.2, usa-se o comando R:

```
x <- c(1.4, 6.5, 3, 4, 71.2)
```

Esta é uma instrução de atribuição usando a função `c()` (“combinar”), que neste contexto pode receber um número arbitrário de argumentos de vetor e cujo valor é um vetor obtido pela concatenação de seus argumentos de ponta a ponta.

Observe que o operador de atribuição (`<-`), que consiste nos dois caracteres ‘<’ (“menor que”) e ‘-’ (“menos”) ocorrendo estritamente lado a lado, e ele “aponta”

para o objeto que recebe o valor da expressão. Na maioria dos contextos, o operador '=' pode ser usado como uma alternativa.

Observe:

```
var1 <- 3
is.vector(var1)
```

```
## [1] TRUE
```

Isso explica aquele [1] que vimos no início do módulo. Quando você associa uma variável dessa forma, o R cria um vetor, e o valor que você definiu será o primeiro item deste vetor.

Para criarmos vetores com mais de um elemento, incluiremos os valores desejados dentro de um `c()` que significa *combinar*.

Veja o exemplo:

```
var1 <- c(3,6,7.8,332)
print(var1)
var2 <- c("Ola", "tudo", "bem")
print(var2)
var3 <- c(TRUE, FALSE, TRUE, TRUE, FALSE, FALSE, TRUE, TRUE,
  ↪ TRUE)
print(var3)
```

```
## [1] 3.0 6.0 7.8 332.0
## [1] "Ola" "tudo" "bem"
## [1] TRUE FALSE TRUE TRUE FALSE FALSE TRUE TRUE TRUE
```

Caso você tente misturar os tipos, o R irá forçar para que os elementos sejam todos do mesmo tipo. Veja alguns exemplos:

10.5.2 3. Matrizes:

- Matrizes são vetores bidimensionais, onde os elementos são organizados em linhas e colunas.
- Todos os elementos de uma matriz devem ser do mesmo tipo de dado.
- Matrizes podem ser criadas usando a função ``matrix()``.

As matrizes são estruturas que correspondem às matrizes matemáticas, conjuntos de elementos com linhas e colunas. Assim como os vetores, todos os seus elementos são do mesmo tipo. Existem algumas formas de criar uma matriz:


```
mat1 <- matrix(c(1,5,10,30,15,8),
  nrow=3,
  ncol=2,
  byrow=TRUE)
print(mat1)
```

```
##      [,1] [,2]
## [1,]    1    5
## [2,]   10   30
## [3,]   15    8
```

Ou

```
vec1 <- c(1, 5)
vec2 <- c(10, 30)
vec3 <- c(15, 8)
mat2 <- rbind(vec1, vec2, vec3)
print(mat2)
class(mat2)
```

```
##      [,1] [,2]
## vec1    1    5
## vec2   10   30
## vec3   15    8
## [1] "matrix" "array"
```

Ou

```
a <- sample(c(0,1,5), 10, replace=TRUE)
b <- sample(c(0,10,20), 10, replace=TRUE)
c <- sample(c(0,30,40), 10, replace=TRUE)
matrix(a,b,c)
```

```
## Warning in matrix(a, b, c): dados não vazios para matriz de extensão zero
```

```
##?matrix
matrix(c(a, b, c), ncol = 3, byrow = FALSE)
mat2 <- matrix(c(a, b, c), ncol = 3, byrow = FALSE)
mat2
#df1 <- data.frame(a,b,c)
#df1
```

```
## <0 x 0 matrix>
##      [,1] [,2] [,3]
## [1,]    1    0    0
## [2,]    0   20    0
## [3,]    1    0   30
## [4,]    1   20   30
## [5,]    1    0   30
## [6,]    1    0   40
## [7,]    5    0   30
## [8,]    1   10    0
## [9,]    5   10    0
## [10,]   1    0   40
##      [,1] [,2] [,3]
## [1,]    1    0    0
## [2,]    0   20    0
## [3,]    1    0   30
## [4,]    1   20   30
## [5,]    1    0   30
## [6,]    1    0   40
## [7,]    5    0   30
## [8,]    1   10    0
## [9,]    5   10    0
## [10,]   1    0   40
```

Na primeira forma, definimos os elementos da matriz, o número de linhas e colunas através dos **argumentos** `nrow` e `ncol`, e se os elementos serão preenchidos ao longo das linhas (`byrow = TRUE`) ou ao longo das colunas (`byrow = FALSE`).

Na segunda forma, criamos dois vetores e então os juntamos através da função `rbind()`. Repare que na segunda matriz, o R nomeou automaticamente as linhas da matriz com os nomes dos vetores, ao invés de definir seus números.

No terceiro caso, a função `sample()` realiza uma amostragem aleatória de elementos. No caso de `a`, são sorteados 10 valores do conjunto $\{0, 1, 5\}$, permitindo repetições (`replace = TRUE`). O resultado é armazenado no vetor `a`. Com a função `matrix()`, porque não funcionou como esperado? Peça ajuda com `?matrix`

Para selecionar itens de matrizes também utilizamos os colchetes, primeiro especificando a linha e depois a coluna que desejamos retornar, no formato `[linha, coluna]`:

```
mat1[2,1]
# outras possibilidades
mat2[ , c(1,3)] # todas as linhas, colunas 1 e 3
mat2[c(1,3), ]  # linhas 1 e 3, todas as colunas
```

```
mat2[1:2, 2:3]    # linhas 1 a 2, colunas 2 a 3
```

```
## [1] 10
##      [,1] [,2]
## [1,]    1    0
## [2,]    0    0
## [3,]    1   30
## [4,]    1   30
## [5,]    1   30
## [6,]    1   40
## [7,]    5   30
## [8,]    1    0
## [9,]    5    0
## [10,]   1   40
##      [,1] [,2] [,3]
## [1,]    1    0    0
## [2,]    1    0   30
##      [,1] [,2]
## [1,]    0    0
## [2,]   20    0
```

Note que as linhas e colunas não tem nomes específicos atribuídos a elas.

10.5.3 4. Data Frames:

- Data frames são estruturas de dados tabulares semelhantes a planilhas ou tabelas de banco de dados.
- Cada coluna de um data frame pode conter um tipo de dado diferente.
- Data frames são amplamente usados para armazenar e manipular conjuntos de dados.
- São frequentemente criados com funções como `data.frame()` ou lidos de arquivos externos.

O Data Frame é a estrutura do R utilizada para armazenar elementos em forma de tabela, organizados em linhas e colunas. As colunas e linhas podem ser nomeadas. Você pode criar um data frame com a função `data.frame()`:

```
df1 <- data.frame(c(1,2,3),c("baixo","medio","alto"),c(TRUE,
  ↪ TRUE, FALSE))
print(df1)
```

```
##   c.1..2..3. c..baixo....medio....alto.. c.TRUE..TRUE..FALSE.
## 1         1                baixo                TRUE
## 2         2                medio                TRUE
## 3         3                alto                 FALSE
```


Ou

```
df2 <- data.frame(Sp1=c(1,5,2,5,3), Sp2=c(21,8,10,7,18))
row.names(df2) <- LETTERS[1:5]
df2
```

```
##   Sp1 Sp2
## A   1  21
## B   5   8
## C   2  10
## D   5   7
## E   3  18
```

É possível plotar esse dataframe:

```
plot(df2, type='n'); text(df2, row.names(df2))
```



Dataframes ou **Matrizes** muito grandes são inviáveis de serem inseridas no ambiente do R através de digitação simples como mostrado anteriormente. Uma opção é usar a função `read.table(text="")` e colar a matriz de dados entre as aspas "...".

```
data <- read.table(text = "
Sp1 Sp2 Sp3 Sp4 Sp5 Sp6 Sp7
A 0 0 0 0 0 0 6
B 0 0 0 2 0 0 10
C 93 2 0 177 0 260 2
D 0 4 0 8 0 0 83
E 0 0 0 0 1 0 0
F 0 0 1 0 0 1 0
G 0 2 0 2 0 0 0
", header = TRUE, row.names = 1)
data
```

```
##   Sp1 Sp2 Sp3 Sp4 Sp5 Sp6 Sp7
## A   0   0   0   0   0   0   6
## B   0   0   0   2   0   0  10
## C  93   2   0 177   0 260   2
## D   0   4   0   8   0   0  83
## E   0   0   0   0   1   0   0
## F   0   0   1   0   0   1   0
## G   0   2   0   2   0   0   0
```

O R vem com alguns conjuntos de dados organizados em Data Frame na sua base, para a finalidade de testes e aprendizado. Um deles é o `mtcars`:

```
print(mtcars)
#?mtcars
```

```
##           mpg  cyl  disp  hp drat   wt  qsec vs am gear carb
## Mazda RX4      21.0    6 160.0 110 3.90 2.620 16.46 0  1    4    4
## Mazda RX4 Wag  21.0    6 160.0 110 3.90 2.875 17.02 0  1    4    4
## Datsun 710     22.8    4 108.0  93 3.85 2.320 18.61 1  1    4    1
## Hornet 4 Drive  21.4    6 258.0 110 3.08 3.215 19.44 1  0    3    1
## Hornet Sportabout 18.7    8 360.0 175 3.15 3.440 17.02 0  0    3    2
## Valiant        18.1    6 225.0 105 2.76 3.460 20.22 1  0    3    1
## Duster 360     14.3    8 360.0 245 3.21 3.570 15.84 0  0    3    4
## Merc 240D      24.4    4 146.7  62 3.69 3.190 20.00 1  0    4    2
## Merc 230       22.8    4 140.8  95 3.92 3.150 22.90 1  0    4    2
## Merc 280       19.2    6 167.6 123 3.92 3.440 18.30 1  0    4    4
## Merc 280C      17.8    6 167.6 123 3.92 3.440 18.90 1  0    4    4
## Merc 450SE     16.4    8 275.8 180 3.07 4.070 17.40 0  0    3    3
## Merc 450SL     17.3    8 275.8 180 3.07 3.730 17.60 0  0    3    3
## Merc 450SLC    15.2    8 275.8 180 3.07 3.780 18.00 0  0    3    3
```

## Cadillac Fleetwood	10.4	8	472.0	205	2.93	5.250	17.98	0	0	3	4
## Lincoln Continental	10.4	8	460.0	215	3.00	5.424	17.82	0	0	3	4
## Chrysler Imperial	14.7	8	440.0	230	3.23	5.345	17.42	0	0	3	4
## Fiat 128	32.4	4	78.7	66	4.08	2.200	19.47	1	1	4	1
## Honda Civic	30.4	4	75.7	52	4.93	1.615	18.52	1	1	4	2
## Toyota Corolla	33.9	4	71.1	65	4.22	1.835	19.90	1	1	4	1
## Toyota Corona	21.5	4	120.1	97	3.70	2.465	20.01	1	0	3	1
## Dodge Challenger	15.5	8	318.0	150	2.76	3.520	16.87	0	0	3	2
## AMC Javelin	15.2	8	304.0	150	3.15	3.435	17.30	0	0	3	2
## Camaro Z28	13.3	8	350.0	245	3.73	3.840	15.41	0	0	3	4
## Pontiac Firebird	19.2	8	400.0	175	3.08	3.845	17.05	0	0	3	2
## Fiat X1-9	27.3	4	79.0	66	4.08	1.935	18.90	1	1	4	1
## Porsche 914-2	26.0	4	120.3	91	4.43	2.140	16.70	0	1	5	2
## Lotus Europa	30.4	4	95.1	113	3.77	1.513	16.90	1	1	5	2
## Ford Pantera L	15.8	8	351.0	264	4.22	3.170	14.50	0	1	5	4
## Ferrari Dino	19.7	6	145.0	175	3.62	2.770	15.50	0	1	5	6
## Maserati Bora	15.0	8	301.0	335	3.54	3.570	14.60	0	1	5	8
## Volvo 142E	21.4	4	121.0	109	4.11	2.780	18.60	1	1	4	2

Algumas funções úteis para conjuntos muito grandes de dados que você deve conhecer:

```

class(mtcars)
mode(mtcars)
typeof(mtcars)
str(mtcars) #atenção
mtcars[1,2]
mtcars["Mazda RX4", "gear"]
mtcars[1:5,1]
mtcars[,2]
mtcars[3,]
rownames(mtcars)
colnames(mtcars)
names(mtcars)
rowSums(mtcars)
colSums(mtcars)
rowMeans(mtcars)
colMeans(mtcars)
mtcars$gear #atenção
sum(mtcars)
mean(as.matrix(mtcars))
sd(as.matrix(mtcars))
t(mtcars) #atenção
nrow(mtcars)
ncol(mtcars)

```

```
mtcars[mtcars<=3]
mtcars[mtcars==0]
mtcars[mtcars!=0] #`!` significa negação lógica (NOT), inverte
  ↪ valores lógicos
length(as.matrix(mtcars))
dim(mtcars)
length(mtcars[mtcars==0])
summary(mtcars) #atenção
```

```
## [1] "data.frame"
## [1] "list"
## [1] "list"
## 'data.frame': 32 obs. of 11 variables:
## $ mpg : num 21 21 22.8 21.4 18.7 18.1 14.3 24.4 22.8 19.2 ...
## $ cyl : num 6 6 4 6 8 6 8 4 4 6 ...
## $ disp: num 160 160 108 258 360 ...
## $ hp : num 110 110 93 110 175 105 245 62 95 123 ...
## $ drat: num 3.9 3.9 3.85 3.08 3.15 2.76 3.21 3.69 3.92 3.92 ...
## $ wt : num 2.62 2.88 2.32 3.21 3.44 ...
## $ qsec: num 16.5 17 18.6 19.4 17 ...
## $ vs : num 0 0 1 1 0 1 0 1 1 1 ...
## $ am : num 1 1 1 0 0 0 0 0 0 0 ...
## $ gear: num 4 4 4 3 3 3 3 4 4 4 ...
## $ carb: num 4 4 1 1 2 1 4 2 2 4 ...
## [1] 6
## [1] 4
## [1] 21.0 21.0 22.8 21.4 18.7
## [1] 6 6 4 6 8 6 8 4 4 6 6 8 8 8 8 8 4 4 4 4 8 8 8 8 4 4 4 8 6 8 4
## mpg cyl disp hp drat wt qsec vs am gear carb
## Datsun 710 22.8 4 108 93 3.85 2.32 18.61 1 1 4 1
## [1] "Mazda RX4" "Mazda RX4 Wag" "Datsun 710"
## [4] "Hornet 4 Drive" "Hornet Sportabout" "Valiant"
## [7] "Duster 360" "Merc 240D" "Merc 230"
## [10] "Merc 280" "Merc 280C" "Merc 450SE"
## [13] "Merc 450SL" "Merc 450SLC" "Cadillac Fleetwood"
## [16] "Lincoln Continental" "Chrysler Imperial" "Fiat 128"
## [19] "Honda Civic" "Toyota Corolla" "Toyota Corona"
## [22] "Dodge Challenger" "AMC Javelin" "Camaro Z28"
## [25] "Pontiac Firebird" "Fiat X1-9" "Porsche 914-2"
## [28] "Lotus Europa" "Ford Pantera L" "Ferrari Dino"
## [31] "Maserati Bora" "Volvo 142E"
## [1] "mpg" "cyl" "disp" "hp" "drat" "wt" "qsec" "vs" "am" "gear"
## [11] "carb"
## [1] "mpg" "cyl" "disp" "hp" "drat" "wt" "qsec" "vs" "am" "gear"
```

```

## [11] "carb"
##      Mazda RX4      Mazda RX4 Wag      Datsun 710      Hornet 4 Drive
##      328.980        329.795        259.580        426.135
##      Hornet Sportabout      Valiant      Duster 360      Merc 240D
##      590.310        385.540        656.920        270.980
##      Merc 230      Merc 280      Merc 280C      Merc 450SE
##      299.570        350.460        349.660        510.740
##      Merc 450SL      Merc 450SLC      Cadillac Fleetwood      Lincoln Continental
##      511.500        509.850        728.560        726.644
##      Chrysler Imperial      Fiat 128      Honda Civic      Toyota Corolla
##      725.695        213.850        195.165        206.955
##      Toyota Corona      Dodge Challenger      AMC Javelin      Camaro Z28
##      273.775        519.650        506.085        646.280
##      Pontiac Firebird      Fiat X1-9      Porsche 914-2      Lotus Europa
##      631.175        208.215        272.570        273.683
##      Ford Pantera L      Ferrari Dino      Maserati Bora      Volvo 142E
##      670.690        379.590        694.710        288.890
##      mpg      cyl      disp      hp      drat      wt      qsec      vs
## 642.900 198.000 7383.100 4694.000 115.090 102.952 571.160 14.000
##      am      gear      carb
## 13.000 118.000 90.000
##      Mazda RX4      Mazda RX4 Wag      Datsun 710      Hornet 4 Drive
##      29.90727        29.98136        23.59818        38.73955
##      Hornet Sportabout      Valiant      Duster 360      Merc 240D
##      53.66455        35.04909        59.72000        24.63455
##      Merc 230      Merc 280      Merc 280C      Merc 450SE
##      27.23364        31.86000        31.78727        46.43091
##      Merc 450SL      Merc 450SLC      Cadillac Fleetwood      Lincoln Continental
##      46.50000        46.35000        66.23273        66.05855
##      Chrysler Imperial      Fiat 128      Honda Civic      Toyota Corolla
##      65.97227        19.44091        17.74227        18.81409
##      Toyota Corona      Dodge Challenger      AMC Javelin      Camaro Z28
##      24.88864        47.24091        46.00773        58.75273
##      Pontiac Firebird      Fiat X1-9      Porsche 914-2      Lotus Europa
##      57.37955        18.92864        24.77909        24.88027
##      Ford Pantera L      Ferrari Dino      Maserati Bora      Volvo 142E
##      60.97182        34.50818        63.15545        26.26273
##      mpg      cyl      disp      hp      drat      wt      qsec
## 20.090625 6.187500 230.721875 146.687500 3.596563 3.217250 17.848750
##      vs      am      gear      carb
## 0.437500 0.406250 3.687500 2.812500
## [1] 4 4 4 3 3 3 3 4 4 4 3 3 3 3 3 3 4 4 4 3 3 3 3 4 5 5 5 5 4
## [1] 13942.2
## [1] 39.60853
## [1] 84.20792
##      Mazda RX4 Mazda RX4 Wag Datsun 710 Hornet 4 Drive Hornet Sportabout

```



```
## mpg      21.00      21.000      22.80      21.400      18.70
## cyl       6.00       6.000       4.00       6.000       8.00
## disp    160.00     160.000     108.00     258.000     360.00
## hp      110.00     110.000     93.00     110.000     175.00
## drat     3.90      3.900      3.85      3.080      3.15
## wt       2.62      2.875      2.32      3.215      3.44
## qsec    16.46     17.020     18.61     19.440     17.02
## vs       0.00      0.000      1.00      1.000      0.00
## am       1.00      1.000      1.00      0.000      0.00
## gear     4.00      4.000      4.00      3.000      3.00
## carb     4.00      4.000      1.00      1.000      2.00
##          Valiant Duster 360 Merc 240D Merc 230 Merc 280 Merc 280C Merc 450SE
## mpg      18.10      14.30      24.40      22.80      19.20      17.80      16.40
## cyl       6.00       8.00       4.00       4.00       6.00       6.00       8.00
## disp    225.00     360.00     146.70     140.80     167.60     167.60     275.80
## hp      105.00     245.00     62.00     95.00     123.00     123.00     180.00
## drat     2.76      3.21      3.69      3.92      3.92      3.92      3.07
## wt       3.46      3.57      3.19      3.15      3.44      3.44      4.07
## qsec    20.22     15.84     20.00     22.90     18.30     18.90     17.40
## vs       1.00      0.00      1.00      1.00      1.00      1.00      0.00
## am       0.00      0.00      0.00      0.00      0.00      0.00      0.00
## gear     3.00      3.00      4.00      4.00      4.00      4.00      3.00
## carb     1.00      4.00      2.00      2.00      4.00      4.00      3.00
##          Merc 450SL Merc 450SLC Cadillac Fleetwood Lincoln Continental
## mpg      17.30      15.20      10.40      10.40
## cyl       8.00       8.00       8.00       8.00
## disp    275.80     275.80     472.00     460.00
## hp      180.00     180.00     205.00     215.00
## drat     3.07      3.07      2.93      3.00
## wt       3.73      3.78      5.25      5.424
## qsec    17.60     18.00     17.98     17.820
## vs       0.00      0.00      0.00      0.00
## am       0.00      0.00      0.00      0.00
## gear     3.00      3.00      3.00      3.00
## carb     3.00      3.00      4.00      4.00
##          Chrysler Imperial Fiat 128 Honda Civic Toyota Corolla Toyota Corona
## mpg      14.700     32.40     30.400     33.900     21.500
## cyl       8.000      4.00      4.000      4.000      4.000
## disp    440.000     78.70     75.700     71.100     120.100
## hp      230.000     66.00     52.000     65.000     97.000
## drat     3.230      4.08      4.930      4.220      3.700
## wt       5.345      2.20      1.615      1.835      2.465
## qsec    17.420     19.47     18.520     19.900     20.010
## vs       0.000      1.00      1.000      1.000      1.000
## am       0.000      1.00      1.000      1.000      0.000
## gear     3.000      4.00      4.000      4.000      3.000
```

```

## carb          4.000      1.00      2.000          1.000      1.000
##      Dodge Challenger AMC Javelin Camaro Z28 Pontiac Firebird Fiat X1-9
## mpg          15.50      15.200      13.30          19.200      27.300
## cyl           8.00      8.000      8.00          8.000      4.000
## disp         318.00      304.000      350.00          400.000      79.000
## hp           150.00      150.000      245.00          175.000      66.000
## drat          2.76      3.150      3.73          3.080      4.080
## wt            3.52      3.435      3.84          3.845      1.935
## qsec          16.87      17.300      15.41          17.050      18.900
## vs            0.00      0.000      0.00          0.000      1.000
## am            0.00      0.000      0.00          0.000      1.000
## gear          3.00      3.000      3.00          3.000      4.000
## carb          2.00      2.000      4.00          2.000      1.000
##      Porsche 914-2 Lotus Europa Ford Pantera L Ferrari Dino Maserati Bora
## mpg          26.00      30.400          15.80          19.70          15.00
## cyl           4.00      4.000          8.00          6.00          8.00
## disp         120.30      95.100          351.00          145.00          301.00
## hp           91.00      113.000          264.00          175.00          335.00
## drat          4.43      3.770          4.22          3.62          3.54
## wt            2.14      1.513          3.17          2.77          3.57
## qsec          16.70      16.900          14.50          15.50          14.60
## vs            0.00      1.000          0.00          0.00          0.00
## am            1.00      1.000          1.00          1.00          1.00
## gear          5.00      5.000          5.00          5.00          5.00
## carb          2.00      2.000          4.00          6.00          8.00
##      Volvo 142E
## mpg          21.40
## cyl           4.00
## disp         121.00
## hp           109.00
## drat          4.11
## wt            2.78
## qsec          18.60
## vs            1.00
## am            1.00
## gear          4.00
## carb          2.00
## [1] 32
## [1] 11
## [1] 2.760 2.930 3.000 2.760 2.620 2.875 2.320 2.200 1.615 1.835 2.465 1.935
## [13] 2.140 1.513 2.770 2.780 0.000 0.000 1.000 1.000 0.000 1.000 0.000 1.000
## [25] 1.000 1.000 1.000 0.000 0.000 0.000 0.000 0.000 0.000 1.000 1.000 1.000
## [37] 1.000 0.000 0.000 0.000 0.000 1.000 0.000 1.000 0.000 0.000 0.000 1.000
## [49] 1.000 1.000 1.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
## [61] 0.000 0.000 0.000 0.000 0.000 1.000 1.000 1.000 0.000 0.000 0.000 0.000
## [73] 0.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 3.000 3.000 3.000 3.000

```

```
## [85] 3.000 3.000 3.000 3.000 3.000 3.000 3.000 3.000 3.000 3.000 3.000 3.000 1.000
## [97] 1.000 2.000 1.000 2.000 2.000 3.000 3.000 3.000 3.000 1.000 2.000 1.000 1.000
## [109] 2.000 2.000 2.000 1.000 2.000 2.000 2.000
## [1] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [1] 21.000 21.000 22.800 21.400 18.700 18.100 14.300 24.400 22.800
## [10] 19.200 17.800 16.400 17.300 15.200 10.400 10.400 14.700 32.400
## [19] 30.400 33.900 21.500 15.500 15.200 13.300 19.200 27.300 26.000
## [28] 30.400 15.800 19.700 15.000 21.400 6.000 6.000 4.000 6.000
## [37] 8.000 6.000 8.000 4.000 4.000 6.000 6.000 8.000 8.000
## [46] 8.000 8.000 8.000 8.000 4.000 4.000 4.000 4.000 8.000
## [55] 8.000 8.000 8.000 4.000 4.000 4.000 8.000 6.000 8.000
## [64] 4.000 160.000 160.000 108.000 258.000 360.000 225.000 360.000 146.700
## [73] 140.800 167.600 167.600 275.800 275.800 275.800 472.000 460.000 440.000
## [82] 78.700 75.700 71.100 120.100 318.000 304.000 350.000 400.000 79.000
## [91] 120.300 95.100 351.000 145.000 301.000 121.000 110.000 110.000 93.000
## [100] 110.000 175.000 105.000 245.000 62.000 95.000 123.000 123.000 180.000
## [109] 180.000 180.000 205.000 215.000 230.000 66.000 52.000 65.000 97.000
## [118] 150.000 150.000 245.000 175.000 66.000 91.000 113.000 264.000 175.000
## [127] 335.000 109.000 3.900 3.900 3.850 3.080 3.150 2.760 3.210
## [136] 3.690 3.920 3.920 3.920 3.070 3.070 3.070 2.930 3.000
## [145] 3.230 4.080 4.930 4.220 3.700 2.760 3.150 3.730 3.080
## [154] 4.080 4.430 3.770 4.220 3.620 3.540 4.110 2.620 2.875
## [163] 2.320 3.215 3.440 3.460 3.570 3.190 3.150 3.440 3.440
## [172] 4.070 3.730 3.780 5.250 5.424 5.345 2.200 1.615 1.835
## [181] 2.465 3.520 3.435 3.840 3.845 1.935 2.140 1.513 3.170
## [190] 2.770 3.570 2.780 16.460 17.020 18.610 19.440 17.020 20.220
## [199] 15.840 20.000 22.900 18.300 18.900 17.400 17.600 18.000 17.980
## [208] 17.820 17.420 19.470 18.520 19.900 20.010 16.870 17.300 15.410
## [217] 17.050 18.900 16.700 16.900 14.500 15.500 14.600 18.600 1.000
## [226] 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000
## [235] 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000
## [244] 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 4.000
## [253] 4.000 4.000 3.000 3.000 3.000 3.000 4.000 4.000 4.000
## [262] 4.000 3.000 3.000 3.000 3.000 3.000 3.000 4.000 4.000
## [271] 4.000 3.000 3.000 3.000 3.000 3.000 4.000 5.000 5.000
## [280] 5.000 5.000 5.000 4.000 4.000 4.000 1.000 1.000 2.000
## [289] 1.000 4.000 2.000 2.000 4.000 4.000 3.000 3.000 3.000
## [298] 4.000 4.000 4.000 1.000 2.000 1.000 1.000 2.000 2.000
## [307] 4.000 2.000 1.000 2.000 2.000 4.000 6.000 8.000 2.000
## [1] 352
## [1] 32 11
## [1] 37
##      mpg      cyl      disp      hp
## Min.   :10.40  Min.   :4.000  Min.   : 71.1  Min.   : 52.0
## 1st Qu.:15.43  1st Qu.:4.000  1st Qu.:120.8  1st Qu.: 96.5
## Median :19.20  Median :6.000  Median :196.3  Median :123.0
```

```
## Mean :20.09 Mean :6.188 Mean :230.7 Mean :146.7
## 3rd Qu.:22.80 3rd Qu.:8.000 3rd Qu.:326.0 3rd Qu.:180.0
## Max. :33.90 Max. :8.000 Max. :472.0 Max. :335.0
##      drat      wt      qsec      vs
## Min. :2.760 Min. :1.513 Min. :14.50 Min. :0.0000
## 1st Qu.:3.080 1st Qu.:2.581 1st Qu.:16.89 1st Qu.:0.0000
## Median :3.695 Median :3.325 Median :17.71 Median :0.0000
## Mean :3.597 Mean :3.217 Mean :17.85 Mean :0.4375
## 3rd Qu.:3.920 3rd Qu.:3.610 3rd Qu.:18.90 3rd Qu.:1.0000
## Max. :4.930 Max. :5.424 Max. :22.90 Max. :1.0000
##      am      gear      carb
## Min. :0.0000 Min. :3.000 Min. :1.000
## 1st Qu.:0.0000 1st Qu.:3.000 1st Qu.:2.000
## Median :0.0000 Median :4.000 Median :2.000
## Mean :0.4062 Mean :3.688 Mean :2.812
## 3rd Qu.:1.0000 3rd Qu.:4.000 3rd Qu.:4.000
## Max. :1.0000 Max. :5.000 Max. :8.000
```

O símbolo `$` é usado para acessar uma coluna específica dentro de um dataframe, no formato `dataframe$coluna`. Já a função `t()`, inverte linhas e colunas, equivalente a **transpor** uma matriz de dados ou um dataframe.

As funções `str()` e `summary()` trazem algumas informações úteis sobre o dataframe, de uma forma geral. É comum utiliza-las ao importar uma base de dados para o R, para se ter uma ideia do que está sendo analisado. O `str()` conta as linhas e colunas e mostra os seus tipos e alguns valores de exemplo. Já o `summary()` traz médias, medianas, máximos, mínimos e quantidade de valores indisponíveis em cada coluna.

10.5.4 5. Fatores:

- Fatores são usados para representar variáveis categóricas ou de fatores.
- São úteis para análises estatísticas e gráficos.
- Podem ser criados com a função ``factor()``.

Por fim, temos os fatores (factors). Fatores são usados para representar categorias. Isso quer dizer que em uma variável do tipo **factor**, aquele valor terá uma quantidade limitada de valores. Pense, por exemplo, nos meses do ano ou letras do alfabeto. Existe um número definido de meses, e o valor estará dentro destas possibilidades. Um nome de uma pessoa, ao contrário, tem infinitas possibilidades, pois não existe uma lista pré-definida de nomes de pessoas, e qualquer um pode criar um novo nome. Para criar um fator, vamos aproveitar o exemplo dos meses do ano e utilizar a função `factor()`:

```
meses <- c("Jan", "Jan", "Feb", "Mar", "Apr", "Apr", "May", "Jan", "Jan"
  ↪      , "May", "May", "Jun")
meses
mesesf <- factor(meses)
print(mesesf)
table(mesesf)
```

```
## [1] "Jan" "Jan" "Feb" "Mar" "Apr" "Apr" "May" "Jan" "Jan" "May" "May" "Jun"
## [1] Jan Jan Feb Mar Apr Apr May Jan Jan May May Jun
## Levels: Apr Feb Jan Jun Mar May
## mesesf
## Apr Feb Jan Jun Mar May
##      2      1      4      1      1      3
```

Um `vector` ou “vetor” é uma estrutura de dados fundamental que armazena uma sequência ordenada de elementos do mesmo tipo. Ao imprimir (`print()`) o vetor `meses`, vemos que o R nos indica os níveis (`levels`), que nada mais são do que os valores únicos que existem naquele vetor. Usando a função `table()`, podemos ver a contagem de cada uma das categorias. Vemos que elas estão ordenadas em ordem alfabética.

Como isso pode ser aplicado?


```
meses <- c("Jan", "Jan", "Jan", "Feb", "Feb", "Feb", "Feb",
  ↪      "Mar", "Mar", "Mar", "Apr", "Apr", "Apr", "May", "May",
  ↪      "May", "Jun", "Jun", "Jun")
meses
factor(meses)
print(meses)
table(meses)
riq <- c(3, 5, 7, 6, 8, 9, 0, 4, 6, 9, 2, 6, 3, 9, 6, 0, 1, 6, 7)
dados <- data.frame(Mes = meses, Riqueza = riq)
riq
dados
factor(meses)
plot(factor(meses), riq)
by(riq, meses, mean)
```

```
## [1] "Jan" "Jan" "Jan" "Feb" "Feb" "Feb" "Feb" "Mar" "Mar" "Mar" "Apr" "Apr"
## [13] "Apr" "May" "May" "May" "Jun" "Jun" "Jun"
## [1] Jan Jan Jan Feb Feb Feb Feb Mar Mar Mar Apr Apr Apr May May May Jun Jun Jun
## Levels: Apr Feb Jan Jun Mar May
## [1] "Jan" "Jan" "Jan" "Feb" "Feb" "Feb" "Feb" "Mar" "Mar" "Mar" "Apr" "Apr"
```

```

## [13] "Apr" "May" "May" "May" "Jun" "Jun" "Jun"
## meses
## Apr Feb Jan Jun Mar May
##   3   4   3   3   3   3
##  [1] 3 5 7 6 8 9 0 4 6 9 2 6 3 9 6 0 1 6 7
##      Mes Riqueza
## 1 Jan          3
## 2 Jan          5
## 3 Jan          7
## 4 Feb          6
## 5 Feb          8
## 6 Feb          9
## 7 Feb          0
## 8 Mar          4
## 9 Mar          6
## 10 Mar         9
## 11 Apr          2
## 12 Apr          6
## 13 Apr          3
## 14 May          9
## 15 May          6
## 16 May          0
## 17 Jun          1
## 18 Jun          6
## 19 Jun          7
##  [1] Jan Jan Jan Feb Feb Feb Feb Mar Mar Mar Apr Apr Apr May May May Jun Jun Jun
## Levels: Apr Feb Jan Jun Mar May
## meses: Apr
## [1] 3.666667
## -----
## meses: Feb
## [1] 5.75
## -----
## meses: Jan
## [1] 5
## -----
## meses: Jun
## [1] 4.666667
## -----
## meses: Mar
## [1] 6.333333
## -----
## meses: May
## [1] 5

```



10.5.5 6. Listas

Listas são um tipo especial de vetor, que podem conter elementos de diferentes tipos, incluindo vetores. Veja a lista baseada em alguns vetores, a seguir:

```
a <- c(3,6,9)
b <- c("a","b","c","d")
c <- c(TRUE, FALSE, TRUE, TRUE)
lista1 <- list(a,b,c)
print(lista1)
```

```
## [[1]]
## [1] 3 6 9
##
## [[2]]
## [1] "a" "b" "c" "d"
##
## [[3]]
## [1] TRUE FALSE TRUE TRUE
```

RESUMO (De <http://venus.ifca.unican.es/Rintro/dataStruct.html>)

- Vetores: arrays unidimensionais usados para armazenar coleções de dados do mesmo tipo

Vetores Numéricos (mode: numeric)

Vetores Complexos (mode: complex)

Vetores Lógicos (mode: logical)

Vetor de Caracteres ou strings de texto (mode: character)

- Matrizes: arrays bidimensionais para armazenar coleções de dados do mesmo modo. São acessados por dois índices inteiros.
- Arrays: semelhantes a matrizes, mas podem ser multidimensionais (mais de duas dimensões).
- Fatores: vetores de variáveis categóricas projetados para agrupar os componentes de outro vetor com o mesmo tamanho.
- Listas: coleção ordenada de objetos, onde os elementos podem ser de tipos diferentes.
- Data Frames: generalização de matrizes onde diferentes colunas podem armazenar dados de modo diferente.
- Funções: objetos criados pelo usuário e reutilizados para realizar operações específicas.


Data Type	Example	Description
Logical	TRUE, FALSE	boolean values
Numeric	2, 45.9, 3782	Numbers of all kinds
Integer	9L, 779L	Explicitly Integers
Complex	8+9i	Real Value + Complex Value
Character	'm', "hello"	Characters and Strings
Raw		Any data is stored as raw bytes

Figure 10.2: Resumo visual dos tipos de dados no ambiente de programação R. (De: <https://www.tutorialkart.com/r-tutorial/r-data-types>)

10.6 Pacotes (packages)

Os pacotes do R são conjuntos de funções, dados e ferramentas desenvolvidos para ampliar as capacidades da linguagem. Eles permitem executar tarefas específicas de forma mais simples e eficiente, como análises estatísticas, criação de gráficos, manipulação de dados, modelagem ecológica e análise multivariada.

O R já possui funções básicas instaladas, porém muitos recursos adicionais são disponibilizados por meio de pacotes criados pela comunidade científica e por




Figure 10.3: Resumo visual dos tipos de dados no ambiente de programação R. (De: <https://lhmet.github.io/adar-ebook/estrutura-dados.html>)

desenvolvedores. Assim, os pacotes tornam o R extremamente flexível e adaptável para diferentes áreas do conhecimento.

Para utilizar um pacote, primeiro é necessário instalá-lo com:

```
install.packages("nome_do_pacote")
```

Depois, o pacote deve ser carregado na sessão do R usando:

```
library(nome_do_pacote)
```

Por exemplo, o pacote `vegan` (DIXON, 2003) é amplamente utilizado em ecologia numérica, enquanto o `ggplot2` (WICKHAM, 2016) é muito usado para criação de gráficos. A autoria de um pacote pode ser referenciada usando a função `citation("nome_do_pacote")`

10.7 Como pedir ajuda?

10.7.1 Dentro do R

No R, você pode solicitar ajuda de várias maneiras:

1. `help()` ou `?`:

Você pode usar a função `help()` seguida pelo nome da função ou pacote sobre o qual você precisa de ajuda. Por exemplo:

```
help(mean)
```

Ou, de forma mais concisa:

```
?getwd()
```

O símbolo `?` é usado para acessar a documentação de uma função ou um pacote no R. Como mostrado acima você pode saber mais sobre a função `getwd()`, usando o comando `?getwd`. Isso vai abrir uma página no menu de ajuda com a descrição, os argumentos, os valores de retorno e os exemplos da função `getwd()`. Você também pode usar o símbolo `?` para obter informações sobre um pacote inteiro. Por exemplo, se você quiser saber mais sobre o pacote `openxlsx`, você pode digitar `?openxlsx`. Isso vai abrir uma página com a visão geral, a instalação, os recursos e as referências do pacote solicitado. Se você recebeu uma mensagem de erro, talvez precise instalar esse pacote (`install.packages("openxlsx")`)

A janela de ajuda do R apresenta as seguintes informações:

função{pacote} - a função solicitada na ajuda e o pacote onde ela se encontra

Description - resumo da função

Usage - como utilizar a função e quais os seus argumentos

Arguments - detalha os argumentos e como os mesmos devem ser especificados

Details - detalhes importantes para se usar a função

Value - mostra como interpretar a saída (output) da função (os resultados)

Notes - notas gerais sobre a função

Authors - autores da função

References - referências bibliográficas para os métodos usados pra construir a função

See also - funções relacionadas

Examples - exemplos do uso da função. Às vezes pode ser útil copiar esse trecho e colar no R para ver como funciona e como usar a função.

2. `help.search()`:

Você pode pesquisar por termos relacionados à sua dúvida usando a função `help.search()`.

```
help.search("linear regression")
```

3. `example()`:

Para ver exemplos de como usar uma função, você pode usar a função `example()`.

```
example(mean)
```

10.7.2 Fora do R

4. R Site e Documentação Online:

O site oficial do R (<https://www.r-project.org/>) oferece uma vasta documentação, tutoriais e recursos para ajudá-lo a aprender e resolver problemas.

5. Fóruns e Comunidades Online:

Existem várias comunidades online onde você pode fazer perguntas e obter ajuda de outros usuários do R, como o Stack Overflow (<https://stackoverflow.com/>), o RStudio Community (<https://community.rstudio.com/>), entre outros.

6. Livros e Tutoriais:

Existem muitos livros e tutoriais disponíveis que podem ajudá-lo a aprender R, desde os conceitos básicos até técnicas avançadas. Os livros em Português mais importantes são (FERREIRA; OLIVEIRA, 2020; OLIVEIRA; GUERRA; MCDONNELL, 2018; SILVA et al., 2022).

Ao usar esses recursos, certifique-se de fornecer informações claras sobre sua dúvida ou problema, incluindo detalhes como o código que você está usando, mensagens de erro (se houver) e o que você já tentou fazer para resolver o problema. Isso ajudará os outros a entenderem melhor sua situação e fornecer uma resposta mais útil.

10.7.3 ChatGPT

Pergunte ao ChatGPT <https://chat.openai.com/>

Para usar o ChatGPT para pedir ajuda ao R, você pode solicitar assistência na elaboração de código, depurar problemas, ou mesmo pedir orientação sobre como realizar uma determinada tarefa em R. Aqui está um exemplo de como você pode pedir ajuda ao R:

Oi ChatGPT! Estou enfrentando um problema ao tentar realizar uma análise de regressão linear no R. Eu tenho um conjunto de dados chamado "dados.csv" e estou tentando ajustar um modelo linear simplificado com a função `lm()`. No entanto, estou recebendo um erro que não consigo entender. Você poderia me ajudar a resolver isso?

Ao fazer uma pergunta específica e fornecer detalhes sobre o que você está tentando alcançar e quais problemas está enfrentando, o ChatGPT pode oferecer orientações úteis e sugestões para ajudá-lo com o seu código em R.

Detalhe, o texto acima foi gerado pelo próprio ChatGPT (Figura 10.4). Você pode chamar o ChatGPT pelo próprio R:

```
# Abrir o link para o site do ChatGPT
browseURL("https://chat.openai.com/")
```




Figure 10.4: Usando o ChatGPT para pedir ajuda sobre o R.

10.8 Work flow

Você já deve estar percebendo que a programação em R pode se tornar confusa, pela quantidade de possibilidades disponíveis e formas diferentes de se obter o mesmo resultado.

Por isso é necessário que o usuário tenha um workflow que permita o reconhecimento de uma **sequência lógica para estruturar e aplicar** os devidos testes estatísticos e construção de gráficos e tabelas, após a organização e manipulação dos dados. Uma sugestão de workflow preliminar é vista na figura 10.5 (modificada de OLIVEIRA; GUERRA; MCDONNELL (2018)):

- Carregar os dados
- Limpar os dados

- Transformar, visualizar e modelar (fase exploratória)
- Comunicar o resultado




Figure 10.5: Exemplo de workflow para análises no R (modificada de @oliveira2018)

Apêndices

Snippet e chunk

Em programação R, tanto **snippet** (“trecho de código”) quanto **chunk** “pedaço de código” referem-se a porções de código usadas dentro de um contexto maior, geralmente no contexto de sessões interativas ou documentos estruturados como R Markdown. Aqui está como eles diferem:

1. Snippet:

- Um “trecho de código” em R geralmente se refere a um pedaço pequeno e isolado de código que executa uma tarefa ou operação específica.
- Trechos de código são frequentemente usados de forma interativa, seja em um console R ou dentro de um ambiente de desenvolvimento integrado (IDE) como o RStudio.
- Esses trechos são geralmente segmentos curtos de código usados para experimentação, testes ou cálculos rápidos.

2. Chunk:

- Um “trecho” em R é um termo comumente usado no contexto da programação literária, especialmente em documentos escritos usando R Markdown.
- Trechos são blocos maiores de código que podem ser executados independentemente dentro de um documento R Markdown.
- Os trechos são delimitados por delimitadores especiais, como `{r}`, que indicam ao processador R Markdown que o conteúdo incluído é código R.

- Documentos R Markdown permitem a integração de trechos de código R com texto narrativo, permitindo que os usuários combinem código, resultados e texto explicativo em um único documento.

Em resumo, enquanto um “trecho de código” geralmente se refere a uma pequena e isolada peça de código usada para testes ou experimentação, um “trecho” se refere a um bloco maior de código usado dentro do contexto da programação literária, particularmente em documentos escritos usando R Markdown. Os trechos permitem a integração de código e texto narrativo em documentos estruturados.

Sites consultados

Recomendo visitar esses sites e ver demais conteúdos relacionados

Visite:

<https://felipegalvao.com.br/pt/blog/basic-r-introduction-data-types-and-structures/>

<https://lhmet.github.io/adar-ebook/datatype.html>

Vídeos:

Objetos, atributos e tipos de dados em R: <https://www.youtube.com/watch?v=YdUUQapPYzs&t=1s>

Outros materiais de apoio:

Tipos de dados e operadores I (Parte 8): <https://www.youtube.com/watch?v=Dy2cI02WbMQ>

Tipos de dados e operadores II (Parte 9) <https://www.youtube.com/watch?v=E6ZTBbicTvg>

Estrutura de dados I (Parte 10): <https://www.youtube.com/watch?v=xzLM33Tqvic>

Estrutura de dados I (Parte 11): <https://www.youtube.com/watch?v=aEaSzIDMcUI>

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executá-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

```
"Início do R Módulo"
600+66
y <- 600+66
```

```

x <- 10
x
for (i in 1:5) {x+1->x
  print(x)}
x
1:5
a <- 5 + 3
a
print(a)
class(a)
var1 <- 3
var2 <- as.integer(3)
class(var1)
class(var2)
y <- 5L
typeof(y) #tipo interno básico usado pelo R para armazenar o
           ↪ objeto `y`
b <- "Ola mundo"
c <- TRUE
class(b)
class(c)
log(x=20, base=10)
log(20)
sqrt(25)
x <- c(1.4, 6.5, 3, 4, 71.2)
var1 <- 3
is.vector(var1)
var1 <- c(3,6,7.8,332)
print(var1)
var2 <- c("Ola", "tudo", "bem")
print(var2)
var3 <- c(TRUE, FALSE, TRUE, TRUE, FALSE, FALSE, TRUE, TRUE,
           ↪ TRUE)
print(var3)
mat1 <- matrix(c(1,5,10,30,15,8),
  nrow=3,
  ncol=2,
  byrow=TRUE)
print(mat1)
vec1 <- c(1, 5)
vec2 <- c(10, 30)
vec3 <- c(15, 8)
mat2 <- rbind(vec1, vec2, vec3)
print(mat2)
class(mat2)

```

```

a <- sample(c(0,1,5), 10, replace=TRUE)
b <- sample(c(0,10,20), 10, replace=TRUE)
c <- sample(c(0,30,40), 10, replace=TRUE)
matrix(a,b,c)
#?matrix
matrix(c(a, b, c), ncol = 3, byrow = FALSE)
mat2 <- matrix(c(a, b, c), ncol = 3, byrow = FALSE)
mat2
#df1 <- data.frame(a,b,c)
#df1
mat1[2,1]
# outras possibilidades
mat2[ , c(1,3)] # todas as linhas, colunas 1 e 3
mat2[c(1,3), ] # linhas 1 e 3, todas as colunas
mat2[1:2, 2:3] # linhas 1 a 2, colunas 2 a 3
df1 <- data.frame(c(1,2,3),c("baixo","medio","alto"),c(TRUE,
  ↪ TRUE, FALSE))
print(df1)
df2 <- data.frame(Sp1=c(1,5,2,5,3), Sp2=c(21,8,10,7,18))
row.names(df2) <- LETTERS[1:5]
df2
plot(df2, type='n'); text(df2, row.names(df2))
data <- read.table(text = "
Sp1 Sp2 Sp3 Sp4 Sp5 Sp6 Sp7
A 0 0 0 0 0 0 6
B 0 0 0 2 0 0 10
C 93 2 0 177 0 260 2
D 0 4 0 8 0 0 83
E 0 0 0 0 1 0 0
F 0 0 1 0 0 1 0
G 0 2 0 2 0 0 0
", header = TRUE, row.names = 1)
data
print(mtcars)
#?mtcars
class(mtcars)
mode(mtcars)
typeof(mtcars)
str(mtcars) #atenção
mtcars[1,2]
mtcars["Mazda RX4","gear"]
mtcars[1:5,1]
mtcars[,2]
mtcars[3,]
rownames(mtcars)

```



```

colnames(mtcars)
names(mtcars)
rowSums(mtcars)
colSums(mtcars)
rowMeans(mtcars)
colMeans(mtcars)
mtcars$gear #atenção
sum(mtcars)
mean(as.matrix(mtcars))
sd(as.matrix(mtcars))
t(mtcars) #atenção
nrow(mtcars)
ncol(mtcars)
mtcars[mtcars<=3]
mtcars[mtcars==0]
mtcars[mtcars!=0] #`!` significa negação lógica (NOT), inverte
  ↪ valores lógicos
length(as.matrix(mtcars))
dim(mtcars)
length(mtcars[mtcars==0])
summary(mtcars) #atenção
meses <- c("Jan", "Jan", "Feb", "Mar", "Apr", "Apr", "May", "Jan", "Jan"
  ↪ , "May", "May", "Jun")
meses
mesesf <- factor(meses)
print(mesesf)
table(mesesf)
meses <- c("Jan", "Jan", "Jan", "Feb", "Feb", "Feb", "Feb",
  ↪ "Mar", "Mar", "Mar", "Apr", "Apr", "Apr", "May", "May",
  ↪ "May", "Jun", "Jun", "Jun")
meses
factor(meses)
print(meses)
table(meses)
riq <- c(3, 5, 7, 6, 8, 9, 0, 4, 6, 9, 2, 6, 3, 9, 6, 0, 1, 6, 7)
dados <- data.frame(Mes = meses, Riqueza = riq)
riq
dados
factor(meses)
plot(factor(meses), riq)
by(riq, meses, mean)
a <- c(3,6,9)
b <- c("a", "b", "c", "d")
c <- c(TRUE, FALSE, TRUE, TRUE)
lista1 <- list(a,b,c)

```

```
print(lista1)
# help(mean)
# ?getwd()
# help.search("linear regression")
# example(mean)
# # Abrir o link para o site do ChatGPT
# browseURL("https://chat.openai.com/")
```

Referências

Chapter 11

R Módulo 2 - Importando planilhas de dados

RESUMO

A importação de planilhas do Excel para o ambiente de programação R é uma tarefa fundamental para análise de dados e estatísticas. Através da importação de planilhas do Excel, é possível transformar dados armazenados em formatos familiares em estruturas que podem ser manipuladas e exploradas de maneira eficaz no R. Isso permite a aplicação de diversas técnicas estatísticas e criação de visualizações informativas, contribuindo para a tomada de decisões embasadas em dados. Neste contexto, entender como importar dados do Excel para o R é um passo crucial para realizar análises de alta qualidade e obter insights significativos a partir dos conjuntos de dados disponíveis.

Apresentação

A importação de planilhas do Excel para o ambiente de programação R é uma tarefa fundamental para análise de dados e estatísticas. O R é uma linguagem de programação amplamente utilizada por cientistas de dados, pesquisadores e analistas para manipular, visualizar e modelar informações. Através da importação de planilhas do Excel, é possível transformar dados armazenados em formatos familiares em estruturas que podem ser manipuladas e exploradas de maneira eficaz no R. Isso permite a aplicação de diversas técnicas estatísticas e criação de visualizações informativas, contribuindo para a tomada de decisões embasadas em dados. Neste contexto, entender como importar dados do Excel para o R é um passo crucial para realizar análises de alta qualidade e obter insights significativos a partir dos conjuntos de dados disponíveis.

11.1 Sobre os dados do PPBio

Usaremos para esse tutorial dados coletados no Programa de Pesquisa em Biodiversidade - PPBio (veja Programa de Pesquisa em Biodiversidade – PPBio). Nesta base de dados estão armazenadas informações sobre diversos grupos taxonômicos distribuídos em diversas unidades amostrais (UA's ou sítios), como peixes, macroinvertebrados bentônicos, quironomídeos e zooplâncton, além de dados do habitat, como variáveis físicas e químicas, morfologia do habitat, composição do substrato, estrutura de habitat marginal, entre outros (Figura 11.1).

Essa é a **matriz bruta de dados**, porque os valores ainda não foram ajustados para os valores de Captura Por Unidade de Esforço (CPUE), nem foram relativizados ou transformados.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	INFO	sp-depts	as-bimac	as-fasc	ch-bimac	ci-ocela	ci-orian	co-macro	co-heter	co-manat	cy-lagid	cy-gribe	ze-bras	he-marg	ho-malab	hy-pusar	le-melan	le-glau
2	S-A-ZAI	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	S-R-CC1	0	99	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
4	S-R-CT1	0	194	55	0	0	5	0	1	14	0	0	3	0	1	9	0	3
5	S-R-CP1	0	13	0	0	0	0	0	0	0	0	0	0	0	5	2	0	0
6	S-A-TA1	0	23	1	13	0	0	0	0	0	0	0	0	0	0	0	0	0
7	S-R-CT2	0	142	3	3	0	69	0	0	4	0	0	0	1	17	43	0	1
8	S-R-CP2	0	5	1	0	40	9	0	0	0	0	0	0	0	10	2	0	3
9	S-A-TA2	0	46	0	178	0	0	0	0	0	0	0	0	0	2	0	0	0
10	S-R-CT3	0	206	64	0	0	25	0	0	8	0	0	1	0	31	11	0	2
11	S-R-CP3	0	16	0	0	13	24	0	0	0	0	0	0	0	4	0	0	1
12	S-A-TA3	0	234	7	238	0	0	2	0	0	0	0	0	0	20	0	0	0
13	S-R-CT4	0	0	1	0	0	5	0	0	1	0	50	3	1	4	3	0	0
14	S-R-CP4	0	0	0	0	11	6	0	0	0	0	0	0	0	2	0	0	2
15	S-A-TA4	0	394	0	273	0	0	0	0	1	0	0	1	0	9	0	0	2
16	B-A-MU1	0	12	0	0	0	0	0	0	0	0	0	190	0	0	0	0	0
17	B-R-T1	0	3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
18	B-A-GU1	0	2	2	0	0	0	0	0	0	0	0	7	0	0	0	0	0
19	B-R-PC2	5	44	0	0	2	0	0	0	0	0	0	8	0	0	0	2	0
20	B-A-MU2	0	99	0	0	0	0	0	0	0	0	0	67	0	1	0	0	0
21	B-A-GU2	0	0	0	0	0	0	0	0	0	0	0	23	0	0	0	0	0
22	B-R-PC3	22	75	7	0	4	0	0	0	0	21	0	16	0	2	1	0	0
23	B-A-MU3	0	511	0	0	0	0	0	0	0	0	0	145	0	0	0	0	0
24	B-A-GU3	0	6	0	0	0	0	0	0	0	0	0	32	0	0	0	0	0
25	B-R-PC4	0	7	17	0	0	0	0	0	0	0	81	5	0	1	0	0	1
26	B-A-MU4	0	235	0	0	0	0	0	0	0	0	0	509	0	0	0	0	0
27	B-A-GU4	0	13	0	0	0	0	0	0	0	0	0	10	0	0	0	0	0

Figure 11.1: Parte da planilha de dados brutos do PPBio.



IMPORTANTE

Veja as matrizes de dados disponíveis para análises, suas descrições e tipos de dados, na seção Arquivos disponíveis do Capítulo Bases de dados.

A planilha `ppbio*-peixes.***` contém o delineamento amostral de um dos estudos do Projeto PPBio (Figura 11.2). Nas linhas são apresentadas as abreviações dos nomes das unidades amostrais (UA's) e nas colunas são apresentados os nomes abreviados das espécies - temos portando uma matriz comunitária. No corpo da planilha temos os valores para o tipo de dados amostrado. Quantitativo, semi-quantitativo ou qualitativo.

Qual desses tipos de dados você acha que é apresentado na planilha?



NOTA

Se você ainda não tem o R e RStudio instalados veja a seção Instalação do R e RStudio do Capítulo Introdução ao R/RStudio




Figure 11.2: Associação entre a planilha de dados brutos do PPBio e o delineamento amostral do estudo.

11.2 Importando a planilha de trabalho



ATENÇÃO

Os links para baixar as planilhas necessárias para repetir esse tutorial podem ser encontrados na seção Arquivos disponíveis do Capítulo Bases de dados.

Ou, baixe aqui o arquivo `ppbio06c-peixes.xlsx`

Para começar a usar o R e analisar os dados do Projeto PPBio, abra o RStudio, verifique sua interface e siga as instruções a seguir.

11.3 Organização básica

No ambiente do RStudio no painel de edição de código execute (**Ctrl+Enter** com o teclado ou **Run** no editor de código) os comandos a seguir, para instalar os pacotes necessários para este módulo.

```
install.packages("readxl") #importa arquivos do excel
```

E em seguida,

```
library(readxl)
```

Os códigos acima, são usados para instalar e carregar os pacotes necessários para este módulo. Esses códigos são comandos para instalar pacotes no R. Um pacote é uma coleção de funções, dados e documentação que ampliam as capacidades do R (R CRAN) (R DEVELOPMENT CORE TEAM, 2017), e RStudio (R STUDIO TEAM, 2022). No exemplo acima, o pacote `readxl` permite ler e escrever arquivos Excel no R.

Para instalar um pacote no R, você precisa usar a função `install.packages()`. Depois de instalar um pacote, você precisa carregá-lo na sua sessão R com a função `library()`.

Por exemplo, para carregar o pacote `readxl`, você precisa executar a função `library(readxl)`. Isso irá permitir que você use as funções do pacote na sua sessão R. Você precisa carregar um pacote toda vez que iniciar uma nova sessão R e quiser usar um pacote instalado.

11.3.1 Definindo diretório de trabalho ou criando um projeto no R (.Rproj)



NOTA

Se você ainda não criou um projeto no R vá até a seção Criando um Controle de Versões no RStudio do Capítulo Ferramentas e veja como criar um projeto associado ao Github.

Se preferir criar um projeto exclusivamente local (no seu computador) siga os passos a seguir.

11.3.1.1 Criando um projeto no R

No RStudio siga as seguintes opções:

File > New Project > New Directory > New project

1. Em **Give your directory name** digite o nome do seu diretório. Esse também será o nome do seu projeto.
2. Em **Create project as subdirectory of** escolha a pasta local onde será mantido seu projeto, clicando na opção **Browse**.
3. Marque a opção **Open in new session**
4. Clique em **Create Project**

Após esses passos o RStudio abrirá uma nova sessão com seu projeto. O RStudio vai criar uma subpasta com o seu projeto (nome do subdiretório) na pasta que você definir em **Project directory name**.

Para carregar seu projeto clique duas vezes no arquivo **.Rproj** a partir do Explorador de Arquivos do Windows ou, no próprio R, clique em **File > Open Project** e escolha o nome do seu projeto.

11.3.1.2 Definindo o diretório de trabalho

Se você prefere não criar um projeto, e não está usando o Github, pode **definir o diretório de trabalho**. Isso facilita o uso e manuseio dos seus arquivos.

Essa função é usada para obter e definir o diretório de trabalho atual no R. A função **getwd()** retorna o caminho do diretório onde o R está lendo e salvando seus arquivos no momento. O comando **setwd()** muda esse diretório de trabalho para o caminho especificado entre aspas.

No seu caso, você deve ajustar o caminho para o seu próprio diretório de trabalho. **Lembre de usar a barra “/” entre os diretórios. E não a contra-barras “\”.**

Usaremos uma matriz multivariada (sítios x espécies, matriz comunitária) do Projeto PPBio chamada `ppbio**.xlsx` que está no diretório “C:/Meu/Diretório/De/Trabalho/Planilha.xlsx”

Lembre que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações.

Ajuste a segunda linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.

Definindo o diretório de trabalho e installando os pacotes necessários:

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

Alternativamente você pode ir na barra de tarefas e escolhes as opções: \SESSION
-> SET WORKING DIRECTORY -> CHOOSE DIRECTORY

11.3.2 Prefira sempre códigos e scripts do que mouse e menus de janelas no R



NOTA

Prefira sempre códigos e scripts do que mouse e menus de janelas no R. Optar pelo uso de scripts e comandos de teclado no R, em vez das opções baseadas em mouse e menus das janelas, oferece várias vantagens significativas para quem está envolvido em análises de dados e programação. O tópico sobre uso do mouse do Capítulo Introdução ao R/RStudio, apresenta algumas justificativas para essa abordagem.

11.4 Importando a planilha

```
library(readxl)
ppbio06 <- read_excel(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.xlsx"
  ↪ ,
                                sheet = "Sheet1",
                                na = "NA")

str(ppbio06)
class(ppbio06)
```


Com essas linhas de código a primeira coluna da matriz importada apresenta texto. Não queremos assim porque vamos fazer cálculos matemáticos na matriz.

Resolvemos o problema com mais algumas linhas de código.

```
ppbio06 <- as.data.frame(ppbio06)
class(ppbio06)
rownames(ppbio06) <- ppbio06[,1] #tem que ser um df
ppbio06[,1] <- NULL
```

Ou podemos instalar esse pacote de importação de arquivos .xlsx para o R.

```
install.packages("openxlsx")
```

```
library(openxlsx)
ppbio <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.xlsx"
  ↪ ,
  rowNames = T,
  colNames = T,
  sheet = "Sheet1")

str(ppbio)
class(ppbio)
ppbio_ma <- as.matrix(ppbio) #lê ppbio como uma matriz
str(ppbio_ma)
class(ppbio_ma)
#ppbio
#ppbio_ma
```

Compare as diferenças. Agora podemos exportar os dados como uma matriz de dados em formato de valores separados por vírgula (.csv).

```
write.table(ppbio, "ppbiocsv.txt", append = F, quote = T, ";",
  ↪ row.names = T)
dir <- getwd()
shell.exec(dir) #abre o diretorio de trabalho no Windows Explorer
```

Podemos abrir o arquivo .csv criado ppbiocsv.txt usando os códigos abaixo.

```
ppbiocsv <- read.csv("ppbiocsv.txt",
  sep = ";", dec = ",", #definimos o dígito
  ↪ separador
  header = T,
  row.names = 1,
  na.strings = NA)

str(ppbiocsv)
ppbiocsv
```

Lembre de prestar atenção no dígito separador de decimais " , " ou " . " . Além disso, só estamos usando `ppbio**.*` porque o diretório de trabalho já foi definido no início. Se não deveríamos estar usando `C:/Seu/Diretório/De/Trabalho/ppbio**.*`

Alguns comandos para exibir a planilha são “case-sensitive” (`ignore.case(object)`)

Atente para os resultados dos comandos a seguir.

```
#View(ppbio)
print(ppbio06[1:10, 1:10])
#ppbio
str(ppbio06)
#?str
mode(ppbio06)
#?mode
class(ppbio06)
#?class
ppbio06_ma <- as.matrix(ppbio06) #lê ppbio como uma matriz
str(ppbio06_ma)
#?View
#?view
#?remove
```

##	ap-davis	as-bimac	as-fasci	ch-bimac	ci-ocela	ci-orien	co-macro	co-heter
## S-A-ZA1	0	1	0	0	0	0	0	0
## S-R-CC1	0	99	0	0	0	0	0	0
## S-R-CT1	0	194	55	0	0	5	0	1
## S-R-CP1	0	19	0	0	0	0	0	0
## S-A-TA1	0	23	1	13	0	0	0	0
## S-R-CT2	0	142	3	3	0	69	0	0
## S-R-CP2	0	5	1	0	40	9	0	0
## S-A-TA2	0	46	0	178	0	0	0	0
## S-R-CT3	0	206	64	0	0	25	0	0
## S-R-CP3	0	16	0	0	13	24	0	0

```

##          cr-menez cu-lepid
## S-A-ZA1      0      0
## S-R-CC1      0      0
## S-R-CT1     14      0
## S-R-CP1      0      0
## S-A-TA1      0      0
## S-R-CT2      4      0
## S-R-CP2      0      0
## S-A-TA2      0      0
## S-R-CT3      8      0
## S-R-CP3      0      0
## 'data.frame':  26 obs. of  35 variables:
## $ ap-davis : num  0 0 0 0 0 0 0 0 0 0 ...
## $ as-bimac : num  1 99 194 19 23 142 5 46 206 16 ...
## $ as-fasci : num  0 0 55 0 1 3 1 0 64 0 ...
## $ ch-bimac : num  0 0 0 0 13 3 0 178 0 0 ...
## $ ci-ocela : num  0 0 0 0 0 0 40 0 0 13 ...
## $ ci-orien : num  0 0 5 0 0 69 9 0 25 24 ...
## $ co-macro : num  0 0 0 0 0 0 0 0 0 0 ...
## $ co-heter : num  0 0 1 0 0 0 0 0 0 0 ...
## $ cr-menez : num  0 0 14 0 0 4 0 0 8 0 ...
## $ cu-lepid : num  0 0 0 0 0 0 0 0 0 0 ...
## $ cy-gilbe : num  0 0 0 0 0 0 0 0 0 0 ...
## $ ge-brasi : num  0 0 3 0 0 0 0 0 1 0 ...
## $ he-margi : num  0 0 0 0 0 1 0 0 0 0 ...
## $ ho-malab : num  0 0 1 5 0 17 10 2 31 4 ...
## $ hy-pusar : num  0 0 9 2 0 43 2 0 11 0 ...
## $ le-melan : num  0 0 0 0 0 0 0 0 0 0 ...
## $ le-piau  : num  0 0 3 0 0 1 3 0 2 1 ...
## $ le-taeni : num  0 0 0 0 0 0 0 0 0 0 ...
## $ mo-costa : num  0 0 0 0 0 0 0 0 0 0 ...
## $ mo-lepid : num  0 1 39 0 0 1 0 0 0 0 ...
## $ or-nilot : num  0 2 36 0 0 77 0 0 138 0 ...
## $ pa-manag : num  0 0 0 0 0 0 0 0 0 0 ...
## $ pimel-sp : num  0 0 6 0 0 0 0 0 0 0 ...
## $ po-retic : num  0 0 0 0 0 20 0 0 5 0 ...
## $ po-vivip : num  0 0 47 15 0 221 32 0 326 10 ...
## $ pr-brevi : num  9 0 5 0 1 15 5 2 164 0 ...
## $ ps-rhomb : num  0 0 0 0 0 0 0 0 1 0 ...
## $ ps-genise: num  0 0 0 0 0 0 0 0 1 0 ...
## $ se-heter : num  0 0 40 14 4 60 0 0 38 0 ...
## $ se-piaba : num  0 0 68 0 0 0 0 0 0 0 ...
## $ se-spilo : num  0 0 0 0 0 0 0 0 1 0 ...
## $ st-noton : num  0 0 1 0 0 25 0 0 115 0 ...
## $ sy-marmo : num  0 0 0 0 0 0 1 0 0 0 ...
## $ te-chalc : num  0 0 0 0 0 0 0 0 0 0 ...

```

```
## $ tr-signa : num 0 0 18 0 0 15 0 0 7 0 ...
## [1] "list"
## [1] "data.frame"
## num [1:26, 1:35] 0 0 0 0 0 0 0 0 0 0 ...
## - attr(*, "dimnames")=List of 2
## ..$ : chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## ..$ : chr [1:35] "ap-davis" "as-bimac" "as-fasci" "ch-bimac" ...
```

11.4.1 Outra forma de achar e importar uma planilha

Essa forma é desaconselhável porque é demorada e sujeita a erros. Além de precisar ser refeita sempre que se quiser abrir uma nova planilha ou reabrir a última planilha importada.

```
getwd()
ppbio <- read.xlsx(file.choose(), #abre o explorador de arquivos
  ↪ do Windows
  , rowNames = T, colNames = T,
  sheet = "Sheet1")
```

11.5 Importando .ods do LibreOffice Calc

A planilha a seguir pode ser baixada da seção Arquivos disponíveis.

```
#install.packages("readODS")
```

```
library(readODS)
ppbio06.ods <- read_ods(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.ods"
  ↪ ,
  row_names = TRUE,
  col_names = TRUE,
  sheet = "Sheet1",
  as_tibble = FALSE,
  na = "n/a") # porque existem células vazias
  ↪ (n/a)
ppbio06.ods <- na.omit(ppbio06.ods)
str(ppbio06.ods)
class(ppbio06.ods)
```

```
ppbio06.ods_ma <- as.matrix(ppbio06.ods) #lê como uma matriz
str(ppbio06.ods_ma)
class(ppbio06.ods_ma)
#ppbio06.ods
#ppbio06.ods_ma
```

11.6 Manipulando matrizes de dados

11.6.1 Colunas com o mesmo nome

Em algumas situações é necessário encontrar colunas com o mesmo nome em um conjunto de dados e soma-las ou fazer sua média. Isso pode ocorrer quando se está trabalhando com dados de várias fontes e é necessário combinar esses diferentes conjuntos de dados.

Considere por exemplo um cenário onde se está trabalhando em um projeto de análise de dados ecológicos e você recebeu conjuntos de dados de diferentes locais de amostragens enviados por diferentes pesquisadores, e cada pesquisador enviou seu conjunto de dados que contém informações sobre as mesmas espécies (ou variáveis ambientais). Devido a diferentes sistemas de registro ou a falta de comunicação entre os pesquisadores, pode haver repetição nos nomes das colunas.

```
#Dados de mamíferos roedores
df <- data.frame(
  Rato = c(1, 2, 3),
  Musaranho = c(4, 5, 6),
  Rato = c(7, 8, 9), #nome duplicado
  Esquilo = c(0, 0, 1),
  Ratão = c(1, 1, 0),
  Castor = c(1, 0, 0),
  Tâmia = c(11, 12, 13),
  Marmota = c(1, 2, 0),
  Castor = c(2, 1, 1), #nome duplicado
  check.names = FALSE
)
df

#Transpor os dados
df_t <- t(df)
df_t
#Somar grupos iguais
```

```

df_sum <- rowsum(
  df_t,
  group = names(df),
  reorder = FALSE
)
df_sum
#Transpor o resultado de volta
resultado <- t(df_sum)
resultado
#Converte para dataframe
resultado <- as.data.frame(resultado)
resultado

```

```

##      Rato Musaranho Rato Esquilo Ratão Castor Tâmia Marmota Castor
## 1      1          4    7        0     1      1    11        1      2
## 2      2          5    8        0     1      0    12        2      1
## 3      3          6    9        1     0      0    13        0      1
##           [,1] [,2] [,3]
## Rato           1    2    3
## Musaranho      4    5    6
## Rato           7    8    9
## Esquilo        0    0    1
## Ratão          1    1    0
## Castor         1    0    0
## Tâmia          11   12   13
## Marmota        1    2    0
## Castor         2    1    1
##           [,1] [,2] [,3]
## Rato           8   10   12
## Musaranho      4    5    6
## Esquilo        0    0    1
## Ratão          1    1    0
## Castor         3    1    1
## Tâmia          11   12   13
## Marmota        1    2    0
##           Rato Musaranho Esquilo Ratão Castor Tâmia Marmota
## [1,]      8          4        0     1      3    11        1
## [2,]     10          5        0     1      1    12        2
## [3,]     12          6        1     0      1    13        0
##           Rato Musaranho Esquilo Ratão Castor Tâmia Marmota
## 1      8          4        0     1      3    11        1
## 2     10          5        0     1      1    12        2
## 3     12          6        1     0      1    13        0

```

Por exemplo, no estudo sobre mamíferos roedores acima, quando se combina o conjunto geral de dados para realizar uma análise abrangente, depara-se com colunas duplicadas, onde a matriz com o conjunto total de dados contém espécies repetidas.

Nesse caso, encontrar e resolver colunas com o mesmo nome é crucial para garantir a integridade dos dados e realizar uma análise precisa. Você deve consolidar essas colunas duplicadas, somando-as ou fazendo sua média.

```
# Achando colunas com nomes duplicados
dup_cols <- names(df)[duplicated(names(df))]
# Somando colunas com o mesmo nome
for (col_name in unique(dup_cols)) {
  # Obtem colunas com o mesmo nome
  col_indices <- which(names(df) == col_name)
  # Soma colunas com o mesmo nome
  df[[col_name]] <- rowSums(df[, col_indices, drop = FALSE])
}
# Remove as colunas duplicadas originais e mantém as novas
  ↪ colunas que são a soma ("except for the first occurrence")
df <- df[, !duplicated(names(df))]
# Mostra a nova tabela com colunas repetidas somadas
print(df)
```

##	Rato	Musaranho	Esquilo	Ratão	Castor	Tâmia	Marmota
## 1	8	4	0	1	3	11	1
## 2	10	5	0	1	1	12	2
## 3	12	6	1	0	1	13	0

Uma situação diferente ocorre quando tem-se colunas com o mesmo nome.

```
df1 <- data.frame(
  A = c(2, 3, 4),
  B = c(4, 5, 6),
  A = c(7, 8, 9), #nome duplicado
  C = c(0, 0, 1),
  D = c(1, 1, 0),
  E = c(1, 0, 0),
  F = c(11, 12, 13),
  G = c(1, 2, 0),
  E = c(2, 1, 1), #nome duplicado
  check.names = FALSE
)
df1
```

```

rownames(df1) <- c("L1", "L2", "L3")
df1

rowSums(df1[, colnames(df1) == "A"])

resultado <- data.frame(
  A = rowSums(df1[, colnames(df1) == "A"]),
  B = df1$B,
  C = df1$C,
  D = df1$D,
  E = rowSums(df1[, colnames(df1) == "E"]),
  F = df1$F,
  G = df1$G
)
resultado

```

```

##   A B A C D E   F G E
## 1 2 4 7 0 1 1 11 1 2
## 2 3 5 8 0 1 0 12 2 1
## 3 4 6 9 1 0 0 13 0 1
##   A B A C D E   F G E
## L1 2 4 7 0 1 1 11 1 2
## L2 3 5 8 0 1 0 12 2 1
## L3 4 6 9 1 0 0 13 0 1
## L1 L2 L3
##   9 11 13
##   A B C D E   F G
## L1  9 4 0 1 3 11 1
## L2 11 5 0 1 1 12 2
## L3 13 6 1 0 1 13 0

```

Por exemplo, nesse dataframe temos colunas duplicadas. Nesse caso, encontrar e resolver colunas com o mesmo nome é crucial para garantir a integridade dos dados e realizar uma análise precisa. Você deve consolidar essas colunas duplicadas, somando-as ou fazendo sua média.

```

df2 <- data.frame(
  A = c(2, 3, 4, 5),
  B = c(4, 5, 6, 7),
  A = c(7, 8, 9, 10), #nome duplicado
  C = c(0, 0, 1, 1),
  D = c(1, 1, 0, 0),
  E = c(1, 0, 0, 1),

```



```

F = c(11, 12, 13, 14),
G = c(1, 2, 0, 1),
E = c(2, 1, 1, 2), #nome duplicado
check.names = FALSE
)
df2
rownames(df2) <- c("L1", "L2", "L3", "L4")
rownames(df2) <- c("L1", "L1", "L2", "L3")
#attr(df2, "row.names") <- c("L1", "L1", "L2", "L3")
df2
df2t <- t(df2)
df2t

rowSums(df2[rownames(df2) == "L1", ])

```

Mesma coisa, mas usando um loop

```

# Achando colunas com nomes duplicados
dup_cols <- names(df1)[duplicated(names(df1))]
# Somando colunas com o mesmo nome
for (col_name in unique(dup_cols)) {
  # Get indices of columns with the same name
  col_indices <- which(names(df1) == col_name)
  # Sum columns with the same name
  df1[[col_name]] <- rowSums(df1[, col_indices, drop = FALSE])
}
# Remove as colunas duplicadas originais e mantem as novas
  ↳ colunas que são a soma ("except for the first occurrence")
df3 <- df1[, !duplicated(names(df1))]
# Mostra a nova tabela com colunas repetidas somadas
print(df3)

```

```

##      A B C D E  F G
## L1   9 4 0 1 3 11 1
## L2  11 5 0 1 1 12 2
## L3  13 6 1 0 1 13 0

```

11.6.2 Removendo linhas ou colunas por nome

```

rownames(ppbio); colnames(ppbio)
#Colunas
m_part <- subset(ppbio, select = -c(`ap-davis`, `as-bimac`))
  ↪ #escolhendo uma coluna pelo nome
m_part
#Linhas
del_rows <- c("S-A-ZA1", "S-R-CC1")
del_rows
m_part <- ppbio[!(row.names(ppbio) %in% c("S-A-ZA1",
  ↪ "S-R-CC1")),]
m_part

```

Note que o `%in%` é um operador de pertencimento. No caso acima, ele pergunta para cada linha (`row.names(ppbio)`): “esse nome está dentro desse conjunto?”. A resposta é um vetor lógico (`TRUE`, `FALSE`), retornado por (`row.names(ppbio) %in% c("S-A-ZA1", "S-R-CC1")`). A negativa `!`, indica que é mantido quem não for identificado por `%in%`.

11.6.3 Criando uma matriz de médias

Por razões diferentes o procedimento anterior pode vir a ser necessário de ser aplicado às linhas. Por exemplo, quando se quer somar ou fazer a média de amostras diferentes do mesmo ambiente de coleta. Veja a matriz abaixo.

```

data <- read.table(text = "
Sp1 Sp2 Sp3 Sp4 Sp5 Sp6 Sp7 Sp8
A1 0 0 0 0 0 0 6 1
A2 0 0 0 2 0 0 10 2
B1 93 2 0 177 0 260 2 5
B2 0 4 0 8 0 0 83 7
C1 0 0 0 0 1 0 0 1
C2 0 0 1 0 0 1 0 1
C3 0 2 0 2 0 0 0 1
", header = TRUE, row.names = 1)
data

```

##	Sp1	Sp2	Sp3	Sp4	Sp5	Sp6	Sp7	Sp8
## A1	0	0	0	0	0	0	6	1
## A2	0	0	0	2	0	0	10	2
## B1	93	2	0	177	0	260	2	5
## B2	0	4	0	8	0	0	83	7
## C1	0	0	0	0	1	0	0	1

```
## C2  0  0  1  0  0  1  0  1
## C3  0  2  0  2  0  0  0  1
```

```
library("tidyverse")
#Inserindo coluna para agrupamentos
nrow(data); ncol(data) #no. de N colunas x M linhas
data_g <- cbind(Grupos = rownames(data), data)
data_g

grps <- substr(data_g[, 1], 1,1)
grps

data_g <- mutate(data_g, Grupos = c(grps))
data_g

#data_avg <- aggregate(data_g[, 9:9], list(data_g$Grupos), mean)
#data_avg

data_avg <- summarise(
  group_by(data_g, Grupos),
  across(.cols = everything(), ~ mean(.x, na.rm = TRUE))
)
data_avg

data_dp <- summarise(
  group_by(data_g, Grupos),
  across(
    .cols = everything(),
    list(mean = mean, sd = sd)
  )
)
data_dp

#Primeira coluna para nomes das linhas
data_dp <- as.data.frame(data_dp)
data_dp
rownames(data_dp) <- data_dp[,1]
data_dp[,1] <- NULL
data_dp <- round(data_dp, 1)
data_dp
#Salvando a matriz
write.table(data_dp,
            "data_dp.csv",
            append = F,
            quote = TRUE,
```

```

      sep = ";", dec = ",",
      row.names = T)
data_dp_csv <- read.csv("data_dp.csv",
      sep = ";", dec = ",",
      header = T,
      row.names = 1,
      na.strings = NA)

data_dp_csv

```

Apêndices

Sites consultados

[<https://youtu.be/U6ksXvvY6Q0>]
 [https://youtu.be/a7EJE_2mtGk]

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executá-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

```

# install.packages("readxl") #importa arquivos do excel
# library(readxl)
# getwd()
# setwd("C:/Seu/Diretório/De/Trabalho")
library(readxl)
ppbio06 <- read_excel(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.xlsx"
  ↪ ,
      sheet = "Sheet1",
      na = "NA")

str(ppbio06)
class(ppbio06)
ppbio06 <- as.data.frame(ppbio06)
class(ppbio06)
rownames(ppbio06) <- ppbio06[,1] #tem que ser um df
ppbio06[,1] <- NULL
# install.packages("openxlsx")
library(openxlsx)

```

```

ppbio <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.xlsx"
  ↪ ,
                                rowNames = T,
                                colNames = T,
                                sheet = "Sheet1")

str(ppbio)
class(ppbio)
ppbio_ma <- as.matrix(ppbio) #lê ppbio como uma matriz
str(ppbio_ma)
class(ppbio_ma)
#ppbio
#ppbio_ma
# write.table(ppbio, "ppbiocsv.txt", append = F, quote = T, ";",
  ↪ row.names = T)
# dir <- getwd()
# shell.exec(dir) #abre o diretorio de trabalho no Windows
  ↪ Explorer
# ppbiocsv <- read.csv("ppbiocsv.txt",
#                       sep = ";", dec = ",", #definimos o dígito
  ↪ separador
#
#                       header = T,
#                       row.names = 1,
#                       na.strings = NA)
# str(ppbiocsv)
# ppbiocsv
#View(ppbio)
print(ppbio06[1:10, 1:10])
#ppbio
str(ppbio06)
#?str
mode(ppbio06)
#?mode
class(ppbio06)
#?class
ppbio06_ma <- as.matrix(ppbio06) #lê ppbio como uma matriz
str(ppbio06_ma)
#?View
#?view
#?remove
# getwd()
# ppbio <- read.xlsx(file.choose(), #abre o explorador de
  ↪ arquivos do Windows
#
#                       rowNames = T, colNames = T,
#                       sheet = "Sheet1")

```

```

# #install.packages("readODS")
library(readODS)
ppbio06.ods <- read_ods(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.ods"
  ↪ ,
  row_names = TRUE,
  col_names = TRUE,
  sheet = "Sheet1",
  as_tibble = FALSE,
  na = "n/a") # porque existem celulas vazias
  ↪ (n/a)
ppbio06.ods <- na.omit(ppbio06.ods)
str(ppbio06.ods)
class(ppbio06.ods)
ppbio06.ods_ma <- as.matrix(ppbio06.ods) #lê como uma matriz
str(ppbio06.ods_ma)
class(ppbio06.ods_ma)
#ppbio06.ods
#ppbio06.ods_ma
#Dados de mamíferos roedores
df <- data.frame(
  Rato = c(1, 2, 3),
  Musaranho = c(4, 5, 6),
  Rato = c(7, 8, 9), #nome duplicado
  Esquilo = c(0, 0, 1),
  Ratão = c(1, 1, 0),
  Castor = c(1, 0, 0),
  Tâmia = c(11, 12, 13),
  Marmota = c(1, 2, 0),
  Castor = c(2, 1, 1), #nome duplicado
  check.names = FALSE
)
df
#Transpor os dados
df_t <- t(df)
df_t
#Somar grupos iguais
df_sum <- rowsum(
  df_t,
  group = names(df),
  reorder = FALSE
)
df_sum
#Transpor o resultado de volta
resultado <- t(df_sum)

```

```

resultado
#Converte para dataframe
resultado <- as.data.frame(resultado)
resultado
# Achando colunas com nomes duplicados
dup_cols <- names(df)[duplicated(names(df))]
# Somando colunas com o mesmo nome
for (col_name in unique(dup_cols)) {
  # Obtem colunas com o mesmo nome
  col_indices <- which(names(df) == col_name)
  # Soma colunas com o mesmo nome
  df[[col_name]] <- rowSums(df[, col_indices, drop = FALSE])
}
# Remove as colunas duplicadas originais e mantem as novas
  ↳ colunas que são a soma ("except for the first occurrence")
df <- df[, !duplicated(names(df))]
# Mostra a nova tabela com colunas repetidas somadas
print(df)
df1 <- data.frame(
  A = c(2, 3, 4),
  B = c(4, 5, 6),
  A = c(7, 8, 9), #nome duplicado
  C = c(0, 0, 1),
  D = c(1, 1, 0),
  E = c(1, 0, 0),
  F = c(11, 12, 13),
  G = c(1, 2, 0),
  E = c(2, 1, 1), #nome duplicado
  check.names = FALSE
)
df1
rownames(df1) <- c("L1", "L2", "L3")
df1
rowSums(df1[, colnames(df1) == "A"])
resultado <- data.frame(
  A = rowSums(df1[, colnames(df1) == "A"]),
  B = df1$B,
  C = df1$C,
  D = df1$D,
  E = rowSums(df1[, colnames(df1) == "E"]),
  F = df1$F,
  G = df1$G
)
resultado
# df2 <- data.frame(

```

```

# A = c(2, 3, 4, 5),
# B = c(4, 5, 6, 7),
# A = c(7, 8, 9, 10), #nome duplicado
# C = c(0, 0, 1, 1),
# D = c(1, 1, 0, 0),
# E = c(1, 0, 0, 1),
# F = c(11, 12, 13, 14),
# G = c(1, 2, 0, 1),
# E = c(2, 1, 1, 2), #nome duplicado
# check.names = FALSE
# )
# df2
# rownames(df2) <- c("L1", "L2", "L3", "L4")
# rownames(df2) <- c("L1", "L1", "L2", "L3")
# #attr(df2, "row.names") <- c("L1", "L1", "L2", "L3")
# df2
# df2t <- t(df2)
# df2t
#
# rowSums(df2[rownames(df2) == "L1", ])
#
# Achando colunas com nomes duplicados
dup_cols <- names(df1)[duplicated(names(df1))]
# Somando colunas com o mesmo nome
for (col_name in unique(dup_cols)) {
  # Get indices of columns with the same name
  col_indices <- which(names(df1) == col_name)
  # Sum columns with the same name
  df1[[col_name]] <- rowSums(df1[, col_indices, drop = FALSE])
}
# Remove as colunas duplicadas originais e mantem as novas
  ↪ colunas que são a soma ("except for the first occurrence")
df3 <- df1[, !duplicated(names(df1))]
# Mostra a nova tabela com colunas repetidas somadas
print(df3)
# rownames(ppbio); colnames(ppbio)
# #Colunas
# m_part <- subset(ppbio, select = -c(`ap-davis`, `as-bimac`))
  ↪ #escolhendo uma coluna pelo nome
# m_part
# #Linhas
# del_rows <- c("S-A-ZA1", "S-R-CC1")
# del_rows
# m_part <- ppbio[!(row.names(ppbio) %in% c("S-A-ZA1",
  ↪ "S-R-CC1")),]

```



```

# m_part
data <- read.table(text = "
Sp1 Sp2 Sp3 Sp4 Sp5 Sp6 Sp7 Sp8
A1 0 0 0 0 0 0 6 1
A2 0 0 0 2 0 0 10 2
B1 93 2 0 177 0 260 2 5
B2 0 4 0 8 0 0 83 7
C1 0 0 0 0 1 0 0 1
C2 0 0 1 0 0 1 0 1
C3 0 2 0 2 0 0 0 1
", header = TRUE, row.names = 1)
data
# library("tidyverse")
# #Inserindo coluna para agrupamentos
# nrow(data); ncol(data) #no. de N colunas x M linhas
# data_g <- cbind(Grupos = rownames(data), data)
# data_g
#
# grps <- substr(data_g[, 1], 1,1)
# grps
#
# data_g <- mutate(data_g, Grupos = c(grps))
# data_g
#
# #data_avg <- aggregate(data_g[, 9:9], list(data_g$Grupos),
# ↪ mean)
# #data_avg
#
# data_avg <- summarise(
#   group_by(data_g, Grupos),
#   across(.cols = everything(), ~ mean(.x, na.rm = TRUE))
# )
# data_avg
#
# data_dp <- summarise(
#   group_by(data_g, Grupos),
#   across(
#     .cols = everything(),
#     list(mean = mean, sd = sd)
#   )
# )
# data_dp
#
# #Primeira coluna para nomes das linhas
# data_dp <- as.data.frame(data_dp)

```

```
# data_dp
# rownames(data_dp) <- data_dp[,1]
# data_dp[,1] <- NULL
# data_dp <- round(data_dp, 1)
# data_dp
# #Salvando a matriz
# write.table(data_dp,
#             "data_dp.csv",
#             append = F,
#             quote = TRUE,
#             sep = ";", dec = ".",
#             row.names = T)
# data_dp_csv <- read.csv("data_dp.csv",
#                         sep = ";", dec = ".",
#                         header = T,
#                         row.names = 1,
#                         na.strings = NA)
# data_dp_csv
```

Referências

Chapter 12

R Módulo 3.1 - Estatísticas descritivas e normalidade

RESUMO

A estatística descritiva tem um papel importante a desempenhar na ciência. Quando problemas específicos são tratados na ciência, os dados precisam ser coletados, analisados e apresentados de forma concisa para que outros possam se beneficiar do que foi encontrado.

Apresentação

A estatística descritiva tem um papel importante a desempenhar na ciência. Quando problemas específicos são tratados na ciência, os dados precisam ser coletados, analisados e apresentados de forma concisa para que outros possam se beneficiar do que foi encontrado. Geralmente não é possível apresentar um conjunto de dados completo em uma publicação ou em um seminário e, mesmo que fosse, é improvável isso permitisse uma boa comunicação dos resultados da pesquisa. Em vez disso, os dados são geralmente resumidos como tabelas de frequência, histogramas e estatísticas descritivas que os leitores ou ouvintes podem assimilar prontamente, mas que ainda transmitem os elementos essenciais do conjunto de dados original. O principal objetivo do cálculo das estatísticas descritivas é transmitir informações essenciais contidas em um conjunto de dados da forma mais concisa e clara possível.

12.1 Sobre os dados

Considere os dados sobre o comprimento dos brotos de *Banksia ericifolia* de charnechas¹ na Baía de Jervis, Austrália (BRADSTOCK; TOZER; KEITH, 1997) (Figura 12.1). Existem 500 medições, um conjunto de dados formidável. Por inspeção, o comprimento mínimo do broto é 10,0 e o máximo é 44,9 cm. Esses valores definem o intervalo da amostra. Agora precisamos subdividir o intervalo em intervalos ou classes, cada um com o mesmo tamanho. Geralmente, é aconselhável arredondar o valor mínimo para baixo e o valor máximo para valores apropriados ao decidir as classes de intervalos. Nesse caso, parece sensato dividir a faixa de 10 a 45 cm em sete intervalos a cada 5 cm de largura. Se contarmos o número de brotos que se encontram em cada um dos sete intervalos, temos a base para a tabulação da frequência. A coluna de frequência foi obtida contando o número de medições que existem dentro de cada classe. A coluna de frequência percentual foi obtida representando cada contagem como uma porcentagem da contagem total. A frequência cumulativa e as frequências percentuais cumulativas foram obtidas somando progressivamente as frequências correspondentes.



ATENÇÃO

Os links para baixar as anilhas necessárias para repetir esse tutorial podem ser encontrados na seção Arquivos disponíveis do Capítulo Bases de dados.

Ou, baixe aqui o arquivo brotos.xlsx

12.2 Organização básica

```
rm(list=ls(all=TRUE)) #limpa a memória
```

Instalando os pacotes necessários para esse módulo.

¹Charneiras, ou charnechas, são tipos de paisagens ou ecossistemas encontrados principalmente em regiões temperadas, como na Europa e América do Norte, embora também possam ser encontrados em outros lugares do mundo. São caracterizados por uma combinação de vegetação herbácea (gramíneas e ervas) e arbustos resistentes, muitas vezes adaptados a condições de solo pobre e clima adverso. Eles desempenham um papel importante na conservação da biodiversidade e na ecologia das áreas onde são encontrados.

28.4	29.1	25.7	26.2	25.8	30.2	26.2	35.8	33.4	29.0	31.6	33.8	22.6	34.8
25.1	36.8	29.9	38.3	27.1	32.3	29.0	27.7	28.1	28.9	21.8	25.0	23.2	26.8
29.9	36.3	26.0	21.2	19.8	36.7	21.1	34.6	29.6	32.6	27.2	34.2	26.7	27.6
25.8	23.2	28.8	38.2	32.7	38.7	33.2	24.5	21.6	28.6	19.4	27.4	43.7	25.5
35.0	25.1	24.7	29.5	24.9	29.2	19.5	20.1	30.3	38.9	28.2	26.2	29.4	22.4
36.4	31.8	31.0	39.4	28.8	31.8	28.7	37.0	25.5	19.3	44.0	38.0	28.6	36.5
29.1	21.1	30.4	31.2	38.0	39.0	19.3	27.6	19.1	32.5	26.8	39.9	36.1	41.5
33.2	26.5	38.1	14.9	33.2	27.8	24.7	24.9	25.0	33.1	24.1	19.7	19.1	31.4
26.9	22.5	25.5	33.0	19.4	26.8	24.6	37.5	19.8	43.7	38.1	30.8	34.5	22.8
34.2	33.6	42.5	19.0	25.8	34.0	34.4	42.0	35.4	31.5	40.6	19.2	24.9	33.5
32.0	38.4	29.1	29.4	29.3	26.8	32.4	25.2	28.5	29.8	22.8	17.1	29.6	33.3
31.7	22.4	21.7	20.1	21.6	23.5	33.2	33.0	29.6	36.9	26.8	38.1	29.8	21.2
23.6	16.2	27.3	33.3	21.6	30.2	22.5	33.0	38.3	29.5	34.9	30.3	26.0	24.5
31.1	31.7	31.6	41.7	25.9	32.3	35.7	31.6	26.0	26.6	26.3	19.6	22.0	40.2
29.1	15.8	22.1	23.2	25.4	28.4	20.2	25.5	26.9	32.7	28.8	39.6	31.9	31.9
29.8	27.1	36.9	32.7	24.8	18.0	40.2	28.0	26.8	41.9	15.8	16.2	33.6	34.8
31.5	27.4	37.2	30.6	32.2	34.8	28.2	31.3	34.3	32.0	33.3	30.1	20.5	37.3
20.6	27.2	25.0	26.1	34.5	44.9	40.5	32.1	40.4	35.7	33.9	29.3	28.1	34.3
29.3	24.7	37.0	36.9	34.8	29.8	22.8	32.3	34.8	29.6	33.6	22.8	31.6	34.7
24.0	30.5	31.6	28.7	20.8	14.6	23.4	26.3	31.9	32.5	34.3	25.7	36.0	37.7
32.4	36.4	24.1	33.1	26.3	35.7	26.4	34.7	27.5	39.6	16.5	30.2	23.8	23.7
30.5	30.1	21.3	27.1	19.0	25.4	36.5	22.6	25.5	30.0	34.4	30.6	32.7	30.4
29.2	30.2	20.8	30.3	27.8	32.9	28.2	20.6	33.6	22.2	37.5	30.0	24.2	18.8
26.1	29.7	32.0	22.2	29.2	21.5	31.4	43.1	35.9	14.9	24.6	26.2	33.4	29.9
38.8	21.9	25.6	29.7	29.9	32.5	30.4	29.2	40.9	14.1	22.1	20.0	24.3	28.6
22.4	19.9	34.8	33.4	28.0	29.1	27.2	18.8	36.2	27.8	20.2	21.9	27.0	21.9
29.9	21.8	33.1	30.4	30.8	33.9	27.1	27.6	37.2	30.9	31.4	41.9	24.7	25.8
28.3	34.3	34.0	29.0	30.9	24.4	29.0	25.4	30.5	31.1	33.9	15.7	40.5	29.9
26.3	38.3	24.8	23.5	29.3	37.8	29.9	28.6	27.4	29.9	33.5	17.0	34.1	30.9
24.3	20.7	22.5	39.5	32.0	27.6	36.3	22.0	28.4	19.1	25.8	25.7	33.9	43.0
16.8	43.9	27.9	44.4	29.7	23.0	26.8	43.4	29.4	26.7	16.5	22.1	23.0	39.4
27.8	33.1	34.9	20.5	25.4	10.0	28.2	31.0	10.6	28.4	16.5	22.3	17.6	24.2
21.9	27.0	26.5	29.2	24.9	18.4	24.1	28.3	29.0	29.1	18.8	36.7	24.7	23.2
26.2	32.6	22.3	31.7	37.1	35.6	19.5	26.9	24.8	19.2	25.1	22.1	37.9	28.3
29.9	42.1	36.6	25.5	34.2	22.4	40.5	21.2	32.3	31.5	34.2	34.5	39.2	29.3
29.3	31.6	23.2	32.1	20.3	27.8	22.9	32.5	24.5	36.5				

Figure 12.1: Comprimentos (cm) de 500 brotos do arbusto **Banksia ericifolia** de charnecas na Baía de Jervis, Austrália.

```
install.packages("openxlsx") #importa arquivos do excel
install.packages("fdth")
```

```
library(openxlsx)
```

Os códigos acima, são usados para instalar e carregar os pacotes necessários para este módulo. Esses códigos são comandos para instalar pacotes no R. Um pacote é uma coleção de funções, dados e documentação que ampliam as capacidades do R (R CRAN (R DEVELOPMENT CORE TEAM, 2017) e RStudio (R STUDIO TEAM, 2022)). No exemplo acima, o pacote `openxlsx` permite ler e escrever arquivos Excel no R. Para instalar um pacote no R, você precisa usar a função `install.packages()`.

Depois de instalar um pacote, você precisa carregá-lo na sua sessão R com a função `library()`. Por exemplo, para carregar o pacote `openxlsx`, você precisa executar a função `library(openxlsx)`. Isso irá permitir que você use as funções do pacote na sua sessão R. Você precisa carregar um pacote toda vez que iniciar uma nova sessão R e quiser usar um pacote instalado.

Agora vamos **definir o diretório de trabalho**. Esse código é usado para obter e definir o diretório de trabalho atual no R. O comando `getwd()` retorna o caminho do diretório onde o R está lendo e salvando arquivos. O comando `setwd()` muda esse diretório de trabalho para o caminho especificado entre aspas. No seu caso, você deve ajustar o caminho para o seu próprio diretório de trabalho. **Lembre de usar a barra “/” entre os diretórios. E não a contra-barra “\”.**

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

12.3 Importando a planilha

Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações. Ajuste a segunda linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.

```
library(openxlsx)
brotos <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/brotos.xlsx"
  ↪ ,
```

```

rowNames = F, colNames = F,
sheet = "Planilha1")
head(brotos,10)
head(brotos[, 1:5], 10)

```

```

##      X1  X2  X3  X4  X5  X6  X7  X8  X9  X10
## 1  28.4 29.1 25.7 26.2 25.8 30.2 26.2 35.8 33.4 29.0
## 2  25.1 36.8 29.9 38.3 27.1 32.3 29.0 27.7 28.1 28.9
## 3  29.9 36.3 26.0 21.2 19.8 36.7 21.1 34.6 29.6 32.6
## 4  25.8 23.2 28.8 38.2 32.7 38.7 33.2 24.5 21.6 28.6
## 5  35.0 25.1 24.7 29.5 24.9 29.2 19.5 20.1 30.3 38.9
## 6  36.4 31.8 31.0 39.4 28.8 31.8 28.7 37.0 25.5 19.3
## 7  29.1 21.1 30.4 31.2 38.0 39.0 19.3 27.6 19.1 32.5
## 8  33.2 26.5 38.1 14.9 33.2 27.8 24.7 24.9 25.0 33.1
## 9  26.9 22.5 25.5 33.0 19.4 26.8 24.6 37.5 19.8 43.7
## 10 34.2 33.6 42.5 19.0 25.8 34.0 34.4 42.0 35.4 31.5
##      X1  X2  X3  X4  X5
## 1  28.4 29.1 25.7 26.2 25.8
## 2  25.1 36.8 29.9 38.3 27.1
## 3  29.9 36.3 26.0 21.2 19.8
## 4  25.8 23.2 28.8 38.2 32.7
## 5  35.0 25.1 24.7 29.5 24.9
## 6  36.4 31.8 31.0 39.4 28.8
## 7  29.1 21.1 30.4 31.2 38.0
## 8  33.2 26.5 38.1 14.9 33.2
## 9  26.9 22.5 25.5 33.0 19.4
## 10 34.2 33.6 42.5 19.0 25.8

```

Exibindo os dados importados (esses comando são “case-sensitive” `ignore.case(object)`).

```

#View(brotos)
print(brotos[1:5,1:5])
brotos
str(brotos)
mode(brotos)
class(brotos)

```

`Brotos.xlsx` está como um dataframe. Precisaremos converter para um vetor. Para isso, transformamos o dataframe em matriz numérica (`as.matrix()`), e na sequência usamos `as.vector()` para achatar a matriz em uma única dimensão.

```
brotos_v <- as.vector(as.matrix(brotos))
brotos_v
```

```
## [1] 28.4 25.1 29.9 25.8 35.0 36.4 29.1 33.2 26.9 34.2 32.0 31.7 23.6 31.1 29.1
## [16] 29.8 31.5 20.6 29.3 24.0 32.4 30.5 29.2 26.1 38.8 22.4 29.9 28.3 26.3 24.3
## [31] 16.8 27.8 21.9 26.2 29.9 29.3 31.6 23.2 32.1 20.3 27.8 22.9 32.5 24.5 36.5
## [46] 39.4 24.2 23.2 28.3 29.3 29.1 36.8 36.3 23.2 25.1 31.8 21.1 26.5 22.5 33.6
## [61] 38.4 22.4 16.2 31.7 15.8 27.1 27.4 27.2 24.7 30.5 36.4 30.1 30.2 29.7 21.9
## [76] 19.9 21.8 34.3 38.3 20.7 43.9 33.1 27.0 32.6 42.1 34.8 26.8 27.6 25.5 22.4
## [91] 36.5 41.5 31.4 22.8 33.5 33.3 21.2 24.5 40.2 31.9 25.7 29.9 26.0 28.8 24.7
## [106] 31.0 30.4 38.1 25.5 42.5 29.1 21.7 27.3 31.6 22.1 36.9 37.2 25.0 37.0 31.6
## [121] 24.1 21.3 20.8 32.0 25.6 34.8 33.1 34.0 24.8 22.5 27.9 34.9 26.5 22.3 36.6
## [136] 34.8 37.3 34.3 34.7 37.7 23.7 30.4 18.8 29.9 28.6 21.9 25.8 29.9 30.9 43.0
## [151] 26.2 38.3 21.2 38.2 29.5 39.4 31.2 14.9 33.0 19.0 29.4 20.1 33.3 41.7 23.2
## [166] 32.7 30.6 26.1 36.9 28.7 33.1 27.1 30.3 22.2 29.7 33.4 30.4 29.0 23.5 39.5
## [181] 44.4 20.5 29.2 31.7 25.5 22.6 23.2 26.7 43.7 29.4 28.6 36.1 19.1 34.5 24.9
## [196] 29.6 29.8 26.0 22.0 31.9 25.8 27.1 19.8 32.7 24.9 28.8 38.0 33.2 19.4 25.8
## [211] 29.3 21.6 21.6 25.9 25.4 24.8 32.2 34.5 34.8 20.8 26.3 19.0 27.8 29.2 29.9
## [226] 28.0 30.8 30.9 29.3 32.0 29.7 25.4 24.9 37.1 34.2 33.6 20.5 28.1 31.6 36.0
## [241] 23.8 32.7 24.2 33.4 24.3 27.0 24.7 40.5 34.1 33.9 30.2 32.3 36.7 38.7 29.2
## [256] 31.8 39.0 27.8 26.8 34.0 26.8 23.5 30.2 32.3 28.4 18.0 34.8 44.9 29.8 14.6
## [271] 35.7 25.4 32.9 21.5 32.5 29.1 33.9 24.4 37.8 27.6 23.0 10.0 18.4 35.6 22.4
## [286] 23.0 17.6 24.7 37.9 39.2 16.2 30.1 29.3 22.8 25.7 30.2 30.6 30.0 26.2 20.0
## [301] 26.2 29.0 21.1 33.2 19.5 28.7 19.3 24.7 24.6 34.4 32.4 33.2 22.5 35.7 20.2
## [316] 40.2 28.2 40.5 22.8 23.4 26.4 36.5 28.2 31.4 30.4 27.2 27.1 29.0 29.9 36.3
## [331] 26.8 28.2 24.1 19.5 40.5 33.8 25.0 34.2 27.4 26.2 38.0 39.9 19.7 30.8 19.2
## [346] 17.1 38.1 30.3 19.6 39.6 35.8 27.7 34.6 24.5 20.1 37.0 27.6 24.9 37.5 42.0
## [361] 25.2 33.0 33.0 31.6 25.5 28.0 31.3 32.1 32.3 26.3 34.7 22.6 20.6 43.1 29.2
## [376] 18.8 27.6 25.4 28.6 22.0 43.4 31.0 28.3 26.9 21.2 21.9 41.9 15.7 17.0 25.7
## [391] 22.1 22.3 36.7 22.1 34.5 15.8 33.3 33.9 33.6 34.3 33.4 28.1 29.6 21.6 30.3
## [406] 25.5 19.1 25.0 19.8 35.4 28.5 29.6 38.3 26.0 26.9 26.8 34.3 40.4 34.8 31.9
## [421] 27.5 25.5 33.6 35.9 40.9 36.2 37.2 30.5 27.4 28.4 29.4 10.6 29.0 24.8 32.3
## [436] 31.6 21.8 27.2 19.4 28.2 44.0 26.8 24.1 38.1 40.6 22.8 26.8 34.9 26.3 28.8
## [451] 29.0 28.9 32.6 28.6 38.9 19.3 32.5 33.1 43.7 31.5 29.8 36.9 29.5 26.6 32.7
## [466] 41.9 32.0 35.7 29.6 32.5 39.6 30.0 22.2 14.9 14.1 27.8 30.9 31.1 29.9 19.1
## [481] 26.7 28.4 29.1 19.2 31.5 16.5 34.4 37.5 24.6 22.1 20.2 31.4 33.9 33.5 25.8
## [496] 16.5 16.5 18.8 25.1 34.2
```

E agora visualizando nossos dados.

```
#View(brotos_v)
print(brotos_v)
```



```

brotos_v
sort(brotos_v)
str(brotos_v)
mode(brotos_v)
class(brotos_v)
range(brotos_v)
length(brotos_v)

```

Tendo em mãos o conjunto total de 500 comprimentos medidos de brotos de *Banksia*, agora **vamos tirar uma subamostra aleatória de uma parte dos 500 valores**. Essa subamostra é tirada usando o comando `size=` no código subsequente, que estabelece o tamanho da subamostra a ser tirada do total de dados. Por exemplo, para uma subamostra de 150 comprimentos, então `size = 150`. Nesse tutorial usaremos todos os 500 comprimentos.

```

set.seed(666)
brotos_sub <- sample(brotos_v, size = 500, replace = F) #atualize
  ↳ o valor de 'size=' se necessário
brotos_sub

```

```

## [1] 22.4 34.8 33.3 34.5 20.8 28.3 30.4 17.0 25.2 37.7 29.4 29.3 27.9 25.7 23.6
## [16] 29.4 30.3 27.4 27.2 18.8 32.7 26.5 21.7 30.5 31.6 31.7 40.9 34.0 27.2 43.7
## [31] 30.1 34.3 34.8 19.4 20.1 26.7 18.4 29.9 20.7 34.9 29.1 38.3 29.0 24.7 23.4
## [46] 32.3 36.2 30.4 26.8 25.7 20.8 24.3 24.2 14.9 33.5 29.2 38.0 33.1 27.8 26.2
## [61] 28.7 33.2 44.9 25.8 34.2 36.6 40.4 37.9 29.7 35.7 34.1 26.8 30.5 14.9 28.4
## [76] 29.6 25.5 27.7 26.0 37.5 22.4 21.6 40.2 26.2 29.0 42.0 32.0 21.9 31.4 21.3
## [91] 29.1 44.4 25.8 24.1 37.5 27.0 32.6 27.8 28.9 32.9 19.8 24.5 20.1 34.4 24.5
## [106] 21.9 29.5 34.2 24.8 33.9 22.1 33.1 25.1 22.8 31.8 22.1 24.8 25.5 23.0 43.1
## [121] 37.0 38.8 25.8 27.2 40.5 36.3 28.6 30.4 24.5 29.1 33.3 23.7 33.6 26.9 22.8
## [136] 14.6 25.5 31.5 19.8 32.4 16.5 20.2 21.1 21.6 28.1 22.9 32.5 20.5 39.4 29.3
## [151] 31.0 41.7 15.7 31.0 25.8 31.9 27.0 33.2 19.0 19.7 32.2 31.8 19.6 27.8 31.1
## [166] 35.9 38.3 22.2 28.4 16.2 31.9 41.5 27.6 42.5 24.9 22.4 16.5 26.2 36.3 36.5
## [181] 19.4 38.7 32.0 25.4 32.1 30.4 24.6 24.6 29.3 31.4 35.7 33.4 22.6 32.3 24.1
## [196] 22.6 23.2 36.4 19.2 23.2 19.1 34.8 28.5 29.9 24.9 29.9 32.7 31.6 26.3 43.9
## [211] 35.4 20.0 28.6 31.6 33.0 31.9 20.2 24.9 29.7 19.5 29.3 31.7 39.0 35.0 36.5
## [226] 23.0 23.2 22.4 39.9 29.9 22.8 24.0 36.8 24.8 34.3 31.5 38.1 30.2 26.3 36.9
## [241] 21.1 23.2 26.3 31.2 26.0 29.4 33.2 21.9 10.6 15.8 31.6 20.3 21.2 29.3 25.0
## [256] 36.4 38.3 22.3 33.8 28.0 30.8 22.5 36.7 24.2 29.2 40.5 33.1 20.6 14.1 32.4
## [271] 38.0 29.1 21.2 30.3 39.2 43.0 37.2 32.5 32.5 38.9 24.3 37.0 25.4 30.3 37.1
## [286] 43.7 23.8 27.6 34.8 25.4 17.1 31.6 28.8 19.2 27.4 29.7 18.8 34.8 39.4 22.3
## [301] 26.6 28.7 25.5 23.5 20.6 30.2 34.5 40.5 19.1 24.1 36.5 16.8 21.6 24.9 36.9
## [316] 22.1 29.9 33.4 26.9 29.2 26.2 25.0 40.2 24.7 24.4 29.1 25.0 22.0 34.7 28.2

```

```
## [331] 29.9 30.5 26.2 27.4 22.0 28.2 29.1 43.4 39.6 27.6 24.7 28.8 29.8 31.3 22.5
## [346] 30.0 34.3 25.5 26.7 31.5 38.4 26.8 33.6 29.5 21.5 35.8 29.0 38.2 33.2 29.8
## [361] 32.3 19.3 26.1 16.2 27.5 30.2 28.8 34.3 28.3 22.5 24.7 32.7 34.7 16.5 42.1
## [376] 26.8 29.0 26.0 33.0 19.1 35.7 36.7 34.4 39.5 37.3 29.9 28.0 41.9 23.2 23.5
## [391] 21.9 28.2 26.9 27.3 29.9 21.2 38.1 30.8 28.6 38.1 15.8 27.1 25.1 28.4 33.9
## [406] 26.3 33.4 37.2 10.0 34.5 27.1 32.5 29.0 28.4 36.9 36.0 34.6 29.3 27.1 28.6
## [421] 28.1 30.1 28.3 19.0 26.1 34.8 27.6 19.9 27.8 34.9 41.9 29.9 25.6 26.8 21.8
## [436] 27.1 25.1 33.3 29.6 33.6 30.9 18.8 33.9 22.1 32.0 44.0 29.8 17.6 18.0 40.6
## [451] 32.7 26.8 29.2 30.0 34.2 25.4 25.7 31.6 26.4 29.2 39.6 27.8 33.6 32.0 30.9
## [466] 24.7 26.5 25.9 25.8 35.6 31.7 29.8 32.3 29.6 33.5 30.2 21.8 30.9 37.8 19.3
## [481] 36.1 33.9 28.2 31.4 20.5 25.5 33.0 22.8 34.0 32.6 30.6 29.6 22.2 26.8 30.6
## [496] 19.5 31.1 34.2 33.1 32.1
```

12.4 Averiguando normalidade

O pressuposto de normalidade é um pré-requisito para muitas técnicas estatísticas inferenciais (COAKES; STEED, 2001). Há várias maneiras diferentes de explorar graficamente esse pressuposto (LEVIN, 1977):

- Tabela de frequências
- Gráfico *Stem-and-leaf*
- Assimetria e Curtose
- Histograma
- Boxplot
- Gráfico de Probabilidade Normal (*Normal Probability Plot* ou *Normal Q-Q plot*)
- Gráfico normal sem tendência.

Além disso, há várias estatísticas disponíveis para testar a normalidade:

- Estatística de Shapiro-Wilk
- Kolmogorov-Smirnov, com nível de significância de Lilliefors

12.5 Tabela de frequências e gráfico *stem-and-leaf*

Mas o primeiro passo é construir uma tabela de frequências. Para fazermos uma tabela de frequência do comprimento dos brotos carregamos o pacote `fdth` e pedimos a função `range` que retorna o valor máximo e mínimo no vetor.

```
library(fdth)
range(brotos_sub) #retorna o valor máximo e mínimo
length(brotos_sub)
##?range
```

```
## [1] 10.0 44.9
## [1] 500
```

Agora é necessário que você substitua os valores de range 10, 44.9 nos valores de início e fim da distribuição de frequência. Os comandos abaixo criam uma tabela de frequência chamada `tf` com valores máximos e mínimos definidos por `range(brotos_v)` em intervalos definidos por `h=5`, e o comando `print(tf)` exibe a tabela de frequência.

```
tf <- fdt(brotos_sub, start=10, end=45, h=5) #tabela de
  ↪ frequência
##?fdt #atente para o uso de k, por exemplo tf <- fdt(brotos_sub,
  ↪ k=7)
print(tf)
```

```
## Class limits    f    rf rf(%)   cf cf(%)
##      [10,15)    6 0.01   1.2    6   1.2
##      [15,20)   35 0.07   7.0   41   8.2
##      [20,25)   93 0.19  18.6  134  26.8
##      [25,30)  155 0.31  31.0  289  57.8
##      [30,35)  130 0.26  26.0  419  83.8
##      [35,40)   57 0.11  11.4  476  95.2
##      [40,45)   24 0.05   4.8  500 100.0
```

Class limits = limites de classe, f = frequência de classe, rf = frequência relativa da classe, $rf(\%)$ = frequência relativa percentual da classe, cf = frequência cumulativa da classe, $cf(\%)$ = frequência cumulativa percentual da classe.

Se contarmos o número de brotos que se encontram em cada um dos sete intervalos, temos a base para a tabulação da frequência. Essa tabulação é mostrada na tabela gerada pelos códigos acima. A coluna de frequência foi obtida contando o número de medições que existem dentro de cada classe. A coluna de frequência percentual foi obtida representando cada contagem como uma porcentagem da contagem total. A frequência cumulativa e as frequências percentuais cumulativas foram obtidas somando progressivamente as frequências correspondentes.

12.5.1 Sobre tabelas de frequência

O valor de h definido anteriormente foi arbitrário. Em boa estatística, precisamos ser mais criteriosos. Para definirmos o valor de h (largura das classes) precisamos ter o valor de k (número de classes). Para isso dividimos a amplitude total dos dados pelo número de classes (k). A amplitude corresponde à diferença entre o maior e o menor valor do conjunto de dados. Essa relação é dada por:

$$h = \frac{\max(x) - \min(x)}{k}$$

onde, h = largura das classes; $\max(x)$ = maior valor observado; $\min(x)$ = menor valor observado; k = número de classes.

Essa fórmula é amplamente utilizada na construção de distribuições de frequência e histogramas, pois permite definir intervalos de classe aproximadamente uniformes (ver MOORE; MCCABE; CRAIG (2017)).

Podemos ainda usar a **Regra de Sturges** para decidir em quantos intervalos (k) os dados devem ser divididos (mas ver HYNDMAN ([s.d.])), através da fórmula:

$$k = 1 + 3.3 \log_{10}(n)$$

onde, k = número de classes e n = tamanho da amostra

```
#Regra de Sturges
k <- 1 + 3.3*log10(length(brotos_sub))
k <- ceiling(k) #ver as funções floor() e round()
h <- (max(brotos_sub) - min(brotos_sub))/k
h <- floor(h)
tf <- fdt(brotos_sub, start=10, end=45, h=h) #tabela de
  ↪ frequência manual
#?fdt #atente para o uso de k, por exemplo tf <- fdt(brotos_sub,
  ↪ k=k)
print(tf)
```

```
## Class limits f rf rf(%) cf cf(%)
## [10,13) 2 0.00 0.4 2 0.4
## [13,16) 7 0.01 1.4 9 1.8
## [16,19) 14 0.03 2.8 23 4.6
## [19,22) 48 0.10 9.6 71 14.2
## [22,25) 63 0.13 12.6 134 26.8
## [25,28) 82 0.16 16.4 216 43.2
```

```
##      [28,31) 98 0.20  19.6 314  62.8
##      [31,34) 78 0.16  15.6 392  78.4
##      [34,37) 52 0.10  10.4 444  88.8
##      [37,40) 32 0.06   6.4 476  95.2
##      [40,43) 15 0.03   3.0 491  98.2
```

12.5.2 Sobre o gráfico *stem-and-leaf*

Podemos agora entender melhor o que é o gráfico Stem-and-leaf.

```
stem(brotos_sub)
sort(brotos_sub)
```

```
##
## The decimal point is at the |
##
## 10 | 06
## 12 |
## 14 | 1699788
## 16 | 225558016
## 18 | 04888001112233445567889
## 20 | 011223556678811222356667889999
## 22 | 0011112233444445556688889002222455678
## 24 | 0111223345556677777888999900011124444555556777888889
## 26 | 00011222233334445566778888889990011112223444566667888889
## 28 | 0011222233344445666677888900000111112222233333444455666677788889999
## 30 | 00112222333444455566889990011234445556666677788999
## 32 | 0000112333344555566777790001111222233344455666689999
## 34 | 00122223333445556778888889904677789
## 36 | 0123344555677899900122355789
## 38 | 001112333478902445669
## 40 | 224555695799
## 42 | 015014779
## 44 | 049
##
## [1] 10.0 10.6 14.1 14.6 14.9 14.9 15.7 15.8 15.8 16.2 16.2 16.5 16.5 16.5 16.8
## [16] 17.0 17.1 17.6 18.0 18.4 18.8 18.8 18.8 19.0 19.0 19.1 19.1 19.1 19.2 19.2
## [31] 19.3 19.3 19.4 19.4 19.5 19.5 19.6 19.7 19.8 19.8 19.9 20.0 20.1 20.1 20.2
## [46] 20.2 20.3 20.5 20.5 20.6 20.6 20.7 20.8 20.8 21.1 21.1 21.2 21.2 21.2 21.3
## [61] 21.5 21.6 21.6 21.6 21.7 21.8 21.8 21.9 21.9 21.9 21.9 22.0 22.0 22.1 22.1
## [76] 22.1 22.1 22.2 22.2 22.3 22.3 22.4 22.4 22.4 22.4 22.5 22.5 22.5 22.6 22.6
## [91] 22.8 22.8 22.8 22.8 22.9 23.0 23.0 23.2 23.2 23.2 23.2 23.2 23.4 23.5 23.5
## [106] 23.6 23.7 23.8 24.0 24.1 24.1 24.1 24.2 24.2 24.3 24.3 24.4 24.5 24.5 24.5
```

```
## [121] 24.6 24.6 24.7 24.7 24.7 24.7 24.7 24.8 24.8 24.8 24.9 24.9 24.9 24.9 25.0
## [136] 25.0 25.0 25.1 25.1 25.1 25.2 25.4 25.4 25.4 25.4 25.5 25.5 25.5 25.5 25.5
## [151] 25.5 25.6 25.7 25.7 25.7 25.8 25.8 25.8 25.8 25.8 25.9 26.0 26.0 26.0 26.1
## [166] 26.1 26.2 26.2 26.2 26.2 26.2 26.3 26.3 26.3 26.3 26.4 26.5 26.5 26.6 26.7
## [181] 26.7 26.8 26.8 26.8 26.8 26.8 26.8 26.8 26.9 26.9 26.9 27.0 27.0 27.1 27.1
## [196] 27.1 27.1 27.2 27.2 27.2 27.3 27.4 27.4 27.4 27.5 27.6 27.6 27.6 27.6 27.7
## [211] 27.8 27.8 27.8 27.8 27.8 27.9 28.0 28.0 28.1 28.1 28.2 28.2 28.2 28.2 28.3
## [226] 28.3 28.3 28.4 28.4 28.4 28.4 28.5 28.6 28.6 28.6 28.6 28.7 28.7 28.8 28.8
## [241] 28.8 28.9 29.0 29.0 29.0 29.0 29.0 29.1 29.1 29.1 29.1 29.1 29.1 29.2 29.2
## [256] 29.2 29.2 29.2 29.3 29.3 29.3 29.3 29.3 29.3 29.4 29.4 29.4 29.5 29.5 29.6
## [271] 29.6 29.6 29.6 29.7 29.7 29.7 29.8 29.8 29.8 29.8 29.9 29.9 29.9 29.9 29.9
## [286] 29.9 29.9 29.9 29.9 30.0 30.0 30.1 30.1 30.2 30.2 30.2 30.2 30.3 30.3 30.3
## [301] 30.4 30.4 30.4 30.4 30.5 30.5 30.5 30.6 30.6 30.6 30.8 30.8 30.9 30.9 31.0
## [316] 31.0 31.1 31.1 31.2 31.3 31.4 31.4 31.4 31.5 31.5 31.5 31.6 31.6 31.6 31.6
## [331] 31.6 31.6 31.7 31.7 31.7 31.8 31.8 31.9 31.9 31.9 32.0 32.0 32.0 32.0 32.1
## [346] 32.1 32.2 32.3 32.3 32.3 32.3 32.4 32.4 32.5 32.5 32.5 32.5 32.6 32.6 32.7
## [361] 32.7 32.7 32.7 32.9 33.0 33.0 33.0 33.1 33.1 33.1 33.1 33.2 33.2 33.2 33.2
## [376] 33.3 33.3 33.3 33.4 33.4 33.4 33.5 33.5 33.6 33.6 33.6 33.6 33.8 33.9 33.9
## [391] 33.9 33.9 34.0 34.0 34.1 34.2 34.2 34.2 34.2 34.3 34.3 34.3 34.3 34.4 34.4
## [406] 34.5 34.5 34.5 34.6 34.7 34.7 34.8 34.8 34.8 34.8 34.8 34.8 34.9 34.9 35.0
## [421] 35.4 35.6 35.7 35.7 35.7 35.8 35.9 36.0 36.1 36.2 36.3 36.3 36.4 36.4 36.5
## [436] 36.5 36.5 36.6 36.7 36.7 36.8 36.9 36.9 36.9 37.0 37.0 37.1 37.2 37.2 37.3
## [451] 37.5 37.5 37.7 37.8 37.9 38.0 38.0 38.1 38.1 38.1 38.2 38.3 38.3 38.3 38.4
## [466] 38.7 38.8 38.9 39.0 39.2 39.4 39.4 39.5 39.6 39.6 39.9 40.2 40.2 40.4 40.5
## [481] 40.5 40.5 40.6 40.9 41.5 41.7 41.9 41.9 42.0 42.1 42.5 43.0 43.1 43.4 43.7
## [496] 43.7 43.9 44.0 44.4 44.9
```

Cada linha tem:

ramo | folhas, ou seja,

Ramo (stem) = parte inicial do número Folhas (leaf) = último dígito

Por exemplo:

28 | 00112222333444456666778889

significa valores como:

28.0 28.0 28.1 28.1 28.2 28.2 ... 28.9

Ou seja, cada dígito após | completa o número.

12.6 Assimetria e curtose

A assimetria mede a falta de simetria em uma distribuição de frequência. Uma distribuição é simétrica se as duas metades à esquerda e à direita da média

são cópias espelhadas uma da outra. Se a distribuição não é simétrica, então é assimétrica. A assimetria pode ser positiva, negativa ou nula (simétrica). Uma assimetria positiva indica que a cauda da distribuição se estende mais para a direita em relação à média ($\text{média} > \text{mediana} > \text{moda}$), enquanto uma assimetria negativa indica que a cauda da distribuição se estende mais para a esquerda em relação à média ($\text{média} < \text{mediana} < \text{moda}$) (LEVIN, 1977).

A curtose descreve o pico ou a “pontigudez” de uma distribuição. Uma distribuição com alta curtose tem uma alta concentração de valores ao redor da média e caudas mais pesadas (ou seja, valores extremos são mais prováveis). Uma distribuição com baixa curtose é mais achatada e dispersa, com caudas mais leves. A curtose pode ser positiva (distribuição leptocúrtica, com alta concentração em torno da média e caudas pesadas), negativa (distribuição platícúrtica, com dispersão alta e caudas mais leves) ou nula (mesocúrtica, similar à distribuição normal) (LEVIN, 1977).

Essas medidas são úteis para compreender as propriedades e características de diferentes conjuntos de dados e distribuições de frequência. Elas ajudam a compreender a forma e o comportamento dos dados em uma amostra ou população (ZAR, 2010).


```
library(moments)
skewness(brotos_sub)
kurtosis(brotos_sub)
```

```
## [1] 0.02432439
## [1] 2.748831
```

12.7 Gráficos de histograma e boxplot

No código abaixo se define o layout dos gráficos para serem exibidos lado a lado, e na sequência criamos um gráfico de histograma com base na tabela de frequência `tf`. O comando `boxplot()` cria um gráfico de boxplot para os valores em `brotos_v`. O argumento “horizontal = TRUE” indica que o boxplot deve ser horizontal.

```
par(mfrow = c(1,2)) #gráficos lado a lado
plot(tf) #distribuição de frequências
boxplot(brotos_sub, horizontal = TRUE,
        xlab="Class limits") #boxplot
par(mfrow = c(1,1)) #gráficos de volta ao normal
```



Se você recebeu a mensagem de erro “Error in plot.new() : figure margins too large”, aumente o tamanho da janela do gráfico e execute as últimas três linhas de comando novamente.

No boxplot observamos,

1. A linha localizada no interior da caixa, que representa a **mediana**, isto é, o valor central da distribuição dos dados,
2. A base da caixa, que corresponde ao **primeiro quartil (Q1)**, abaixo do qual se encontram **25% das observações**,
3. O topo da caixa, que corresponde ao **terceiro quartil (Q3)**, acima do qual estão **75% dos dados**,
4. A própria caixa representa o **intervalo interquartil ($IQR = Q3 - Q1$)**, contendo os 50% centrais da distribuição,
5. Os bigodes (*whiskers*), que indicam **os valores mínimos e máximos** que não são considerados outliers,
6. Os pontos isolados, que representam possíveis valores discrepantes ou **outliers**.

Uma nota sobre **outliers** em um boxplot. Seu cálculo varia dentre os textos e tipos de estatísticas sendo calculadas. Para outliers em um boxplot, MOORE; MCCABE; CRAIG (2017) propõem a “**regra de $1,5 \times IQR$ para outliers**”, onde IQR significa (*Interquartile Range* ou amplitude interquartil). Ou seja, considere uma observação como um possível *outlier* se ela estiver mais de $1,5 \times$

IQR acima do terceiro quartil ou abaixo do primeiro quartil².

O IQR (*Interquartile Range* ou amplitude interquartil) é definido como:

$$IQR = Q_3 - Q_1$$

onde, Q_1 = primeiro quartil (25%) e Q_3 = terceiro quartil (75%).

Essa regra de $1,5 \times IQR$ é usada em boxplots para identificar valores potencialmente extremos.

Os limites são calculados como:

$$\text{Limite inferior} = Q_1 - 1.5 \times IQR$$

$$\text{Limite superior} = Q_3 + 1.5 \times IQR$$

Valores fora desses limites são considerados possíveis outliers. Façamos o cálculo no R.

```
# Quartis
Q1 <- quantile(brotos_sub, 0.25)
Q3 <- quantile(brotos_sub, 0.75)
# Intervalo interquartil
IQR <- IQR(brotos_sub)
# Limites para outliers
lim_inf <- Q1 - 1.5 * IQR
lim_sup <- Q3 + 1.5 * IQR
# Valores considerados outliers
outliers <- brotos_sub[
  brotos_sub < lim_inf |
  brotos_sub > lim_sup]
# Resultados
Q1
Q3
IQR
lim_inf
lim_sup
outliers
sort(outliers)
```


²Quantil é o termo geral para pontos que dividem uma distribuição em proporções definidas; **quartis** dividem os dados em 4 partes iguais (25%, 50%, 75%) e ****percentis*** dividem os dados em 100 partes iguais (1%, 2%, ..., 99%).

```
## 25%
## 24.7
## 75%
## 33.225
## [1] 8.525
## 25%
## 11.9125
## 75%
## 46.0125
## [1] 10.6 10.0
## [1] 10.0 10.6
```

12.7.1 Histograma de densidade

Outra forma de ver a distribuição de frequência é através do histograma de densidade de probabilidade e curva normal teórica sobreposta.

```
hist(brotos_sub, probability = TRUE) #adicionamos a função
  ⇨ densidade
curve(dnorm(x, mean = mean(brotos_sub),
  sd = sd(brotos_sub)), #cria valores de x dentro do
  ⇨ intervalo do gráfico
  col = "red",
  add = TRUE) #adiciona ao gráfico atual
```



Esse código adiciona uma **curva da distribuição normal** sobre um gráfico já existente, nesse caso o histograma. Ou seja, ele desenha a **função densidade da distribuição normal** usando a média e o desvio padrão dos seus dados. Normalmente essa curva é usada para verificar visualmente se os dados se aproximam de uma distribuição normal. Mas ela só pode ser sobreposta ao histograma de densidade, e não a de frequências, porque ambos passam a estar na mesma escala.

Vejamos:

Nem sempre o gráfico produzido com método acima, com a função `hist()` e `probability = TRUE` fica igual ao método anterior usando simplesmente a função `plot()` e a tabela de frequência criada por `fdt()`. Principalmente quando temos distribuições de frequências assimétricas.

Isso ocorre porque o histograma produzido pela função `hist()` e a tabela de frequência produzida pela função `fdt()`, embora conceitualmente consistentes, representam quantidades diferentes. A principal fonte da diferença está no argumento utilizado no histograma:

```
hist(brotos_sub, probability = TRUE)
```

Quando utilizamos `probability = TRUE` o eixo y do histograma deixa de representar frequências absolutas e passa a representar **densidade de probabilidade**. Por isso, o gráfico apresenta valores pequenos no eixo vertical (0.00-0.06) em vez das frequências maiores esperadas (mostradas por números inteiros).

Isso acontece porque a tabela `fdt()` apresenta as frequências absolutas ou relativas (%), a partir de:

```
fdt(brotos_sub, start=10, end=45, h=5)
```

[15,20) -> 35 observações, o que indica que existem 35 valores entre 15 e 20. Já a frequência relativa (rf) é 0.07, e significa que aproximadamente 7% dos dados estão nesse intervalo.

O histograma com `probability = TRUE` é ajustado para que a área total das barras seja igual a 1 (**área total = 1**). Nesse caso, o gráfico representa uma **densidade de probabilidade**, e não frequências absolutas (ou relativas). Uma consequência importante, é que a altura das barras NÃO corresponde diretamente à frequência (nem a forma geral do histograma).

No histograma de densidade temos:

$$\text{Área} = \text{base} \times \text{altura}$$

então,

$$\text{altura} = \frac{\text{frequência relativa}}{\text{largura da classe}}$$

Na tabela `fdt()` desse exemplo foi utilizado `h=5`, portanto cada classe possui amplitude igual a 5. Para a classe [15,20), a frequência relativa foi 0.07. Assim, a altura esperada da barra no histograma de densidade é aproximadamente:

$$\frac{0.07}{5} = 0.014$$


É importante lembrar que em histogramas de densidade, as alturas precisam ser ajustadas para garantir que a área total sob o histograma deve ser igual a 1.

Podemos usar a função `hist()` para criar um histograma manualmente mostrando as frequências absolutas. Se o objetivo for visualizar frequências absolutas diretamente, basta estabelecer o argumento `probability = FALSE`. Nesse caso, o eixo y representará contagens/frequências. Podemos ainda definir os intervalos das classes manualmente na função `hist()`

```
hist(
  brotos_sub,
  probability = TRUE,
  breaks = seq(10, 45, by = 5)
)
```

12.8. GRÁFICO DE PROBABILIDADE NORMAL (NORMAL PROBABILITY PLOT OU NORMAL Q-Q PLOT)

```
curve(dnorm(x, mean = mean(brotos_sub),  
        sd = sd(brotos_sub)), #cria valores de x dentro do  
        ↪ intervalo do gráfico  
      col = "red",  
      add = TRUE) #adiciona ao gráfico atual
```




Por fim, deve-se ter em mente que nenhum desses métodos gera exatamente o mesmo histograma por que todos usam parâmetros levemente diferentes. O que é importante é a forma da distribuição de frequência e os demais critérios para determinação de normalidade.

12.8 Gráfico de probabilidade normal (*Normal probability plot* ou *Normal Q-Q plot*)

Em um gráfico Q-Q normal, pontos próximos da reta indicam que os dados seguem aproximadamente uma distribuição normal. Quando os pontos apresentam curvaturas acentuadas, isso sugere assimetria ou desvios importantes da normalidade. Já pontos muito afastados da reta podem indicar a presença de valores discrepantes (*outliers*).

```
qqnorm(brotos_sub,
       main = "Normal Q-Q Plot dos Brotos")
qqline(brotos_sub,
       col = "red",
       lwd = 2)
```



12.8.1 Algumas informações sobre o Q-Q plot e porquê ele é importante

O nome Q-Q plot vem de **Quantile-Quantile Plot**. Ele compara os quantis dos nossos dados com os quantis de uma distribuição teórica normal. Os quantis são posições na distribuição dos dados, por exemplo, a mediana é o quantil 50%. Os quartis dividem os dados em 4 partes, e o percentil divide em 100 partes. *Quantis e percentis são tipos de quantis.*

Atente que, os “quantis teóricos normais” não vêm dos seus dados. Eles vêm da distribuição normal ideal. O que vem dos seus dados são a quantidade de observações e a ordem dos valores (eixo y do Q-Q plot).

Tendo em vista que o eixo x do Q-Q plot mostra os quantis teóricos da normal padrão,

$$Z \sim N(0, 1)$$

e nessa distribuição, a média é 0 e o desvio padrão é 1.

Ou seja, no Q-Q Plot, o eixo x não mostra nossos dados diretamente (eles estão no eixo y). No eixo x, valores geralmente vão de cerca de -3 até +3, do intervalo de distribuições, onde ± 1 representa ~68% dos valores, ± 2 ~95% e 3 ~99.7%. Então quase todos os valores ficam entre

$$-3 \leq Z \leq 3$$

Dessa forma, cada ponto na distribuição representa o quantil teórico (eixo x) em relação ao valor observado nos nossos dados (eixo y).

12.9 Sumário estatístico geral

```
summary(brotos_sub)
#?summary
sd(brotos_sub) #desvio padrão
var(brotos_sub) #variância
names(sort(table(brotos_sub), decreasing = TRUE))[1] #moda
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  10.00  24.70   29.10   28.97   33.23   44.90
## [1] 6.373581
## [1] 40.62254
## [1] "29.9"
```

12.10 Estatística de Shapiro-Wilk

Os testes de Shapiro-Wilk e Kolmogorov-Smirnov são ambos usados para avaliar normalidade, mas funcionam de maneiras diferentes e têm objetivos diferentes (MOORE; MCCABE; CRAIG, 2017). O Shapiro-Wilk é mais utilizado para amostras pequenas e médias (preferível em relação ao Kolmogorov-Smirnov). Testa as hipóteses:

H_0 (Hipótese nula): os dados seguem distribuição normal

H_1 (Hipótese alternativa): os dados não seguem distribuição normal

```
shapiro.test(brotos_sub)
#format(p, scientific = FALSE)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  brotos_sub
## W = 0.99695, p-value = 0.4748
```

Para um $p = 0.05$ você não rejeita H_0 ao nível de 5%. Ou seja, os dados são compatíveis com uma distribuição normal.

O QUE REPORTAR:

O teste de Shapiro-Wilk não indicou desvio significativo da normalidade ($W=0.99695$, $p=0.4748$).

12.11 Estatística de Kolmogorov-Smirnov, com nível de significância de Lilliefors

O Kolmogorov-Smirnov é um teste mais geral, desenvolvido para responder a pergunta: “A distribuição observada difere da distribuição teórica?”. Portanto, mede se a distribuição observada difere da distribuição teórica, comparando a distribuição acumulada empírica dos dados com uma distribuição teórica. Por isso, ele pode ser usado para vários tipos de distribuição (normal, exponencial, uniforme, Poisson, etc). A estatística do teste é o D , e ele mede a maior distância entre as duas curvas acumuladas, sendo menos poderoso para normalidade e mais sensível ao centro da distribuição.

No caso do Kolmogorov-Smirnov, para testar normalidade, precisamos fornecer a média e o desvio padrão da amostra. Quando elas são estimados da própria amostra, o teste deixa de ser o Kolmogorov-Smirnov “puro” (mas veja a seguir). Por isso, **para normalidade, o Shapiro-Wilk costuma ser preferido**. O Kolmogorov-Smirnov pressupõe, ainda, que não existem empates (**ties**) nos dados, ou seja, valores repetidos. Nesses casos, o valor- p pode ficar menos confiável. Quando há muitos empates, a distribuição empírica fica “escalonada”, o que viola a hipótese teórica do teste.

Outro problema do Kolmogorov-Smirnov, para teste de normalidade é que ele precisa da média e do desvio padrão da normal teórica. Se a média e desvio padrão são estimados da amostra, isso enfraquece o teste. Uma possibilidade é a versão adaptada do Kolmogorov-Smirnov de Lilliefors no R. Ele é uma adaptação do Kolmogorov-Smirnov para normalidade com média e desvio padrão estimados da amostra.

```
#ks.test(brotos_sub, "pnorm") #assume media 0 e desvio padrão 1
ks.test(brotos_sub, #média e desvio padrão estimados da amostra
```



```
"pnorm",
mean(brotos_sub),
sd(brotos_sub))
```

```
## Warning in ks.test.default(brotos_sub, "pnorm", mean(brotos_sub),
## sd(brotos_sub)): não devem existir empates no teste de Kolmogorov-Smirnov de
## apenas uma amostra
```

```
#format(p, scientific = FALSE)
```

```
##
## Asymptotic one-sample Kolmogorov-Smirnov test
##
## data: brotos_sub
## D = 0.021571, p-value = 0.9741
## alternative hypothesis: two-sided
```

O teste Kolmogorov-Smirnov clássico foi desenvolvido para distribuições contínuas sem empates. No código acima foi estimada média e desvio usando a própria amostra.

Como o Kolmogorov-Smirnov clássico assume parâmetros conhecidos previamente, isso torna o teste “otimista”.

O teste ideal nesse caso é o Lilliefors

```
#install.packages("nortest")
library(nortest)
lillie.test(brotos_sub)
#format(p, scientific = FALSE)
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: brotos_sub
## D = 0.021571, p-value = 0.8279
```

12.12 Transformação de variáveis e outros tipos de conjuntos de dados

Todos os gráficos e estatísticas acima sugerem que os dados de **brots** apresentam distribuição normal. Porém, na natureza, as variáveis raramente se conformam a uma distribuição normal clássica, e também raramente lidamos com uma única variável.

Com mais frequência, as distribuições são assimétricas e apresentam graus variados de **assimetria** e **curtose**. Quando a assimetria e a curtose são extremas, a transformação é uma opção. A decisão de transformar variáveis depende da gravidade do afastamento em relação à normalidade. Tendo decidido que a transformação é desejável, o pesquisador deve selecionar os métodos de transformação mais apropriados. As opções disponíveis podem ser encontradas em qualquer bom capítulo sobre triagem dos dados, mas alguns textos que abordam esse tema são SOKAL; ROHLF (1995), SOKAL; ROHLF (2009) e ZAR (2010).

Além disso, em ecologia, comumente temos matrizes multivariadas de dados de espécies (matriz comunitária) ou de dados do ambiente (matriz ambiental). Veja nas matrizes disponíveis seção Arquivos disponíveis do Capítulo sobre Bases de dados..

12.12.1 Sobre transformações de variáveis em ecologia

As transformações de dados são procedimentos matemáticos aplicados individualmente a cada valor de uma matriz de dados, independentemente das linhas ou colunas. Seu principal objetivo é reduzir problemas estatísticos, como assimetria da distribuição (‘skewness’), heterogeneidade de variâncias e excesso de influência de valores muito altos (SOKAL; ROHLF, 1995; SOKAL; ROHLF, 2009; ZAR, 2010). Além disso, em análises multivariadas, as transformações ajudam a melhorar medidas de similaridade e a equilibrar a importância entre espécies raras e abundantes (LEGENDRE; LEGENDRE, 1998; VALENTIN, 2000).



NOTA

Veja a seção Tipos e estruturas de dados no R do Capítulo Sintaxe e Tipos de dados no R

Os principais tipos de transformação de dados são (SOKAL; ROHLF, 1995; SOKAL; ROHLF, 2009; ZAR, 2010):

12.12.1.1 Transformação exponencial (*power transformation*)

A transformação exponencial é uma das mais utilizadas em matrizes ecológicas. Ela consiste em elevar os valores da matriz a uma potência 'p':

$$y' = y^p$$

onde:

y = valor original; y' = valor transformado; p = potência aplicada.

Os valores mais comuns de 'p' são:

$$p = 1$$

Ou seja, sem transformação.

$$p = 0.5$$

Equivale a raiz quadrada, que também pode ser implementada por:

$$y' = \sqrt{y}$$

$$p = 0.25$$

Equivale a raiz quarta, ou:

$$y' = \sqrt{\sqrt{y}}$$

Temos ainda:

$$p = 0,$$

que, quando aplicado aos valores não-zero dos dados retorna a presença/ausência.

Em resumo, quanto menor o valor de 'p', maior é a compressão relativa dos valores altos.

12.12.1.2 Transformação logarítmica

Na distribuição de frequência, a transformação logarítmica comprime valores altos e espalha valores baixos, sendo muito utilizada para dados de abundância, biomassa e variáveis ambientais.

Pode ser usada como o log simples (base 10) ou o log natural (base e)

Pode ser usada como o log simples ($\log_{10}(y)$) ou o log natural ($\ln(y)$) (também, $\log_e(y)$, em que $e = \exp(1)$, como implementado no R).

$$y' = \log(y)$$

Uma variação do log, é:

$$y' = \log(y + 1)$$

O valor 1 é geralmente adicionado para evitar problemas com zeros no conjunto de dados. Essa transformação reduz a influência de valores extremos e melhora a distribuição dos dados.

12.12.1.3 Transformação arco-seno

A transformação arco-seno é aplicada principalmente em dados proporcionais ou percentuais, cujos valores variam entre 0 e 1.

$$y' = \arcsin(y)$$

Apesar de clássica, ela não é recomendada para muitos casos porque tende a comprimir valores baixos e espalhar valores altos.

12.12.1.4 Transformação arco-seno da raiz quadrada

Essa transformação é mais adequada para dados proporcionais, pois melhora a normalidade e redistribui melhor os valores percentuais.

$$y' = \arcsin(\sqrt{y})$$

Ou

$$y' = \frac{2}{\pi} \arcsin(\sqrt{y})$$

Nesses casos, os valores entram na fórmula variando entre 0 e 1, e o resultado continua variando entre 0 e 1. Essa transformação é especialmente útil quando os dados representam proporções ou porcentagens.

Note que, a escolha da transformação deve ser feita com critério, pois diferentes transformações podem alterar os resultados e as conclusões das análises multivariadas. Em ecologia, essa escolha depende mais da interpretação biológica desejada — como enfatizar espécies comuns ou raras — do que apenas de critérios estatísticos.

Para ilustrar o processo de transformação e conjuntos de dados mais realistas, veja o capítulo a seguir.

Apêndices

Sites consultados

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executa-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

```
# rm(list=ls(all=TRUE)) #limpa a memória
# install.packages("openxlsx") #importa arquivos do excel
# install.packages("fdth")
library(openxlsx)
# getwd()
# setwd("C:/Seu/Diretório/De/Trabalho")
library(openxlsx)
brotos <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/brotos.xlsx"
  ↪ ,
  rowNames = F, colNames = F,
  sheet = "Planilha1")

head(brotos,10)
head(brotos[, 1:5], 10)
# #View(brotos)
# print(brotos[1:5,1:5])
# brotos
# str(brotos)
# mode(brotos)
# class(brotos)
brotos_v <- as.vector(as.matrix(brotos))
brotos_v
# #View(brotos_v)
# print(brotos_v)
# brotos_v
# str(brotos_v)
# mode(brotos_v)
# class(brotos_v)
set.seed(666)
brotos_sub <- sample(brotos_v, size = 500, replace = F) #atualize
  ↪ o valor de 'size=' se necessário
brotos_sub
library(fdth)
```

```

range(brotos_sub) #retorna o valor máximo e mínimo
##?range
tf <- fdt(brotos_sub, start=10, end=45, h=5) #tabela de
  ↪ frequência
##?fdt #atente para o uso de k, por exemplo tf <- fdt(brotosv,
  ↪ k=5)
print(tf)
stem(brotos_sub)
sort(brotos_sub)
library(moments)
skewness(brotos_sub)
kurtosis(brotos_sub)
par(mfrow = c(1,2)) #gráficos lado a lado
plot(tf) #distribuição de frequências
boxplot(brotos_sub, horizontal = TRUE,
        xlab="Class limits") #boxplot
par(mfrow = c(1,1)) #gráficos de volta ao normal
hist(brotos_sub, probability = TRUE) #adicionamos a função
  ↪ densidade
curve(dnorm(x, mean = mean(brotos_sub),
                sd = sd(brotos_sub)), #cria valores de x dentro do
      ↪ intervalo do gráfico
      col = "red",
      add = TRUE) #adiciona ao gráfico atual
qqnorm(brotos_sub,
       main = "Normal Q-Q Plot dos Brotos")
qqline(brotos_sub,
       col = "red",
       lwd = 2)
summary(brotos_sub)
##?summary
sd(brotos_sub) #desvio padrão
var(brotos_sub) #variância
shapiro.test(brotos_sub)
ks.test(brotos_sub,
        "pnorm",
        mean(brotos_sub),
        sd(brotos_sub))
#install.packages("nortest")
library(nortest)
lillie.test(brotos_sub)

```

Referências

Chapter 13

R Módulo 3.2 - Testes estatísticos

RESUMO

A estatística descritiva tem um papel importante a desempenhar na ciência. Quando problemas específicos são tratados na ciência, os dados precisam ser coletados, analisados e apresentados de forma concisa para que outros possam se beneficiar do que foi encontrado.

Apresentação

A estatística descritiva tem um papel importante a desempenhar na ciência. Quando problemas específicos são tratados na ciência, os dados precisam ser coletados, analisados e apresentados de forma concisa para que outros possam se beneficiar do que foi encontrado. Geralmente não é possível apresentar um conjunto de dados completo em uma publicação ou em um seminário e, mesmo que fosse, é improvável isso permitisse uma boa comunicação dos resultados da pesquisa. Em vez disso, os dados são geralmente resumidos como tabelas de frequência, histogramas e estatísticas descritivas que os leitores ou ouvintes podem assimilar prontamente, mas que ainda transmitem os elementos essenciais do conjunto de dados original. O principal objetivo do cálculo das estatísticas descritivas é transmitir informações essenciais contidas em um conjunto de dados da forma mais concisa e clara possível.




Figure 13.1: Resumo esquemático dos possíveis testes estatísticos paramétricos univariados de acordo com a pergunta científica. No detalhe, suas respectivas alternativas não-paramétricas.

13.1 Sobre os dados

Considere os dados merísticos (ou medições morfológicas) da espécie de peixe *Cichla ocellaris* (tucunaré amarelo) do reservatório da barragem de Gramame, PB (MEDEIROS; ROSA, 1994) (Figura 13.2). Existem 421 medições do comprimento total (CT), comprimento padrão (CP) e peso total (PT), além do sexo (MACHO, FÊMEA ou imaturo), e outros descritores da estrutura populacional da espécie, um conjunto de dados formidável.



ATENÇÃO

Os links para baixar as planilhas necessárias para repetir esse tutorial podem ser encontrados na seção **Arquivos disponíveis** do Capítulo **Bases de dados**.

Ou, baixe aqui o arquivo `tucuna.xlsx`

n = 421	mes	período	estação	sexo	CT_cm	CP_cm	PT_g
TU 0001	ago	chuvoso	inverno	MACHO	32,4	27,2	468,8
TU 0002	ago	chuvoso	inverno	MACHO	33,4	28,8	520,0
TU 0003	ago	chuvoso	inverno	MACHO	27,3	23,8	301,5
TU 0004	ago	chuvoso	inverno	MACHO	13,2	11,0	28,2
TU 0005	ago	chuvoso	inverno	MACHO	14,3	11,9	38,9
TU 0006	set	chuvoso	inverno	MACHO	22,7	20,5	431,7
TU 0007	set	chuvoso	inverno	FEMEA	23,2	19,2	544,0
TU 0008	set	chuvoso	inverno	imaturo	13,5	11,5	161,6
TU 0009	set	chuvoso	inverno	MACHO	24,6	20,5	200,5
TU 0010	set	chuvoso	inverno	MACHO	19,4	16,0	86,7
TU 0011	set	chuvoso	inverno	FEMEA	25,5	21,2	206,7
TU 0012	set	chuvoso	inverno	MACHO	23,0	18,9	153,0
TU 0013	set	chuvoso	inverno	MACHO	17,4	14,4	68,7
TU 0014	set	chuvoso	inverno	FEMEA	16,5	12,2	53,6
TU 0015	set	chuvoso	inverno	MACHO	21,9	18,4	141,1
TU 0016	set	chuvoso	inverno	MACHO	28,1	23,4	299,3
TU 0017	set	chuvoso	inverno	MACHO	27,2	22,2	253,6
TU 0018	set	chuvoso	inverno	MACHO	25,5	20,6	226,0
TU 0019	set	chuvoso	inverno	FEMEA	38,0	32,0	437,1
TU 0020	set	chuvoso	inverno	MACHO	27,5	22,8	299,8
TU 0021	set	chuvoso	inverno	imaturo	7,8	6,2	4,5
TU 0022	set	chuvoso	inverno	imaturo	6,6	5,1	2,1
TU 0023	set	chuvoso	inverno	imaturo	7,8	6,1	4,0
TU 0024	set	chuvoso	inverno	imaturo	8,3	6,6	5,5
TU 0025	set	chuvoso	inverno	imaturo	8,6	6,8	6,7
TU 0026	set	chuvoso	inverno	imaturo	6,3	5,9	2,5
TU 0027	set	chuvoso	inverno	imaturo	8,0	6,1	4,9
TU 0028	set	chuvoso	inverno	imaturo	10,9	8,5	13,5
TU 0029	set	chuvoso	inverno	imaturo	7,1	5,5	3,3
TU 0030	set	chuvoso	inverno	imaturo	9,8	7,8	10,0
TU 0031	set	chuvoso	inverno	imaturo	6,0	4,6	2,1
TU 0032	set	chuvoso	inverno	imaturo	6,1	5,9	2,0
TU 0033	set	chuvoso	inverno	imaturo	6,2	4,9	1,9
TU 0034	set	chuvoso	inverno	imaturo	6,6	5,2	2,3
TU 0035	set	chuvoso	inverno	imaturo	6,5	5,0	2,5
TU 0036	set	chuvoso	inverno	imaturo	6,1	4,8	2,2
TU 0037	set	chuvoso	inverno	imaturo	6,1	4,8	2,5

Figure 13.2: Dados merísticos da espécie de peixe *Cichla ocellaris* (tucunaré amarelo) do reservatório da barragem de Gramame, PB.

13.2 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

Instalando os pacotes necessários para esse módulo

```
install.packages("openxlsx") #importa arquivos do excel
install.packages("fdth")
install.packages("ggpubr")
install.packages("multcomp")
```

```
library(openxlsx)
```

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

13.3 Importando a planilha

Vamos importar a planilha de dados univariados `tucuna.xlsx`. Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações. Ajuste a segunda linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.

```
library(openxlsx)
univ <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/tucuna.xlsx"
  ↪ ,
  rowNames = T, colNames = T,
  sheet = "tucuna")
head(univ, 10)
head(univ[, 1:5], 10)
```

```
##          CT_cm  PT_g  CP_cm  Ctubo_cm  PC_g      p_PT  Pest_g  Cest_cm  gr_est      ir_est
```

```

## TU001 32.4 468.8 27.2 39.8 458.9 2.111775 3.9 7.7 I 0.8319113
## TU002 33.4 520.0 28.8 14.3 507.4 2.423077 5.9 10.0 I 1.1346154
## TU003 27.3 301.5 23.8 13.0 283.4 6.003317 15.5 10.2 III 5.1409619
## TU004 13.2 28.2 11.0 16.5 27.7 1.773050 0.3 4.3 I 1.0638298
## TU005 14.3 38.9 11.9 15.5 37.7 3.084833 0.8 4.5 III 2.0565553
## TU006 22.7 431.7 20.5 24.2 418.7 3.011350 9.9 6.4 III 2.2932592
## TU007 23.2 544.0 19.2 25.0 520.1 4.393382 6.8 7.5 II 1.2500000
## TU008 13.5 161.6 11.5 17.5 157.0 2.846535 4.1 6.8 II 2.5371287
## TU009 24.6 200.5 20.5 25.7 195.9 2.294264 2.5 7.6 II 1.2468828
## TU010 19.4 86.7 16.0 18.3 84.5 2.537486 0.7 5.1 I 0.8073818
##      Pint_g Cint_cm gr_int  ir_int Pgon_g Cgon_cm      emg      ig
## TU001 4.8 38.3 II 1.0238908 1.2 7 IMATURO 0.25597270
## TU002 5.3 13.3 II 1.0192308 1.4 6.5 MADURO 0.26923077
## TU003 2.4 12.0 II 0.7960199 0.2 7.7 EM MATURACAO 0.06633499
## TU004 0.1 16.0 II 0.3546099 0.1 5 IMATURO 0.35460993
## TU005 0.3 15.0 II 0.7712082 0.1 3.2 IMATURO 0.25706941
## TU006 2.7 23.7 II 0.6254343 0.4 7.8 EM MATURACAO 0.09265694
## TU007 3.3 24.5 II 0.6066176 13.8 7.9 MADURO 2.53676471
## TU008 0.4 17.0 I 0.2475248 0.1 2.5 IMATURO 0.06188119
## TU009 2.0 25.3 II 0.9975062 0.1 6.5 EM MATURACAO 0.04987531
## TU010 1.4 17.7 II 1.6147636 0.1 6 IMATURO 0.11534025
##      mes periodo estação  sexo  sexo2
## TU001 ago chuvoso inverno  MACHO  FEMEA
## TU002 ago chuvoso inverno  MACHO  FEMEA
## TU003 ago chuvoso inverno  MACHO  FEMEA
## TU004 ago chuvoso inverno  MACHO  FEMEA
## TU005 ago chuvoso inverno  MACHO  FEMEA
## TU006 set chuvoso inverno  MACHO  FEMEA
## TU007 set chuvoso inverno  FEMEA  MACHO
## TU008 set chuvoso inverno imaturo imaturo
## TU009 set chuvoso inverno  MACHO  FEMEA
## TU010 set chuvoso inverno  MACHO  FEMEA
##      CT_cm PT_g CP_cm Ctubo_cm PC_g
## TU001 32.4 468.8 27.2 39.8 458.9
## TU002 33.4 520.0 28.8 14.3 507.4
## TU003 27.3 301.5 23.8 13.0 283.4
## TU004 13.2 28.2 11.0 16.5 27.7
## TU005 14.3 38.9 11.9 15.5 37.7
## TU006 22.7 431.7 20.5 24.2 418.7
## TU007 23.2 544.0 19.2 25.0 520.1
## TU008 13.5 161.6 11.5 17.5 157.0
## TU009 24.6 200.5 20.5 25.7 195.9
## TU010 19.4 86.7 16.0 18.3 84.5

```

Exibindo os dados importados (esses comando são “case-sensitive” `ignore.case(object)`).

```
#View(univ)
print(univ[1:5,1:5])
univ
str(univ)
mode(univ)
class(univ)
```

Vamos escolher uma coluna como a variável de interesse para trabalhar com ela. No código abaixo, essa coluna é descrita pelo seu nome apresentado depois do \$. Antes do \$ especificamos e qual data frame está a variável. Depois disso, a convertemos para um vetor.

```
colnames(univ)
var <- univ$CP_cm
var_v <- as.vector(var)
range(var_v)
```

```
## [1] "CT_cm" "PT_g" "CP_cm" "Ctubo_cm" "PC_g" "p_PT"
## [7] "Pest_g" "Cest_cm" "gr_est" "ir_est" "Pint_g" "Cint_cm"
## [13] "gr_int" "ir_int" "Pgon_g" "Cgon_cm" "emg" "ig"
## [19] "mes" "periodo" "estação" "sexo" "sexo2"
## [1] 3.5 36.1
```




Figure 13.3: Estimativa do comprimento padrão (CP) e comprimento total (CT) em cm.

E agora visualizando nossos dados.

```
#View(var)
print(var_v)
var_v
sort(var_v)
str(var_v)
mode(var_v)
class(var_v)
range(var_v)
length(var_v)
```

Por inspeção, o comprimento total mínimo do peixe é 3.5 cm e o máximo é 36.1 cm. Esses valores definem o intervalo da amostra. Agora precisamos subdividir os dados em intervalos ou classes, cada um com o mesmo tamanho. Geralmente, é aconselhável arredondar o valor mínimo para baixo e o valor máximo para cima, para valores apropriados ao decidir as classes de intervalos. Nesse caso, parece sensato dividir a faixa de `range(var_v)` cm em sete intervalos a cada 5 cm de largura. Se contarmos o número de peixes que se encontram em cada um dos sete intervalos, temos a base para a tabulação da frequência.

A coluna de frequência será obtida contando o número de medições que existem dentro de cada classe. A coluna de frequência percentual será obtida representando cada contagem como uma porcentagem da contagem total. A frequência cumulativa e as frequências percentuais cumulativas serão obtidas somando progressivamente as frequências correspondentes.

Tendo em mãos o conjunto total de 434 valores merísticos da variável de interesse agora **podemos tirar uma subamostra aleatória de uma parte dos 434 valores**. Essa subamostra é tirada usando o comando `size=` no código subsequente, que estabelece o tamanho da subamostra a ser tirada do total de dados. Por exemplo, para uma subamostra de 150 comprimentos, então `size = 150`. Nesse tutorial usaremos todos os 434 comprimentos. Podemos ainda escolher uma das colunas da base de dados, nesse caso vamos usar a coluna

Substitua em `n <-` o valor de `size=` desejado. Aqui `n <-` será todo o conjunto de dados `length(var_v)`.

```
n <- length(var_v)
set.seed(666)
var_sub <- sample(var_v, size = n, replace = F) #atualize o valor
  ↪ de 'size=' se necessário
#OU
var_sub <- univ[univ$CP_cm >0 & univ$CP_cm <20,] #data.frame
var_sub <- var_v[var_v>=5 & var_v <=15] #vector
```

13.4 REINÍCIO

```
var_sub <- var_trns
```

13.5 Averiguando normalidade

13.5.1 Tabela de frequências e gráfico *stem-and-leaf*

Para fazermos uma tabela de frequência dos valores merísticos carregamos o pacote `fdth` e pedimos a função `range` que retorna o valor máximo e mínimo no vetor.

```
library(fdth)
range <- range(var_sub) #retorna o valor máximo e mínimo
##range
```

Agora é necessário que você substitua os valores de `range` 3.5, 36.1 nos valores de início e fim da distribuição de frequência. Os comandos abaixo criam uma tabela de frequência chamada `tf` com valores máximos e mínimos definidos por `range(var_sub)` em intervalos definidos por `h`, e o comando `print(tf)` exibe a tabela de frequência.

```
##Regra de Sturges
k <- 1 + 3.3*log10(length(var_sub))
k <- ceiling(k) #ver as funções floor() e round()
h <- (max(var_sub) - min(var_sub))/k
h <- floor(h)
tf <- fdt(var_sub, start=3, end=40, h=4) #tabela de frequência
  ↪ manual
tfk <- fdt(var_sub, k=k) #atente para o uso de k
##fdt
print(tf)
print(tfk)
```

```
## Class limits   f   rf rf(%)   cf   cf(%)
##           [3,7) 141 0.32 32.49 141  32.49
##           [7,11) 97 0.22 22.35 238  54.84
##           [11,15) 82 0.19 18.89 320  73.73
```



```
##      [15,19)  29 0.07  6.68 349  80.41
##      [19,23)  29 0.07  6.68 378  87.10
##      [23,27)  21 0.05  4.84 399  91.94
##      [27,31)  20 0.05  4.61 419  96.54
##      [31,35)  10 0.02  2.30 429  98.85
##      [35,39)   5 0.01  1.15 434 100.00
##      Class limits  f   rf rf(%)  cf  cf(%)
##      [3.465,6.7646) 137 0.32 31.57 137 31.57
##      [6.7646,10.064) 79 0.18 18.20 216 49.77
##      [10.064,13.364) 82 0.19 18.89 298 68.66
##      [13.364,16.663) 33 0.08  7.60 331 76.27
##      [16.663,19.963) 27 0.06  6.22 358 82.49
##      [19.963,23.263) 22 0.05  5.07 380 87.56
##      [23.263,26.562) 19 0.04  4.38 399 91.94
##      [26.562,29.862) 15 0.03  3.46 414 95.39
##      [29.862,33.161) 14 0.03  3.23 428 98.62
##      [33.161,36.461)  6 0.01  1.38 434 100.00
```

13.5.2 Gráfico *stem-and-leaf*

```
stem(var_sub)
sort(var_sub)
```

```
##
## The decimal point is at the |
##
##      2 | 5556677778999
##      4 | 00012233333555555556666677778888888999999000011112222222333334555+15
##      6 | 00011111122222233444556667777888900122333456666778888899
##      8 | 0001334455555777777888011112223344445556667899
##     10 | 0000011124444556677778899900012233356666777889999999
##     12 | 000000112222223344455778990011223444559999
##     14 | 00122224455572555778
##     16 | 005500266799
##     18 | 0145568889126688889
##     20 | 02556770258889
##     22 | 0125890245689
##     24 | 0002570034
##     26 | 0002024
##     28 | 005780022368
##     30 | 00002002
##     32 | 000190
```

```
## 34 | 9000
## 36 | 01
##
## [1] 3.5 3.5 3.5 3.6 3.6 3.7 3.7 3.7 3.7 3.7 3.8 3.9 3.9 3.9 4.0 4.0
## [16] 4.0 4.1 4.2 4.2 4.3 4.3 4.3 4.3 4.3 4.3 4.5 4.5 4.5 4.5 4.5 4.5
## [31] 4.5 4.5 4.5 4.6 4.6 4.6 4.6 4.6 4.6 4.6 4.7 4.7 4.7 4.7 4.8 4.8
## [46] 4.8 4.8 4.8 4.8 4.8 4.9 4.9 4.9 4.9 4.9 4.9 4.9 4.9 5.0 5.0 5.0
## [61] 5.0 5.1 5.1 5.1 5.1 5.2 5.2 5.2 5.2 5.2 5.2 5.2 5.2 5.3 5.3 5.3
## [76] 5.3 5.3 5.4 5.5 5.5 5.5 5.5 5.6 5.6 5.6 5.6 5.6 5.6 5.6 5.6 5.7
## [91] 5.7 5.7 5.7 5.7 5.7 5.7 5.7 5.8 5.8 5.8 5.8 5.8 5.8 5.9 5.9 5.9
## [106] 5.9 5.9 5.9 6.0 6.0 6.0 6.1 6.1 6.1 6.1 6.1 6.1 6.1 6.2 6.2 6.2
## [121] 6.2 6.2 6.2 6.3 6.3 6.4 6.4 6.4 6.4 6.4 6.5 6.5 6.6 6.6 6.6 6.7
## [136] 6.7 6.7 6.8 6.8 6.8 6.9 7.0 7.0 7.1 7.2 7.2 7.2 7.3 7.3 7.3 7.4
## [151] 7.5 7.6 7.6 7.6 7.6 7.7 7.7 7.8 7.8 7.8 7.8 7.8 7.8 7.9 7.9 8.0
## [166] 8.0 8.0 8.1 8.3 8.3 8.4 8.4 8.5 8.5 8.5 8.5 8.5 8.5 8.7 8.7 8.7
## [181] 8.7 8.7 8.7 8.7 8.8 8.8 8.8 8.8 9.0 9.1 9.1 9.1 9.1 9.2 9.2 9.2
## [196] 9.3 9.3 9.4 9.4 9.4 9.4 9.5 9.5 9.5 9.6 9.6 9.6 9.6 9.7 9.8 9.9
## [211] 9.9 10.0 10.0 10.0 10.0 10.0 10.1 10.1 10.1 10.2 10.4 10.4 10.4 10.4 10.4 10.5
## [226] 10.5 10.6 10.6 10.7 10.7 10.7 10.7 10.7 10.8 10.8 10.9 10.9 10.9 10.9 11.0 11.0
## [241] 11.0 11.1 11.2 11.2 11.3 11.3 11.3 11.5 11.6 11.6 11.6 11.6 11.6 11.7 11.7 11.7
## [256] 11.7 11.8 11.8 11.9 11.9 11.9 11.9 11.9 11.9 11.9 12.0 12.0 12.0 12.0 12.0 12.0
## [271] 12.0 12.1 12.1 12.2 12.2 12.2 12.2 12.2 12.2 12.2 12.3 12.3 12.4 12.4 12.4 12.5
## [286] 12.5 12.7 12.7 12.8 12.9 12.9 12.9 13.0 13.0 13.1 13.1 13.2 13.2 13.3 13.4 13.4
## [301] 13.4 13.5 13.5 13.9 13.9 13.9 13.9 14.0 14.0 14.1 14.2 14.2 14.2 14.2 14.2 14.4
## [316] 14.4 14.5 14.5 14.5 14.7 15.2 15.5 15.5 15.5 15.7 15.7 15.8 16.0 16.0 16.5 16.5
## [331] 16.5 17.0 17.0 17.2 17.6 17.6 17.7 17.9 17.9 18.0 18.1 18.4 18.5 18.5 18.6 18.6
## [346] 18.8 18.8 18.8 18.9 19.1 19.2 19.6 19.6 19.8 19.8 19.8 19.8 19.8 19.9 20.0 20.2
## [361] 20.5 20.5 20.6 20.7 20.7 21.0 21.2 21.5 21.8 21.8 21.8 21.8 21.9 22.0 22.1 22.2
## [376] 22.5 22.8 22.9 23.0 23.2 23.4 23.5 23.6 23.8 23.9 24.0 24.0 24.0 24.2 24.5 24.5
## [391] 24.7 25.0 25.0 25.3 25.4 26.0 26.0 26.0 26.2 27.0 27.2 27.4 28.0 28.0 28.5 28.5
## [406] 28.7 28.8 29.0 29.0 29.2 29.2 29.3 29.6 29.8 30.0 30.0 30.0 30.0 30.2 31.0 31.0
## [421] 31.0 31.2 32.0 32.0 32.0 32.1 32.9 33.0 34.9 35.0 35.0 35.0 36.0 36.1 36.1
```



13.5.3 Assimetria e curtose

```
library(moments)
skewness(var_sub)
kurtosis(var_sub)
```

```
## [1] 1.145572
## [1] 3.462176
```

13.6 Histograma e boxplot

```
par(mfrow = c(2,1)) #gráficos lado a lado
plot(tf) #distribuição de frequências
boxplot(var_sub, horizontal = TRUE,
        xlab="Class limits") #boxplot
par(mfrow = c(1,1)) #gráficos de volta ao normal
```



IMPORTANTE Se você recebeu a mensagem de erro “Error in plot.new() : figure margins too large”, aumente o tamanho da janela do gráfico e execute as últimas três linhas de comando novamente.

Calculando os outliers.

```
# Quartis
Q1 <- quantile(var_sub, 0.25)
Q3 <- quantile(var_sub, 0.75)

# Intervalo interquartil
IQR <- IQR(var_sub)

# Limites para outliers
```

```

lim_inf <- Q1 - 1.5 * IQR
lim_sup <- Q3 + 1.5 * IQR

# Valores considerados outliers
outliers <- var_sub[
  var_sub < lim_inf |
  var_sub > lim_sup
]
# Resultados
Q1
Q3
IQR
lim_inf
lim_sup
outliers
sort(outliers)
boxplot.stats(var_sub)
#var_sub_sem_outliers <- var_sub[!var_sub %in% outliers]


```

```

## 25%
## 6
## 75%
## 15.7
## [1] 9.7
## 25%
## -8.55
## 75%
## 30.25
## [1] 34.9 31.0 35.0 32.0 32.1 35.0 32.0 35.0 31.2 32.9 36.1 32.0 33.0 31.0 36.0
## [1] 31.0 31.0 31.2 32.0 32.0 32.0 32.1 32.9 33.0 34.9 35.0 35.0 35.0 36.0 36.1
## $stats
## [1] 3.5 6.0 10.1 15.7 30.2
##
## $n
## [1] 434
##
## $conf
## [1] 9.364328 10.835672
##
## $out
## [1] 34.9 31.0 35.0 32.0 32.1 35.0 32.0 35.0 31.2 32.9 36.1 32.0 33.0 31.0 36.0

```

```
hist(var_sub, probability = TRUE) #adicionamos a função densidade
curve(dnorm(x, mean = mean(var_sub),
            sd = sd(var_sub)), #cria valores de x dentro do
            ↪ intervalo do gráfico
      col = "red",
      add = TRUE) #adiciona ao gráfico atual
```



13.7 Sumário estatístico geral

```
summary(var_sub)
#?summary
sd(var_sub) #desvio padrão
var(var_sub) #variância
names(sort(table(var_sub), decreasing = TRUE))[1] #moda
```




```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      3.50   6.00   10.10   12.32   15.70   36.10
## [1] 7.845708
## [1] 61.55514
## [1] "4.5"
```


13.8 Testando normalidade

13.8.1 Q-Q plots

```
limites <- range(var_sub)
par(mfrow=c(3,1))
qqnorm(var_sub,
      main = "Normal Q-Q Plot")
qqline(var_sub,
      col = "red",
      lwd = 1)
boxplot(var_sub, horizontal = TRUE, #atentar para o parâmetro
      ↪ `horizontal`
      main="Boxplot",
      ylim=limites,
      xlab="Class limits") #boxplot
hist(var_sub, probability = TRUE,
      xlim = limites,
      main = "Histogram") #adicionamos a função densidade
curve(dnorm(x, mean = mean(var_sub),
      sd = sd(var_sub)), #cria valores de x dentro do
      ↪ intervalo do gráfico
      col = "red",
      add = TRUE) #adiciona ao gráfico atual
par(mfrow=c(1,1))

library(ggpubr)
ggqqplot(var_sub)
```





13.8.2 Testes de Shapiro-Wilk e Kolmogorov-Smirnov

```
shap <- shapiro.test(var_sub)
shap
p <- format(shap$p.value, scientific = FALSE)
p
```



```

#?str()
#?attributes()
ks.test(var_sub, "pnorm")

```

```

## Warning in ks.test.default(var_sub, "pnorm"): não devem existir empates no
## teste de Kolmogorov-Smirnov de apenas uma amostra

```

```

ks.test(var_sub,
        "pnorm",
        mean(var_sub),
        sd(var_sub))

```

```

## Warning in ks.test.default(var_sub, "pnorm", mean(var_sub), sd(var_sub)): não
## devem existir empates no teste de Kolmogorov-Smirnov de apenas uma amostra

```

```

##
##  Shapiro-Wilk normality test
##
## data:  var_sub
## W = 0.86837, p-value < 2.2e-16
##
## [1] "0.00000000000000000107347"
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  var_sub
## D = 0.99977, p-value < 2.2e-16
## alternative hypothesis: two-sided
##
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  var_sub
## D = 0.15016, p-value = 6.326e-09
## alternative hypothesis: two-sided

```

```

#install.packages("nortest")
library(nortest)
lillie.test(var_sub)

```

```
##  
##  Lilliefors (Kolmogorov-Smirnov) normality test  
##  
## data:  var_sub  
## D = 0.15016, p-value < 2.2e-16
```

13.9 Transformando os dados

Podemos aplicar algumas transformações nesses dados para tentar aproximá-los mais de uma distribuição normal.



NOTA

Veja a seção Transformando variáveis e outros tipos de conjuntos de dados do Capítulo Introdução ao R/RStudio

```
library(MASS)  
boxcox(lm(var_sub ~ 1))  
var_trns <- var_sub
```

Se o lambda ótimo da função `boxcox()` for:

- 1, usar transformação inversa ($1/y$);
- 0, usar log;
- 0.5, usar raiz quadrada;
- 1, não transformar.



REINÍCIO

Volte até a seção de REINÍCIO desse capítulo e refaça as análises com os dados transformados.

Se achar necessário, revise o conteúdo do capítulo anterior Estatísticas descritivas e normalidade

13.10 Comparando médias

13.10.1 Testando homogeneidade de variâncias

Um pressuposto importante que deve ser testado quando se compara médias entre conjuntos de dados é a **homogeneidade de variâncias**. Os grupos devem ser provenientes de populações que apresentem variâncias semelhantes.

Para verificar esse pressuposto, utilizamos o **teste de Levene** para igualdade de variâncias (COAKES; STEED, 2001; MCDONALD, 2014).

Se o teste de Levene for significativo ($p < 0,05$), rejeita-se a hipótese nula de igualdade das variâncias e aceita-se a hipótese alternativa de que as variâncias são diferentes entre os grupos. Nesse caso, devem ser utilizados os resultados que não assumem igualdade de variâncias. Se o teste de Levene não for significativo ($p > 0,05$), não há evidências para rejeitar a hipótese nula, indicando que as variâncias dos grupos podem ser consideradas homogêneas. Nesse caso, podem ser utilizados os resultados que assumem igualdade de variâncias.

Essa distinção torna-se mais clara ao interpretar a saída do teste t para amostras independentes, que normalmente apresenta resultados tanto para a situação em que as variâncias são consideradas iguais quanto para aquela em que são consideradas diferentes.

Hipótese nula (H_0): as variâncias populacionais são iguais entre os grupos, há homogeneidade de variâncias.

Hipótese alternativa (H_1): pelo menos uma das variâncias populacionais difere das demais, há heterogeneidade de variâncias.

Interpretação:

$p > 0,05$: não se rejeita H_0

$p < 0,05$: rejeita-se H_0

```
# Levene
library(car)
univ$sexo <- as.factor(univ$sexo) #evita o Warning de "group
  ↳ coerced to factor"
fator <- factor(univ$sexo, levels = c("MACHO", "FEMEA",
  ↳ "imaturo"))
lev <- leveneTest(var_sub ~ fator, data = univ)
fator
lev
# Teste de Levene entre dois de tres (ou mais) grupos
machos_CP_cm <- na.omit(univ$CP_cm[univ$sexo == "MACHO"])
femeas_CP_cm <- na.omit(univ$CP_cm[univ$sexo == "FEMEA"])
imat_CP_cm <- na.omit(univ$CP_cm[univ$sexo == "imaturo"])
```

```
leveneTest(CP_cm ~ sexo, data = univ[univ$sexo %in% c("MACHO",
  ↪ "FEMEA"), ])
```

*#Interpretação: Um valor de p maior que o nível de significância
 ↪ de 0.05 significa que, a hipótese nula é mantida e NÃO HÁ
 ↪ diferença significativa entre as variâncias.*


```
univ$sexo <- factor(univ$sexo, levels = c("MACHO", "FEMEA",
  ↪ "imaturado"))
boxplot(CP_cm ~ fator, data = univ)
```

```
## [1] MACHO MACHO MACHO MACHO MACHO MACHO FEMEA imaturado MACHO
## [10] MACHO FEMEA MACHO MACHO FEMEA MACHO MACHO MACHO MACHO
## [19] FEMEA MACHO imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [28] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [37] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [46] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [55] imaturado imaturado imaturado imaturado imaturado imaturado MACHO FEMEA FEMEA MACHO
## [64] MACHO MACHO FEMEA MACHO MACHO MACHO FEMEA FEMEA MACHO MACHO
## [73] FEMEA MACHO MACHO imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [82] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [91] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [100] imaturado imaturado imaturado imaturado imaturado imaturado imaturado MACHO MACHO imaturado
## [109] MACHO MACHO MACHO MACHO FEMEA imaturado imaturado FEMEA FEMEA
## [118] MACHO FEMEA imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [127] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [136] FEMEA FEMEA imaturado imaturado MACHO FEMEA MACHO MACHO MACHO
## [145] imaturado imaturado imaturado FEMEA imaturado imaturado imaturado imaturado imaturado
## [154] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [163] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [172] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [181] imaturado imaturado MACHO MACHO FEMEA imaturado imaturado imaturado imaturado
## [190] FEMEA FEMEA FEMEA MACHO FEMEA imaturado imaturado FEMEA imaturado
## [199] imaturado FEMEA MACHO imaturado FEMEA imaturado FEMEA imaturado FEMEA
## [208] imaturado imaturado FEMEA MACHO MACHO FEMEA FEMEA MACHO imaturado
## [217] FEMEA MACHO MACHO FEMEA MACHO FEMEA imaturado FEMEA imaturado
## [226] FEMEA FEMEA imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [235] imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado imaturado
## [244] imaturado imaturado imaturado imaturado FEMEA imaturado imaturado MACHO MACHO
## [253] imaturado imaturado imaturado imaturado imaturado imaturado FEMEA imaturado imaturado
## [262] imaturado imaturado imaturado imaturado imaturado FEMEA MACHO imaturado FEMEA
## [271] MACHO FEMEA FEMEA imaturado imaturado imaturado imaturado imaturado imaturado
## [280] imaturado imaturado imaturado imaturado imaturado FEMEA imaturado FEMEA imaturado
## [289] FEMEA MACHO MACHO imaturado imaturado imaturado FEMEA FEMEA MACHO
## [298] FEMEA imaturado MACHO FEMEA FEMEA MACHO MACHO MACHO MACHO
```

```

## [307] FEMEA FEMEA MACHO imaturo FEMEA imaturo FEMEA MACHO FEMEA
## [316] FEMEA imaturo imaturo imaturo imaturo imaturo imaturo imaturo imaturo
## [325] imaturo MACHO MACHO imaturo MACHO MACHO FEMEA FEMEA imaturo
## [334] MACHO MACHO FEMEA MACHO FEMEA MACHO MACHO MACHO imaturo
## [343] FEMEA FEMEA MACHO MACHO FEMEA FEMEA MACHO FEMEA imaturo
## [352] MACHO MACHO FEMEA MACHO FEMEA MACHO MACHO MACHO MACHO
## [361] imaturo MACHO MACHO MACHO FEMEA FEMEA FEMEA MACHO FEMEA
## [370] imaturo imaturo MACHO MACHO FEMEA MACHO FEMEA MACHO MACHO
## [379] imaturo imaturo MACHO MACHO MACHO FEMEA FEMEA MACHO MACHO
## [388] MACHO FEMEA FEMEA FEMEA FEMEA FEMEA MACHO MACHO MACHO
## [397] MACHO FEMEA MACHO FEMEA FEMEA MACHO MACHO MACHO FEMEA
## [406] MACHO FEMEA MACHO MACHO FEMEA imaturo MACHO FEMEA MACHO
## [415] imaturo MACHO FEMEA MACHO imaturo FEMEA FEMEA MACHO MACHO
## [424] MACHO MACHO MACHO FEMEA MACHO MACHO imaturo MACHO MACHO
## [433] MACHO MACHO
## Levels: MACHO FEMEA imaturo
## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value Pr(>F)
## group  2  0.2018 0.8173
##      431
## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value Pr(>F)
## group  1 10.638 0.001292 **
##      211
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```



13.11 Testes t (*t-tests*)

Os **testes t** são utilizados para determinar se um valor, ou conjuntos de valores, são da mesma população amostral, e podem ser classificados em três tipos principais (LEVIN; COSTA, 1987):

Teste t para uma amostra (*One-sample t-test*)

Teste t para grupos independentes (*Independent groups t-test*) - Bicaudal (*Two-sided*) - Unicaudal (*Single-sided*)

Teste t para amostras pareadas, ou para medidas repetidas (*Repeated measures t-test*)

13.11.0.1 Pressupostos

Cada teste estatístico possui determinados pressupostos (*assumptions*) que precisam ser atendidos antes da análise. Esses pressupostos devem ser avaliados, pois a interpretação correta dos resultados depende de eles não serem violados. Alguns pressupostos são comuns a todos os tipos de teste t, enquanto outros são específicos de determinados modelos.

Os pressupostos gerais dos testes t são:

1. Escala de medida: Os dados devem estar em nível de mensuração intervalar ou razão.
2. Amostragem aleatória: Os escores devem ser obtidos por amostragem aleatória da população de interesse.
3. Normalidade: Os escores devem apresentar distribuição normal na população.

Os pressupostos 1 e 2 dependem do delineamento da pesquisa e não da análise estatística em si. O pressuposto 3 pode ser avaliado de diferentes maneiras, como testes de normalidade e inspeção gráfica.

13.11.0.2 Exemplos

De acordo com CÂMARA; CHELLAPPA; CHELLAPPA (2002), o tamanho da primeira maturação sexual de *Cichla ocellaris* é 26,2cm para os machos e 21,4 para fêmeas. Já GOMIERO; BRAGA (2004), encontrou o L_{50} e L_{100} da primeira maturação sexual para fêmeas da espécie sendo 20 e 29 cm, respectivamente.

A partir daqui, podemos seguir com três tipos de perguntas para o nosso conjunto de dados:

1. O comprimento médio dos indivíduos amostrados difere do tamanho de primeira maturação sexual descrito na literatura? (Teste t para uma amostra)
2. O comprimento médio difere entre machos e fêmeas de *Cichla ocellaris*? (Teste t para grupos independentes)
3. Existe diferença no comprimento dos indivíduos antes e após a maturação sexual? (Teste t para medidas repetidas)

13.11.1 Teste t para uma amostra (*One-sample t-test*)

H_0 : a média populacional da variável é igual ao valor de referência.

H_1 : a média populacional da variável é diferente do valor de referência.

```
var_sub <- var_v
```

```

# Machos
machos <- subset(var_sub, univ$sexo == "MACHO")
machos
mean(machos)
t_machos <- t.test(
  machos,
  mu = 26.2
)
t_machos
# Fêmeas
femeas <- subset(var_sub, univ$sexo == "FEMEA")
femeas
mean(femeas)
t_femeas <- t.test(
  femeas,
  mu = 21.4
)
t_femeas

```

```

## [1] 27.2 28.8 23.8 11.0 11.9 20.5 20.5 16.0 18.9 14.4 18.4 23.4 22.2 20.6 22.8
## [16] 31.2 23.2 21.8 22.9 29.8 18.0 19.6 19.8 18.8 21.5 23.9 27.0 25.0 22.0 32.1
## [31] 29.6 22.1 15.7 20.2 23.6 14.4 17.9 20.7 19.1 13.0 13.0 10.6 10.9 10.4 12.9
## [46] 12.0 10.8 10.7 8.1 12.7 28.0 11.9 12.0 15.5 10.9 14.1 14.2 9.5 12.4 15.7
## [61] 8.8 8.7 10.0 12.3 13.9 9.6 9.8 10.4 11.6 12.0 14.2 7.3 8.7 9.1 8.5
## [76] 9.3 9.1 8.5 6.9 9.0 9.4 10.9 11.0 10.5 12.0 11.1 11.7 16.5 17.0 15.5
## [91] 11.0 12.0 13.2 26.2 28.5 36.1 29.2 29.3 29.2 32.9 14.5 16.5 13.9 19.6 27.4
## [106] 22.5 28.7 20.7 31.0 35.0 25.3 28.0 29.0 29.0 30.0 30.0 30.0 31.0 35.0 35.0
## [121] 36.0 33.0
## [1] 18.70164
##
## One Sample t-test
##
## data: machos
## t = -10.156, df = 121, p-value < 2.2e-16
## alternative hypothesis: true mean is not equal to 26.2
## 95 percent confidence interval:
## 17.23992 20.16335
## sample estimates:
## mean of x
## 18.70164
##
## [1] 19.2 21.2 12.2 32.0 19.8 30.2 24.0 19.8 19.9 24.2 23.0 18.1 17.7 23.5 26.0
## [16] 19.8 13.3 14.0 18.5 15.5 13.2 12.8 11.7 8.4 17.9 10.0 13.4 12.2 10.0 10.8
## [31] 10.4 11.7 10.6 8.8 9.3 9.6 10.1 10.0 11.9 11.6 13.5 10.7 8.5 11.3 9.4

```



```
## [46] 12.3 14.5 18.8 12.1 12.2 14.5 15.2 6.2 7.2 11.8 7.0 20.0 7.8 10.1 11.2
## [61] 6.7 7.7 8.5 8.0 8.0 9.2 8.7 10.5 11.7 11.6 12.7 13.1 17.0 12.9 21.8
## [76] 17.6 18.5 18.6 21.8 24.5 14.0 17.2 24.0 24.7 25.4 26.0 25.0 24.0 14.2 26.0
## [91] 30.0
## [1] 15.27692
##
## One Sample t-test
##
## data:  femeas
## t = -9.3405, df = 90, p-value = 6.728e-15
## alternative hypothesis: true mean is not equal to 21.4
## 95 percent confidence interval:
## 13.97458 16.57927
## sample estimates:
## mean of x
## 15.27692
```

O QUE REPORTAR: Os comprimentos médios observados para machos e fêmeas de *Cichla ocellaris* diferiram significativamente dos tamanhos de primeira maturação sexual descritos por CÂMARA; CHELLAPPA; CHELLAPPA (2002). Os machos apresentaram comprimento médio de 18,70 cm, significativamente inferior ao valor de referência de 26,2 cm (teste t para uma amostra: $t = -10,16$; $gl = 121$; $p < 0,001$). As fêmeas apresentaram comprimento médio de 15,28 cm, também inferior ao valor de referência de 21,4 cm (teste t para uma amostra: $t = -9,34$; $gl = 90$; $p < 0,001$).

13.11.2 Teste t para grupos independentes (*Independent groups t-test*)

```
t.test(machos_CP_cm, femeas_CP_cm,
       alternative = c("two.sided"), # "two.sided", "less",
       ↪ "greater"
       mu = 0, paired = FALSE,
       var.equal = FALSE, # não assume homog. de variâncias =
       ↪ Welch's t-test
       conf.level = 0.95)
```

```
##
## Welch Two Sample t-test
##
## data:  machos_CP_cm and femeas_CP_cm
## t = 3.4686, df = 210.82, p-value = 0.0006342
```

```
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  1.478371 5.371062
## sample estimates:
## mean of x mean of y
##  18.70164  15.27692
```

O QUE REPORTAR: Foi observada diferença significativa no comprimento padrão entre machos e fêmeas de *Cichla ocellaris* (teste t de Welch: $t = 3,47$; $gl = 210,82$; $p < 0,001$). Os machos apresentaram maior comprimento médio (18,70 cm) em comparação às fêmeas (15,28 cm).

Quanto a sua direção, o teste t para grupos independentes, pode ser bicaudal (o que usamos anteriormente) e unicaudal. No primeiro caso, a área de rejeição é dividida entre as duas extremidades (caudas) da distribuição. É usado quando você quer saber se existe uma diferença, mas não tem certeza se o resultado será maior ou menor. No **teste t unicaudal**, toda a área de rejeição fica em apenas uma das extremidades. É usado quando a sua hipótese prevê uma direção específica (ex: testar se um novo remédio é melhor, mas não se ele é pior).

Quanto a sua direção, o teste t para grupos independentes, pode ser bicaudal (o que usamos anteriormente) e unicaudal. O **teste t bicaudal** é utilizado quando se deseja verificar se existe qualquer diferença entre duas médias, sem especificar previamente a direção dessa diferença.

H_0 : as médias populacionais de dois grupos são iguais.

H_1 : as médias populacionais de dois grupos são diferentes.

No exemplo com tucunaré, perguntamos: “O comprimento padrão médio difere entre machos e fêmeas?”. Aqui não se assume previamente qual sexo possui maior comprimento.

Já o **teste t unicaudal** é utilizado quando existe uma **hipótese direcional**, ou seja, quando se espera previamente que uma média seja maior ou menor que a outra.

No exemplo do tucunaré, perguntamos: “Os machos possuem comprimento padrão médio maior que as fêmeas?”. No R, isso é implementado com o argumento `alternative = c("greater")`.

```
t.test(machos_CP_cm, femeas_CP_cm,
       alternative = c("greater"), # "two.sided", "less", "greater"
       mu = 0, paired = FALSE,
       var.equal = FALSE, # não assume homog. de variâncias =
       ↪ Welch's t-test
       conf.level = 0.95)
```

```
##
##  Welch Two Sample t-test
##
## data: machos_CP_cm and femeas_CP_cm
## t = 3.4686, df = 210.82, p-value = 0.0003171
## alternative hypothesis: true difference in means is greater than 0
## 95 percent confidence interval:
##  1.7935      Inf
## sample estimates:
## mean of x mean of y
##  18.70164  15.27692
```

O QUE REPORTAR: O comprimento padrão médio foi significativamente maior nos machos (18,70 cm) do que nas fêmeas (15,28 cm) (teste t de Welch unilateral: $t = 3,47$; $gl = 210,82$; $p = 0,0003$).

A pergunta oposta, “Os machos possuem comprimento padrão médio menor que as fêmeas?”, é implementada com o argumento `alternative = c("less")`.

13.11.3 Teste t pareado ou para medidas repetidas (*Repeated measures t-test*)

A principal característica do teste t pareado é que cada observação do primeiro grupo possui uma observação correspondente no segundo grupo. Ou seja, os dados vêm dos mesmos indivíduos ou de unidades experimentais que formam pares naturais (desenho amostral do tipo antes e depois).

O teste não compara diretamente as médias dos grupos. Na verdade, ele calcula a diferença dentro de cada par e testa se a média dessas diferenças é igual a zero.

H_0 : Hipótese nula: a média das diferenças entre as duas medidas pareadas é igual a zero.

H_1 : Hipótese alternativa: a média das diferenças entre as duas medidas pareadas é diferente de zero.

```
# Filtrar apenas fêmeas
femeas <- subset(univ, sexo == "FEMEA")
# Manter apenas IMATURO e MADURO
femeas2 <- subset(
  femeas,
  emg %in% c("IMATURO", "EM MATURACAO")
)
t.test(
  CP_cm ~ emg,
```

```

data = femeas2,
alternative = "two.sided",
var.equal = FALSE,    #Welch t-test
conf.level = 0.95
)

##
##  Welch Two Sample t-test
##
## data:  CP_cm by emg
## t = 2.4517, df = 12.999, p-value = 0.02912
## alternative hypothesis: true difference in means between group EM MATURACAO and group EM IMATURAS
## 95 percent confidence interval:
##  0.4039742 6.3950597
## sample estimates:
## mean in group EM MATURACAO      mean in group EM IMATURAS
##                16.87778                13.47826

```

O QUE REPORTAR: O comprimento padrão diferiu significativamente entre fêmeas imaturas e em maturação de *Cichla ocellaris* (teste t de Welch: $t = 2,45$; $gl = 13,00$; $p = 0,029$). Fêmeas em maturação apresentaram maior comprimento médio (16,88 cm) em comparação às fêmeas imaturas (13,48 cm).

13.12 Teste entre três médias (ANOVA)

13.12.1 ANOVA One-Way, teste entre grupos com comparações *pos hoc*

No caso anterior foi testada a hipótese nula de que duas médias populacionais eram iguais. Quando se deseja comparar as médias de mais de dois grupos ou níveis de uma variável independente, utiliza-se uma análise de variância de uma via (*One-way Analysis of Variance* - ANOVA).

No centro da ANOVA está o conceito de variância. O procedimento básico consiste em obter duas estimativas diferentes da variância populacional a partir dos dados e, em seguida, calcular uma estatística baseada na razão entre essas duas estimativas.

Uma dessas estimativas (**variância entre grupos**) mede o efeito da variável independente combinado com a variância do erro. A outra estimativa (**variância dentro dos grupos**) mede apenas a variância do erro.

A razão F é a razão entre a variância entre grupos e a variância dentro dos grupos. Um valor significativo de F indica que provavelmente nem todas as médias populacionais são iguais.

$$F = \frac{\text{Variância entre grupos}}{\text{Variância dentro dos grupos}}$$

13.12.2 Cálculo da variância entre grupos

A variância entre grupos é obtida a partir da Soma dos Quadrados Entre os Grupos (SQE), que mede o quanto as médias dos grupos se afastam da média geral:

$$SQE = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2$$

onde:

- k é o número de grupos;
- n_i é o número de observações no grupo i ;
- $\bar{x}_i$ é a média do grupo i ;
- $\bar{x}$ é a média geral.

A variância entre grupos, também chamada de Quadrado Médio Entre os Grupos (QME), é calculada por:

$$QME = \frac{SQE}{k - 1}$$

13.12.3 Cálculo da variância dentro dos grupos

A variância dentro dos grupos é obtida pela Soma dos Quadrados Dentro dos Grupos (SQD), que representa a variabilidade das observações em torno da média de seu próprio grupo:

$$SQD = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2$$

A variância dentro dos grupos, também chamada de Quadrado Médio do Erro (QMD ou QMR), é dada por:

$$QMD = \frac{SQD}{N - k}$$

onde:

- N é o número total de observações;
- k é o número de grupos.

Finalmente, a estatística de teste da ANOVA é calculada como:

$$F = \frac{QME}{QMD}$$

Quando a hipótese nula (H_0) é verdadeira, espera-se que as estimativas de variância entre e dentro dos grupos sejam semelhantes, produzindo um valor de (F) próximo de 1. Valores elevados de (F) indicam que a variabilidade entre os grupos é significativamente maior do que a variabilidade dentro dos grupos, fornecendo evidências para rejeitar a hipótese nula. Assim, conclui-se que pelo menos uma média populacional difere das demais, sendo necessários testes *pos hoc* para identificar quais grupos apresentam diferenças significativas.

Como a hipótese nula é rejeitada quando qualquer par de médias é desigual, é necessário identificar onde estão as diferenças significativas. Isso requer uma **análise *post hoc***.

A análise *pos hoc* ocorre quando se procura nos dados qualquer significância estatística. Ou seja, deseja-se realizar um conjunto completo de comparações.

Esse tipo de teste envolve riscos de erros do tipo I¹. Diferentemente das comparações planejadas, os testes *pos hoc* são elaborados para proteger contra erros do tipo I, considerando que todas as comparações possíveis serão realizadas. Esses testes são mais rigorosos do que as comparações planejadas e, portanto, é mais difícil obter significância estatística.

Há vários testes *pos hoc* disponíveis. Quanto mais opções de comparação um teste oferece, mais rigoroso ele é na determinação da significância.

O teste de Scheffé, por exemplo, permite realizar todas as comparações possíveis, mas é bastante rigoroso na rejeição da hipótese nula. Em contraste, o **teste HSD de Tukey (*Honestly Significant Difference*)** é mais flexível, mas há restrições quanto aos tipos de comparações que podem ser realizados. No nosso caso, usaremos o teste *pos hoc* HSD de Tukey (COAKES; STEED, 2001).

¹O erro do Tipo I ocorre quando rejeitamos a hipótese nula (H_0) apesar de ela ser verdadeira. Em outras palavras, conclui-se, incorretamente, que existe uma diferença significativa quando, na realidade, ela não existe.

13.12.3.1 Pressupostos

Antes de realizar a ANOVA, é necessário garantir que os pressupostos necessários sejam atendidos. Os pressupostos da ANOVA são os mesmos do teste t. Os dois pressupostos principais são:

Normalidade populacional: As populações das quais as amostras foram retiradas devem apresentar distribuição normal. Isso deve ser verificado para cada grupo usando estatísticas de normalidade, como assimetria (*skewness*) e teste de Shapiro-Wilk.

Homogeneidade de variâncias: Os escores de cada grupo devem apresentar variâncias homogêneas. Assim como no teste t, o teste de Levene determinará se as variâncias são iguais ou diferentes.

13.12.3.2 Exemplos

Como no exemplo anterior, podemos testar três tipos de perguntas:

1. Testar os pressupostos subjacentes da ANOVA.
2. Determinar se existem diferenças significativas no comprimento dos peixes entre as três classificações para a variável `sexo`.
3. Identificar a origem dessas diferenças (caso elas existam) utilizando análise *pos hoc*.

13.12.4 Gráficos exploratórios

```
levels(univ$sexo)
univ$sexo <- ordered(univ$sexo,
                     levels = c("MACHO", "FEMEA", "imaturado"))

library(dplyr)
summarise(
  group_by(univ, sexo),
  count = n(),
  mean = mean(CP_cm, na.rm = TRUE),
  sd = sd(CP_cm, na.rm = TRUE)
)

# Conjunto de gráficos
library("ggpubr")
ggboxplot(univ, x = "sexo", y = "CP_cm",
          color = "sexo", palette = c("#00AFBB", "#E7B800",
          ↵ "#FC4E07"),
```

```


    order = c("MACHO", "FEMEA", "imaturo"),
    ylab = "CP_cm", xlab = "Sexo")
ggline(univ, x = "sexo", y = "CP_cm",
      add = c("mean_se", "jitter"),
      order = c("MACHO", "FEMEA", "imaturo"),
      ylab = "CP (cm)", xlab = "Sexo")
boxplot(CP_cm ~ sexo, data = univ,
        xlab = "Sexo", ylab = "CP_cm",
        frame = FALSE, col = c("#00AFBB", "#E7B800", "#FC4E07"))
library(gplots)
plotmeans(CP_cm ~ sexo, data = univ,
          xlab = "Sexo", ylab = "CP_cm",
          main="Média com 95% IC") #frame = FALSE



```


```

## [1] "MACHO" "FEMEA" "imaturo"
## # A tibble: 3 x 4
##   sexo    count  mean    sd
##   <ord>   <int> <dbl> <dbl>
## 1 MACHO    122  18.7  8.16
## 2 FEMEA    91   15.3  6.25
## 3 imaturo  221   7.57  4.44

```







13.12.5 Análise de variância (ANOVA)

H_0 : Hipótese nula: todas as médias populacionais dos grupos são iguais.

H_1 : Hipótese alternativa: pelo menos uma das médias populacionais difere das demais.

```
anova <- aov(CP_cm ~ sexo, data = univ)
summary(anova)
```

*#Interpretação: Um valor de p MENOR que o nível de significância
 ↳ de 0.05 significa que,
 #EXISTE diferença significativa entre as três grupos de médias.*

```
##           Df Sum Sq Mean Sq F value Pr(>F)
## sexo      2  10743    5371   145.5 <2e-16 ***
## Residuals 431  15911      37
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

O QUE REPORTAR: Foi observada diferença significativa no comprimento padrão entre os grupos de sexo avaliados (ANOVA one-way: F , = 145,5; $p < 0,001$).

Mas a ANOVA não informa quais dos grupos diferem entre si. Para isso você precisa fazer um teste *pos hoc*.

13.12.6 Comparações múltiplas *pos hoc*

```

TukeyHSD(anova)
library(multcomp)
summary(glht(anova, linfct = mcp(sexo = "Tukey")))
# T-test entre pares
pairwise.t.test(univ$CP_cm, univ$sexo,
                 p.adjust.method = "BH")
#pairwise.t.test

##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = CP_cm ~ sexo, data = univ)
##
## $sexo
##              diff              lwr              upr              p adj
## FEMEA-MACHO   -3.424716   -5.403982  -1.445451  0.0001655
## imaturo-MACHO -11.127884 -12.739590  -9.516177  0.0000000
## imaturo-FEMEA  -7.703167  -9.482984  -5.923350  0.0000000
##
##
##   Simultaneous Tests for General Linear Hypotheses
##
## Multiple Comparisons of Means: Tukey Contrasts
##
## Fit: aov(formula = CP_cm ~ sexo, data = univ)
##
## Linear Hypotheses:
##              Estimate Std. Error t value Pr(>|t|)
## FEMEA - MACHO == 0    -3.4247    0.8416  -4.069 0.000161 ***
## imaturo - MACHO == 0  -11.1279    0.6853 -16.238 < 1e-04 ***
## imaturo - FEMEA == 0   -7.7032    0.7568 -10.179 < 1e-04 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## (Adjusted p values reported -- single-step method)
##
##
## Pairwise comparisons using t tests with pooled SD
##
## data:  univ$CP_cm and univ$sexo
##

```

```
##          MACHO   FEMEA
## FEMEA    5.6e-05 -
## imaturo < 2e-16 < 2e-16
##
## P value adjustment method: BH
```


O QUE REPORTAR: O comprimento padrão diferiu significativamente entre os grupos avaliados (ANOVA one-way: $F, = 145,5$; $p < 0,001$). O teste *pos hoc* de Tukey indicou que os machos apresentaram comprimento padrão significativamente maior que as fêmeas (diferença média = 3,42 cm; $p < 0,001$) e indivíduos imaturos (diferença média = 11,13 cm; $p < 0,001$). Além disso, as fêmeas apresentaram comprimento significativamente maior que os indivíduos imaturos (diferença média = 7,70 cm; $p < 0,001$).


13.12.7 Avaliações *a posteriori*

```
## Homogeneidade de variâncias
plot(anova, 1) #valores numerados são outliers
library(car)
leveneTest(CP_cm ~ sexo, data = univ)
# ANOVA sem o pressuposto de igualdade de variâncias
oneway.test(CP_cm ~ sexo, data = univ)
# Testes pareados sem o pressuposto de igualdade de variâncias
pairwise.t.test(univ$CP_cm, univ$sexo,
                 p.adjust.method = "BH", pool.sd = FALSE)
# Normalidade pelos resíduos (Q-Q plot)
plot(anova, 2)
# Extraíndo os resíduos e rodando o Shapiro-Wilk neles
anova_residuals <- residuals(object = anova)
shapiro.test(x = anova_residuals)
# ANOVA não-paramétrica (Kruskal-Wallis)
kruskal.test(CP_cm ~ sexo, data = univ)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##          Df F value    Pr(>F)
## group    2  45.138 < 2.2e-16 ***
##          431
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## One-way analysis of means (not assuming equal variances)
##
```

```
## data: CP_cm and sexo
## F = 134.26, num df = 2.00, denom df = 180.92, p-value < 2.2e-16
##
##
## Pairwise comparisons using t tests with non-pooled SD
##
## data: univ$CP_cm and univ$sexo
##
##      MACHO  FEMEA
## FEMEA  0.00063 -
## imaturo < 2e-16 < 2e-16
##
## P value adjustment method: BH
##
## Shapiro-Wilk normality test
##
## data: anova_residuals
## W = 0.93021, p-value = 2.35e-13
##
##
## Kruskal-Wallis rank sum test
##
## data: CP_cm by sexo
## Kruskal-Wallis chi-squared = 217.39, df = 2, p-value < 2.2e-16
```





13.13 ANOVA Two-Way, teste entre grupos e dois fatores (*Factorial ANOVA*)

A ANOVA fatorial funciona da mesma maneira que a ANOVA de uma via, exceto pelo fato de que uma variável independente adicional é examinada. Cada variável independente pode possuir dois ou mais níveis. Em um delineamento entre grupos com dois fatores, cada participante foi aleatoriamente designado para apenas um dos diferentes níveis de cada variável independente, onde cada uma das diferentes células representa combinações únicas dos níveis dos dois fatores.

13.13.0.1 Pressupostos

Antes de realizar a ANOVA de duas vias, é necessário garantir que os pressupostos necessários sejam atendidos. Os pressupostos da ANOVA de duas vias são os mesmos da ANOVA de uma via:

Normalidade populacional: As populações das quais as amostras foram retiradas devem apresentar distribuição normal. Isso deve ser verificado para cada grupo usando estatísticas de normalidade, como assimetria (*skewness*) e teste de Shapiro-Wilk.

Homogeneidade de variâncias: Os escores em cada grupo devem apresentar variâncias homogêneas.

A principal preocupação está relacionada às violações do segundo pressuposto, porque tais violações podem significar que os dados foram avaliados em um nível de significância maior do que o inicialmente assumido. Em vez de serem significativos em um nível alfa de 0,05, os resultados podem, na realidade, ser significativos apenas em um nível alfa de 0,10.

Isso ocorre porque violações do pressuposto de homogeneidade distorcem o formato da distribuição F, de modo que o valor crítico de F deixa de corresponder a um ponto de corte de 5%.

13.13.0.2 Exemplo

No caso dos dados de dinâmica populacional do tucunaré, além do fator **sexo** (que tem três níveis: MACHO, FÊMEA, imaturo), podemos querer considerar o efeito de um segundo fator no comprimento dos indivíduos. Podemos usar o fator **período** (dois níveis: chuvoso, seco).

Assim, a primeira variável independente é o sexo, com três níveis, e a segunda variável independente é o período do ano, com dois níveis. A variável dependente pode ser o comprimento padrão (CP_cm) ou comprimento total (CT_cm).

Atente que agora temos um delineamento fatorial 3×2 , com seis combinações possíveis.

```
univ$sexo <- factor(univ$sexo,
  levels = c("MACHO", "FÊMEA", "imaturo"))
univ$período <- factor(univ$período,
  levels = c("chuvoso", "seco"))
str(univ)
table(univ$sexo, univ$período)
```

```
## 'data.frame': 434 obs. of 23 variables:
## $ CT_cm : num 32.4 33.4 27.3 13.2 14.3 22.7 23.2 13.5 24.6 19.4 ...
## $ PT_g : num 468.8 520 301.5 28.2 38.9 ...
## $ CP_cm : num 27.2 28.8 23.8 11 11.9 20.5 19.2 11.5 20.5 16 ...
## $ Ctubo_cm: num 39.8 14.3 13 16.5 15.5 24.2 25 17.5 25.7 18.3 ...
## $ PC_g : num 458.9 507.4 283.4 27.7 37.7 ...
## $ p_PT : num 2.11 2.42 6 1.77 3.08 ...
## $ Pest_g : num 3.9 5.9 15.5 0.3 0.8 9.9 6.8 4.1 2.5 0.7 ...
## $ Cest_cm : num 7.7 10 10.2 4.3 4.5 6.4 7.5 6.8 7.6 5.1 ...
## $ gr_est : chr "I" "I" "III" "I" ...
## $ ir_est : num 0.832 1.135 5.141 1.064 2.057 ...
```

```
## $ Pint_g : num 4.8 5.3 2.4 0.1 0.3 2.7 3.3 0.4 2 1.4 ...
## $ Cint_cm : num 38.3 13.3 12 16 15 23.7 24.5 17 25.3 17.7 ...
## $ gr_int : chr "II" "II" "II" "II" ...
## $ ir_int : num 1.024 1.019 0.796 0.355 0.771 ...
## $ Pgon_g : num 1.2 1.4 0.2 0.1 0.1 0.4 13.8 0.1 0.1 0.1 ...
## $ Cgon_cm : chr "7" "6.5" "7.7" "5" ...
## $ emg : chr "IMATURO" "MADURO" "EM MATURACAO" "IMATURO" ...
## $ ig : num 0.256 0.2692 0.0663 0.3546 0.2571 ...
## $ mes : chr "ago" "ago" "ago" "ago" ...
## $ periodo : Factor w/ 2 levels "chuvoso","seco": 1 1 1 1 1 1 1 1 1 1 ...
## $ estação : chr "inverno" "inverno" "inverno" "inverno" ...
## $ sexo : Ord.factor w/ 3 levels "MACHO"<"FEMEA"<...: 1 1 1 1 1 1 2 3 1 1 ...
## $ sexo2 : chr "FEMEA" "FEMEA" "FEMEA" "FEMEA" ...
##
##           chuvoso seco
## MACHO           68  54
## FEMEA           38  53
## imaturo          60 161
```

Cada célula da tabela criada, representa uma combinação entre **sexo** (MACHO, FÊMEA, imaturo) e período (chuvoso, seco).

A partir desse desenho, podemos responder às seguintes perguntas:

1. O sexo influencia o comprimento dos indivíduos?
2. O período do ano influencia o comprimento dos indivíduos?
3. A influência do sexo sobre o comprimento depende do período do ano?

Ou seja, deseja-se avaliar a possível interação entre sexo e período sobre a estrutura de tamanho populacional de *Cichla ocellaris*.


13.13.1 Gráficos exploratórios



```
library("ggpubr")
ggboxplot(univ, x = "sexo", y = "CP_cm", color = "periodo",
          palette = c("#00AFBB", "#E7B800"))
ggline(univ, x = "sexo", y = "CP_cm", color = "periodo",
       add = c("mean_se", "dotplot"),
       binwidth = 1,
       palette = c("#00AFBB", "#E7B800"))
```



13.13. ANOVA TWO-WAY, TESTE ENTRE GRUPOS E DOIS FATORES (FACTORIAL ANOVA) 237

```
## Bin width defaults to 1/30 of the range of the data. Pick better value with  
## `binwidth`.
```

```
boxplot(CP_cm ~ periodo * sexo, data=univ, frame = FALSE,  
        col = c("#00AFBB", "#E7B800"), ylab="CP_cm")  
  
# Gráfico das interações  
interaction.plot(x.factor = univ$periodo, trace.factor =  
  ↪ univ$sexo,  
                 response = univ$CP_cm, fun = mean,  
                 type = "b", legend = TRUE,  
                 xlab = "Sexo", ylab="CP_cm",  
                 pch=c(1,19), col = c("#00AFBB", "#E7B800"))
```







De forma geral, para uma ANOVA de dois fatores (*two-way* ANOVA) são testadas três hipóteses, correspondentes aos dois efeitos principais e à interação entre os fatores.

13.13.1.1 Efeito principal do fator A

Hipótese nula (H_0): as médias populacionais são iguais entre os níveis do fator A, ou seja, o fator A não exerce efeito sobre a variável resposta.

Hipótese alternativa (H_1): pelo menos uma média difere entre os níveis do fator A.

13.13.1.2 Efeito principal do fator B

Hipótese nula (H_0): as médias populacionais são iguais entre os níveis do fator B, ou seja, o fator B não exerce efeito sobre a variável resposta.

Hipótese alternativa (H_1): pelo menos uma média difere entre os níveis do fator B.

13.13.1.3 Interação entre os fatores

Hipótese nula (H_0): não existe interação entre os fatores A e B; o efeito de um fator é o mesmo em todos os níveis do outro fator.

Hipótese alternativa (H_1): existe interação entre os fatores A e B; o efeito de um fator depende do nível do outro fator.

```
anova2 <- aov(CP_cm ~ periodo + sexo, data = univ)
summary(anova2)
#O modelo ajustado acima não representa um modelo aditivo.
#Pressupõe-se que as duas variáveis fatoriais sejam independentes
  ⇨ entre si.
#Substitua o símbolo de soma (+) por um asterisco (*) caso você
  ⇨ considere
#que essas duas variáveis possam interagir, produzindo um efeito
  ⇨ sinérgico.
```

```
anova3 <- aov(CP_cm ~ periodo * sexo, data = univ)
summary(anova3)
```

```
require("dplyr")
summarise(
  group_by(univ, periodo, sexo),
  count = n(),
  mean = mean(CP_cm, na.rm = TRUE),
  sd = sd(CP_cm, na.rm = TRUE)
)
```

```
## `summarise()` has regrouped the output.
## i Summaries were computed grouped by periodo and sexo.
## i Output is grouped by periodo.
## i Use `summarise(.groups = "drop_last")` to silence this message.
## i Use `summarise(.by = c(periodo, sexo))` for per-operation grouping (`?dplyr::dplyr`)
```

```
# Comparações múltiplas pares: Tukey
TukeyHSD(anova3, which = "sexo")
TukeyHSD(anova3, which = "periodo")
TukeyHSD(anova3)

# Comparações múltiplas pares
library(multcomp)
summary(glht(anova2, linfct = mcp(sexo = "Tukey"))))

# T-test entre pares
pairwise.t.test(univ$CP_cm, univ$sexo,
  p.adjust.method = "BH")
```

```
##           Df Sum Sq Mean Sq F value Pr(>F)
```

13.13. ANOVA TWO-WAY, TESTE ENTRE GRUPOS E DOIS FATORES (FACTORIAL ANOVA)241

```
## periodo      1      231      231      6.29 0.0125 *
## sexo         2    10634     5317   144.80 <2e-16 ***
## Residuals    430   15789       37
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##              Df Sum Sq Mean Sq F value Pr(>F)
## periodo      1      231      231    6.287 0.0125 *
## sexo         2    10634     5317  144.714 <2e-16 ***
## periodo:sexo  2       64       32    0.874 0.4180
## Residuals    428   15725       37
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## # A tibble: 6 x 5
## # Groups:   periodo [2]
##   periodo sexo    count mean    sd
##   <fct>   <ord>    <int> <dbl> <dbl>
## 1 chuvoso MACHO     68  17.7  8.41
## 2 chuvoso FEMEA     38  14.9  6.78
## 3 chuvoso imaturo    60   7.18  6.25
## 4 seco    MACHO     54  20.0  7.70
## 5 seco    FEMEA     53  15.5  5.90
## 6 seco    imaturo   161   7.72  3.56
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = CP_cm ~ periodo * sexo, data = univ)
##
## $sexo
##              diff          lwr          upr      p adj
## FEMEA-MACHO    -3.214875   -5.189460 -1.240291 0.0004334
## imaturo-MACHO -10.698753 -12.306648 -9.090859 0.0000000
## imaturo-FEMEA  -7.483878  -9.259486 -5.708270 0.0000000
##
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = CP_cm ~ periodo * sexo, data = univ)
##
## $periodo
##              diff          lwr          upr      p adj
## seco-chuvoso  -1.501065  -2.677777 -0.3243541 0.0125349
##
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = CP_cm ~ periodo * sexo, data = univ)
```

```
##
## $periodo
##               diff            lwr            upr            p adj
## seco-chuvoso -1.501065 -2.677777 -0.3243541 0.0125349
##
## $sexo
##               diff            lwr            upr            p adj
## FEMEA-MACHO   -3.214875  -5.189460 -1.240291 0.0004334
## imaturo-MACHO -10.698753 -12.306648 -9.090859 0.0000000
## imaturo-FEMEA  -7.483878  -9.259486 -5.708270 0.0000000
##
## `$periodo:sexo`
##               diff            lwr            upr            p adj
## seco:MACHO-chuvoso:MACHO      2.3360566  -0.8267292  5.4988425 0.2817433
## chuvoso:FEMEA-chuvoso:MACHO  -2.7650155  -6.2793887  0.7493578 0.2163302
## seco:FEMEA-chuvoso:MACHO     -2.1223640  -5.3017372  1.0570091 0.3967891
## chuvoso:imaturo-chuvoso:MACHO -10.4876471 -13.5610260 -7.4142681 0.0000000
## seco:imaturo-chuvoso:MACHO    -9.9471502 -12.4566753 -7.4376250 0.0000000
## chuvoso:FEMEA-seco:MACHO      -5.1010721  -8.7751338 -1.4270104 0.0011585
## seco:FEMEA-seco:MACHO         -4.4584207  -7.8134652 -1.1033762 0.0022418
## chuvoso:imaturo-seco:MACHO    -12.8237037 -16.0784799 -9.5689275 0.0000000
## seco:imaturo-seco:MACHO      -12.2832068 -15.0118743 -9.5545393 0.0000000
## seco:FEMEA-chuvoso:FEMEA       0.6426514  -3.0456990  4.3310018 0.9962034
## chuvoso:imaturo-chuvoso:FEMEA -7.7226316 -11.3200158 -4.1252474 0.0000000
## seco:imaturo-chuvoso:FEMEA    -7.1821347 -10.3115486 -4.0527208 0.0000000
## chuvoso:imaturo-seco:FEMEA    -8.3652830 -11.6361800 -5.0943860 0.0000000
## seco:imaturo-seco:FEMEA       -7.8247861 -10.5726627 -5.0769095 0.0000000
## seco:imaturo-chuvoso:imaturo   0.5404969  -2.0840164  3.1650102 0.9917050
##
##
## Simultaneous Tests for General Linear Hypotheses
##
## Multiple Comparisons of Means: Tukey Contrasts
##
##
## Fit: aov(formula = CP_cm ~ periodo + sexo, data = univ)
##
## Linear Hypotheses:
##               Estimate Std. Error t value Pr(>|t|)
## FEMEA - MACHO == 0    -3.5823     0.8438  -4.246 7.4e-05 ***
## imaturo - MACHO == 0  -11.4502     0.7060 -16.219 < 1e-05 ***
## imaturo - FEMEA == 0  -7.8679     0.7601 -10.351 < 1e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## (Adjusted p values reported -- single-step method)
##
```

```
##
## Pairwise comparisons using t tests with pooled SD
##
## data: univ$CP_cm and univ$sexo
##
##          MACHO    FEMEA
## FEMEA    5.6e-05 -
## imaturo < 2e-16 < 2e-16
##
## P value adjustment method: BH
```

O QUE REPORTAR (anova2): A ANOVA de duas vias revelou efeito significativo do período do ano sobre o comprimento padrão dos indivíduos (F , = 6,29; p = 0,013), bem como efeito significativo do sexo (F , = 144,80; p < 0,001).

No caso da anova2, o modelo NÃO testou **interação** (período + sexo). Portanto, você NÃO pode afirmar se o efeito do sexo depende do período. Para testar a interação usamos período * sexo, na anova2.

O QUE REPORTAR (anova3): A ANOVA de duas vias revelou efeito significativo do período do ano (F , = 6,29; p = 0,013) e do sexo (F , = 144,71; p < 0,001), separadamente, sobre o comprimento padrão de *Cichla ocellaris*. Entretanto, não foi observada interação significativa entre período e sexo (F , = 0,87; p = 0,418).


13.13.2 Avaliações *a posteriori*


```
# Homogeneidade de variâncias
plot(anova3, 1)
library(car)
leveneTest(CP_cm ~ periodo*periodo, data = univ)
# Normalidade pelos resíduos (Q-Q plot)
plot(anova3, 2)
# Extraíndo os resíduos e rodando o Shapiro-Wilk neles
anova3_residuals <- residuals(object = anova3)
shapiro.test(x = anova3_residuals )

# ANOVA para desenhos não balanceados
library(car)
nb_anova <- aov(CP_cm ~ periodo * sexo, data = univ)
Anova(nb_anova, type = "III")
```

```
## Levene's Test for Homogeneity of Variance (center = median)
```

```
##           Df F value  Pr(>F)
## group      1  5.4279 0.02028 *
##           432
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Shapiro-Wilk normality test
##
## data:  anova3_residuals
## W = 0.92359, p-value = 4.653e-14
##
## Anova Table (Type III tests)
##
## Response: CP_cm
##           Sum Sq Df F value Pr(>F)
## (Intercept) 27390.0  1 745.5129 <2e-16 ***
## periodo      122.3  1   3.3281 0.0688 .
## sexo         3641.5  2  49.5584 <2e-16 ***
## periodo:sexo   64.2  2   0.8741 0.4180
## Residuals    15724.6 428
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```





13.14 Técnicas não-paramétricas

Os testes não-paramétricos devem ser usados quando os dados NÃO apresentam normalidade, há presença de outliers fortes, a distribuição é assimétrica e as variâncias são muito heterogêneas, ou seja, quando ocorrem violações importantes dos pressupostos de distribuição exigidos pelos testes paramétricos. Em geral, esses testes tendem a ser menos poderosos do que seus equivalentes paramétricos.

Além disso, alguns testes não-paramétricos, como o qui-quadrado que veremos a seguir, são apropriados para dados medidos em escalas que não são intervalares nem de razão.

A seguir apresento de forma resumida a implementação dos principais testes não-paramétricos no R.

- Teste qui-quadrado de aderência (*goodness of fit*)
- Teste qui-quadrado de independência ou associação
- Teste de Mann–Whitney (soma dos postos de Wilcoxon)
- Teste de postos sinalizados de Wilcoxon (*Wilcoxon signed-rank*)
- Teste de Kruskal–Wallis

- Teste de Friedman
- Correlação por postos de Spearman.

A verificação dos pressupostos para técnicas não paramétricas não é tão rigorosa quanto para os métodos paramétricos. Entretanto, alguns pressupostos gerais ainda devem ser considerados:

Amostragem aleatória: As observações devem ser obtidas por meio de amostragem aleatória da população de interesse. Forma e variabilidade semelhantes entre distribuições: Os grupos comparados devem apresentar distribuições com formatos e dispersões relativamente semelhantes. Independência das observações: Em delineamentos entre grupos (*between-subjects*), cada indivíduo deve pertencer a apenas um grupo, e os grupos não devem apresentar qualquer tipo de dependência entre si.

13.14.1 Testes qui-quadrado

Existem dois principais tipos de testes qui-quadrado:

O teste **qui-quadrado de aderência** (*goodness of fit*), utilizado para analisar uma única variável categórica e verificar se as frequências observadas diferem das frequências esperadas, e o **qui-quadrado de independência ou associação**, utilizado para avaliar a relação entre duas variáveis categóricas (COAKES; STEED, 2001; MCDONALD, 2014).

13.14.1.1 Pressupostos

Antes de realizar um teste qui-quadrado, três pressupostos devem ser avaliados:

Amostragem aleatória: As observações devem ser selecionadas aleatoriamente da população de todas as observações possíveis.

Independência das observações: Cada observação deve corresponder a um indivíduo diferente, sem que um mesmo indivíduo seja contabilizado mais de uma vez.

Tamanho das frequências esperadas: Quando o número de células da tabela é pequeno (especialmente inferior a dez) e o tamanho amostral total também é reduzido, a menor frequência esperada recomendada para aplicação do teste qui-quadrado é cinco. As frequências observadas, por outro lado, podem assumir qualquer valor, inclusive zero.

13.14.1.2 Exemplos

13.14.2 Teste qui-quadrado de aderência

O teste qui-quadrado de aderência é usado quando existe apenas uma variável categórica e queremos verificar se as frequências observadas seguem uma distribuição esperada. Nos dados de tucunaré, algumas perguntas que poderiam ser respondidas com esse teste são:

Razão sexual: A proporção de machos e fêmeas na população de tucunarés é de 1:1?

Hipótese nula: A proporção de machos e fêmeas é igual (50% para cada sexo).

Estágios de maturação: Os estágios de maturação ocorrem na mesma proporção?

Hipótese nula: Os indivíduos estão distribuídos igualmente entre os estágios de maturação.

Neste caso, o teste verifica se as frequências observadas diferem das frequências esperadas sob uma distribuição uniforme.

13.14.3 Teste qui-quadrado de independência ou associação

Se o teste qui-quadrado de aderência compara frequências observadas com frequências esperadas de uma variável categórica, no qui-quadrado de independência, duas variáveis categóricas, são comparadas, e o teste averigua a associação entre elas.

Pergunta: A proporção de machos e fêmeas varia entre os períodos seco e chuvoso?

Nesse caso seriam analisadas simultaneamente as variáveis sexo e período.

13.14.4 Demais testes não-paramétricos

13.14.4.1 Teste t não-paramétrico:

1. Wilcoxon para uma amostra
2. Wilcoxon pareado
3. Mann-Whitney (Wilcoxon rank-sum)

```
# Wilcoxon para uma amostra
wilcox_machos <- wilcox.test(
  machos,
  mu = 26.2,
  alternative = "two.sided",
  conf.int = TRUE,
  conf.level = 0.95
)
wilcox_machos
wilcox_femeas <- wilcox.test(
  femeas,
  mu = 21.4,
  alternative = "two.sided",
  conf.int = TRUE,
  conf.level = 0.95
)
wilcox_femeas

# Wilcoxon para grupos independentes
wilcox_sexo <- wilcox.test(
  machos,
  femeas,
  paired = FALSE,
  alternative = "two.sided",
  conf.int = TRUE,
  conf.level = 0.95
)
wilcox_sexo

# Wilcoxon para medidas repetidas
# Filtrar apenas fêmeas
femeas <- subset(univ, sexo == "FEMEA")
# Manter apenas IMATURO e MADURO
femeas2 <- subset(
  femeas,
  emg %in% c("IMATURO", "MADURO")
)
femeas2
# Teste de Mann-Whitney/Wilcoxon
wilcox.test(
  CP_cm ~ emg,
  data = femeas2,
  alternative = "two.sided",
  conf.int = TRUE
)
```

O comprimento total diferiu significativamente entre os estágios de maturação avaliados nas fêmeas (teste de Mann-Whitney/Wilcoxon: $W = 24$; $p < 0,001$). A diferença estimada entre os grupos foi de -16,60 cm (IC95% = -21,60 a -11,30).

13.14.4.2 ANOVA não-paramétrica:

1. Kruskal-Wallis
2. Scheirer-Ray-Hare test

```
univ$sexo <- factor(univ$sexo)
univ$periodo <- factor(univ$periodo)

anova1 <- kruskal.test(
  CP_cm ~ sexo,
  data = univ
)
anova1
#Pós-hoc para Kruskal-Wallis
#install.packages("FSA")
library(FSA)
dunnTest(
  CP_cm ~ sexo,
  data = univ,
  method = "bonferroni"
)

#install.packages("rcompanion")
library(rcompanion)
anova2 <- scheirerRayHare(
  CP_cm ~ periodo + sexo,
  data = univ
)
anova2

anova3 <- scheirerRayHare(
  CP_cm ~ periodo * sexo,
  data = univ
)
anova3

#Se sexo for significativo:
dunnTest(
  CP_cm ~ sexo,
  data = univ,
```

```
method = "bonferroni"
)
```

13.15 Material de apoio

13.16 TESTE SEUS CONHECIMENTOS



NOTA

Baixe esse arquivo de apoio (LISTA) e responda às questões. Se achar necessário, insira “chunks” de scripts do R, prints de tela ou cópias de gráficos, resultados ou mensagens de erro.

Apêndices

Sites para consulta

ANOVA

Two-way ANOVA

Correlação e regressão

Script limpo

Aqui apresento o script na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executá-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

```
# dev.off() #apaga os graficos, se houver algum
# rm(list=ls(all=TRUE)) #limpa a memória
# cat("\014") #limpa o console
# install.packages("openxlsx") #importa arquivos do excel
# install.packages("fdth")
# install.packages("ggpubr")
# install.packages("multcomp")
library(openxlsx)
```

```

# getwd()
# setwd("C:/Seu/Diretório/De/Trabalho")
library(openxlsx)
univ <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/tucuna.xlsx"
  ↪ ,
                                rowNames = T, colNames = T,
                                sheet = "tucuna")

head(univ, 10)
head(univ[, 1:5], 10)
# #View(univ)
# print(univ[1:5,1:5])
# univ
# str(univ)
# mode(univ)
# class(univ)
colnames(univ)
var <- univ$CP_cm
var_v <- as.vector(var)
range(var_v)
# #View(var)
# print(var_v)
# var_v
# sort(var_v)
# str(var_v)
# mode(var_v)
# class(var_v)
# range(var_v)
# length(var_v)
n <- length(var_v)
set.seed(666)
var_sub <- sample(var_v, size = n, replace = F) #atualize o valor
  ↪ de 'size=' se necessário
#OU
#var_sub <- univ[univ$CP_cm >0 & univ$CP_cm <20,] #data.frame
#var_sub <- var_v[var_v>=5 & var_v <=15] #vector
# var_sub <- var_trns
library(fdth)
range <- range(var_sub) #retorna o valor máximo e mínimo
#?range
#Regra de Sturges
k <- 1 + 3.3*log10(length(var_sub))
k <- ceiling(k) #ver as funções floor() e round()
h <- (max(var_sub) - min(var_sub))/k
h <- floor(h)

```

```

tf <- fdt(var_sub, start=3, end=40, h=4) #tabela de frequência
  ↪ manual
tfk <- fdt(var_sub, k=k) #atente para o uso de k
#?fdt
print(tf)
print(tfk)
stem(var_sub)
sort(var_sub)
library(moments)
skewness(var_sub)
kurtosis(var_sub)
par(mfrow = c(2,1)) #gráficos lado a lado
plot(tf) #distribuição de frequências
boxplot(var_sub, horizontal = TRUE,
        xlab="Class limits") #boxplot
par(mfrow = c(1,1)) #gráficos de volta ao normal
# Quartis
Q1 <- quantile(var_sub, 0.25)
Q3 <- quantile(var_sub, 0.75)
# Intervalo interquartil
IQR <- IQR(var_sub)
# Limites para outliers
lim_inf <- Q1 - 1.5 * IQR
lim_sup <- Q3 + 1.5 * IQR
# Valores considerados outliers
outliers <- var_sub[
  var_sub < lim_inf |
  var_sub > lim_sup
]
# Resultados
Q1
Q3
IQR
lim_inf
lim_sup
outliers
sort(outliers)
hist(var_sub, probability = TRUE) #adicionamos a função densidade
curve(dnorm(x, mean = mean(var_sub),
            sd = sd(var_sub)), #cria valores de x dentro do
  ↪ intervalo do gráfico
      col = "red",
      add = TRUE) #adiciona ao gráfico atual
summary(var_sub)
#?summary

```



```

sd(var_sub) #desvio padrão
var(var_sub) #variância
names(sort(table(var_sub), decreasing = TRUE))[1] #moda
limites <- range(var_sub)
par(mfrow=c(3,1))
qqnorm(var_sub,
       main = "Normal Q-Q Plot")
qqline(var_sub,
       col = "red",
       lwd = 1)
boxplot(var_sub, horizontal = TRUE, #atentar para o parâmetro
        ↪ `horizontal`
        main="Boxplot",
        ylim=limites,
        xlab="Class limits") #boxplot
hist(var_sub, probability = TRUE,
     xlim = limites,
     main = "Histogram") #adicionamos a função densidade
curve(dnorm(x, mean = mean(var_sub),
            sd = sd(var_sub)), #cria valores de x dentro do
        ↪ intervalo do gráfico
        col = "red",
        add = TRUE) #adiciona ao gráfico atual
par(mfrow=c(1,1))
library(ggpubr)
ggqqplot(var_sub)
shap <- shapiro.test(var_sub)
shap
p <- format(shap$p.value, scientific = FALSE)
p
##?str()
##?attributes()
ks.test(var_sub, "pnorm")
ks.test(var_sub,
        "pnorm",
        mean(var_sub),
        sd(var_sub))
#install.packages("nortest")
library(nortest)
lillie.test(var_sub)
# library(MASS)
# boxcox(lm(var_sub ~ 1))
# var_trns <- var_sub
# Levene
library(car)

```

```

univ$sexo <- as.factor(univ$sexo) #evita o Warning de "group
  ↪ coerced to factor"
fator <- factor(univ$sexo, levels = c("MACHO", "FEMEA",
  ↪ "imaturu"))
lev <- leveneTest(var_sub ~ fator, data = univ)
fator
lev
# Teste de Levene entre dois de tres (ou mais) grupos
machos_CP_cm <- na.omit(univ$CP_cm[univ$sexo == "MACHO"])
femeas_CP_cm <- na.omit(univ$CP_cm[univ$sexo == "FEMEA"])
imat_CP_cm <- na.omit(univ$CP_cm[univ$sexo == "imaturu"])
leveneTest(CP_cm ~ sexo, data = univ[univ$sexo %in% c("MACHO",
  ↪ "FEMEA"), ])
#Interpretação: Um valor de p maior que o nível de significância
  ↪ de 0.05 significa que, a hipótese nula é mantida e NÃO HÁ
  ↪ diferença significativa entre as variâncias.
univ$sexo <- factor(univ$sexo, levels = c("MACHO", "FEMEA",
  ↪ "imaturu"))
boxplot(CP_cm ~ fator, data = univ)
var_sub <- var_v
# Machos
machos <- subset(var_sub, univ$sexo == "MACHO")
machos
mean(machos)
t_machos <- t.test(
  machos,
  mu = 26.2
)
t_machos
# Fêmeas
femeas <- subset(var_sub, univ$sexo == "FEMEA")
femeas
mean(femeas)
t_femeas <- t.test(
  femeas,
  mu = 21.4
)
t_femeas
t.test(machos_CP_cm, femeas_CP_cm,
  alternative = c("two.sided"), #"two.sided", "less",
  ↪ "greater"
  mu = 0, paired = FALSE,
  var.equal = FALSE, #não assume homeg. de variâncias =
  ↪ Welch's t-test
  conf.level = 0.95)

```

```

# Filtrar apenas fêmeas
femeas <- subset(univ, sexo == "FEMEA")
# Manter apenas IMATURO e MADURO
femeas2 <- subset(
  femeas,
  emg %in% c("IMATURO", "EM MATURACAO")
)
t.test(
  CP_cm ~ emg,
  data = femeas2,
  alternative = "two.sided",
  var.equal = FALSE, # Welch t-test
  conf.level = 0.95
)
levels(univ$sexo)
univ$sexo <- ordered(univ$sexo,
  levels = c("MACHO", "FEMEA", "imaturo"))

library(dplyr)
summarise(
  group_by(univ, sexo),
  count = n(),
  mean = mean(CP_cm, na.rm = TRUE),
  sd = sd(CP_cm, na.rm = TRUE)
)

# Conjunto de gráficos
library("ggpubr")
ggboxplot(univ, x = "sexo", y = "CP_cm",
  color = "sexo", palette = c("#00AFBB", "#E7B800",
    ↪ "#FC4E07"),
  order = c("MACHO", "FEMEA", "imaturo"),
  ylab = "CP_cm", xlab = "Sexo")
ggline(univ, x = "sexo", y = "CP_cm",
  add = c("mean_se", "jitter"),
  order = c("MACHO", "FEMEA", "imaturo"),
  ylab = "Weight", xlab = "Treatment")
boxplot(CP_cm ~ sexo, data = univ,
  xlab = "Sexo", ylab = "CP_cm",
  frame = FALSE, col = c("#00AFBB", "#E7B800", "#FC4E07"))
library(gplots)
plotmeans(CP_cm ~ sexo, data = univ,
  xlab = "Sexo", ylab = "CP_cm",
  main="Média com 95% IC") #frame = FALSE
anova <- aov(CP_cm ~ sexo, data = univ)
summary(anova)
#Interpretação: Um valor de p MENOR que o nível de significância
↪ de 0.05 significa que,

```

```

#EXISTE diferença significativa entre as três grupos de médias.
TukeyHSD(anova)
library(multcomp)
summary(glht(anova, linfct = mcp(sexo = "Tukey"))))
# T-test entre pares
pairwise.t.test(univ$CP_cm, univ$sexo,
                 p.adjust.method = "BH")
#pairwise.t.test
## Homogeneidade de variâncias
plot(anova, 1) #valores numerados são outliers
library(car)
leveneTest(CP_cm ~ sexo, data = univ)
# ANOVA sem o pressuposto de igualdade de variâncias
oneway.test(CP_cm ~ sexo, data = univ)
# Testes pareados sem o pressuposto de igualdade de variâncias
pairwise.t.test(univ$CP_cm, univ$sexo,
                 p.adjust.method = "BH", pool.sd = FALSE)
# Normalidade pelos resíduos (Q-Q plot)
plot(anova, 2)
# Extraíndo os resíduos e rodando o Shapiro-Wilk neles
anova_residuais <- residuals(object = anova)
shapiro.test(x = anova_residuais)
# ANOVA não-paramétrica (Kruskal-Wallis)
kruskal.test(CP_cm ~ sexo, data = univ)
univ$sexo <- factor(univ$sexo,
                   labels = c("MACHO", "FEMEA", "imaturo"))
univ$periodo <- factor(univ$periodo,
                      labels = c("chuvoso", "seco"))

str(univ)
table(univ$sexo, univ$periodo)
library("ggpubr")
ggboxplot(univ, x = "sexo", y = "CP_cm", color = "periodo",
           palette = c("#00AFBB", "#E7B800"))
ggline(univ, x = "sexo", y = "CP_cm", color = "periodo",
        add = c("mean_se", "dotplot"),
        binwidth = 1,
        palette = c("#00AFBB", "#E7B800"))
boxplot(CP_cm ~ periodo * sexo, data=univ, frame = FALSE,
        col = c("#00AFBB", "#E7B800"), ylab="CP_cm")
# Gráfico das interações
interaction.plot(x.factor = univ$periodo, trace.factor =
  ↪ univ$sexo,
                 response = univ$CP_cm, fun = mean,
                 type = "b", legend = TRUE,
                 xlab = "Sexo", ylab="CP_cm",

```

```

                                pch=c(1,19), col = c("#00AFBB", "#E7B800"))
anova2 <- aov(CP_cm ~ periodo + sexo, data = univ)
summary(anova2)
#O modelo ajustado acima não representa um modelo aditivo.
#Pressupõe-se que as duas variáveis fatoriais sejam independentes
  ↳ entre si.
#Substitua o símbolo de soma (+) por um asterisco (*) caso você
  ↳ considera
#que essas duas variáveis possam interagir, produzindo um efeito
  ↳ sinérgico.
anova3 <- aov(CP_cm ~ periodo * sexo, data = univ)
summary(anova3)
require("dplyr")
summarise(
  group_by(univ, periodo, sexo),
  count = n(),
  mean = mean(CP_cm, na.rm = TRUE),
  sd = sd(CP_cm, na.rm = TRUE)
)
# Comparações múltiplas pares: Tukey
TukeyHSD(anova3, which = "sexo")
TukeyHSD(anova3, which = "periodo")
TukeyHSD(anova3)
# Comparações múltiplas pares
library(multcomp)
summary(glht(anova2, linfct = mcp(sexo = "Tukey"))))
# T-test entre pares
pairwise.t.test(univ$CP_cm, univ$sexo,
                p.adjust.method = "BH")
# Homogeneidade de variâncias
plot(anova3, 1)
library(car)
leveneTest(CP_cm ~ periodo*periodo, data = univ)
# Normalidade pelos resíduos (Q-Q plot)
plot(anova3, 2)
# Extraíndo os resíduos e rodando o Shapiro-Wilk neles
anova3_residuals <- residuals(object = anova3)
shapiro.test(x = anova3_residuals )
# ANOVA para desenhos não balanceados
library(car)
nb_anova <- aov(CP_cm ~ periodo * sexo, data = univ)
Anova(nb_anova, type = "III")
# # Wilcoxon para uma amostra
# wilcox_machos <- wilcox.test(
#   machos,

```

```

#   mu = 26.2,
#   alternative = "two.sided",
#   conf.int = TRUE,
#   conf.level = 0.95
# )
# wilcox_machos
# wilcox_femeas <- wilcox.test(
#   femeas,
#   mu = 21.4,
#   alternative = "two.sided",
#   conf.int = TRUE,
#   conf.level = 0.95
# )
# wilcox_femeas
#
# # Wilcoxon para grupos independentes
# wilcox_sexo <- wilcox.test(
#   machos,
#   femeas,
#   paired = FALSE,
#   alternative = "two.sided",
#   conf.int = TRUE,
#   conf.level = 0.95
# )
# wilcox_sexo
#
# # Wilcoxon para medidas repetidas
# # Filtrar apenas fêmeas
# femeas <- subset(univ, sexo == "FEMEA")
# # Manter apenas IMATURO e MADURO
# femeas2 <- subset(
#   femeas,
#   emg %in% c("IMATURO", "MADURO")
# )
# femeas2
# # Teste de Mann-Whitney/Wilcoxon
# wilcox.test(
#   CP_cm ~ emg,
#   data = femeas2,
#   alternative = "two.sided",
#   conf.int = TRUE
# )
# univ$sexo <- factor(univ$sexo)
# univ$periodo <- factor(univ$periodo)
#

```

```
# anova1 <- kruskal.test(  
#   CP_cm ~ sexo,  
#   data = univ  
# )  
# anova1  
# #Pós-hoc para Kruskal-Wallis  
# #install.packages("FSA")  
# library(FSA)  
# dunnTest(  
#   CP_cm ~ sexo,  
#   data = univ,  
#   method = "bonferroni"  
# )  
#  
# #install.packages("rcompanion")  
# library(rcompanion)  
# anova2 <- scheirerRayHare(  
#   CP_cm ~ periodo + sexo,  
#   data = univ  
# )  
# anova2  
#  
# anova3 <- scheirerRayHare(  
#   CP_cm ~ periodo * sexo,  
#   data = univ  
# )  
# anova3  
#  
# #Se sexo for significativo:  
# dunnTest(  
#   CP_cm ~ sexo,  
#   data = univ,  
#   method = "bonferroni"  
# )
```

Referências

Chapter 14

Correlação e Regressão

RESUMO

A estatística descritiva tem um papel importante a desempenhar na ciência. Quando problemas específicos são tratados na ciência, os dados precisam ser coletados, analisados e apresentados de forma concisa para que outros possam se beneficiar do que foi encontrado.

Apresentação

A estatística descritiva tem um papel importante a desempenhar na ciência. Quando problemas específicos são tratados na ciência, os dados precisam ser coletados, analisados e apresentados de forma concisa para que outros possam se beneficiar do que foi encontrado. Geralmente não é possível apresentar um conjunto de dados completo em uma publicação ou em um seminário e, mesmo que fosse, é improvável isso permitisse uma boa comunicação dos resultados da pesquisa. Em vez disso, os dados são geralmente resumidos como tabelas de frequência, histogramas e estatísticas descritivas que os leitores ou ouvintes podem assimilar prontamente, mas que ainda transmitem os elementos essenciais do conjunto de dados original. O principal objetivo do cálculo das estatísticas descritivas é transmitir informações essenciais contidas em um conjunto de dados da forma mais concisa e clara possível.

14.1 Sobre os dados

**ATENÇÃO**

Os links para baixar as planilhas necessárias para repetir esse tutorial podem ser encontrados na seção Arquivos disponíveis do Capítulo Bases de dados.

Ou, baixe aqui o arquivo `tucuna.xlsx`

14.2 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
options(scipen = 999) #sem notação científica, oposto de scipen =
↪ 0
```

Instalando os pacotes necessários para esse módulo

```
install.packages("openxlsx") #importa arquivos do excel
```

```
library(openxlsx)
```

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

14.3 Importando a planilha

Vamos importar a planilha de dados univariados `tucuna.xlsx`. Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações. Ajuste a segunda linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.

```
library(openxlsx)
univ <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/tucuna.xlsx"
  ↪ ,
  rowNames = T, colNames = T,
  sheet = "tucuna")
head(univ, 10)
head(univ[, 1:5], 10)
```

```
##      CT_cm PT_g CP_cm Ctubo_cm PC_g      p_PT Pest_g Cest_cm gr_est      ir_est
## TU001  32.4 468.8  27.2    39.8 458.9 2.111775    3.9    7.7      I 0.8319113
## TU002  33.4 520.0  28.8    14.3 507.4 2.423077    5.9   10.0      I 1.1346154
## TU003  27.3 301.5  23.8    13.0 283.4 6.003317   15.5   10.2     III 5.1409619
## TU004  13.2  28.2  11.0    16.5  27.7 1.773050    0.3    4.3      I 1.0638298
## TU005  14.3  38.9  11.9    15.5  37.7 3.084833    0.8    4.5     III 2.0565553
## TU006  22.7 431.7  20.5    24.2 418.7 3.011350    9.9    6.4     III 2.2932592
## TU007  23.2 544.0  19.2    25.0 520.1 4.393382    6.8    7.5      II 1.2500000
## TU008  13.5 161.6  11.5    17.5 157.0 2.846535    4.1    6.8      II 2.5371287
## TU009  24.6 200.5  20.5    25.7 195.9 2.294264    2.5    7.6      II 1.2468828
## TU010  19.4  86.7  16.0    18.3  84.5 2.537486    0.7    5.1      I 0.8073818
##      Pint_g Cint_cm gr_int      ir_int Pgon_g Cgon_cm      emg      ig
## TU001    4.8   38.3    II 1.0238908    1.2    7      IMATURO 0.25597270
## TU002    5.3   13.3    II 1.0192308    1.4    6.5      MADURO 0.26923077
## TU003    2.4   12.0    II 0.7960199    0.2    7.7 EM MATURACAO 0.06633499
## TU004    0.1   16.0    II 0.3546099    0.1    5      IMATURO 0.35460993
## TU005    0.3   15.0    II 0.7712082    0.1    3.2      IMATURO 0.25706941
## TU006    2.7   23.7    II 0.6254343    0.4    7.8 EM MATURACAO 0.09265694
## TU007    3.3   24.5    II 0.6066176   13.8    7.9      MADURO 2.53676471
## TU008    0.4   17.0      I 0.2475248    0.1    2.5      IMATURO 0.06188119
## TU009    2.0   25.3    II 0.9975062    0.1    6.5 EM MATURACAO 0.04987531
## TU010    1.4   17.7    II 1.6147636    0.1    6      IMATURO 0.11534025
##      mes periodo estação      sexo      sexo2
## TU001 ago chuvoso inverno    MACHO    FEMEA
## TU002 ago chuvoso inverno    MACHO    FEMEA
## TU003 ago chuvoso inverno    MACHO    FEMEA
## TU004 ago chuvoso inverno    MACHO    FEMEA
## TU005 ago chuvoso inverno    MACHO    FEMEA
## TU006 set chuvoso inverno    MACHO    FEMEA
## TU007 set chuvoso inverno    FEMEA    MACHO
## TU008 set chuvoso inverno imaturo imaturo
## TU009 set chuvoso inverno    MACHO    FEMEA
## TU010 set chuvoso inverno    MACHO    FEMEA
##      CT_cm PT_g CP_cm Ctubo_cm PC_g
## TU001  32.4 468.8  27.2    39.8 458.9
```

```
## TU002 33.4 520.0 28.8 14.3 507.4
## TU003 27.3 301.5 23.8 13.0 283.4
## TU004 13.2 28.2 11.0 16.5 27.7
## TU005 14.3 38.9 11.9 15.5 37.7
## TU006 22.7 431.7 20.5 24.2 418.7
## TU007 23.2 544.0 19.2 25.0 520.1
## TU008 13.5 161.6 11.5 17.5 157.0
## TU009 24.6 200.5 20.5 25.7 195.9
## TU010 19.4 86.7 16.0 18.3 84.5
```

Exibindo os dados importados (esses comando são “case-sensitive” `ignore.case(object)`).

```
#View(univ)
print(univ[1:5,1:5])
univ
str(univ)
mode(univ)
class(univ)
```

14.4 Correlação

O **coeficiente de correlação produto-momento de Pearson** (r) descreve a relação entre duas variáveis numéricas contínuas. A análise de correlação também pode ser aplicada entre variáveis categóricas binárias (coeficiente Phi) ou entre uma variável numérica contínua e uma variável categórica binária (correlação ponto-bisserial) (COAKES; STEED, 2001), porém essas abordagens não constituem o foco do presente texto.

Quando os pressupostos da correlação não podem ser adequadamente atendidos, utiliza-se uma alternativa não-paramétrica, a **correlação por postos de Spearman** (ρ).

Neste capítulo serão abordadas:

- Correlação simples bivariada (coeficiente de correlação produto-momento de Pearson)
- Correlação de Spearman (bivariada não-paramétrica)
- Correlação parcial

A correlação bivariada simples, refere-se à correlação entre duas variáveis contínuas e é a medida mais comum de relação linear.

Esse coeficiente possui valores possíveis variando de:

-1 a +1,

onde o valor indica a força da relação, enquanto o sinal indica a direção da relação.

A correlação parcial fornece uma medida única de associação linear entre duas variáveis, ajustando para os efeitos de uma ou mais variáveis adicionais.

As duas fórmulas medem aspectos diferentes da relação entre duas variáveis.

14.4.1 Coeficiente de correlação de Pearson (r)

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

onde:

- x_i e y_i : valores observados das variáveis (x) e (y) para a observação (i);
- $\bar{x}$ e $\bar{y}$: médias de (x) e (y);
- n : número de observações.

14.4.1.1 Como a fórmula funciona

Primeiro, calculamos o desvio de cada observação em relação à média:

$$x_i - \bar{x}$$

e

$$y_i - \bar{y}$$

Segundo, multiplicamos os desvios das duas variáveis:

$$(x_i - \bar{x})(y_i - \bar{y}).$$

Se **ambos os desvios forem positivos ou ambos negativos**, o produto é positivo, indicando associação positiva. Se **um desvio for positivo e o outro negativo**, o produto é negativo, indicando associação negativa.

Terceiro, somamos todos esses produtos, obtendo uma medida da covariação entre as variáveis.

Por último, dividimos pelo produto dos desvios padrão, padronizando o resultado para que ele varie entre -1 e 1.

Assim:

$r = 1$: correlação positiva perfeita; $r = -1$: correlação negativa perfeita; $r = 0$: ausência de correlação linear.

14.4.2 Coeficiente de determinação (r^2)

Na regressão linear simples, temos:

$$R^2 = \frac{\text{SQ} * \text{Regressão}}{\text{SQ} * \text{Total}}.$$

onde:

- SQ_{Total} : soma de quadrados total, representa toda a variação da variável resposta.

e

$$\text{SQ} * \text{Total} = \sum_{i=1}^n (y_i - \bar{y})^2$$

- $\text{SQ}_{\text{Regressão}}$: soma de quadrados explicada pelo modelo.

Finalmente,

$$\text{SQ} * \text{Regressão} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

onde $\hat{y}_i$ é o valor previsto pela regressão.

14.4.2.1 Como a fórmula funciona

O coeficiente de determinação calcula a fração da variação total de (y) que é explicada pela regressão.

Por exemplo, se

$$\text{SQ}_{\text{Regressão}} = 80 \quad \text{SQ}_{\text{Total}} = 100,$$

então

$$r^2 = \frac{80}{100} = 0.80.$$

Isso significa que **80% da variação da variável resposta é explicada pelo modelo**, enquanto os 20% restantes são atribuídos a outros fatores ou ao erro aleatório.

14.4.3 Relação entre (r) e (R^2)

Na regressão linear simples existe apenas uma variável explicativa, e vale a relação

$$r^2 = R^2$$

Assim, se

$$r = 0.90,$$

então

$$R^2 = 0.90^2 = 0.81.$$

Ou seja, a correlação mede a **força e a direção** da relação linear entre duas variáveis, enquanto o coeficiente de determinação mede **quanto da variação da variável resposta é explicada pelo modelo de regressão**.

14.4.3.1 Não confundir com resíduos

No desvio em relação à média

$$x_i - \bar{x}$$

é o **desvio da observação em relação à média** da variável (x) .

Ele indica quanto um valor observado está acima ou abaixo da média e é utilizado no cálculo da variância, covariância e da correlação de Pearson.

Na regressão, o resíduo é

$$e_i = y_i - \hat{y}_i,$$

onde:

- y_i : valor observado;
- $\hat{y}_i$: valor previsto pelo modelo.

O resíduo mede o **erro de predição** da regressão, ou seja, a distância vertical entre o ponto observado e a reta ajustada.

14.4.3.2 Pressupostos

A análise de correlação possui vários pressupostos:

1. Pares relacionados: Os dados devem ser coletados em pares relacionados. Ou seja, se houver um escore na variável x , deve haver também um escore correspondente na variável y para o mesmo participante.
2. Escala de medida: Os dados devem possuir natureza intervalar ou de razão.
3. Normalidade: Os escores de cada variável devem apresentar distribuição normal.
4. **Linearidade:** A relação entre as duas variáveis deve ser linear.
5. Homoscedasticidade: A variabilidade dos escores de uma variável deve ser aproximadamente a mesma em todos os valores da outra variável. Ou seja, refere-se à forma como os escores se distribuem uniformemente em torno da linha de regressão.

Os pressupostos 1 e 2 dependem do delineamento da pesquisa.

O pressuposto 3 pode ser avaliado utilizando os procedimentos descritos nos capítulos anteriores.

Os pressupostos 4 e 5 podem ser avaliados examinando gráficos de dispersão (*scatterplots*) das variáveis.

14.4.3.3 Exemplos

14.5 Correlação simples (bivariada)

No caso dos dados de dinâmica populacional do tucunaré (*Cichla ocellaris*), pode-se investigar a relação entre duas variáveis biométricas contínuas, como o comprimento padrão (CP_cm) e o comprimento total (CT_cm).

Suspeita-se que exista uma relação linear positiva entre essas variáveis, uma vez que indivíduos com maior comprimento padrão tendem também a apresentar maior comprimento total.

Assim, pode-se utilizar a correlação produto-momento de Pearson para responder à seguinte questão:

1. Existe correlação significativa entre o comprimento padrão e o comprimento total dos indivíduos?

Hipótese nula (H_0): não existe correlação linear entre as duas variáveis na população.

Hipótese alternativa (H_1): existe correlação linear entre as duas variáveis na população.

Nesse caso, utiliza-se:


```
df<-data.frame(univ$CP_cm, univ$CT_cm, univ$PT_g)
#df
plot(df[,1:2])

# Teste de Pearson
cor(df, method="pearson")
cor.test(univ$CP_cm, univ$CT_cm,
         method = "pearson") #"pearson", "kendall", "spearman"

# Teste de Spearman
cor(df[,1:2], method="spearman")
cor.test(univ$CT_cm, univ$CP_cm,
         method="spearman")
```

```
##          univ.CP_cm univ.CT_cm univ.PT_g
## univ.CP_cm  1.0000000  0.9990120  0.9039503
## univ.CT_cm  0.9990120  1.0000000  0.9057485
## univ.PT_g   0.9039503  0.9057485  1.0000000
##
## Pearson's product-moment correlation
##
## data:  univ$CP_cm and univ$CT_cm
## t = 467.22, df = 432, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.9988068 0.9991819
## sample estimates:
##      cor
## 0.999012
##
##          univ.CP_cm univ.CT_cm
## univ.CP_cm  1.0000000  0.9976789
## univ.CT_cm  0.9976789  1.0000000
##
## Spearman's rank correlation rho
##
## data:  univ$CT_cm and univ$CP_cm
## S = 31624, p-value < 2.2e-16
```

```
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##      rho
## 0.9976789
```



Interpretação:

Os resultados da **correlação de Pearson** (`cor.test(x, y, method = "pearson")`) revelam a **estatística do teste**, $t = 467.22$ (para 432 **graus de liberdade**), indicando forte evidência contra a hipótese nula, e o **valor de p**, < 0.001 , indicando que a correlação é estatisticamente significativa. Também é mostrado o **coeficiente de correlação** (r) de 0.999 e o intervalo de confiança (95%) de 0.9988 0.9992.

Em uma correlação simples (bivariada), não existe uma distinção estatística obrigatória entre variável explicativa (independente) e variável resposta (dependente). A correlação mede apenas a força e a direção da associação entre duas variáveis (sem assumir causalidade), e o coeficiente de correlação é o mesmo independentemente da ordem das variáveis.

Entretanto, quando se faz um gráfico de dispersão, por convenção:

Eixo x (horizontal): variável explicativa (independente), quando houver uma hipótese causal;

Eixo y (vertical): variável resposta (dependente).

Por exemplo, nos dados de tucunaré, como nosso objetivo é verificar se o comprimento padrão (CP) explica o comprimento total (CT), temos que:

x: comprimento padrão (CP_cm)

y: comprimento total (CT_cm)

Se pretendemos ajustar uma **regressão linear**, a variável explicativa deve ser colocada no eixo x e a variável resposta no eixo y, pois a reta de regressão depende dessa escolha (veremos isso a seguir).

Na **correlação de Spearman**, os dados são transformados em *ranks* (postos).

valor	rank
10	1
12	2
12	2
15	4

Quando existem valores repetidos, no exemplo acima, 12 e 12, ocorrem empates (*ties*). O teste exato de Spearman assume ranks únicos, sem valores repetidos. Como nossos dados possuem medidas repetidas (muito comum em biometria), o R usa uma aproximação assintótica (removendo os empates), em vez do cálculo exato. Isso não invalida o teste, em caso de amostras grandes, mas significa uma limitação do teste de correlação não-paramétrico.

O QUE REPORTAR (Pearson): Foi observada correlação linear positiva extremamente forte entre o comprimento padrão (CP_cm) e o comprimento total (CT_cm) dos indivíduos analisados (correlação de Pearson: $r = 0,957$; $p < 0,001$; $n = 433$).

O QUE REPORTAR (spearman): Foi observada correlação positiva significativa entre comprimento padrão (CP_cm) e o comprimento total (CT_cm) (Spearman: $\rho = 0,998$; $p < 0,001$).

14.6 Correlação parcial

Além disso, pode-se avaliar se essa relação permanece significativa quando o efeito de uma variável adicional, como o peso corporal (PT_g) ou o período do ano (`periodo`), é controlada na análise. Nesse caso, a correlação parcial remove a parte da correlação explicada pelo peso. Ou seja, a correlação parcial faz a mesma coisa da bivariada, mas controla o efeito de uma terceira variável.

Espera-se que peixes mais pesados tendem a aumentar em ambos os comprimentos (CP e CT). Podemos, portanto, correlacionar CP_cm e CT_cm, e controlar pelo peso, para responder a seguinte questão:

1. Comprimento padrão e comprimento total ainda se correlacionam independentemente do peso?

Hipótese nula (H_0): não existe correlação linear entre as duas variáveis na população, após controlar o efeito de uma terceira variável.

Hipótese alternativa (H_1): existe correlação linear entre as duas variáveis na população, após controlar o efeito de uma terceira variável.

```
cor(
  univ[, c("CP_cm", "CT_cm", "PT_g")],
  use = "complete.obs"
)
#install.packages("ppcor")
library(ppcor)
pcor.test(
  univ$CP_cm,
  univ$CT_cm,
  univ$PT_g
)

##           CP_cm      CT_cm      PT_g
## CP_cm 1.0000000 0.9990120 0.9039503
## CT_cm 0.9990120 1.0000000 0.9057485
## PT_g  0.9039503 0.9057485 1.0000000
##      estimate p.value statistic   n gp Method
## 1 0.9945978      0 198.9168 434 1 pearson
```

Interpretação:

O resultado da **correlação parcial** (`pcor.test()`) de Pearson, isto é, a correlação entre CP_cm e CT_cm após controlar o efeito de uma terceira variável (PT_g), demonstra um **coeficiente de correlação parcial** r_p de 0.9946 (*estimate*), mesmo após remover o efeito do peso (PT_g). A **estatística t** (*statistic*) de 198.92 utilizada para testar a significância da correlação parcial e o **número de observações** (n) também são apresentados. O **número de variáveis controladas** (neste caso, apenas PT_g), é demonstrado em `gp = 1`. O **valor de p** ($<0,001$) é extremamente pequeno. Finalmente, o **método utilizado** (correlação parcial de Pearson) é apresentado.

Tivemos uma correlação parcial extremamente forte e positiva ($r = 0.955$) entre CP_cm e CT_cm, mesmo após remover o efeito do PT_g (peso total) ($p < 0,001$). Isso indica que a associação entre comprimento padrão e comprimento total permanece muito forte independentemente do peso corporal.

O QUE REPORTAR: Análise de correlação parcial revelou associação positiva extremamente forte entre comprimento padrão e comprimento total, mesmo após o controle do peso corporal ($r = 0,955$; $p < 0,001$).

14.7 Regressão simples

Nesse texto, optei por tratar correlação e regressão linear como diferentes aspectos de uma mesma análise (seguindo a visão de MCDONALD (2014)), apesar de que também podemos considerar correlação e regressão linear como um único teste estatístico (CLEOPHAS; ZWINDERMAN, 2016; COAKES; STEED, 2001).

A principal diferença entre correlação e regressão é que, na correlação, ambas as variáveis medidas são amostradas aleatoriamente a partir de uma população, enquanto na regressão os valores da variável independente (x) costumam ser escolhidos ou controlados pelo pesquisador (MCDONALD, 2014).

No nosso exemplo, o pesquisador interessado na biometria de *Cichla ocellaris* deseja compreender a relação entre o comprimento padrão e o comprimento total dos indivíduos. Em estudos pesqueiros, muitas vezes apenas parte do exemplar é obtida, seja devido ao processamento do pescado, danos durante a captura ou coleta incompleta em campo (ROYCE, 1942). Nesses casos, torna-se útil estimar o comprimento total do peixe a partir do comprimento padrão.

Já fizemos a avaliação da correlação entre as variáveis de interesse. Agora faremos uma análise de regressão linear entre essas variáveis, para que possamos, usando o modelo ajustado da regressão, prever o comprimento total a partir do comprimento padrão.

14.7.0.1 Variáveis independentes e dependentes

Quando se testa uma relação de causa e efeito, a variável que supostamente causa a relação é chamada de variável **independente**, e geralmente é representada no eixo x. Já a variável que representa o efeito é denominada **variável dependente**, e é representada no eixo y.

Em alguns experimentos, o pesquisador **define os valores da variável independente**. Por exemplo, se o interesse for avaliar o efeito da temperatura sobre a taxa de vocalização de anuros, os animais podem ser mantidos em câmaras com temperaturas controladas de 10°C, 15°C, 20°C (MCDONALD, 2014), e essa seria a variável independente. Uma outra possibilidade é quando, **ambas as variáveis apresentam variação natural**, mas a relação causal ocorre apenas em uma direção. Por exemplo, ao medir temperatura do ar e taxa de vocalização de sapos em diferentes noites, ambas variam naturalmente. Entretanto, caso exista relação causal, espera-se que a temperatura (**independente**) afete a vocalização (**dependente**), e não o contrário, já que a vocalização dos sapos não altera a temperatura do ambiente (MCDONALD, 2014).

Um último caso ocorre quando desejamos prever uma variável (**dependente**) a partir de uma segunda variável (**independente**). Em estudos biométricos como o em *Cichla ocellaris*, podemos investigar a relação entre comprimento padrão (CP_cm) e comprimento total (CT_cm). Nesse caso, podemos considerar comprimento padrão como variável independente, pois desejamos prever comprimento total a partir do comprimento padrão.

No R, isso é implementando usando a função `lm()`

```
lm(y ~ x, data = dados)
```

onde:

o que está à esquerda de `~` é a variável dependente (resposta, y);

o que está à direita de `~` é a variável independente (explicativa, preditora, x).

14.7.0.2 Exemplo

No script a seguir, seguimos as seguintes etapas:

1. Explorar relações biométricas
2. Calcular correlações simples
3. Teste de significância
4. Ajuste da regressão linear
5. Verificação de pressupostos
6. Realização da ANOVA do modelo da regressão
7. Aplicação de correção robusta

```

df<-data.frame(univ$CP_cm, univ$CT_cm, univ$PT_g)
#df
plot(df[,1:2],
      xlim = c(0, 40),
      ylim = c(0, 50))
#abline(modelo, col = "red", lwd = 2)

# Teste de Pearson
cor(df, method="pearson")
cor.test(univ$CP_cm, univ$CT_cm,
         method = "pearson")
# Teste de Spearman
cor(df[,1:2], method="spearman")
cor.test(univ$CP_cm, univ$CT_cm,
         method="spearman")

modelo <- lm(CT_cm ~ CP_cm, data=univ)
summary(modelo)

```


```

##              univ.CP_cm univ.CT_cm univ.PT_g
## univ.CP_cm   1.0000000   0.9990120 0.9039503
## univ.CT_cm   0.9990120   1.0000000 0.9057485
## univ.PT_g    0.9039503   0.9057485 1.0000000
##
## Pearson's product-moment correlation
##
## data:  univ$CP_cm and univ$CT_cm
## t = 467.22, df = 432, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.9988068 0.9991819
## sample estimates:
##      cor
## 0.999012
##
##              univ.CP_cm univ.CT_cm
## univ.CP_cm   1.0000000   0.9976789
## univ.CT_cm   0.9976789   1.0000000
##
## Spearman's rank correlation rho
##
## data:  univ$CP_cm and univ$CT_cm
## S = 31624, p-value < 2.2e-16
## alternative hypothesis: true rho is not equal to 0

```



```
## sample estimates:
##      rho
## 0.9976789
##
## Call:
## lm(formula = CT_cm ~ CP_cm, data = univ)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.3777 -0.1281 -0.0147  0.1260  3.0354
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.147883   0.037700   3.923 0.000102 ***
## CP_cm       1.206566   0.002582 467.221 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4216 on 432 degrees of freedom
## Multiple R-squared:  0.998, Adjusted R-squared:  0.998
## F-statistic: 2.183e+05 on 1 and 432 DF, p-value: < 2.2e-16
```



No caso do nosso exemplo, o modelo de regressão linear simples pode ser representado por:

$$CT_{cm} = \beta_0 + \beta_1 CP_{cm} + \varepsilon$$

onde:

- CT_{cm} = comprimento total (variável resposta ou dependente);
- CP_{cm} = comprimento padrão (variável preditora ou independente);

- β_0 = intercepto do modelo;
- β_1 = coeficiente angular da regressão;
- ε = erro aleatório associado ao modelo.

Esse modelo busca prever o comprimento total dos indivíduos a partir do comprimento padrão.

No R, o modelo é ajustado utilizando a função:

```
modelo <- lm(CT_cm ~ CP_cm, data = univ)
```

Interpretação:

A função `summary()` fornece todas as informações necessárias para interpretar os resultados da regressão linear.

A fórmula utilizada dentro da função `lm()` indica que `CT_cm` é a variável resposta (dependente) e `CP_cm` é a variável explicativa (independente). A **equação do modelo ajustado** seria:

$$CT_{cm} = 0.147 + 1.206 \times CP_{cm}$$

onde:

- 0,147 é o intercepto (β_0)
- 1,206 é o coeficiente angular (β_1)

O **intercept** ($\beta_0 = 0.147$) representa o valor esperado de `CT_cm` quando `CP_cm`=0 (geralmente sem interpretação biológica, mas importante em Modelos Lineares Generalizados). O **coeficiente angular** ($\beta_1 = 1,206$) indica que, em média, para cada aumento de 1 cm em `CP_cm`, espera-se aumento aproximado de 1,206 cm em `CT_cm`. O **erro padrão do coeficiente angular**, que mede a precisão da estimativa de β_1 , foi de 0,00258.

Os resultados também mostram que O coeficiente de `CP_cm` é altamente significativo ($t=467.22$, $p<0.001$), indicando que o comprimento padrão é um forte preditor do comprimento total. Embora o modelo apresente um erro médio de aproximadamente 0,42 cm na predição do comprimento total, como mostrado no **erro padrão residual** de 0.4216. Os **coeficientes de determinação** (múltiplos e ajustados) de 0.998, indicam que o cerca de 99,8% da variação no comprimento total.

Finalmente, o **teste F** de $2.183e+05$ e seu **valor de p** < 0.001 , testam a hipótese de que o modelo não explica a variável resposta:

H_0 : Hipótese nula: $\beta_1 = 0$, ou seja, a variável explicativa não exerce efeito sobre a variável resposta (o modelo não possui poder preditivo).

H_1 : Hipótese alternativa: $\beta_1 \neq 0$, ou seja, a variável explicativa exerce efeito sobre a variável resposta (o modelo possui poder preditivo).

Como $p < 0.001$, rejeita-se H_0 e aceita-se H_1 , o modelo de regressão é estatisticamente significativo e tem poder preditivo para o comprimento total.

O QUE REPORTAR: A regressão linear simples revelou que o comprimento padrão foi um preditor significativo do comprimento total ($\beta = 1.207 \pm 0.003$, $t_{(432)} = 467.22$, $p < 0.001$). O modelo apresentou excelente ajuste aos dados ($r^2 = 0.998$; $F_{(1,432)} = 218300$, $p < 0.001$), explicando aproximadamente 99,8% da variação no comprimento total. A equação ajustada foi $CT_{cm} = 0.148 + 1.207 \times CP_{cm}$.

Na sequência avaliamos homogeneidade de variâncias. Para o caso de heterogeneidade de variâncias devemos usar a **correção robusta de White (HC3)**. Antes disso realizamos uma ANOVA da regressão, para testar se o comprimento padrão explica uma parcela significativa da variação no comprimento total. A diferença entre `anova()` e `Anova()` só aparece em modelos com dois ou mais preditores. `Anova(modelo, white.adjust = TRUE)` calcula o mesmo teste, mas utilizando a correção robusta de White (HC3) para os erros padrão. Essa correção é recomendada quando há heterocedasticidade (variância não constante dos resíduos).


```
par(mfrow=c(2,2))
plot(modelo)
par(mfrow=c(1,1))

anova(modelo)
library(car)
Anova(modelo)
Anova(modelo, white.adjust=TRUE)
```

```
## Coefficient covariances computed by hccm()


## Analysis of Variance Table
##
## Response: CT_cm
##           Df Sum Sq Mean Sq F value    Pr(>F)
## CP_cm      1  38802    38802  218295 < 2.2e-16 ***
## Residuals 432      77         0
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## Anova Table (Type II tests)
##
## Response: CT_cm
##           Sum Sq  Df F value    Pr(>F)
```

```
## CP_cm      38802    1 218295 < 2.2e-16 ***
## Residuals    77 432
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## Analysis of Deviance Table (Type II tests)
##
## Response: CT_cm
##           Df      F    Pr(>F)
## CP_cm      1 75315 < 2.2e-16 ***
## Residuals 432
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Em um novo exemplo, podemos analisar comprimento total e peso corporal em peixes. Em estudos de relação peso-comprimento normalmente considera-se comprimento como variável independente e peso como variável dependente.

```
df<-data.frame(univ$CP_cm, univ$CT_cm, univ$PT_g)
#df
plot(df[,c(2,3)])
#abline(modelo, col = "red", lwd = 2)
```



14.8 Gráfico de dispersão (*scatterplot*)

Um gráfico de dispersão mostra a relação entre duas variáveis quantitativas, representando cada observação como um ponto no plano cartesiano. Faremos isso usando o pacote `ggplot2`.

14.8.1 O que é ggplot2?

O `ggplot2` é um pacote de visualização de dados para R, que permite definir visualmente o que se quer mostrar através de camadas adicionadas usando o símbolo `+`, usando os seguintes componentes principais:

- a) Dados (`data`): O ponto de partida para qualquer gráfico é um data frame — uma tabela com linhas (observações) e colunas (variáveis).
- b) Mapeamento estético (`aesthetics/aes`): Define como variáveis do dataset mapeiam para propriedades visuais como posição (x, y), cor (color), tamanho (size) ou forma (shape), entre outros:
 - `x`: eixo horizontal
 - `y`: eixo vertical
 - `color`: cor
 - `size`: tamanho
 - `shape`: forma
 - `fill`: preenchimento
- c) Representações geométricas (`geoms`): Cada elemento visual do gráfico é adicionado como uma camada. Por exemplo:
 - `geom_point()` para gráficos de dispersão
 - `geom_line()` para linhas
 - `geom_bar()` para gráficos de barras

A estrutura geral de um gráfico em `ggplot2` é:

```
ggplot(data = dados,
       mapping = aes(x = var1,
                     y = var2)) +
  geom_tipo()
?ggplot
```

Esse modelo modular torna possível compor gráficos simples ou complexos com clareza.


```
library(ggplot2)
colnames(univ)
dados <- subset(univ,
                sexo != "imaturo" & Pgon_g>0.2 & Pgon_g<10) #ou
↪ `filter` do dplyr
```



```
table(dados$sexo)
unique(dados$sexo)
ggplot(dados, aes(x = CP_cm,
                  y = Pgon_g,
                  color = sexo)) +
  geom_point() +
  geom_smooth(method = "lm",
             se = FALSE)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## [1] "CT_cm" "PT_g" "CP_cm" "Ctubo_cm" "PC_g" "p_PT"
## [7] "Pest_g" "Cest_cm" "gr_est" "ir_est" "Pint_g" "Cint_cm"
## [13] "gr_int" "ir_int" "Pgon_g" "Cgon_cm" "emg" "ig"
## [19] "mes" "periodo" "estação" "sexo" "sexo2"
##
## FEMEA MACHO
## 21 39
## [1] "MACHO" "FEMEA"
```



O gráfico acima ilustra uma regressão linear simples entre CP_cm e Pgon_g, com ajuste separado por **sexo**. As diferenças entre as retas e a dispersão dos pontos sugerem que o peso gonadal não depende apenas do comprimento corporal, mas

também de outras características do indivíduo. Por isso, podemos testar como uma análise seguinte a **regressão múltipla**, incorporando simultaneamente `CP_cm`, `sexo` e outras possíveis covariáveis relevantes para estimar efeitos parciais e testar interações.

Assim, embora a regressão simples seja útil para descrever a associação bivariada, ela não controla simultaneamente múltiplas fontes de variação.

Apêndices

Sites para consulta

<https://stackoverflow.com/questions/31741742/how-to-identify-the-distribution-of-the-given-data-using-r>

<https://stats.stackexchange.com/questions/132652/how-to-determine-which-distribution-fits-my-data-best>

<https://www.r-bloggers.com/2015/11/correlation-and-linear-regression/>

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executá-lo. Lembre de remover os `#` ou `##` caso necessite executar essas linhas.

Referências

Chapter 15

Regressão múltipla

RESUMO

A estatística descritiva tem um papel importante a desempenhar na ciência. Quando problemas específicos são tratados na ciência, os dados precisam ser coletados, analisados e apresentados de forma concisa para que outros possam se beneficiar do que foi encontrado.

Apresentação

A regressão múltipla é uma extensão da correlação bivariada e tem como objetivo **predizer uma variável dependente a partir de duas ou mais variáveis independentes**. Esse método é amplamente utilizado quando as variáveis preditoras apresentam associação entre si e também com a variável resposta. As variáveis independentes podem ser contínuas ou categóricas, embora variáveis categóricas devam ser previamente convertidas em variáveis *dummy* para serem incluídas no modelo. Em contraste, a variável dependente deve ser medida em uma escala contínua. Se a variável dependente não for contínua, então a análise discriminante é apropriada (COAKES; STEED, 2001).

O resultado da regressão é uma equação que representa a melhor previsão de uma variável dependente a partir de várias variáveis independentes.

Para isso, existem três principais modelos de regressão. **Regressão múltipla simultânea** ou padrão, **regressão múltipla hierárquica** e a **regressão múltipla *stepwise*** (“passo-a-passo”). Esses modelos diferem em dois aspectos: primeiro, na forma como tratam a variabilidade compartilhada decorrente da correlação entre as variáveis independentes; e, segundo, na ordem de entrada das variáveis independentes na equação.

No **modelo padrão ou simultâneo**, todas as variáveis independentes entram na equação de regressão ao mesmo tempo, porque se deseja examinar a relação entre todo o conjunto de preditores e a variável dependente. Na **regressão múltipla hierárquica**, a ordem de entrada das variáveis é definida previamente, pelo pesquisador, com base em conhecimento teórico ou hipóteses biológicas. Já na **regressão múltipla *stepwise***, a inclusão ou remoção das variáveis ocorre automaticamente a partir de critérios estatísticos, buscando selecionar os melhores preditores do modelo, gerados pelo procedimento *stepwise*. A regressão *stepwise* pode ainda ser, *forward* (seleção progressiva), *backward* (seleção regressiva) ou *mixed* (uma combinação de ambos), dependendo da ordem na qual as variáveis são incorporadas. Veremos mais sobre isso a seguir.

Na seleção *forward*, os preditores são adicionados ao modelo um de cada vez. A ordem de entrada e a permanência de cada preditor no modelo são determinadas com base em dois critérios: se o teste F excede um valor crítico preestabelecido e se é atingido um nível crítico de significância.

Na seleção *backward*, o modelo é inicialmente ajustado com todas as variáveis independentes e, em seguida, aquelas com menor contribuição são removidas gradualmente, com base no fato de seu valor parcial de F ser inferior a um valor crítico. Além disso, deve ser atendido o critério padrão de significância para remoção.

A seleção *stepwise* combina os procedimentos *forward* e *backward*, permitindo que variáveis previamente incluídas no modelo sejam posteriormente removidas, caso deixem de atender aos critérios estatísticos estabelecidos.

A escolha do método depende, em grande parte, dos objetivos do pesquisador, e a aplicação da regressão múltipla exige o atendimento de alguns pressupostos estatísticos (COAKES; STEED, 2001).

15.0.0.1 Pressupostos

Uma série de pressupostos sustenta o uso da regressão:

1. **Razão entre casos e variáveis independentes:** O número de casos necessários depende do tipo de modelo de regressão a ser utilizado. Para regressão padrão ou hierárquica, idealmente deve-se ter vinte vezes mais casos do que preditores, enquanto ainda mais casos são necessários para regressão *stepwise*. O requisito mínimo é ter pelo menos cinco vezes mais casos do que variáveis independentes (COAKES; STEED, 2001).
2. **Outliers:** Casos extremos têm impacto considerável na solução de regressão e devem ser excluídos ou modificados para reduzir sua influência. Outliers univariados podem ser detectados durante a triagem de dados, conforme descrito na seção Gráficos de histograma e boxplot. Outliers multivariados podem ser detectados usando métodos estatísticos, como a

distância de Mahalanobis, e métodos gráficos, como gráficos de dispersão dos resíduos (isso é abordado na **PARTE V** Análise de outliers baseada no desvio padrão do centróide deste livro). A decisão de remover outliers do conjunto de dados deve ser tomada com cuidado, porque sua exclusão frequentemente resulta na geração de outros casos discrepantes.

3. **Multicolinearidade e singularidade:** *Multicolinearidade* refere-se a altas correlações entre as variáveis independentes, enquanto *singularidade* ocorre quando existem correlações perfeitas entre variáveis independentes. Esses problemas afetam a forma como se interpretam quaisquer relações entre os preditores (VIs) e a variável dependente, e podem ser detectados examinando-se a matriz de correlação, as correlações múltiplas ao quadrado e as tolerâncias. A maioria dos programas computacionais possui valores padrão para multicolinearidade. É importante não admitir-mos variáveis que representem esse tipo de problema.
4. Normalidade, linearidade, homocedasticidade e independência dos resíduos: Um exame dos gráficos de dispersão dos resíduos permite testar os pressupostos acima. Assume-se que as diferenças entre os escores observados e previstos da variável dependente sejam normalmente distribuídas. Além disso, assume-se que os resíduos tenham uma relação linear com os escores previstos da variável dependente e que a variância dos resíduos seja a mesma para todos os escores previstos. Desvios leves da linearidade não são graves. Desvios moderados a extremos podem levar a uma séria subestimação de uma relação.

O pressuposto 1 relaciona-se ao delineamento da pesquisa. Os pressupostos 2, 3 e 4 são avaliados por meio da análise de regressão.

No contexto da biometria de *Cichla ocellaris*, a regressão múltipla pode ser utilizada para investigar quais variáveis morfométricas melhor predizem o peso corporal dos indivíduos. Nesse caso, o peso total (PT_g) pode ser utilizado como variável dependente, enquanto variáveis como comprimento total (CT_cm), comprimento padrão (CP_cm) podem atuar como variáveis independentes. Assim, o modelo busca explicar a variação do peso corporal a partir de múltiplos atributos biométricos dos indivíduos analisados.

Com esse tipo de análise, é possível responder questões como:

- (1) Qual a contribuição conjunta das variáveis biométricas para a predição do peso corporal?
- (2) Qual variável apresenta maior poder preditivo?
- (3) Se determinadas hipóteses biológicas previamente propostas são sustentadas pelos dados observados.

15.0.0.2 Exemplo 1

15.1 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

15.1.1 Organizando os dados

```
library(openxlsx)
univ <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/tucuna.xlsx"
  ↪ ,
  rowNames = T, colNames = T,
  sheet = "tucuna")
head(univ, 10)
head(univ[, 1:5], 10)
```

##	CT_cm	PT_g	CP_cm	Ctubo_cm	PC_g	p_PT	Pest_g	Cest_cm	gr_est	ir_est
## TU001	32.4	468.8	27.2	39.8	458.9	2.111775	3.9	7.7	I	0.8319113
## TU002	33.4	520.0	28.8	14.3	507.4	2.423077	5.9	10.0	I	1.1346154
## TU003	27.3	301.5	23.8	13.0	283.4	6.003317	15.5	10.2	III	5.1409619
## TU004	13.2	28.2	11.0	16.5	27.7	1.773050	0.3	4.3	I	1.0638298
## TU005	14.3	38.9	11.9	15.5	37.7	3.084833	0.8	4.5	III	2.0565553
## TU006	22.7	431.7	20.5	24.2	418.7	3.011350	9.9	6.4	III	2.2932592
## TU007	23.2	544.0	19.2	25.0	520.1	4.393382	6.8	7.5	II	1.2500000
## TU008	13.5	161.6	11.5	17.5	157.0	2.846535	4.1	6.8	II	2.5371287
## TU009	24.6	200.5	20.5	25.7	195.9	2.294264	2.5	7.6	II	1.2468828
## TU010	19.4	86.7	16.0	18.3	84.5	2.537486	0.7	5.1	I	0.8073818
##	Pint_g	Cint_cm	gr_int	ir_int	Pgon_g	Cgon_cm		emg	ig	
## TU001	4.8	38.3	II	1.0238908	1.2	7		IMATURO	0.25597270	
## TU002	5.3	13.3	II	1.0192308	1.4	6.5		MADURO	0.26923077	
## TU003	2.4	12.0	II	0.7960199	0.2	7.7	EM	MATURACAO	0.06633499	
## TU004	0.1	16.0	II	0.3546099	0.1	5		IMATURO	0.35460993	
## TU005	0.3	15.0	II	0.7712082	0.1	3.2		IMATURO	0.25706941	
## TU006	2.7	23.7	II	0.6254343	0.4	7.8	EM	MATURACAO	0.09265694	
## TU007	3.3	24.5	II	0.6066176	13.8	7.9		MADURO	2.53676471	
## TU008	0.4	17.0	I	0.2475248	0.1	2.5		IMATURO	0.06188119	

```
## TU009      2.0      25.3      II 0.9975062      0.1      6.5 EM MATURACAO 0.04987531
## TU010      1.4      17.7      II 1.6147636      0.1      6      IMATURO 0.11534025
##          mes periodo estação      sexo      sexo2
## TU001 ago chuvoso inverno      MACHO      FEMEA
## TU002 ago chuvoso inverno      MACHO      FEMEA
## TU003 ago chuvoso inverno      MACHO      FEMEA
## TU004 ago chuvoso inverno      MACHO      FEMEA
## TU005 ago chuvoso inverno      MACHO      FEMEA
## TU006 set chuvoso inverno      MACHO      FEMEA
## TU007 set chuvoso inverno      FEMEA      MACHO
## TU008 set chuvoso inverno imaturo imaturo
## TU009 set chuvoso inverno      MACHO      FEMEA
## TU010 set chuvoso inverno      MACHO      FEMEA
##          CT_cm PT_g CP_cm Ctubo_cm PC_g
## TU001 32.4 468.8 27.2 39.8 458.9
## TU002 33.4 520.0 28.8 14.3 507.4
## TU003 27.3 301.5 23.8 13.0 283.4
## TU004 13.2 28.2 11.0 16.5 27.7
## TU005 14.3 38.9 11.9 15.5 37.7
## TU006 22.7 431.7 20.5 24.2 418.7
## TU007 23.2 544.0 19.2 25.0 520.1
## TU008 13.5 161.6 11.5 17.5 157.0
## TU009 24.6 200.5 20.5 25.7 195.9
## TU010 19.4 86.7 16.0 18.3 84.5
```

15.1.1.1 Correlograma e redução de variáveis desnecessárias

```
# Correlograma e redução de variáveis desnecessárias
library(psych)
colnames(univ)

#png("fig-nome.png")
pairs.panels(univ[,1:6], #colunas de interesse
             method = "pearson", # correlation method
             scale = FALSE, lm = FALSE,
             hist.col = "#00AFBB", pch = 19,
             density = TRUE, # show density plots
             ellipses = TRUE, # show correlation ellipses
             alpha = 0.5)

#dev.off()

cor <- cor(univ[,1:6])
cor
```

```

library(corrplot)
#png("fig-nome.png")
corrplot(cor, method = "circle")
#dev.off()


## Impressão em papel
#win.print()
#corrplot(cor, method = "circle")
#dev.off()


```

```

## [1] "CT_cm"      "PT_g"      "CP_cm"      "Ctubo_cm"  "PC_g"      "p_PT"
## [7] "Pest_g"    "Cest_cm"   "gr_est"     "ir_est"    "Pint_g"    "Cint_cm"
## [13] "gr_int"    "ir_int"    "Pgon_g"     "Cgon_cm"   "emg"       "ig"
## [19] "mes"       "período"   "estação"    "sexo"      "sexo2"
##
##          CT_cm      PT_g      CP_cm      Ctubo_cm      PC_g      p_PT
## CT_cm      1.000000    0.9057485  0.9990120  0.9091518  0.9039903 -0.5189589
## PT_g       0.9057485    1.0000000  0.9039503  0.8093258  0.9999423 -0.3320403
## CP_cm      0.9990120    0.9039503  1.0000000  0.9071124  0.9021382 -0.5159241
## Ctubo_cm   0.9091518    0.8093258  0.9071124  1.0000000  0.8062440 -0.4330032
## PC_g       0.9039903    0.9999423  0.9021382  0.8062440  1.0000000 -0.3321762
## p_PT      -0.5189589   -0.3320403 -0.5159241 -0.4330032 -0.3321762  1.0000000

```





15.1.1.2 Exemplo 2

Um pesquisador deseja determinar o efeito das variáveis ambientais de corpos aquáticos sobre a riqueza de espécies. Para isso, foram amostrados diferentes tipos de ambientes aquáticos e registradas a abundância e densidade de indivíduos, além de vários tipos de variáveis ambientais que refletem a morfologia local, qualidade da água, composição do sedimento e estruturas subaquáticas do habitat marginal. Regressão Múltipla foi utilizada nesse conjunto de dados para responder às seguintes perguntas:

- (1) Qual contribuição as variáveis morfológicas oferecem para a previsão da riqueza de espécies?
- (2) Qual variável morfológica é a melhor preditora da riqueza de espécies?
- (3) Estudos anteriores sugerem que a largura influencia a riqueza de espécies. Essa hipótese é corroborada pelos dados analisados?

15.2 Sobre os dados

**ATENÇÃO**

Os links para baixar as planilhas necessárias para repetir esse tutorial podem ser encontrados na seção Arquivos disponíveis do Capítulo Bases de dados.

Ou, baixe aqui o arquivo `ppbio06com-bentos.xlsx`

Também usaremos uma matriz ambiental com seus respectivos agrupamentos.

**ATENÇÃO**

Os links para baixar as planilhas necessárias para repetir esse tutorial podem ser encontrados na seção Arquivos disponíveis do Capítulo Bases de dados.

Ou, baixe aqui o arquivo `ppbio06amb-bentos.xlsx`

15.3 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

```
library(openxlsx)
densidade <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06com-bentos.xlsx"
  ↪ ,
  rowNames = T,
  colNames = T,
  sheet = "densidade")
habitat <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06amb-bentos.xlsx"
  ↪ ,
  rowNames = T,
  colNames = T,
```

```

                                sheet = "ambiente")
grupos <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06amb-bentos.xlsx"
  ↪ ,
                                rowNames = T,
                                colNames = T,
                                sheet = "grupos")
densidade[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas
  ↪ de 1 a 5.

# Removendo linhas e colunas zeradas
rownames(densidade)
rowSums(densidade)
colSums(densidade)
matriz <- densidade

# Linhas zeradas
sum <- rowSums(matriz)
sum
zero_sum <- rownames(matriz)[which(rowSums(matriz) == 0)]
zero_sum # nomes das linhas zeradas
m_part_rows <- matriz[(rowSums(matriz) != 0), ] #em != a
  ↪ exclamação inverte o sentido
zero_sum2 <- rownames(m_part_rows)[which(rowSums(m_part_rows) ==
  ↪ 0)]
zero_sum2 #nomes das linhas zeradas
sum <- rowSums(m_part_rows)
sum
# Colunas zeradas
sum <- colSums(m_part_rows)
sum
zero_sum <- names(which(colSums(m_part_rows) == 0))
zero_sum #nomes das espécies zeradas
m_part_cols <- m_part_rows[, (colSums(m_part_rows) != 0)] #remove
  ↪ colunas zeradas
zero_sum2 <- names(which(colSums(m_part_cols) == 0))
zero_sum2 #nomes das espécies zeradas
sum <- colSums(m_part_cols)
sum

m_dens <- as.data.frame(m_part_cols)

# Particionando a matriz ambiental
rownames(habitat)
del_rows <- c("B-A-MU-1", "B-R-EP-1")

```

```

del_rows
m_hab <- habitat[!(row.names(habitat) %in% c(del_rows)),]
m_hab

# Particionando tabela de grupos
t_grps <- grupos[!(row.names(grupos) %in% del_rows),]

# Salvando as matrizes finais particionadas
write.table(m_dens, "m_dens.csv",
            sep = ";", dec = ".", #"\t",
            row.names = TRUE,
            quote = TRUE,
            append = FALSE)
write.table(t_grps, "t_grps.csv",
            sep = ";", dec = ".", #"\t",
            row.names = TRUE,
            quote = TRUE,
            append = FALSE)
write.table(m_hab, "m_hab.csv",
            sep = ";", dec = ".", #"\t",
            row.names = TRUE,
            quote = TRUE,
            append = FALSE)
t_grps <- read.csv("t_grps.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)
m_dens <- read.csv("m_dens.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)
m_hab <- read.csv("m_hab.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)

# Particionando a matriz de contagem
contagem <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06com-bentos.xlsx"
  ↪ ,
                                rowNames = T,
                                colNames = T,

```

```

        sheet = "contagem")
contagem[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas de
↪ 1 a 5.

matriz <- contagem

# Linhas zeradas
sum <- rowSums(matriz)
sum
zero_sum <- rownames(matriz)[which(rowSums(matriz) == 0)]
zero_sum # nomes das linhas zeradas
m_part_rows <- matriz[(rowSums(matriz) != 0), ] #em != a
↪ exclamação inverte o sentido
zero_sum2 <- rownames(m_part_rows)[which(rowSums(m_part_rows) ==
↪ 0)]
zero_sum2 #nomes das linhas zeradas
sum <- rowSums(m_part_rows)
sum
# Colunas zeradas
sum <- colSums(m_part_rows)
sum
zero_sum <- names(which(colSums(m_part_rows) == 0))
zero_sum #nomes das espécies zeradas
m_part_cols <- m_part_rows[, (colSums(m_part_rows) != 0)] #remove
↪ colunas zeradas
zero_sum2 <- names(which(colSums(m_part_cols) == 0))
zero_sum2 #nomes das espécies zeradas
sum <- colSums(m_part_cols)
sum

m_cont <- as.data.frame(m_part_cols)

# Salvando a matriz final
write.table(m_cont, "m_cont.csv",
            sep = ";", dec = ".", #"\t",
            row.names = TRUE,
            quote = TRUE,
            append = FALSE)
m_cont <- read.csv("m_cont.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)

```

```
##          Hydrachnidia Ampularidae Atyidae    Baetidae Belastomatidae
```

```

## S-R-CI-1      0.00    0.000000      0    0.000000      0
## S-R-CI-2      0.00    0.000000      0    2.083333      0
## S-R-CI-3     93.75    2.083333      0 177.083333      0
## S-R-CI-4      0.00    4.166667      0    8.333333      0
## B-A-SA-1      0.00    0.000000      0    0.000000      0
## [1] "S-R-CI-1" "S-R-CI-2" "S-R-CI-3" "S-R-CI-4" "B-A-SA-1" "B-A-SA-2"
## [7] "B-A-SA-3" "B-A-SA-4" "B-A-MU-1" "B-A-MU-2" "B-A-MU-3" "B-A-MU-4"
## [13] "B-R-EP-1" "B-R-EP-2" "B-R-EP-3" "B-R-EP-4" "S-A-RE-1" "S-A-RE-2"
## [19] "S-A-RE-3" "S-A-RE-4" "S-R-SE-1" "S-R-SE-2" "S-R-SE-3" "S-R-SE-4"
##      S-R-CI-1      S-R-CI-2      S-R-CI-3      S-R-CI-4      B-A-SA-1      B-A-SA-2
##      62.500000  3022.916667  9010.416667  2029.166667  10.416667  29.166667
##      B-A-SA-3      B-A-SA-4      B-A-MU-1      B-A-MU-2      B-A-MU-3      B-A-MU-4
##      31.250000  83.333333    0.000000    6.250000    8.333333    25.000000
##      B-R-EP-1      B-R-EP-2      B-R-EP-3      B-R-EP-4      S-A-RE-1      S-A-RE-2
##      0.000000  2895.833333  927.083333  2791.666667  3345.833333  2252.083333
##      S-A-RE-3      S-A-RE-4      S-R-SE-1      S-R-SE-2      S-R-SE-3      S-R-SE-4
##      2829.166667  3629.166667  64.583333  2639.583333  8731.250000  14231.250000
##      Hydrachnidia      Ampularidae      Atyidae      Baetidae      Belastomatidae
##      93.750000      8.333333      122.916667      233.333333      4.166667
##      Caenidae      Ceratopogonidae      Coenagrionidae      Conchostraca      Corixidae
##      318.750000      156.250000      37.500000      375.000000      1833.333333
##      Curculionidae      Chaoboridae      Chironomidae_L      Chironomidae_P      Dytiscidae_L
##      12.500000      4.166667      13839.583333      289.583333      12.500000
##      Dytiscidae_A      Gerridae      Gomphidae      Glossosomatidae      Hydrophilidae_L
##      70.833333      4.166667      83.333333      12.500000      485.416667
##      Hydrophilide_A      Hirudinea      Leptohiphidae      Leptoceridae      Libellulidae
##      204.166667      16.666667      72.916667      6.250000      497.916667
##      Lymnaeidae      Naucoridae      Notonectidae      Oligochaeta      Ostracoda
##      6.250000      27.083333      137.500000      8370.833333      270.833333
##      Planorbidae      Physidae      Sphaeridae      Thiaridae      Veliidae
##      1493.750000      62.500000      2.083333      29483.333333      6.250000
##      S-R-CI-1      S-R-CI-2      S-R-CI-3      S-R-CI-4      B-A-SA-1      B-A-SA-2
##      62.500000  3022.916667  9010.416667  2029.166667  10.416667  29.166667
##      B-A-SA-3      B-A-SA-4      B-A-MU-1      B-A-MU-2      B-A-MU-3      B-A-MU-4
##      31.250000  83.333333    0.000000    6.250000    8.333333    25.000000
##      B-R-EP-1      B-R-EP-2      B-R-EP-3      B-R-EP-4      S-A-RE-1      S-A-RE-2
##      0.000000  2895.833333  927.083333  2791.666667  3345.833333  2252.083333
##      S-A-RE-3      S-A-RE-4      S-R-SE-1      S-R-SE-2      S-R-SE-3      S-R-SE-4
##      2829.166667  3629.166667  64.583333  2639.583333  8731.250000  14231.250000
## [1] "B-A-MU-1" "B-R-EP-1"
## character(0)
##      S-R-CI-1      S-R-CI-2      S-R-CI-3      S-R-CI-4      B-A-SA-1      B-A-SA-2
##      62.500000  3022.916667  9010.416667  2029.166667  10.416667  29.166667
##      B-A-SA-3      B-A-SA-4      B-A-MU-2      B-A-MU-3      B-A-MU-4      B-R-EP-2
##      31.250000  83.333333    6.250000    8.333333    25.000000  2895.833333
##      B-R-EP-3      B-R-EP-4      S-A-RE-1      S-A-RE-2      S-A-RE-3      S-A-RE-4

```

```

## 927.083333 2791.666667 3345.833333 2252.083333 2829.166667 3629.166667
## S-R-SE-1 S-R-SE-2 S-R-SE-3 S-R-SE-4
## 64.583333 2639.583333 8731.250000 14231.250000
## Hydrachnidia Ampularidae Atyidae Baetidae Belastomatidae
## 93.750000 8.333333 122.916667 233.333333 4.166667
## Caenidae Ceratopogonidae Coenagrionidae Conchostraca Corixidae
## 318.750000 156.250000 37.500000 375.000000 1833.333333
## Curculionidae Chaoboridae Chironomidae_L Chironomidae_P Dytiscidae_L
## 12.500000 4.166667 13839.583333 289.583333 12.500000
## Dytiscidae_A Gerridae Gomphidae Glossosomatidae Hidrophilidae_L
## 70.833333 4.166667 83.333333 12.500000 485.416667
## Hidrophilide_A Hirudinea Leptohyphidae Leptoceridae Libellulidae
## 204.166667 16.666667 72.916667 6.250000 497.916667
## Lymnaeidae Naucoridae Notonectidae Oligochaeta Ostracoda
## 6.250000 27.083333 137.500000 8370.833333 270.833333
## Planorbidae Physidae Sphaeridae Thiaridae Veliidae
## 1493.750000 62.500000 2.083333 29483.333333 6.250000
## character(0)
## character(0)
## Hydrachnidia Ampularidae Atyidae Baetidae Belastomatidae
## 93.750000 8.333333 122.916667 233.333333 4.166667
## Caenidae Ceratopogonidae Coenagrionidae Conchostraca Corixidae
## 318.750000 156.250000 37.500000 375.000000 1833.333333
## Curculionidae Chaoboridae Chironomidae_L Chironomidae_P Dytiscidae_L
## 12.500000 4.166667 13839.583333 289.583333 12.500000
## Dytiscidae_A Gerridae Gomphidae Glossosomatidae Hidrophilidae_L
## 70.833333 4.166667 83.333333 12.500000 485.416667
## Hidrophilide_A Hirudinea Leptohyphidae Leptoceridae Libellulidae
## 204.166667 16.666667 72.916667 6.250000 497.916667
## Lymnaeidae Naucoridae Notonectidae Oligochaeta Ostracoda
## 6.250000 27.083333 137.500000 8370.833333 270.833333
## Planorbidae Physidae Sphaeridae Thiaridae Veliidae
## 1493.750000 62.500000 2.083333 29483.333333 6.250000
## [1] "S-R-CI-1" "S-R-CI-2" "S-R-CI-3" "S-R-CI-4" "B-A-SA-1" "B-A-SA-2"
## [7] "B-A-SA-3" "B-A-SA-4" "B-A-MU-1" "B-A-MU-2" "B-A-MU-3" "B-A-MU-4"
## [13] "B-R-EP-1" "B-R-EP-2" "B-R-EP-3" "B-R-EP-4" "S-A-RE-1" "S-A-RE-2"
## [19] "S-A-RE-3" "S-A-RE-4" "S-R-SE-1" "S-R-SE-2" "S-R-SE-3" "S-R-SE-4"
## [1] "B-A-MU-1" "B-R-EP-1"
## g.river_length g.altitude m.depth_mar m.depth_max m.slope m.width
## S-R-CI-1 83.0500 169 22.666667 60 60 17.24
## S-R-CI-2 83.0500 169 32.666667 68 60 18.47
## S-R-CI-3 83.0500 169 32.666667 79 60 15.10
## S-R-CI-4 83.0500 169 45.333333 64 60 10.70
## B-A-SA-1 212.6667 713 8.166667 60 30 330.00
## B-A-SA-2 212.6667 713 7.000000 69 30 321.00
## B-A-SA-3 212.6667 713 6.833333 68 30 314.20

```

##	B-A-SA-4	212.6667	713	4.666667	63	30	289.50	
##	B-A-MU-2	214.0200	725	22.000000	115	30	247.63	
##	B-A-MU-3	214.0200	725	25.666667	117	30	234.53	
##	B-A-MU-4	214.0200	725	41.333333	112	30	239.00	
##	B-R-EP-2	196.8333	402	49.333333	110	90	29.60	
##	B-R-EP-3	196.8333	402	50.000000	80	90	27.30	
##	B-R-EP-4	196.8333	402	52.833333	95	90	20.00	
##	S-A-RE-1	110.2000	270	54.666667	154	60	102.00	
##	S-A-RE-2	110.2000	270	37.666667	118	60	100.00	
##	S-A-RE-3	110.2000	270	22.333333	109	60	88.00	
##	S-A-RE-4	110.2000	270	30.333333	87	60	72.20	
##	S-R-SE-1	163.2000	226	81.333333	106	30	19.64	
##	S-R-SE-2	163.2000	226	67.000000	105	30	16.10	
##	S-R-SE-3	163.2000	226	32.333333	110	30	6.20	
##	S-R-SE-4	163.2000	226	32.333333	74	30	5.40	
##		q.w_vel	q.temp	q.do	q.turb	s.mud	s.sand	s.smlgrav
##	S-R-CI-1	0.1591512	35.20000	6.863333	26.00000	16.666667	70.000000	5.000000
##	S-R-CI-2	0.0000000	29.00000	3.015000	33.00000	0.666667	87.666667	3.333333
##	S-R-CI-3	0.0000000	29.66667	5.000000	50.33333	48.750000	22.500000	10.000000
##	S-R-CI-4	0.0000000	27.60000	4.900000	60.00000	5.000000	60.000000	0.000000
##	B-A-SA-1	0.0000000	29.23333	5.136667	25.66667	96.666667	3.333333	0.000000
##	B-A-SA-2	0.0000000	29.00000	1.850000	55.00000	98.000000	2.000000	0.000000
##	B-A-SA-3	0.0000000	24.00000	8.800000	51.66667	87.777778	6.666667	3.333333
##	B-A-SA-4	0.0000000	24.70000	8.750000	36.00000	95.166667	3.416667	1.333333
##	B-A-MU-2	0.0000000	29.00000	1.815000	43.00000	20.600000	77.000000	0.000000
##	B-A-MU-3	0.0000000	26.00000	5.700000	63.00000	65.000000	35.000000	0.000000
##	B-A-MU-4	0.0000000	25.95000	7.300000	89.00000	91.777778	3.222222	0.000000
##	B-R-EP-2	0.0000000	29.00000	5.635000	50.00000	39.000000	56.000000	3.000000
##	B-R-EP-3	0.0000000	29.00000	5.000000	32.33333	33.666667	63.000000	3.333333
##	B-R-EP-4	0.0000000	28.85000	5.100000	30.00000	48.875000	47.875000	1.875000
##	S-A-RE-1	0.1000000	34.00000	4.820000	61.00000	81.666667	8.333333	1.666667
##	S-A-RE-2	0.0000000	29.00000	5.000000	90.00000	5.000000	95.000000	0.000000
##	S-A-RE-3	0.0000000	34.00000	9.000000	51.66667	46.666667	40.000000	6.666667
##	S-A-RE-4	0.0000000	29.53333	9.433333	67.00000	59.1428571	38.714286	2.142857
##	S-R-SE-1	0.1666667	32.90000	6.510000	46.00000	65.000000	30.000000	0.000000
##	S-R-SE-2	0.1250000	32.00000	5.375000	44.00000	40.000000	40.000000	0.000000
##	S-R-SE-3	0.0000000	28.26667	6.000000	17.33333	65.5555556	23.111111	0.000000
##	S-R-SE-4	0.0000000	32.60000	6.000000	16.00000	95.000000	1.833333	0.000000
##		s.lrggrav	s.cobbles	s.rocks	s.bedrock	h.macroph	h.grass	
##	S-R-CI-1	5.00000000	3.3333333	0.000000	0.000000	0.000000	23.333333	
##	S-R-CI-2	3.33333333	5.0000000	0.000000	0.000000	0.000000	0.000000	
##	S-R-CI-3	10.00000000	8.7500000	0.000000	0.000000	0.000000	0.000000	
##	S-R-CI-4	0.00000000	25.0000000	10.000000	0.000000	0.000000	0.000000	
##	B-A-SA-1	0.00000000	0.0000000	0.000000	0.000000	46.666667	0.000000	
##	B-A-SA-2	0.00000000	0.0000000	0.000000	0.000000	2.600000	7.500000	
##	B-A-SA-3	2.22222222	0.0000000	0.000000	0.000000	0.000000	13.333333	


```

## B-A-SA-4 0.08333333 0.0000000 0.000000 0.000000 2.083333 0.0000000
## B-A-MU-2 0.00000000 2.4000000 0.000000 0.000000 0.000000 54.0000000
## B-A-MU-3 0.00000000 0.0000000 0.000000 0.000000 0.000000 28.3333333
## B-A-MU-4 0.00000000 0.0000000 5.000000 0.000000 0.000000 5.5555556
## B-R-EP-2 0.00000000 1.0000000 1.000000 0.000000 0.000000 2.0000000
## B-R-EP-3 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.0000000
## B-R-EP-4 0.00000000 0.1250000 1.250000 0.000000 0.000000 0.0000000
## S-A-RE-1 0.00000000 0.0000000 0.000000 8.333333 5.833333 0.0000000
## S-A-RE-2 0.00000000 0.0000000 0.000000 0.000000 54.833333 0.3333333
## S-A-RE-3 6.66666667 0.0000000 0.000000 0.000000 44.629630 8.1111111
## S-A-RE-4 0.00000000 0.0000000 0.000000 0.000000 37.309524 0.0000000
## S-R-SE-1 0.00000000 1.6666667 0.000000 3.333333 8.333333 20.0000000
## S-R-SE-2 0.00000000 20.0000000 0.000000 0.000000 0.000000 20.0000000
## S-R-SE-3 0.00000000 3.0000000 8.333333 0.000000 0.000000 0.1111111
## S-R-SE-4 0.00000000 0.3333333 2.833333 0.000000 0.000000 4.1666667
##          h.subveg h.overhveg h.litter h.filalgae h.attalgae h.roots
## S-R-CI-1 3.000000 26.666667 2.3333333 3.3333333 0.6666667 3.333333
## S-R-CI-2 0.000000 33.333333 1.0000000 0.0000000 0.0000000 5.000000
## S-R-CI-3 0.000000 0.000000 1.5000000 6.2500000 0.5000000 1.000000
## S-R-CI-4 0.000000 8.333333 1.0000000 25.0000000 50.0000000 0.000000
## B-A-SA-1 3.333333 3.333333 0.0000000 0.0000000 0.0000000 0.000000
## B-A-SA-2 26.000000 0.400000 0.0000000 0.0000000 1.0000000 0.000000
## B-A-SA-3 0.000000 0.000000 0.0000000 25.0000000 0.0000000 0.000000
## B-A-SA-4 0.000000 0.000000 0.0000000 0.8333333 42.5000000 0.000000
## B-A-MU-2 36.600000 0.000000 5.0000000 0.0000000 0.0000000 0.000000
## B-A-MU-3 8.333333 0.000000 1.0000000 0.0000000 0.3333333 0.000000
## B-A-MU-4 0.000000 0.000000 0.4444444 0.0000000 30.0000000 0.000000
## B-R-EP-2 0.000000 0.000000 0.4000000 0.0000000 0.4000000 0.000000
## B-R-EP-3 0.000000 0.000000 0.3333333 0.0000000 0.0000000 0.000000
## B-R-EP-4 0.000000 0.000000 0.5000000 0.0000000 0.0000000 0.000000
## S-A-RE-1 16.666667 33.333333 3.6666667 25.0000000 3.3333333 0.000000
## S-A-RE-2 0.000000 8.333333 1.0000000 33.3333330 0.0000000 0.000000
## S-A-RE-3 0.000000 0.000000 0.6666667 9.0000000 0.0000000 0.000000
## S-A-RE-4 0.000000 0.000000 0.5714286 0.0000000 0.0000000 0.000000
## S-R-SE-1 10.000000 0.000000 0.6666667 0.0000000 12.0000000 0.000000
## S-R-SE-2 0.000000 0.000000 0.0000000 0.0000000 1.0000000 0.000000
## S-R-SE-3 0.000000 0.000000 0.0000000 0.0000000 0.0000000 0.000000
## S-R-SE-4 0.000000 0.000000 0.8333333 0.0000000 7.5000000 0.000000
##          h.smldeb h.lrgdeb
## S-R-CI-1 2.0000000 1.6666667
## S-R-CI-2 7.0000000 3.3333333
## S-R-CI-3 3.0000000 0.6666667
## S-R-CI-4 1.0000000 0.0000000
## B-A-SA-1 0.0000000 0.0000000
## B-A-SA-2 0.0000000 0.0000000
## B-A-SA-3 0.0000000 0.0000000

```

```

## B-A-SA-4 3.7500000 0.0000000
## B-A-MU-2 10.0000000 0.0000000
## B-A-MU-3 5.0000000 6.6666667
## B-A-MU-4 7.2222222 3.2222222
## B-R-EP-2 0.4000000 0.0000000
## B-R-EP-3 0.4444444 0.0000000
## B-R-EP-4 2.5000000 0.0000000
## S-A-RE-1 10.0000000 0.0000000
## S-A-RE-2 5.3333333 8.3333333
## S-A-RE-3 1.6666667 0.0000000
## S-A-RE-4 3.2857143 0.0000000
## S-R-SE-1 1.6666667 1.6666667
## S-R-SE-2 0.0000000 0.0000000
## S-R-SE-3 2.2222222 0.0000000
## S-R-SE-4 5.0000000 0.0000000
##           Hydrachnidia Ampularidae Atyidae Baetidae Belastomatidae
## S-R-CI-1           0           0           0           0           0
## S-R-CI-2           0           0           0           1           0
## S-R-CI-3          45           1           0          85           0
## S-R-CI-4           0           2           0           4           0
## B-A-SA-1           0           0           0           0           0
## S-R-CI-1 S-R-CI-2 S-R-CI-3 S-R-CI-4 B-A-SA-1 B-A-SA-2 B-A-SA-3 B-A-SA-4
##          30      1451      4325      974           5          14          15          40
## B-A-MU-1 B-A-MU-2 B-A-MU-3 B-A-MU-4 B-R-EP-1 B-R-EP-2 B-R-EP-3 B-R-EP-4
##           0           3           4          12           0        1390          445          1340
## S-A-RE-1 S-A-RE-2 S-A-RE-3 S-A-RE-4 S-R-SE-1 S-R-SE-2 S-R-SE-3 S-R-SE-4
##          1606          1081          1358          1742           31          1267          4191          6831
## [1] "B-A-MU-1" "B-R-EP-1"
## character(0)
## S-R-CI-1 S-R-CI-2 S-R-CI-3 S-R-CI-4 B-A-SA-1 B-A-SA-2 B-A-SA-3 B-A-SA-4
##          30      1451      4325      974           5          14          15          40
## B-A-MU-2 B-A-MU-3 B-A-MU-4 B-R-EP-2 B-R-EP-3 B-R-EP-4 S-A-RE-1 S-A-RE-2
##           3           4          12        1390          445          1340          1606          1081
## S-A-RE-3 S-A-RE-4 S-R-SE-1 S-R-SE-2 S-R-SE-3 S-R-SE-4
##          1358          1742           31          1267          4191          6831
##           Hydrachnidia Ampularidae Atyidae Baetidae Belastomatidae
##           45           4           59          112           2
##           Caenidae Ceratopogonidae Coenagrionidae Conchostraca Corixidae
##           153           75           18          180          880
## Curculionidae Chaoboridae Chironomidae_L Chironomidae_P Dytiscidae_L
##           6           2          6643          139           6
## Dytiscidae_A Gerridae Gomphidae Glossosomatidae Hidrophilidae_L
##           34           2           40           6          233
## Hidrophilide_A Hirudinea Leptohiphidae Leptoceridae Libellulidae
##           98           8           35           3          239
## Lymnaeidae Naucoridae Notonectidae Oligochaeta Ostracoda

```

```
##          3          13          66          4018          130
## Planorbidae Physidae Sphaeridae Thiaridae Veliidae
##          717          30          1          14152          3
## character(0)
## character(0)
## Hydrachnidia Ampularidae Atyidae Baetidae Belastomatidae
##          45          4          59          112          2
## Caenidae Ceratopogonidae Coenagrionidae Conchostraca Corixidae
##          153          75          18          180          880
## Curculionidae Chaoboridae Chironomidae_L Chironomidae_P Dytiscidae_L
##          6          2          6643          139          6
## Dytiscidae_A Gerridae Gomphidae Glossosomatidae Hidrophilidae_L
##          34          2          40          6          233
## Hidrophilide_A Hirudinea Leptohyphidae Leptoceridae Libellulidae
##          98          8          35          3          239
## Lymnaeidae Naucoridae Notonectidae Oligochaeta Ostracoda
##          3          13          66          4018          130
## Planorbidae Physidae Sphaeridae Thiaridae Veliidae
##          717          30          1          14152          3
```

15.3.0.1 Correlograma e redução de variáveis desnecessárias

```
dev.off()
rm(list=ls(all=TRUE))
cat("\014")
t_grps <- read.csv("t_grps.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)
m_hab <- read.csv("m_hab.csv",
                 sep = ";", dec = ".",
                 row.names = 1,
                 header = TRUE,
                 na.strings = NA)

# Correlograma e redução de variáveis desnecessárias
library(psych)
colnames(m_hab)

#png("fig-hab_pairs.png")
pairs.panels(m_hab[,3:6], #colunas de interesse
             method = "pearson", # correlation method
```

```

        scale = FALSE, lm = FALSE,
        hist.col = "#00AFBB", pch = 19,
        density = TRUE, # show density plots
        ellipses = TRUE, # show correlation ellipses
        alpha = 0.5)
#dev.off()

cor <- cor(m_hab)
cor

library(corrplot)
#png("fig-hab_corrplot.png")
corrplot(cor, method = "circle")
#dev.off()

## Impressão em papel
#win.print()
#corrplot(cor, method = "circle")
#dev.off()

# Deletando colineares
#sink(file = "colineares.txt", append = F, split = T)
colnames(m_hab)
del_cols <- c() # "g.river_length", "g.altitude" #NÃO DELETEI
  ↪ VARIÁVEIS
m_hab_part <- m_hab[, !(colnames(m_hab) %in% del_cols)]

# Somando redundantes
m_hab_part$s.gravel <- m_hab_part$s.smlgrav +
  ↪ m_hab_part$s.lrggrav + m_hab_part$s.cobbles
m_hab_part <- m_hab_part[, !(colnames(m_hab_part)
  %in% c("s.smlgrav", "s.lrggrav",
  ↪ "s.cobbles"))]
m_hab_part$s.rocks <- m_hab_part$s.rocks + m_hab_part$s.bedrock
m_hab_part <- m_hab_part[, !(colnames(m_hab_part)
  %in% c("s.bedrock"))] #rocks novo
  ↪ substitui o antigo
m_hab_part$h.algae <- m_hab_part$h.filalgae +
  ↪ m_hab_part$h.attalgae
m_hab_part <- m_hab_part[, !(colnames(m_hab_part)
  %in% c("h.filalgae", "h.attalgae"))]
m_hab_part$h.debris <- m_hab_part$h.smldeb + m_hab_part$h.lrgdeb
m_hab_part <- m_hab_part[, !(colnames(m_hab_part)
  %in% c("h.smldeb", "h.lrgdeb"))]

```

```

colnames(m_hab_part)
m_hab_part
#sink()

write.table(m_hab_part, "m_hab_part.csv",
            sep = ";", dec = ".", #"\t",
            row.names = TRUE,
            quote = TRUE,
            append = FALSE)
m_hab_part <- read.csv("m_hab_part.csv",
                      sep = ";", dec = ".",
                      row.names = 1,
                      header = TRUE,
                      na.strings = NA)

## null device
##          1
##
## [1] "g.river_length" "g.altitude"      "m.depth_mar"      "m.depth_max"
## [5] "m.slope"           "m.width"          "q.w_vel"          "q.temp"
## [9] "q.do"              "q.turb"           "s.mud"            "s.sand"
## [13] "s.smlgrav"         "s.lrggrav"        "s.cobbles"        "s.rocks"
## [17] "s.bedrock"         "h.macroph"        "h.grass"          "h.subveg"
## [21] "h.overhveg"        "h.litter"         "h.filalgae"       "h.attalgae"
## [25] "h.roots"           "h.smldeb"         "h.lrgdeb"
##
##      g.river_length g.altitude m.depth_mar m.depth_max
## g.river_length    1.000000000 0.84502567 -0.2107788227 0.03193375
## g.altitude        0.845025674 1.000000000 -0.5456269822 -0.05715772
## m.depth_mar       -0.210778823 -0.54562698 1.00000000000 0.48741161
## m.depth_max       0.031933747 -0.05715772 0.4874116097 1.00000000
## m.slope           -0.349208370 -0.42489758 0.3283867843 0.05612196
## m.width           0.641988529 0.92424799 -0.6825592240 -0.12448305
## q.w_vel           -0.262001078 -0.38295700 0.5171356166 0.17255835
## q.temp            -0.525665151 -0.63928720 0.3911634740 0.21637312
## q.do              -0.051659274 -0.04102810 -0.0991121996 -0.07100992
## q.turb            -0.091714999 0.16898017 0.1101861220 0.43212925
## s.mud             0.572275653 0.53376284 -0.3050313798 -0.02986246
## s.sand            -0.419694387 -0.39540877 0.2504305845 0.07714330
## s.smlgrav         -0.471237455 -0.33801390 -0.1291605642 -0.18707938
## s.lrggrav         -0.544226442 -0.34645497 -0.2042006110 -0.21830987
## s.cobbles         -0.403532433 -0.42286274 0.3291265735 -0.17913390
## s.rocks           -0.117779725 -0.20066951 0.1319413256 -0.03858935
## s.bedrock         -0.192613303 -0.18845652 0.4127970495 0.56482143
## h.macroph         -0.215456970 -0.05481455 -0.1836470655 0.09117336

```

## h.grass	0.265200241	0.30832251	-0.0409219509	0.20663711	
## h.subveg	0.279722831	0.39857061	-0.1392387004	0.27630152	
## h.overhveg	-0.590722577	-0.38967693	0.0687330694	0.04945054	
## h.litter	-0.242878589	-0.06083615	0.0507371439	0.39847691	
## h.filalgae	-0.392485116	-0.17902428	0.0005987805	0.18844607	
## h.attalgae	-0.001186444	0.10038855	0.0148526066	-0.23527738	
## h.roots	-0.516543690	-0.36183451	-0.0963721795	-0.35893734	
## h.smldeb	-0.124355809	0.06081352	0.0325551250	0.51395706	
## h.lrgdeb	-0.117830284	0.03802733	0.0419116237	0.26995051	
##	m.slope	m.width	q.w_vel	q.temp	q.do
## g.river_length	-0.349208370	0.6419885285	-0.26200108	-0.52566515	-0.0516592738
## g.altitude	-0.424897575	0.9242479855	-0.38295700	-0.63928720	-0.0410280998
## m.depth_mar	0.328386784	-0.6825592240	0.51713562	0.39116347	-0.0991121996
## m.depth_max	0.056121960	-0.1244830484	0.17255835	0.21637312	-0.0710099161
## m.slope	1.000000000	-0.5498770747	-0.10766070	0.19871727	-0.0419308349
## m.width	-0.549877075	1.0000000000	-0.31411254	-0.54204077	0.0008131425
## q.w_vel	-0.107660702	-0.3141125390	1.00000000	0.64759095	0.0629064699
## q.temp	0.198717266	-0.5420407696	0.64759095	1.00000000	-0.0722772054
## q.do	-0.041930835	0.0008131425	0.06290647	-0.07227721	1.0000000000
## q.turb	0.010259341	0.2383863495	-0.11099701	-0.24210974	0.1100032765
## s.mud	-0.528125673	0.5605422773	-0.09358538	-0.20493421	0.3008137410
## s.sand	0.526002627	-0.4515653205	0.04563133	0.16012915	-0.3159294821
## s.smlgrav	0.465564864	-0.2836142916	-0.02643266	0.23060553	0.2292491864
## s.lrggrav	0.185917468	-0.2204634853	0.03572644	0.27712369	0.1463795646
## s.cobbles	-0.005901226	-0.3824094214	0.19824905	0.05603254	-0.1890471593
## s.rocks	-0.082932175	-0.2519993118	-0.21518824	-0.22008642	0.0037875243
## s.bedrock	0.031654006	-0.0873140063	0.49907808	0.41780461	-0.0673382190
## h.macroph	0.050444099	0.1399878974	-0.14691717	0.18665422	0.2629680490
## h.grass	-0.403122259	0.2434340256	0.30883851	0.09532319	-0.2353366428
## h.subveg	-0.312667133	0.4184204319	0.10626426	0.11033997	-0.6046348220
## h.overhveg	0.226153390	-0.2288480414	0.37153753	0.39196980	-0.2374637651
## h.litter	0.046848349	-0.0329222552	0.22271660	0.34840703	-0.3956033776
## h.filalgae	0.127026094	0.0195632889	-0.01352383	-0.04474398	0.0751694004
## h.attalgae	-0.179393906	0.1059553668	-0.06926506	-0.35207241	0.2105548893
## h.roots	0.176998187	-0.2800912329	0.20229610	0.21512444	-0.2009824555
## h.smldeb	-0.116260323	0.0704089450	-0.05336000	0.04276197	-0.2490107269
## h.lrgdeb	-0.064284838	0.0620580191	-0.03594483	-0.17183100	-0.0868542185
##	q.turb	s.mud	s.sand	s.smlgrav	s.lrggrav
## g.river_length	-0.09171500	0.57227565	-0.419694387	-0.471237455	-0.54422644
## g.altitude	0.16898017	0.53376284	-0.395408774	-0.338013905	-0.34645497
## m.depth_mar	0.11018612	-0.30503138	0.250430585	-0.129160564	-0.20420061
## m.depth_max	0.43212925	-0.02986246	0.077143302	-0.187079380	-0.21830987
## m.slope	0.01025934	-0.52812567	0.526002627	0.465564864	0.18591747
## m.width	0.23838635	0.56054228	-0.451565321	-0.283614292	-0.22046349
## q.w_vel	-0.11099701	-0.09358538	0.045631331	-0.026432657	0.03572644
## q.temp	-0.24210974	-0.20493421	0.160129148	0.230605533	0.27712369

```

## q.do          0.11000328  0.30081374 -0.315929482  0.229249186  0.14637956
## q.turb        1.00000000 -0.07223620  0.083599381 -0.090296375 -0.07355212
## s.mud         -0.07223620  1.00000000 -0.957783005 -0.222195445 -0.22432912
## s.sand        0.08359938 -0.95778300  1.000000000  0.111089985  0.08256158
## s.smlgrav     -0.09029638 -0.22219545  0.111089985  1.000000000  0.91807630
## s.lrggrav     -0.07355212 -0.22432912  0.082561585  0.918076304  1.00000000
## s.cobbles     0.01134598 -0.44887064  0.222657542 -0.026424565  0.08842146
## s.rocks       -0.01558541 -0.06910979 -0.069654875 -0.309941518 -0.22077847
## s.bedrock     0.14116818  0.20182097 -0.224546542 -0.078999373 -0.13636908
## h.macroph     0.31158993 -0.04413777  0.126276177  0.006717696  0.04584885
## h.grass       -0.01509716 -0.16537718  0.222442150 -0.177811657 -0.04127532
## h.subveg      0.06506041  0.08033288 -0.004435688 -0.286378841 -0.20744404
## h.overhveg    -0.03986454 -0.35117567  0.318668751  0.140256840  0.16791271
## h.litter      0.06881438 -0.32562795  0.327771847  0.078055730  0.12016548
## h.filalgae    0.49077319 -0.22342824  0.158521843  0.039501763  0.06036785
## h.attalgae    0.20060451  0.08590942 -0.194244940 -0.263503810 -0.21204080
## h.roots       -0.26305709 -0.47340712  0.446429062  0.369358654  0.44783328
## h.smldeb      0.26451875 -0.08555157  0.144514486 -0.145032992 -0.07961314
## h.lrgdeb      0.53297687 -0.29308976  0.392806733 -0.175030819 -0.04309051
##              s.cobbles    s.rocks    s.bedrock    h.macroph    h.grass
## g.river_length -0.403532433 -0.117779725 -0.19261330 -0.215456970  0.265200241
## g.altitude     -0.422862740 -0.200669512 -0.18845652 -0.054814547  0.308322511
## m.depth_mar    0.329126574  0.131941326  0.41279705 -0.183647065 -0.040921951
## m.depth_max    -0.179133903 -0.038589348  0.56482143  0.091173356  0.206637114
## m.slope        -0.005901226 -0.082932175  0.03165401  0.050444099 -0.403122259
## m.width        -0.382409421 -0.251999312 -0.08731401  0.139987897  0.243434026
## q.w_vel        0.198249045 -0.215188244  0.49907808 -0.146917169  0.308838515
## q.temp         0.056032544 -0.220086417  0.41780461  0.186654221  0.095323192
## q.do          -0.189047159  0.003787524 -0.06733822  0.262968049 -0.235336643
## q.turb         0.011345983 -0.015585412  0.14116818  0.311589934 -0.015097158
## s.mud         -0.448870644 -0.069109791  0.20182097 -0.044137771 -0.165377185
## s.sand         0.222657542 -0.069654875 -0.22454654  0.126276177  0.222442150
## s.smlgrav     -0.026424565 -0.309941518 -0.07899937  0.006717696 -0.177811657
## s.lrggrav     0.088421459 -0.220778474 -0.13636908  0.045848851 -0.041275322
## s.cobbles     1.000000000  0.469913591 -0.12127157 -0.252264472  0.023835319
## s.rocks       0.469913591  1.000000000 -0.13468574 -0.243815262 -0.247534694
## s.bedrock     -0.121271567 -0.134685736  1.00000000 -0.043359102 -0.060677870
## h.macroph     -0.252264472 -0.243815262 -0.04335910  1.000000000 -0.225166424
## h.grass       0.023835319 -0.247534694 -0.06067787 -0.225166424  1.000000000
## h.subveg      -0.160976449 -0.231842136  0.30426497 -0.149722575  0.649953984
## h.overhveg    0.064906116 -0.098085706  0.50479206 -0.057627452 -0.109199604
## h.litter      -0.013581580 -0.153337520  0.43853508 -0.125555623  0.566470585
## h.filalgae    0.188914571  0.134383965  0.33443584  0.298616900 -0.195372923
## h.attalgae    0.405309857  0.555931124 -0.01984227 -0.211808706 -0.188804421
## h.roots       0.084905231 -0.161381949 -0.09968140 -0.180448561 -0.004101108
## h.smldeb      -0.231674975 -0.054180714  0.41463548 -0.074651931  0.262978643

```

```

## h.lrgdeb          -0.158839149 -0.123236069 -0.08773874  0.270168938  0.099117063
##                  h.subveg  h.overhveg  h.litter  h.filalgae  h.attalgae
## g.river_length  0.279722831 -0.59072258 -0.24287859 -0.3924851158 -0.001186444
## g.altitude      0.398570607 -0.38967693 -0.06083615 -0.1790242790  0.100388552
## m.depth_mar     -0.139238700  0.06873307  0.05073714  0.0005987805  0.014852607
## m.depth_max     0.276301517  0.04945054  0.39847691  0.1884460741 -0.235277380
## m.slope         -0.312667133  0.22615339  0.04684835  0.1270260944 -0.179393906
## m.width         0.418420432 -0.22884804 -0.03292226  0.0195632889  0.105955367
## q.w_vel         0.106264262  0.37153753  0.22271660 -0.0135238333 -0.069265056
## q.temp          0.110339966  0.39196980  0.34840703 -0.0447439758 -0.352072407
## q.do            -0.604634822 -0.23746377 -0.39560338  0.0751694004  0.210554889
## q.turb          0.065060415 -0.03986454  0.06881438  0.4907731880  0.200604509
## s.mud           0.080332879 -0.35117567 -0.32562795 -0.2234282427  0.085909418
## s.sand          -0.004435688  0.31866875  0.32777185  0.1585218432 -0.194244940
## s.smlgrav       -0.286378841  0.14025684  0.07805573  0.0395017635 -0.263503810
## s.lrggrav       -0.207444039  0.16791271  0.12016548  0.0603678501 -0.212040802
## s.cobbles       -0.160976449  0.06490612 -0.01358158  0.1889145712  0.405309857
## s.rocks         -0.231842136 -0.09808571 -0.15333752  0.1343839650  0.555931124
## s.bedrock       0.304264973  0.50479206  0.43853508  0.3344358402 -0.019842268
## h.macroph       -0.149722575 -0.05762745 -0.12555562  0.2986168997 -0.211808706
## h.grass         0.649953984 -0.10919960  0.56647059 -0.1953729233 -0.188804421
## h.subveg        1.000000000  0.05371661  0.65370466 -0.0812920466 -0.168289149
## h.overhveg      0.053716610  1.00000000  0.44095646  0.3071336586 -0.067998523
## h.litter        0.653704655  0.44095646  1.00000000  0.1849508655 -0.129422759
## h.filalgae      -0.081292047  0.30713366  0.18495087  1.0000000000  0.156814606
## h.attalgae      -0.168289149 -0.06799852 -0.12942276  0.1568146063  1.000000000
## h.roots         -0.132672304  0.72073747  0.16368669 -0.1312445975 -0.158491818
## h.smldeb        0.407462990  0.42571768  0.72455356  0.1168191385  0.038651614
## h.lrgdeb        -0.092240200  0.17593257  0.02424289  0.2700099670 -0.075556606
##                  h.roots  h.smldeb  h.lrgdeb
## g.river_length -0.516543690 -0.12435581 -0.11783028
## g.altitude     -0.361834509  0.06081352  0.03802733
## m.depth_mar    -0.096372180  0.03255513  0.04191162
## m.depth_max    -0.358937337  0.51395706  0.26995051
## m.slope        0.176998187 -0.11626032 -0.06428484
## m.width        -0.280091233  0.07040894  0.06205802
## q.w_vel        0.202296097 -0.05336000 -0.03594483
## q.temp         0.215124441  0.04276197 -0.17183100
## q.do           -0.200982456 -0.24901073 -0.08685422
## q.turb         -0.263057089  0.26451875  0.53297687
## s.mud          -0.473407121 -0.08555157 -0.29308976
## s.sand         0.446429062  0.14451449  0.39280673
## s.smlgrav      0.369358654 -0.14503299 -0.17503082
## s.lrggrav      0.447833281 -0.07961314 -0.04309051
## s.cobbles      0.084905231 -0.23167498 -0.15883915
## s.rocks        -0.161381949 -0.05418071 -0.12323607

```



```

## s.bedrock      -0.099681402  0.41463548 -0.08773874
## h.macroph      -0.180448561 -0.07465193  0.27016894
## h.grass        -0.004101108  0.26297864  0.09911706
## h.subveg       -0.132672304  0.40746299 -0.09224020
## h.overhveg     0.720737471  0.42571768  0.17593257
## h.litter       0.163686687  0.72455356  0.02424289
## h.filalgae     -0.131244597  0.11681914  0.27000997
## h.attalgae     -0.158491818  0.03865161 -0.07555661
## h.roots        1.000000000  0.17466111  0.19797552
## h.smldeb       0.174661113  1.00000000  0.32818609
## h.lrgdeb       0.197975524  0.32818609  1.00000000
## [1] "g.river_length" "g.altitude"      "m.depth_mar"      "m.depth_max"
## [5] "m.slope"          "m.width"          "q.w_vel"          "q.temp"
## [9] "q.do"             "q.turb"           "s.mud"            "s.sand"
## [13] "s.smlgrav"        "s.lrggrav"        "s.cobbles"        "s.rocks"
## [17] "s.bedrock"        "h.macroph"        "h.grass"          "h.subveg"
## [21] "h.overhveg"       "h.litter"         "h.filalgae"       "h.attalgae"
## [25] "h.roots"          "h.smldeb"         "h.lrgdeb"
## [1] "g.river_length" "g.altitude"      "m.depth_mar"      "m.depth_max"
## [5] "m.slope"          "m.width"          "q.w_vel"          "q.temp"
## [9] "q.do"             "q.turb"           "s.mud"            "s.sand"
## [13] "s.rocks"          "h.macroph"        "h.grass"          "h.subveg"
## [17] "h.overhveg"       "h.litter"         "h.roots"          "s.gravel"
## [21] "h.algae"          "h.debris"
##          g.river_length g.altitude m.depth_mar m.depth_max m.slope m.width
## S-R-CI-1      83.0500      169      22.666667      60      60      17.24
## S-R-CI-2      83.0500      169      32.666667      68      60      18.47
## S-R-CI-3      83.0500      169      32.666667      79      60      15.10
## S-R-CI-4      83.0500      169      45.333333      64      60      10.70
## B-A-SA-1     212.6667      713       8.166667      60      30     330.00
## B-A-SA-2     212.6667      713       7.000000      69      30     321.00
## B-A-SA-3     212.6667      713       6.833333      68      30     314.20
## B-A-SA-4     212.6667      713       4.666667      63      30     289.50
## B-A-MU-2     214.0200      725      22.000000     115      30     247.63
## B-A-MU-3     214.0200      725      25.666667     117      30     234.53
## B-A-MU-4     214.0200      725      41.333333     112      30     239.00
## B-R-EP-2     196.8333      402      49.333333     110      90      29.60
## B-R-EP-3     196.8333      402      50.000000      80      90      27.30
## B-R-EP-4     196.8333      402      52.833333      95      90      20.00
## S-A-RE-1     110.2000      270      54.666667     154      60     102.00
## S-A-RE-2     110.2000      270      37.666667     118      60     100.00
## S-A-RE-3     110.2000      270      22.333333     109      60      88.00
## S-A-RE-4     110.2000      270      30.333333      87      60      72.20
## S-R-SE-1     163.2000      226      81.333333     106      30      19.64
## S-R-SE-2     163.2000      226      67.000000     105      30      16.10
## S-R-SE-3     163.2000      226      32.333333     110      30       6.20

```

## S-R-SE-4	163.2000	226	32.333333	74	30	5.40	
##	q.w_vel	q.temp	q.do	q.turb	s.mud	s.sand	s.rocks
## S-R-CI-1	0.1591512	35.20000	6.863333	26.00000	16.6666667	70.000000	0.000000
## S-R-CI-2	0.0000000	29.00000	3.015000	33.00000	0.6666667	87.666667	0.000000
## S-R-CI-3	0.0000000	29.66667	5.000000	50.33333	48.7500000	22.500000	0.000000
## S-R-CI-4	0.0000000	27.60000	4.900000	60.00000	5.0000000	60.000000	10.000000
## B-A-SA-1	0.0000000	29.23333	5.136667	25.66667	96.6666667	3.333333	0.000000
## B-A-SA-2	0.0000000	29.00000	1.850000	55.00000	98.0000000	2.000000	0.000000
## B-A-SA-3	0.0000000	24.00000	8.800000	51.66667	87.7777778	6.666667	0.000000
## B-A-SA-4	0.0000000	24.70000	8.750000	36.00000	95.1666667	3.416667	0.000000
## B-A-MU-2	0.0000000	29.00000	1.815000	43.00000	20.6000000	77.000000	0.000000
## B-A-MU-3	0.0000000	26.00000	5.700000	63.00000	65.0000000	35.000000	0.000000
## B-A-MU-4	0.0000000	25.95000	7.300000	89.00000	91.7777778	3.222222	5.000000
## B-R-EP-2	0.0000000	29.00000	5.635000	50.00000	39.0000000	56.000000	1.000000
## B-R-EP-3	0.0000000	29.00000	5.000000	32.33333	33.6666667	63.000000	0.000000
## B-R-EP-4	0.0000000	28.85000	5.100000	30.00000	48.8750000	47.875000	1.250000
## S-A-RE-1	0.1000000	34.00000	4.820000	61.00000	81.6666667	8.333333	8.333333
## S-A-RE-2	0.0000000	29.00000	5.000000	90.00000	5.0000000	95.000000	0.000000
## S-A-RE-3	0.0000000	34.00000	9.000000	51.66667	46.6666667	40.000000	0.000000
## S-A-RE-4	0.0000000	29.53333	9.433333	67.00000	59.1428571	38.714286	0.000000
## S-R-SE-1	0.1666667	32.90000	6.510000	46.00000	65.0000000	30.000000	3.333333
## S-R-SE-2	0.1250000	32.00000	5.375000	44.00000	40.0000000	40.000000	0.000000
## S-R-SE-3	0.0000000	28.26667	6.000000	17.33333	65.5555556	23.111111	8.333333
## S-R-SE-4	0.0000000	32.60000	6.000000	16.00000	95.0000000	1.833333	2.833333
##	h.macroph	h.grass	h.subveg	h.overhveg	h.litter	h.roots	
## S-R-CI-1	0.0000000	23.3333333	3.000000	26.666667	2.3333333	3.333333	
## S-R-CI-2	0.0000000	0.0000000	0.000000	33.333333	1.0000000	5.000000	
## S-R-CI-3	0.0000000	0.0000000	0.000000	0.000000	1.5000000	1.000000	
## S-R-CI-4	0.0000000	0.0000000	0.000000	8.333333	1.0000000	0.000000	
## B-A-SA-1	46.666667	0.0000000	3.333333	3.333333	0.0000000	0.000000	
## B-A-SA-2	2.600000	7.5000000	26.000000	0.400000	0.0000000	0.000000	
## B-A-SA-3	0.000000	13.3333333	0.000000	0.000000	0.0000000	0.000000	
## B-A-SA-4	2.083333	0.0000000	0.000000	0.000000	0.0000000	0.000000	
## B-A-MU-2	0.000000	54.0000000	36.600000	0.000000	5.0000000	0.000000	
## B-A-MU-3	0.000000	28.3333333	8.333333	0.000000	1.0000000	0.000000	
## B-A-MU-4	0.000000	5.5555556	0.000000	0.000000	0.4444444	0.000000	
## B-R-EP-2	0.000000	2.0000000	0.000000	0.000000	0.4000000	0.000000	
## B-R-EP-3	0.000000	0.0000000	0.000000	0.000000	0.3333333	0.000000	
## B-R-EP-4	0.000000	0.0000000	0.000000	0.000000	0.5000000	0.000000	
## S-A-RE-1	5.833333	0.0000000	16.666667	33.333333	3.6666667	0.000000	
## S-A-RE-2	54.833333	0.3333333	0.000000	8.333333	1.0000000	0.000000	
## S-A-RE-3	44.629630	8.1111111	0.000000	0.000000	0.6666667	0.000000	
## S-A-RE-4	37.309524	0.0000000	0.000000	0.000000	0.5714286	0.000000	
## S-R-SE-1	8.333333	20.0000000	10.000000	0.000000	0.6666667	0.000000	
## S-R-SE-2	0.000000	20.0000000	0.000000	0.000000	0.0000000	0.000000	
## S-R-SE-3	0.000000	0.1111111	0.000000	0.000000	0.0000000	0.000000	

```
## S-R-SE-4  0.000000  4.1666667  0.000000  0.000000  0.8333333  0.000000
##          s.gravel  h.algae  h.debris
## S-R-CI-1 13.3333333  4.0000000  3.6666667
## S-R-CI-2 11.6666667  0.0000000 10.3333333
## S-R-CI-3 28.7500000  6.7500000  3.6666667
## S-R-CI-4 25.0000000 75.0000000  1.0000000
## B-A-SA-1  0.0000000  0.0000000  0.0000000
## B-A-SA-2  0.0000000  1.0000000  0.0000000
## B-A-SA-3  5.5555556 25.0000000  0.0000000
## B-A-SA-4  1.4166667 43.3333333  3.7500000
## B-A-MU-2  2.4000000  0.0000000 10.0000000
## B-A-MU-3  0.0000000  0.3333333 11.6666667
## B-A-MU-4  0.0000000 30.0000000 10.4444444
## B-R-EP-2  4.0000000  0.4000000  0.4000000
## B-R-EP-3  3.3333333  0.0000000  0.4444444
## B-R-EP-4  2.0000000  0.0000000  2.5000000
## S-A-RE-1  1.6666667 28.3333333 10.0000000
## S-A-RE-2  0.0000000 33.3333330 13.6666667
## S-A-RE-3 13.3333333  9.0000000  1.6666667
## S-A-RE-4  2.1428571  0.0000000  3.2857143
## S-R-SE-1  1.6666667 12.0000000  3.3333333
## S-R-SE-2 20.0000000  1.0000000  0.0000000
## S-R-SE-3  3.0000000  0.0000000  2.2222222
## S-R-SE-4  0.3333333  7.5000000  5.0000000
```

15.3.0.2 Calculando a riqueza de espécies

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console

m_cont <- read.csv("m_cont.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)

m_cont

##RAREFAÇÃO BASEADA EM CONTAGEM----
library(vegan)
data <- m_cont
S <- specnumber(data) #observed number of species
S
```

```

#raremax <- min(rowSums(data))
raremax <- round(mean(rowSums(data)))
#raremax <- 1000
raremax
Srare <- rarefy(data, raremax)
Srare
plot(S, Srare, xlab = "Observed No. of Species", ylab = "Rarefied
  ↪ No. of Species")
abline(0, 1)
#png("fig-rarecurve.png")
rarecurve(data, step = 20, sample = raremax, col = "blue", cex =
  ↪ 0.6,
          xlab = "Sample size", ylab = "Taxa", xlim = c())
          ↪ #c(0,5000)
#dev.off()

##ANOVAS-----
anovas <- cbind(Srare = Srare, m_cont)
anovas <- anovas[,1, drop = FALSE]
anovas
m_dens <- read.csv("m_dens.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)

m_dens
anovas$dens <- rowMeans(m_dens, na.rm = TRUE)
anovas
S <- specnumber(m_dens)
anovas$S <- S
anovas

###CRIANDO GRUPOS-----
library(tidyverse)
anovas <- cbind(Grupos = rownames(anovas), anovas)
anovas
grps <- substr(anovas[, 1], 5,6)
grps
anovas <- mutate(anovas, Grupos = c(grps))
anovas

###SALVANDO MATRIZ FINAL ANOVAS-----
write.table(anovas, "t_anovas.csv",
            sep = ";", dec = ".", #"\t",
            row.names = TRUE,

```

```

        quote = TRUE,
        append = FALSE)
anovas <- read.csv("t_anovas.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)

anovas

```

```
## null device
```

```
##          1
```

```
##
```

	Hydrachnidia	Ampularidae	Atyidae	Baetidae	Belastomatidae	Caenidae
## S-R-CI-1	0		0	0	0	0
## S-R-CI-2	0		0	0	1	0
## S-R-CI-3	45		1	0	85	125
## S-R-CI-4	0		2	0	4	0
## B-A-SA-1	0		0	0	0	0
## B-A-SA-2	0		0	0	0	0
## B-A-SA-3	0		1	0	1	0
## B-A-SA-4	0		0	0	0	0
## B-A-MU-2	0		0	0	3	0
## B-A-MU-3	0		0	0	0	0
## B-A-MU-4	0		0	0	0	0
## B-R-EP-2	0		0	0	0	0
## B-R-EP-3	0		0	3	0	0
## B-R-EP-4	0		0	10	0	0
## S-A-RE-1	0		0	0	16	0
## S-A-RE-2	0		0	0	0	0
## S-A-RE-3	0		0	0	2	0
## S-A-RE-4	0		0	0	0	27
## S-R-SE-1	0		0	0	0	1
## S-R-SE-2	0		0	0	0	0
## S-R-SE-3	0		0	27	0	0
## S-R-SE-4	0		0	19	0	0
##	Ceratopogonidae	Coenagrionidae	Conchostraca	Corixidae	Curculionidae	
## S-R-CI-1	3		0	0	0	0
## S-R-CI-2	5		0	0	37	0
## S-R-CI-3	1		0	0	709	1
## S-R-CI-4	40		0	0	113	0
## B-A-SA-1	0		0	0	0	0
## B-A-SA-2	0		0	0	0	0
## B-A-SA-3	0		0	0	0	0
## B-A-SA-4	0		0	0	0	0

## B-A-MU-2	0	0	0	0	0
## B-A-MU-3	0	0	0	0	0
## B-A-MU-4	0	0	0	0	0
## B-R-EP-2	1	0	0	0	0
## B-R-EP-3	0	0	0	0	0
## B-R-EP-4	0	0	0	0	0
## S-A-RE-1	3	1	149	0	0
## S-A-RE-2	1	0	24	0	0
## S-A-RE-3	13	2	7	21	5
## S-A-RE-4	1	13	0	0	0
## S-R-SE-1	0	2	0	0	0
## S-R-SE-2	0	0	0	0	0
## S-R-SE-3	0	0	0	0	0
## S-R-SE-4	7	0	0	0	0
##	Chaoboridae	Chironomidae_L	Chironomidae_P	Dytiscidae_L	Dytiscidae_A
## S-R-CI-1	0	12	0	0	0
## S-R-CI-2	2	1291	84	0	3
## S-R-CI-3	0	2879	0	3	0
## S-R-CI-4	0	587	26	1	5
## B-A-SA-1	0	3	2	0	0
## B-A-SA-2	0	9	0	0	0
## B-A-SA-3	0	7	0	0	0
## B-A-SA-4	0	10	0	0	0
## B-A-MU-2	0	0	0	0	0
## B-A-MU-3	0	3	0	0	1
## B-A-MU-4	0	3	0	0	0
## B-R-EP-2	0	5	0	0	0
## B-R-EP-3	0	6	0	0	0
## B-R-EP-4	0	0	0	0	0
## S-A-RE-1	0	911	24	1	0
## S-A-RE-2	0	16	0	0	0
## S-A-RE-3	0	49	0	1	7
## S-A-RE-4	0	3	0	0	0
## S-R-SE-1	0	11	0	0	0
## S-R-SE-2	0	1	0	0	0
## S-R-SE-3	0	4	0	0	0
## S-R-SE-4	0	833	3	0	18
##	Gerridae	Gomphidae	Glossosomatidae	Hidrophilidae_L	Hidrophilide_A
## S-R-CI-1	0	0	0	0	7
## S-R-CI-2	2	6	0	0	0
## S-R-CI-3	0	3	3	181	2
## S-R-CI-4	0	16	3	40	1
## B-A-SA-1	0	0	0	0	0
## B-A-SA-2	0	0	0	0	0
## B-A-SA-3	0	1	0	0	0
## B-A-SA-4	0	0	0	0	0

## B-A-MU-2	0	0	0	0	0	
## B-A-MU-3	0	0	0	0	0	
## B-A-MU-4	0	0	0	0	0	
## B-R-EP-2	0	0	0	0	0	
## B-R-EP-3	0	1	0	0	0	
## B-R-EP-4	0	0	0	0	0	
## S-A-RE-1	0	0	0	1	7	
## S-A-RE-2	0	0	0	0	0	
## S-A-RE-3	0	0	0	6	51	
## S-A-RE-4	0	2	0	4	15	
## S-R-SE-1	0	1	0	1	0	
## S-R-SE-2	0	2	0	0	0	
## S-R-SE-3	0	0	0	0	0	
## S-R-SE-4	0	8	0	0	15	
##	Hirudinea Leptohiphidae Leptoceridae Libellulidae Lymnaeidae					
## S-R-CI-1	0	0	0	0	0	
## S-R-CI-2	0	0	0	0	0	
## S-R-CI-3	0	35	3	11	0	
## S-R-CI-4	0	0	0	80	0	
## B-A-SA-1	0	0	0	0	0	
## B-A-SA-2	0	0	0	0	0	
## B-A-SA-3	0	0	0	0	0	
## B-A-SA-4	0	0	0	0	0	
## B-A-MU-2	0	0	0	0	0	
## B-A-MU-3	0	0	0	0	0	
## B-A-MU-4	0	0	0	0	0	
## B-R-EP-2	0	0	0	0	0	
## B-R-EP-3	0	0	0	0	0	
## B-R-EP-4	0	0	0	0	0	
## S-A-RE-1	0	0	0	26	3	
## S-A-RE-2	0	0	0	16	0	
## S-A-RE-3	3	0	0	52	0	
## S-A-RE-4	5	0	0	54	0	
## S-R-SE-1	0	0	0	0	0	
## S-R-SE-2	0	0	0	0	0	
## S-R-SE-3	0	0	0	0	0	
## S-R-SE-4	0	0	0	0	0	
##	Naucoridae Notonectidae Oligochaeta Ostracoda Planorbidae Physidae					
## S-R-CI-1	0	0	3	0	5	0
## S-R-CI-2	0	14	1	0	2	0
## S-R-CI-3	0	12	2	0	222	0
## S-R-CI-4	0	17	0	0	38	0
## B-A-SA-1	0	0	0	0	0	0
## B-A-SA-2	0	0	2	0	0	0
## B-A-SA-3	0	0	1	0	4	0
## B-A-SA-4	0	0	0	0	2	0

##	B-A-MU-2	0	0	0	0	0	0
##	B-A-MU-3	0	0	0	0	0	0
##	B-A-MU-4	0	9	0	0	0	0
##	B-R-EP-2	0	0	125	0	0	0
##	B-R-EP-3	0	0	13	0	0	0
##	B-R-EP-4	0	0	0	0	1	0
##	S-A-RE-1	1	0	443	0	20	0
##	S-A-RE-2	0	0	1016	3	0	5
##	S-A-RE-3	11	11	950	127	18	20
##	S-A-RE-4	0	0	1462	0	151	5
##	S-R-SE-1	0	0	0	0	4	0
##	S-R-SE-2	0	0	0	0	0	0
##	S-R-SE-3	0	0	0	0	15	0
##	S-R-SE-4	1	3	0	0	235	0
##	Sphaeridae Thiaridae Veliidae						
##	S-R-CI-1	0	0	0			
##	S-R-CI-2	0	0	3			
##	S-R-CI-3	1	1	0			
##	S-R-CI-4	0	1	0			
##	B-A-SA-1	0	0	0			
##	B-A-SA-2	0	3	0			
##	B-A-SA-3	0	0	0			
##	B-A-SA-4	0	28	0			
##	B-A-MU-2	0	0	0			
##	B-A-MU-3	0	0	0			
##	B-A-MU-4	0	0	0			
##	B-R-EP-2	0	1259	0			
##	B-R-EP-3	0	422	0			
##	B-R-EP-4	0	1329	0			
##	S-A-RE-1	0	0	0			
##	S-A-RE-2	0	0	0			
##	S-A-RE-3	0	0	0			
##	S-A-RE-4	0	0	0			
##	S-R-SE-1	0	11	0			
##	S-R-SE-2	0	1264	0			
##	S-R-SE-3	0	4145	0			
##	S-R-SE-4	0	5689	0			
##	S-R-CI-1	S-R-CI-2	S-R-CI-3	S-R-CI-4	B-A-SA-1	B-A-SA-2	B-A-SA-3
##	5	13	21	16	2	3	6
##	B-A-MU-2	B-A-MU-3	B-A-MU-4	B-R-EP-2	B-R-EP-3	B-R-EP-4	S-A-RE-1
##	1	2	2	4	5	3	14
##	S-A-RE-3	S-A-RE-4	S-R-SE-1	S-R-SE-2	S-R-SE-3	S-R-SE-4	
##	20	12	7	3	4	11	
##	[1] 1280						
##	S-R-CI-1	S-R-CI-2	S-R-CI-3	S-R-CI-4	B-A-SA-1	B-A-SA-2	B-A-SA-3
##	5.000000	12.719603	15.057283	16.000000	2.000000	3.000000	6.000000
##							3.000000


```

## B-A-MU-2 B-A-MU-3 B-A-MU-4 B-R-EP-2 B-R-EP-3 B-R-EP-4 S-A-RE-1 S-A-RE-2
## 1.000000 2.000000 2.000000 3.920860 5.000000 2.955224 13.171426 7.000000
## S-A-RE-3 S-A-RE-4 S-R-SE-1 S-R-SE-2 S-R-SE-3 S-R-SE-4
## 19.932602 11.638514 7.000000 3.000000 3.763162 8.603085
## attr("Subsample")
## [1] 1280
##          Srare
## S-R-CI-1 5.000000
## S-R-CI-2 12.719603
## S-R-CI-3 15.057283
## S-R-CI-4 16.000000
## B-A-SA-1 2.000000
## B-A-SA-2 3.000000
## B-A-SA-3 6.000000
## B-A-SA-4 3.000000
## B-A-MU-2 1.000000
## B-A-MU-3 2.000000
## B-A-MU-4 2.000000
## B-R-EP-2 3.920860
## B-R-EP-3 5.000000
## B-R-EP-4 2.955224
## S-A-RE-1 13.171426
## S-A-RE-2 7.000000
## S-A-RE-3 19.932602
## S-A-RE-4 11.638514
## S-R-SE-1 7.000000
## S-R-SE-2 3.000000
## S-R-SE-3 3.763162
## S-R-SE-4 8.603085
##          Hydrachnidia Ampularidae Atyidae Baetidae Belastomatidae Caenidae
## S-R-CI-1          0.00 0.000000 0.00000 0.000000 0.000000 0.000000
## S-R-CI-2          0.00 0.000000 0.00000 2.083333 0.000000 0.000000
## S-R-CI-3        93.75 2.083333 0.00000 177.083333 0.000000 260.416667
## S-R-CI-4          0.00 4.166667 0.00000 8.333333 0.000000 0.000000
## B-A-SA-1          0.00 0.000000 0.00000 0.000000 0.000000 0.000000
## B-A-SA-2          0.00 0.000000 0.00000 0.000000 0.000000 0.000000
## B-A-SA-3          0.00 2.083333 0.00000 2.083333 0.000000 0.000000
## B-A-SA-4          0.00 0.000000 0.00000 0.000000 0.000000 0.000000
## B-A-MU-2          0.00 0.000000 0.00000 6.250000 0.000000 0.000000
## B-A-MU-3          0.00 0.000000 0.00000 0.000000 0.000000 0.000000
## B-A-MU-4          0.00 0.000000 0.00000 0.000000 0.000000 0.000000
## B-R-EP-2          0.00 0.000000 0.00000 0.000000 0.000000 0.000000
## B-R-EP-3          0.00 0.000000 6.25000 0.000000 0.000000 0.000000
## B-R-EP-4          0.00 0.000000 20.83333 0.000000 0.000000 0.000000
## S-A-RE-1          0.00 0.000000 0.00000 33.333333 0.000000 0.000000
## S-A-RE-2          0.00 0.000000 0.00000 0.000000 0.000000 0.000000

```

## S-A-RE-3	0.00	0.000000	0.00000	4.166667	4.166667	0.000000
## S-A-RE-4	0.00	0.000000	0.00000	0.000000	0.000000	56.250000
## S-R-SE-1	0.00	0.000000	0.00000	0.000000	0.000000	2.083333
## S-R-SE-2	0.00	0.000000	0.00000	0.000000	0.000000	0.000000
## S-R-SE-3	0.00	0.000000	56.25000	0.000000	0.000000	0.000000
## S-R-SE-4	0.00	0.000000	39.58333	0.000000	0.000000	0.000000
##	Ceratopogonidae	Coenagrionidae	Conchostraca	Corixidae	Curculionidae	
## S-R-CI-1	6.250000	0.000000	0.00000	0.00000	0.000000	
## S-R-CI-2	10.416667	0.000000	0.00000	77.08333	0.000000	
## S-R-CI-3	2.083333	0.000000	0.00000	1477.08333	2.083333	
## S-R-CI-4	83.333333	0.000000	0.00000	235.41667	0.000000	
## B-A-SA-1	0.000000	0.000000	0.00000	0.00000	0.000000	
## B-A-SA-2	0.000000	0.000000	0.00000	0.00000	0.000000	
## B-A-SA-3	0.000000	0.000000	0.00000	0.00000	0.000000	
## B-A-SA-4	0.000000	0.000000	0.00000	0.00000	0.000000	
## B-A-MU-2	0.000000	0.000000	0.00000	0.00000	0.000000	
## B-A-MU-3	0.000000	0.000000	0.00000	0.00000	0.000000	
## B-A-MU-4	0.000000	0.000000	0.00000	0.00000	0.000000	
## B-R-EP-2	2.083333	0.000000	0.00000	0.00000	0.000000	
## B-R-EP-3	0.000000	0.000000	0.00000	0.00000	0.000000	
## B-R-EP-4	0.000000	0.000000	0.00000	0.00000	0.000000	
## S-A-RE-1	6.250000	2.083333	310.41667	0.00000	0.000000	
## S-A-RE-2	2.083333	0.000000	50.00000	0.00000	0.000000	
## S-A-RE-3	27.083333	4.166667	14.58333	43.75000	10.416667	
## S-A-RE-4	2.083333	27.083333	0.00000	0.00000	0.000000	
## S-R-SE-1	0.000000	4.166667	0.00000	0.00000	0.000000	
## S-R-SE-2	0.000000	0.000000	0.00000	0.00000	0.000000	
## S-R-SE-3	0.000000	0.000000	0.00000	0.00000	0.000000	
## S-R-SE-4	14.583333	0.000000	0.00000	0.00000	0.000000	
##	Chaoboridae	Chironomidae_L	Chironomidae_P	Dytiscidae_L	Dytiscidae_A	
## S-R-CI-1	0.000000	25.000000	0.000000	0.000000	0.000000	
## S-R-CI-2	4.166667	2689.583333	175.000000	0.000000	6.250000	
## S-R-CI-3	0.000000	5997.916667	0.000000	6.250000	0.000000	
## S-R-CI-4	0.000000	1222.916667	54.166667	2.083333	10.416667	
## B-A-SA-1	0.000000	6.250000	4.166667	0.000000	0.000000	
## B-A-SA-2	0.000000	18.750000	0.000000	0.000000	0.000000	
## B-A-SA-3	0.000000	14.583333	0.000000	0.000000	0.000000	
## B-A-SA-4	0.000000	20.833333	0.000000	0.000000	0.000000	
## B-A-MU-2	0.000000	0.000000	0.000000	0.000000	0.000000	
## B-A-MU-3	0.000000	6.250000	0.000000	0.000000	2.083333	
## B-A-MU-4	0.000000	6.250000	0.000000	0.000000	0.000000	
## B-R-EP-2	0.000000	10.416667	0.000000	0.000000	0.000000	
## B-R-EP-3	0.000000	12.500000	0.000000	0.000000	0.000000	
## B-R-EP-4	0.000000	0.000000	0.000000	0.000000	0.000000	
## S-A-RE-1	0.000000	1897.916667	50.000000	2.083333	0.000000	
## S-A-RE-2	0.000000	33.333333	0.000000	0.000000	0.000000	

## S-A-RE-3	0.000000	102.083333	0.000000	2.083333	14.583333
## S-A-RE-4	0.000000	6.250000	0.000000	0.000000	0.000000
## S-R-SE-1	0.000000	22.916667	0.000000	0.000000	0.000000
## S-R-SE-2	0.000000	2.083333	0.000000	0.000000	0.000000
## S-R-SE-3	0.000000	8.333333	0.000000	0.000000	0.000000
## S-R-SE-4	0.000000	1735.416667	6.250000	0.000000	37.500000
##	Gerridae	Gomphidae	Glossosomatidae	Hidrophilidae_L	Hidrophilidae_A
## S-R-CI-1	0.000000	0.000000	0.00	0.000000	14.583333
## S-R-CI-2	4.166667	12.500000	0.00	0.000000	0.000000
## S-R-CI-3	0.000000	6.250000	6.25	377.083333	4.166667
## S-R-CI-4	0.000000	33.333333	6.25	83.333333	2.083333
## B-A-SA-1	0.000000	0.000000	0.00	0.000000	0.000000
## B-A-SA-2	0.000000	0.000000	0.00	0.000000	0.000000
## B-A-SA-3	0.000000	2.083333	0.00	0.000000	0.000000
## B-A-SA-4	0.000000	0.000000	0.00	0.000000	0.000000
## B-A-MU-2	0.000000	0.000000	0.00	0.000000	0.000000
## B-A-MU-3	0.000000	0.000000	0.00	0.000000	0.000000
## B-A-MU-4	0.000000	0.000000	0.00	0.000000	0.000000
## B-R-EP-2	0.000000	0.000000	0.00	0.000000	0.000000
## B-R-EP-3	0.000000	2.083333	0.00	0.000000	0.000000
## B-R-EP-4	0.000000	0.000000	0.00	0.000000	0.000000
## S-A-RE-1	0.000000	0.000000	0.00	2.083333	14.583333
## S-A-RE-2	0.000000	0.000000	0.00	0.000000	0.000000
## S-A-RE-3	0.000000	0.000000	0.00	12.500000	106.250000
## S-A-RE-4	0.000000	4.166667	0.00	8.333333	31.250000
## S-R-SE-1	0.000000	2.083333	0.00	2.083333	0.000000
## S-R-SE-2	0.000000	4.166667	0.00	0.000000	0.000000
## S-R-SE-3	0.000000	0.000000	0.00	0.000000	0.000000
## S-R-SE-4	0.000000	16.666667	0.00	0.000000	31.250000
##	Hirudinea	Leptohyphidae	Leptoceridae	Libellulidae	Lymnaeidae
## S-R-CI-1	0.000000	0.000000	0.00	0.000000	0.00
## S-R-CI-2	0.000000	0.000000	0.00	0.000000	0.00
## S-R-CI-3	0.000000	72.916667	6.25	22.916667	0.00
## S-R-CI-4	0.000000	0.000000	0.00	166.666667	0.00
## B-A-SA-1	0.000000	0.000000	0.00	0.000000	0.00
## B-A-SA-2	0.000000	0.000000	0.00	0.000000	0.00
## B-A-SA-3	0.000000	0.000000	0.00	0.000000	0.00
## B-A-SA-4	0.000000	0.000000	0.00	0.000000	0.00
## B-A-MU-2	0.000000	0.000000	0.00	0.000000	0.00
## B-A-MU-3	0.000000	0.000000	0.00	0.000000	0.00
## B-A-MU-4	0.000000	0.000000	0.00	0.000000	0.00
## B-R-EP-2	0.000000	0.000000	0.00	0.000000	0.00
## B-R-EP-3	0.000000	0.000000	0.00	0.000000	0.00
## B-R-EP-4	0.000000	0.000000	0.00	0.000000	0.00
## S-A-RE-1	0.000000	0.000000	0.00	54.166667	6.25
## S-A-RE-2	0.000000	0.000000	0.00	33.333333	0.00

##	S-A-RE-3	6.25000	0.00000	0.00	108.33333	0.00
##	S-A-RE-4	10.41667	0.00000	0.00	112.50000	0.00
##	S-R-SE-1	0.00000	0.00000	0.00	0.00000	0.00
##	S-R-SE-2	0.00000	0.00000	0.00	0.00000	0.00
##	S-R-SE-3	0.00000	0.00000	0.00	0.00000	0.00
##	S-R-SE-4	0.00000	0.00000	0.00	0.00000	0.00
##	Naucoridae Notonectidae Oligochaeta Ostracoda Planorbidae Physidae					
##	S-R-CI-1	0.000000	0.00000	6.250000	0.0000	10.416667
##	S-R-CI-2	0.000000	29.16667	2.083333	0.0000	4.166667
##	S-R-CI-3	0.000000	25.00000	4.166667	0.0000	462.500000
##	S-R-CI-4	0.000000	35.41667	0.000000	0.0000	79.166667
##	B-A-SA-1	0.000000	0.00000	0.000000	0.0000	0.000000
##	B-A-SA-2	0.000000	0.00000	4.166667	0.0000	0.000000
##	B-A-SA-3	0.000000	0.00000	2.083333	0.0000	8.333333
##	B-A-SA-4	0.000000	0.00000	0.000000	0.0000	4.166667
##	B-A-MU-2	0.000000	0.00000	0.000000	0.0000	0.000000
##	B-A-MU-3	0.000000	0.00000	0.000000	0.0000	0.000000
##	B-A-MU-4	0.000000	18.75000	0.000000	0.0000	0.000000
##	B-R-EP-2	0.000000	0.00000	260.416667	0.0000	0.000000
##	B-R-EP-3	0.000000	0.00000	27.083333	0.0000	0.000000
##	B-R-EP-4	0.000000	0.00000	0.000000	0.0000	2.083333
##	S-A-RE-1	2.083333	0.00000	922.916667	0.0000	41.666667
##	S-A-RE-2	0.000000	0.00000	2116.666667	6.2500	0.000000
##	S-A-RE-3	22.916667	22.91667	1979.166667	264.5833	37.500000
##	S-A-RE-4	0.000000	0.00000	3045.833333	0.0000	314.583333
##	S-R-SE-1	0.000000	0.00000	0.000000	0.0000	8.333333
##	S-R-SE-2	0.000000	0.00000	0.000000	0.0000	0.000000
##	S-R-SE-3	0.000000	0.00000	0.000000	0.0000	31.250000
##	S-R-SE-4	2.083333	6.25000	0.000000	0.0000	489.583333
##	Sphaeridae Thiaridae Veliidae					
##	S-R-CI-1	0.000000	0.000000	0.00		
##	S-R-CI-2	0.000000	0.000000	6.25		
##	S-R-CI-3	2.083333	2.083333	0.00		
##	S-R-CI-4	0.000000	2.083333	0.00		
##	B-A-SA-1	0.000000	0.000000	0.00		
##	B-A-SA-2	0.000000	6.250000	0.00		
##	B-A-SA-3	0.000000	0.000000	0.00		
##	B-A-SA-4	0.000000	58.333333	0.00		
##	B-A-MU-2	0.000000	0.000000	0.00		
##	B-A-MU-3	0.000000	0.000000	0.00		
##	B-A-MU-4	0.000000	0.000000	0.00		
##	B-R-EP-2	0.000000	2622.916667	0.00		
##	B-R-EP-3	0.000000	879.166667	0.00		
##	B-R-EP-4	0.000000	2768.750000	0.00		
##	S-A-RE-1	0.000000	0.000000	0.00		
##	S-A-RE-2	0.000000	0.000000	0.00		

##	S-A-RE-3	0.000000	0.000000	0.00
##	S-A-RE-4	0.000000	0.000000	0.00
##	S-R-SE-1	0.000000	22.916667	0.00
##	S-R-SE-2	0.000000	2633.333333	0.00
##	S-R-SE-3	0.000000	8635.416667	0.00
##	S-R-SE-4	0.000000	11852.083333	0.00
##		Scare	dens	
##	S-R-CI-1	5.000000	1.7857143	
##	S-R-CI-2	12.719603	86.3690476	
##	S-R-CI-3	15.057283	257.4404762	
##	S-R-CI-4	16.000000	57.9761905	
##	B-A-SA-1	2.000000	0.2976190	
##	B-A-SA-2	3.000000	0.8333333	
##	B-A-SA-3	6.000000	0.8928571	
##	B-A-SA-4	3.000000	2.3809524	
##	B-A-MU-2	1.000000	0.1785714	
##	B-A-MU-3	2.000000	0.2380952	
##	B-A-MU-4	2.000000	0.7142857	
##	B-R-EP-2	3.920860	82.7380952	
##	B-R-EP-3	5.000000	26.4880952	
##	B-R-EP-4	2.955224	79.7619048	
##	S-A-RE-1	13.171426	95.5952381	
##	S-A-RE-2	7.000000	64.3452381	
##	S-A-RE-3	19.932602	80.8333333	
##	S-A-RE-4	11.638514	103.6904762	
##	S-R-SE-1	7.000000	1.8452381	
##	S-R-SE-2	3.000000	75.4166667	
##	S-R-SE-3	3.763162	249.4642857	
##	S-R-SE-4	8.603085	406.6071429	
##		Scare	dens	S
##	S-R-CI-1	5.000000	1.7857143	5
##	S-R-CI-2	12.719603	86.3690476	13
##	S-R-CI-3	15.057283	257.4404762	21
##	S-R-CI-4	16.000000	57.9761905	16
##	B-A-SA-1	2.000000	0.2976190	2
##	B-A-SA-2	3.000000	0.8333333	3
##	B-A-SA-3	6.000000	0.8928571	6
##	B-A-SA-4	3.000000	2.3809524	3
##	B-A-MU-2	1.000000	0.1785714	1
##	B-A-MU-3	2.000000	0.2380952	2
##	B-A-MU-4	2.000000	0.7142857	2
##	B-R-EP-2	3.920860	82.7380952	4
##	B-R-EP-3	5.000000	26.4880952	5
##	B-R-EP-4	2.955224	79.7619048	3
##	S-A-RE-1	13.171426	95.5952381	14
##	S-A-RE-2	7.000000	64.3452381	7

```

## S-A-RE-3 19.932602 80.8333333 20
## S-A-RE-4 11.638514 103.6904762 12
## S-R-SE-1 7.000000 1.8452381 7
## S-R-SE-2 3.000000 75.4166667 3
## S-R-SE-3 3.763162 249.4642857 4
## S-R-SE-4 8.603085 406.6071429 11
##          Grupos      Srare      dens  S
## S-R-CI-1 S-R-CI-1 5.000000 1.7857143 5
## S-R-CI-2 S-R-CI-2 12.719603 86.3690476 13
## S-R-CI-3 S-R-CI-3 15.057283 257.4404762 21
## S-R-CI-4 S-R-CI-4 16.000000 57.9761905 16
## B-A-SA-1 B-A-SA-1 2.000000 0.2976190 2
## B-A-SA-2 B-A-SA-2 3.000000 0.8333333 3
## B-A-SA-3 B-A-SA-3 6.000000 0.8928571 6
## B-A-SA-4 B-A-SA-4 3.000000 2.3809524 3
## B-A-MU-2 B-A-MU-2 1.000000 0.1785714 1
## B-A-MU-3 B-A-MU-3 2.000000 0.2380952 2
## B-A-MU-4 B-A-MU-4 2.000000 0.7142857 2
## B-R-EP-2 B-R-EP-2 3.920860 82.7380952 4
## B-R-EP-3 B-R-EP-3 5.000000 26.4880952 5
## B-R-EP-4 B-R-EP-4 2.955224 79.7619048 3
## S-A-RE-1 S-A-RE-1 13.171426 95.5952381 14
## S-A-RE-2 S-A-RE-2 7.000000 64.3452381 7
## S-A-RE-3 S-A-RE-3 19.932602 80.8333333 20
## S-A-RE-4 S-A-RE-4 11.638514 103.6904762 12
## S-R-SE-1 S-R-SE-1 7.000000 1.8452381 7
## S-R-SE-2 S-R-SE-2 3.000000 75.4166667 3
## S-R-SE-3 S-R-SE-3 3.763162 249.4642857 4
## S-R-SE-4 S-R-SE-4 8.603085 406.6071429 11
## [1] "CI" "CI" "CI" "CI" "SA" "SA" "SA" "SA" "MU" "MU" "MU" "EP" "EP" "EP" "RE"
## [16] "RE" "RE" "RE" "SE" "SE" "SE" "SE"
##          Grupos      Srare      dens  S
## S-R-CI-1      CI 5.000000 1.7857143 5
## S-R-CI-2      CI 12.719603 86.3690476 13
## S-R-CI-3      CI 15.057283 257.4404762 21
## S-R-CI-4      CI 16.000000 57.9761905 16
## B-A-SA-1      SA 2.000000 0.2976190 2
## B-A-SA-2      SA 3.000000 0.8333333 3
## B-A-SA-3      SA 6.000000 0.8928571 6
## B-A-SA-4      SA 3.000000 2.3809524 3
## B-A-MU-2      MU 1.000000 0.1785714 1
## B-A-MU-3      MU 2.000000 0.2380952 2
## B-A-MU-4      MU 2.000000 0.7142857 2
## B-R-EP-2      EP 3.920860 82.7380952 4
## B-R-EP-3      EP 5.000000 26.4880952 5
## B-R-EP-4      EP 2.955224 79.7619048 3

```

```
## S-A-RE-1      RE 13.171426  95.5952381 14
## S-A-RE-2      RE  7.000000  64.3452381  7
## S-A-RE-3      RE 19.932602  80.8333333 20
## S-A-RE-4      RE 11.638514 103.6904762 12
## S-R-SE-1      SE  7.000000   1.8452381  7
## S-R-SE-2      SE  3.000000  75.4166667  3
## S-R-SE-3      SE  3.763162 249.4642857  4
## S-R-SE-4      SE  8.603085 406.6071429 11
##              Grupos      Srare      dens  S
## S-R-CI-1      CI  5.000000   1.7857143  5
## S-R-CI-2      CI 12.719603  86.3690476 13
## S-R-CI-3      CI 15.057283 257.4404762 21
## S-R-CI-4      CI 16.000000  57.9761905 16
## B-A-SA-1      SA  2.000000   0.2976190  2
## B-A-SA-2      SA  3.000000   0.8333333  3
## B-A-SA-3      SA  6.000000   0.8928571  6
## B-A-SA-4      SA  3.000000   2.3809524  3
## B-A-MU-2      MU  1.000000   0.1785714  1
## B-A-MU-3      MU  2.000000   0.2380952  2
## B-A-MU-4      MU  2.000000   0.7142857  2
## B-R-EP-2      EP  3.920860  82.7380952  4
## B-R-EP-3      EP  5.000000  26.4880952  5
## B-R-EP-4      EP  2.955224  79.7619048  3
## S-A-RE-1      RE 13.171426  95.5952381 14
## S-A-RE-2      RE  7.000000  64.3452381  7
## S-A-RE-3      RE 19.932602  80.8333333 20
## S-A-RE-4      RE 11.638514 103.6904762 12
## S-R-SE-1      SE  7.000000   1.8452381  7
## S-R-SE-2      SE  3.000000  75.4166667  3
## S-R-SE-3      SE  3.763162 249.4642857  4
## S-R-SE-4      SE  8.603085 406.6071429 11
```

15.3.0.3 Organizando variáveis de interesse

Cada linha deve representar uma observação e cada coluna uma variável.

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console

library(tidyverse)
library(caret)
library(leaps)
library(MASS)
```

```

anovas <- read.csv("t_anovas.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)
m_hab_part <- read.csv("m_hab_part.csv",
                      sep = ";", dec = ".",
                      row.names = 1,
                      header = TRUE,
                      na.strings = NA)

# Selecionamos colunas começando com "m."
colnames(m_hab_part)
vars <- grep("^m\\.", colnames(m_hab_part), value = TRUE)
  ↪ #^(g|m) mais de uma inicial
vars
m_vars <- sqrt((m_hab_part[, vars])) #TRANSFORMAÇÃO
m_vars
dados <- cbind(Srare = anovas$Srare, m_vars)
dados

```

```

## null device
##          1
##
## [1] "g.river_length" "g.altitude"      "m.depth_mar"      "m.depth_max"
## [5] "m.slope"         "m.width"          "q.w_vel"          "q.temp"
## [9] "q.do"            "q.turb"           "s.mud"            "s.sand"
## [13] "s.rocks"         "h.macroph"        "h.grass"          "h.subveg"
## [17] "h.overhveg"      "h.litter"         "h.roots"          "s.gravel"
## [21] "h.algae"         "h.debris"
## [1] "m.depth_mar" "m.depth_max" "m.slope"         "m.width"
##          m.depth_mar m.depth_max m.slope m.width
## S-R-CI-1  4.760952   7.745967 7.745967 4.152108
## S-R-CI-2  5.715476   8.246211 7.745967 4.297674
## S-R-CI-3  5.715476   8.888194 7.745967 3.885872
## S-R-CI-4  6.733003   8.000000 7.745967 3.271085
## B-A-SA-1  2.857738    7.745967 5.477226 18.165902
## B-A-SA-2  2.645751   8.306624 5.477226 17.916473
## B-A-SA-3  2.614065   8.246211 5.477226 17.725688
## B-A-SA-4  2.160247   7.937254 5.477226 17.014700
## B-A-MU-2  4.690416  10.723805 5.477226 15.736264
## B-A-MU-3  5.066228  10.816654 5.477226 15.314372
## B-A-MU-4  6.429101  10.583005 5.477226 15.459625

```



```

## B-R-EP-2      7.023769    10.488088 9.486833  5.440588
## B-R-EP-3      7.071068     8.944272 9.486833  5.224940
## B-R-EP-4      7.268654     9.746794 9.486833  4.472136
## S-A-RE-1      7.393691    12.409674 7.745967 10.099505
## S-A-RE-2      6.137318    10.862780 7.745967 10.000000
## S-A-RE-3      4.725816    10.440307 7.745967  9.380832
## S-A-RE-4      5.507571     9.327379 7.745967  8.497058
## S-R-SE-1      9.018500    10.295630 5.477226  4.431704
## S-R-SE-2      8.185353    10.246951 5.477226  4.012481
## S-R-SE-3      5.686241    10.488088 5.477226  2.489980
## S-R-SE-4      5.686241     8.602325 5.477226  2.323790
##              Srare m.depth_mar m.depth_max m.slope  m.width
## S-R-CI-1    5.000000     4.760952    7.745967 7.745967  4.152108
## S-R-CI-2   12.719603     5.715476     8.246211 7.745967  4.297674
## S-R-CI-3   15.057283     5.715476     8.888194 7.745967  3.885872
## S-R-CI-4   16.000000     6.733003     8.000000 7.745967  3.271085
## B-A-SA-1    2.000000     2.857738     7.745967 5.477226 18.165902
## B-A-SA-2    3.000000     2.645751     8.306624 5.477226 17.916473
## B-A-SA-3    6.000000     2.614065     8.246211 5.477226 17.725688
## B-A-SA-4    3.000000     2.160247     7.937254 5.477226 17.014700
## B-A-MU-2    1.000000     4.690416    10.723805 5.477226 15.736264
## B-A-MU-3    2.000000     5.066228    10.816654 5.477226 15.314372
## B-A-MU-4    2.000000     6.429101    10.583005 5.477226 15.459625
## B-R-EP-2    3.920860     7.023769    10.488088 9.486833  5.440588
## B-R-EP-3    5.000000     7.071068     8.944272 9.486833  5.224940
## B-R-EP-4    2.955224     7.268654     9.746794 9.486833  4.472136
## S-A-RE-1   13.171426     7.393691    12.409674 7.745967 10.099505
## S-A-RE-2    7.000000     6.137318    10.862780 7.745967 10.000000
## S-A-RE-3   19.932602     4.725816    10.440307 7.745967  9.380832
## S-A-RE-4   11.638514     5.507571     9.327379 7.745967  8.497058
## S-R-SE-1    7.000000     9.018500    10.295630 5.477226  4.431704
## S-R-SE-2    3.000000     8.185353    10.246951 5.477226  4.012481
## S-R-SE-3    3.763162     5.686241    10.488088 5.477226  2.489980
## S-R-SE-4    8.603085     5.686241     8.602325 5.477226  2.323790

```

15.4 Regressão Multipla Simultânea

Na regressão múltipla simultânea, tentamos responder a pergunta:

- (1) Qual contribuição as variáveis morfológicas oferecem para a previsão da riqueza de espécies?

Para isso testamos a hipótese de:

H_0 : nenhuma das variáveis explicativas está associada à variável resposta.

H_1 : pelo menos uma das variáveis explicativas está associada à variável resposta.

No R, implementamos o modelo de RMS usando a fórmula:


$$y \sim x_1 + x_2 + x_3$$

onde,

a primeira coluna da matriz de dados representa a variável resposta y e as demais colunas representam as variáveis preditoras x . Para isso, usamos a função `lm()`

```
colnames(dados)
modelo <- lm(Srare ~ m.depth_mar + m.depth_max + m.slope +
  ↪ m.width,
             data = dados)
par(mfrow=c(2,2))
plot(modelo)
summary(modelo)
```

```
## [1] "Srare"          "m.depth_mar" "m.depth_max" "m.slope"      "m.width"
##
## Call:
## lm(formula = Srare ~ m.depth_mar + m.depth_max + m.slope + m.width,
##     data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.9250 -3.1546 -0.8167  3.3069 10.4837
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   5.1795     10.8307   0.478   0.639
## m.depth_mar  -1.2540      1.2626  -0.993   0.335
## m.depth_max   0.7514      1.2572   0.598   0.558
## m.slope        0.9270      0.8668   1.069   0.300
## m.width       -0.5149      0.3466  -1.486   0.156
##
## Residual standard error: 5.219 on 17 degrees of freedom
## Multiple R-squared:  0.244, Adjusted R-squared:  0.06611
## F-statistic: 1.372 on 4 and 17 DF,  p-value: 0.2852
```



`plot(modelo)` demonstra o **diagnóstico dos resíduos**, onde são produzidos os gráficos de **resíduos × valores ajustados**, que verifica homocedasticidade (ideal sem padrão), o **q-q plot** dos resíduos, que verifica normalidade (ver Capítulo Estatísticas descritivas e normalidade). Nesse caso os pontos devem seguir aproximadamente a reta. O gráfico de **scale-location** também avalia homocedasticidade e o gráfico de **resíduos × alavancagem** identifica observações influentes.

Sobre o modelo ajustado, temos a **equação**:

$$S_{rare} = \beta_0 + \beta_1(m.depth_mar) + \beta_2(m.depth_max) + \beta_3(m.slope) + \beta_4(m.width) + \varepsilon$$

onde:

- Variável resposta: S_{rare}
- Variáveis explicativas:
 - $m.depth_mar$
 - $m.depth_max$
 - $m.slope$
 - $m.width$

Portanto, a equação usada para prever S_{rare} seria:

$$\widehat{S_{rare}} = 5.1795 - 1.2540(m.depth_mar) + 0.7514(m.depth_max) + 0.9270(m.slope) - 0.5149(m.width)$$

Observando os **resíduos**, temos um resumo dos erros do modelo (melhor observado nos gráficos anteriores) com, idealmente, uma mediana próxima de zero e distribuição aproximadamente simétrica. Isso deve ser confirmado pelos gráficos dos resíduos.

Além da **tabela de coeficientes**, temos o intercepto (*Estimate*), erro padrão residual, r^2 , r^2 ajustado, teste F e valor de p.

Sobre os **coeficientes**, o *estimate* = 5.18, é o valor esperado de S_{rare} quando todas as variáveis são iguais a zero. Como profundidade, largura e declividade iguais a zero não fazem sentido ecologicamente, normalmente o intercepto não é interpretado.

$m.depth_mar$: *Estimate* = -1.254, mantendo todas as outras variáveis constantes, um aumento de 1 unidade em $m.depth_mar$, reduz a riqueza rarefeita em aproximadamente 1,25 espécies. Entretanto, $p = 0.335$ não é significativo, logo, não há evidência estatística de que essa variável explique a riqueza.

O mesmo se aplica as demais variáveis.

$m.width$: *Estimate* = -0.515, para cada unidade adicional de largura, a riqueza diminui cerca de 0,52 espécies. Foi a variável mais próxima da significância com $p = 0.156$.

O **erro padrão residual** de 5.219 (para 17 graus de liberdade), significa que em média, as previsões do modelo erram em aproximadamente 5,2 espécies. Quanto menor esse valor, melhor.

O r^2 múltiplo de 0.244, significa que o modelo explica 24,4% da variação observada em S_{rare} . Ou seja, aproximadamente 75% da variação continua sem explicação.

Isso indica um ajuste relativamente fraco.

O r^2 ajustado de 0.066 é o valor mais importante. Após penalizar o modelo pelo número de variáveis, restam apenas 6,6% da variação realmente explicada. Isso mostra que adicionar quatro variáveis praticamente não melhorou o modelo.

Por fim, o **teste F** de 1.372 com $p = 0.2852$, verifica a hipótese de:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$$

ou seja, nenhuma variável explica a riqueza.

Contra a hipótese alternativa de:

$$H_1 : \beta_1 \neq 0 \text{ ou } \beta_2 \neq 0 \text{ ou } \beta_3 \neq 0 \text{ ou } \beta_4 \neq 0$$

onde, pelo menos um dos coeficientes β é diferente de 0, pelo menos uma variável explica a riqueza.

Como, $p = 0.285$ não rejeitamos H_0 .

Portanto, o modelo como um todo não é estatisticamente significativo.

O QUE REPORTAR: O modelo de regressão múltipla simultânea não foi significativo ($F = 1,37$; $p = 0,285$), explicando apenas 24,4% da variação da riqueza rarefeita ($r^2 = 0,244$; r^2 ajustado = 0,066). Nenhuma das variáveis ambientais avaliadas (m.depth_mar, m.depth_max, m.slope e m.width) apresentou efeito significativo sobre a riqueza rarefeita (todos os $p > 0,05$), indicando que, para este conjunto de dados, essas variáveis não explicam de forma consistente a variação observada em Sr_{are} .

Verificamos agora a multicolinearidade, usando a função `vif()` do pacote `library(car)`

```
library(car)
vif(modelo)
```

```
## m.depth_mar m.depth_max      m.slope      m.width
##      4.123894      2.074864      1.324621      3.167376
```

A função `vif(modelo)` do pacote `library(car)` calcula o VIF (*Variance Inflation Factor*), ou Fator de Inflação da Variância. O objetivo do VIF é verificar se existe multicolinearidade entre as variáveis explicativas, isto é, se uma variável pode ser explicada pelas demais (FOX; WEISBERG, 2019).

O VIF é calculado para cada variável explicativa, e o R ajusta uma regressão em que ela é a variável resposta e as outras variáveis são as preditoras.

Por exemplo, para m.depth_mar, o R ajusta:

```
m.depth_mar ~ m.depth_max + m.slope + m.width
```

Obtém-se o coeficiente de determinação dessa regressão (R^2) calculando-se:

$$VIF = \frac{1}{1 - r^2}$$

Quanto maior o r^2 , maior será o VIF. Isso significa que a variável é bem explicada pelas demais, indicando multicolinearidade.

Para os resultados de VIF de m.depth_mar = 4.123894, m.depth_max = 2.074864, m.slope = 1.324621 e m.width = 3.167376, temos por exemplo:

m.depth_mar (VIF = 4.12) é a variável mais correlacionada com as outras. Isso significa que o erro padrão do seu coeficiente é aproximadamente 4.12, ou:

$$\sqrt{4.12} = 2.03$$

vezes maior do que seria se não existisse correlação entre as variáveis. Ainda assim, esse valor não é considerado problemático (FOX; WEISBERG, 2019).

VIF	Interpretação
1	Nenhuma multicolinearidade
1–2	Multicolinearidade muito baixa
2–5	Multicolinearidade moderada, geralmente aceitável
> 5	Multicolinearidade alta, merece atenção
> 10	Multicolinearidade muito alta, normalmente problemática

Portanto, não há evidências de multicolinearidade severa entre as variáveis explicativas. Assim, o fato de nenhuma variável ter sido significativa ($p > 0,05$) provavelmente não é consequência da multicolinearidade, mas sim porque, para este conjunto de dados, essas variáveis realmente apresentam pouca capacidade de explicar a variação de *Srare*.

O QUE REPORTAR: A multicolinearidade entre as variáveis explicativas foi avaliada pelo Fator de Inflação da Variância (VIF). Todos os valores de VIF foram inferiores a 5 (1,32–4,12), indicando ausência de multicolinearidade entre os preditores e sugerindo que as estimativas dos coeficientes não foram substancialmente afetadas pela correlação entre as variáveis independentes.

15.5 Regressão Múltipla Hierárquica

Na regressão múltipla hierárquica, respondemos a pergunta:

- (2) Qual variável morfológica é a melhor preditora da riqueza de espécies?

Nesse caso, as variáveis são inseridas em blocos, definidos a priori com base em uma hipótese biológica ou teórica. O objetivo é verificar quanto cada bloco acrescenta ao poder explicativo do modelo.

No R, ela é implementada ajustando vários modelos com `lm()` e comparando-os.

Podemos testar:

Bloco 1: características morfológicas associadas a profundidade - m.depth_mar - m.depth_max

Bloco 2: acrescentamos a variável associada ao declive da margem - m.slope

Bloco 3: acrescentamos a variável largura - m.width

```

#Modelo 1
modelo1 <- lm(Srare ~ m.depth_mar + m.depth_max,
              data = dados)

#Modelo 2
modelo2 <- lm(Srare ~ m.depth_mar + m.depth_max +
              m.slope,
              data = dados)

#Modelo 3
modelo3 <- lm(Srare ~ m.depth_mar + m.depth_max +
              m.slope +
              m.width,
              data = dados)

```

15.5.0.1 Comparando os modelos

A principal comparação é feita com a função `anova()`.

```

anova(modelo1, modelo2, modelo3)
anova(modelo1); summary(modelo1)
anova(modelo2); summary(modelo2)
anova(modelo3); summary(modelo3)

```

```

## Analysis of Variance Table
##
## Model 1: Srare ~ m.depth_mar + m.depth_max
## Model 2: Srare ~ m.depth_mar + m.depth_max + m.slope
## Model 3: Srare ~ m.depth_mar + m.depth_max + m.slope + m.width
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      19 586.89
## 2      18 523.07  1    63.826 2.3437 0.1442
## 3      17 462.96  1    60.106 2.2071 0.1557
## Analysis of Variance Table
##
## Response: Srare
##              Df Sum Sq Mean Sq F value Pr(>F)
## m.depth_mar   1  16.89  16.8921   0.5469 0.4686
## m.depth_max   1   8.59   8.5901   0.2781 0.6041
## Residuals    19 586.89  30.8890
##
## Call:
## lm(formula = Srare ~ m.depth_mar + m.depth_max, data = dados)
##

```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.401 -3.766 -2.436  3.713 14.105
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   8.5276     8.9970   0.948   0.355
## m.depth_mar   0.7114     0.7844   0.907   0.376
## m.depth_max  -0.5807     1.1011  -0.527   0.604
##
## Residual standard error: 5.558 on 19 degrees of freedom
## Multiple R-squared:  0.04161,    Adjusted R-squared:  -0.05927
## F-statistic: 0.4125 on 2 and 19 DF,  p-value: 0.6678
##
## Analysis of Variance Table
##
## Response: Srare
##              Df Sum Sq Mean Sq F value Pr(>F)
## m.depth_mar   1  16.89   16.892   0.5813 0.4557
## m.depth_max   1   8.59    8.590   0.2956 0.5933
## m.slope        1  63.83   63.826   2.1964 0.1556
## Residuals    18 523.07   29.059
##
## Call:
## lm(formula = Srare ~ m.depth_mar + m.depth_max + m.slope, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -7.638 -3.186 -1.628  3.381 12.204
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -0.2265     10.5376  -0.021   0.983
## m.depth_mar   0.1794     0.8412   0.213   0.833
## m.depth_max  -0.2667     1.0888  -0.245   0.809
## m.slope       1.2771     0.8617   1.482   0.156
##
## Residual standard error: 5.391 on 18 degrees of freedom
## Multiple R-squared:  0.1458, Adjusted R-squared:  0.003479
## F-statistic: 1.024 on 3 and 18 DF,  p-value: 0.4052
##
## Analysis of Variance Table
##
## Response: Srare
##              Df Sum Sq Mean Sq F value Pr(>F)
## m.depth_mar   1  16.89   16.892   0.6203 0.4418
```



```
## m.depth_max 1 8.59 8.590 0.3154 0.5817
## m.slope 1 63.83 63.826 2.3437 0.1442
## m.width 1 60.11 60.106 2.2071 0.1557
## Residuals 17 462.96 27.233
##
## Call:
## lm(formula = Srare ~ m.depth_mar + m.depth_max + m.slope + m.width,
## data = dados)
##
## Residuals:
## Min 1Q Median 3Q Max
## -6.9250 -3.1546 -0.8167 3.3069 10.4837
##
## Coefficients:
## Estimate Std. Error t value Pr(>|t|)
## (Intercept) 5.1795 10.8307 0.478 0.639
## m.depth_mar -1.2540 1.2626 -0.993 0.335
## m.depth_max 0.7514 1.2572 0.598 0.558
## m.slope 0.9270 0.8668 1.069 0.300
## m.width -0.5149 0.3466 -1.486 0.156
##
## Residual standard error: 5.219 on 17 degrees of freedom
## Multiple R-squared: 0.244, Adjusted R-squared: 0.06611
## F-statistic: 1.372 on 4 and 17 DF, p-value: 0.2852
```

O QUE REPORTAR (MÉTODOS): Foi realizada uma regressão linear múltipla hierárquica, com as variáveis inseridas em blocos definidos *a priori*. Inicialmente foram incluídas as variáveis m.depth_mar e m.depth_max (Modelo 1). Em seguida foi adicionada m.slope (Modelo 2) e, por fim, m.width (Modelo 3). A contribuição de cada bloco foi avaliada por meio da comparação entre modelos utilizando o teste F (anova) e pelo coeficiente de determinação (R^2).

O QUE REPORTAR (RESULTADOS): Foi realizada uma regressão linear múltipla hierárquica para avaliar a contribuição incremental das variáveis morfométricas sobre a riqueza rarefeita (Srare). O Modelo 1, contendo m.depth_mar e m.depth_max, não foi estatisticamente significativo ($F_{2,19} = 0.41$, $p = 0.668$; $r^2 = 0.042$). A inclusão de m.slope no Modelo 2 aumentou o coeficiente de determinação para $r^2 = 0.146$, porém essa melhoria não foi significativa em relação ao Modelo 1 ($F_{1,18} = 2.34$, $p = 0.144$). Da mesma forma, a adição de m.width no Modelo 3 elevou o r^2 para 0.244, mas não promoveu melhora significativa do ajuste ($F_{1,17} = 2.21$, $p = 0.156$). O modelo final também não foi significativo ($F_{4,17} = 1.37$, $p = 0.285$).

Na regressão hierárquica, as hipóteses são testadas a cada etapa, isto é, para cada bloco de variáveis adicionado ao modelo.

Suponha os modelos:

Modelo 1: $Srare \sim m.depth_mar + m.depth_max$

Modelo 2: $Srare \sim m.depth_mar + m.depth_max + m.slope$

Ao comparar modelo1 e modelo2 com `anova(modelo1, modelo2)`, as hipóteses são:

Hipótese nula (H_0): O novo bloco não melhora o modelo.

Hipótese alternativa (H_1): O novo bloco melhora o modelo.

Ou seja, após considerar `m.depth_mar` e `m.depth_max`, a variável `m.slope` não acrescenta capacidade explicativa para `Srare`.

Portanto o teste F, responde à pergunta:

As variáveis adicionadas neste bloco aumentam significativamente o poder explicativo do modelo?

Se $p < 0,05$, rejeita-se H_0 : o bloco acrescenta informação ao modelo.

Se $p \geq 0,05$, não se rejeita H_0 : o bloco não melhora significativamente o modelo.

Diferentemente da **regressão múltipla simultânea**, em que o teste F avalia todo o conjunto de preditores, na **regressão hierárquica** cada teste F avalia apenas a contribuição adicional do bloco recém-incluído, mantendo fixas as variáveis que já estavam no modelo.

15.6 Regressão Múltipla *Stepwise*

- (3) Estudos anteriores sugerem que a largura influencia a riqueza de espécies. Essa hipótese é corroborada pelos dados analisados?

15.6.0.1 *Forward selection*

Na seleção progressiva (*forward selection*), inicia-se com um modelo nulo ($y \sim .$), que não contém variáveis preditoras (x). Em seguida, as variáveis são adicionadas ao modelo, uma de cada vez, de acordo com sua significância estatística, até que nenhuma nova variável contribua significativamente para melhorar o modelo.

```
# Initialize an empty model (with all predictors)
null_model <- lm(Srare ~., data = dados)
# Forward stepwise regression
modelo_for <- step(null_model, direction = "forward",
                  scope = list(lower = ~ 1, upper = ~ .),
                  k = 2) #AIC
summary(modelo_for)
```

```
## Start:  AIC=77.03
## Srare ~ m.depth_mar + m.depth_max + m.slope + m.width
##
##
## Call:
## lm(formula = Srare ~ m.depth_mar + m.depth_max + m.slope + m.width,
##     data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.9250 -3.1546 -0.8167  3.3069 10.4837
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   5.1795    10.8307   0.478   0.639
## m.depth_mar  -1.2540     1.2626  -0.993   0.335
## m.depth_max   0.7514     1.2572   0.598   0.558
## m.slope        0.9270     0.8668   1.069   0.300
## m.width       -0.5149     0.3466  -1.486   0.156
##
## Residual standard error: 5.219 on 17 degrees of freedom
## Multiple R-squared:  0.244, Adjusted R-squared:  0.06611
## F-statistic: 1.372 on 4 and 17 DF,  p-value: 0.2852
```

No código acima, utilizamos o conjunto de dados `dados`. Inicialmente, ajustamos um modelo nulo utilizando a função `lm()`, ou seja, um modelo que contém apenas o intercepto. Em seguida, aplicamos a função `step()` com o argumento `direction = "forward"` para realizar a seleção progressiva. O argumento `scope` define o intervalo de modelos que será considerado durante o processo de seleção. Nesse caso, `lower = ~ 1` representa o modelo nulo, enquanto `upper = ~ .` representa o modelo completo, contendo todas as variáveis preditoras disponíveis, exceto a variável resposta (`SRare`).

A função `step()` adiciona, de forma iterativa, as variáveis mais estatisticamente significativas ao modelo até encontrar o modelo considerado ótimo, de acordo com o critério de seleção especificado (como AIC ou BIC, *Bayesian Information Criterion*).

O critério utilizado é o *Akaike Information Criterion* (AIC). No `step()`, isso é controlado pelo argumento `k`:

- AIC: $k = 2$ (padrão)
- BIC: $k = \log(n)$, onde n é o número de observações

```
k = log(nrow(dados))
```

Depende do objetivo:

AIC: quando o foco é maximizar a capacidade preditiva do modelo. É o mais utilizado em problemas de previsão.

BIC: quando o objetivo é identificar o modelo mais simples que explica os dados. É mais conservador e tende a selecionar menos variáveis.



NOTA

O `step()` usa **AIC** (ou não p-valores para escolher as variáveis que entram no modelo final.

15.6.0.2 Backward elimination

Nesse método, começamos com um modelo que inclui todas as variáveis preditoras e, de forma iterativa, removemos a variável menos estatisticamente significativa a cada etapa, até que a remoção de novas variáveis deixe de melhorar o modelo.

```
# Initialize a model with all predictors
null_model <- lm(Srare ~., data = dados)
# Backward stepwise regression
modelo_back <- step(null_model, direction = "backward",
                    scope = list(lower = ~ 1, upper = ~ .),
                    k = 2) #AIC
summary(modelo_back)
```

```
## Start:  AIC=77.03
## Srare ~ m.depth_mar + m.depth_max + m.slope + m.width
##
##           Df Sum of Sq  RSS   AIC
## - m.depth_max 1    9.728 472.69 75.483
## - m.depth_mar 1   26.864 489.82 76.266
## - m.slope     1   31.148 494.11 76.458
## <none>                462.96 77.025
## - m.width     1   60.106 523.07 77.711
##
## Step:  AIC=75.48
## Srare ~ m.depth_mar + m.slope + m.width
##
##           Df Sum of Sq  RSS   AIC
## - m.depth_mar 1   17.894 490.58 74.300
## - m.slope     1   30.845 503.53 74.873
```

```
## <none>                                472.69 75.483
## - m.width      1      52.122 524.81 75.784
##
## Step:  AIC=74.3
## Srare ~ m.slope + m.width
##
##           Df Sum of Sq    RSS    AIC
## - m.slope  1     27.656 518.24 73.507
## - m.width  1     34.474 525.06 73.794
## <none>                                490.58 74.300
##
## Step:  AIC=73.51
## Srare ~ m.width
##
##           Df Sum of Sq    RSS    AIC
## <none>                                518.24 73.507
## - m.width  1     94.135 612.37 75.179
##
## Call:
## lm(formula = Srare ~ m.width, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.817  -3.523  -1.387   3.542  13.060
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.2693     2.0346   5.047 6.16e-05 ***
## m.width      -0.3621     0.1900  -1.906  0.0711 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.09 on 20 degrees of freedom
## Multiple R-squared:  0.1537, Adjusted R-squared:  0.1114
## F-statistic: 3.633 on 1 and 20 DF,  p-value: 0.07112
```

15.6.0.3 *Both-directions*

Na regressão bidirecional, o algoritmo combina as abordagens *forward* e *backward*, otimizando o modelo ao adicionar variáveis estatisticamente significativas e remover aquelas que não são significativas.

```
# Initialize a model with all predictors
null_model <- lm(Srare ~., data = dados)
```



```
# Both-direction stepwise regression
modelo_both <- step(null_model, direction = "both",
                    scope = list(lower = ~ 1, upper = ~ .),
                    k = 2) #AIC
summary(modelo_both)
```


```
## Start:  AIC=77.03
## Srare ~ m.depth_mar + m.depth_max + m.slope + m.width
##
##           Df Sum of Sq   RSS   AIC
## - m.depth_max 1     9.728 472.69 75.483
## - m.depth_mar 1    26.864 489.82 76.266
## - m.slope      1    31.148 494.11 76.458
## <none>                462.96 77.025
## - m.width      1    60.106 523.07 77.711
##
## Step:  AIC=75.48
## Srare ~ m.depth_mar + m.slope + m.width
##
##           Df Sum of Sq   RSS   AIC
## - m.depth_mar 1    17.894 490.58 74.300
## - m.slope      1    30.845 503.53 74.873
## <none>                472.69 75.483
## - m.width      1    52.122 524.81 75.784
## + m.depth_max  1     9.728 462.96 77.025
##
## Step:  AIC=74.3
## Srare ~ m.slope + m.width
##
##           Df Sum of Sq   RSS   AIC
## - m.slope      1    27.656 518.24 73.507
## - m.width      1    34.474 525.06 73.794
## <none>                490.58 74.300
## + m.depth_mar  1    17.894 472.69 75.483
## + m.depth_max  1     0.758 489.82 76.266
##
## Step:  AIC=73.51
## Srare ~ m.width
##
##           Df Sum of Sq   RSS   AIC
## <none>                518.24 73.507
## + m.slope      1    27.656 490.58 74.300
## + m.depth_mar  1    14.706 503.53 74.873
## - m.width      1    94.135 612.37 75.179
```

```
## + m.depth_max 1      0.391 517.85 75.490
##
## Call:
## lm(formula = Srare ~ m.width, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.817  -3.523  -1.387   3.542  13.060
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.2693     2.0346    5.047 6.16e-05 ***
## m.width      -0.3621     0.1900   -1.906  0.0711 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.09 on 20 degrees of freedom
## Multiple R-squared:  0.1537, Adjusted R-squared:  0.1114
## F-statistic: 3.633 on 1 and 20 DF,  p-value: 0.07112
```

15.6.0.4 Visualizando resíduos

```
# Resíduos para cada modelo
plot(modelo_for$residuals, main = "Forward Residuals", ylab =
  ↪ "Residuals")
plot(modelo_back$residuals, main = "Backward Residuals", ylab =
  ↪ "Residuals")
plot(modelo_both$residuals, main = "Both-Direction Residuals",
  ↪ ylab = "Residuals")
```

Forward Residuals**Backward Residuals**



15.6.0.5 Exemplo 3

15.6.0.6 Organizando variáveis de interesse

Cada linha deve representar uma observação e cada coluna uma variável.

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console

library(tidyverse)
library(caret)
library(leaps)
library(MASS)

anovas <- read.csv("t_anovas.csv",
  sep = ";", dec = ".",
  row.names = 1,
  header = TRUE,
  na.strings = NA)
m_hab_part <- read.csv("m_hab_part.csv",
  sep = ";", dec = ".",
  row.names = 1,
```

```

                                header = TRUE,
                                na.strings = NA)

# Selecionamos colunas começando com "m."
colnames(m_hab_part)
vars <- grep("^ (q)\\.\\.", colnames(m_hab_part), value = TRUE)
  ↪  #(g/m) mais de uma inicial
vars
m_vars <- sqrt((m_hab_part[, vars])) #TRANSFORMAÇÃO
m_vars
dados <- cbind(Srare = anovas$Srare, m_vars)
dados

## null device
##          1
##
## [1] "g.river_length" "g.altitude"      "m.depth_mar"      "m.depth_max"
## [5] "m.slope"           "m.width"          "q.w_vel"          "q.temp"
## [9] "q.do"              "q.turb"           "s.mud"            "s.sand"
## [13] "s.rocks"           "h.macrophyte"     "h.grass"          "h.subveg"
## [17] "h.overhveg"        "h.litter"         "h.roots"          "s.gravel"
## [21] "h.algae"           "h.debris"
## [1] "q.w_vel" "q.temp" "q.do"    "q.turb"
##          q.w_vel  q.temp    q.do    q.turb
## S-R-CI-1 0.3989376 5.932959 2.619796 5.099020
## S-R-CI-2 0.0000000 5.385165 1.736376 5.744563
## S-R-CI-3 0.0000000 5.446712 2.236068 7.094599
## S-R-CI-4 0.0000000 5.253570 2.213594 7.745967
## B-A-SA-1 0.0000000 5.406786 2.266422 5.066228
## B-A-SA-2 0.0000000 5.385165 1.360147 7.416198
## B-A-SA-3 0.0000000 4.898979 2.966479 7.187953
## B-A-SA-4 0.0000000 4.969909 2.958040 6.000000
## B-A-MU-2 0.0000000 5.385165 1.347219 6.557439
## B-A-MU-3 0.0000000 5.099020 2.387467 7.937254
## B-A-MU-4 0.0000000 5.094114 2.701851 9.433981
## B-R-EP-2 0.0000000 5.385165 2.373815 7.071068
## B-R-EP-3 0.0000000 5.385165 2.236068 5.686241
## B-R-EP-4 0.0000000 5.371220 2.258318 5.477226
## S-A-RE-1 0.3162278 5.830952 2.195450 7.810250
## S-A-RE-2 0.0000000 5.385165 2.236068 9.486833
## S-A-RE-3 0.0000000 5.830952 3.000000 7.187953
## S-A-RE-4 0.0000000 5.434458 3.071373 8.185353
## S-R-SE-1 0.4082483 5.735852 2.551470 6.782330
## S-R-SE-2 0.3535534 5.656854 2.318405 6.633250

```

```
## S-R-SE-3 0.0000000 5.316641 2.449490 4.163332
## S-R-SE-4 0.0000000 5.709641 2.449490 4.000000
##           Srare    q.w_vel    q.temp    q.do    q.turb
## S-R-CI-1  5.000000 0.3989376 5.932959 2.619796 5.099020
## S-R-CI-2 12.719603 0.0000000 5.385165 1.736376 5.744563
## S-R-CI-3 15.057283 0.0000000 5.446712 2.236068 7.094599
## S-R-CI-4 16.000000 0.0000000 5.253570 2.213594 7.745967
## B-A-SA-1  2.000000 0.0000000 5.406786 2.266422 5.066228
## B-A-SA-2  3.000000 0.0000000 5.385165 1.360147 7.416198
## B-A-SA-3  6.000000 0.0000000 4.898979 2.966479 7.187953
## B-A-SA-4  3.000000 0.0000000 4.969909 2.958040 6.000000
## B-A-MU-2  1.000000 0.0000000 5.385165 1.347219 6.557439
## B-A-MU-3  2.000000 0.0000000 5.099020 2.387467 7.937254
## B-A-MU-4  2.000000 0.0000000 5.094114 2.701851 9.433981
## B-R-EP-2  3.920860 0.0000000 5.385165 2.373815 7.071068
## B-R-EP-3  5.000000 0.0000000 5.385165 2.236068 5.686241
## B-R-EP-4  2.955224 0.0000000 5.371220 2.258318 5.477226
## S-A-RE-1 13.171426 0.3162278 5.830952 2.195450 7.810250
## S-A-RE-2  7.000000 0.0000000 5.385165 2.236068 9.486833
## S-A-RE-3 19.932602 0.0000000 5.830952 3.000000 7.187953
## S-A-RE-4 11.638514 0.0000000 5.434458 3.071373 8.185353
## S-R-SE-1  7.000000 0.4082483 5.735852 2.551470 6.782330
## S-R-SE-2  3.000000 0.3535534 5.656854 2.318405 6.633250
## S-R-SE-3  3.763162 0.0000000 5.316641 2.449490 4.163332
## S-R-SE-4  8.603085 0.0000000 5.709641 2.449490 4.000000
```

15.6.0.7 Treinando o modelo

Existem diversas funções e pacotes no R para realizar a regressão *stepwise*. Entre eles, destaca-se a função `stepAIC()`, disponível no pacote `MASS`, que seleciona o melhor modelo com base no **Critério de Informação de Akaike (AIC)**.

A função possui o argumento `direction`, que define a estratégia de seleção a ser utilizada (“both”, “backward” e “forward”).

```
# Ajuste do modelo completo
full.model <- lm(Srare ~., data = dados)
# Modelo de regressão stepwise
step.model <- stepAIC(full.model, direction = "both", #both,
  ↪ backward, forward
                        trace = FALSE)
summary(step.model)
```

```
##
```

```
## Call:
## lm(formula = Srare ~ q.w_vel + q.temp + q.do + q.turb, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.261  -2.745  -1.332   2.076   9.693
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -94.3966    29.2076  -3.232  0.00490 **
## q.w_vel       -19.9724     9.0431  -2.209  0.04122 *
## q.temp        16.1083     4.9672   3.243  0.00478 **
## q.do           3.2526     2.2062   1.474  0.15868
## q.turb         1.1461     0.7015   1.634  0.12070
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.558 on 17 degrees of freedom
## Multiple R-squared:  0.4233, Adjusted R-squared:  0.2876
## F-statistic: 3.119 on 4 and 17 DF,  p-value: 0.04274
```

A função `regsubsets()`, disponível no pacote `leaps`, também pode ser utilizada para realizar a seleção de variáveis. Ela possui o argumento `nvmax`, que especifica o número máximo de variáveis preditoras a serem incluídas no modelo.

Diferentemente da função `stepAIC()`, `regsubsets()` não retorna apenas um único modelo. Em vez disso, ela ajusta e retorna **vários modelos**, com diferentes números de variáveis preditoras, até o limite definido por `nvmax`. Assim, cabe ao usuário comparar o desempenho desses modelos para escolher o mais adequado.

A função `regsubsets()` também possui o argumento `method`, que pode assumir os valores “backward”, “forward” e “seqrep” (`seqrep` realiza a substituição sequencial (*sequential replacement*), combinando etapas de inclusão e remoção de variáveis durante o processo de seleção).

```
models <- regsubsets(Srare ~ ., data = dados, nvmax = 5, #maximal
  ↪ number of predictors to incorporate in the model
  method = "seqrep") #sequential replacement,
  ↪ combination of forward and backward
  ↪ selections
summary(models)
```

```
## Subset selection object
## Call: regsubsets.formula(Srare ~ ., data = dados, nvmax = 5, method = "seqrep")
```

```
## 4 Variables (and intercept)
##           Forced in Forced out
## q.w_vel   FALSE      FALSE
## q.temp    FALSE      FALSE
## q.do       FALSE      FALSE
## q.turb     FALSE      FALSE
## 1 subsets of each size up to 4
## Selection Algorithm: 'sequential replacement'
##           q.w_vel q.temp q.do q.turb
## 1 ( 1 ) " "      "*"    " " " "
## 2 ( 1 ) "*"     "*"    " " " "
## 3 ( 1 ) "*"     "*"    " " "*"
## 4 ( 1 ) "*"     "*"    "*"  "*"

```

Usamos a função `train()` do pacote `caret`, para um fluxo de trabalho simplificado para realizar a seleção de variáveis por meio dos pacotes `leaps` e `MASS`. Ela também possui o argumento `method` (“`leapBackward`”, “`leapForward`” e “`leapSeq`”).

Nesse caso, também é necessário especificar o parâmetro de ajuste `nvmax`, que corresponde ao número máximo de variáveis preditoras a serem incorporadas ao modelo. Por exemplo, é possível variar `nvmax` de 1 a 5. Nesse caso, a função busca os melhores modelos de diferentes tamanhos, até o melhor modelo com quatro variáveis.

Para avaliar o desempenho desses modelos, é utilizada a validação cruzada com 10 partições (*10-fold cross-validation*), estimando o erro médio de predição (**RMSE**) de cada um dos modelos. A métrica estatística RMSE é então utilizada para comparar os modelos e selecionar automaticamente o melhor, sendo considerado melhor aquele que apresenta o menor valor de RMSE.

```
# Train model
set.seed(123)
# set up repeated k-fold (number=10) cross-validation ("cv")
train.control <- trainControl(method = "cv", number = 10) #5,
  ↪ boot, LOOCV
# Train the model
step.model <- train(Srare ~., data = dados,
  method = "leapSeq", #leapBackward,
  ↪ leapForward, leapSeq
  tuneGrid = data.frame(nvmax = 1:4),
  trControl = train.control)
***You can't directly use two different data frames in train(),
  ↪ because train()
#(from caret package) expects all predictor (X) and response (Y)
  ↪ variables

```

```
#to be in the same data frame.
step.model$results
```

```
##      nvmax      RMSE Rsquared      MAE  RMSESD RsquaredSD      MAESD
## 1         1 5.089398 0.8435254 4.558268 2.024500 0.3335191 1.884537
## 2         2 5.461844 0.9013086 5.241949 1.734071 0.2053764 1.730369
## 3         3 5.163835 0.8914627 4.898494 2.135903 0.2559743 2.047153
## 4         4 4.853016 0.9294455 4.504808 2.148373 0.2034874 2.066347
```

Os resultados mostram diferentes métricas e seus respectivos desvios padrão, utilizadas para comparar a precisão dos melhores modelos. As colunas são:

- **nvmax**: número de variáveis presentes no modelo. Por exemplo, **nvmax** = 2 indica o melhor modelo contendo duas variáveis preditoras.
- **RMSE** e **MAE**: são duas métricas utilizadas para medir o erro de predição de cada modelo. Quanto menores os valores de RMSE e MAE, melhor é o desempenho do modelo. **R-quadrado (r^2)**: indica a correlação entre os valores observados da variável resposta e os valores preditos pelo modelo. Quanto maior o valor de (r^2), melhor o ajuste do modelo.

No exemplo apresentado, observa-se que o modelo com quatro variáveis (**nvmax** = 4) é o que apresenta o menor valor de RMSE.

Na sequência, obtemos Os melhores valores do parâmetro de ajuste (**nvmax**) selecionados automaticamente pela função **train()**, o melhor conjunto de variáveis para cada tamanho de modelo (função **summary()**), desde o melhor modelo com uma variável até o melhor modelo com quatro variáveis e os coeficientes de regressão do modelo final (**id** = 4).

```
step.model$bestTune
summary(step.model$finalModel)
nvmax <- step.model$bestTune$nvmax
nvmax
coef(step.model$finalModel, nvmax)
```

```
##      nvmax
## 4         4
## Subset selection object
## 4 Variables (and intercept)
##      Forced in Forced out
## q.w_vel      FALSE      FALSE
```

```
## q.temp      FALSE      FALSE
## q.do        FALSE      FALSE
## q.turb      FALSE      FALSE
## 1 subsets of each size up to 4
## Selection Algorithm: 'sequential replacement'
##           q.w_vel q.temp q.do q.turb
## 1  ( 1 ) " "      "*"      " " " "
## 2  ( 1 ) "*"      "*"      " " " "
## 3  ( 1 ) "*"      "*"      " " "*"
## 4  ( 1 ) "*"      "*"      "*" "*"
## [1] 4
## (Intercept)      q.w_vel      q.temp      q.do      q.turb
## -94.396637 -19.972427  16.108337   3.252551   1.146074
```

Esses resultados indicam que o melhor modelo é aquele com **nvmax = 4** variáveis preditoras. O asterisco (*) indica que uma determinada variável está incluída no modelo correspondente.

Finalmente podemos refazer o modelo usando apenas os preditores selecionados:

```
coef(step.model$finalModel, nvmax)
lm_model <- lm(Srare ~ q.w_vel + q.temp + q.do + q.turb,
  data = dados)
summary(lm_model)
```

```
## (Intercept)      q.w_vel      q.temp      q.do      q.turb
## -94.396637 -19.972427  16.108337   3.252551   1.146074
##
## Call:
## lm(formula = Srare ~ q.w_vel + q.temp + q.do + q.turb, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.261 -2.745 -1.332   2.076   9.693
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -94.3966    29.2076  -3.232  0.00490 **
## q.w_vel      -19.9724     9.0431  -2.209  0.04122 *
## q.temp       16.1083     4.9672   3.243  0.00478 **
## q.do          3.2526     2.2062   1.474  0.15868
## q.turb        1.1461     0.7015   1.634  0.12070
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 4.558 on 17 degrees of freedom
## Multiple R-squared:  0.4233, Adjusted R-squared:  0.2876
## F-statistic: 3.119 on 4 and 17 DF,  p-value: 0.04274
```

O QUE REPORTAR (MÉTODOS): Foi realizada uma regressão linear múltipla com seleção de variáveis pelo método de sequential replacement (leapSeq), utilizando o pacote caret. A seleção dos modelos foi avaliada por validação cruzada (*10-fold cross-validation*), considerando modelos contendo as variáveis preditoras (nvmax). O modelo com quatro variáveis apresentou o melhor desempenho de validação e foi selecionado como modelo final.

O QUE REPORTAR (RESULTADOS): O Modelo de Regressão Múltipla *Step-wise* (SMRM) com seleção de variáveis pelo método *sequential replacement* foi aplicado separadamente para cada um dos quatro conjuntos de variáveis ambientais (morfologia, qualidade da água, composição do sedimento e estruturas do habitat marginal). Dentre as variáveis de qualidade da água, a SMRM identificou um modelo contendo velocidade da água, temperatura, oxigênio dissolvido e turbidez como preditores de Srare. O modelo selecionado apresentou o melhor desempenho na validação cruzada (RMSE = 4.85; $r^2 = 0.929$) e foi estatisticamente significativo ($F_{4,17} = 3.12$, $p = 0.043$), explicando 42,3% da variação na riqueza rarefeita (r^2 ajustado = 0.288). A velocidade da água teve efeito negativo significativo ($\beta = -19.97$, $p = 0.041$), enquanto a temperatura apresentou efeito positivo significativo ($\beta = 16.11$, $p = 0.005$). As variáveis oxigênio dissolvido e turbidez não apresentaram efeitos significativos no modelo final ($p > 0.05$).

Apêndices

Sites para consulta

<https://stackoverflow.com/questions/31741742/how-to-identify-the-distribution-of-the-given-data-using-r>
<https://stats.stackexchange.com/questions/132652/how-to-determine-which-distribution-fits-my-data-best>
<https://www.r-bloggers.com/2015/11/correlation-and-linear-regression/>
<https://www.r-bloggers.com/2023/12/a-complete-guide-to-stepwise-regression-in-r/>
<https://www.sthda.com/english/articles/37-model-selection-essentials-in-r/154-stepwise-regression-essentials-in-r/>
<https://www.r-bloggers.com/2023/12/a-complete-guide-to-stepwise-regression-in-r/>

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executa-lo. Lembre de remover os `#` ou `##` caso necessite executar essas linhas.

Referências

Chapter 16

Modelos lineares generalizados (GLMs)

RESUMO

Até este ponto, assumimos que a variância é constante e que os erros seguem uma distribuição normal. Entretanto, para muitos tipos de dados, uma ou ambas essas suposições não são válidas. Se quisermos que nossas análises sejam imparciais e que nossas interpretações sejam cientificamente corretas, precisamos de métodos capazes de lidar com essas situações. Em dados de contagem, por exemplo, nos quais a variável resposta assume valores inteiros e frequentemente há muitos zeros no conjunto de dados, a variância pode aumentar linearmente com a média. Em dados de proporção, nos quais registramos tanto o número de sucessos quanto o número de fracassos de um evento, a variância apresenta uma relação em forma de U invertido com a média. Já quando a variável resposta segue uma distribuição gama (como em dados de tempo até a morte ou tempo até a ocorrência de um evento), a variância aumenta mais rapidamente do que de forma linear em relação à média. Assim, na prática, os dados frequentemente apresentam outros tipos de padrões de relação entre média e variância (veja Crawley (2005) e (2015), de onde esse capítulo é baseado). A maneira de tratar todos esses problemas dentro de um único arcabouço teórico foi desenvolvida por John Nelder (NELDER; WEDDERBURN, 1972), que denominou essa abordagem de **Modelos Lineares Generalizados** (*Generalized Linear Models*), ou simplesmente **GLMs** (originalmente chamados de *glims*).

Apresentação

A principal suposição que fizemos até aqui para os modelos lineares (função `lm()`), é que a variância é constante (Figura 16.1, (a)). Entretanto, em **da-**

dos de contagem, nos quais a variável resposta assume valores inteiros e frequentemente há muitos zeros no conjunto de dados, a variância pode aumentar linearmente com a média (Figura 16.1, (b)). Em **dados de proporção**, nos quais se registra tanto o número de sucessos quanto o número de fracassos de um evento, a variância apresenta uma relação em forma de *U* invertido com a média (Figura 16.1, (c)). Quando a variável resposta segue uma distribuição gama (como em **dados de tempo** até a morte ou tempo até a ocorrência de um evento), a variância aumenta mais rapidamente do que de forma linear em relação à média (Figura 16.1, (d)).




Figure 16.1: Relação entre a média e a variância para diferentes distribuições de probabilidade utilizadas em Modelos Lineares Generalizados (GLMs). (a) Distribuição normal, com variância constante; (b) distribuição de Poisson, em que a variância é igual à média; (c) distribuição binomial, cuja variância apresenta uma relação em forma de *U* invertido com a média; e (d) distribuição gama, em que a variância aumenta proporcionalmente ao quadrado da média. Essas diferentes relações entre média e variância justificam o uso de famílias de distribuições específicas em GLMs, em substituição aos modelos lineares clássicos que assumem homocedasticidade.

Essas quatro relações fundamentam a escolha da família de distribuição em

Modelos Lineares Generalizados (GLMs), pois cada tipo de variável resposta apresenta um padrão característico de relação entre a média e a variância.

Muitos dos métodos estatísticos clássicos, como a **regressão linear** e o **teste t de Student**, assumem que a variância é constante (homocedasticidade). No entanto, em diversas aplicações essa suposição não é válida. É justamente por isso que os GLMs são tão úteis, pois permitem modelar adequadamente situações em que a variância depende da média da variável resposta (CRAWLEY, 2005, 2015; DUNN; SMYTH, 2018; MCCULLAGH; NELDER, 1989; NELDER; WEDDERBURN, 1972; ZUUR et al., 2009).

16.0.0.1 Pressupostos

Um Modelo Linear Generalizado possui três componentes fundamentais: **a estrutura de erros**, **o preditor linear** e **a função de ligação** (*link function*) (CRAWLEY, 2015):

16.0.0.2 Estrutura de erros:

Até este ponto, trabalhamos com análises estatísticas que assumem **erros normalmente distribuídos**. Na prática, entretanto, muitos tipos de dados apresentam distribuições de erro que não seguem a distribuição normal (CRAWLEY, 2005, 2015). Alguns exemplos incluem:

- erros com forte assimetria;
- erros com excesso ou deficiência de curtose;
- erros limitados a um intervalo específico, como ocorre com dados de proporções;
- erros que não podem produzir valores ajustados negativos, como em dados de contagem.

As principais alternativas para lidar com essas situações consistem em **transformar a variável resposta** ou utilizar **métodos não-paramétricos** (SOKAL; ROHLF, 1995). Os **Modelos Lineares Generalizados** representam uma abordagem mais flexível, pois permitem especificar diferentes distribuições de probabilidade para os erros, de acordo com a natureza da variável resposta.

Entre as distribuições de erro mais utilizadas em GLMs destacam-se:

- **Distribuição de Poisson**, apropriada para dados de contagem;
- **Distribuição Binomial**, indicada para dados de proporções ou sucessos e fracassos;
- **Distribuição Gama**, adequada para variáveis contínuas, positivas, cuja variabilidade tende a aumentar proporcionalmente ao quadrado da média (ou que apresentam coeficiente de variação aproximadamente constante);

- **Distribuição Exponencial**, empregada em dados de tempo até a ocorrência de um evento, como em análises de sobrevivência.

16.0.0.3 Estrutura do modelo:

A estrutura de um modelo relaciona cada valor observado da variável resposta ($\mathbf{y}$) a um valor previsto ($\hat{\mathbf{y}}$). Esse valor previsto é obtido por meio de uma transformação aplicada ao resultado do **preditor linear**.

O **preditor linear**, geralmente representado pela letra grega (η) (*eta*), consiste em uma combinação linear dos efeitos de uma ou mais variáveis explicativas (x_j):

$$\eta_i = \beta_0 + \sum_{j=1}^p x_{ij}\beta_j,$$

em que:

- x_{ij} representa o valor da j -ésima variável explicativa para a i -ésima observação;
- β_j são os parâmetros do modelo, normalmente desconhecidos e estimados a partir dos dados;
- p é o número de variáveis explicativas incluídas no modelo.

O lado direito da equação é denominado **estrutura linear**. O número de termos do preditor linear depende da quantidade de parâmetros que precisam ser estimados.

Por exemplo:

Em uma **regressão linear simples**, o preditor linear possui dois parâmetros: o intercepto (β_0) e o coeficiente angular (β_1). Em uma **ANOVA de um fator** com quatro tratamentos, o preditor linear contém quatro termos, correspondentes às médias estimadas para cada nível do fator. Quando o modelo inclui **covariáveis**, cada uma delas acrescenta um novo termo ao preditor linear, representando sua inclinação (coeficiente de regressão). Em uma **ANOVA fatorial**, os termos de interação também adicionam parâmetros ao modelo. O número de parâmetros depende dos graus de liberdade envolvidos. Por exemplo, a interação entre um fator com dois níveis e outro com quatro níveis acrescenta três parâmetros, pois $((2 - 1)(4 - 1) = 3)$.

No caso dos GLMs, para avaliar o ajuste de um modelo, calcula-se inicialmente o valor do **preditor linear** (η) para cada observação da variável resposta. Em seguida, esse valor é relacionado à variável resposta por meio da **função de ligação** (*link function*). A função de ligação transforma a média da variável resposta para uma escala em que a relação com os preditores seja linear. Após

estimar o preditor linear, o modelo aplica a **função inversa da ligação** para retornar os valores previstos à escala original da variável resposta. Esses valores são conhecidos como **valores ajustados** (*fitted values*).

Por exemplo, quando a função de ligação é o **logaritmo** (*log link*), o valor ajustado é obtido aplicando a função exponencial ao preditor linear:

$$\hat{\mu} = e^{\eta}$$

e quando a função de ligação é o **recíproco** (*reciprocal link*), o valor ajustado corresponde ao inverso do preditor linear:

$$\hat{\mu} = \frac{1}{\eta}$$

Assim, embora o ajuste do modelo seja realizado na escala do preditor linear, **os resultados finais são expressos na escala original da variável resposta**, facilitando sua interpretação.

16.0.0.4 Função de ligação:

Segundo CRAWLEY (2015), um dos conceitos mais desafiadores dos GLMs é a compreensão da relação entre os valores da variável resposta, observados nos dados e previstos pelo modelo, e o **preditor linear**. A ideia fundamental é que a **função de ligação** (*link function*) estabelece a relação entre a **média da variável resposta** e o preditor linear.

CRAWLEY (2015) expressa essa relação em termos matemáticos como:

$$\eta = g(\mu),$$

onde,

- η é o **preditor linear**;
- $\mu = E(y)$ é a média esperada da variável resposta;
- $g(\cdot)$ é a função de ligação.

Embora a expressão seja simples, seu significado merece atenção. O preditor linear (η) é obtido a partir da combinação linear das variáveis explicativas e de seus respectivos coeficientes. Portanto, ele **não corresponde diretamente a um valor da variável resposta**, exceto no caso particular da **função de ligação identidade**, utilizada implicitamente na regressão linear tradicional.

Em um GLM, a média da variável resposta é inicialmente transformada pela função de ligação, produzindo o preditor linear. Após o ajuste do modelo, a

função inversa da ligação é aplicada ao preditor linear para obter os valores ajustados na escala original da variável resposta:

$$\mu = g^{-1}(\eta)$$

Assim, o modelo é ajustado em uma escala linear, mas as previsões são apresentadas na escala original dos dados, o que facilita sua interpretação.

16.0.1 Escolha da função de ligação

Uma das principais razões para utilizar diferentes funções de ligação é garantir que os valores ajustados permaneçam dentro de limites compatíveis com a natureza da variável resposta.

Por exemplo:

Em **dados de contagem**, os valores previstos devem ser sempre **maiores ou iguais a zero**, pois contagens negativas não fazem sentido. Nesse caso, a **função de ligação logarítmica** (*log link*) é uma escolha apropriada, pois sua função inversa é a exponencial:

$$\mu = e^{\eta}$$

que produz apenas valores positivos.

Da mesma forma, quando a variável resposta representa uma **proporção** ou uma **probabilidade**, os valores ajustados devem estar obrigatoriamente entre 0 e 1. Para esses casos, utiliza-se geralmente a **função de ligação logito** (*logit link*), definida como:

$$\eta = \log \left(\frac{p}{1-p} \right)$$

em que p representa a probabilidade de ocorrência do evento de interesse. A função inversa do logito garante que todas as probabilidades estimadas permaneçam no intervalo entre 0 e 1.

16.0.1.1 Comparação entre funções de ligação

Uma das vantagens dos GLMs é que diferentes funções de ligação podem ser utilizadas para um mesmo conjunto de dados, permitindo comparar modelos que descrevem diferentes formas de relação entre o preditor linear e a variável resposta.

— M.J. Crawley em (CRAWLEY, 2015).

Como todos esses modelos são ajustados utilizando a mesma estrutura de dados, é possível comparar seus desempenhos por meio da **deviância residual** (*residual deviance*). Em geral, a função de ligação mais adequada é aquela que produz a **menor deviância residual**, indicando que o modelo descreve os dados de forma mais eficiente.

Dessa forma, a escolha da função de ligação não altera apenas a forma matemática do modelo, mas também influencia diretamente a qualidade do ajuste e a interpretação dos efeitos das variáveis explicativas sobre a variável resposta.

16.0.1.2 Funções canônicas de ligação

As **funções de ligação canônicas** (*canonical link functions*) são as funções de ligação utilizadas no R por padrão quando uma determinada distribuição de erros é especificada no argumento **family** de um GLM. Em outras palavras, quando nenhuma função de ligação é explicitamente informada, o software adota automaticamente a função de ligação canônica associada à distribuição escolhida.

As principais combinações entre distribuições de erro e suas respectivas funções de ligação canônicas são apresentadas na Tabela abaixo.

Distribuição de erros (family)	Função de ligação canônica (link)	Função inversa
Normal	Identidade (<i>identity</i>)	$\mu = \eta$
Poisson	Logaritmo (<i>log</i>)	$\mu = e^\eta$
Binomial	Logito (<i>logit</i>)	$\mu = \frac{e^\eta}{1 + e^\eta}$
Gama	Recíproca (<i>reciprocal</i>)	$\mu = \frac{1}{\eta}$

Cada uma dessas funções foi desenvolvida para estabelecer uma relação adequada entre o **preditor linear** (η) e a **média da variável resposta** (μ), respeitando as características da distribuição dos dados. A escolha da função de ligação garante que os valores ajustados permaneçam dentro de limites plausíveis. Por exemplo, a função **log** assegura que as estimativas para dados de contagem sejam sempre positivas, enquanto a função **logito** produz probabilidades compreendidas entre 0 e 1.

Embora essas sejam as funções de ligação canônicas, elas **não são as únicas opções disponíveis**. Em muitos casos, é possível utilizar outras funções de ligação para uma mesma distribuição. Por exemplo, para a distribuição binomial também podem ser empregadas as funções **probit** e **complementary log-log** (**cloglog**), e para a distribuição gama podem ser utilizadas as funções **log** e **identidade**. A função canônica, entretanto, costuma ser a escolha inicial por

apresentar propriedades matemáticas convenientes e, frequentemente, proporcionar estimativas mais eficientes (MCCULLAGH; NELDER, 1989; ZUUR et al., 2009).

No **R**, basta especificar a família da distribuição para que a função de ligação canônica seja utilizada automaticamente. Para uma regressão linear (distribuição normal e função identidade)(equivalente a `lm()`):

```
glm(y ~ x, family = gaussian(link = "identity"))
```

Caso seja desejada outra função de ligação, ela pode ser especificada por meio do argumento `link`. Para a distribuição Gama com ligação log:

```
glm(y ~ x, family = Gamma(link = "log"))
```

As quatro combinações canônicas apresentadas na tabela correspondem aos modelos mais utilizados na prática e constituem o ponto de partida para a maioria das análises.

16.0.1.3 Exemplo 1

16.1 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

16.1.1 Organizando os dados

```
anovas <- read.csv("t_anovas.csv",
  sep = ";", dec = ".",
  row.names = 1,
  header = TRUE,
  na.strings = NA)
anovas <- anovas[, -1]
anovas <- cbind(Grupos = rownames(anovas), anovas)
anovas
grps <- substr(anovas[, 1], 1,1)
```

```

grps
library(dplyr)
testtt <- mutate(anovas, Grupos = c(grps))
testtt

###SALVANDO MATRIZ FINAL ANOVAS----
write.table(testtt, "t_test.csv",
            sep = ";", dec = ".", #"\t",
            row.names = TRUE,
            quote = TRUE,
            append = FALSE)
testtt <- read.csv("t_test.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA)

testtt

```

```

##           Grupos      Srare      dens  S
## S-R-CI-1 S-R-CI-1  5.000000   1.7857143  5
## S-R-CI-2 S-R-CI-2 12.719603  86.3690476 13
## S-R-CI-3 S-R-CI-3 15.057283 257.4404762 21
## S-R-CI-4 S-R-CI-4 16.000000  57.9761905 16
## B-A-SA-1 B-A-SA-1  2.000000   0.2976190  2
## B-A-SA-2 B-A-SA-2  3.000000   0.8333333  3
## B-A-SA-3 B-A-SA-3  6.000000   0.8928571  6
## B-A-SA-4 B-A-SA-4  3.000000   2.3809524  3
## B-A-MU-2 B-A-MU-2  1.000000   0.1785714  1
## B-A-MU-3 B-A-MU-3  2.000000   0.2380952  2
## B-A-MU-4 B-A-MU-4  2.000000   0.7142857  2
## B-R-EP-2 B-R-EP-2  3.920860  82.7380952  4
## B-R-EP-3 B-R-EP-3  5.000000  26.4880952  5
## B-R-EP-4 B-R-EP-4  2.955224  79.7619048  3
## S-A-RE-1 S-A-RE-1 13.171426  95.5952381 14
## S-A-RE-2 S-A-RE-2  7.000000  64.3452381  7
## S-A-RE-3 S-A-RE-3 19.932602  80.8333333 20
## S-A-RE-4 S-A-RE-4 11.638514 103.6904762 12
## S-R-SE-1 S-R-SE-1  7.000000   1.8452381  7
## S-R-SE-2 S-R-SE-2  3.000000  75.4166667  3
## S-R-SE-3 S-R-SE-3  3.763162 249.4642857  4
## S-R-SE-4 S-R-SE-4  8.603085 406.6071429 11
## [1] "S" "S" "S" "S" "B" "B" "B" "B" "B" "B" "B" "B" "B" "B" "S" "S" "S" "S" "S"
## [20] "S" "S" "S"
##           Grupos      Srare      dens  S

```

##	S-R-CI-1	S	5.000000	1.7857143	5
##	S-R-CI-2	S	12.719603	86.3690476	13
##	S-R-CI-3	S	15.057283	257.4404762	21
##	S-R-CI-4	S	16.000000	57.9761905	16
##	B-A-SA-1	B	2.000000	0.2976190	2
##	B-A-SA-2	B	3.000000	0.8333333	3
##	B-A-SA-3	B	6.000000	0.8928571	6
##	B-A-SA-4	B	3.000000	2.3809524	3
##	B-A-MU-2	B	1.000000	0.1785714	1
##	B-A-MU-3	B	2.000000	0.2380952	2
##	B-A-MU-4	B	2.000000	0.7142857	2
##	B-R-EP-2	B	3.920860	82.7380952	4
##	B-R-EP-3	B	5.000000	26.4880952	5
##	B-R-EP-4	B	2.955224	79.7619048	3
##	S-A-RE-1	S	13.171426	95.5952381	14
##	S-A-RE-2	S	7.000000	64.3452381	7
##	S-A-RE-3	S	19.932602	80.8333333	20
##	S-A-RE-4	S	11.638514	103.6904762	12
##	S-R-SE-1	S	7.000000	1.8452381	7
##	S-R-SE-2	S	3.000000	75.4166667	3
##	S-R-SE-3	S	3.763162	249.4642857	4
##	S-R-SE-4	S	8.603085	406.6071429	11
##	Grupos	Srare	dens	S	
##	S-R-CI-1	S	5.000000	1.7857143	5
##	S-R-CI-2	S	12.719603	86.3690476	13
##	S-R-CI-3	S	15.057283	257.4404762	21
##	S-R-CI-4	S	16.000000	57.9761905	16
##	B-A-SA-1	B	2.000000	0.2976190	2
##	B-A-SA-2	B	3.000000	0.8333333	3
##	B-A-SA-3	B	6.000000	0.8928571	6
##	B-A-SA-4	B	3.000000	2.3809524	3
##	B-A-MU-2	B	1.000000	0.1785714	1
##	B-A-MU-3	B	2.000000	0.2380952	2
##	B-A-MU-4	B	2.000000	0.7142857	2
##	B-R-EP-2	B	3.920860	82.7380952	4
##	B-R-EP-3	B	5.000000	26.4880952	5
##	B-R-EP-4	B	2.955224	79.7619048	3
##	S-A-RE-1	S	13.171426	95.5952381	14
##	S-A-RE-2	S	7.000000	64.3452381	7
##	S-A-RE-3	S	19.932602	80.8333333	20
##	S-A-RE-4	S	11.638514	103.6904762	12
##	S-R-SE-1	S	7.000000	1.8452381	7
##	S-R-SE-2	S	3.000000	75.4166667	3
##	S-R-SE-3	S	3.763162	249.4642857	4
##	S-R-SE-4	S	8.603085	406.6071429	11

16.1.2 ANOVA vs GLM

Suponha que você queira comparar a riqueza (Srare) entre grupos (Grupos):

```
dados <- anovas
modelo_aov <- aov(Srare ~ Grupos, data = dados)
summary(modelo_aov)
```

```
##              Df Sum Sq Mean Sq
## Grupos      21  612.4   29.16
```

ou

```
modelo_lm <- lm(Srare ~ Grupos, data = dados)
anova(modelo_lm)
```

```
## Analysis of Variance Table
##
## Response: Srare
##              Df Sum Sq Mean Sq F value Pr(>F)
## Grupos      21  612.37   29.161    NaN    NaN
## Residuals    0    0.00      NaN
```

2. O mesmo modelo usando GLM

```
modelo_glm <- glm(Srare ~ Grupos,
                  data = dados,
                  family = gaussian(link = "identity"))
anova(modelo_glm, test = "F")
```

```
## Analysis of Deviance Table
##
## Model: gaussian, link: identity
##
## Response: Srare
##
## Terms added sequentially (first to last)
##
##              Df Deviance Resid. Df Resid. Dev
## NULL              21      612.37
## Grupos 21      612.37           0           0.00
```

ou

```
summary(modelo_glm)
```

```
##
## Call:
## glm(formula = Srare ~ Grupos, family = gaussian(link = "identity"),
##      data = dados)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      1.000         NaN    NaN    NaN
## GruposB-A-MU-3    1.000         NaN    NaN    NaN
## GruposB-A-MU-4    1.000         NaN    NaN    NaN
## GruposB-A-SA-1    1.000         NaN    NaN    NaN
## GruposB-A-SA-2    2.000         NaN    NaN    NaN
## GruposB-A-SA-3    5.000         NaN    NaN    NaN
## GruposB-A-SA-4    2.000         NaN    NaN    NaN
## GruposB-R-EP-2    2.921         NaN    NaN    NaN
## GruposB-R-EP-3    4.000         NaN    NaN    NaN
## GruposB-R-EP-4    1.955         NaN    NaN    NaN
## GruposS-A-RE-1   12.171         NaN    NaN    NaN
## GruposS-A-RE-2    6.000         NaN    NaN    NaN
## GruposS-A-RE-3   18.933         NaN    NaN    NaN
## GruposS-A-RE-4   10.639         NaN    NaN    NaN
## GruposS-R-CI-1    4.000         NaN    NaN    NaN
## GruposS-R-CI-2   11.720         NaN    NaN    NaN
## GruposS-R-CI-3   14.057         NaN    NaN    NaN
## GruposS-R-CI-4   15.000         NaN    NaN    NaN
## GruposS-R-SE-1    6.000         NaN    NaN    NaN
## GruposS-R-SE-2    2.000         NaN    NaN    NaN
## GruposS-R-SE-3    2.763         NaN    NaN    NaN
## GruposS-R-SE-4    7.603         NaN    NaN    NaN
##
## (Dispersion parameter for gaussian family taken to be NaN)
##
##      Null deviance: 6.1237e+02  on 21  degrees of freedom
## Residual deviance: 1.5560e-27  on  0  degrees of freedom
## AIC: -1317.6
##
## Number of Fisher Scoring iterations: 1
```

Esse modelo é matematicamente equivalente à ANOVA.

```
options(scipen = 999)

#packageVersion("rlang")
#remove.packages("rlang")
#install.packages("rlang")
#packageVersion("rlang")
#install.packages("devtools")
#devtools::install_github("dustinfife/flexplot")
library(flexplot)
library(ggplot2)

# A Numeric v. Numeric example (simple regression)

flexplot(Srare ~ 1, data = dados)
flexplot(S ~ 1, data = dados)
flexplot(Srare ~ S, data = dados)
flexplot(Srare ~ S,
         data = dados,
         method = "lm")

lm(Srare ~ S, data = dados)

flexplot(Srare ~ S,
         data = dados,
         method = "lm") +
  xlim(0, 25) +
  geom_smooth(method = "lm", fullrange = TRUE)

model <- lm(Srare ~ S,
            data = dados)

summary(model)
estimates(model)

# note that the "significance" of the correlation is the
# same thing as the p-value for the slope of the lm

cor.test(dados$Srare,
         dados$S)

# A Categorical v. Numeric example (previous name t-test)

dados <- testt
flexplot(Srare ~ 1,
```

```

        data = dados)

flexplot(Grupos ~ 1,
        data = dados)

flexplot(Srare ~ Grupos,
        data = dados)

modelt <- lm(Srare ~ Grupos,
            data = dados)
summary(modelt)
estimates(modelt)

# proof that the GLM method results in the same thing as a t-test

t <- t.test(Srare ~ Grupos,
            data = dados,
            var.equal = TRUE)
t

#install.packages("effectsize")
library(effectsize)

cohens_d(Srare ~ Grupos,
        data = dados)

library(psych)

cohen.d(Srare ~ Grupos,
        data = dados)

# Uma forma de calcular d a partir do valor de t e dos graus de
↳ liberdade

t_to_d(t$statistic, t$parameter)

# Uma forma de calcular o tamanho de efeito r a partir do valor
↳ de t e dos graus de liberdade

t_to_r(t$statistic, t$parameter)

##
## Call:
## lm(formula = Srare ~ S, data = dados)
##

```




```
## Coefficients:
## (Intercept)          S
##      0.4760      0.8737
##
##
## Call:
## lm(formula = Srare ~ S, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.7667 -0.2195 -0.0736  0.4080  1.9823
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)   0.4760     0.3835   1.241      0.229
## S             0.8737     0.0403  21.682 0.0000000000000023 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.118 on 20 degrees of freedom
## Multiple R-squared:  0.9592, Adjusted R-squared:  0.9572
## F-statistic: 470.1 on 1 and 20 DF,  p-value: 0.0000000000000023
##
## Model R squared:
## 0.959 (0.93, 0.99)
##
## Semi-Partial R squared:
##      S
## 0.959
## Correlation:
## 0.979
##
##
## Estimates for Numeric Variables =
##      variables estimate lower upper std.estimate std.lower std.upper
## 1 (Intercept)    0.48 -0.28  1.23          0.00      0.00      0.00
## 2              S    0.87  0.79  0.95          0.98      0.89      1.07
##
## Pearson's product-moment correlation
##
## data:  dados$Srare and dados$S
## t = 21.682, df = 20, p-value = 0.0000000000000023
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.9500773 0.9915604
## sample estimates:
```



```



##          cor
## 0.9793833
##
##
## Call:
## lm(formula = Srare ~ Grupos, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -7.240 -1.975 -0.110  2.337  9.692
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    3.088      1.291   2.392 0.026707 *
## GruposS        7.153      1.748   4.092 0.000567 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.082 on 20 degrees of freedom
## Multiple R-squared:  0.4557, Adjusted R-squared:  0.4285
## F-statistic: 16.75 on 1 and 20 DF,  p-value: 0.0005671
##
## Model R squared:
## 0.456 (0.18, 0.73)
##
## Semi-Partial R squared:
## Grupos
## 0.456
##
## Estimates for Factors:
##  variables levels estimate lower upper
## 1    Grupos      B      3.09  0.39  5.78
## 2              S     10.24  7.78  12.7
##
##
## Mean Differences:
##  variables comparison difference lower upper cohens.d
## 1    Grupos      S-B      7.15    2 12.31    1.75
##
## Two Sample t-test
##
## data:  Srare by Grupos
## t = -4.0922, df = 20, p-value = 0.0005671
## alternative hypothesis: true difference in means between group B and group S is not
## 95 percent confidence interval:
## -10.798979 -3.506749



```


```
## sample estimates:
## mean in group B mean in group S
##      3.087608      10.240473
##
## Cohen's d |          95% CI
## -----
## -1.75      | [-2.73, -0.74]
##
## - Estimated using pooled SD.Call: cohen.d(x = Srare ~ Grupos, data = dados)
## Cohen d statistic of difference between two means
##      lower effect upper
## Srare  0.81   1.84   2.83
##
## Multivariate (Mahalanobis) distance between groups
## [1] 1.8
## r equivalent of difference between two means
## Srare
##  0.68
## d      |          95% CI
## -----
## -1.83 | [-2.86, -0.77]
## r      |          95% CI
## -----
## -0.68 | [-0.82, -0.36]
```











Apêndices

Sites para consulta

<https://stackoverflow.com/questions/31741742/how-to-identify-the-distribution-of-the-given-data-using-r>

<https://stats.stackexchange.com/questions/132652/how-to-determine-which-distribution-fits-my-data-best>

<https://www.r-bloggers.com/2015/11/correlation-and-linear-regression/>

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executa-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

Referências

Chapter 17

R Módulo 4.1 - Estrutura da comunidade

RESUMO

Na ecologia de comunidades, a diversidade de espécies é uma medida importante para entender a complexidade e a estrutura de uma comunidade de organismos. Vamos explorar algumas das métricas comuns usadas para avaliar a diversidade de espécies.

Apresentação

Na ecologia de comunidades, a diversidade de espécies é uma medida importante para entender a complexidade e a estrutura de uma comunidade de organismos. Vamos explorar algumas das métricas comuns usadas para avaliar a diversidade de espécies. Essas métricas são usadas para avaliar a diversidade e a estrutura de comunidades ecológicas. Elas podem fornecer informações importantes sobre como as diferentes espécies interagem em um ecossistema e como a diversidade de espécies pode ser afetada por mudanças ambientais ou distúrbios (MAGURRAN, 1988).

17.1 Sobre os dados

Usaremos para esse tutorial dois conjuntos de dados. A **Matriz comunitária** (ppbio06c-peixes.xlsx) de dados coletados no Programa de Pesquisa em Biodiversidade - PPBio (Veja Programa de Pesquisa em Biodiversidade – PP-Bio). Esses são dados de espécies de peixes distribuídas em diversas unidades

amostrais (UA's ou sítios). Essa é a **matriz bruta de dados**, porque os valores ainda não foram ajustados para os valores de Captura Por Unidade de Esforço (CPUE), nem foram relativizados ou transformados.

Além disso usaremos a **tabela de agrupamentos** (ppbio06-grupos.xlsx)

Revise as informações sobre as bases de dados no Capítulo 7. A matriz de dados para esse Módulo pode ser baixada na Seção 7.2.

17.2 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

Instalando os pacotes necessários para esse módulo.

```
install.packages("vegan")
install.packages("moments")
install.packages("ggplot2")
install.packages("dplyr")
install.packages("tidyr")
install.packages("tibble")
install.packages("tidyverse") #atente para alguma msg de erro qdo
  ↪ executar essa linha
install.packages("forcats")
install.packages("iNEXT")
install.packages("openxlsx")
install.packages("gt")
```

Depois de instalados, carregue os pacotes a seguir no seu computador.

```
library(tibble); library(tidyverse); library(forcats);
  ↪ library(Rcpp)
```

Os códigos acima, são usados para instalar e carregar os pacotes necessários para este módulo. Esses códigos são comandos para instalar pacotes no R. Um pacote é uma coleção de funções, dados e documentação que ampliam as capacidades do R (R CRAN, (R DEVELOPMENT CORE TEAM, 2017)) e RStudio (R STUDIO TEAM, 2022)). No exemplo acima, o pacote **openxlsx** permite ler e

escrever arquivos Excel no R. Para instalar um pacote no R, você precisa usar a função `install.packages()`.

Depois de instalar um pacote, você precisa carregá-lo na sua sessão R com a função `library()`. Por exemplo, para carregar o pacote `openxlsx`, você precisa executar a função `library(openxlsx)`. Isso irá permitir que você use as funções do pacote na sua sessão R. Você precisa carregar um pacote toda vez que iniciar uma nova sessão R e quiser usar um pacote instalado.

Agora vamos **definir o diretório de trabalho**. Esse código é usado para obter e definir o diretório de trabalho atual no R. O comando `getwd()` retorna o caminho do diretório onde o R está lendo e salvando arquivos. O comando `setwd()` muda esse diretório de trabalho para o caminho especificado entre aspas. No seu caso, você deve ajustar o caminho para o seu próprio diretório de trabalho. **Lembre de usar a barra “/” entre os diretórios. E não a contra-barra “\”.**

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

17.3 Importando a planilha

Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações.

- Ajuste a primeira linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.
- Ajuste o parâmetro `sheet = "Sheet1"` para refletir a aba correta do arquivo .xlsx a ser importado.

```
library(openxlsx)
ppbio <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.xlsx"
  ↪ ,
                                rowNames = T, colNames = T,
                                sheet = "Sheet1")

str(ppbio)
#View(ppbio)
ppbio[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas de 1
  ↪ a 5.
```

```
## 'data.frame':    26 obs. of  35 variables:
## $ ap-davis : num  0 0 0 0 0 0 0 0 0 0 ...
```

```

## $ as-bimac : num 1 99 194 19 23 142 5 46 206 16 ...
## $ as-fasci : num 0 0 55 0 1 3 1 0 64 0 ...
## $ ch-bimac : num 0 0 0 0 13 3 0 178 0 0 ...
## $ ci-ocela : num 0 0 0 0 0 0 40 0 0 13 ...
## $ ci-orien : num 0 0 5 0 0 69 9 0 25 24 ...
## $ co-macro : num 0 0 0 0 0 0 0 0 0 0 ...
## $ co-heter : num 0 0 1 0 0 0 0 0 0 0 ...
## $ cr-menez : num 0 0 14 0 0 4 0 0 8 0 ...
## $ cu-lepid : num 0 0 0 0 0 0 0 0 0 0 ...
## $ cy-gilbe : num 0 0 0 0 0 0 0 0 0 0 ...
## $ ge-brasi : num 0 0 3 0 0 0 0 0 1 0 ...
## $ he-margi : num 0 0 0 0 0 1 0 0 0 0 ...
## $ ho-malab : num 0 0 1 5 0 17 10 2 31 4 ...
## $ hy-pusar : num 0 0 9 2 0 43 2 0 11 0 ...
## $ le-melan : num 0 0 0 0 0 0 0 0 0 0 ...
## $ le-piau : num 0 0 3 0 0 1 3 0 2 1 ...
## $ le-taeni : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-costa : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-lepid : num 0 1 39 0 0 1 0 0 0 0 ...
## $ or-nilot : num 0 2 36 0 0 77 0 0 138 0 ...
## $ pa-manag : num 0 0 0 0 0 0 0 0 0 0 ...
## $ pimel-sp : num 0 0 6 0 0 0 0 0 0 0 ...
## $ po-retic : num 0 0 0 0 0 20 0 0 5 0 ...
## $ po-vivip : num 0 0 47 15 0 221 32 0 326 10 ...
## $ pr-brevi : num 9 0 5 0 1 15 5 2 164 0 ...
## $ ps-rhomb : num 0 0 0 0 0 0 0 0 1 0 ...
## $ ps-genise : num 0 0 0 0 0 0 0 0 1 0 ...
## $ se-heter : num 0 0 40 14 4 60 0 0 38 0 ...
## $ se-piaba : num 0 0 68 0 0 0 0 0 0 0 ...
## $ se-spilo : num 0 0 0 0 0 0 0 0 1 0 ...
## $ st-noton : num 0 0 1 0 0 25 0 0 115 0 ...
## $ sy-marmo : num 0 0 0 0 0 0 1 0 0 0 ...
## $ te-chalc : num 0 0 0 0 0 0 0 0 0 0 ...
## $ tr-signa : num 0 0 18 0 0 15 0 0 7 0 ...
##      ap-davis as-bimac as-fasci ch-bimac ci-ocela
## S-A-ZA1      0      1      0      0      0
## S-R-CC1      0     99      0      0      0
## S-R-CT1      0    194     55      0      0
## S-R-CP1      0     19      0      0      0
## S-A-TA1      0     23      1     13      0

```

Exibindo os dados importados (esses comando são “case-sensitive” `ignore.case(object)`).

```

#View(ppbio)
print(ppbio[1:8,1:8])

```

```
ppbio[1:10,1:10]
str(ppbio)
mode(ppbio)
class(ppbio)
```

17.4 REINÍCIO

```
m_trab <- ppbio
#pat <- "~S"
#m_trab <- m_trab[!grepl(pat, rownames(m_trab)), ] #exclui quem
  ↳ começa com pat
```

Aqui cria-se um novo objeto do R (`m_trab`, ou a matriz de trabalho, para esse momento) que substitui a matriz de dados original, por uma nova matriz que pode ser a matriz relativizada, transformada, transposta, etc. Dessa forma, mantemos a matriz de dados original caso precisemos dela novamente (Veja a Tabela 7.1).

Revise Seção 7.2.2 e a Tabela de Abreviações (@ref(tab:200m_2)) na mesma Seção que resumem os tipos de matrizes e suas abreviações, para os nossos códigos.

17.5 Transpor a matriz para trabalhar com as espécies

Vamos transpor a matriz para trabalharmos com as espécies. A função `t` transpõe a matriz. Só deve ser usada uma vez, pois se repetida com **Ctrl+Enter** continua “girando” a matriz. As espécies como colunas representam uma matriz comunitária e as espécies como linhas representam uma matriz (comunitária) transposta.

```
m_trab <- t(ppbio)
str(m_trab)
#View(m_trab)
m_trab
print(m_trab[1:5,1:5])
m_trab[1:5,1:5]
```

```
str(m_trab)
mode(m_trab)
class(m_trab)
```

```
## num [1:35, 1:26] 0 1 0 0 0 0 0 0 0 0 ...
## - attr(*, "dimnames")=List of 2
## ..$ : chr [1:35] "ap-davis" "as-bimac" "as-fasci" "ch-bimac" ...
## ..$ : chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
##      S-A-ZA1 S-R-CC1 S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2
## ap-davis      0      0      0      0      0      0      0      0
## as-bimac       1     99     194     19     23     142      5     46
## as-fasci       0      0      55      0      1      3      1      0
## ch-bimac       0      0      0      0     13      3      0    178
## ci-ocela       0      0      0      0      0      0     40      0
## ci-orien       0      0      5      0      0     69      9      0
## co-macro       0      0      0      0      0      0      0      0
## co-heter       0      0      1      0      0      0      0      0
## cr-menez       0      0     14      0      0      4      0      0
## cu-lepid       0      0      0      0      0      0      0      0
## cy-gilbe       0      0      0      0      0      0      0      0
## ge-brasi       0      0      3      0      0      0      0      0
## he-margi       0      0      0      0      0      1      0      0
## ho-malab       0      0      1      5      0     17     10      2
## hy-pusar       0      0      9      2      0     43      2      0
## le-melan       0      0      0      0      0      0      0      0
## le-piau        0      0      3      0      0      1      3      0
## le-taeni       0      0      0      0      0      0      0      0
## mo-costa       0      0      0      0      0      0      0      0
## mo-lepid       0      1     39      0      0      1      0      0
## or-nilot       0      2     36      0      0     77      0      0
## pa-manag       0      0      0      0      0      0      0      0
## pimel-sp       0      0      6      0      0      0      0      0
## po-retic       0      0      0      0      0     20      0      0
## po-vivip       0      0     47     15      0    221     32      0
## pr-brevi       9      0      5      0      1     15      5      2
## ps-rhomb       0      0      0      0      0      0      0      0
## ps-genise      0      0      0      0      0      0      0      0
## se-heter       0      0     40     14      4     60      0      0
## se-piaba       0      0     68      0      0      0      0      0
## se-spilo       0      0      0      0      0      0      0      0
## st-noton       0      0      1      0      0     25      0      0
## sy-marmo       0      0      0      0      0      0      1      0
## te-chalc       0      0      0      0      0      0      0      0
## tr-signa       0      0     18      0      0     15      0      0
```

17.5. TRANSPOR A MATRIZ PARA TRABALHAR COM AS ESPÉCIES379

##	S-R-CT3	S-R-CP3	S-A-TA3	S-R-CT4	S-R-CP4	S-A-TA4	B-A-MU1	B-R-ET1
## ap-davis	0	0	0	0	0	0	0	0
## as-bimac	206	16	234	0	0	394	12	3
## as-fasci	64	0	7	1	0	0	0	0
## ch-bimac	0	0	238	0	0	273	0	0
## ci-ocela	0	13	0	0	11	0	0	0
## ci-orien	25	24	0	5	6	0	0	0
## co-macro	0	0	2	0	0	0	0	0
## co-heter	0	0	0	0	0	0	0	0
## cr-menez	8	0	0	1	0	1	0	0
## cu-lepid	0	0	0	0	0	0	0	0
## cy-gilbe	0	0	0	50	0	0	0	0
## ge-brasi	1	0	0	3	0	1	190	0
## he-margi	0	0	0	1	0	0	0	0
## ho-malab	31	4	20	4	2	9	0	0
## hy-pusar	11	0	0	3	0	0	0	0
## le-melan	0	0	0	0	0	0	0	0
## le-piau	2	1	0	0	2	2	0	0
## le-taeni	0	0	0	0	0	0	0	0
## mo-costa	0	0	0	0	0	0	0	0
## mo-lepid	0	0	0	0	0	0	0	0
## or-nilot	138	0	0	73	0	1	6	8
## pa-manag	0	0	0	0	0	0	0	1
## pimel-sp	0	0	0	0	0	0	0	0
## po-retic	5	0	0	0	0	0	0	34
## po-vivip	326	10	0	28	80	0	0	0
## pr-brevi	164	0	0	59	0	3	0	0
## ps-rhomb	1	0	0	0	0	0	0	0
## ps-genise	1	0	0	0	0	0	0	0
## se-heter	38	0	0	3	3	0	0	0
## se-piaba	0	0	0	0	0	0	0	0
## se-spilo	1	0	0	0	0	0	0	0
## st-noton	115	0	0	64	0	0	0	0
## sy-marmo	0	0	0	0	0	0	0	0
## te-chalc	0	0	0	0	0	0	0	0
## tr-signa	7	0	0	141	0	0	0	0
##	B-A-GU1	B-R-PC2	B-A-MU2	B-A-GU2	B-R-PC3	B-A-MU3	B-A-GU3	B-R-PC4
## ap-davis	0	5	0	0	22	0	0	0
## as-bimac	2	44	99	0	75	511	6	7
## as-fasci	2	0	0	0	7	0	0	17
## ch-bimac	0	0	0	0	0	0	0	0
## ci-ocela	0	2	0	0	4	0	0	0
## ci-orien	0	0	0	0	0	0	0	0
## co-macro	0	0	0	0	0	0	0	0
## co-heter	0	0	0	0	0	0	0	0
## cr-menez	0	0	0	0	0	0	0	0

## cu-lepid	0	0	0	0	21	0	0	0
## cy-gilbe	0	0	0	0	0	0	0	81
## ge-brasi	7	8	67	23	16	145	32	5
## he-margi	0	0	0	0	0	0	0	0
## ho-malab	0	0	1	0	2	0	0	1
## hy-pusar	0	0	0	0	1	0	0	0
## le-melan	0	2	0	0	0	0	0	0
## le-piau	0	0	0	0	0	0	0	1
## le-taeni	0	1	0	0	0	0	0	0
## mo-costa	0	0	0	0	1	0	0	0
## mo-lepid	0	0	0	0	0	0	0	0
## or-nilot	3	5	1	36	65	11	247	9
## pa-manag	11	0	0	102	0	0	250	0
## pimel-sp	0	0	0	0	0	0	0	0
## po-retic	0	0	10	0	0	46	0	0
## po-vivip	0	0	8	0	0	48	0	0
## pr-brevi	0	9	0	0	6	1	0	0
## ps-rhomb	0	0	0	0	0	0	0	0
## ps-genise	0	0	0	0	0	0	0	0
## se-heter	0	10	0	0	93	0	0	31
## se-piaba	0	0	0	0	0	0	0	0
## se-spilo	0	0	0	0	0	0	0	0
## st-noton	0	0	0	0	0	0	0	0
## sy-marmo	0	0	0	0	0	0	0	0
## te-chalc	0	76	0	0	58	0	0	0
## tr-signa	0	23	0	0	0	0	0	4
##	B-A-MU4	B-A-GU4						
## ap-davis	0	0						
## as-bimac	235	13						
## as-fasci	0	0						
## ch-bimac	0	0						
## ci-ocela	0	0						
## ci-orien	0	0						
## co-macro	0	0						
## co-heter	0	0						
## cr-menez	0	0						
## cu-lepid	0	0						
## cy-gilbe	0	0						
## ge-brasi	509	10						
## he-margi	0	0						
## ho-malab	0	0						
## hy-pusar	0	0						
## le-melan	0	0						
## le-piau	0	0						
## le-taeni	0	0						
## mo-costa	0	0						

17.5. TRANSPOR A MATRIZ PARA TRABALHAR COM AS ESPÉCIES381

```
## mo-lepid      0      0
## or-nilot      1     129
## pa-manag      0     190
## pimel-sp      0      0
## po-retic     266      0
## po-vivip     163      0
## pr-brevi      0      0
## ps-rhomb      0      0
## ps-genise     0      0
## se-heter      0      0
## se-piaba      0      0
## se-spilo      0      0
## st-noton      0      0
## sy-marmo      0      0
## te-chalc      0      0
## tr-signa      0      0
##      S-A-ZA1 S-R-CC1 S-R-CT1 S-R-CP1 S-A-TA1
## ap-davis      0      0      0      0      0
## as-bimac      1     99     194     19     23
## as-fasci      0      0     55      0      1
## ch-bimac      0      0      0      0     13
## ci-ocela      0      0      0      0      0
##      S-A-ZA1 S-R-CC1 S-R-CT1 S-R-CP1 S-A-TA1
## ap-davis      0      0      0      0      0
## as-bimac      1     99     194     19     23
## as-fasci      0      0     55      0      1
## ch-bimac      0      0      0      0     13
## ci-ocela      0      0      0      0      0
## num [1:35, 1:26] 0 1 0 0 0 0 0 0 0 0 ...
## - attr(*, "dimnames")=List of 2
## ..$ : chr [1:35] "ap-davis" "as-bimac" "as-fasci" "ch-bimac" ...
## ..$ : chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## [1] "numeric"
## [1] "matrix" "array"
```

17.5.1 Informações básicas da matriz

Agora podemos pedir ao R as informações básicas da matriz de trabalho (`m_trab`), como o número de observações ou tamanho do vetor (depende do tipo da matriz), número de observações igual a zero, número de observações maiores que zero e proporção de zeros na matriz.

```
range(m_trab) #menor e maior valores
length(m_trab) #no. de colunas
```

```

ncol(m_trab) #no. de N colunas
nrow(m_trab) #no. de M linhas
sum(lengths(m_trab)) #soma os nos. de colunas
length(as.matrix(m_trab)) #tamanho da matriz m x n
sum(m_trab == 0) #número de observações igual a zero
sum(m_trab > 0) #número de observações maiores que zero
#calculando a proporção de zeros na matriz
zeros <- (sum(m_trab == 0)/length(as.matrix(m_trab)))*100
zeros

```

```

## [1] 0 511
## [1] 910
## [1] 26
## [1] 35
## [1] 910
## [1] 910
## [1] 716
## [1] 194
## [1] 78.68132

```

Tabela que resume as informações geradas (Tabela 17.1).

```

##      Comando Resultado
## 1      range    0 - 511
## 2     lenght     910
## 3      n cols      26
## 4   m linhas      35
## 5   Tamanho     910
## 6   Tamanho     910
## 7      Zeros     716
## 8 Nao zeros     194
## 9    % Zeros    78.7

```

Table 17.1: Resumo das informações sobre o tamanho da base de dados.

Comando	Resultado
range	0 - 511
lenght	910
n cols	26
m linhas	35
Tamanho	910
Tamanho	910

Comando	Resultado
Zeros	716
Nao zeros	194
% Zeros	78.7

Ou seja, temos uma matriz de tamanho $m \times n$ igual a 35 objetos por 26 atributos, onde 78.68% dos valores da matriz são iguais a zero!

Agora de conhecimento dessas informações básicas podemos calcular os primeiros descritores da estrutura da comunidade a ser estudada.

17.6 Calculando os descritores da comunidade

Entre outras métricas, calcularemos os seguintes índices:

1. Riqueza de Espécies:

- A riqueza de espécies simplesmente se refere ao número total de espécies diferentes em uma comunidade. É uma medida fundamental da diversidade ecológica e reflete a variedade de formas de vida coexistentes em um ecossistema. Comunidades com alta riqueza de espécies têm um grande número de espécies diferentes, enquanto comunidades com baixa riqueza têm menos espécies.

2. Índice de Diversidade de Simpson:

- O índice de diversidade de Simpson (ou índice de Simpson) mede a probabilidade de escolher aleatoriamente duas vezes o mesmo indivíduo de uma comunidade. Quanto mais próximo de 1 for o índice de Simpson, menor é a diversidade, indicando que uma ou algumas espécies dominam a comunidade. Quanto mais próximo de 0 for o índice de Simpson, maior é a diversidade, indicando uma comunidade mais equilibrada.

3. Índice de Diversidade de Shannon-Wiener:

- O índice de Shannon-Wiener (ou índice de Shannon) leva em consideração a riqueza de espécies e a equitabilidade (distribuição uniforme das abundâncias das espécies). Ele mede a incerteza associada à identificação de uma espécie aleatória em uma comunidade. Quanto maior o índice de Shannon, maior é a diversidade, pois indica uma comunidade com várias espécies bem distribuídas em termos de abundância.

4. Equitabilidade:

- A equitabilidade é uma medida que avalia o quão uniformemente as abundâncias das diferentes espécies estão distribuídas em uma comunidade. Quanto maior a equitabilidade, mais igual é a distribuição das abundâncias, o que indica uma comunidade mais equilibrada.

5. Abundância:

- A abundância se refere ao número total de indivíduos de uma espécie em uma comunidade. É uma medida simples que indica quantos indivíduos de uma espécie específica estão presentes na comunidade.

6. Abundância Relativa:

- A abundância relativa é a proporção ou a fração da abundância de uma espécie em relação à abundância total de todas as espécies na comunidade. É uma medida que ajuda a entender a importância relativa de cada espécie na comunidade.

7. Dominância de Espécies:

- A dominância de espécies se refere à presença de uma ou algumas espécies que têm uma abundância significativamente maior do que as outras na comunidade. Comunidades com alta dominância são frequentemente menos diversas, pois algumas espécies dominantes podem suprimir o crescimento de outras.

17.6.1 Variabilidade

Primeiro a variabilidade estatística

```
##?apply
Sum <- rowSums(m_trab)
#ou
Sum <- apply(m_trab,1,sum)
Sum
## Abundância relativa (%)
RA <- (Sum / sum(Sum)) * 100 # percentage
## Media
Mean <- rowMeans(m_trab)
Mean
```

```
## Ou
Mean <- apply(m_trab,1,mean)
Mean
## Desvio padrão
DP <- apply(m_trab,1,sd)
DP
## Máximo
Max <- apply(m_trab,1,max)
Max
## Mínimo
Min <- apply(m_trab,1,min)
Min
## Mínimo não-zero
MinZ <- apply(m_trab, 1, function(row) {
  non_zero_values <- row[row > 0] # Filter out zero values
  if (length(non_zero_values) == 0) {
    return(0) # If all values are zero, return 0
  } else {
    return(min(non_zero_values)) # Return the minimum of
    ↪ non-zero values
  }
})
MinZ
```

```
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
##      27      2386      158      705      70      143      2      1
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
##      28      21      131      1020      2      109      71      2
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
##      15      1      1      41      848      554      6      381
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
##      978      279      1      1      296      68      1      205
## sy-marmo te-chalc tr-signa
##      1      134      208
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien
## 1.03846154 91.76923077 6.07692308 27.11538462 2.69230769 5.50000000
## co-macro co-heter cr-menez cu-lepid cy-gilbe ge-brasi
## 0.07692308 0.03846154 1.07692308 0.80769231 5.03846154 39.23076923
## he-margi ho-malab hy-pusar le-melan le-piau le-taeni
## 0.07692308 4.19230769 2.73076923 0.07692308 0.57692308 0.03846154
## mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 0.03846154 1.57692308 32.61538462 21.30769231 0.23076923 14.65384615
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba
## 37.61538462 10.73076923 0.03846154 0.03846154 11.38461538 2.61538462
```

```

## se-spilo st-noton sy-marmo te-chalc tr-signa
## 0.03846154 7.88461538 0.03846154 5.15384615 8.00000000
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien
## 1.03846154 91.76923077 6.07692308 27.11538462 2.69230769 5.50000000
## co-macro co-heter cr-menez cu-lepid cy-gilbe ge-brasi
## 0.07692308 0.03846154 1.07692308 0.80769231 5.03846154 39.23076923
## he-margi ho-malab hy-pusar le-melan le-piau le-taeni
## 0.07692308 4.19230769 2.73076923 0.07692308 0.57692308 0.03846154
## mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 0.03846154 1.57692308 32.61538462 21.30769231 0.23076923 14.65384615
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba
## 37.61538462 10.73076923 0.03846154 0.03846154 11.38461538 2.61538462
## se-spilo st-noton sy-marmo te-chalc tr-signa
## 0.03846154 7.88461538 0.03846154 5.15384615 8.00000000
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien
## 4.3861671 132.4348316 16.2035134 75.8732242 8.2982853 14.6184815
## co-macro co-heter cr-menez cu-lepid cy-gilbe ge-brasi
## 0.3922323 0.1961161 3.1486261 4.1184388 18.3313519 106.3478473
## he-margi ho-malab hy-pusar le-melan le-piau le-taeni
## 0.2717465 7.6053625 8.6605205 0.3922323 0.9868364 0.1961161
## mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 0.1961161 7.6376597 59.1452970 62.3928004 1.1766968 52.5242362
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba
## 79.5004790 33.3892889 0.1961161 0.1961161 22.9905666 13.3358972
## se-spilo st-noton sy-marmo te-chalc tr-signa
## 0.1961161 25.5582893 0.1961161 18.3841068 27.8280434
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
## 22 511 64 273 40 69 2 1
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
## 14 21 81 509 1 31 43 2
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 3 1 1 39 247 250 6 266
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
## 326 164 1 1 93 68 1 115
## sy-marmo te-chalc tr-signa
## 1 76 141
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
## 0 0 0 0 0 0 0 0
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
## 0 0 0 0 0 0 0 0
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 0 0 0 0 0 0 0 0
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
## 0 0 0 0 0 0 0 0
## sy-marmo te-chalc tr-signa
## 0 0 0

```

```
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
##      5      1      1      3      2      5      2      1
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
##      1      21     50      1      1      1      1      2
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
##      1      1      1      1      1      1      6      5
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
##      8      1      1      1      3      68      1      1
## sy-marmo te-chalc tr-signa
##      1      58      4
```

17.6.2 Riqueza

Atente para o fato de que a riqueza será a frequência de ocorrência na matrix transposta. Converte-se primeiro para matriz binária.

```
m_pa <- m_trab
m_pa[m_pa != 0] <- 1
rowSums(m_pa)
library(vegan)
bin <- decostand(m_trab, "pa")
bin[1:10, 1:10]
S <- apply(bin, 1, sum)
S
#OU
Riqueza <- specnumber(m_trab)
Riqueza
Riqueza_total <- specnumber(colSums(m_trab))
Riqueza_total
#OU
FO <- rowSums(m_trab > 0) / ncol(m_trab) * 100
FO
```

```
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
##      2      23     10      5      5      7      1      1
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
##      5      1      2     15      2     14      7      1
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
##      8      1      1      3     18      5      1      6
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
##     11     12      1      1     10      1      1      4
## sy-marmo te-chalc tr-signa
##      1      2      6
##      S-A-ZA1 S-R-CC1 S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2
```

```

## ap-davis      0      0      0      0      0      0      0      0
## as-bimac      1      1      1      1      1      1      1      1
## as-fasci      0      0      1      0      1      1      1      0
## ch-bimac      0      0      0      0      1      1      0      1
## ci-ocela      0      0      0      0      0      0      1      0
## ci-orien      0      0      1      0      0      1      1      0
## co-macro      0      0      0      0      0      0      0      0
## co-heter      0      0      1      0      0      0      0      0
## cr-menez      0      0      1      0      0      1      0      0
## cu-lepid      0      0      0      0      0      0      0      0
##      S-R-CT3 S-R-CP3
## ap-davis      0      0
## as-bimac      1      1
## as-fasci      1      0
## ch-bimac      0      0
## ci-ocela      0      1
## ci-orien      1      1
## co-macro      0      0
## co-heter      0      0
## cr-menez      1      0
## cu-lepid      0      0
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
##      2      23      10      5      5      7      1      1
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
##      5      1      2      15      2      14      7      1
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
##      8      1      1      3      18      5      1      6
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
##      11      12      1      1      10      1      1      4
## sy-marmo te-chalc tr-signa
##      1      2      6
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
##      2      23      10      5      5      7      1      1
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
##      5      1      2      15      2      14      7      1
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
##      8      1      1      3      18      5      1      6
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
##      11      12      1      1      10      1      1      4
## sy-marmo te-chalc tr-signa
##      1      2      6
## [1] 26
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
## 7.692308 88.461538 38.461538 19.230769 19.230769 26.923077 3.846154 3.846154
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
## 19.230769 3.846154 7.692308 57.692308 7.692308 53.846154 26.923077 3.846154

```



```
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 30.769231 3.846154 3.846154 11.538462 69.230769 19.230769 3.846154 23.076923
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
## 42.307692 46.153846 3.846154 3.846154 38.461538 3.846154 3.846154 15.384615
## sy-marmo te-chalc tr-signa
## 3.846154 7.692308 23.076923
```

17.7 Índices de Diversidade

17.7.1 Shannon

O índice de diversidade de Shannon ou Shannon–Weaver (or Shannon–Wiener) é uma medida de diversidade que leva em consideração tanto a riqueza de espécies quanto a uniformidade na distribuição dessas espécies (DIXON, 2003; OKSANEN et al., 2020). Este índice é definido por:

$$H' = - \sum_i p_i \log_b p_i$$

Onde:

- H' é a entropia de Shannon.
- p_i é a abundância proporcional da espécie i .
- b é a base do logaritmo.

É mais comum usar-se o logaritmo natural, embora pode-se argumentar que para o logaritmo de base = 2 (o que faz sentido mas nenhuma diferença)

Outra fórmula para calcular o índice de diversidade de Shannon é:

$$H' = - \sum_{i=1}^S \left(\frac{n_i}{N} \times \ln \frac{n_i}{N} \right)$$

Onde:

- H' é a entropia de Shannon (ou a diversidade de Shannon).
- n_i é o número de indivíduos da espécie i .
- N é o número total de indivíduos na comunidade.
- S é o número total de espécies na comunidade.

Esta fórmula mede a incerteza (ou entropia) na identificação de uma espécie selecionada aleatoriamente da comunidade. Quanto maior o valor de H' , maior a diversidade da comunidade.

```
H <- diversity(m_trab, index = "shannon")
H
```

```
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
## 0.4791656 2.4239775 1.4761308 1.1783625 1.1883832 1.4976803 0.0000000 0.0000000
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
## 1.2205076 0.0000000 0.6648803 1.5668772 0.6931472 2.1167591 1.2492728 0.0000000
## le-piau le-taeni mo-costa mo-lepid or-tilot pa-manag pimel-sp po-retic
## 1.9913464 0.0000000 0.0000000 0.2287207 2.1072815 1.1268689 0.0000000 1.0288585
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
## 1.8633952 1.3708151 0.0000000 0.0000000 1.8675926 0.0000000 0.0000000 0.9702899
## sy-marmo te-chalc tr-signa
## 0.0000000 0.6840978 1.0985693
```

17.7.2 Simpson

O índice de diversidade de Simpson é uma medida de diversidade que leva em consideração a riqueza de espécies e a abundância relativa de cada espécie em uma comunidade. A fórmula para calcular o índice de diversidade de Simpson é:

$$D = 1 - \sum_{i=1}^S \left(\frac{n_i(n_i - 1)}{N(N - 1)} \right)$$

Onde:

- D é o índice de diversidade de Simpson.
- n_i é o número de indivíduos da espécie i .
- N é o número total de indivíduos na comunidade.
- S é o número total de espécies na comunidade.

Esta fórmula fornece um valor entre 0 e 1, onde 0 indica uma comunidade com apenas uma espécie presente e 1 indica uma comunidade com uma distribuição uniforme de espécies.

Existem duas variantes do índice de Simpson baseado em $D = \sum p_i^2$ (DIXON, 2003; MACARTHUR; RECHER; CODY, 1966; OKSANEN et al., 2020):

- Ao escolhermos `simpson` o R retorna $1 - D$, e
- ao escolhermos `invsimpson` o R retorna $1/D$.

```
D <- diversity(m_trab, "simpson")
D
D[is.na(D)] <- 0 #substitui NA ou NaN por 0
D
```

```
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro
## 0.30178326 0.88451845 0.69860599 0.67197827 0.61020408 0.70027874 0.00000000
## co-heter cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab
## 0.00000000 0.64540816 0.00000000 0.47200047 0.68977124 0.50000000 0.83982830
## hy-pusar le-melan le-piau le-taeni mo-costa mo-lepid or-nilot
## 0.58956556 0.00000000 0.85333333 0.00000000 0.00000000 0.09399167 0.83992302
## pa-manag pimel-sp po-retic po-vivip pr-brevi ps-rhomb ps-genise
## 0.64444343 0.00000000 0.48641164 0.79634160 0.60348659 0.00000000 0.00000000
## se-heter se-piaba se-spilo st-noton sy-marmo te-chalc tr-signa
## 0.81071950 0.00000000 0.00000000 0.57294468 0.00000000 0.49097795 0.51405325
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro
## 0.30178326 0.88451845 0.69860599 0.67197827 0.61020408 0.70027874 0.00000000
## co-heter cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab
## 0.00000000 0.64540816 0.00000000 0.47200047 0.68977124 0.50000000 0.83982830
## hy-pusar le-melan le-piau le-taeni mo-costa mo-lepid or-nilot
## 0.58956556 0.00000000 0.85333333 0.00000000 0.00000000 0.09399167 0.83992302
## pa-manag pimel-sp po-retic po-vivip pr-brevi ps-rhomb ps-genise
## 0.64444343 0.00000000 0.48641164 0.79634160 0.60348659 0.00000000 0.00000000
## se-heter se-piaba se-spilo st-noton sy-marmo te-chalc tr-signa
## 0.81071950 0.00000000 0.00000000 0.57294468 0.00000000 0.49097795 0.51405325
```

17.7.3 Equitabilidade de Pielou

O índice de equitabilidade de Pielou é uma medida de uniformidade em uma distribuição de espécies (PIELOU, 1975). Sua fórmula é dada por:

$$J' = \frac{H'}{\ln(S)}$$

Onde:

- J' é o índice de equitabilidade de Pielou.
- H' é a entropia de Shannon (ou a diversidade de Shannon), que é calculada como $-\sum_{i=1}^S p_i \cdot \ln(p_i)$, onde S é o número total de espécies e p_i é a proporção da espécie i .
- $\ln(S)$ é o logaritmo natural do número total de espécies na comunidade.

Esta fórmula fornece um valor entre 0 e 1, onde 0 indica uma distribuição completamente desigual onde uma comunidade apresenta uma única espécie dominante e 1 indica uma distribuição completamente equitativa onde todas as espécies têm a mesma abundância.

```
E <- H/log(specnumber(m_trab))
E
E[is.na(E)] <- 0 #substitui NA ou NaN por 0
E
```

```
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
## 0.6912899 0.7730767 0.6410755 0.7321578 0.7383840 0.7696554      NaN      NaN
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
## 0.7583440      NaN 0.9592195 0.5785997 1.0000000 0.8020891 0.6419992      NaN
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 0.9576352      NaN      NaN 0.2081906 0.7290694 0.7001630      NaN 0.5742169
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
## 0.7770962 0.5516566      NaN      NaN 0.8110852      NaN      NaN 0.6999162
## sy-marmo te-chalc tr-signa
##      NaN 0.9869445 0.6131232
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
## 0.6912899 0.7730767 0.6410755 0.7321578 0.7383840 0.7696554 0.0000000 0.0000000
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
## 0.7583440 0.0000000 0.9592195 0.5785997 1.0000000 0.8020891 0.6419992 0.0000000
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 0.9576352 0.0000000 0.0000000 0.2081906 0.7290694 0.7001630 0.0000000 0.5742169
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
## 0.7770962 0.5516566 0.0000000 0.0000000 0.8110852 0.0000000 0.0000000 0.6999162
## sy-marmo te-chalc tr-signa
## 0.0000000 0.9869445 0.6131232
```

17.7.3.1 Assimetria e curtose

A assimetria mede a falta de simetria em uma distribuição de frequência. Uma distribuição é simétrica se as duas metades à esquerda e à direita da média são cópias espelhadas uma da outra. Se a distribuição não é simétrica, então é assimétrica. A assimetria pode ser positiva, negativa ou nula (simétrica). Uma assimetria positiva indica que a cauda da distribuição se estende mais para a direita em relação à média, enquanto uma assimetria negativa indica que a cauda da distribuição se estende mais para a esquerda em relação à média.

A curtose descreve o pico ou a “pontigudez” de uma distribuição. Uma distribuição com alta curtose tem uma alta concentração de valores ao redor da média e caudas mais pesadas (ou seja, valores extremos são mais prováveis).

Uma distribuição com baixa curtose é mais achatada e dispersa, com caudas mais leves. A curtose pode ser positiva (distribuição leptocúrtica, com alta concentração em torno da média e caudas pesadas), negativa (distribuição platícúrtica, com dispersão alta e caudas mais leves) ou nula (mesocúrtica, similar à distribuição normal).

Essas medidas são úteis para compreender as propriedades e características de diferentes conjuntos de dados e distribuições de frequência. Elas ajudam a compreender a forma e o comportamento dos dados em uma amostra ou população (ZAR, 2010).

```
library(moments)
Assimetria <- apply(m_trab,1,skewness)
Assimetria
Curtose <- apply(m_trab,1,kurtosis)
Curtose
```

```
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
## 4.469425 1.774738 2.959549 2.544388 3.796856 3.482201 4.800000 4.800000
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
## 3.252387 4.800000 3.484076 3.638552 3.175426 2.282120 4.127075 4.800000
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 1.437653 4.800000 4.800000 4.790304 2.287297 2.867520 4.800000 4.462822
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
## 2.544468 4.046241 4.800000 4.800000 2.293389 4.800000 4.800000 3.419722
## sy-marmo te-chalc tr-signa
## 4.800000 3.281874 4.442741
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
## 21.730097 5.556931 10.273303 7.736436 17.146010 15.065210 24.040000 24.040000
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
## 12.820351 24.040000 13.776840 16.059988 11.083333 7.604321 19.499005 24.040000
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
## 3.655586 24.040000 24.040000 23.979582 7.972989 9.860393 24.040000 21.825541
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
## 8.674340 18.659676 24.040000 24.040000 7.676958 24.040000 24.040000 13.817921
## sy-marmo te-chalc tr-signa
## 24.040000 12.021173 21.715543
```

17.7.3.2 Tabela de descritores

Muito confuso? Criamos na sequência uma tabela final com todos os descritores da comunidade e da normalidade.

17.7.3.2.1 Descritores da estrutura da comunidade: Espécies Sum, soma; RA, abundância relativa (%), mean, média; DP, desvio padrão da média; Max, maior valor; Min, menor valor; S, riqueza (ou frequência de ocorrência na matriz transposta); RR, riqueza rarefacionada; E, índice de equitabilidade de Pielou (PIELOU, 1975); H, índice de diversidade de Shannon (LUDWIG; REYNOLDS, 1988); D, índice de diversidade de Simpson (HURLBERT, 1971).

```
RR <- S
Descritores1 <- cbind(Sum, RA, Mean, DP, Max, Min, MinZ, FO, S,
  ↪ RR, E, H, D)
Descritores1 <- as.data.frame(Descritores1)
Descritores1
#Descritores1 <- Descritores1 %>%
  ↪ rownames_to_column(var="Espécies") #da nome a primeira coluna
SomaTotalD <- apply(Descritores1,2,sum)
SomaTotalD
MediaTotalD <- apply(Descritores1,2,mean)
MediaTotalD
DPTotalD <- apply(Descritores1,2,sd)
DPTotalD
Descritores2 <- cbind(SomaTotalD, MediaTotalD, DPTotalD)
Descritores2 <- as.data.frame(Descritores2)
Descritores2 <- t(Descritores2)
Descritores2
DescritoresFinal <- rbind(Descritores1, Descritores2)
DescritoresFinal
DescritoresFinal <- round (DescritoresFinal, 2)
DescritoresFinal
```

##	Sum	RA	Mean	DP	Max	Min	MinZ	FO	S	RR
## ap-davis	27	0.30354132	1.03846154	4.3861671	22	0	5	7.692308	2	2
## as-bimac	2386	26.82405846	91.76923077	132.4348316	511	0	1	88.461538	23	23
## as-fasci	158	1.77627881	6.07692308	16.2035134	64	0	1	38.461538	10	10
## ch-bimac	705	7.92580101	27.11538462	75.8732242	273	0	3	19.230769	5	5
## ci-ocela	70	0.78695897	2.69230769	8.2982853	40	0	2	19.230769	5	5
## ci-orien	143	1.60764474	5.50000000	14.6184815	69	0	5	26.923077	7	7
## co-macro	2	0.02248454	0.07692308	0.3922323	2	0	2	3.846154	1	1
## co-heter	1	0.01124227	0.03846154	0.1961161	1	0	1	3.846154	1	1
## cr-menez	28	0.31478359	1.07692308	3.1486261	14	0	1	19.230769	5	5
## cu-lepid	21	0.23608769	0.80769231	4.1184388	21	0	21	3.846154	1	1
## cy-gilbe	131	1.47273749	5.03846154	18.3313519	81	0	50	7.692308	2	2
## ge-brasi	1020	11.46711636	39.23076923	106.3478473	509	0	1	57.692308	15	15
## he-margi	2	0.02248454	0.07692308	0.2717465	1	0	1	7.692308	2	2
## ho-malab	109	1.22540753	4.19230769	7.6053625	31	0	1	53.846154	14	14
## hy-pusar	71	0.79820124	2.73076923	8.6605205	43	0	1	26.923077	7	7

## le-melan	2	0.02248454	0.07692308	0.3922323	2	0	2	3.846154	1	1
## le-piau	15	0.16863406	0.57692308	0.9868364	3	0	1	30.769231	8	8
## le-taeni	1	0.01124227	0.03846154	0.1961161	1	0	1	3.846154	1	1
## mo-costa	1	0.01124227	0.03846154	0.1961161	1	0	1	3.846154	1	1
## mo-lepid	41	0.46093311	1.57692308	7.6376597	39	0	1	11.538462	3	3
## or-nilot	848	9.53344576	32.61538462	59.1452970	247	0	1	69.230769	18	18
## pa-manag	554	6.22821810	21.30769231	62.3928004	250	0	1	19.230769	5	5
## pimel-sp	6	0.06745363	0.23076923	1.1766968	6	0	6	3.846154	1	1
## po-retic	381	4.28330523	14.65384615	52.5242362	266	0	5	23.076923	6	6
## po-vivip	978	10.99494098	37.61538462	79.5004790	326	0	8	42.307692	11	11
## pr-brevi	279	3.13659359	10.73076923	33.3892889	164	0	1	46.153846	12	12
## ps-rhomb	1	0.01124227	0.03846154	0.1961161	1	0	1	3.846154	1	1
## ps-genise	1	0.01124227	0.03846154	0.1961161	1	0	1	3.846154	1	1
## se-heter	296	3.32771220	11.38461538	22.9905666	93	0	3	38.461538	10	10
## se-piaba	68	0.76447442	2.61538462	13.3358972	68	0	68	3.846154	1	1
## se-spilo	1	0.01124227	0.03846154	0.1961161	1	0	1	3.846154	1	1
## st-noton	205	2.30466554	7.88461538	25.5582893	115	0	1	15.384615	4	4
## sy-marmo	1	0.01124227	0.03846154	0.1961161	1	0	1	3.846154	1	1
## te-chalc	134	1.50646431	5.15384615	18.3841068	76	0	58	7.692308	2	2
## tr-signa	208	2.33839236	8.00000000	27.8280434	141	0	4	23.076923	6	6
##		E	H	D						
## ap-davis	0.6912899	0.4791656	0.30178326							
## as-bimac	0.7730767	2.4239775	0.88451845							
## as-fasci	0.6410755	1.4761308	0.69860599							
## ch-bimac	0.7321578	1.1783625	0.67197827							
## ci-ocela	0.7383840	1.1883832	0.61020408							
## ci-orien	0.7696554	1.4976803	0.70027874							
## co-macro	0.0000000	0.0000000	0.00000000							
## co-heter	0.0000000	0.0000000	0.00000000							
## cr-menez	0.7583440	1.2205076	0.64540816							
## cu-lepid	0.0000000	0.0000000	0.00000000							
## cy-gilbe	0.9592195	0.6648803	0.47200047							
## ge-brasi	0.5785997	1.5668772	0.68977124							
## he-margi	1.0000000	0.6931472	0.50000000							
## ho-malab	0.8020891	2.1167591	0.83982830							
## hy-pusar	0.6419992	1.2492728	0.58956556							
## le-melan	0.0000000	0.0000000	0.00000000							
## le-piau	0.9576352	1.9913464	0.85333333							
## le-taeni	0.0000000	0.0000000	0.00000000							
## mo-costa	0.0000000	0.0000000	0.00000000							
## mo-lepid	0.2081906	0.2287207	0.09399167							
## or-nilot	0.7290694	2.1072815	0.83992302							
## pa-manag	0.7001630	1.1268689	0.64444343							
## pimel-sp	0.0000000	0.0000000	0.00000000							
## po-retic	0.5742169	1.0288585	0.48641164							
## po-vivip	0.7770962	1.8633952	0.79634160							

```

## pr-brevi 0.5516566 1.3708151 0.60348659
## ps-rhomb 0.0000000 0.0000000 0.00000000
## ps-genise 0.0000000 0.0000000 0.00000000
## se-heter 0.8110852 1.8675926 0.81071950
## se-piaba 0.0000000 0.0000000 0.00000000
## se-spilo 0.0000000 0.0000000 0.00000000
## st-noton 0.6999162 0.9702899 0.57294468
## sy-marmo 0.0000000 0.0000000 0.00000000
## te-chalc 0.9869445 0.6840978 0.49097795
## tr-signa 0.6131232 1.0985693 0.51405325
##      Sum      RA      Mean      DP      Max      Min      MinZ
## 8895.00000 100.00000 342.11538 807.30587 3484.00000 0.00000 262.00000
##      FO      S      RR      E      H      D
## 746.15385 194.00000 194.00000 16.69499 30.09298 14.31057
##      Sum      RA      Mean      DP      Max      Min
## 254.1428571 2.8571429 9.7747253 23.0658821 99.5428571 0.0000000
##      MinZ      FO      S      RR      E      H
## 7.4857143 21.3186813 5.5428571 5.5428571 0.4769997 0.8597994
##      D
## 0.4088734
##      Sum      RA      Mean      DP      Max      Min
## 468.3865386 5.2657284 18.0148669 33.0609233 138.2715450 0.0000000
##      MinZ      FO      S      RR      E      H
## 16.4573807 21.3807831 5.5590036 5.5590036 0.3757324 0.7784814
##      D
## 0.3354621
##      Sum      RA      Mean      DP      Max Min      MinZ
## SomaTotalD 8895.0000 100.000000 342.115385 807.30587 3484.00000 0 262.000000
## MediaTotalD 254.1429 2.857143 9.774725 23.06588 99.54286 0 7.485714
## DPTotalD 468.3865 5.265728 18.014867 33.06092 138.27155 0 16.457381
##      FO      S      RR      E      H      D
## SomaTotalD 746.15385 194.000000 194.000000 16.6949878 30.0929803 14.3105692
## MediaTotalD 21.31868 5.542857 5.542857 0.4769997 0.8597994 0.4088734
## DPTotalD 21.38078 5.559004 5.559004 0.3757324 0.7784814 0.3354621
##      Sum      RA      Mean      DP      Max Min
## ap-davis 27.0000 0.30354132 1.03846154 4.3861671 22.00000 0
## as-bimac 2386.0000 26.82405846 91.76923077 132.4348316 511.00000 0
## as-fasci 158.0000 1.77627881 6.07692308 16.2035134 64.00000 0
## ch-bimac 705.0000 7.92580101 27.11538462 75.8732242 273.00000 0
## ci-ocela 70.0000 0.78695897 2.69230769 8.2982853 40.00000 0
## ci-orien 143.0000 1.60764474 5.50000000 14.6184815 69.00000 0
## co-macro 2.0000 0.02248454 0.07692308 0.3922323 2.00000 0
## co-heter 1.0000 0.01124227 0.03846154 0.1961161 1.00000 0
## cr-menez 28.0000 0.31478359 1.07692308 3.1486261 14.00000 0
## cu-lepid 21.0000 0.23608769 0.80769231 4.1184388 21.00000 0
## cy-gilbe 131.0000 1.47273749 5.03846154 18.3313519 81.00000 0

```


## ge-brasi	1020.0000	11.46711636	39.23076923	106.3478473	509.00000	0
## he-margi	2.0000	0.02248454	0.07692308	0.2717465	1.00000	0
## ho-malab	109.0000	1.22540753	4.19230769	7.6053625	31.00000	0
## hy-pusar	71.0000	0.79820124	2.73076923	8.6605205	43.00000	0
## le-melan	2.0000	0.02248454	0.07692308	0.3922323	2.00000	0
## le-piau	15.0000	0.16863406	0.57692308	0.9868364	3.00000	0
## le-taeni	1.0000	0.01124227	0.03846154	0.1961161	1.00000	0
## mo-costa	1.0000	0.01124227	0.03846154	0.1961161	1.00000	0
## mo-lepid	41.0000	0.46093311	1.57692308	7.6376597	39.00000	0
## or-nilot	848.0000	9.53344576	32.61538462	59.1452970	247.00000	0
## pa-manag	554.0000	6.22821810	21.30769231	62.3928004	250.00000	0
## pimel-sp	6.0000	0.06745363	0.23076923	1.1766968	6.00000	0
## po-retic	381.0000	4.28330523	14.65384615	52.5242362	266.00000	0
## po-vivip	978.0000	10.99494098	37.61538462	79.5004790	326.00000	0
## pr-brevi	279.0000	3.13659359	10.73076923	33.3892889	164.00000	0
## ps-rhomb	1.0000	0.01124227	0.03846154	0.1961161	1.00000	0
## ps-genise	1.0000	0.01124227	0.03846154	0.1961161	1.00000	0
## se-heter	296.0000	3.32771220	11.38461538	22.9905666	93.00000	0
## se-piaba	68.0000	0.76447442	2.61538462	13.3358972	68.00000	0
## se-spilo	1.0000	0.01124227	0.03846154	0.1961161	1.00000	0
## st-noton	205.0000	2.30466554	7.88461538	25.5582893	115.00000	0
## sy-marmo	1.0000	0.01124227	0.03846154	0.1961161	1.00000	0
## te-chalc	134.0000	1.50646431	5.15384615	18.3841068	76.00000	0
## tr-signa	208.0000	2.33839236	8.00000000	27.8280434	141.00000	0
## SomaTotalD	8895.0000	100.00000000	342.11538462	807.3058718	3484.00000	0
## MediaTotalD	254.1429	2.85714286	9.77472527	23.0658821	99.54286	0
## DPTotalD	468.3865	5.26572837	18.01486687	33.0609233	138.27155	0
##	MinZ	F0	S	RR	E	H
## ap-davis	5.000000	7.692308	2.000000	2.000000	0.6912899	0.4791656
## as-bimac	1.000000	88.461538	23.000000	23.000000	0.7730767	2.4239775
## as-fasci	1.000000	38.461538	10.000000	10.000000	0.6410755	1.4761308
## ch-bimac	3.000000	19.230769	5.000000	5.000000	0.7321578	1.1783625
## ci-ocela	2.000000	19.230769	5.000000	5.000000	0.7383840	1.1883832
## ci-orien	5.000000	26.923077	7.000000	7.000000	0.7696554	1.4976803
## co-macro	2.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## co-heter	1.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## cr-menez	1.000000	19.230769	5.000000	5.000000	0.7583440	1.2205076
## cu-lepid	21.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## cy-gilbe	50.000000	7.692308	2.000000	2.000000	0.9592195	0.6648803
## ge-brasi	1.000000	57.692308	15.000000	15.000000	0.5785997	1.5668772
## he-margi	1.000000	7.692308	2.000000	2.000000	1.0000000	0.6931472
## ho-malab	1.000000	53.846154	14.000000	14.000000	0.8020891	2.1167591
## hy-pusar	1.000000	26.923077	7.000000	7.000000	0.6419992	1.2492728
## le-melan	2.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## le-piau	1.000000	30.769231	8.000000	8.000000	0.9576352	1.9913464
## le-taeni	1.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000

## mo-costa	1.000000	3.846154	1.000000	1.000000	0.000000	0.000000
## mo-lepid	1.000000	11.538462	3.000000	3.000000	0.2081906	0.2287207
## or-nilot	1.000000	69.230769	18.000000	18.000000	0.7290694	2.1072815
## pa-manag	1.000000	19.230769	5.000000	5.000000	0.7001630	1.1268689
## pimel-sp	6.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## po-retic	5.000000	23.076923	6.000000	6.000000	0.5742169	1.0288585
## po-vivip	8.000000	42.307692	11.000000	11.000000	0.7770962	1.8633952
## pr-brevi	1.000000	46.153846	12.000000	12.000000	0.5516566	1.3708151
## ps-rhomb	1.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## ps-genise	1.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## se-heter	3.000000	38.461538	10.000000	10.000000	0.8110852	1.8675926
## se-piaba	68.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## se-spilo	1.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## st-noton	1.000000	15.384615	4.000000	4.000000	0.6999162	0.9702899
## sy-marmo	1.000000	3.846154	1.000000	1.000000	0.0000000	0.0000000
## te-chalc	58.000000	7.692308	2.000000	2.000000	0.9869445	0.6840978
## tr-signa	4.000000	23.076923	6.000000	6.000000	0.6131232	1.0985693
## SomaTotalD	262.000000	746.153846	194.000000	194.000000	16.6949878	30.0929803
## MediaTotalD	7.485714	21.318681	5.542857	5.542857	0.4769997	0.8597994
## DPTotalD	16.457381	21.380783	5.559004	5.559004	0.3757324	0.7784814
##		D				
## ap-davis	0.30178326					
## as-bimac	0.88451845					
## as-fasci	0.69860599					
## ch-bimac	0.67197827					
## ci-ocela	0.61020408					
## ci-orien	0.70027874					
## co-macro	0.00000000					
## co-heter	0.00000000					
## cr-menez	0.64540816					
## cu-lepid	0.00000000					
## cy-gilbe	0.47200047					
## ge-brasi	0.68977124					
## he-margi	0.50000000					
## ho-malab	0.83982830					
## hy-pusar	0.58956556					
## le-melan	0.00000000					
## le-piau	0.85333333					
## le-taeni	0.00000000					
## mo-costa	0.00000000					
## mo-lepid	0.09399167					
## or-nilot	0.83992302					
## pa-manag	0.64444343					
## pimel-sp	0.00000000					
## po-retic	0.48641164					
## po-vivip	0.79634160					

## pr-brevi	0.60348659								
## ps-rhomb	0.00000000								
## ps-genise	0.00000000								
## se-heter	0.81071950								
## se-piaba	0.00000000								
## se-spilo	0.00000000								
## st-noton	0.57294468								
## sy-marmo	0.00000000								
## te-chalc	0.49097795								
## tr-signa	0.51405325								
## SomaTotalD	14.31056920								
## MediaTotalD	0.40887341								
## DPTotalD	0.33546207								
##	Sum	RA	Mean	DP	Max	Min	MinZ	FO	S
## ap-davis	27.00	0.30	1.04	4.39	22.00	0	5.00	7.69	2.00
## as-bimac	2386.00	26.82	91.77	132.43	511.00	0	1.00	88.46	23.00
## as-fasci	158.00	1.78	6.08	16.20	64.00	0	1.00	38.46	10.00
## ch-bimac	705.00	7.93	27.12	75.87	273.00	0	3.00	19.23	5.00
## ci-ocela	70.00	0.79	2.69	8.30	40.00	0	2.00	19.23	5.00
## ci-orien	143.00	1.61	5.50	14.62	69.00	0	5.00	26.92	7.00
## co-macro	2.00	0.02	0.08	0.39	2.00	0	2.00	3.85	1.00
## co-heter	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00
## cr-menez	28.00	0.31	1.08	3.15	14.00	0	1.00	19.23	5.00
## cu-lepid	21.00	0.24	0.81	4.12	21.00	0	21.00	3.85	1.00
## cy-gilbe	131.00	1.47	5.04	18.33	81.00	0	50.00	7.69	2.00
## ge-brasi	1020.00	11.47	39.23	106.35	509.00	0	1.00	57.69	15.00
## he-margi	2.00	0.02	0.08	0.27	1.00	0	1.00	7.69	2.00
## ho-malab	109.00	1.23	4.19	7.61	31.00	0	1.00	53.85	14.00
## hy-pusar	71.00	0.80	2.73	8.66	43.00	0	1.00	26.92	7.00
## le-melan	2.00	0.02	0.08	0.39	2.00	0	2.00	3.85	1.00
## le-piau	15.00	0.17	0.58	0.99	3.00	0	1.00	30.77	8.00
## le-taeni	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00
## mo-costa	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00
## mo-lepid	41.00	0.46	1.58	7.64	39.00	0	1.00	11.54	3.00
## or-nilot	848.00	9.53	32.62	59.15	247.00	0	1.00	69.23	18.00
## pa-manag	554.00	6.23	21.31	62.39	250.00	0	1.00	19.23	5.00
## pimel-sp	6.00	0.07	0.23	1.18	6.00	0	6.00	3.85	1.00
## po-retic	381.00	4.28	14.65	52.52	266.00	0	5.00	23.08	6.00
## po-vivip	978.00	10.99	37.62	79.50	326.00	0	8.00	42.31	11.00
## pr-brevi	279.00	3.14	10.73	33.39	164.00	0	1.00	46.15	12.00
## ps-rhomb	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00
## ps-genise	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00
## se-heter	296.00	3.33	11.38	22.99	93.00	0	3.00	38.46	10.00
## se-piaba	68.00	0.76	2.62	13.34	68.00	0	68.00	3.85	1.00
## se-spilo	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00
## st-noton	205.00	2.30	7.88	25.56	115.00	0	1.00	15.38	4.00

## sy-marmo	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00
## te-chalc	134.00	1.51	5.15	18.38	76.00	0	58.00	7.69	2.00
## tr-signa	208.00	2.34	8.00	27.83	141.00	0	4.00	23.08	6.00
## SomaTotalD	8895.00	100.00	342.12	807.31	3484.00	0	262.00	746.15	194.00
## MediaTotalD	254.14	2.86	9.77	23.07	99.54	0	7.49	21.32	5.54
## DPTotalD	468.39	5.27	18.01	33.06	138.27	0	16.46	21.38	5.56
##	RR	E	H	D					
## ap-davis	2.00	0.69	0.48	0.30					
## as-bimac	23.00	0.77	2.42	0.88					
## as-fasci	10.00	0.64	1.48	0.70					
## ch-bimac	5.00	0.73	1.18	0.67					
## ci-ocela	5.00	0.74	1.19	0.61					
## ci-orien	7.00	0.77	1.50	0.70					
## co-macro	1.00	0.00	0.00	0.00					
## co-heter	1.00	0.00	0.00	0.00					
## cr-menez	5.00	0.76	1.22	0.65					
## cu-lepid	1.00	0.00	0.00	0.00					
## cy-gilbe	2.00	0.96	0.66	0.47					
## ge-brasi	15.00	0.58	1.57	0.69					
## he-margi	2.00	1.00	0.69	0.50					
## ho-malab	14.00	0.80	2.12	0.84					
## hy-pusar	7.00	0.64	1.25	0.59					
## le-melan	1.00	0.00	0.00	0.00					
## le-piau	8.00	0.96	1.99	0.85					
## le-taeni	1.00	0.00	0.00	0.00					
## mo-costa	1.00	0.00	0.00	0.00					
## mo-lepid	3.00	0.21	0.23	0.09					
## or-nilot	18.00	0.73	2.11	0.84					
## pa-manag	5.00	0.70	1.13	0.64					
## pimel-sp	1.00	0.00	0.00	0.00					
## po-retic	6.00	0.57	1.03	0.49					
## po-vivip	11.00	0.78	1.86	0.80					
## pr-brevi	12.00	0.55	1.37	0.60					
## ps-rhomb	1.00	0.00	0.00	0.00					
## ps-genise	1.00	0.00	0.00	0.00					
## se-heter	10.00	0.81	1.87	0.81					
## se-piaba	1.00	0.00	0.00	0.00					
## se-spilo	1.00	0.00	0.00	0.00					
## st-noton	4.00	0.70	0.97	0.57					
## sy-marmo	1.00	0.00	0.00	0.00					
## te-chalc	2.00	0.99	0.68	0.49					
## tr-signa	6.00	0.61	1.10	0.51					
## SomaTotalD	194.00	16.69	30.09	14.31					
## MediaTotalD	5.54	0.48	0.86	0.41					
## DPTotalD	5.56	0.38	0.78	0.34					

```

#Fazendo uma tabela
library(gt)
df <- DescritoresFinal
ncol(df); nrow(df) #no. de N colunas x M linhas
df <- cbind(Spp = rownames(df), df)
gt(df, rowname_col = "Spp", caption = "Descritores da diversidade
  ↳ por espécie (colunas). Sum, soma; RA, abundância relativa
  ↳ (%); mean, média; DP, desvio padrão da média; Max, maior
  ↳ valor; Min, menor valor; MinZ, menor valor não zero; F0,
  ↳ frequência de ocorrência (%); S, riqueza (ou no. de
  ↳ ocorrências, da matriz transposta); E, índice de
  ↳ equitabilidade de Pielou; H, índice de diversidade de
  ↳ Shannon; D, índice de diversidade de Simpson.")

```

```

## [1] 13
## [1] 38

```

17.7.3.2.2 Descritores da normalidade Agora tabelamos os descritores de normalidade

```

Normalidade1 <- cbind(Assimetria, Curtose)
Normalidade1 <- as.data.frame(Normalidade1)
Normalidade1
SomaTotalN <- apply(Normalidade1,2,sum)
SomaTotalN
MediaTotalN <- apply(Normalidade1,2,mean)
MediaTotalN
DPTotalN <- apply(Normalidade1,2,sd)
DPTotalN
Normalidade2<-cbind(SomaTotalN, MediaTotalN, DPTotalN)
Normalidade2<-as.data.frame(Normalidade2)
Normalidade2 <- t(Normalidade2) #"t" transpoe a matriz
Normalidade2
NormalidadeFinal <- rbind(Normalidade1, Normalidade2)
NormalidadeFinal
NormalidadeFinal <- round(NormalidadeFinal, 2)
NormalidadeFinal

```

```

##          Assimetria   Curtose
## ap-davis    4.469425 21.730097
## as-bimac    1.774738  5.556931

```

```

## as-fasci      2.959549 10.273303
## ch-bimac      2.544388  7.736436
## ci-ocela      3.796856 17.146010
## ci-orien      3.482201 15.065210
## co-macro      4.800000 24.040000
## co-heter      4.800000 24.040000
## cr-menez      3.252387 12.820351
## cu-lepid      4.800000 24.040000
## cy-gilbe      3.484076 13.776840
## ge-brasi      3.638552 16.059988
## he-margi      3.175426 11.083333
## ho-malab      2.282120  7.604321
## hy-pusar      4.127075 19.499005
## le-melan      4.800000 24.040000
## le-piau       1.437653  3.655586
## le-taeni      4.800000 24.040000
## mo-costa      4.800000 24.040000
## mo-lepid      4.790304 23.979582
## or-nilot      2.287297  7.972989
## pa-manag      2.867520  9.860393
## pimel-sp      4.800000 24.040000
## po-retic      4.462822 21.825541
## po-vivip      2.544468  8.674340
## pr-brevi      4.046241 18.659676
## ps-rhomb      4.800000 24.040000
## ps-genise     4.800000 24.040000
## se-heter      2.293389  7.676958
## se-piaba      4.800000 24.040000
## se-spilo      4.800000 24.040000
## st-noton      3.419722 13.817921
## sy-marmo      4.800000 24.040000
## te-chalc      3.281874 12.021173
## tr-signa      4.442741 21.715543
## Assimetria    Curtose
## 132.4608      596.6915
## Assimetria    Curtose
## 3.784595      17.048329
## Assimetria    Curtose
## 1.043802      6.944634
##               Assimetria    Curtose
## SomaTotalN    132.460824 596.691528
## MediaTotalN   3.784595  17.048329
## DPTotalN      1.043802  6.944634
##               Assimetria    Curtose
## ap-davis      4.469425 21.730097
## as-bimac      1.774738  5.556931

```

## as-fasci	2.959549	10.273303
## ch-bimac	2.544388	7.736436
## ci-ocela	3.796856	17.146010
## ci-orien	3.482201	15.065210
## co-macro	4.800000	24.040000
## co-heter	4.800000	24.040000
## cr-menez	3.252387	12.820351
## cu-lepid	4.800000	24.040000
## cy-gilbe	3.484076	13.776840
## ge-brasi	3.638552	16.059988
## he-margi	3.175426	11.083333
## ho-malab	2.282120	7.604321
## hy-pusar	4.127075	19.499005
## le-melan	4.800000	24.040000
## le-piau	1.437653	3.655586
## le-taeni	4.800000	24.040000
## mo-costa	4.800000	24.040000
## mo-lepid	4.790304	23.979582
## or-nilot	2.287297	7.972989
## pa-manag	2.867520	9.860393
## pimel-sp	4.800000	24.040000
## po-retic	4.462822	21.825541
## po-vivip	2.544468	8.674340
## pr-brevi	4.046241	18.659676
## ps-rhomb	4.800000	24.040000
## ps-genise	4.800000	24.040000
## se-heter	2.293389	7.676958
## se-piaba	4.800000	24.040000
## se-spilo	4.800000	24.040000
## st-noton	3.419722	13.817921
## sy-marmo	4.800000	24.040000
## te-chalc	3.281874	12.021173
## tr-signa	4.442741	21.715543
## SomaTotalN	132.460824	596.691528
## MediaTotalN	3.784595	17.048329
## DPTotalN	1.043802	6.944634
##	Assimetria	Curtose
## ap-davis	4.47	21.73
## as-bimac	1.77	5.56
## as-fasci	2.96	10.27
## ch-bimac	2.54	7.74
## ci-ocela	3.80	17.15
## ci-orien	3.48	15.07
## co-macro	4.80	24.04
## co-heter	4.80	24.04
## cr-menez	3.25	12.82

```
## cu-lepid      4.80  24.04
## cy-gilbe      3.48  13.78
## ge-brasi      3.64  16.06
## he-margi      3.18  11.08
## ho-malab      2.28   7.60
## hy-pusar      4.13  19.50
## le-melan      4.80  24.04
## le-piau       1.44   3.66
## le-taeni      4.80  24.04
## mo-costa      4.80  24.04
## mo-lepid      4.79  23.98
## or-nilot      2.29   7.97
## pa-manag      2.87   9.86
## pimel-sp      4.80  24.04
## po-retic      4.46  21.83
## po-vivip      2.54   8.67
## pr-brevi      4.05  18.66
## ps-rhomb      4.80  24.04
## ps-genise     4.80  24.04
## se-heter      2.29   7.68
## se-piaba      4.80  24.04
## se-spilo      4.80  24.04
## st-noton      3.42  13.82
## sy-marmo      4.80  24.04
## te-chalc      3.28  12.02
## tr-signa      4.44  21.72
## SomaTotalN    132.46 596.69
## MediaTotalN   3.78  17.05
## DPTotalN      1.04   6.94
```

A função `fix(nome da matriz)` dá acesso ao grid da matriz criada para manipulação dos dados numéricos.

```
#Fazendo uma tabela
nf <- NormalidadeFinal
ncol(nf); nrow(nf) #no. de N colunas x M linhas
nf <- cbind(Spp = rownames(nf), nf)
gt(nf, rowname_col = "Spp", caption = "Descritores da normalidade
↪ por espécie (coluna)")
```

```
## [1] 2
## [1] 38
```

Nos Apêndices você pode ver o script para os mesmos descritores para as Unidades Amostrais (UA's)

17.7.3.3 Lidando com células vazias

Em R, `NaN` (Not a Number) e `NA` (Not Available) são valores especiais que representam dados ausentes ou valores inválidos em um vetor, matriz, data frame ou outra estrutura de dados.

- **NaN (Not a Number):** É usado para representar resultados inválidos em operações matemáticas, como a divisão por zero ou a operação de raiz quadrada de um número negativo.
- **NA (Not Available):** É usado para indicar dados ausentes. Pode ser usado em contextos onde o valor real está ausente ou desconhecido.

Em muitas operações, o `NA` é tratado como um valor especial que propagará em outras operações. Isso significa que se uma operação é realizada com um ou mais valores `NA`, o resultado geralmente será `NA`. Por outro lado, `NaN` é um valor específico que indica um resultado matematicamente indefinido ou inválido.

Por exemplo, ao realizar operações em um vetor que contém `NA`, o resultado será `NA` para qualquer operação que envolva um valor `NA`:

```
x <- c(1, 2, NA, 4)
mean(x) # Resultado será NA porque há um valor NA no vetor
```

```
## [1] NA
```

Por outro lado, `NaN` resulta de operações matemáticas inválidas:

```
0/0 # Resultado será NaN, pois a divisão por zero é indefinida
sqrt(-1) # Resultado será NaN, pois não há raiz quadrada real de
  ↪ um número negativo
```

```
## Warning in sqrt(-1): NaNs produzidos
```

```
## [1] NaN
## [1] NaN
```

Em resumo, enquanto `NA` indica dados ausentes ou não disponíveis, `NaN` indica resultados de operações matematicamente inválidos.

```

write.table(data.frame("Spp"=rownames(DescritoresFinal),
                      DescritoresFinal),
            "DescritoresSPP.txt",
            row.names=FALSE,
            sep="\t")
write.table(data.frame("Spp"=rownames(NormalidadeFinal),
                      NormalidadeFinal),
            "NormalidadeSPP.txt",
            row.names=FALSE,
            sep="\t")

```

17.7.3.3.1 Salvando as tabelas criadas em .txt direto no diretório de trabalho Agora é necessário voltar à matriz comunitária (antes de ter sido transposta), antes de continuarmos a análise, porque as análises anteriores também precisam ser refeitas com a matriz não transposta. A seguir confere-se se está sendo usada a matriz comunitária com as espécies nas colunas.

Para ver o código dos descritores da estrutura da comunidade para as Unidades Amostrais (UA's), matriz não transposta, veja Descritores da estrutura da comunidade: UA's nos apêndices.

m_trab

##	S-A-ZA1	S-R-CC1	S-R-CT1	S-R-CP1	S-A-TA1	S-R-CT2	S-R-CP2	S-A-TA2
## ap-davis	0	0	0	0	0	0	0	0
## as-bimac	1	99	194	19	23	142	5	46
## as-fasci	0	0	55	0	1	3	1	0
## ch-bimac	0	0	0	0	13	3	0	178
## ci-ocela	0	0	0	0	0	0	40	0
## ci-orien	0	0	5	0	0	69	9	0
## co-macro	0	0	0	0	0	0	0	0
## co-heter	0	0	1	0	0	0	0	0
## cr-menez	0	0	14	0	0	4	0	0
## cu-lepid	0	0	0	0	0	0	0	0
## cy-gilbe	0	0	0	0	0	0	0	0
## ge-brasi	0	0	3	0	0	0	0	0
## he-margi	0	0	0	0	0	1	0	0
## ho-malab	0	0	1	5	0	17	10	2
## hy-pusar	0	0	9	2	0	43	2	0
## le-melan	0	0	0	0	0	0	0	0
## le-piau	0	0	3	0	0	1	3	0

## le-taeni	0	0	0	0	0	0	0	0
## mo-costa	0	0	0	0	0	0	0	0
## mo-lepid	0	1	39	0	0	1	0	0
## or-nilot	0	2	36	0	0	77	0	0
## pa-manag	0	0	0	0	0	0	0	0
## pimel-sp	0	0	6	0	0	0	0	0
## po-retic	0	0	0	0	0	20	0	0
## po-vivip	0	0	47	15	0	221	32	0
## pr-brevi	9	0	5	0	1	15	5	2
## ps-rhomb	0	0	0	0	0	0	0	0
## ps-genise	0	0	0	0	0	0	0	0
## se-heter	0	0	40	14	4	60	0	0
## se-piaba	0	0	68	0	0	0	0	0
## se-spilo	0	0	0	0	0	0	0	0
## st-noton	0	0	1	0	0	25	0	0
## sy-marmo	0	0	0	0	0	0	1	0
## te-chalc	0	0	0	0	0	0	0	0
## tr-signa	0	0	18	0	0	15	0	0
##	S-R-CT3	S-R-CP3	S-A-TA3	S-R-CT4	S-R-CP4	S-A-TA4	B-A-MU1	B-R-ET1
## ap-davis	0	0	0	0	0	0	0	0
## as-bimac	206	16	234	0	0	394	12	3
## as-fasci	64	0	7	1	0	0	0	0
## ch-bimac	0	0	238	0	0	273	0	0
## ci-ocela	0	13	0	0	11	0	0	0
## ci-orien	25	24	0	5	6	0	0	0
## co-macro	0	0	2	0	0	0	0	0
## co-heter	0	0	0	0	0	0	0	0
## cr-menez	8	0	0	1	0	1	0	0
## cu-lepid	0	0	0	0	0	0	0	0
## cy-gilbe	0	0	0	50	0	0	0	0
## ge-brasi	1	0	0	3	0	1	190	0
## he-margi	0	0	0	1	0	0	0	0
## ho-malab	31	4	20	4	2	9	0	0
## hy-pusar	11	0	0	3	0	0	0	0
## le-melan	0	0	0	0	0	0	0	0
## le-piau	2	1	0	0	2	2	0	0
## le-taeni	0	0	0	0	0	0	0	0
## mo-costa	0	0	0	0	0	0	0	0
## mo-lepid	0	0	0	0	0	0	0	0
## or-nilot	138	0	0	73	0	1	6	8
## pa-manag	0	0	0	0	0	0	0	1
## pimel-sp	0	0	0	0	0	0	0	0
## po-retic	5	0	0	0	0	0	0	34
## po-vivip	326	10	0	28	80	0	0	0
## pr-brevi	164	0	0	59	0	3	0	0
## ps-rhomb	1	0	0	0	0	0	0	0

## ps-genise	1	0	0	0	0	0	0	0
## se-heter	38	0	0	3	3	0	0	0
## se-piaba	0	0	0	0	0	0	0	0
## se-spilo	1	0	0	0	0	0	0	0
## st-noton	115	0	0	64	0	0	0	0
## sy-marmo	0	0	0	0	0	0	0	0
## te-chalc	0	0	0	0	0	0	0	0
## tr-signa	7	0	0	141	0	0	0	0
##	B-A-GU1	B-R-PC2	B-A-MU2	B-A-GU2	B-R-PC3	B-A-MU3	B-A-GU3	B-R-PC4
## ap-davis	0	5	0	0	22	0	0	0
## as-bimac	2	44	99	0	75	511	6	7
## as-fasci	2	0	0	0	7	0	0	17
## ch-bimac	0	0	0	0	0	0	0	0
## ci-ocela	0	2	0	0	4	0	0	0
## ci-orien	0	0	0	0	0	0	0	0
## co-macro	0	0	0	0	0	0	0	0
## co-heter	0	0	0	0	0	0	0	0
## cr-menez	0	0	0	0	0	0	0	0
## cu-lepid	0	0	0	0	21	0	0	0
## cy-gilbe	0	0	0	0	0	0	0	81
## ge-brasi	7	8	67	23	16	145	32	5
## he-margi	0	0	0	0	0	0	0	0
## ho-malab	0	0	1	0	2	0	0	1
## hy-pusar	0	0	0	0	1	0	0	0
## le-melan	0	2	0	0	0	0	0	0
## le-piau	0	0	0	0	0	0	0	1
## le-taeni	0	1	0	0	0	0	0	0
## mo-costa	0	0	0	0	1	0	0	0
## mo-lepid	0	0	0	0	0	0	0	0
## or-nilot	3	5	1	36	65	11	247	9
## pa-manag	11	0	0	102	0	0	250	0
## pimel-sp	0	0	0	0	0	0	0	0
## po-retic	0	0	10	0	0	46	0	0
## po-vivip	0	0	8	0	0	48	0	0
## pr-brevi	0	9	0	0	6	1	0	0
## ps-rhomb	0	0	0	0	0	0	0	0
## ps-genise	0	0	0	0	0	0	0	0
## se-heter	0	10	0	0	93	0	0	31
## se-piaba	0	0	0	0	0	0	0	0
## se-spilo	0	0	0	0	0	0	0	0
## st-noton	0	0	0	0	0	0	0	0
## sy-marmo	0	0	0	0	0	0	0	0
## te-chalc	0	76	0	0	58	0	0	0
## tr-signa	0	23	0	0	0	0	0	4
##	B-A-MU4	B-A-GU4						
## ap-davis	0	0						

## as-bimac	235	13
## as-fasci	0	0
## ch-bimac	0	0
## ci-ocela	0	0
## ci-orien	0	0
## co-macro	0	0
## co-heter	0	0
## cr-menez	0	0
## cu-lepid	0	0
## cy-gilbe	0	0
## ge-brasi	509	10
## he-margi	0	0
## ho-malab	0	0
## hy-pusar	0	0
## le-melan	0	0
## le-piau	0	0
## le-taeni	0	0
## mo-costa	0	0
## mo-lepid	0	0
## or-nilot	1	129
## pa-manag	0	190
## pimel-sp	0	0
## po-retic	266	0
## po-vivip	163	0
## pr-brevi	0	0
## ps-rhomb	0	0
## ps-genise	0	0
## se-heter	0	0
## se-piaba	0	0
## se-spilo	0	0
## st-noton	0	0
## sy-marmo	0	0
## te-chalc	0	0
## tr-signa	0	0

```
m_trab <- ppbio
```

Note que em uma matriz comunitária (onde os atributos são as espécies), a matriz transposta vai conter as unidades amostrais como colunas e espécies como linhas. Não tendo a mesma interpretação de matriz transposta em matemática.

Agora faremos uma série de gráficos para a matriz comunitária.

17.8 Gráficos descritivos

17.8.1 Série de Hill e perfil da diversidade

Pode-se utilizar uma série de Hill ao invés dos índices específicos de diversidade. Assim, quanto maior o valor de q (definido em `scales`), maior será o peso para a equabilidade. Quanto mais próximo de zero, maior o peso para riqueza. Quando $q = 0$, o valor de Hill é igual a riqueza de espécies.

```
Hill <- renyi(m_trab,
              scales = c(0:5),
              hill = TRUE)
Hill
```

##		0	1	2	3	4	5
##	S-A-ZA1	2	1.384145	1.219512	1.170411	1.150768	1.140762
##	S-R-CC1	3	1.163476	1.060983	1.045792	1.040607	1.038021
##	S-R-CT1	18	8.433432	5.644824	4.479923	3.925407	3.628965
##	S-R-CP1	5	4.089106	3.729963	3.562264	3.464767	3.397679
##	S-A-TA1	5	2.988203	2.463687	2.265900	2.160258	2.093130
##	S-R-CT2	17	8.120284	5.912807	4.995084	4.517360	4.233135
##	S-R-CP2	10	5.475674	4.064111	3.571020	3.347621	3.223289
##	S-A-TA2	4	1.820866	1.537624	1.437328	1.389021	1.362287
##	S-R-CT3	18	7.820420	6.079509	5.349788	4.920580	4.635690
##	S-R-CP3	6	4.641083	4.135957	3.852830	3.659934	3.518793
##	S-A-TA3	5	2.507947	2.244026	2.186542	2.165167	2.154376
##	S-R-CT4	14	6.554517	5.259698	4.665939	4.284640	4.026809
##	S-R-CP4	6	2.359044	1.645269	1.479932	1.418625	1.388109
##	S-A-TA4	8	2.249743	2.035378	1.981428	1.947091	1.920271
##	B-A-MU1	3	1.418412	1.192503	1.145257	1.128263	1.119791
##	B-R-ET1	4	2.200997	1.720325	1.562987	1.494812	1.458881
##	B-A-GU1	5	3.959865	3.342246	3.016650	2.834369	2.720943
##	B-R-PC2	11	5.630175	4.005266	3.427912	3.151799	2.991159
##	B-A-MU2	6	2.863745	2.393193	2.248679	2.175626	2.127807
##	B-A-GU2	3	2.464739	2.119634	1.930295	1.826854	1.766551
##	B-R-PC3	13	7.253371	5.945359	5.447786	5.182436	5.009929
##	B-A-MU3	6	2.710687	2.025352	1.799132	1.699897	1.647087
##	B-A-GU3	4	2.537469	2.297723	2.232385	2.206183	2.192731
##	B-R-PC4	9	4.374404	3.048096	2.586659	2.377604	2.263942
##	B-A-MU4	5	3.672499	3.348321	3.103452	2.925311	2.799120
##	B-A-GU4	4	2.514025	2.206452	2.107190	2.053368	2.015850

Podemos mapear isso em um gráfico de perfil de diversidade

```

library(ggplot2)
library(tidyr)
library(tidyverse)
grafico1 <- Hill %>%
  rownames_to_column() %>%
  pivot_longer(-rowname) %>%
  mutate(name = factor(name, name[1:length(Hill)])) %>%
  ggplot(aes(x = name, y = value, group = rowname,
             col = rowname)) +
  geom_point(size = 2) +
  geom_line(size = 1) +
  xlab("Parâmetro de ordem de diversidade (q)") +
  ylab("Diversidade") +
  labs(col = "Locais") +
  theme_bw() +
  theme(text = element_text(size = 10)) #ajustar a fonte caso nao
  ↪ caiba no output html

```

```

## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## This warning is displayed once per session.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was generated.

```

```

grafico1
ggsave(grafico1, dpi = 300, filename = "fig-hill.png")

```

```

## Saving 6.5 x 4.5 in image

```

17.9 Distribuição de abundância

Uma maneira de observar a diversidade de espécies é usando um gráfico de distribuição de abundâncias de uma comunidade, como mostrado a seguir. Note que aqui utiliza-se as abundâncias totais das espécies (Figura 17.2), mas é possível fazer por linha, basta substituir o objeto `abund` pela abundância de uma linha. Como na linha marcada com o #.

```

abund <- colSums(m_trab)

```




Figure 17.1: Mapeamento dos pontos de coleta em um gráfico de perfil de diversidade.

Na primeira linha do código abaixo, retira-se o # do início da linha para rodar a distribuição de abundância apenas para o local (linha) 1 comunidade[1,]. Pode-se mudar o número para o local de interesse.

O código a seguir produzirá o gráfico para o local escolhido.

```
#abund <- m_trab[1, ] #escolhe a primeira linha para a
# distribuição de abundância
df <- data.frame(sp = colnames(m_trab),
                 abun = abund)
grafico2 <- ggplot(df, aes(fct_reorder(sp, -abun),
                                abun, group = 1)) +
  geom_col() +
  geom_line(col = "red", linetype = "dashed") +
  geom_point(col = "red") +
  xlab("Espécies") +
  ylab("Abundância") +
  theme_bw() +
  theme(axis.text.x = element_text(
    angle = 45,
    hjust = 1,
```



```
face = "italic"))
grafico2
ggsave(grafico2, dpi = 300, filename = "fig-abun.png")
```

```
## Saving 6.5 x 4.5 in image
```




Figure 17.2: Distribuição da densidade de indivíduos.

17.10 Curva de rarefação

O código abaixo indica como usar o pacote iNEXT (CHAO et al., 2014; HSIEH; MA; CHAO, 2025) para extrapolar e interpolar curvas de rarefação visando comparar a riqueza de diferentes locais (linhas, por isso se trabalha com a matriz transposta). A curva de rarefação vai ser construída para as UA's demarcadas em `rarefa <- t(m_trab[c("S-R-CT2", "S-R-CP2", "S-A-TA2", "B-A-MU2"),])`

Pode-se, alternativamente, construir a curva de rarefação para as 8 linhas (UA's) com maior somatório dos valores das espécies (linhas marcadas com o símbolo #).

```

m_trab_r <- mutate(m_trab, across(everything(), ceiling))
  ↳ #arredonda a matriz original para números inteiros
colSums(t(m_trab_r))
colnames(t(m_trab_r))
rarefa <-
  ↳ t(m_trab_r[c("S-R-CT2", "S-R-CP2", "S-A-TA2", "B-A-MU2"),])
  ↳ #curva de rarefação para os sítios especificados
class(m_trab)
## Curva de rarefação para todos os sítios
#rarefa <- t(m_trab_r)
## Curva de rarefação para as 8 UA's com maior soma
#m_trab_r <- as.data.frame(t(m_trab_r)) #transpõe a matriz
#col_sums <- colSums(m_trab_r)
#largest_columns <- names(sort(col_sums, decreasing = TRUE)[1:8])
#rarefa <- m_trab_r[largest_columns] #curva de rarefação para as
  ↳ 8 UA's com maior soma

```

```

## S-A-ZA1 S-R-CC1 S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2 S-R-CT3 S-R-CP3
##      10      102      545      55      42      717      108      228      1144      68
## S-A-TA3 S-R-CT4 S-R-CP4 S-A-TA4 B-A-MU1 B-R-ET1 B-A-GU1 B-R-PC2 B-A-MU2 B-A-GU2
##      501      436      104      684      208      46      25      185      186      161
## B-R-PC3 B-A-MU3 B-A-GU3 B-R-PC4 B-A-MU4 B-A-GU4
##      371      762      535      156      1174      342
## [1] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" "S-A-TA1" "S-R-CT2" "S-R-CP2"
## [8] "S-A-TA2" "S-R-CT3" "S-R-CP3" "S-A-TA3" "S-R-CT4" "S-R-CP4" "S-A-TA4"
## [15] "B-A-MU1" "B-R-ET1" "B-A-GU1" "B-R-PC2" "B-A-MU2" "B-A-GU2" "B-R-PC3"
## [22] "B-A-MU3" "B-A-GU3" "B-R-PC4" "B-A-MU4" "B-A-GU4"
## [1] "data.frame"

```

A curva de rarefação vai ser construída para os sítios: “S-R-CT2”, “S-R-CP2”, “S-A-TA2”, “B-A-MU2”

No código abaixo o valor de `q` pode ser mudado para `q=1` para comparar a diversidade de Shannon e para `q=2` para Simpson (Figura (17.3)). A função `endpoint=` define o tamanho da amostra para o qual se deseja extrapolar a curva de rarefação. Se `endpoint=NULL`, a extrapolação será feita para o dobro do valor amostrado.

```

library(iNEXT)
print(iNEXT, bibtex=TRUE)

```

```

## function (x, q = 0, datatype = "abundance", size = NULL, endpoint = NULL,
##      knots = 40, se = TRUE, conf = 0.95, nboot = 50)

```

```

## {
##   TYPE <- c("abundance", "incidence", "incidence_freq", "incidence_raw")
##   if (is.na(pmatch(datatype, TYPE)))
##     stop("invalid datatype")
##   if (pmatch(datatype, TYPE) == -1)
##     stop("ambiguous datatype")
##   datatype <- match.arg(datatype, TYPE)
##   class_x <- class(x)[1]
##   if (datatype == "incidence") {
##     stop("datatype=\"incidence\" was no longer supported after v2.0.8, \n           please t
##   }
##   if (datatype == "incidence_freq")
##     datatype <- "incidence"
##   if (datatype == "incidence_raw") {
##     if (class_x == "list") {
##       x <- lapply(x, as.incfreq)
##     }
##     else {
##       x <- as.incfreq(x)
##     }
##     datatype <- "incidence"
##   }
##   Fun <- function(x, q, assem_name) {
##     x <- as.numeric(unlist(x))
##     unconditional_var <- TRUE
##     if (datatype == "abundance") {
##       if (sum(x) == 0)
##         stop("Zero abundance counts in one or more sample sites")
##       out <- iNEXT.Ind(Spec = x, q = q, m = size, endpoint = ifelse(is.null(endpoint),
##         2 * sum(x), endpoint), knots = knots, se = se,
##         nboot = nboot, conf = conf, unconditional_var)
##     }
##     if (datatype == "incidence") {
##       t <- x[1]
##       y <- x[-1]
##       if (t > sum(y)) {
##         warning("Insufficient data to provide reliable estimators and associated s.e.")
##       }
##       if (sum(x) == 0)
##         stop("Zero incidence frequencies in one or more sample sites")
##       out <- iNEXT.Sam(Spec = x, q = q, t = size, endpoint = ifelse(is.null(endpoint),
##         2 * max(x), endpoint), knots = knots, se = se,
##         nboot = nboot, conf = conf)
##     }
##     if (unconditional_var) {
##       out <- lapply(out, function(out_) cbind(Assemblage = assem_name,

```

```

##           out_))
##       }
##       else {
##         out[[1]] <- cbind(Assemblage = assem_name, out[[1]])
##       }
##       out
##     }
##   if (!inherits(q, "numeric"))
##     stop("invlid class of order q, q should be a postive value/vector of numeri
##   if (min(q) < 0) {
##     warning("ambiguous of order q, we only compute postive q")
##     q <- q[q >= 0]
##   }
##   z <- qnorm(1 - (1 - 0.95)/2)
##   if (class_x == "numeric" | class_x == "integer" | class_x ==
##       "double") {
##     out <- Fun(x, q, "Assemblage1")
##     out <- list(size_based = out[[1]], coverage_based = out[[2]])
##     index <- AsyD(x = x, q = c(0, 1, 2), datatype = ifelse(datatype ==
##       "abundance", "abundance", "incidence_freq"), nboot = 100,
##       conf = 0.95)
##     LCL <- index$qD.LCL[index$method == "Estimated"]
##     UCL <- index$qD.UCL[index$method == "Estimated"]
##     index <- dcast(index, formula = Order.q ~ method, value.var = "qD")
##     index <- cbind(index[, -1], se = (UCL - index$Estimated)/z,
##       LCL, UCL)
##     index$LCL[index$LCL < index$Empirical & index$Order.q ==
##       0] <- index$Empirical[index$LCL < index$Empirical &
##       index$Order.q == 0]
##     colnames(index) <- c("Observed", "Estimator", "Est_s.e.",
##       "95% Lower", "95% Upper")
##     rownames(index) <- c("Species Richness", "Shannon diversity",
##       "Simpson diversity")
##   }
##   else if (class_x == "matrix" | class_x == "data.frame") {
##     if (is.null(colnames(x))) {
##       colnames(x) <- sapply(1:ncol(x), function(i) paste0("assemblage",
##         i))
##     }
##     out <- lapply(1:ncol(x), function(i) {
##       tmp <- Fun(x[, i], q, colnames(x)[i])
##       tmp
##     })
##     out <- list(size_based = do.call(rbind, lapply(out, function(out_) {
##       out_[[1]]
##     })), coverage_based = do.call(rbind, lapply(out, function(out_) {

```

```

##           out_[[2]]
##       })))
##       index <- AsyD(x = x, q = c(0, 1, 2), datatype = ifelse(datatype ==
##           "abundance", "abundance", "incidence_freq"), nboot = 100,
##           conf = 0.95)
##       index = index[order(index$Assemblage), ]
##       LCL <- index$qD.LCL[index$method == "Estimated"]
##       UCL <- index$qD.UCL[index$method == "Estimated"]
##       index <- dcast(index, formula = Assemblage + Order.q ~
##           method, value.var = "qD")
##       index <- cbind(index, se = (UCL - index$Estimated)/z,
##           LCL, UCL)
##       index$LCL[index$LCL < index$Empirical & index$Order.q ==
##           0] <- index$Empirical[index$LCL < index$Empirical &
##           index$Order.q == 0]
##       index$Order.q <- c("Species richness", "Shannon diversity",
##           "Simpson diversity")
##       colnames(index) <- c("Assemblage", "Diversity", "Observed",
##           "Estimator", "s.e.", "LCL", "UCL")
##   }
##   else if (class_x == "list") {
##       if (is.null(names(x))) {
##           names(x) <- sapply(1:length(x), function(i) paste0("assemblage",
##               i))
##       }
##       out <- lapply(1:length(x), function(i) {
##           tmp <- Fun(x[[i]], q, names(x)[i])
##           tmp
##       })
##       out <- list(size_based = do.call(rbind, lapply(out, function(out_) {
##           out_[[1]]
##       })), coverage_based = do.call(rbind, lapply(out, function(out_) {
##           out_[[2]]
##       })))
##       index <- AsyD(x = x, q = c(0, 1, 2), datatype = ifelse(datatype ==
##           "abundance", "abundance", "incidence_freq"), nboot = 100,
##           conf = 0.95)
##       index = index[order(index$Assemblage), ]
##       LCL <- index$qD.LCL[index$method == "Estimated"]
##       UCL <- index$qD.UCL[index$method == "Estimated"]
##       index <- dcast(index, formula = Assemblage + Order.q ~
##           method, value.var = "qD")
##       index <- cbind(index, se = (UCL - index$Estimated)/z,
##           LCL, UCL)
##       index$LCL[index$LCL < index$Empirical & index$Order.q ==
##           0] <- index$Empirical[index$LCL < index$Empirical &

```

```

##           index$Order.q == 0]
##       index$Order.q <- c("Species richness", "Shannon diversity",
##           "Simpson diversity")
##       colnames(index) <- c("Assemblage", "Diversity", "Observed",
##           "Estimator", "s.e.", "LCL", "UCL")
##   }
##   else {
##       stop("invalid class of x, x should be a object of numeric, matrix, data.frame")
##   }
##   out$size_based$Assemblage <- as.character(out$size_based$Assemblage)
##   out$coverage_based$Assemblage <- as.character(out$coverage_based$Assemblage)
##   info <- DataInfo(x, datatype)
##   z <- list(DataInfo = info, iNextEst = out, AsyEst = index)
##   class(z) <- c("iNEXT")
##   return(z)
## }
## <bytecode: 0x000001e24ee0a9a8>
## <environment: namespace:iNEXT>

```

```

out <- iNEXT(rarefa, q = 0,
            datatype = "abundance",
            size = NULL,
            endpoint = 2000, #define o comprimento de eixo x
            knots = 40,
            se = TRUE,
            conf = 0.95,
            nboot = 50)
grafico3 <- ggiNEXT(out, type = 1, facet.var="None") +
  theme_bw() +
  labs(fill = "Áreas") +
  xlab("Número de indivíduos") +
  ylab("Riqueza de espécies") +
  theme(legend.title=element_blank()) #ver como fica com
  ↪ facet.var="Assemblage"
grafico3
ggsave(grafico3, dpi = 300, filename = "fig-rare1.png")

```

```
## Saving 6.5 x 4.5 in image
```

A linha sólida representa a interpolação do número de espécies observadas, e a linha tracejada mostra uma extrapolação do que seria esperado dado um aumento no número de indivíduos coletados. A área mais clara representa o intervalo de confiança de 95%.




Figure 17.3: Curva de rarefação para sítios específicos. $q=0$, riqueza; $q=1$, diversidade de Shannon; $q=2$, diversidade de Simpson; $q=5$, equitabilidade.

17.10.1 Interpretando a curva de rarefação

A curva de rarefação é uma ferramenta gráfica comumente usada em ecologia para estimar e visualizar a riqueza de espécies em uma comunidade, especialmente quando se têm dados de amostragem incompletos. Ela ajuda a responder à pergunta: “Quantas espécies diferentes podemos esperar encontrar em uma comunidade com base nas amostras que coletamos até agora?”

Aqui está uma explicação passo a passo sobre como interpretar uma curva de rarefação:

1. Eixo X (Número de Indivíduos Amostrados):

- O eixo horizontal (eixo X) representa o número de indivíduos ou unidades amostrados da comunidade. Isso pode ser o número de indivíduos observados, o número de amostras coletadas ou qualquer outra unidade de amostragem que seja relevante para o estudo.

2. Eixo Y (Riqueza de Espécies):

- O eixo vertical (eixo Y) representa a riqueza de espécies, ou seja, o número total de espécies diferentes observadas ou estimadas nas amostras.

3. Pontos na Curva:

- Cada ponto na curva de rarefação representa a riqueza de espécies estimada com base no número de indivíduos amostrados até o momento.
- À medida que você aumenta o número de indivíduos amostrados (ou seja, move-se para a direita ao longo do eixo X), a riqueza de espécies estimada também aumenta (ou seja, move-se para cima ao longo do eixo Y).

4. Inclinação da Curva:

- A inclinação da curva de rarefação é importante. Uma curva que sobe rapidamente indica que novas espécies estão sendo encontradas à medida que mais indivíduos são amostrados. Isso sugere que a comunidade é rica em espécies, e ainda há muitas espécies não observadas.
- Uma curva que sobe lentamente sugere que a maioria das espécies já foi observada, e a riqueza de espécies está se estabilizando. Isso indica uma comunidade menos diversa ou uma amostragem mais completa.

5. Assíntota:

- A assíntota é o ponto em que a curva de rarefação começa a nivelar-se, e a adição de mais indivíduos à amostra tem um impacto mínimo na riqueza de espécies estimada. A assíntota é uma estimativa da riqueza de espécies máxima que pode ser alcançada com a amostragem disponível.

6. Interpretação:

- A interpretação da curva de rarefação depende do contexto. Se a curva ainda estiver subindo acentuadamente no ponto em que você parou de amostrar, isso sugere que a amostragem está incompleta, e mais espécies provavelmente serão encontradas com mais esforço de amostragem.
- Se a curva estiver nivelada e próxima de uma assíntota, isso sugere que a amostragem foi mais completa, e você pode ter uma estimativa confiável da riqueza de espécies na comunidade.

7. Estimativas da Riqueza:

- A curva de rarefação pode ser usada para fazer estimativas da riqueza de espécies com base nas amostras coletadas. No entanto, lembre-se de que essas são estimativas e estão sujeitas a variações amostrais. É comum calcular intervalos de confiança ao redor dessas estimativas.

Em resumo, a curva de rarefação é uma ferramenta valiosa para estimar a riqueza de espécies em uma comunidade com base em amostras coletadas. A interpretação depende da inclinação da curva, da presença de uma assíntota e do contexto do estudo. É importante lembrar que a amostragem mais completa geralmente resulta em estimativas mais confiáveis da riqueza de espécies.

17.11 Curva de acumulação de espécies


```
acumula <- specaccum(m_trab,
                     method = "random")
acumula
```

```
## Species Accumulation Curve
## Accumulation method: random, with 100 permutations
## Call: specaccum(comm = m_trab, method = "random")
##
##
## Sites      1.00000  2.00000  3.00000  4.00000  5.0000  6.00000  7.00000  8.00000
## Richness 6.44000 10.67000 13.61000 16.41000 18.8500 20.53000 21.74000 23.25000
## sd       4.01089  4.73127  4.55914  4.43151  4.1228  4.07866  3.98639  3.48844
##
## Sites      9.0000 10.0000 11.00000 12.00000 13.00000 14.00000 15.00000 16.00000
## Richness 24.5300 25.7300 26.38000 27.27000 28.18000 28.80000 29.57000 30.18000
## sd       3.1413  2.9877  2.87722  2.86341  2.60683  2.53461  2.65244  2.52415
##
## Sites      17.00000 18.00000 19.00000 20.00000 21.00000 22.00000 23.00000
## Richness 30.76000 31.32000 31.83000 32.29000 32.89000 33.23000 33.77000
## sd       2.34895  2.33498  2.23406  2.11438  1.85807  1.77443  1.45543
##
## Sites      24.00000 25.0000 26
## Richness 34.17000 34.5600 35
## sd       1.23137  0.8683  0
```

17.11.1 Plot locais

Plotamos uma curva de acumulação de espécies simples.

```
plot(acumula)
```



Uma curva de acumulação de espécies é uma ferramenta gráfica usada para entender como a riqueza de espécies em uma comunidade aumenta à medida que mais amostras são coletadas ou observações são feitas. Ela é especialmente útil em estudos de biodiversidade e ecologia. Aqui está uma explicação sobre como interpretar uma curva de acumulação de espécies:

1. Eixo X (Número de Amostras ou Unidades de Observação):

- O eixo horizontal (eixo X) representa o número de amostras coletadas, unidades de observação ou esforço amostral. Isso pode ser o número de áreas amostradas, pontos de observação, horas de coleta de dados ou qualquer unidade relevante para o estudo.

2. Eixo Y (Riqueza de Espécies Acumulada):

- O eixo vertical (eixo Y) representa a riqueza de espécies acumulada, ou seja, o número total de espécies diferentes observadas ou registradas até o momento.

3. Pontos na Curva:

- Cada ponto na curva de acumulação de espécies representa a riqueza de espécies acumulada com base no número de amostras coletadas ou observações feitas até aquele ponto.
- À medida que você aumenta o número de amostras (ou seja, move-se para a direita ao longo do eixo X), a riqueza de espécies acumulada também aumenta (ou seja, move-se para cima ao longo do eixo Y).

4. Inclinação da Curva:

- A inclinação da curva de acumulação de espécies é importante. Uma curva que sobe rapidamente indica que novas espécies estão sendo encontradas à medida que mais amostras são coletadas. Isso sugere que a comunidade é rica em espécies e que ainda há muitas espécies não observadas.
- Uma curva que sobe lentamente sugere que a maioria das espécies já foi observada, e a riqueza de espécies está se estabilizando. Isso indica uma comunidade menos diversa ou uma amostragem mais completa.

5. Assíntota:

- A assíntota é o ponto onde a curva de acumulação de espécies começa a nivelar-se, e a adição de mais amostras tem um impacto mínimo na riqueza de espécies acumulada. A assíntota é uma estimativa da riqueza de espécies máxima que pode ser alcançada com o esforço amostral disponível.

6. Interpretação:

- A interpretação da curva de acumulação de espécies depende do contexto. Se a curva ainda estiver subindo acentuadamente no ponto em que você parou de amostrar, isso sugere que a amostragem está incompleta, e mais espécies provavelmente serão encontradas com mais esforço amostral.
- Se a curva estiver nivelada e próxima de uma assíntota, isso sugere que a amostragem foi mais completa, e você pode ter uma estimativa confiável da riqueza de espécies na comunidade.

7. Estimativas da Riqueza:

- A curva de acumulação de espécies pode ser usada para fazer estimativas da riqueza de espécies com base nas amostras coletadas. No entanto, lembre-se de que essas são estimativas e estão sujeitas a variações amostrais. É comum calcular intervalos de confiança ao redor dessas estimativas.

Em resumo, a curva de acumulação de espécies é uma ferramenta valiosa para entender como a riqueza de espécies aumenta com o esforço amostral em uma comunidade. A interpretação depende da inclinação da curva, da presença de uma assíntota e do contexto do estudo. Ela ajuda a responder à pergunta: “Quantas espécies diferentes podemos esperar encontrar em uma comunidade com base nas amostras que coletamos até agora?”


Agora podemos plotar uma curva de acumulação de espécies melhorada.

```

plot_data <- data.frame("UAs" = c(0, acumula$sites),
                        "Riqueza" = c(0, acumula$richness),
                        "lower" = c(0, acumula$richness -
                                   ↪ acumula$sd),
                        "upper" = c(0, acumula$richness +
                                   ↪ acumula$sd))
gLocais <- ggplot(plot_data, aes(x = UAs, y = Riqueza)) +
  geom_point(color = "blue", size = 4) +
  geom_line(color = "blue", lwd = 2) +
  geom_ribbon(aes(ymin = lower, ymax = upper),
            linetype=2, alpha=0.3, fill = "yellow") +
  ylab("Riqueza acumulada") +
  theme_classic() +
  theme(text = element_text(size = 16))
gLocais
ggsave(gLocais, dpi = 300, filename = "fig-acum.png")


```

```
## Saving 6.5 x 4.5 in image
```




17.12 Plot individuos

```
plot_data <- data.frame("Individuos" = c(0, acumula$individuals),
                        "Riqueza" = c(0, acumula$richness),
                        "lower" = c(0, acumula$richness -
                                     ↪ acumula$sd),
                        "upper" = c(0, acumula$richness +
                                     ↪ acumula$sd))
gInd <- ggplot(plot_data, aes(x = Individuos, y = Riqueza)) +
  geom_point(color = "blue", size = 4) +
  geom_line(color = "blue", lwd = 2) +
  geom_ribbon(aes(ymin = lower, ymax = upper),
             linetype=2, alpha=0.3, fill = "yellow") +
  ylab("Riqueza acumulada") +
  theme_classic() +
  theme(text = element_text(size = 16))
gInd
```



17.13 Riqueza rarefacionada

```
# Rarefação baseada na matriz de contagem
library(vegan)
data <- m_trab
S <- specnumber(data) #observed number of species
S
#raremax <- min(rowSums(data))
raremax <- round(mean(rowSums(data)))
#raremax <- 1000
raremax
Srare <- rarefy(data, raremax)
Srare
plot(S, Srare, xlab = "Observed No. of Species", ylab = "Rarefied
  ↪ No. of Species")
abline(0, 1)
```




```
#png("fig-rarecurve.png")
rarecurve(data, step = 20,
  sample = raremax, #linhas de rarefação
  col = "blue", cex = 0.6,
```

```

xlab = "Sample size", ylab = "Taxa", xlim = c()
  ↪ #c(0,5000)

```



```

#dev.off()

```

```

## S-A-ZA1 S-R-CC1 S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2 S-R-CT3 S-R-CP3
##      2      3     18      5      5     17     10      4     18      6
## S-A-TA3 S-R-CT4 S-R-CP4 S-A-TA4 B-A-MU1 B-R-ET1 B-A-GU1 B-R-PC2 B-A-MU2 B-A-GU2
##      5     14      6      8      3      4      5     11      6      3
## B-R-PC3 B-A-MU3 B-A-GU3 B-R-PC4 B-A-MU4 B-A-GU4
##     13      6      4      9      5      4
## [1] 342
## S-A-ZA1 S-R-CC1 S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2
## 2.000000 3.000000 16.763604 5.000000 5.000000 15.071550 10.000000 4.000000
## S-R-CT3 S-R-CP3 S-A-TA3 S-R-CT4 S-R-CP4 S-A-TA4 B-A-MU1 B-R-ET1
## 14.375683 6.000000 4.899417 13.321417 6.000000 6.124063 3.000000 4.000000
## B-A-GU1 B-R-PC2 B-A-MU2 B-A-GU2 B-R-PC3 B-A-MU3 B-A-GU3 B-R-PC4
## 5.000000 11.000000 6.000000 3.000000 12.837720 5.447475 3.997904 9.000000
## B-A-MU4 B-A-GU4
## 4.291312 4.000000
## attr("Subsample")
## [1] 342

```

Apêndices

Criando uma tabela de espécies

Nessa etapa precisaremos da tabela de grupos. Selecionamos a aba `peixes`, porque nela constam os agrupamentos *a-priori* para os dados de peixes.

```
library(openxlsx)
t_grps <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06-grupos.xlsx"
  ↪ ,
  rowNames = T, colNames = T,
  sheet = "peixes")
str(t_grps)
#View(ppbio)
t_grps[1:4,1:4] #[1:4,1:4] mostra apenas as linhas e colunas de 1
  ↪ a 4.
```

```
## 'data.frame': 26 obs. of 4 variables:
## $ area : chr "Serido" "Serido" "Serido" "Serido" ...
## $ ambiente: chr "acude" "rio" "rio" "rio" ...
## $ UA : chr "ZA" "CC" "CT" "CP" ...
## $ coleta : num 1 1 1 1 1 2 2 2 3 3 ...
## area ambiente UA coleta
## S-A-ZA1 Serido acude ZA 1
## S-R-CC1 Serido rio CC 1
## S-R-CT1 Serido rio CT 1
## S-R-CP1 Serido rio CP 1
```

```
library(dplyr)
library(tidyr)
m_trab <- m_trab %>%
  rename_with(~ gsub("-", ".", .)) #apenas troquei o hífen pelo
  ↪ ponto.
m <- m_trab %>%
  group_by(Area = t_grps$area,
           Habitat = t_grps$ambiente,
           Ponto = t_grps$UA) %>%
  summarise(across(where(is.numeric),
                    list(mean = mean, sd = sd)),
            .groups = 'drop') %>%
  pivot_longer(
```



```

    cols = -c(Area, Habitat, Ponto),
    names_to = c("Variable", ".value"),
    names_sep = "_"
  )
m
m <- as.data.frame(m)
m_wide <- m %>%
  mutate(stat_string = ifelse(
    Variable == "nome_da_variavel", #escolhe uma variável pra
    ↪ ter 3 casas decimais
    paste0(round(mean, 3), "(", round(sd, 3), ")"),
    paste0(round(mean, 1), "(", round(sd, 1), ")")
  )) %>%
  unite("Location", Area, Habitat, Ponto, sep = "_") %>%
  dplyr::select(Variable, Location, stat_string) %>% #dplyr dá
  ↪ conflito com MASS
  pivot_wider(names_from = Location, values_from = stat_string)

m_wide
m_wide <- as.data.frame(m_wide)
m_wide

#Exportando dados para Excel----
library(openxlsx)
write.xlsx(m_wide, file = "tabela da comunidade.xlsx", rowNames =
  ↪ FALSE)
wb <- loadWorkbook("tabela da comunidade.xlsx")
writeData(wb, sheet = "Sheet 1", x = m_wide)
saveWorkbook(wb, "tabela da comunidade.xlsx", overwrite = TRUE)

#Escolher sumário de uma variavel----
m
var <- "as.bimac"
m[m$Variable == var, "mean"] #cada valor de var
summary(m[m$Variable == var, "mean"]) #sumário dos valores de var

```

```

## # A tibble: 315 x 6
##   Area Habitat Ponto Variable mean  sd
##   <chr> <chr> <chr> <chr> <dbl> <dbl>
## 1 Buique acude GU ap.davis 0 0
## 2 Buique acude GU as.bimac 5.25 5.74
## 3 Buique acude GU as.fasci 0.5 1
## 4 Buique acude GU ch.bimac 0 0
## 5 Buique acude GU ci.ocela 0 0

```

```

## 6 Buique acude GU ci.orien 0 0
## 7 Buique acude GU co.macro 0 0
## 8 Buique acude GU co.heter 0 0
## 9 Buique acude GU cr.menez 0 0
## 10 Buique acude GU cu.lepid 0 0
## # i 305 more rows
## # A tibble: 35 x 10
##   Variable Buique_acude_GU Buique_acude_MU Buique_rio_ET Buique_rio_PC
##   <chr> <chr> <chr> <chr> <chr>
## 1 ap.davis 0(0) 0(0) 0(NA) 9(11.5)
## 2 as.bimac 5.2(5.7) 214.2(218.1) 3(NA) 42(34)
## 3 as.fasci 0.5(1) 0(0) 0(NA) 8(8.5)
## 4 ch.bimac 0(0) 0(0) 0(NA) 0(0)
## 5 ci.ocela 0(0) 0(0) 0(NA) 2(2)
## 6 ci.orien 0(0) 0(0) 0(NA) 0(0)
## 7 co.macro 0(0) 0(0) 0(NA) 0(0)
## 8 co.heter 0(0) 0(0) 0(NA) 0(0)
## 9 cr.menez 0(0) 0(0) 0(NA) 0(0)
## 10 cu.lepid 0(0) 0(0) 0(NA) 7(12.1)
## # i 25 more rows
## # i 5 more variables: Serido_acude_TA <chr>, Serido_acude_ZA <chr>,
## # Serido_rio_CC <chr>, Serido_rio_CP <chr>, Serido_rio_CT <chr>
##   Variable Buique_acude_GU Buique_acude_MU Buique_rio_ET Buique_rio_PC
## 1 ap.davis 0(0) 0(0) 0(NA) 9(11.5)
## 2 as.bimac 5.2(5.7) 214.2(218.1) 3(NA) 42(34)
## 3 as.fasci 0.5(1) 0(0) 0(NA) 8(8.5)
## 4 ch.bimac 0(0) 0(0) 0(NA) 0(0)
## 5 ci.ocela 0(0) 0(0) 0(NA) 2(2)
## 6 ci.orien 0(0) 0(0) 0(NA) 0(0)
## 7 co.macro 0(0) 0(0) 0(NA) 0(0)
## 8 co.heter 0(0) 0(0) 0(NA) 0(0)
## 9 cr.menez 0(0) 0(0) 0(NA) 0(0)
## 10 cu.lepid 0(0) 0(0) 0(NA) 7(12.1)
## 11 cy.gilbe 0(0) 0(0) 0(NA) 27(46.8)
## 12 ge.brasi 18(11.6) 227.8(194.3) 0(NA) 9.7(5.7)
## 13 he.margi 0(0) 0(0) 0(NA) 0(0)
## 14 ho.malab 0(0) 0.2(0.5) 0(NA) 1(1)
## 15 hy.pusar 0(0) 0(0) 0(NA) 0.3(0.6)
## 16 le.melan 0(0) 0(0) 0(NA) 0.7(1.2)
## 17 le.piau 0(0) 0(0) 0(NA) 0.3(0.6)
## 18 le.taeni 0(0) 0(0) 0(NA) 0.3(0.6)
## 19 mo.costa 0(0) 0(0) 0(NA) 0.3(0.6)
## 20 mo.lepid 0(0) 0(0) 0(NA) 0(0)
## 21 or.nilot 103.8(109.4) 4.8(4.8) 8(NA) 26.3(33.5)
## 22 pa.manag 138.2(104.4) 0(0) 1(NA) 0(0)
## 23 pimel.sp 0(0) 0(0) 0(NA) 0(0)

```

## 24	po.retic	0(0)	80.5(125.2)	34(NA)	0(0)
## 25	po.vivip	0(0)	54.8(75.2)	0(NA)	0(0)
## 26	pr.brevi	0(0)	0.2(0.5)	0(NA)	5(4.6)
## 27	ps.rhomb	0(0)	0(0)	0(NA)	0(0)
## 28	ps.genise	0(0)	0(0)	0(NA)	0(0)
## 29	se.heter	0(0)	0(0)	0(NA)	44.7(43.2)
## 30	se.piaba	0(0)	0(0)	0(NA)	0(0)
## 31	se.spilo	0(0)	0(0)	0(NA)	0(0)
## 32	st.noton	0(0)	0(0)	0(NA)	0(0)
## 33	sy.marmo	0(0)	0(0)	0(NA)	0(0)
## 34	te.chalc	0(0)	0(0)	0(NA)	44.7(39.7)
## 35	tr.signa	0(0)	0(0)	0(NA)	9(12.3)
##	Serido_acude_TA	Serido_acude_ZA	Serido_rio_CC	Serido_rio_CP	Serido_rio_CT
## 1	0(0)	0(NA)	0(NA)	0(0)	0(0)
## 2	174.2(174.3)	1(NA)	99(NA)	10(9)	135.5(94.5)
## 3	2(3.4)	0(NA)	0(NA)	0.2(0.5)	30.8(33.4)
## 4	175.5(115.2)	0(NA)	0(NA)	0(0)	0.8(1.5)
## 5	0(0)	0(NA)	0(NA)	16(17)	0(0)
## 6	0(0)	0(NA)	0(NA)	9.8(10.2)	26(30.2)
## 7	0.5(1)	0(NA)	0(NA)	0(0)	0(0)
## 8	0(0)	0(NA)	0(NA)	0(0)	0.2(0.5)
## 9	0.2(0.5)	0(NA)	0(NA)	0(0)	6.8(5.6)
## 10	0(0)	0(NA)	0(NA)	0(0)	0(0)
## 11	0(0)	0(NA)	0(NA)	0(0)	12.5(25)
## 12	0.2(0.5)	0(NA)	0(NA)	0(0)	1.8(1.5)
## 13	0(0)	0(NA)	0(NA)	0(0)	0.5(0.6)
## 14	7.8(9)	0(NA)	0(NA)	5.2(3.4)	13.2(13.7)
## 15	0(0)	0(NA)	0(NA)	1(1.2)	16.5(18)
## 16	0(0)	0(NA)	0(NA)	0(0)	0(0)
## 17	0.5(1)	0(NA)	0(NA)	1.5(1.3)	1.5(1.3)
## 18	0(0)	0(NA)	0(NA)	0(0)	0(0)
## 19	0(0)	0(NA)	0(NA)	0(0)	0(0)
## 20	0(0)	0(NA)	1(NA)	0(0)	10(19.3)
## 21	0.2(0.5)	0(NA)	2(NA)	0(0)	81(42.2)
## 22	0(0)	0(NA)	0(NA)	0(0)	0(0)
## 23	0(0)	0(NA)	0(NA)	0(0)	1.5(3)
## 24	0(0)	0(NA)	0(NA)	0(0)	6.2(9.5)
## 25	0(0)	0(NA)	0(NA)	34.2(31.9)	155.5(143)
## 26	1.5(1.3)	9(NA)	0(NA)	1.2(2.5)	60.8(72.7)
## 27	0(0)	0(NA)	0(NA)	0(0)	0.2(0.5)
## 28	0(0)	0(NA)	0(NA)	0(0)	0.2(0.5)
## 29	1(2)	0(NA)	0(NA)	4.2(6.7)	35.2(23.7)
## 30	0(0)	0(NA)	0(NA)	0(0)	17(34)
## 31	0(0)	0(NA)	0(NA)	0(0)	0.2(0.5)
## 32	0(0)	0(NA)	0(NA)	0(0)	51.2(49.8)
## 33	0(0)	0(NA)	0(NA)	0.2(0.5)	0(0)

## 34		0(0)		0(NA)	0(NA)	0(0)	0(0)
## 35		0(0)		0(NA)	0(NA)	0(0)	45.2(64)
##	Area	Habitat	Ponto	Variable	mean	sd	
## 1	Buique	acude	GU	ap.davis	0.0000000	0.0000000	
## 2	Buique	acude	GU	as.bimac	5.2500000	5.7373048	
## 3	Buique	acude	GU	as.fasci	0.5000000	1.0000000	
## 4	Buique	acude	GU	ch.bimac	0.0000000	0.0000000	
## 5	Buique	acude	GU	ci.ocela	0.0000000	0.0000000	
## 6	Buique	acude	GU	ci.orien	0.0000000	0.0000000	
## 7	Buique	acude	GU	co.macro	0.0000000	0.0000000	
## 8	Buique	acude	GU	co.heter	0.0000000	0.0000000	
## 9	Buique	acude	GU	cr.menez	0.0000000	0.0000000	
## 10	Buique	acude	GU	cu.lepid	0.0000000	0.0000000	
## 11	Buique	acude	GU	cy.gilbe	0.0000000	0.0000000	
## 12	Buique	acude	GU	ge.brasi	18.0000000	11.6332856	
## 13	Buique	acude	GU	he.margi	0.0000000	0.0000000	
## 14	Buique	acude	GU	ho.malab	0.0000000	0.0000000	
## 15	Buique	acude	GU	hy.pusar	0.0000000	0.0000000	
## 16	Buique	acude	GU	le.melan	0.0000000	0.0000000	
## 17	Buique	acude	GU	le.piau	0.0000000	0.0000000	
## 18	Buique	acude	GU	le.taeni	0.0000000	0.0000000	
## 19	Buique	acude	GU	mo.costa	0.0000000	0.0000000	
## 20	Buique	acude	GU	mo.lepid	0.0000000	0.0000000	
## 21	Buique	acude	GU	or.nilot	103.7500000	109.3903561	
## 22	Buique	acude	GU	pa.manag	138.2500000	104.3595547	
## 23	Buique	acude	GU	pimel.sp	0.0000000	0.0000000	
## 24	Buique	acude	GU	po.retic	0.0000000	0.0000000	
## 25	Buique	acude	GU	po.vivip	0.0000000	0.0000000	
## 26	Buique	acude	GU	pr.brevi	0.0000000	0.0000000	
## 27	Buique	acude	GU	ps.rhomb	0.0000000	0.0000000	
## 28	Buique	acude	GU	ps.genise	0.0000000	0.0000000	
## 29	Buique	acude	GU	se.heter	0.0000000	0.0000000	
## 30	Buique	acude	GU	se.piaba	0.0000000	0.0000000	
## 31	Buique	acude	GU	se.spilo	0.0000000	0.0000000	
## 32	Buique	acude	GU	st.noton	0.0000000	0.0000000	
## 33	Buique	acude	GU	sy.marmo	0.0000000	0.0000000	
## 34	Buique	acude	GU	te.chalc	0.0000000	0.0000000	
## 35	Buique	acude	GU	tr.signa	0.0000000	0.0000000	
## 36	Buique	acude	MU	ap.davis	0.0000000	0.0000000	
## 37	Buique	acude	MU	as.bimac	214.2500000	218.0815979	
## 38	Buique	acude	MU	as.fasci	0.0000000	0.0000000	
## 39	Buique	acude	MU	ch.bimac	0.0000000	0.0000000	
## 40	Buique	acude	MU	ci.ocela	0.0000000	0.0000000	
## 41	Buique	acude	MU	ci.orien	0.0000000	0.0000000	
## 42	Buique	acude	MU	co.macro	0.0000000	0.0000000	
## 43	Buique	acude	MU	co.heter	0.0000000	0.0000000	

## 44	Buique	acude	MU	cr.menez	0.0000000	0.0000000
## 45	Buique	acude	MU	cu.lepid	0.0000000	0.0000000
## 46	Buique	acude	MU	cy.gilbe	0.0000000	0.0000000
## 47	Buique	acude	MU	ge.brasi	227.7500000	194.2633522
## 48	Buique	acude	MU	he.margi	0.0000000	0.0000000
## 49	Buique	acude	MU	ho.malab	0.2500000	0.5000000
## 50	Buique	acude	MU	hy.pusar	0.0000000	0.0000000
## 51	Buique	acude	MU	le.melan	0.0000000	0.0000000
## 52	Buique	acude	MU	le.piau	0.0000000	0.0000000
## 53	Buique	acude	MU	le.taeni	0.0000000	0.0000000
## 54	Buique	acude	MU	mo.costa	0.0000000	0.0000000
## 55	Buique	acude	MU	mo.lepid	0.0000000	0.0000000
## 56	Buique	acude	MU	or.nilot	4.7500000	4.7871355
## 57	Buique	acude	MU	pa.manag	0.0000000	0.0000000
## 58	Buique	acude	MU	pimel.sp	0.0000000	0.0000000
## 59	Buique	acude	MU	po.retic	80.5000000	125.2344468
## 60	Buique	acude	MU	po.vivip	54.7500000	75.1592753
## 61	Buique	acude	MU	pr.brevi	0.2500000	0.5000000
## 62	Buique	acude	MU	ps.rhomb	0.0000000	0.0000000
## 63	Buique	acude	MU	ps.genise	0.0000000	0.0000000
## 64	Buique	acude	MU	se.heter	0.0000000	0.0000000
## 65	Buique	acude	MU	se.piaba	0.0000000	0.0000000
## 66	Buique	acude	MU	se.spilo	0.0000000	0.0000000
## 67	Buique	acude	MU	st.noton	0.0000000	0.0000000
## 68	Buique	acude	MU	sy.marmo	0.0000000	0.0000000
## 69	Buique	acude	MU	te.chalc	0.0000000	0.0000000
## 70	Buique	acude	MU	tr.signa	0.0000000	0.0000000
## 71	Buique	rio	ET	ap.davis	0.0000000	NA
## 72	Buique	rio	ET	as.bimac	3.0000000	NA
## 73	Buique	rio	ET	as.fasci	0.0000000	NA
## 74	Buique	rio	ET	ch.bimac	0.0000000	NA
## 75	Buique	rio	ET	ci.ocela	0.0000000	NA
## 76	Buique	rio	ET	ci.orien	0.0000000	NA
## 77	Buique	rio	ET	co.macro	0.0000000	NA
## 78	Buique	rio	ET	co.heter	0.0000000	NA
## 79	Buique	rio	ET	cr.menez	0.0000000	NA
## 80	Buique	rio	ET	cu.lepid	0.0000000	NA
## 81	Buique	rio	ET	cy.gilbe	0.0000000	NA
## 82	Buique	rio	ET	ge.brasi	0.0000000	NA
## 83	Buique	rio	ET	he.margi	0.0000000	NA
## 84	Buique	rio	ET	ho.malab	0.0000000	NA
## 85	Buique	rio	ET	hy.pusar	0.0000000	NA
## 86	Buique	rio	ET	le.melan	0.0000000	NA
## 87	Buique	rio	ET	le.piau	0.0000000	NA
## 88	Buique	rio	ET	le.taeni	0.0000000	NA
## 89	Buique	rio	ET	mo.costa	0.0000000	NA

## 90	Buique	rio	ET	mo.lepid	0.0000000	NA
## 91	Buique	rio	ET	or.nilot	8.0000000	NA
## 92	Buique	rio	ET	pa.manag	1.0000000	NA
## 93	Buique	rio	ET	pimel.sp	0.0000000	NA
## 94	Buique	rio	ET	po.retic	34.0000000	NA
## 95	Buique	rio	ET	po.vivip	0.0000000	NA
## 96	Buique	rio	ET	pr.brevi	0.0000000	NA
## 97	Buique	rio	ET	ps.rhomb	0.0000000	NA
## 98	Buique	rio	ET	ps.genise	0.0000000	NA
## 99	Buique	rio	ET	se.heter	0.0000000	NA
## 100	Buique	rio	ET	se.piaba	0.0000000	NA
## 101	Buique	rio	ET	se.spilo	0.0000000	NA
## 102	Buique	rio	ET	st.noton	0.0000000	NA
## 103	Buique	rio	ET	sy.marmo	0.0000000	NA
## 104	Buique	rio	ET	te.chalc	0.0000000	NA
## 105	Buique	rio	ET	tr.signa	0.0000000	NA
## 106	Buique	rio	PC	ap.davis	9.0000000	11.5325626
## 107	Buique	rio	PC	as.bimac	42.0000000	34.0440891
## 108	Buique	rio	PC	as.fasci	8.0000000	8.5440037
## 109	Buique	rio	PC	ch.bimac	0.0000000	0.0000000
## 110	Buique	rio	PC	ci.ocela	2.0000000	2.0000000
## 111	Buique	rio	PC	ci.orien	0.0000000	0.0000000
## 112	Buique	rio	PC	co.macro	0.0000000	0.0000000
## 113	Buique	rio	PC	co.heter	0.0000000	0.0000000
## 114	Buique	rio	PC	cr.menez	0.0000000	0.0000000
## 115	Buique	rio	PC	cu.lepid	7.0000000	12.1243557
## 116	Buique	rio	PC	cy.gilbe	27.0000000	46.7653718
## 117	Buique	rio	PC	ge.brasi	9.6666667	5.6862407
## 118	Buique	rio	PC	he.margi	0.0000000	0.0000000
## 119	Buique	rio	PC	ho.malab	1.0000000	1.0000000
## 120	Buique	rio	PC	hy.pusar	0.3333333	0.5773503
## 121	Buique	rio	PC	le.melan	0.6666667	1.1547005
## 122	Buique	rio	PC	le.piau	0.3333333	0.5773503
## 123	Buique	rio	PC	le.taeni	0.3333333	0.5773503
## 124	Buique	rio	PC	mo.costa	0.3333333	0.5773503
## 125	Buique	rio	PC	mo.lepid	0.0000000	0.0000000
## 126	Buique	rio	PC	or.nilot	26.3333333	33.5459883
## 127	Buique	rio	PC	pa.manag	0.0000000	0.0000000
## 128	Buique	rio	PC	pimel.sp	0.0000000	0.0000000
## 129	Buique	rio	PC	po.retic	0.0000000	0.0000000
## 130	Buique	rio	PC	po.vivip	0.0000000	0.0000000
## 131	Buique	rio	PC	pr.brevi	5.0000000	4.5825757
## 132	Buique	rio	PC	ps.rhomb	0.0000000	0.0000000
## 133	Buique	rio	PC	ps.genise	0.0000000	0.0000000
## 134	Buique	rio	PC	se.heter	44.6666667	43.1547603
## 135	Buique	rio	PC	se.piaba	0.0000000	0.0000000

## 136	Buique	rio	PC	se.spilo	0.0000000	0.0000000
## 137	Buique	rio	PC	st.noton	0.0000000	0.0000000
## 138	Buique	rio	PC	sy.marmo	0.0000000	0.0000000
## 139	Buique	rio	PC	te.chalc	44.6666667	39.7156560
## 140	Buique	rio	PC	tr.signa	9.0000000	12.2882057
## 141	Serido	acude	TA	ap.davis	0.0000000	0.0000000
## 142	Serido	acude	TA	as.bimac	174.2500000	174.3413797
## 143	Serido	acude	TA	as.fasci	2.0000000	3.3665016
## 144	Serido	acude	TA	ch.bimac	175.5000000	115.2171862
## 145	Serido	acude	TA	ci.ocela	0.0000000	0.0000000
## 146	Serido	acude	TA	ci.orien	0.0000000	0.0000000
## 147	Serido	acude	TA	co.macro	0.5000000	1.0000000
## 148	Serido	acude	TA	co.heter	0.0000000	0.0000000
## 149	Serido	acude	TA	cr.menez	0.2500000	0.5000000
## 150	Serido	acude	TA	cu.lepid	0.0000000	0.0000000
## 151	Serido	acude	TA	cy.gilbe	0.0000000	0.0000000
## 152	Serido	acude	TA	ge.brasi	0.2500000	0.5000000
## 153	Serido	acude	TA	he.margi	0.0000000	0.0000000
## 154	Serido	acude	TA	ho.malab	7.7500000	9.0323493
## 155	Serido	acude	TA	hy.pusar	0.0000000	0.0000000
## 156	Serido	acude	TA	le.melan	0.0000000	0.0000000
## 157	Serido	acude	TA	le.piau	0.5000000	1.0000000
## 158	Serido	acude	TA	le.taeni	0.0000000	0.0000000
## 159	Serido	acude	TA	mo.costa	0.0000000	0.0000000
## 160	Serido	acude	TA	mo.lepid	0.0000000	0.0000000
## 161	Serido	acude	TA	or.nilot	0.2500000	0.5000000
## 162	Serido	acude	TA	pa.manag	0.0000000	0.0000000
## 163	Serido	acude	TA	pimel.sp	0.0000000	0.0000000
## 164	Serido	acude	TA	po.retic	0.0000000	0.0000000
## 165	Serido	acude	TA	po.vivip	0.0000000	0.0000000
## 166	Serido	acude	TA	pr.brevi	1.5000000	1.2909944
## 167	Serido	acude	TA	ps.rhomb	0.0000000	0.0000000
## 168	Serido	acude	TA	ps.genise	0.0000000	0.0000000
## 169	Serido	acude	TA	se.heter	1.0000000	2.0000000
## 170	Serido	acude	TA	se.piaba	0.0000000	0.0000000
## 171	Serido	acude	TA	se.spilo	0.0000000	0.0000000
## 172	Serido	acude	TA	st.noton	0.0000000	0.0000000
## 173	Serido	acude	TA	sy.marmo	0.0000000	0.0000000
## 174	Serido	acude	TA	te.chalc	0.0000000	0.0000000
## 175	Serido	acude	TA	tr.signa	0.0000000	0.0000000
## 176	Serido	acude	ZA	ap.davis	0.0000000	NA
## 177	Serido	acude	ZA	as.bimac	1.0000000	NA
## 178	Serido	acude	ZA	as.fasci	0.0000000	NA
## 179	Serido	acude	ZA	ch.bimac	0.0000000	NA
## 180	Serido	acude	ZA	ci.ocela	0.0000000	NA
## 181	Serido	acude	ZA	ci.orien	0.0000000	NA

## 182	Serido	acude	ZA	co.macro	0.0000000	NA
## 183	Serido	acude	ZA	co.heter	0.0000000	NA
## 184	Serido	acude	ZA	cr.menez	0.0000000	NA
## 185	Serido	acude	ZA	cu.lepid	0.0000000	NA
## 186	Serido	acude	ZA	cy.gilbe	0.0000000	NA
## 187	Serido	acude	ZA	ge.brasi	0.0000000	NA
## 188	Serido	acude	ZA	he.margi	0.0000000	NA
## 189	Serido	acude	ZA	ho.malab	0.0000000	NA
## 190	Serido	acude	ZA	hy.pusar	0.0000000	NA
## 191	Serido	acude	ZA	le.melan	0.0000000	NA
## 192	Serido	acude	ZA	le.piau	0.0000000	NA
## 193	Serido	acude	ZA	le.taeni	0.0000000	NA
## 194	Serido	acude	ZA	mo.costa	0.0000000	NA
## 195	Serido	acude	ZA	mo.lepid	0.0000000	NA
## 196	Serido	acude	ZA	or.nilot	0.0000000	NA
## 197	Serido	acude	ZA	pa.manag	0.0000000	NA
## 198	Serido	acude	ZA	pimel.sp	0.0000000	NA
## 199	Serido	acude	ZA	po.retic	0.0000000	NA
## 200	Serido	acude	ZA	po.vivip	0.0000000	NA
## 201	Serido	acude	ZA	pr.brevi	9.0000000	NA
## 202	Serido	acude	ZA	ps.rhomb	0.0000000	NA
## 203	Serido	acude	ZA	ps.genise	0.0000000	NA
## 204	Serido	acude	ZA	se.heter	0.0000000	NA
## 205	Serido	acude	ZA	se.piaba	0.0000000	NA
## 206	Serido	acude	ZA	se.spilo	0.0000000	NA
## 207	Serido	acude	ZA	st.noton	0.0000000	NA
## 208	Serido	acude	ZA	sy.marmo	0.0000000	NA
## 209	Serido	acude	ZA	te.chalc	0.0000000	NA
## 210	Serido	acude	ZA	tr.signa	0.0000000	NA
## 211	Serido	rio	CC	ap.davis	0.0000000	NA
## 212	Serido	rio	CC	as.bimac	99.0000000	NA
## 213	Serido	rio	CC	as.fasci	0.0000000	NA
## 214	Serido	rio	CC	ch.bimac	0.0000000	NA
## 215	Serido	rio	CC	ci.ocela	0.0000000	NA
## 216	Serido	rio	CC	ci.orien	0.0000000	NA
## 217	Serido	rio	CC	co.macro	0.0000000	NA
## 218	Serido	rio	CC	co.heter	0.0000000	NA
## 219	Serido	rio	CC	cr.menez	0.0000000	NA
## 220	Serido	rio	CC	cu.lepid	0.0000000	NA
## 221	Serido	rio	CC	cy.gilbe	0.0000000	NA
## 222	Serido	rio	CC	ge.brasi	0.0000000	NA
## 223	Serido	rio	CC	he.margi	0.0000000	NA
## 224	Serido	rio	CC	ho.malab	0.0000000	NA
## 225	Serido	rio	CC	hy.pusar	0.0000000	NA
## 226	Serido	rio	CC	le.melan	0.0000000	NA
## 227	Serido	rio	CC	le.piau	0.0000000	NA

## 228	Serido	rio	CC	le.taeni	0.0000000	NA
## 229	Serido	rio	CC	mo.costa	0.0000000	NA
## 230	Serido	rio	CC	mo.lepid	1.0000000	NA
## 231	Serido	rio	CC	or.nilot	2.0000000	NA
## 232	Serido	rio	CC	pa.manag	0.0000000	NA
## 233	Serido	rio	CC	pimel.sp	0.0000000	NA
## 234	Serido	rio	CC	po.retic	0.0000000	NA
## 235	Serido	rio	CC	po.vivip	0.0000000	NA
## 236	Serido	rio	CC	pr.brevi	0.0000000	NA
## 237	Serido	rio	CC	ps.rhomb	0.0000000	NA
## 238	Serido	rio	CC	ps.genise	0.0000000	NA
## 239	Serido	rio	CC	se.heter	0.0000000	NA
## 240	Serido	rio	CC	se.piaba	0.0000000	NA
## 241	Serido	rio	CC	se.spilo	0.0000000	NA
## 242	Serido	rio	CC	st.noton	0.0000000	NA
## 243	Serido	rio	CC	sy.marmo	0.0000000	NA
## 244	Serido	rio	CC	te.chalc	0.0000000	NA
## 245	Serido	rio	CC	tr.signa	0.0000000	NA
## 246	Serido	rio	CP	ap.davis	0.0000000	0.0000000
## 247	Serido	rio	CP	as.bimac	10.0000000	8.9814624
## 248	Serido	rio	CP	as.fasci	0.2500000	0.5000000
## 249	Serido	rio	CP	ch.bimac	0.0000000	0.0000000
## 250	Serido	rio	CP	ci.ocela	16.0000000	16.9901932
## 251	Serido	rio	CP	ci.orien	9.7500000	10.2102889
## 252	Serido	rio	CP	co.macro	0.0000000	0.0000000
## 253	Serido	rio	CP	co.heter	0.0000000	0.0000000
## 254	Serido	rio	CP	cr.menez	0.0000000	0.0000000
## 255	Serido	rio	CP	cu.lepid	0.0000000	0.0000000
## 256	Serido	rio	CP	cy.gilbe	0.0000000	0.0000000
## 257	Serido	rio	CP	ge.brasi	0.0000000	0.0000000
## 258	Serido	rio	CP	he.margi	0.0000000	0.0000000
## 259	Serido	rio	CP	ho.malab	5.2500000	3.4034296
## 260	Serido	rio	CP	hy.pusar	1.0000000	1.1547005
## 261	Serido	rio	CP	le.melan	0.0000000	0.0000000
## 262	Serido	rio	CP	le.piau	1.5000000	1.2909944
## 263	Serido	rio	CP	le.taeni	0.0000000	0.0000000
## 264	Serido	rio	CP	mo.costa	0.0000000	0.0000000
## 265	Serido	rio	CP	mo.lepid	0.0000000	0.0000000
## 266	Serido	rio	CP	or.nilot	0.0000000	0.0000000
## 267	Serido	rio	CP	pa.manag	0.0000000	0.0000000
## 268	Serido	rio	CP	pimel.sp	0.0000000	0.0000000
## 269	Serido	rio	CP	po.retic	0.0000000	0.0000000
## 270	Serido	rio	CP	po.vivip	34.2500000	31.9204741
## 271	Serido	rio	CP	pr.brevi	1.2500000	2.5000000
## 272	Serido	rio	CP	ps.rhomb	0.0000000	0.0000000
## 273	Serido	rio	CP	ps.genise	0.0000000	0.0000000

```

## 274 Serido    rio    CP    se.heter    4.2500000    6.6520673
## 275 Serido    rio    CP    se.piaba    0.0000000    0.0000000
## 276 Serido    rio    CP    se.spilo    0.0000000    0.0000000
## 277 Serido    rio    CP    st.noton    0.0000000    0.0000000
## 278 Serido    rio    CP    sy.marmo    0.2500000    0.5000000
## 279 Serido    rio    CP    te.chalc    0.0000000    0.0000000
## 280 Serido    rio    CP    tr.signa    0.0000000    0.0000000
## 281 Serido    rio    CT    ap.davis    0.0000000    0.0000000
## 282 Serido    rio    CT    as.bimac    135.5000000    94.5074953
## 283 Serido    rio    CT    as.fasci    30.7500000    33.4103277
## 284 Serido    rio    CT    ch.bimac    0.7500000    1.5000000
## 285 Serido    rio    CT    ci.ocela    0.0000000    0.0000000
## 286 Serido    rio    CT    ci.orien    26.0000000    30.1772541
## 287 Serido    rio    CT    co.macro    0.0000000    0.0000000
## 288 Serido    rio    CT    co.heter    0.2500000    0.5000000
## 289 Serido    rio    CT    cr.menez    6.7500000    5.6199051
## 290 Serido    rio    CT    cu.lepid    0.0000000    0.0000000
## 291 Serido    rio    CT    cy.gilbe    12.5000000    25.0000000
## 292 Serido    rio    CT    ge.brasi    1.7500000    1.5000000
## 293 Serido    rio    CT    he.margi    0.5000000    0.5773503
## 294 Serido    rio    CT    ho.malab    13.2500000    13.7204227
## 295 Serido    rio    CT    hy.pusar    16.5000000    17.9907384
## 296 Serido    rio    CT    le.melan    0.0000000    0.0000000
## 297 Serido    rio    CT    le.piau    1.5000000    1.2909944
## 298 Serido    rio    CT    le.taeni    0.0000000    0.0000000
## 299 Serido    rio    CT    mo.costa    0.0000000    0.0000000
## 300 Serido    rio    CT    mo.lepid    10.0000000    19.3390796
## 301 Serido    rio    CT    or.nilot    81.0000000    42.2453153
## 302 Serido    rio    CT    pa.manag    0.0000000    0.0000000
## 303 Serido    rio    CT    pimel.sp    1.5000000    3.0000000
## 304 Serido    rio    CT    po.retic    6.2500000    9.4648472
## 305 Serido    rio    CT    po.vivip    155.5000000    143.0489427
## 306 Serido    rio    CT    pr.brevi    60.7500000    72.7203548
## 307 Serido    rio    CT    ps.rhomb    0.2500000    0.5000000
## 308 Serido    rio    CT    ps.genise    0.2500000    0.5000000
## 309 Serido    rio    CT    se.heter    35.2500000    23.6836793
## 310 Serido    rio    CT    se.piaba    17.0000000    34.0000000
## 311 Serido    rio    CT    se.spilo    0.2500000    0.5000000
## 312 Serido    rio    CT    st.noton    51.2500000    49.8021084
## 313 Serido    rio    CT    sy.marmo    0.0000000    0.0000000
## 314 Serido    rio    CT    te.chalc    0.0000000    0.0000000
## 315 Serido    rio    CT    tr.signa    45.2500000    64.0019531
## [1]    5.25 214.25    3.00 42.00 174.25    1.00 99.00 10.00 135.50
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1.00    5.25   42.00   76.03 135.50 214.25

```

Descritores da estrutura da comunidade: UA's

Sum, soma; mean, média; DP, desvio padrão da média; Max, maior valor; Min, menor valor; S, riqueza (ou frequência de ocorrência na matriz transposta); E, índice de equitabilidade de Pielou (PIELOU, 1975); H, índice de diversidade de Shannon (LUDWIG; REYNOLDS, 1988); D, índice de diversidade de Simpson (HURLBERT, 1971).

```
#Matriz transposta
m_trab <- t(m_trab) #transpõe a matriz de volta para comunitaria
Sum <- rowSums(m_trab)
Sum <- apply(m_trab,1,sum)
Mean <- rowMeans(m_trab)
Mean <- apply(m_trab,1,mean)
DP <- apply(m_trab,1,sd)
Max <- apply(m_trab,1,max)
Min <- apply(m_trab,1,min)
#library(vegan)
bin <- decostand(m_trab,"pa")
S <- apply(bin,1,sum)
Riqueza <- specnumber(m_trab)
Riqueza_total <- specnumber(colSums(m_trab))
H <- diversity(m_trab)
D <- diversity(m_trab, "simpson")
D[is.na(D)] <- 0 #substitui NA ou NaN por 0
E <- H/log(specnumber(m_trab))
E[is.na(E)] <- 0 #substitui NA ou NaN por 0
#library(moments)
Assimetria <- apply(m_trab,1,skewness)
Curtose <- apply(m_trab,1,kurtosis)
m_trab <- t(m_trab) #traz de volta
Descritores1 <- cbind(Sum, Mean, DP, Max, Min, S, E, H, D)
Descritores1 <- as.data.frame(Descritores1)
Descritores1
#Descritores1 <- Descritores1 %>% rownames_to_column(var="UA's")
↪ #da nome a primeira coluna
SomaTotalD <- apply(Descritores1,2,sum)
SomaTotalD
MediaTotalD <- apply(Descritores1,2,mean)
MediaTotalD
DPTotalD <- apply(Descritores1,2,sd)
DPTotalD
Descritores2 <- cbind(SomaTotalD, MediaTotalD, DPTotalD)
Descritores2 <- as.data.frame(Descritores2)
Descritores2 <- t(Descritores2)
```

```

Descritores2
DescritoresFinal <- rbind(Descritores1, Descritores2)
DescritoresFinal
DescritoresFinal <- round (DescritoresFinal, 2)
#Fazendo uma tabela
#library(gt)
df <- DescritoresFinal
ncol(df); nrow(df) #no. de N colunas x M linhas
df <- cbind(UA = rownames(df), df)
gt(df, caption = "Descritores da diversidade por Unidade Amostral
  ↪ (UA). Sum, soma; mean, média; DP, desvio padrão da média;
  ↪ Max, maior valor; Min, menor valor; S, riqueza (ou frequência
  ↪ de ocorrência na matriz transposta); E, índice de
  ↪ equitabilidade de Pielou; H, índice de diversidade de
  ↪ Shannon; D, índice de diversidade de Simpson.")

```

Descritores da normalidade

```

Normalidade1 <- cbind(Assimetria, Curtose)
Normalidade1 <- as.data.frame(Normalidade1)
Normalidade1 <- na.omit(Normalidade1) #remove NA e NaN
Normalidade1
SomaTotalN <- apply(Normalidade1,2,sum)
SomaTotalN
MediaTotalN <- apply(Normalidade1,2,mean)
MediaTotalN
DPTotalN <- apply(Normalidade1,2,sd)
DPTotalN
Normalidade2<-cbind(SomaTotalN, MediaTotalN, DPTotalN)
Normalidade2<-as.data.frame(Normalidade2)
Normalidade2 <- t(Normalidade2) #"t" transpoe a matriz
Normalidade2
NormalidadeFinal <- rbind(Normalidade1, Normalidade2)
NormalidadeFinal
NormalidadeFinal <- round(NormalidadeFinal, 2)
#Fazendo uma tabela
nf <- NormalidadeFinal
ncol(nf); nrow(nf) #no. de N colunas x M linhas
nf <- cbind(UA = rownames(nf), nf)
gt(nf, caption = "Descritores da normalidade por Unidade Amostral
  ↪ (UA)")

```

A função `fix(nome da matriz)` dá acesso ao grid da matriz criada para manipulação dos dados numéricos.

Salvando as tabelas criadas em txt direto no diretório de trabalho

```
write.table(data.frame("Spp"=rownames(DescritoresFinal),
                      DescritoresFinal),
            "DescritoresUA.csv",
            row.names=FALSE,
            sep="\t")
write.table(data.frame("Spp"=rownames(NormalidadeFinal),
                      NormalidadeFinal),
            "NormalidadeUA.txt",
            row.names=FALSE,
            sep="\t")
```

Sites consultados

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executá-lo. Lembre de remover os `#` ou `##` caso necessite executar essas linhas.

```
## dev.off() #apaga os graficos, se houver algum
## rm(list=ls(all=TRUE)) #limpa a memória
## cat("\014") #limpa o console
## install.packages("vegan")
## install.packages("moments")
## install.packages("ggplot2")
## install.packages("dplyr")
## install.packages("tidyr")
## install.packages("tibble")
## install.packages("tidyverse") #atente para alguma msg de erro
↵ qdo executar essa linha
## install.packages("forcats")
## install.packages("iNEXT")
## install.packages("openxlsx")
```

```

## install.packages("gt")
## library(tibble); library(tidyverse); library(forcats);
  ↪ library(openxlsx); library(Rcpp)
## getwd()
## setwd("C:/Seu/Diretório/De/Trabalho")
#dir <- getwd() #criamos um vetor com o diretório de trabalho
#shell.exec(dir) #abre o diretório de trabalho no Windows
  ↪ Explorer
ppbio <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06.xlsx"
  ↪ ,
                                rowNames = T, colNames = T,
                                sheet = "Sheet1")

str(ppbio)
#View(ppbio)
ppbio[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas de 1
  ↪ a 5.
## #View(ppbio)
## print(ppbio[1:8,1:8])
## ppbio[1:10,1:10]
## str(ppbio)
## mode(ppbio)
## class(ppbio)
m_trab <- ppbio
m_trab <- t(ppbio)
str(m_trab)
#View(m_trab)
m_trab
print(m_trab[1:5,1:5])
m_trab[1:5,1:5]
str(m_trab)
mode(m_trab)
class(m_trab)
range(m_trab) #menor e maior valores
length(m_trab) #no. de colunas
ncol(m_trab) #no. de N colunas
nrow(m_trab) #no. de M linhas
sum(lengths(m_trab)) #soma os nos. de colunas
length(as.matrix(m_trab)) #tamanho da matriz m x n
sum(m_trab == 0) #número de observações igual a zero
sum(m_trab > 0) #número de observações maiores que zero
#calculando a proporção de zeros na matriz
zeros <- (sum(m_trab == 0)/length(as.matrix(m_trab)))*100
zeros
tamanho <- data.frame(

```

```

Função = c("range", "length", "n cols", "m linhas", "Tamanho",
  ↪ "Tamanho",
    "Zeros", "Nao zeros", "% Zeros"),
Resultado = c(paste(range(m_trab), collapse = " - "),
  length(m_trab), ncol(m_trab),
  nrow(m_trab), sum(lengths(m_trab)),
  length(as.matrix(m_trab)), sum(m_trab == 0),
  sum(m_trab > 0), round(zeros, 1)))

tamanho
knitr::kable(tamanho, format = "markdown", caption = "Resumo das
  ↪ informações sobre o tamanho da base de dados.")
#?apply
Sum <- rowSums(m_trab)
#ou
Sum <- apply(m_trab,1,sum)
Sum
## Media
Mean <- rowMeans(m_trab)
Mean
## Ou
Mean <- apply(m_trab,1,mean)
Mean
## Desvio padrão
DP <- apply(m_trab,1,sd)
DP
## Máximo
Max <- apply(m_trab,1,max)
Max
## Mínimo
Min <- apply(m_trab,1,min)
Min
library(vegan)
bin <- decostand(m_trab,"pa")
bin[1:10, 1:10]
S <- apply(bin,1,sum)
S
#OU
Riqueza <- specnumber(m_trab)
Riqueza
Riqueza_total <- specnumber(colSums(m_trab))
Riqueza_total
H <- diversity(m_trab, index = "shannon")
H
D <- diversity(m_trab, "simpson")
D

```

```

D[is.na(D)] <- 0 #substitui NA ou NaN por 0
D
E <- H/log(specnumber(m_trab))
E
E[is.na(E)] <- 0 #substitui NA ou NaN por 0
E
library(moments)
Assimetria <- apply(m_trab,1,skewness)
Assimetria
Curtose <- apply(m_trab,1,kurtosis)
Curtose
Descritores1 <- cbind(Sum, Mean, DP, Max, Min, S, E, H, D)
Descritores1 <- as.data.frame(Descritores1)
Descritores1
#Descritores1 <- Descritores1 %>%
  ↪ rownames_to_column(var="Espécies") #da nome a primeira coluna
SomaTotalD <- apply(Descritores1,2,sum)
SomaTotalD
MediaTotalD <- apply(Descritores1,2,mean)
MediaTotalD
DPTotalD <- apply(Descritores1,2,sd)
DPTotalD
Descritores2 <- cbind(SomaTotalD, MediaTotalD, DPTotalD)
Descritores2 <- as.data.frame(Descritores2)
Descritores2 <- t(Descritores2)
Descritores2
DescritoresFinal <- rbind(Descritores1, Descritores2)
DescritoresFinal
DescritoresFinal <- round (DescritoresFinal, 2)
DescritoresFinal
#Fazendo uma tabela
library(gt)
df <- DescritoresFinal
ncol(df); nrow(df) #no. de N colunas x M linhas
df <- cbind(Spp = rownames(df), df)
gt(df, rowname_col = "Espécie", caption = "Descritores da
  ↪ diversidade por espécie (colunas). Sum, soma; mean, média;
  ↪ DP, desvio padrão da média; Max, maior valor; Min, menor
  ↪ valor; S, riqueza (ou frequência de ocorrência na matriz
  ↪ transposta); E, índice de equitabilidade de Pielou; H, índice
  ↪ de diversidade de Shannon; D, índice de diversidade de
  ↪ Simpson.")
Normalidade1 <- cbind(Assimetria, Curtose)
Normalidade1 <- as.data.frame(Normalidade1)
Normalidade1

```



```

SomaTotalN <- apply(Normalidade1,2,sum)
SomaTotalN
MediaTotalN <- apply(Normalidade1,2,mean)
MediaTotalN
DPTotalN <- apply(Normalidade1,2,sd)
DPTotalN
Normalidade2<-cbind(SomaTotalN, MediaTotalN, DPTotalN)
Normalidade2<-as.data.frame(Normalidade2)
Normalidade2 <- t(Normalidade2) #"t" transpoe a matriz
Normalidade2
NormalidadeFinal <- rbind(Normalidade1, Normalidade2)
NormalidadeFinal
NormalidadeFinal <- round(NormalidadeFinal, 2)
NormalidadeFinal
#Fazendo uma tabela
nf <- NormalidadeFinal
ncol(nf); nrow(nf) #no. de N colunas x M linhas
nf <- cbind(Spp = rownames(nf), nf)
gt(nf, rowname_col = "Espécie", caption = "Descritores da
  ↪ normalidade por espécie (coluna)")
write.table(data.frame("Spp"=rownames(DescritoresFinal),
  DescritoresFinal),
  "DescritoresSPP.txt",
  row.names=FALSE,
  sep="\t")
write.table(data.frame("Spp"=rownames(NormalidadeFinal),
  NormalidadeFinal),
  "NormalidadeSPP.txt",
  row.names=FALSE,
  sep="\t")
m_trab <- ppbio
m_trab
Hill <- renyi(m_trab,
  scales = c(0:5),
  hill = TRUE)
Hill
library(ggplot2)
library(tidyr)
library(tidyverse)
grafico1 <- Hill %>%
  rownames_to_column() %>%
  pivot_longer(-rowname) %>%
  mutate(name = factor(name, name[1:length(Hill)])) %>%
  ggplot(aes(x = name, y = value, group = rowname,
    col = rowname)) +

```

```

geom_point(size = 2) +
geom_line(size = 1) +
xlab("Parâmetro de ordem de diversidade (q)") +
ylab("Diversidade") +
labs(col = "Locais") +
theme_bw() +
theme(text = element_text(size = 5)) #ajustar a fonte caso nao
  ↳ caiba no output html
grafico1
ggsave(grafico1, dpi = 300, filename = "fig-hill.png")
abund <- colSums(m_trab)
#abund <- m_trab[1, ] #escolhe a primeira linha para a
  ↳ distribuição de abundância
df <- data.frame(sp = colnames(m_trab),
                 abun = abund)
grafico2 <- ggplot(df, aes(fct_reorder(sp, -abun),
                               abun, group = 1)) +

  geom_col() +
  geom_line(col = "red", linetype = "dashed") +
  geom_point(col = "red") +
  xlab("Espécies") +
  ylab("Abundância") +
  theme_bw() +
  theme(axis.text.x = element_text(
    angle = 45,
    hjust = 1,
    face = "italic"))
grafico2
ggsave(grafico2, dpi = 300, filename = "fig-abun.png")
m_trab_r <- mutate(m_trab, across(everything(), ceiling))
  ↳ #arredonda a matriz original para números inteiros
colnames(t(m_trab_r))
rarefa <-
  ↳ t(m_trab_r[c("S-R-CT2", "S-R-CP2", "S-A-TA2", "B-A-MU2"),])
  ↳ #curva de rarefação para os sítios especificados
class(m_trab)
## Curva de rarefação para todos os sítios
#rarefa <- t(m_trab_r)
## Curva de rarefação para as 8 UA's com maior soma
#m_trab_r <- as.data.frame(t(m_trab_r)) #transpõe a matriz
#col_sums <- colSums(m_trab_r)
#largest_columns <- names(sort(col_sums, decreasing = TRUE)[1:8])
#rarefa <- m_trab_r[largest_columns] #curva de rarefação para as
  ↳ 8 UA's com maior soma
library(iNEXT)

```

```

out <- iNEXT(rarefa, q = 0,
             datatype = "abundance",
             size = NULL,
             endpoint = 1500, #define o comprimento de eixo x
             knots = 40,
             se = TRUE,
             conf = 0.95,
             nboot = 50)
grafico3 <- ggiNEXT(out, type = 1, facet.var="None") +
  theme_bw() +
  labs(fill = "Áreas") +
  xlab("Número de indivíduos") +
  ylab("Riqueza de espécies") +
  theme(legend.title=element_blank()) #ver como fica com
  ↪ facet.var="Assemblage"
grafico3
ggsave(grafico3, dpi = 300, filename = "fig-rare1.png")
acumula <- specaccum(m_trab,
                    method = "random")

acumula
plot(acumula)
plot_data <- data.frame("UAs" = c(0, acumula$sites),
                       "Riqueza" = c(0, acumula$richness),
                       "lower" = c(0, acumula$richness -
                                   ↪ acumula$sd),
                       "upper" = c(0, acumula$richness +
                                   ↪ acumula$sd))
gLocais <- ggplot(plot_data, aes(x = UAs, y = Riqueza)) +
  geom_point(color = "blue", size = 4) +
  geom_line(color = "blue", lwd = 2) +
  geom_ribbon(aes(ymin = lower, ymax = upper),
             linetype=2, alpha=0.3, fill = "yellow") +
  ylab("Riqueza acumulada") +
  theme_classic() +
  theme(text = element_text(size = 16))
gLocais
plot_data <- data.frame("Individuos" = c(0, acumula$individuals),
                       "Riqueza" = c(0, acumula$richness),
                       "lower" = c(0, acumula$richness -
                                   ↪ acumula$sd),
                       "upper" = c(0, acumula$richness +
                                   ↪ acumula$sd))
gInd <- ggplot(plot_data, aes(x = Individuos, y = Riqueza)) +
  geom_point(color = "blue", size = 4) +
  geom_line(color = "blue", lwd = 2) +

```

```

    geom_ribbon(aes(ymin = lower, ymax = upper),
               linetype=2, alpha=0.3, fill = "yellow") +
    ylab("Riqueza acumulada") +
    theme_classic() +
    theme(text = element_text(size = 16))
gInd
#Matriz transposta
m_trab <- t(m_trab) #transpõe a matriz
Sum <- rowSums(m_trab)
Sum <- apply(m_trab,1,sum)
Mean <- rowMeans(m_trab)
Mean <- apply(m_trab,1,mean)
DP <- apply(m_trab,1,sd)
Max <- apply(m_trab,1,max)
Min <- apply(m_trab,1,min)
#library(vegan)
bin <- decostand(m_trab,"pa")
S <- apply(bin,1,sum)
Riqueza <- specnumber(m_trab)
Riqueza_total <- specnumber(colSums(m_trab))
H <- diversity(m_trab)
D <- diversity(m_trab, "simpson")
D[is.na(D)] <- 0 #substitui NA ou NaN por 0
E <- H/log(specnumber(m_trab))
E[is.na(E)] <- 0 #substitui NA ou NaN por 0
#library(moments)
Assimetria <- apply(m_trab,1,skewness)
Curtose <- apply(m_trab,1,kurtosis)
m_trab <- t(m_trab) #traz de volta
Descritores1 <- cbind(Sum, Mean, DP, Max, Min, S, E, H, D)
Descritores1 <- as.data.frame(Descritores1)
Descritores1
#Descritores1 <- Descritores1 %>%
  ↪ rownames_to_column(var="Espécies") #da nome a primeira coluna
SomaTotalD <- apply(Descritores1,2,sum)
SomaTotalD
MediaTotalD <- apply(Descritores1,2,mean)
MediaTotalD
DPTotalD <- apply(Descritores1,2,sd)
DPTotalD
Descritores2 <- cbind(SomaTotalD, MediaTotalD, DPTotalD)
Descritores2 <- as.data.frame(Descritores2)
Descritores2 <- t(Descritores2)
Descritores2
DescritoresFinal <- rbind(Descritores1, Descritores2)

```

```

DescritoresFinal
DescritoresFinal <- round (DescritoresFinal, 2)
#Fazendo uma tabela
#library(gt)
df <- DescritoresFinal
ncol(df); nrow(df) #no. de N colunas x M linhas
df <- cbind(UA = rownames(df), df)
gt(df, caption = "Descritores da diversidade por Unidade Amostral
  ↳ (UA). Sum, soma; mean, média; DP, desvio padrão da média;
  ↳ Max, maior valor; Min, menor valor; S, riqueza (ou frequência
  ↳ de ocorrência na matriz transposta); E, índice de
  ↳ equitabilidade de Pielou; H, índice de diversidade de
  ↳ Shannon; D, índice de diversidade de Simpson.")
Normalidade1 <- cbind(Assimetria, Curtose)
Normalidade1 <- as.data.frame(Normalidade1)
Normalidade1 <- na.omit(Normalidade1) #remove NA e NaN
Normalidade1
SomaTotalN <- apply(Normalidade1,2,sum)
SomaTotalN
MediaTotalN <- apply(Normalidade1,2,mean)
MediaTotalN
DPTotalN <- apply(Normalidade1,2,sd)
DPTotalN
Normalidade2<-cbind(SomaTotalN, MediaTotalN, DPTotalN)
Normalidade2<-as.data.frame(Normalidade2)
Normalidade2 <- t(Normalidade2) #"t" transpoe a matriz
Normalidade2
NormalidadeFinal <- rbind(Normalidade1, Normalidade2)
NormalidadeFinal
NormalidadeFinal <- round(NormalidadeFinal, 2)
#Fazendo uma tabela
nf <- NormalidadeFinal
ncol(nf); nrow(nf) #no. de N colunas x M linhas
nf <- cbind(UA = rownames(nf), nf)
gt(nf, caption = "Descritores da normalidade por Unidade Amostral
  ↳ (UA)")
write.table(data.frame("Spp"=rownames(DescritoresFinal),
  DescritoresFinal),
  "DescritoresUA.csv",
  row.names=FALSE,
  sep="\t")
write.table(data.frame("Spp"=rownames(NormalidadeFinal),
  NormalidadeFinal),
  "NormalidadeUA.txt",
  row.names=FALSE,

```

```
sep="\t")
```

Referências

Table 17.2: Descritores da diversidade por espécie (colunas). Sum, soma; RA, abundância relativa (%); mean, média; DP, desvio padrão da média; Max, maior valor; Min, menor valor; MinZ, menor valor não zero; FO, frequência de ocorrência (%); S, riqueza (ou no. de ocorrências, da matriz transposta); E, índice de equitabilidade de Pielou; H, índice de diversidade de Shannon; D, índice de diversidade de Simpson.

	Sum	RA	Mean	DP	Max	Min	MinZ	FO	S	R
ap-davis	27.00	0.30	1.04	4.39	22.00	0	5.00	7.69	2.00	2.00
as-bimac	2386.00	26.82	91.77	132.43	511.00	0	1.00	88.46	23.00	23.00
as-fasci	158.00	1.78	6.08	16.20	64.00	0	1.00	38.46	10.00	10.00
ch-bimac	705.00	7.93	27.12	75.87	273.00	0	3.00	19.23	5.00	5.00
ci-ocela	70.00	0.79	2.69	8.30	40.00	0	2.00	19.23	5.00	5.00
ci-orien	143.00	1.61	5.50	14.62	69.00	0	5.00	26.92	7.00	7.00
co-macro	2.00	0.02	0.08	0.39	2.00	0	2.00	3.85	1.00	1.00
co-heter	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00	1.00
cr-menez	28.00	0.31	1.08	3.15	14.00	0	1.00	19.23	5.00	5.00
cu-lepid	21.00	0.24	0.81	4.12	21.00	0	21.00	3.85	1.00	1.00
cy-gilbe	131.00	1.47	5.04	18.33	81.00	0	50.00	7.69	2.00	2.00
ge-brasi	1020.00	11.47	39.23	106.35	509.00	0	1.00	57.69	15.00	15.00
he-margi	2.00	0.02	0.08	0.27	1.00	0	1.00	7.69	2.00	2.00
ho-malab	109.00	1.23	4.19	7.61	31.00	0	1.00	53.85	14.00	14.00
hy-pusar	71.00	0.80	2.73	8.66	43.00	0	1.00	26.92	7.00	7.00
le-melan	2.00	0.02	0.08	0.39	2.00	0	2.00	3.85	1.00	1.00
le-piau	15.00	0.17	0.58	0.99	3.00	0	1.00	30.77	8.00	8.00
le-taeni	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00	1.00
mo-costa	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00	1.00
mo-lepid	41.00	0.46	1.58	7.64	39.00	0	1.00	11.54	3.00	3.00
or-nilot	848.00	9.53	32.62	59.15	247.00	0	1.00	69.23	18.00	18.00
pa-manag	554.00	6.23	21.31	62.39	250.00	0	1.00	19.23	5.00	5.00
pimel-sp	6.00	0.07	0.23	1.18	6.00	0	6.00	3.85	1.00	1.00
po-retic	381.00	4.28	14.65	52.52	266.00	0	5.00	23.08	6.00	6.00
po-vivip	978.00	10.99	37.62	79.50	326.00	0	8.00	42.31	11.00	11.00
pr-brevi	279.00	3.14	10.73	33.39	164.00	0	1.00	46.15	12.00	12.00
ps-rhomb	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00	1.00
ps-genise	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00	1.00
se-heter	296.00	3.33	11.38	22.99	93.00	0	3.00	38.46	10.00	10.00
se-piaba	68.00	0.76	2.62	13.34	68.00	0	68.00	3.85	1.00	1.00
se-spilo	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00	1.00
st-noton	205.00	2.30	7.88	25.56	115.00	0	1.00	15.38	4.00	4.00
sy-marmo	1.00	0.01	0.04	0.20	1.00	0	1.00	3.85	1.00	1.00
te-chalc	134.00	1.51	5.15	18.38	76.00	0	58.00	7.69	2.00	2.00
tr-signa	208.00	2.34	8.00	27.83	141.00	0	4.00	23.08	6.00	6.00
SomaTotalD	8895.00	100.00	342.12	807.31	3484.00	0	262.00	746.15	194.00	194.00
MediaTotalD	254.14	2.86	9.77	23.07	99.54	0	7.49	21.32	5.54	5.54
DPTotalD	468.39	5.27	18.01	33.06	138.27	0	16.46	21.38	5.56	5.56

Table 17.3: Descritores da normalidade por espécie (coluna)

	Assimetria	Curtose
ap-davis	4.47	21.73
as-bimac	1.77	5.56
as-fasci	2.96	10.27
ch-bimac	2.54	7.74
ci-ocela	3.80	17.15
ci-orien	3.48	15.07
co-macro	4.80	24.04
co-heter	4.80	24.04
cr-menez	3.25	12.82
cu-lepid	4.80	24.04
cy-gilbe	3.48	13.78
ge-brasi	3.64	16.06
he-margi	3.18	11.08
ho-malab	2.28	7.60
hy-pusar	4.13	19.50
le-melan	4.80	24.04
le-piau	1.44	3.66
le-taeni	4.80	24.04
mo-costa	4.80	24.04
mo-lepid	4.79	23.98
or-nilot	2.29	7.97
pa-manag	2.87	9.86
pimel-sp	4.80	24.04
po-retic	4.46	21.83
po-vivip	2.54	8.67
pr-brevi	4.05	18.66
ps-rhomb	4.80	24.04
ps-genise	4.80	24.04
se-heter	2.29	7.68
se-piaba	4.80	24.04
se-spilo	4.80	24.04
st-noton	3.42	13.82
sy-marmo	4.80	24.04
te-chalc	3.28	12.02
tr-signa	4.44	21.72
SomaTotalN	132.46	596.69
MediaTotalN	3.78	17.05
DPTotalN	1.04	6.94

Chapter 18

R Modulo 4.2 - Decomposição da diversidade

RESUMO

Na ecologia de comunidades, a diversidade de espécies é uma medida importante para entender a complexidade e a estrutura de uma comunidade de organismos. Vamos explorar algumas das métricas comuns usadas para avaliar a diversidade de espécies.

Apresentação

Na ecologia de comunidades, a diversidade de espécies é uma medida importante para entender a complexidade e a estrutura de uma comunidade de organismos. Vamos explorar algumas das métricas comuns usadas para avaliar a diversidade de espécies. Essas métricas são usadas para avaliar a diversidade e a estrutura de comunidades ecológicas. Elas podem fornecer informações importantes sobre como as diferentes espécies interagem em um ecossistema e como a diversidade de espécies pode ser afetada por mudanças ambientais ou distúrbios (MAGURRAN, 1988).

18.1 Sobre os dados

Usaremos para esse tutorial dois conjuntos de dados. A **Matriz comunitária** (ppbio06c-peixes.xlsx) de dados coletados no Programa de Pesquisa em Bio-

diversidade - PPBio (Veja Programa de Pesquisa em Biodiversidade – PPBio). Esses são dados de espécies de peixes distribuídas em diversas unidades amostrais (UA's ou sítios). Essa é a **matriz bruta de dados**, porque os valores ainda não foram ajustados para os valores de Captura Por Unidade de Esforço (CPUE), nem foram relativizados ou transformados.

Além disso usaremos a **tabela de agrupamentos** (ppbio06-grupos)

Revise as informações sobre as bases de dados no capítulo Bases de Dados. A matriz de dados para esse Módulo pode ser baixada na seção Arquivos disponíveis.

Revise o módulo anterior Estrutura da Comunidade

18.1.1 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

Instalando os pacotes necessários para esse módulo.

```
install.packages("vegan")
install.packages("moments")
install.packages("ggplot2")
install.packages("dplyr")
install.packages("tidyr")
install.packages("tibble")
install.packages("tidyverse") #atente para alguma msg de erro qdo
  ↪ executar essa linha
install.packages("forcats")
install.packages("iNEXT")
install.packages("openxlsx")
install.packages("gt")
install.packages("ggVennDiagram")
```

Depois de instalados, carregue os pacotes a seguir no seu computador.

```
library(openxlsx); library(tibble); library(tidyverse);
  ↪ library(forcats); library(Rcpp)
```

Os códigos acima, são usados para instalar e carregar os pacotes necessários para este módulo. Esses códigos são comandos para instalar pacotes no R. Um pacote é uma coleção de funções, dados e documentação que ampliam as capacidades do R (R CRAN, (R DEVELOPMENT CORE TEAM, 2017)) e RStudio (R STUDIO TEAM, 2022)). No exemplo acima, o pacote **openxlsx** permite ler e escrever arquivos Excel no R. Para instalar um pacote no R, você precisa usar a função **install.packages()**.

Depois de instalar um pacote, você precisa carregá-lo na sua sessão R com a função `library()`. Por exemplo, para carregar o pacote `openxlsx`, você precisa executar a função `library(openxlsx)`. Isso irá permitir que você use as funções do pacote na sua sessão R. Você precisa carregar um pacote toda vez que iniciar uma nova sessão R e quiser usar um pacote instalado.

Agora vamos **definir o diretório de trabalho**. Esse código é usado para obter e definir o diretório de trabalho atual no R. O comando `getwd()` retorna o caminho do diretório onde o R está lendo e salvando arquivos. O comando `setwd()` muda esse diretório de trabalho para o caminho especificado entre aspas. No seu caso, você deve ajustar o caminho para o seu próprio diretório de trabalho. **Lembre de usar a barra “/” entre os diretórios. E não a contra-barra “\”.**

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

18.1.2 Importando a planilha

Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações.

- Ajuste a primeira linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.
- Ajuste o parâmetro `sheet = "Sheet1"` para refletir a aba correta do arquivo `.xlsx` a ser importado.

```
#dir <- getwd() #criamos um vetor com o diretório de trabalho
#shell.exec(dir) #abre o diretório de trabalho no Windows
↳ Explorer
ppbio <- read.xlsx(
↳ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06p-peixes.xlsx"
↳ ,
rowNames = T, colNames = T,
sheet = "Sheet1")
str(ppbio)
```

```
#View(ppbio)
ppbio[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas de 1
↪ a 5.
```

```
## 'data.frame': 23 obs. of 35 variables:
## $ ap-davis : num 0 0 0 0 0 0 0 0 0 0 ...
## $ as-bimac : num 194 19 23 142 5 46 206 16 234 0 ...
## $ as-fasci : num 55 0 1 3 1 0 64 0 7 1 ...
## $ ch-bimac : num 0 0 13 3 0 178 0 0 238 0 ...
## $ ci-ocela : num 0 0 0 0 40 0 0 13 0 0 ...
## $ ci-orien : num 5 0 0 69 9 0 25 24 0 5 ...
## $ co-macro : num 0 0 0 0 0 0 0 0 2 0 ...
## $ co-heter : num 1 0 0 0 0 0 0 0 0 0 ...
## $ cr-menez : num 14 0 0 4 0 0 8 0 0 1 ...
## $ cu-lepid : num 0 0 0 0 0 0 0 0 0 0 ...
## $ cy-gilbe : num 0 0 0 0 0 0 0 0 0 50 ...
## $ ge-brasi : num 3 0 0 0 0 0 1 0 0 3 ...
## $ he-margi : num 0 0 0 1 0 0 0 0 0 1 ...
## $ ho-malab : num 1 5 0 17 10 2 31 4 20 4 ...
## $ hy-pusar : num 9 2 0 43 2 0 11 0 0 3 ...
## $ le-melan : num 0 0 0 0 0 0 0 0 0 0 ...
## $ le-piau : num 3 0 0 1 3 0 2 1 0 0 ...
## $ le-taeni : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-costa : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-lepid : num 39 0 0 1 0 0 0 0 0 0 ...
## $ or-nilot : num 36 0 0 77 0 0 138 0 0 73 ...
## $ pa-manag : num 0 0 0 0 0 0 0 0 0 0 ...
## $ pimel-sp : num 6 0 0 0 0 0 0 0 0 0 ...
## $ po-retic : num 0 0 0 20 0 0 5 0 0 0 ...
## $ po-vivip : num 47 15 0 221 32 0 326 10 0 28 ...
## $ pr-brevi : num 5 0 1 15 5 2 164 0 0 59 ...
## $ ps-rhomb : num 0 0 0 0 0 0 1 0 0 0 ...
## $ ps-genise : num 0 0 0 0 0 0 1 0 0 0 ...
## $ se-heter : num 40 14 4 60 0 0 38 0 0 3 ...
## $ se-piaba : num 68 0 0 0 0 0 0 0 0 0 ...
## $ se-spilo : num 0 0 0 0 0 0 1 0 0 0 ...
## $ st-noton : num 1 0 0 25 0 0 115 0 0 64 ...
## $ sy-marmo : num 0 0 0 0 1 0 0 0 0 0 ...
## $ te-chalc : num 0 0 0 0 0 0 0 0 0 0 ...
## $ tr-signa : num 18 0 0 15 0 0 7 0 0 141 ...
## ap-davis as-bimac as-fasci ch-bimac ci-ocela
## S-R-CT1 0 194 55 0 0
## S-R-CP1 0 19 0 0 0
## S-A-TA1 0 23 1 13 0
```

## S-R-CT2	0	142	3	3	0
## S-R-CP2	0	5	1	0	40

Exibindo os dados importados (esses comando são “case-sensitive” `ignore.case(object)`).

```
#View(ppbio)
print(ppbio[1:8,1:8])
ppbio[1:10,1:10]
str(ppbio)
mode(ppbio)
class(ppbio)
```

18.2 REINÍCIO 1

```
m_trab <- ppbio
```

Aqui cria-se um novo objeto do R (`m_trab`, ou a matriz de trabalho, para esse momento) que substitui a matriz de dados original, por uma nova matriz que pode ser a matriz relativizada, transformada, transposta, etc. Dessa forma, mantemos a matriz de dados original caso precisemos dela novamente.

Abreviações

No interesse de sistematizar o código R das várias matrizes que são comumente usadas em uma AMD, a tabela @ref(tab:42tbl-m_2) resume seus tipos e abreviações.

18.3 Análise de Espécies Compartilhadas

Instalando os pacotes necessários

```
install.packages("dplyr")
install.packages("eulerr")
install.packages("VennDiagram")
install.packages("ggVennDiagram")
install.packages("ggvenn")
install.packages("gplots")
```

Carregado a base de dados `teste` para ajudar no entendimento.

```
teste <- read.table(text = "
  SP1 SP2 SP3 SP4 SP5 SP6 SP7 SP8 SP9 SP10 SP11 SP12
  ↪ SP13 SP14 SP15 SP16 SP17 SP18 SP19 SP20
A1 1 0 0 1 0 1 1 1 0 0 1 0 0 1 0 1
  ↪ 1 1 0 0
A2 1 0 0 1 0 1 1 0 0 0 1 0 0 1 0 1
  ↪ 1 0 0 0
A3 1 0 0 1 0 1 1 0 0 0 1 0 0 1 0 1
  ↪ 1 0 0 0
B1 0 1 0 1 1 0 1 0 1 0 0 1 0 1 1 0
  ↪ 1 0 1 0
B2 0 1 0 1 1 0 1 0 0 0 0 1 0 1 1 0
  ↪ 1 0 0 0
B3 0 1 0 1 1 0 1 0 0 0 0 1 0 1 1 0
  ↪ 1 0 0 0
C1 0 0 1 0 1 1 1 0 0 1 0 0 1 0 1 1
  ↪ 1 0 0 1
C2 0 0 1 0 1 1 1 0 0 0 0 0 1 0 1 1
  ↪ 1 0 0 0
C3 0 0 1 0 1 1 1 0 0 0 0 0 1 0 1 1
  ↪ 1 0 0 0
", header = TRUE, row.names = 1)
teste
```

18.4 REINÍCIO 2

```
m_trab <- ppbio
```

18.4.1 Separando a matriz `ppbio` em suas partes (S e B ou A e R)

Separa-se S- e B-, e atribui-se, respectivamente, aos grupos G1 e G2 e remove-se as colunas zeradas.

```
G1 <- m_trab[1:12,]
names(which(colSums(G1) == 0)) #all-zero columns
```

Table 18.1: Código para o delineamento amostral. *n, total amostrado = 23; **np, n planejado = 96.

Hierarquia	n*=23			
Área				
S-	Ambiente	Ponto	Coleta	Data
B-	R-	CT	1	01-04-2006
	A-	CP	2	26-06-2006
		TA	3	22-09-2006
		MU	4	17-12-2006
		GU		
		PC		
2	x 2	x 6	x 4	np**= 96

```
G1 <- G1[, colSums(G1 != 0) > 0]
G2 <- m_trab[13:23,]
names(which(colSums(G2) == 0)) #all-zero columns
G2 <- G2[, colSums(G2 != 0) > 0]
```

18.4.1.1 Mesmo procedimento usando o comando grepl() do pacote dplyr

Outra forma de separar grupos, mas agora para R- e A-, atribuindo-se, respectivamente, aos grupos G3 e G4 e removendo-se as colunas zeradas.

```
library(dplyr)
G3 <- filter(m_trab, grepl("R-", row.names(m_trab)))
names(which(colSums(G3) == 0)) #all-zero columns
G3 <- G3[, colSums(G3 != 0) > 0]
G4 <- filter(m_trab, grepl("A-", row.names(m_trab)))
names(which(colSums(G4) == 0)) #all-zero columns
G4 <- G4[, colSums(G4 != 0) > 0]
```

18.5 Táxons compartilhados pelas duas bases de dados

18.5.1 Bases de dados em arquivos diferentes B e S

Nos códigos abaixo, a função `intersect()` é usada para se obter os nomes de colunas em comum entre `fixo` e `entorno`, que são guardados em um vetor. Esses vetores são repassados nos outros argumentos subsequentes. O propósito dos argumentos `setdiff()` e `\<- 0` não é preencher células vazias com zeros, mas adicionar novas colunas em cada data frame com nomes de colunas que estão presentes em um data frame mas não em outro. Se uma coluna está faltando em um data frame, ela será adicionada aquele data frame com o termo NA ou NULL. Para substituir os valores rotulados de NA ou NULL usa-se a função `merged[is.na(merged)] <- 0`. Ver Apêndices.

```
shared_spp <- intersect(names(G1), names(G2)) #get the common
  ↪ column names
shared_spp
G1_only <- setdiff(names(G1), names(G2))
G1_only
G2_only <- setdiff(names(G2), names(G1))
G2_only
Riqueza <- length(shared_spp) + length(G1_only) + length(G2_only)
Riqueza
```

Criando um `data.frame` com todas as espécies compartilhadas e exclusivas.

```
library(tidyverse)
# Create a data frame with all species
all_species <- data.frame(
  type = c(rep("Shared", length(shared_spp)),
           rep("G1_only", length(G1_only)),
           rep("G2_only", length(G2_only))),
  species = c(shared_spp, G1_only, G2_only)
)
# Create a table using the `table()` function
species_table <- table(all_species$type, all_species$species)

# Convert the table to a data frame and format it
species_table_df <- as.data.frame.matrix(species_table)
rownames(species_table_df) <- c("G1_only", "G2_only", "Shared")
species_table_df <- t(species_table_df[,
  ↪ order(colnames(species_table_df))])
```



```

species_table_df <- as.data.frame(species_table_df)
species_table_df
# Ordenando pelo nome da coluna
species_table_df <- rownames_to_column(species_table_df, var =
  ↪ "Espécies")
species_table_df <-
  ↪ species_table_df[order(species_table_df$G1_only,
  ↪ species_table_df$G2_only, species_table_df$Shared, decreasing
  ↪ = TRUE),]
library(gt)
gt(species_table_df)

```

18.6 REINÍCIO 3

```
m_bruta <- ppbio
```

Aqui cria-se o vetor da matriz bruta a partir da base de dados depois de feitos os ajustes necessários.

18.6.1 Criando uma matriz de médias

```

#Inserindo coluna para agrupamentos
ncol(m_bruta); nrow(m_bruta) #no. de N colunas x M linhas
m_bruta_g <- cbind(Grupos = rownames(m_bruta), m_bruta)

###Mudando nomes de linhas, ajuste em BB-EN
#m_bruta_g$Grupos[m_bruta_g$Grupos == "EN11"] <- "BE11"
#m_bruta_g$Grupos[m_bruta_g$Grupos == "EN14"] <- "BE14"
#m_bruta_g$Grupos[m_bruta_g$Grupos == "EN15"] <- "BE15"
###

agrup1 <- substr(m_bruta_g[, 1], 1,1)
agrup1
m_bruta_g <- m_bruta_g %>% mutate(Grupos=c(agrup1))

#m_avg_part <- aggregate(m_bruta_g[, 2:3],
  ↪ list(m_bruta_g$Grupos), mean)

```

```

m_avg <- m_bruta_g %>%
  group_by(Grupos) %>%
  summarise(across(.cols = everything(), ~ mean(.x, na.rm =
    ↪ TRUE)))
#m_avg <- m_bruta_g %>%
#  group_by(Grupos) %>%
#  summarise(across(.cols = everything(), list(mean = mean, sd =
    ↪ sd)))
#?across

#Primeira coluna para nomes das linhas
m_avg <- as.data.frame(m_avg)
class(m_avg)
rownames(m_avg) <- m_avg[,1]
m_avg[,1] <- NULL
m_avg
#Salvando a matriz
write.table(m_avg,
  "m_avgcsv.csv",
  append = F,
  quote = TRUE,
  sep = ";", dec = ",",
  row.names = T)
m_avg1_csv <- read.csv("m_avgcsv.csv",
  sep = ";", dec = ",",
  header = T,
  row.names = 1,
  na.strings = NA)

```

18.6.2 Análise de Espécies Compartilhadas: Em arquivos diferentes

```

#Espécies compartilhadas
shared_spp1 <- intersect(names(G1), names(G2)) #get the common
  ↪ column names
shared_spp1
G1_only <- setdiff(names(G1), names(G2))
G1_only
G2_only <- setdiff(names(G2), names(G1))
G2_only
Riqueza <- length(shared_spp1) + length(G1_only) +
  ↪ length(G2_only)

```

Riqueza

```
shared_spp2 <- intersect(names(G3), names(G4))
shared_spp2
G3_only <- setdiff(names(G3), names(G4))
G3_only
G4_only <- setdiff(names(G4), names(G3))
G4_only
Riqueza <- length(shared_spp2) + length(G3_only) +
  ↪ length(G4_only)
Riqueza
```

18.6.3 Bases de dados no mesmo arquivo ppbio

Pode-se usar a matriz `teste.xlsx` para testar e verificar os resultados dos comandos em comparação com as matrizes reais. O comando `fix()` permite editar uma matriz. A matriz de teste tem 9 linhas e 20 colunas, com os nomes A1, A2, A3, B1, B2, B3, C1, C2, C3 nas linhas e SP1, SP2, SP3, SP4, SP5, SP6, SP7, SP8, SP9, SP10, SP11, SP12, SP13, SP14, SP15, SP16, SP17, SP18, SP19, SP20 como os nomes das colunas. Códigos baseados nas letras A, B e C, portanto, se referem a matriz de teste.

A seguir separamos a matriz em suas partes.

```
data <- (teste)
data
library(dplyr)
A <- filter(data, grepl("A", row.names(data)))
names(which(colSums(A) == 0)) #all-zero columns
A <- A[, colSums(A != 0) > 0]
B <- filter(data, grepl("B", row.names(data)))
names(which(colSums(B) == 0)) #all-zero columns
B <- B[, colSums(B != 0) > 0]
C <- filter(data, grepl("C", row.names(data)))
names(which(colSums(C) == 0)) #all-zero columns
C <- C[, colSums(C != 0) > 0]
```

18.7 REINÍCIO 4

```
data <- (m_bruta)
```

18.8 Encontrando espécies exclusivas

18.8.1 Escolhendo as LINHAS OU GRUPOS para comparar

```
# Get the row indices where "A" occurs
rownames(data)
rows <- grep("S-", rownames(data))
#rows <- grep("B-", rownames(data))
#rows <- c(1:36)
rows
```

18.8.1.1 Espécies exclusivas que ocorrem em 1 LINHA E OUTRA, OU EM 1 GRUPO E OUTRO (#EM TESTE)

Aqui procuramos espécies que ocorrem em todas as linhas do grupo definido pelo vetor `rows` no chunk anterior `rows`

```
# Initialize an empty vector to store species exclusive to 'A'
↪ rows
species_only_in <- character(0)
# Iterate over each column
for (col in colnames(data)) {
  # Check if the species occurs only in 'A' rows
  if (all(data[rows, col] != 0) && !any(data[-rows, col] != 0)) {
    species_only_in <- c(species_only_in, col)
  }
}
# Print species that only occur in 'A' rows
print(species_only_in)
data
```

18.9. ESPÉCIES EXCLUSIVAS PARA 2 LINHAS OU 2 GRUPOS - BASEADO NA SOMA DOS GRUPOS (#FUN

18.8.2 Espécies exclusivas para 1 LINHA OU 1 GRUPO - Baseado na soma dos grupos (#FUNCIONA)

```
# Get the row indices where 'A' occurs
rows
# Calculate the sum of occurrences of each species in 'A' rows
sum_of <- colSums(data[rows, ])
sum_of
# Initialize an empty vector to store species exclusive to 'A'
↪ rows
species_only_in <- character(0)
# Iterate over each column
for (col in colnames(data)) {
  # Check if the species occurs only in 'A' rows
  if (sum(data[rows, col]) == sum_of[col] && !any(data[-rows,
↪ col] != 0)) {
    species_only_in <- c(species_only_in, col)
  }
}
# Print species that only occur in 'A' rows
print(species_only_in)
species_only_in
data
rows
```

18.9 Espécies exclusivas para 2 LINHAS OU 2 GRUPOS - Baseado na soma dos grupos (#FUNCIONA)

```
# Get the row indices where 'A' occurs
rows <- grep("S-", rownames(data))
rows2 <- grep("B-", rownames(data))
#rows <- as.vector(rbind(c(rows, rows2)))
rows
```

```
# Calculate the sum of occurrences of each species in 'A' rows
sum_of <- colSums(data[rows, ])
```

```

sum_of
# Initialize an empty vector to store species exclusive to 'A'
↪ rows
species_only_in <- character(0)
# Iterate over each column
for (col in colnames(data)) {
  # Check if the species occurs only in 'A' rows
  if (sum(data[rows, col]) == sum_of[col] && !any(data[-rows,
    ↪ col] != 0)) {
    species_only_in <- c(species_only_in, col)
  }
}
# Print species that only occur in 'A' rows
print(species_only_in)
species_only_in
data
rows
#identical(S_only, species_only_in)
#intersect(S_only, species_only_in) #shared column names
#setdiff(S_only, species_only_in) #only in 1st vector
#length(intersect(S_only, species_only_in)) #how many

```

18.10 Encontrando espécies compartilhadas ENTRE DOIS (OU MAIS) GRUPOS

Encontra espécies que são compartilhadas (ocorrem em **TODAS AS LINHAS**) dentro do grupo analisado. Mas, não significa que elas estejam apenas nestas linhas. A função `any()` indica que **QUALQUER** linha em comum entre duas colunas faz com que elas tenha essas colunas compartilhadas. Já a função `all()` indica que, para duas colunas terem linhas compartilhadas os grupos das colunas tem que compartilhar **TODAS** as suas linhas. Uma análise sobre esse loop. Adicionamos `&& any(data[rows_G3, col] != 0)` para um terceiro grupo e assim sucessivamente.

```

# Get the rows corresponding to A and B (and C)
rows_G1 <- grep("S-", rownames(data))
rows_G2 <- grep("B-", rownames(data))
rows_G3 <- grep("R-", rownames(data))
rows_G4 <- grep("A-", rownames(data))
#rows <- as.vector(cbind(c(rows_G1, rows_G2, rows_G3, rows_G4)))
# Initialize an empty vector to store species that A and B have
↪ in common

```

```

species_in <- character(0)
# Iterate over each column
for (col in colnames(data)) {
  # Check if the species has at least one non-zero value in both
  ↪ A and B rows
  if (any(data[rows_G1, col] != 0) && any(data[rows_G2, col] !=
  ↪ 0)) {
    species_in <- c(species_in, col)
  }
}
# Print species that A and B have in common
print(species_in)
shared_spp
data

```

Uma análise feita pelo ChatGPT sobre o loop “for...{...if{...}}” acima e os outros anteriores é apresentada aqui

18.11 Diagrama de Venn

Primeiro é necessário criar uma matriz binária para os valores das colunas nas linhas. Isso é feito a seguir.

```

library("gt")
m_venn <- as.data.frame(t(m_avg))
m_venn
gt(round(m_venn, 2), rownames_to_stub = TRUE)
m_venn[m_venn !=0] <- 1 #matriz binária

```

##	B	S
## ap-davis	2.45454545	0.00000000
## as-bimac	91.27272727	106.58333333
## as-fasci	2.36363636	11.00000000
## ch-bimac	0.00000000	58.75000000
## ci-ocela	0.54545455	5.33333333
## ci-orien	0.00000000	11.91666667
## co-macro	0.00000000	0.16666667
## co-heter	0.00000000	0.08333333
## cr-menez	0.00000000	2.33333333
## cu-lepid	1.90909091	0.00000000
## cy-gilbe	7.36363636	4.16666667

```
## ge-brasi 92.00000000 0.66666667
## he-margi 0.00000000 0.16666667
## ho-malab 0.36363636 8.75000000
## hy-pusar 0.09090909 5.83333333
## le-melan 0.18181818 0.00000000
## le-piau 0.09090909 1.16666667
## le-taeni 0.09090909 0.00000000
## mo-costa 0.09090909 0.00000000
## mo-lepid 0.00000000 3.33333333
## or-nilot 46.63636364 27.08333333
## pa-manag 50.27272727 0.00000000
## pimel-sp 0.00000000 0.50000000
## po-retic 29.27272727 2.08333333
## po-vivip 19.90909091 63.25000000
## pr-brevi 1.45454545 21.16666667
## ps-rhomb 0.00000000 0.08333333
## ps-genise 0.00000000 0.08333333
## se-heter 12.18181818 13.50000000
## se-piaba 0.00000000 5.66666667
## se-spilo 0.00000000 0.08333333
## st-noton 0.00000000 17.08333333
## sy-marmo 0.00000000 0.08333333
## te-chalc 12.18181818 0.00000000
## tr-signa 2.45454545 15.08333333
```

18.11.1 Usando o pacote eulerr

```
library("eulerr")
```

```
## Warning: pacote 'eulerr' foi compilado no R versão 4.5.3
```

```
## Registered S3 method overwritten by 'eulerr':
```

```
##   method      from
##   plot.venn    gplots
```

```
##
```

```
## Anexando pacote: 'eulerr'
```


```
## O seguinte objeto é mascarado por 'package:gplots':
```

```
##
```

```
##   venn
```



```
#set.seed() #this seed changes the orientation of the sets  
↵  
plot(euler(m_venn), counts = TRUE, fontface = 1)
```



18.12 Usando o pacote VennDiagram

```
# Load required libraries  
library(VennDiagram)
```

```
## Warning: pacote 'VennDiagram' foi compilado no R versão 4.5.3  
  
## Carregando pacotes exigidos: grid  
  
## Carregando pacotes exigidos: futile.logger  
  
## Warning: pacote 'futile.logger' foi compilado no R versão 4.5.3  
  
##  
## Anexando pacote: 'VennDiagram'
```

```
## O seguinte objeto é mascarado por 'package:car':
##
##      ellipse


## O seguinte objeto é mascarado por 'package:ggpubr':
##
##      rotate
```


```
library(ggvenn)
```

```
## Warning: pacote 'ggvenn' foi compilado no R versão 4.5.3
```



```
G1 <- nrow(subset(m_venn, S==1))
G2 <- nrow(subset(m_venn, B==1))
#G3 <- nrow(subset(m_venn, R==1))
#G4 <- nrow(subset(m_venn, A==1))
G1_G2 <- nrow(subset(m_venn, G1==1 & G2==1))
#G3_G4 <- nrow(subset(m_venn, G3==1 & G4==1))

grid.newpage()
draw.single.venn(area = G1, category = "G1")
```







```
grid.newpage()
draw.single.venn(G1, category = "G1",
                 lty = "blank",
                 fill = "cornflower blue",
                 alpha = 0.5)
```



```
##lty - outline of circles, ## fill - colour, ## alpha - colour  
↪ transparency  
grid.newpage()
```

```
draw.pairwise.venn(G1, G2, G1_G2,  
                    category = c("G1","G2"))
```



```
grid.newpage()
draw.pairwise.venn(G1, G2, G1_G2,
  category = c("G1","G2"),
  lty = rep("blank",2),
  fill = c("light blue", "pink"),
  alpha = rep(0.5,2),
  cat.pos = c(0,0),
  cat.dist = rep(0.025,2))
```





```
## cat.pos - position of category titles, represented by degree
#  ↳ from the
## middle of the circle
## cat.dist - distance of the category titles from the edge of
#  ↳ the circle

grid.newpage()
draw.pairwise.venn(G1, G2, G1_G2,
  category = c("G1", "G2"),
  lty = rep("blank", 2),
  fill = c("light blue", "pink"),
  alpha = rep(0.5, 2),
  cat.pos = c(0, 0),
  cat.dist = rep(0.025, 2),
  scaled = FALSE)
```





```
## scaled - TRUE for scaled or FALSE for unscaled circles

grid.newpage() #<--
draw.pairwise.venn(area1 = G1, area2 = G2, cross.area = 0,
```



```
category = c("G1","G2"),  
lty = rep("blank",2),  
fill = c("light blue", "green"),  
alpha = rep(0.5, 2),  
cat.pos = c(0, 180),  
euler.d = TRUE, sep.dist = 0.03,  
rotation.degree = 45)
```





```
## euler.d - TRUE for movable circles; FALSE for unmovable
  ↪ circles. Must be
## TRUE to have space between non-overlapping circles.
## sep.dist - distance between circles
## rotation.degree - degrees the diagram is rotated

#grid.newpage()
#draw.triple.venn(area1 = BB, area2 = CA, area3 = EN,
#                 n12 = BB_CA, n23 = CA_EN, n13 = BB_EN,
#                 n123 = BB_CA_EN,
#                 category = c("Rio Barro Branco", "#Rio Caiana",
#                 ↪ "Entorno da REBio"),
#                 lty = "blank",
#                 fill = c("skyblue", "pink1", "#mediumorchid"),
#                 scaled = TRUE)
#grid.newpage()
#draw.quad.venn(area1 = BB, area2 = CA, area3 = EN, #area4 = RE,
#               n12 = BB_CA, n23 = CA_EN, n13 = BB_EN,
#               n14 = BB_RE, n24 = CA_RE, n34 = EN_RE,
#               n123 = BB_CA_EN, n1234 = BB_CA_EN_RE,
#               n124 = BB_CA_RE, n134 = BB_EN_RE,
#               n234 = CA_EN_RE,
#               category = c("BB", "CA", "EN", "RE"),
#               lty = "blank",
```

```
#           fill = c("skyblue", "pink1", #"mediumorchid",
↪  "orange"),
#           scaled = TRUE)
```

18.13 Diagrama de Venn - BASEADO EM PALAVRAS

Cálculo do overlap [AQUI](#) ou [AQUI](#)

```
lista <- m_venn
lista

G1 <- rownames(lista)[which(lista$S !=0)]
G2 <- rownames(lista)[which(lista$B !=0)]
G3 <- rownames(lista)[which(lista$R !=0)]
G4 <- rownames(lista)[which(lista$A !=0)]
over = list(G1, G2)
over

venn.diagram(#salva o diagrama em um arquivo
  x = list(G1, G2),
  category.names = c("G1", "G2"),
  filename = 'fig-venn_diagramm2.png',
  height = 3000, width = 3000, resolution = 500,
  disable.logging = T, scaled = T,
  output = F,
  lty = "blank",
  fill = c("skyblue", "pink1"))
```

```
## INFO [2026-07-24 15:20:21] $x
## INFO [2026-07-24 15:20:21] list(G1, G2)
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $category.names
## INFO [2026-07-24 15:20:21] c("G1", "G2")
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $filename
## INFO [2026-07-24 15:20:21] [1] "fig-venn_diagramm2.png"
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $height
## INFO [2026-07-24 15:20:21] [1] 3000
## INFO [2026-07-24 15:20:21]
```

```
## INFO [2026-07-24 15:20:21] $width
## INFO [2026-07-24 15:20:21] [1] 3000
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $resolution
## INFO [2026-07-24 15:20:21] [1] 500
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $disable.logging
## INFO [2026-07-24 15:20:21] T
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $scaled
## INFO [2026-07-24 15:20:21] T
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $output
## INFO [2026-07-24 15:20:21] F
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $lty
## INFO [2026-07-24 15:20:21] [1] "blank"
## INFO [2026-07-24 15:20:21]
## INFO [2026-07-24 15:20:21] $fill
## INFO [2026-07-24 15:20:21] c("skyblue", "pink1")
## INFO [2026-07-24 15:20:21]
```

```
overlap <- calculate.overlap(over)
overlap
VennDiagram::get.venn.partitions(over)
```

```
## Warning in make.truth.table(x): fixing missing, empty or duplicated names.
```

```
##           B S
## ap-davis  1 0
## as-bimac   1 1
## as-fasci   1 1
## ch-bimac   0 1
## ci-ocela   1 1
## ci-orien   0 1
## co-macro   0 1
## co-heter   0 1
## cr-menez   0 1
## cu-lepid   1 0
## cy-gilbe   1 1
## ge-brasi   1 1
## he-margi   0 1
## ho-malab   1 1
## hy-pusar   1 1
```

```

## le-melan 1 0
## le-piau 1 1
## le-taeni 1 0
## mo-costa 1 0
## mo-lepid 0 1
## or-nilot 1 1
## pa-manag 1 0
## pimel-sp 0 1
## po-retic 1 1
## po-vivip 1 1
## pr-brevi 1 1
## ps-rhomb 0 1
## ps-genise 0 1
## se-heter 1 1
## se-piaba 0 1
## se-spilo 0 1
## st-noton 0 1
## sy-marmo 0 1
## te-chalc 1 0
## tr-signa 1 1
## [[1]]
## [1] "as-bimac" "as-fasci" "ch-bimac" "ci-ocela" "ci-orien" "co-macro"
## [7] "co-heter" "cr-menez" "cy-gilbe" "ge-brasi" "he-margi" "ho-malab"
## [13] "hy-pusar" "le-piau" "mo-lepid" "or-nilot" "pimel-sp" "po-retic"
## [19] "po-vivip" "pr-brevi" "ps-rhomb" "ps-genise" "se-heter" "se-piaba"
## [25] "se-spilo" "st-noton" "sy-marmo" "tr-signa"
##
## [[2]]
## [1] "ap-davis" "as-bimac" "as-fasci" "ci-ocela" "cu-lepid" "cy-gilbe"
## [7] "ge-brasi" "ho-malab" "hy-pusar" "le-melan" "le-piau" "le-taeni"
## [13] "mo-costa" "or-nilot" "pa-manag" "po-retic" "po-vivip" "pr-brevi"
## [19] "se-heter" "te-chalc" "tr-signa"
##
## [1] 1
## $a1
## [1] "as-bimac" "as-fasci" "ch-bimac" "ci-ocela" "ci-orien" "co-macro"
## [7] "co-heter" "cr-menez" "cy-gilbe" "ge-brasi" "he-margi" "ho-malab"
## [13] "hy-pusar" "le-piau" "mo-lepid" "or-nilot" "pimel-sp" "po-retic"
## [19] "po-vivip" "pr-brevi" "ps-rhomb" "ps-genise" "se-heter" "se-piaba"
## [25] "se-spilo" "st-noton" "sy-marmo" "tr-signa"
##
## $a2
## [1] "ap-davis" "as-bimac" "as-fasci" "ci-ocela" "cu-lepid" "cy-gilbe"
## [7] "ge-brasi" "ho-malab" "hy-pusar" "le-melan" "le-piau" "le-taeni"
## [13] "mo-costa" "or-nilot" "pa-manag" "po-retic" "po-vivip" "pr-brevi"
## [19] "se-heter" "te-chalc" "tr-signa"

```

```
##
## $a3
## [1] "as-bimac" "as-fasci" "ci-ocela" "cy-gilbe" "ge-brasi" "ho-malab"
## [7] "hy-pusar" "le-piau" "or-nilot" "po-retic" "po-vivip" "pr-brevi"
## [13] "se-heter" "tr-signa"
##
##      X1      X2      ..set..
## 1  TRUE  TRUE      X1 X2
## 2 FALSE  TRUE  (X2) (X1)
## 3  TRUE FALSE  (X1) (X2)
##
## 1  as-bimac, as-fasci, ci-ocela, cy-gilbe, ge-brasi, ho-malab, hy-pusar, le-piau, o
## 2                                     ap-davis, o
## 3 ch-bimac, ci-orien, co-macro, co-heter, cr-menez, he-margi, mo-lepid, pimel-sp, p
##      ..count..
## 1          14
## 2           7
## 3          14
```

Mais opções Aqui e Aqui

```
library("ggVennDiagram")
x <- list(
  G1 = rownames(lista)[which(lista$S !=0)],
  G2 = rownames(lista)[which(lista$B !=0)],
  G3 = rownames(lista)[which(lista$R !=0)],
  G4 = rownames(lista)[which(lista$A !=0)])

ggvenn(
  x,
  fill_color = c("#0073C2FF", "#EFC000FF", "#868686FF",
    ↪ "#CD534CFF"),
  stroke_size = 0.5, set_name_size = 4
)

# Default plot
ggVennDiagram(
  x, label_alpha = 0,
  category.names = c("G1", "G2", "G3", "G4")
) +
  ggplot2::scale_fill_gradient(low="yellow", high = "green")

grid.newpage()
ggVennDiagram(x[1:2], label_alpha = 0)
```

```
library("ggvenn")
grid.newpage()
ggvenn(x)

library("gplots")
grid.newpage()
v.table <- venn(x)
v.table <- as.data.frame(v.table)
print(v.table)
print(t(m_avg))
```

```
# Estrutura da comunidade
system(paste("open", shQuote(
  ↪ "D:/Elvio/OneDrive/MSS/_Zoo-Rebio/R_ZooRebio/strcom.qmd"))))
```

18.14 PARTIÇÃO DA DIVERSIDADE

O output da função `adipart` no pacote `vegan` do R fornece uma análise detalhada da diversidade alfa, beta e gama baseada no índice de riqueza para o seu conjunto de dados `fauna.zoo` em diferentes escalas espaciais definidas por `escala.total`. Aqui está uma explicação detalhada do output e sua interpretação:

18.14.1 Output da Função `adipart`

18.15 Extrair valores do objeto `part` - geral

```
statistic <- part.geral
statistic$SES <- -part.geral$ecosimuzmean <-
-part.geral$ecosimuzmeanslower
2.5 <- -apply(part.geral$ecosimuzsimulated, 1, quantile, probs =
0.025)
median_50 <- -apply(part.geral$ecosimuzsimulated, 1, quantile, probs =
0.50)
upper_97.5 <- -apply(part.geral$ecosimuzsimulated, 1, quantile, probs =
0.975)
Pr_sim <- part.geral$ecosimu$pval
```

18.16 Definir função para adicionar significância

```
get_significance <- function(p) { if (p <= 0.001) { return(" ") } else if (p
<= 0.01) { return(" ") } else if (p <= 0.05) { return(" ") } else if (p <=
0.1) { return(" ") } else { return(" ") } }
significance <- sapply(Pr_sim, get_significance)
```

18.17 Criar dataframe com todas as informações

```
diversity_data <- data.frame( Component = names(statistic), Observed =
round(statistic, 2), SES = round(SES, 2), Mean = round(mean, 2), Lower_2.5
= round(lower_2.5, 2), Median_50 = round(median_50, 2), Upper_97.5 =
round(upper_97.5, 2), Pr_sim = Pr_sim, Sign = significance )
```

18.18 Exibir a tabela

```
print(diversity_data) str(part.geral) gt(diversity_data)
```

18.18.0.1 Chamada

A chamada da função especifica os parâmetros utilizados: - **y**: `fauna.zoo` (seu conjunto de dados) - **x**: `escala.total` (as escalas espaciais) - **index**: “richness” (medida de diversidade) - **weights**: “unif” (pesos uniformes) - **nsimul**: 999 (número de simulações para o modelo nulo)

18.18.0.2 Modelo Nulo

O método usado para as simulações do modelo nulo é `r2dtable` com 999 simulações. Este método simula tabelas aleatórias com as mesmas somas de linhas e colunas que a tabela observada.

18.18.0.3 Estatísticas e Teste de Hipótese

O output fornece os valores observados das estatísticas, os tamanhos dos efeitos padronizados (SES), médias, percentis (2.5%, 50%, 97.5%) e valores de p (Pr(sim.)) para cada componente de diversidade.

18.18.1 Análise das Estatísticas

1. **alpha.1, alpha.2, alpha.3**: Estes são os valores de diversidade alfa em diferentes níveis hierárquicos.
 - A diversidade alfa mede a riqueza média de espécies dentro de cada unidade de amostragem.
 - Os valores observados são significativamente menores do que os valores simulados, conforme indicado pelos valores de p muito baixos (0.001).

2. **gamma:** Esta é a diversidade gama, representando a riqueza total de espécies em todas as unidades de amostragem.
 - O valor observado é igual ao valor simulado, indicando que não há desvio significativo do modelo nulo (valor de $p = 1.000$).
3. **beta.1, beta.2, beta.3:** Estes são os valores de diversidade beta em diferentes níveis hierárquicos.
 - A diversidade beta mede a diferenciação na composição de espécies entre as unidades de amostragem.
 - O valor beta.1 observado é significativamente menor, enquanto os valores beta.2 e beta.3 são significativamente maiores do que os valores simulados (todos os valores de $p = 0.001$).

18.18.1.1 Códigos de Significância

- ‘***’ indica um valor de $p < 0.001$, mostrando resultados altamente significativos.

18.18.2 Interpretação

- **Diversidade Alfa:** Os valores de diversidade alfa observados significativamente menores sugerem que a riqueza de espécies dentro das unidades individuais é menor do que o esperado ao acaso.
- **Diversidade Gama:** A riqueza total de espécies (diversidade gama) não difere do valor esperado, o que implica que a riqueza total é como esperado.
- **Diversidade Beta:** Os resultados mistos para diversidade beta (beta.1 menor e beta.2, beta.3 maiores) indicam variabilidade na composição de espécies entre as unidades de amostragem em diferentes níveis hierárquicos. Isso pode sugerir diferentes processos ecológicos ou estruturas comunitárias nessas escalas.

No geral, esses resultados fornecem insights sobre a partição da diversidade dentro do seu conjunto de dados, destacando áreas onde os padrões observados diferem daqueles esperados sob um modelo nulo.

O modelo nulo `r2dtable` é uma técnica utilizada em ecologia e biologia da conservação para gerar tabelas de contingência aleatórias que mantêm as margens (somas de linhas e colunas) iguais às da tabela original. Isso é útil para testes de hipótese e análise de diversidade porque permite comparar os dados observados com o que seria esperado por acaso, mantendo as restrições estruturais dos dados originais.

18.18.3 Detalhes do `r2dtable`

- **Função:** `r2dtable` faz parte do pacote base do R e é usado para gerar tabelas de contingência aleatórias.
- **Entrada:** A função `r2dtable(n, r, c)` toma três argumentos:
 - `n`: número de tabelas aleatórias a serem geradas.
 - `r`: vetor com as somas das linhas da tabela original.
 - `c`: vetor com as somas das colunas da tabela original.
- **Saída:** Produz uma lista de tabelas de contingência aleatórias que têm as mesmas somas de linhas e colunas que a tabela original.

18.18.4 Como Funciona

O algoritmo por trás do `r2dtable` usa uma permutação aleatória das células da tabela original, mas ajusta as células de forma que as somas das linhas e colunas permaneçam constantes. Isso cria uma distribuição nula contra a qual os dados observados podem ser comparados.

18.18.5 Uso no Contexto do `vegan` e `adipart`

Quando aplicado no contexto de diversidade com a função `adipart` do pacote `vegan`:

1. **Geração de Tabelas Aleatórias:** `r2dtable` gera tabelas de contingência aleatórias baseadas nas margens (somas das linhas e colunas) da tabela original `fauna.zoo`.
2. **Simulações:** A função `adipart` utiliza essas tabelas para criar uma distribuição nula de riqueza de espécies (ou qualquer outro índice de diversidade especificado).
3. **Comparação com Dados Observados:** Os valores observados de alfa, beta e gama diversidade são comparados com a distribuição nula para determinar se os padrões observados são significativamente diferentes do que seria esperado por acaso.

18.18.6 Interpretação

- **Valores Observados vs. Valores Simulados:** Comparando os valores observados com os valores simulados, pode-se determinar se a diversidade observada é maior ou menor do que o esperado por acaso.
- **Significância Estatística:** Valores de `p` são calculados para testar a significância das diferenças entre os valores observados e a distribuição nula.

18.18.7 Exemplos de Uso

Aqui está um exemplo básico de como o `r2dtable` pode ser usado diretamente no R:

```
# Suponha uma tabela original com margens definidas
r <- c(20, 30, 25) # somas das linhas
c <- c(25, 25, 25) # somas das colunas

# Gerar 999 tabelas aleatórias
simulated_tables <- r2dtable(999, r, c)

# Visualizar a primeira tabela simulada
print(simulated_tables[[1]])
```

No contexto do `vegan` e `adipart`, você normalmente não chamaria `r2dtable` diretamente, pois a função `adipart` faz isso internamente para gerar as distribuições nulas necessárias para a análise de diversidade.

Essa técnica permite realizar uma análise robusta da diversidade, considerando a estrutura dos dados e fornecendo uma base para testes de hipóteses sobre os padrões de diversidade observados.

Claro! Vamos interpretar os resultados em português:

A saída que você compartilhou parece ser de uma análise de simulação hierárquica realizada com a função `hiersimu`, que provavelmente faz parte de um pacote para estatísticas ecológicas ou biodiversidade no R. Aqui está uma breve interpretação dos componentes principais:

- **statistic:** O valor observado da estatística de diversidade para cada nível hierárquico (por exemplo, habitat, ponto, rio, etc.).
- **SES (Tamanho do Efeito Padronizado):** Indica como a estatística observada se compara ao modelo nulo. Um SES negativo significa que a diversidade observada é menor do que a esperada por acaso, enquanto um SES positivo significa que é maior.
- **mean, 2.5%, 50%, 97.5%:** Esses valores representam a média e o intervalo de confiança de 95% (IC) para a estatística sob o modelo nulo (ou seja, valores simulados).
- **Pr(sim.):** O valor-p que indica a probabilidade de que a estatística observada seja menor ou maior do que os valores simulados sob a hipótese nula. Um valor-p baixo (por exemplo, <0.01) sugere que a estatística observada é significativamente diferente do modelo nulo.

Aqui está a interpretação dos resultados:

1. **rebio.habitat:**

- Estatística observada: 0.90817
- SES: -35.933 (sugerindo uma diversidade muito menor comparada ao modelo nulo)
- Valor-p: 0.01, indicando que o valor observado é significativamente menor do que o esperado por acaso.

2. **rebio.ponto:**

- Estatística observada: 0.99444
- SES: -39.547
- Valor-p: 0.01, indicando uma diversidade significativamente menor.

3. **rebio.rio:**

- Estatística observada: 1.61250
- SES: -23.345
- Valor-p: 0.01, indicando uma diversidade significativamente menor.

4. **rebio:**

- Estatística observada: 1.80002
- SES: 0.000 (indicando que a diversidade observada está exatamente no nível esperado pelo modelo nulo)
- Valor-p: 1.00, significando que não há diferença significativa em relação ao modelo nulo.

Resumindo, todos os níveis hierárquicos, exceto “rebio”, mostram desvios significativos na diversidade em relação ao que é esperado por acaso, com uma diversidade observada significativamente menor. “rebio” está exatamente no nível esperado, sem desvio significativo.

Apêndices

Sites consultados

Primeira coluna para nomes das linhas

Script limpo

Aqui apresento o script na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executá-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

Referências

	B	S
ap-davis	2.45	0.00
as-bimac	91.27	106.58
as-fasci	2.36	11.00
ch-bimac	0.00	58.75
ci-ocela	0.55	5.33
ci-orien	0.00	11.92
co-macro	0.00	0.17
co-heter	0.00	0.08
cr-menez	0.00	2.33
cu-lepid	1.91	0.00
cy-gilbe	7.36	4.17
ge-brasi	92.00	0.67
he-margi	0.00	0.17
ho-malab	0.36	8.75
hy-pusar	0.09	5.83
le-melan	0.18	0.00
le-piau	0.09	1.17
le-taeni	0.09	0.00
mo-costa	0.09	0.00
mo-lepid	0.00	3.33
or-nilot	46.64	27.08
pa-manag	50.27	0.00
pimel-sp	0.00	0.50
po-retic	29.27	2.08
po-vivip	19.91	63.25
pr-brevi	1.45	21.17
ps-rhomb	0.00	0.08
ps-genise	0.00	0.08
se-heter	12.18	13.50
se-piaba	0.00	5.67
se-spilo	0.00	0.08
st-noton	0.00	17.08
sy-marmo	0.00	0.08
te-chalc	12.18	0.00
tr-signa	2.45	15.08

Chapter 19

R Módulo 4.3 - Estrutura do habitat

RESUMO

Apresentação

19.1 Sobre os dados

Usaremos para esse tutorial dois conjuntos de dados. A **Matriz ambiental** (ppbio06p-amb.xlsx) de dados coletados no Programa de Pesquisa em Biodiversidade - PPBio (Veja Programa de Pesquisa em Biodiversidade – PPBio) (MEDEIROS; SILVA; RAMOS, 2008). Esses são dados de **variáveis ambientais** distribuídas em diversas unidades amostrais (UA's ou sítios). Essa é a **matriz bruta de dados**, porque os valores ainda não foram transformados (SOKAL; ROHLF, 1995). Note que as variáveis foram medidas em diferentes unidades (cm, m, °C, mg/L, etc.), com uma alta amplitude de variação, sugerido uso de matriz transformada e/ou reescalada. Além disso usaremos a **tabela de agrupamentos** (ppbio06-grupos.xlsx).

Revise as informações sobre as bases de dados no Capítulo 7. As bases de dados para esse Módulo podem ser baixadas na Seção 7.2.

19.2 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

19.2.1 Instalando os pacotes necessários para esse módulo.

Se você já fez o módulo anterior, não vai precisar instalar nenhum pacote novo. Os pacotes necessários serão carregados ao longo desse módulo.

```
install.packages("psych")
install.packages("corrplot")
```

Agora vamos **definir o diretório de trabalho**. Esse código é usado para obter e definir o diretório de trabalho atual no R. O comando `getwd()` retorna o caminho do diretório onde o R está lendo e salvando arquivos. O comando `setwd()` muda esse diretório de trabalho para o caminho especificado entre aspas. No seu caso, você deve ajustar o caminho para o seu próprio diretório de trabalho. **Lembre de usar a barra “/” entre os diretórios. E não a contra-barra “\”.**

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

19.3 Importando a planilha

Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações.

- Ajuste a primeira linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.
- Ajuste o parâmetro `sheet = "Sheet1"` para refletir a aba correta do arquivo .xlsx a ser importado. Vamos trabalhar com os dados do ano 1.

```
#dir <- getwd() #criamos um vetor com o diretório de trabalho
#shell.exec(dir) #abre o diretório de trabalho no Windows
↪ Explorer
library(openxlsx)
ppbio <- read.xlsx(
↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06p-amb.xlsx"
↪ ,
```



```

                                rowNames = T, colNames = T,
                                sheet = "ano1")
str(ppbio)
#View(ppbio)
ppbio[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas de 1
↪ a 5.

```

```

## 'data.frame':    23 obs. of  30 variables:
## $ h.macroph : num  8.33 0 5.83 0 0 ...
## $ h.grass : num  20 23.3 0 20 0 ...
## $ h.subveg : num  10 3 16.7 0 0 ...
## $ h.overhveg : num  0 26.7 33.3 0 33.3 ...
## $ h.litter : num  0.667 2.333 23.667 0 1 ...
## $ h.filalgae : num  0 3.33 25 0 0 ...
## $ h.attalgae : num  12 0.667 3.333 1 0 ...
## $ h.roots : num  0 3.33 0 0 5 ...
## $ h.lrgdeb : num  1.67 1.67 0 0 3.33 ...
## $ h.smldeb : num  1.67 2 10 0 7 ...
## $ s.mud : num  65 16.667 81.667 40 0.667 ...
## $ s.sand : num  30 70 8.33 40 87.67 ...
## $ s.smlgrav : num  0 5 1.67 0 3.33 ...
## $ s.lrggrav : num  0 5 0 0 3.33 ...
## $ s.cobbles : num  1.67 3.33 0 20 5 ...
## $ s.rocks : num  0 0 0 0 0 ...
## $ s.bedrock : num  3.33 0 8.33 0 0 ...
## $ m.elev : num  226 169 270 226 169 270 226 169 270 226 ...
## $ m.river : num  163 83 110 163 83 ...
## $ m.stream : num  163.2 13.6 37.1 163.2 13.6 ...
## $ m.distsource: num  84.45 6.15 8.85 84.45 6.15 ...
## $ m.distmouth : num  217 186 255 217 186 ...
## $ m.maxslope : num  30 60 60 30 60 60 30 60 60 30 ...
## $ m.maxdepth : num  106 60 154 105 68 118 110 79 109 74 ...
## $ m.habdepth : num  81.3 22.7 54.7 67 32.7 ...
## $ m.width : num  19.6 17.2 102 16.1 18.5 ...
## $ a.veloc : num  0.167 0.159 0.1 0.125 0 ...
## $ a.temp : num  32.9 35.2 34 32 29 ...
## $ a.do : num  6.51 6.86 4.82 5.38 3.02 ...
## $ a.transp : num  46 26 61 44 33 ...
##      h.macroph h.grass h.subveg h.overhveg h.litter
## S-R-CT1  8.333333 20.00000 10.00000  0.00000 0.666667
## S-R-CP1  0.000000 23.33333  3.00000 26.66667 2.333333
## S-A-TA1  5.833333  0.00000 16.66667 33.33333 23.666660
## S-R-CT2  0.000000 20.00000  0.00000  0.00000 0.000000
## S-R-CP2  0.000000  0.00000  0.00000 33.33333 1.000000

```

Exibindo os dados importados (esses comando são “case-sensitive” `ignore.case(object)`).

```
#View(ppbio)
print(ppbio[1:8,1:8])
ppbio[1:10,1:10]
str(ppbio)
mode(ppbio)
class(ppbio)
```

19.4 Reset point

```
m_amb <- ppbio
#pat <- "~S"
#m_amb <- m_amb[!grepl(pat, rownames(m_amb)), ] #exclui quem
↪ começa com pat
```

Aqui cria-se um novo objeto do R (`m_trab`, ou a matriz de trabalho, para esse momento) que substitui a matriz de dados original, por uma nova matriz que pode ser a matriz relativizada, transformada, transposta, etc. Dessa forma, mantemos a matriz de dados original caso precisemos dela novamente (Veja a Tabela 7.1).

Revise Seção 7.2.2 e a Tabela de Abreviações ([@ref\(tab:200m_2\)](#)) na mesma Seção que resumem os tipos de matrizes e suas abreviações, para os nossos códigos.

19.5 Correlograma e remoção de variáveis redundantes ou desnecessárias

```
library(psych)
colnames(m_amb)
pairs.panels(m_amb[,1:10],
             method = "pearson", # correlation method
             scale = FALSE, lm = FALSE,
             hist.col = "#00AFBB", pch = 19,
             density = TRUE, # show density plots
             ellipses = TRUE, # show correlation ellipses)
```

```

alpha = 0.5)

cor <- cor(m_amb)
cor
library(corrplot)
corrplot(cor, method = "circle")
#win.print()
#corrplot(cor, method = "circle")
#dev.off()

```

```

## [1] "h.macroph"      "h.grass"        "h.subveg"       "h.overhveg"     "h.litter"
## [6] "h.filalgae"     "h.attalgae"     "h.roots"        "h.lrgdeb"       "h.smldeb"
## [11] "s.mud"          "s.sand"         "s.smlgrav"      "s.lrggrav"      "s.cobbles"
## [16] "s.rocks"        "s.bedrock"      "m.elev"         "m.river"        "m.stream"
## [21] "m.distsource"   "m.distmouth"    "m.maxslope"     "m.maxdepth"     "m.habdepth"
## [26] "m.width"        "a.veloc"        "a.temp"         "a.do"           "a.transp"
##
##      h.macroph      h.grass      h.subveg      h.overhveg      h.litter
## h.macroph      1.00000000 -0.246531504 -0.13690655 -0.0460990189 -0.062637491
## h.grass        -0.24653150  1.000000000  0.48407509 -0.1460764735 -0.001721976
## h.subveg       -0.13690655  0.484075094  1.00000000  0.0635287907  0.399197150
## h.overhveg     -0.04609902 -0.146076474  0.06352879  1.0000000000  0.603643875
## h.litter       -0.06263749 -0.001721976  0.39919715  0.6036438749  1.000000000
## h.filalgae     0.30739321 -0.225737505 -0.06840003  0.3151725645  0.391954687
## h.attalgae     -0.20061743 -0.203856535 -0.15804953 -0.0588612264 -0.074417928
## h.roots        -0.17114523 -0.042846121 -0.12422422  0.7224571129 -0.020670464
## h.lrgdeb       0.03975689  0.517038783 -0.13497524 -0.0002521598 -0.076622164
## h.smldeb       -0.11282416  0.430029457  0.32450367  0.3420275576  0.524639005
## s.mud          -0.02825772 -0.213876066  0.09356431 -0.3318047182  0.081241055
## s.sand         0.10165279  0.290788117 -0.02468805  0.2908755666 -0.108025446
## s.smlgrav      0.02303766 -0.230252599 -0.26591389  0.1532179364  0.008573628
## s.lrggrav      0.05597825 -0.088160779 -0.19524294  0.1761326511 -0.054082053
## s.cobbles      -0.24512665 -0.007205913 -0.15483540  0.0694742877 -0.093430622
## s.rocks        -0.23075335 -0.259155527 -0.21954489 -0.0873692368 -0.121239165
## s.bedrock      -0.03652910 -0.083573123  0.30828355  0.5073656218  0.900953133
## m.elev         -0.08310889  0.403591279  0.35058982 -0.4003114855 -0.131742426
## m.river        -0.23257092  0.335464812  0.24926832 -0.5955683647 -0.242615414
## m.stream       -0.06608660 -0.004596811 -0.07497728 -0.2227767752 -0.096058730
## m.distsource   -0.16898179  0.005784151 -0.10079544 -0.2397842969 -0.143925113
## m.distmouth    -0.09461959  0.058821726 -0.01701650 -0.2886438017  0.009362746
## m.maxslope     0.06917689 -0.432093408 -0.28679549  0.2396730909  0.112055941
## m.maxdepth     0.03186630  0.402241943  0.19851159 -0.0016801722  0.489997569
## m.habdepth     -0.18039247 -0.045055633 -0.13643528  0.0703614430  0.206858486
## m.width        0.10609087  0.339661628  0.37489017 -0.2460756693 -0.036647042
## a.veloc        -0.13503225  0.204580859  0.11506415  0.3775858154  0.314867909

```

```

## a.temp      0.18273224  0.093689794  0.10708693  0.3872777253  0.376177481
## a.do        0.26259801 -0.202794752 -0.60025144 -0.2351348072 -0.186841357
## a.transp    0.30879962 -0.007818165  0.06381010 -0.0405424177  0.149062804
##            h.filalgae  h.attalgae  h.roots  h.lrgdeb  h.smldeb
## h.macroph   0.307393212 -0.2006174303 -0.17114523  0.0397568923 -0.1128241586
## h.grass     -0.225737505 -0.2038565351 -0.04284612  0.5170387832  0.4300294573
## h.subveg    -0.068400029 -0.1580495292 -0.12422422 -0.1349752429  0.3245036701
## h.overhveg  0.315172564 -0.0588612264  0.72245711 -0.0002521598  0.3420275576
## h.litter    0.391954687 -0.0744179283 -0.02067046 -0.0766221642  0.5246390055
## h.filalgae  1.000000000  0.1650218328 -0.12170792  0.0330671467  0.0566631854
## h.attalgae  0.165021833  1.0000000000 -0.15141029 -0.1110887477 -0.0007226332
## h.roots     -0.121707915 -0.1514102880  1.00000000  0.0359061688  0.1278778876
## h.lrgdeb    0.033067147 -0.1110887477  0.03590617  1.0000000000  0.5126858957
## h.smldeb    0.056663185 -0.0007226332  0.12787789  0.5126858957  1.0000000000
## s.mud       -0.203493831  0.0966629147 -0.45742597 -0.2661041300 -0.1358265852
## s.sand      0.131463557 -0.2065073854  0.42226823  0.3631216979  0.2116433147
## s.smlgrav   0.056355761 -0.2466165417  0.37504581 -0.2178131916 -0.1938969370
## s.lrggrav   0.071026543 -0.2019284184  0.45157180 -0.1064395977 -0.1131217094
## s.cobbles   0.193135679  0.4075488652  0.08813464 -0.1218105205 -0.2307397229
## s.rocks     0.144067566  0.5595435077 -0.15324139 -0.1450923302 -0.0896567456
## s.bedrock   0.338537041 -0.0146391847 -0.09492929 -0.0956520825  0.3503440506
## m.elev      -0.203448440  0.0716487680 -0.36640440  0.2656332571  0.1727891903
## m.river     -0.405669260 -0.0195694902 -0.51853032  0.1309548871 -0.0189887633
## m.stream    -0.185417996 -0.0598126521 -0.21720079 -0.1720191090 -0.1810175388
## m.distsource -0.254533090 -0.0572352576 -0.18429493 -0.1776252995 -0.2083808690
## m.distmouth -0.217780469 -0.2330343386 -0.33511609  0.1038897654  0.0767920775
## m.maxslope  0.145284072 -0.1601113205  0.18673984 -0.1907894213 -0.1808970343
## m.maxdepth  0.114574709 -0.2474674119 -0.35179352  0.5122182964  0.6060301921
## m.habdepth  0.002882856  0.0164745166 -0.09468290  0.0036984721  0.0212264396
## m.width     -0.011447418  0.0797573366 -0.28844323  0.2562191774  0.1713597968
## a.veloc     -0.002302649 -0.0605797247  0.20772262 -0.1007706522 -0.0883913083
## a.temp      -0.047385170 -0.3528557182  0.21266182 -0.0633115802  0.0495255921
## a.do        0.075932799  0.2107159895 -0.19965987 -0.0527554510 -0.2305667359
## a.transp    0.486443594  0.1991293428 -0.26299621  0.2727840805  0.2437019444
##            s.mud      s.sand      s.smlgrav  s.lrggrav  s.cobbles
## h.macroph   -0.02825772  0.10165279  0.023037659  0.05597825 -0.245126650
## h.grass     -0.21387607  0.29078812 -0.230252599 -0.08816078 -0.007205913
## h.subveg    0.09356431 -0.02468805 -0.265913890 -0.19524294 -0.154835404
## h.overhveg  -0.33180472  0.29087557  0.153217936  0.17613265  0.069474288
## h.litter    0.08124106 -0.10802545  0.008573628 -0.05408205 -0.093430622
## h.filalgae  -0.20349383  0.13146356  0.056355761  0.07102654  0.193135679
## h.attalgae  0.09666291 -0.20650739 -0.246616542 -0.20192842  0.407548865
## h.roots     -0.45742597  0.42226823  0.375045814  0.45157180  0.088134635
## h.lrgdeb    -0.26610413  0.36312170 -0.217813192 -0.10643960 -0.121810520
## h.smldeb    -0.13582659  0.21164331 -0.193896937 -0.11312171 -0.230739723
## s.mud       1.00000000 -0.95732831 -0.196136235 -0.20727196 -0.436951580

```

19.5. CORRELOGRAMA E REMOÇÃO DE VARIÁVEIS REDUNDANTES OU DESNECESSÁRIAS 497

## s.sand	-0.95732831	1.00000000	0.077601964	0.06113988	0.208220232
## s.smlgrav	-0.19613624	0.07760196	1.000000000	0.91794933	-0.018580075
## s.lrggrav	-0.20727196	0.06113988	0.917949325	1.00000000	0.092736437
## s.cobbles	-0.43695158	0.20822023	-0.018580075	0.09273644	1.000000000
## s.rocks	-0.05450604	-0.08712170	-0.290187186	-0.20917141	0.471919983
## s.bedrock	0.20788751	-0.23158686	-0.068825165	-0.12957657	-0.117937719
## m.elev	0.46647761	-0.31506556	-0.363536747	-0.35844427	-0.418891510
## m.river	0.52267706	-0.35870643	-0.487625688	-0.54998626	-0.404162728
## m.stream	0.25913400	-0.29280195	-0.351718673	-0.23344861	0.162336709
## m.distsource	0.20798419	-0.24660914	-0.335764568	-0.23558448	0.197820570
## m.distmouth	-0.12783195	0.26298990	-0.055199753	-0.33221276	-0.343006017
## m.maxslope	-0.48822579	0.47051421	0.480231912	0.19989479	0.003285850
## m.maxdepth	-0.08984828	0.15690152	-0.233610098	-0.23813743	-0.181918712
## m.habdepth	-0.29918013	0.24152725	-0.124634583	-0.20123580	0.329637349
## m.width	0.49913277	-0.37568825	-0.310246711	-0.23740245	-0.381602616
## a.veloc	-0.07881376	0.02561095	-0.011480476	0.04477510	0.201826380
## a.temp	-0.20642510	0.16196759	0.223976700	0.27319038	0.054683155
## a.do	0.29936318	-0.31184728	0.228246923	0.14674375	-0.188261015
## a.transp	-0.07274786	0.08367750	-0.090575822	-0.07405382	0.010898759
##	s.rocks	s.bedrock	m.elev	m.river	m.stream
## h.macroph	-0.230753352	-0.03652910	-0.08310889	-0.23257092	-0.066086599
## h.grass	-0.259155527	-0.08357312	0.40359128	0.33546481	-0.004596811
## h.subveg	-0.219544891	0.30828355	0.35058982	0.24926832	-0.074977285
## h.overhveg	-0.087369237	0.50736562	-0.40031149	-0.59556836	-0.222776775
## h.litter	-0.121239165	0.90095313	-0.13174243	-0.24261541	-0.096058730
## h.filalgae	0.144067566	0.33853704	-0.20344844	-0.40566926	-0.185417996
## h.attalgae	0.559543508	-0.01463918	0.07164877	-0.01956949	-0.059812652
## h.roots	-0.153241391	-0.09492929	-0.36640440	-0.51853032	-0.217200787
## h.lrgdeb	-0.145092330	-0.09565208	0.26563326	0.13095489	-0.172019109
## h.smldeb	-0.089656746	0.35034405	0.17278919	-0.01898876	-0.181017539
## s.mud	-0.054506037	0.20788751	0.46647761	0.52267706	0.259134004
## s.sand	-0.087121705	-0.23158686	-0.31506556	-0.35870643	-0.292801947
## s.smlgrav	-0.290187186	-0.06882517	-0.36353675	-0.48762569	-0.351718673
## s.lrggrav	-0.209171407	-0.12957657	-0.35844427	-0.54998626	-0.233448612
## s.cobbles	0.471919983	-0.11793772	-0.41889151	-0.40416273	0.162336709
## s.rocks	1.000000000	-0.12799218	-0.21907348	-0.13545807	0.215737335
## s.bedrock	-0.127992185	1.000000000	-0.19742578	-0.20071090	0.131806173
## m.elev	-0.219073482	-0.19742578	1.000000000	0.85251041	-0.351025053
## m.river	-0.135458068	-0.20071090	0.85251041	1.000000000	0.017040248
## m.stream	0.215737335	0.13180617	-0.35102505	0.01704025	1.000000000
## m.distsource	0.248398309	0.08398842	-0.36628911	0.04500187	0.987553629
## m.distmouth	-0.128592531	-0.03694612	0.21088433	0.43005863	-0.285305822
## m.maxslope	-0.063334534	0.04208746	-0.45271956	-0.37494422	-0.445502469
## m.maxdepth	-0.078095404	0.47564528	0.08022982	0.12595144	0.094085376
## m.habdepth	0.133210844	0.41315901	-0.52848500	-0.21000817	0.395997655
## m.width	-0.267413674	-0.09980488	0.92959448	0.66160089	-0.341120113


```


## a.veloc      -0.203924152  0.50163597 -0.39264584 -0.27533927  0.410516289
## a.temp       -0.221454717  0.41538130 -0.60522317 -0.50743529  0.318565681
## a.do         0.004835464 -0.06655234 -0.04245875 -0.05281226  0.104875559
## a.transp     -0.016360295  0.14038232  0.16444871 -0.08762683 -0.339047044
##             m.distsource m.distmouth m.maxslope m.maxdepth m.habdepth
## h.macroph    -0.168981791 -0.094619591  0.069176887  0.031866297 -0.180392470
## h.grass       0.005784151  0.058821726 -0.432093408  0.402241943 -0.045055633
## h.subveg     -0.100795436 -0.017016500 -0.286795491  0.198511591 -0.136435275
## h.overhveg   -0.239784297 -0.288643802  0.239673091 -0.001680172  0.070361443
## h.litter      -0.143925113  0.009362746  0.112055941  0.489997569  0.206858486
## h.filalgae    -0.254533090 -0.217780469  0.145284072  0.114574709  0.002882856
## h.attalgae    -0.057235258 -0.233034339 -0.160111320 -0.247467412  0.016474517
## h.roots       -0.184294932 -0.335116093  0.186739840 -0.351793522 -0.094682904
## h.lrgdeb      -0.177625299  0.103889765 -0.190789421  0.512218296  0.003698472
## h.smldeb      -0.208380869  0.076792078 -0.180897034  0.606030192  0.021226440
## s.mud         0.207984189 -0.127831955 -0.488225793 -0.089848279 -0.299180125
## s.sand        -0.246609145  0.262989896  0.470514210  0.156901516  0.241527247
## s.smlgrav     -0.335764568 -0.055199753  0.480231912 -0.233610098 -0.124634583
## s.lrggrav     -0.235584477 -0.332212758  0.199894791 -0.238137430 -0.201235803
## s.cobbles     0.197820570 -0.343006017  0.003285850 -0.181918712  0.329637349
## s.rocks       0.248398309 -0.128592531 -0.063334534 -0.078095404  0.133210844
## s.bedrock     0.083988424 -0.036946118  0.042087459  0.475645280  0.413159010
## m.elev        -0.366289105  0.210884333 -0.452719558  0.080229817 -0.528485000
## m.river       0.045001873  0.430058635 -0.374944223  0.125951443 -0.210008174
## m.stream      0.987553629 -0.285305822 -0.445502469  0.094085376  0.395997655
## m.distsource  1.000000000 -0.208886217 -0.380287859  0.070018120  0.454126171
## m.distmouth   -0.208886217  1.000000000  0.575655522  0.409794260  0.329568908
## m.maxslope    -0.380287859  0.575655522  1.000000000 -0.033910389  0.326367540
## m.maxdepth    0.070018120  0.409794260 -0.033910389  1.000000000  0.425648040
## m.habdepth    0.454126171  0.329568908  0.326367540  0.425648040  1.000000000
## m.width       -0.403406954 -0.091476026 -0.569731109  0.010919605 -0.663930169
## a.veloc       0.409162331 -0.251728578 -0.087772483  0.109911454  0.516555276
## a.temp        0.303332037 -0.107191864  0.190578794  0.204458211  0.390454228
## a.do          0.054863239 -0.066103944 -0.039194058 -0.068299977 -0.098869325
## a.transp      -0.402578165  0.084213818  0.008475289  0.389325169  0.109987158
##             m.width      a.veloc      a.temp      a.do      a.transp
## h.macroph    0.106090873 -0.135032245  0.18273224  0.262598008  0.308799625
## h.grass      0.339661628  0.204580859  0.09368979 -0.202794752 -0.007818165
## h.subveg     0.374890169  0.115064150  0.10708693 -0.600251445  0.063810096
## h.overhveg   -0.246075669  0.377585815  0.38727773 -0.235134807 -0.040542418
## h.litter     -0.036647042  0.314867909  0.37617748 -0.186841357  0.149062804
## h.filalgae   -0.011447418 -0.002302649 -0.04738517  0.075932799  0.486443594
## h.attalgae   0.079757337 -0.060579725 -0.35285572  0.210715990  0.199129343
## h.roots      -0.288443233  0.207722616  0.21266182 -0.199659873 -0.262996213
## h.lrgdeb     0.256219177 -0.100770652 -0.06331158 -0.052755451  0.272784080
## h.smldeb     0.171359797 -0.088391308  0.04952559 -0.230566736  0.243701944

```

19.5. CORRELOGRAMA E REMOÇÃO DE VARIÁVEIS REDUNDANTES OU DESNECESSÁRIAS 499

```
## s.mud      0.499132769 -0.078813761 -0.20642510  0.299363179 -0.072747855
## s.sand     -0.375688250  0.025610951  0.16196759 -0.311847278  0.083677500
## s.smlgrav  -0.310246711 -0.011480476  0.22397670  0.228246923 -0.090575822
## s.lrggrav  -0.237402453  0.044775100  0.27319038  0.146743753 -0.074053824
## s.cobbles  -0.381602616  0.201826380  0.05468315 -0.188261015  0.010898759
## s.rocks    -0.267413674 -0.203924152 -0.22145472  0.004835464 -0.016360295
## s.bedrock  -0.099804876  0.501635966  0.41538130 -0.066552340  0.140382315
## m.elev     0.929594477 -0.392645839 -0.60522317 -0.042458750  0.164448713
## m.river    0.661600887 -0.275339274 -0.50743529 -0.052812259 -0.087626835
## m.stream   -0.341120113  0.410516289  0.31856568  0.104875559 -0.339047044
## m.distsource -0.403406954  0.409162331  0.30333204  0.054863239 -0.402578165
## m.distmouth -0.091476026 -0.251728578 -0.10719186 -0.066103944  0.084213818
## m.maxslope  -0.569731109 -0.087772483  0.19057879 -0.039194058  0.008475289
## m.maxdepth  0.010919605  0.109911454  0.20445821 -0.068299977  0.389325169
## m.habdepth  -0.663930169  0.516555276  0.39045423 -0.098869325  0.109987158
## m.width     1.000000000 -0.326799203 -0.51641177 -0.002086238  0.232399977
## a.veloc    -0.326799203  1.000000000  0.64196801  0.063666386 -0.111321669
## a.temp     -0.516411771  0.641968008  1.00000000 -0.072530252 -0.241797672
## a.do       -0.002086238  0.063666386 -0.07253025  1.000000000  0.109896052
## a.transp    0.232399977 -0.111321669 -0.24179767  0.109896052  1.000000000
```





19.6 Deletando variáveis colineares

Primeiro vamos listar as variáveis com correlação maior que 70% ou $r > 0.7$.

```
# Get upper triangle (to avoid duplicate pairs)
r <- 0.7
cor_pairs <- which(abs(cor) > r & abs(cor) < 1, arr.ind = TRUE)

# Extract unique variable pairs
results <- data.frame(
  var1 = rownames(cor)[cor_pairs[, 1]],
  var2 = colnames(cor)[cor_pairs[, 2]],
  correlation = cor[cor_pairs]
)

# Remove duplicates (e.g. A-B and B-A)
results <- results[results$var1 < results$var2, ]

# Sort by absolute correlation (descending)
results <- results[order(-abs(results$correlation)), ]
results
```



```
##           var1      var2 correlation
## 12 m.distsource m.stream  0.9875536
##  5           s.mud      s.sand -0.9573283
## 14           m.elev    m.width  0.9295945
##  6           s.lrggrav s.smlgrav 0.9179493
##  8           h.litter s.bedrock 0.9009531
## 11           m.elev    m.river  0.8525104
##  3           h.overhveg h.roots  0.7224571
```

Agora que temos as variáveis correlacionadas, prosseguimos para deleta-las.

```
colnames(m_amb)
del_cols <- c("m.distsource", "m.elev") #exemplo,
  ↪ "g.river_length", "g.altitude"
m_amb_part <- m_amb[, !(colnames(m_amb) %in% del_cols)]
```

```
## [1] "h.macroph"      "h.grass"         "h.subveg"        "h.overhveg"      "h.litter"
## [6] "h.filalgae"     "h.attalgae"      "h.roots"         "h.lrgdeb"        "h.smldeb"
## [11] "s.mud"          "s.sand"          "s.smlgrav"       "s.lrggrav"       "s.cobbles"
## [16] "s.rocks"        "s.bedrock"       "m.elev"          "m.river"         "m.stream"
## [21] "m.distsource"   "m.distmouth"     "m.maxslope"      "m.maxdepth"      "m.habdepth"
## [26] "m.width"        "a.veloc"         "a.temp"          "a.do"            "a.transp"
```

19.7 Somando variáveis redundantes

Algumas dessa variáveis são redundantes, vamos soma-las.

```
m_amb_part$s.gravel <- m_amb_part$s.smlgrav +
  ↪ m_amb_part$s.lrggrav + m_amb_part$s.cobbles
m_amb_part <- m_amb_part[, !(colnames(m_amb_part)
  %in% c("s.smlgrav", "s.lrggrav",
  ↪ "s.cobbles"))]
m_amb_part$s.rock <- m_amb_part$s.rocks + m_amb_part$s.bedrock
m_amb_part <- m_amb_part[, !(colnames(m_amb_part)
  %in% c("s.rocks", "s.bedrock"))]
m_amb_part$h.algae <- m_amb_part$h.filalgae +
  ↪ m_amb_part$h.attalgae
m_amb_part <- m_amb_part[, !(colnames(m_amb_part)
  %in% c("h.filalgae", "h.attalgae"))]
m_amb_part$h.debris <- m_amb_part$h.smldeb + m_amb_part$h.lrgdeb
m_amb_part <- m_amb_part[, !(colnames(m_amb_part)
```

```

                                %in% c("h.smldeb", "h.lrgdeb"))]

colnames(m_amb_part)
m_amb_part

```

```

## [1] "h.macroph" "h.grass" "h.subveg" "h.overhveg" "h.litter"
## [6] "h.roots" "s.mud" "s.sand" "m.river" "m.stream"
## [11] "m.distmouth" "m.maxslope" "m.maxdepth" "m.habdepth" "m.width"
## [16] "a.veloc" "a.temp" "a.do" "a.transp" "s.gravel"
## [21] "s.rock" "h.algae" "h.debris"
## h.macroph h.grass h.subveg h.overhveg h.litter h.roots
## S-R-CT1 8.333333 20.000000 10.000000 0.000000 0.6666667 0.000000
## S-R-CP1 0.000000 23.333334 3.000000 26.666666 2.3333333 3.333333
## S-A-TA1 5.833333 0.000000 16.666666 33.333332 23.6666660 0.000000
## S-R-CT2 0.000000 20.000000 0.000000 0.000000 0.000000 0.000000
## S-R-CP2 0.000000 0.000000 0.000000 33.333332 1.000000 5.000000
## S-A-TA2 54.833332 0.333333 0.000000 8.333333 1.000000 0.000000
## S-R-CT3 0.000000 0.111111 0.000000 0.000000 0.000000 0.000000
## S-R-CP3 0.000000 0.000000 0.000000 0.000000 1.500000 1.000000
## S-A-TA3 44.629631 8.111107 0.000000 0.000000 0.6666667 0.000000
## S-R-CT4 0.000000 4.166665 0.000000 0.000000 0.8333333 0.000000
## S-R-CP4 0.000000 0.000000 0.000000 8.333333 1.000000 0.000000
## S-A-TA4 37.309525 0.000000 0.000000 0.000000 0.5714286 0.000000
## B-A-MU1 0.000000 50.000000 0.000000 0.000000 1.000000 0.000000
## B-A-GU1 46.666668 0.000000 3.333333 3.333333 0.000000 0.000000
## B-R-PC2 0.000000 2.000000 0.000000 0.000000 0.400000 0.000000
## B-A-MU2 0.000000 54.000000 36.599998 0.000000 5.000000 0.000000
## B-A-GU2 2.600000 7.500000 26.000000 0.400000 0.000000 0.000000
## B-R-PC3 0.000000 0.000000 0.000000 0.000000 0.3333333 0.000000
## B-A-MU3 0.000000 28.333334 8.333333 0.000000 1.000000 0.000000
## B-A-GU3 0.000000 13.333333 0.000000 0.000000 0.000000 0.000000
## B-R-PC4 0.000000 0.000000 0.000000 0.000000 0.500000 0.000000
## B-A-MU4 0.000000 5.555553 0.000000 0.000000 0.4444444 0.000000
## B-A-GU4 2.083333 0.000000 0.000000 0.000000 0.000000 0.000000
## s.mud s.sand m.river m.stream m.distmouth m.maxslope
## S-R-CT1 65.000000 30.000000 163.2000 163.2000 217.1500 30
## S-R-CP1 16.666666 70.000000 83.0500 13.5500 185.5500 60
## S-A-TA1 81.666664 8.333333 110.2000 37.1000 254.5500 60
## S-R-CT2 40.000000 40.000000 163.2000 163.2000 217.1500 30
## S-R-CP2 0.6666667 87.666664 83.0500 13.5500 185.5500 60
## S-A-TA2 5.000000 95.000000 110.2000 37.1000 254.5500 60
## S-R-CT3 65.555553 23.111111 163.2000 163.2000 217.1500 30
## S-R-CP3 48.750000 22.500000 83.0500 13.5500 185.5500 60
## S-A-TA3 46.666667 40.000000 110.2000 37.1000 254.5500 60

```

##	S-R-CT4	95.0000000	1.833333	163.2000	163.20000	217.1500	30
##	S-R-CP4	5.0000000	60.000000	83.0500	13.55000	185.5500	60
##	S-A-TA4	59.1428566	38.714287	110.2000	37.10000	254.5500	60
##	B-A-MU1	33.3333321	65.000000	214.0200	19.83333	290.8767	30
##	B-A-GU1	96.6666641	3.333333	212.6667	32.33333	203.8333	30
##	B-R-PC2	39.0000000	56.000000	196.8333	13.75000	401.6667	90
##	B-A-MU2	20.6000004	77.000000	214.0200	19.83333	290.8767	30
##	B-A-GU2	98.0000000	2.000000	212.6667	32.33333	203.8333	30
##	B-R-PC3	33.6666679	63.000000	196.8333	13.75000	401.6667	90
##	B-A-MU3	65.0000000	35.000000	214.0200	19.83333	290.8767	30
##	B-A-GU3	87.7777786	6.666667	212.6667	32.33333	203.8333	30
##	B-R-PC4	48.8750000	47.875000	196.8333	13.75000	401.6667	90
##	B-A-MU4	91.7777786	3.222222	214.0200	19.83333	290.8767	30
##	B-A-GU4	95.1666641	3.416667	212.6667	32.33333	203.8333	30
##		m.maxdepth	m.habdepth	m.width	a.veloc	a.temp	a.do a.transp
##	S-R-CT1	106	81.333333	19.64	0.1666667	32.90000	6.510000 46.00000
##	S-R-CP1	60	22.666667	17.24	0.1591512	35.20000	6.863333 26.00000
##	S-A-TA1	154	54.666667	102.00	0.1000000	34.00000	4.820000 61.00000
##	S-R-CT2	105	67.000000	16.10	0.1250000	32.00000	5.375000 44.00000
##	S-R-CP2	68	32.666667	18.47	0.0000000	29.00000	3.015000 33.00000
##	S-A-TA2	118	37.666667	100.00	0.0000000	29.00000	5.000000 90.00000
##	S-R-CT3	110	32.333333	6.20	0.0000000	28.26667	6.000000 17.33333
##	S-R-CP3	79	32.666667	15.10	0.0000000	29.66667	5.000000 50.33333
##	S-A-TA3	109	22.333333	88.00	0.0000000	34.00000	9.000000 51.66667
##	S-R-CT4	74	32.333333	5.40	0.0000000	32.60000	6.000000 16.00000
##	S-R-CP4	64	45.333333	10.70	0.0000000	27.60000	4.900000 60.00000
##	S-A-TA4	87	30.333333	72.20	0.0000000	29.53333	9.433333 67.00000
##	B-A-MU1	152	32.666667	270.00	0.0000000	29.83333	5.666667 48.00000
##	B-A-GU1	60	8.166667	330.00	0.0000000	29.23333	5.136667 25.66667
##	B-R-PC2	110	49.333333	29.60	0.0000000	29.00000	5.635000 50.00000
##	B-A-MU2	115	22.000000	247.63	0.0000000	29.00000	1.815000 43.00000
##	B-A-GU2	69	7.000000	321.00	0.0000000	29.00000	1.850000 55.00000
##	B-R-PC3	80	50.000000	27.30	0.0000000	29.00000	5.000000 32.33333
##	B-A-MU3	117	25.666667	234.53	0.0000000	26.00000	5.700000 63.00000
##	B-A-GU3	68	6.833333	314.20	0.0000000	24.00000	8.800000 51.66667
##	B-R-PC4	95	52.833333	20.00	0.0000000	28.85000	5.100000 30.00000
##	B-A-MU4	112	41.333333	239.00	0.0000000	25.95000	7.300000 89.00000
##	B-A-GU4	63	4.666667	289.50	0.0000000	24.70000	8.750000 36.00000
##		s.gravel	s.rock	h.algae	h.debris		
##	S-R-CT1	1.6666666	3.333333	12.000000	3.333333		
##	S-R-CP1	13.333333	0.000000	3.999999	3.666666		
##	S-A-TA1	1.6666666	8.333333	28.333333	10.000000		
##	S-R-CT2	20.000000	0.000000	1.000000	0.000000		
##	S-R-CP2	11.666666	0.000000	0.000000	10.333333		
##	S-A-TA2	0.000000	0.000000	33.333321	13.666665		
##	S-R-CT3	3.000000	8.333333	0.000000	2.222223		

Salvando a matriz final particionada de dados ambientais.

19.8 Tabela de dados ambientais

```
library(openxlsx)
t_grps <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06-grupos.xlsx"
  ↪ ,
  rowNames = T, colNames = T,
  sheet = "ambientalp")
str(t_grps)
```



```

unite("Location", Area, Habitat, Ponto, sep = "_") %>%
  dplyr::select(Variable, Location, stat_string) %>% #
  ↪ find("select"), dplyr::select evita conflito entre
  ↪ package:MASS package:dplyr
  pivot_wider(names_from = Location, values_from = stat_string)

m_wide
m_wide <- as.data.frame(m_wide)
m_wide

#Exportando dados para Excel----
library(openxlsx)
write.xlsx(m_wide, file = "tabela de habitat.xlsx", rowNames =
  ↪ FALSE)
wb <- loadWorkbook("tabela de habitat.xlsx")
writeData(wb, sheet = "Sheet 1", x = m_wide)
saveWorkbook(wb, "tabela de habitat.xlsx", overwrite = TRUE)

#Escolher sumário de uma variável----
m
var <- "h.roots"
m[m$Variable == var, "mean"] #cada valor de var
summary(m[m$Variable == var, "mean"]) #sumário dos valores de var

#Escolher sumário de um grupo de variáveis do df m----
vars <- unique(grep("^h\\.", m$Variable, value = TRUE))
summaries <- list() #cria uma lista vazia para guardar os
  ↪ sumários
# Loop para cada variável do grupo e guarda em summaries
for (var in vars) {
  summaries[[var]] <- summary(m[m$Variable == var, "mean"])
}
# var is a temporary variable used in the for loop to iterate
  ↪ through
# each variable name that starts with "h."

summaries
summary_table <- do.call(rbind, lapply(summaries,
  ↪ as.data.frame.list))
round(summary_table, 2)
#sink(file = "summary_h.txt", split = TRUE)
round(summary_table[order(summary_table$Mean, decreasing =
  ↪ FALSE), ], 2)
#sink()

```

```
#Tabela limpa
summary_table <- cbind(Variable = rownames(summary_table),
  ↪ summary_table)
rownames(summary_table) <- NULL
colnames(summary_table) <- c("Variable", "Min", "Q1", "Median",
  ↪ "Mean", "Q3", "Max")
summary_table
```

Apêndices

Sites consultados

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executá-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

Referências

Part V

**V. ANÁLISES
MULTIVARIADAS**

Chapter 20

R Modulo 5 - Relativizações e transformações

RESUMO

Transformações e relativizações de dados são técnicas essenciais na análise de dados em Ecologia Numérica, permitindo comparar diferentes variáveis que estão em escalas diferentes ou que possuem unidades distintas.

Apresentação

O R é uma ferramenta poderosa para realização dessas operações, com diversos pacotes disponíveis para essa finalidade. Neste tutorial, iremos explorar algumas das principais funções do pacote `vegan`, que permite realizar transformações e relativizações de dados de forma simples e eficiente. Além disso, também utilizaremos outras bibliotecas importantes para reorganização e visualização de dados. O tutorial irá abordar desde as operações básicas, como filtragem e seleção de dados, até as transformações mais complexas, como a normalização de dados e a relativização por medidas de biomassa ou área. Com exemplos práticos e ilustrações gráficas, o objetivo é permitir que os usuários do R possam aplicar essas técnicas em suas próprias análises e estudos de Ecologia Numérica. Ao final do tutorial, espera-se que o usuário esteja apto a realizar transformações e relativizações de dados em suas próprias análises, aumentando a qualidade e a precisão dos resultados obtidos.

20.1 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

Instalando os pacotes necessários para esse módulo

```
install.packages("openxlsx") #importa arquivos do excel
install.packages("moments") #calcula assimetria e curtose dos
↪ dados
install.packages("vegan") #estatísticas para ecologia de
↪ comunidades
```

Agora vamos **definir o diretório de trabalho**. Esse código é usado para obter e definir o diretório de trabalho atual no R. O comando `getwd()` retorna o caminho do diretório onde o R está lendo e salvando arquivos. O comando `setwd()` muda esse diretório de trabalho para o caminho especificado entre aspas. No seu caso, você deve ajustar o caminho para o seu próprio diretório de trabalho. **Lembre de usar a barra “/” entre os diretórios. E não a contra-barra “\”.**

Definindo o diretório de trabalho e installando os pacotes necessários:

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

20.1.1 Importando a planilha

Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações.

- Ajuste a primeira linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.
- Ajuste o parâmetro `sheet = "Sheet1"` para refletir a aba correta do arquivo .xlsx a ser importado.

```
library(openxlsx)
#dir <- getwd() #criamos um vetor com o diretório de trabalho
```

```

#shell.exec(dir) #abre o diretorio de trabalho no Windows
↪ Explorer
m_bruta <- read.xlsx(
↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.xlsx"
↪ ,
                                rowNames = T, colNames = T,
                                sheet = "Sheet1")
str(m_bruta)
#View(m_bruta)
m_bruta[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas de
↪ 1 a 5.

```

```

## 'data.frame': 26 obs. of 35 variables:
## $ ap-davis : num 0 0 0 0 0 0 0 0 0 0 ...
## $ as-bimac : num 1 99 194 19 23 142 5 46 206 16 ...
## $ as-fasci : num 0 0 55 0 1 3 1 0 64 0 ...
## $ ch-bimac : num 0 0 0 0 13 3 0 178 0 0 ...
## $ ci-ocela : num 0 0 0 0 0 0 40 0 0 13 ...
## $ ci-orien : num 0 0 5 0 0 69 9 0 25 24 ...
## $ co-macro : num 0 0 0 0 0 0 0 0 0 0 ...
## $ co-heter : num 0 0 1 0 0 0 0 0 0 0 ...
## $ cr-menez : num 0 0 14 0 0 4 0 0 8 0 ...
## $ cu-lepid : num 0 0 0 0 0 0 0 0 0 0 ...
## $ cy-gilbe : num 0 0 0 0 0 0 0 0 0 0 ...
## $ ge-brasi : num 0 0 3 0 0 0 0 0 1 0 ...
## $ he-margi : num 0 0 0 0 0 1 0 0 0 0 ...
## $ ho-malab : num 0 0 1 5 0 17 10 2 31 4 ...
## $ hy-pusar : num 0 0 9 2 0 43 2 0 11 0 ...
## $ le-melan : num 0 0 0 0 0 0 0 0 0 0 ...
## $ le-piau : num 0 0 3 0 0 1 3 0 2 1 ...
## $ le-taeni : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-costa : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-lepid : num 0 1 39 0 0 1 0 0 0 0 ...
## $ or-nilot : num 0 2 36 0 0 77 0 0 138 0 ...
## $ pa-manag : num 0 0 0 0 0 0 0 0 0 0 ...
## $ pimel-sp : num 0 0 6 0 0 0 0 0 0 0 ...
## $ po-retic : num 0 0 0 0 0 20 0 0 5 0 ...
## $ po-vivip : num 0 0 47 15 0 221 32 0 326 10 ...
## $ pr-brevi : num 9 0 5 0 1 15 5 2 164 0 ...
## $ ps-rhomb : num 0 0 0 0 0 0 0 0 1 0 ...
## $ ps-genise: num 0 0 0 0 0 0 0 0 1 0 ...
## $ se-heter : num 0 0 40 14 4 60 0 0 38 0 ...
## $ se-piaba : num 0 0 68 0 0 0 0 0 0 0 ...
## $ se-spilo : num 0 0 0 0 0 0 0 0 1 0 ...

```

```
## $ st-noton : num  0 0 1 0 0 25 0 0 115 0 ...
## $ sy-marmo : num  0 0 0 0 0 0 1 0 0 0 ...
## $ te-chalc : num  0 0 0 0 0 0 0 0 0 0 ...
## $ tr-signa : num  0 0 18 0 0 15 0 0 7 0 ...
##          ap-davis as-bimac as-fasci ch-bimac ci-ocela
## S-A-ZA1          0          1          0          0          0
## S-R-CC1          0          99          0          0          0
## S-R-CT1          0         194          55          0          0
## S-R-CP1          0          19          0          0          0
## S-A-TA1          0          23          1          13          0
```

Exibindo os dados importados (esses comando são “case-sensitive” `ignore.case(object)`).

```
#View(m_bruta)
print(m_bruta[1:8,1:8])
m_bruta[1:10,1:10]
str(m_bruta)
mode(m_bruta)
class(m_bruta)
```

Podemos exibir a planilha depois de ter sido importada para o ambiente R/RStudio usando as funções `View()`, `print()` ou `head()`. Note que essas funções são case-sensitive. A função `ignore.case()` é uma função do pacote `stringr` que modifica um padrão para que ele não considere o caso das letras nas correspondências. Por exemplo, se você quiser encontrar todas as ocorrências da letra “a” em um vetor de caracteres, independente de ser “A” ou “a”, você pode usar essa função.

```
#View(m_bruta)
print(m_bruta)
head(m_bruta)
```

A função `head()` no RStudio é uma forma de ver as primeiras (`n=6`) linhas de um objeto, como um vetor, uma matriz, um data frame ou uma lista. Ela é útil para ter uma ideia do conteúdo e da estrutura do objeto.

Também podemos explorar as características da planilha usando as funções `str()`, `mode()`, `class()` e `length()`. O número de observações ou tamanho do vetor depende do tipo de dados, se eles são uma matrix ou um data.frame.

Abreviações

No interesse de sistematizar o código R das várias matrizes que são comumente usadas em uma AMD, a tabela 20.1, a seguir, resume seus tipos e abreviações.

```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_ordin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

20.2 Tamanho da matriz

Podemos agora calcular o número e a proporção de zeros na matriz usando as funções `sum()` e `length()` (Você pode pesquisar o que faz a função `length()` usando o comando `?length`).

```
range(m_bruta) #menor e maior valores
length(m_bruta) #no. de colunas
ncol(m_bruta) #no. de N colunas
nrow(m_bruta) #no. de M linhas
sum(lengths(m_bruta)) #soma os nos. de colunas
length(as.matrix(m_bruta)) #tamanho da matriz m x n
sum(m_bruta == 0) # número de observações igual a zero
sum(m_bruta > 0) # número de observações maiores que zero
zeros <- (sum(m_bruta == 0)/length(as.matrix(m_bruta)))*100 #
  ↪ proporção de zeros na matriz
zeros
```

```
## [1] 0 511
## [1] 35
## [1] 35
## [1] 26
## [1] 910
## [1] 910
## [1] 716
## [1] 194
## [1] 78.68132
```

Tabela que resume as informações geradas (20.2).

```
tamanho <- data.frame(
  Comando = c("range", "length", "m cols", "n linhas", "Tamanho",
    ↪ "Tamanho",
    "Zeros", "Nao zeros", "% Zeros"),
  Resultado = c(paste(range(m_bruta), collapse = " - "),
    ↪ length(m_bruta), ncol(m_bruta),
```

Table 20.1: Nomenclatura das matrizes em AMD em relação aos atributos das colunas

Nome	Atributos (colunas)	Abreviação no R
Matriz comunitaria	Os atributos são táxons ou OTU's (Unidades Taxonômicas Operacionais) (ex. espécies, gêneros, morfotipos)	m_com
Matriz ambiental	Os atributos são dados ambientais e variáveis físicas e químicas (ex. pH, condutividade, temperatura)	m_amb
Matriz de habitat	Os atributos são elementos da estrutura do habitat (ex. macrófitas, algas, pedras, lama, etc)	m_hab
Matriz bruta	Os atributos ainda não receberam nenhum tipo de tratamento estatístico (valores brutos, como coletados)	m_bruta
Matriz transposta	Os atributos foram transpostos para as linhas	m_t
Matriz relativizada	Os atributos foram relativizados por um critério de tamanho ou de variação (ex. dividir os valores de cada coluna pela soma)	m_rel, m_relcol, m_rellin
Matriz transformada	Foi aplicado um operador matemático a todos os atributos (ex. raiz quadrada, log)	m_trns, m_log10, m_asrq
Matriz de distâncias	Matriz de m x m similaridades ou de distâncias (ex. Euclidiana, Manhattan, Bray-Curtis, etc)	m_dists, m_euclid, m_bray
Matriz de trabalho	Qualquer matriz que seja o foco da análise atual (ex. comunitária, relativizada, etc)	m_trab
Matriz particionada	Foram removidas linhas ou colunas (ex. linhas que são outliers e espécies zeradas)	m_part
Base de dados	Arquivo do Excel planilhado a partir de dados de campo ou de laboratório. Será manejada e particionada no R, para criar a Matriz bruta	ppbio06.xlsx, zoore- bio.xlsx, ben- tos06.xlsx

Table 20.2: Resumo das informações geradas.

Comando	Resultado
range	0 - 511
length	35
m cols	35
n linhas	26
Tamanho	910
Tamanho	910
Zeros	716
Nao zeros	194
% Zeros	78.7

```

nrow(m_bruta), sum(lengths(m_bruta)),
↪ length(as.matrix(m_bruta)), sum(m_bruta ==
↪ 0),
sum(m_bruta > 0), round(zeros, 1)))
tamanho

```

```

##      Comando Resultado
## 1      range    0 - 511
## 2     length         35
## 3     m cols         35
## 4   n linhas         26
## 5   Tamanho         910
## 6   Tamanho         910
## 7     Zeros         716
## 8 Nao zeros         194
## 9    % Zeros        78.7

```

Ou seja, temos uma matriz de tamanho $m \times n$ igual a 26 objetos por 35 atributos, onde 78.68% dos valores da matriz são iguais a zero!

20.3 REINÍCIO 1

```
m_trab <- m_bruta
```

Aqui cria-se um novo objeto do R (`m_trab`, ou a matriz de trabalho, para esse momento) que substitui a matriz de dados original, por uma nova matriz que

pode ser a matriz relativizada, transformada, transposta, etc. Dessa forma, mantemos a matriz de dados original caso precisemos dela novamente (Veja a Tabela Tabela @ref(tab:5tblm_2)).

20.4 Cálculo da matriz de distâncias

Agora vamos calcular a matriz de distâncias euclidiana (BORCARD; GILLET; LEGENDRE, 2018; LEGENDRE; LEGENDRE, 1998) entre as UA's usando a função `dist()` (pesquise o que faz essa função usando o comando `?dist`).

```
m_dists <- dist(m_trab, method = "euclidian", diag = TRUE, upper
  ↪ = FALSE)
```

Pronto, calculamos a matriz de distâncias (euclidiana). Agora podemos visualizar a matriz.

```
#m_dists
str(m_dists)
mode(m_dists)
class(m_dists)
length(as.matrix(m_dists))
as.matrix(m_dists)[1:10, 1:10]
```

```
## 'dist' num [1:325] 98.4 228.5 29.2 27.1 294.1 ...
## - attr(*, "Size")= int 26
## - attr(*, "Labels")= chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## - attr(*, "Diag")= logi TRUE
## - attr(*, "Upper")= logi FALSE
## - attr(*, "method")= chr "euclidean"
## - attr(*, "call")= language dist(x = m_trab, method = "euclidian", diag = TRUE, up
## [1] "numeric"
## [1] "dist"
## [1] 676
##           S-A-ZA1   S-R-CC1   S-R-CT1   S-R-CP1   S-A-TA1   S-R-CT2   S-R-CP2
## S-A-ZA1    0.00000   98.43780  228.5235  29.24038  27.09243  294.0629  53.40412
## S-R-CC1    98.43780    0.00000  154.2433  82.79493  77.25283  261.3905  108.10180
## S-R-CT1   228.52352  154.24331    0.0000  208.52338  209.69263  224.9133  224.09150
## S-R-CP1    29.24038   82.79493  208.5234    0.00000  23.25941  271.4922  49.22398
## S-A-TA1    27.09243   77.25283  209.6926  23.25941    0.00000  283.7869  57.82733
## S-R-CT2   294.06292  261.39051  224.9133  271.49217  283.78689    0.0000  268.95167
## S-R-CP2    53.40412  108.10180  224.0915  49.22398   57.82733  268.9517   0.00000
```

```
## S-A-TA2 183.74439 185.75791 261.8301 181.24845 166.66133 326.3327 190.15257
## S-R-CT3 460.42155 428.64437 366.6429 443.90877 453.59674 238.3799 438.54532
## S-R-CP3 34.17601 88.06816 215.2557 31.32092 33.13608 275.0436 40.37326
##          S-A-TA2  S-R-CT3  S-R-CP3
## S-A-ZA1 183.7444 460.4215 34.17601
## S-R-CC1 185.7579 428.6444 88.06816
## S-R-CT1 261.8301 366.6429 215.25566
## S-R-CP1 181.2484 443.9088 31.32092
## S-A-TA1 166.6613 453.5967 33.13608
## S-R-CT2 326.3327 238.3799 275.04363
## S-R-CP2 190.1526 438.5453 40.37326
## S-A-TA2 0.0000 478.9008 182.86060
## S-R-CT3 478.9008 0.0000 449.24826
## S-R-CP3 182.8606 449.2483 0.00000
```

Uma matriz do tipo `dist` no R é um objeto que armazena as distâncias entre as linhas de uma matriz ou um data frame. Ela é criada pela função `dist()`, que calcula as distâncias usando diferentes medidas, como “euclidean”, “manhattan”, “canberra”, “binary” ou “minkowski” (HORTON; KLEINMAN, 2015).

```
range(m_trab)
range(m_dists)
min(m_dists)
max(m_dists)
mean(m_dists) #CENTROIDE!! ou Grand mean
sd(m_dists)   #standard deviation
centroide <- mean(m_dists)
centroide
```

```
## [1] 0 511
## [1] 16.27882 707.32666
## [1] 16.27882
## [1] 707.3267
## [1] 285.9043
## [1] 172.9708
## [1] 285.9043
```

A função `mean()` calcula a média de todos os valores da matriz de distâncias, ou seja, a média multivariada, que é o centróide. Nesse caso o **centroide assume o valor de 285.9**. Usamos agora a fórmula $n*(n-1)/2$, onde n é o no. de objetos sendo comparados, para calcular quantas distâncias temos na nossa matriz.

```
length(m_dists)
n <- nrow(as.matrix(m_dists))
n
n*(n-1)/2
summary(m_dists)
```

```
## [1] 325
## [1] 26
## [1] 325
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  16.28  142.70  242.82  285.90  423.64  707.33
```

Temos então que n é 26 objetos (ou linhas), e portanto, a matriz de distâncias tem 325 valores. Fazemos agora um breve sumário do que foi calculado até agora com base na matriz de distâncias.

```
Sumario1 <- cbind(min(m_dists),
                  max(m_dists),
                  sd(m_dists),
                  mean(m_dists),
                  length(m_dists))
colnames(Sumario1) <- c("Minimo", "Maximo", "Desv.Padr", "Media",
  ↪  "m(m-1)/2")
rownames(Sumario1) <- ("Valores")
Sumario1
```

```
##           Minimo   Maximo Desv.Padr   Media m(m-1)/2
## Valores 16.27882 707.3267  172.9708 285.9043      325
```

A matriz `m_dists` está como uma classe `dist`, mas podemos transformá-la em uma classe `matrix` usando a função `as.matrix()`.

```
dist <- (as.matrix(m_dists))
#View(dist)
str(dist)
mode(dist)
class(dist)
#head(dist)
dist[1:5, 1:5] #mostra as 5 primeiras linhas e colunas da matriz
```

```
## num [1:26, 1:26] 0 98.4 228.5 29.2 27.1 ...
## - attr(*, "dimnames")=List of 2
## ..$ : chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## ..$ : chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## [1] "numeric"
## [1] "matrix" "array"
##           S-A-ZA1  S-R-CC1  S-R-CT1  S-R-CP1  S-A-TA1
## S-A-ZA1    0.00000  98.43780 228.5235  29.24038  27.09243
## S-R-CC1   98.43780   0.00000 154.2433  82.79493  77.25283
## S-R-CT1  228.52352 154.24331   0.0000 208.52338 209.69263
## S-R-CP1   29.24038  82.79493 208.5234   0.00000  23.25941
## S-A-TA1   27.09243  77.25283 209.6926  23.25941   0.00000
```

Visualizando a matriz de distâncias, observamos que ela é uma matriz quadrada que contém as distâncias entre cada par de elementos do conjunto de dados. A matriz de distâncias terá dimensão $n \times n$, e cada elemento da matriz será a distância entre cada par de observações ou objetos. A matriz de distâncias é simétrica, pois a distância entre i e j é igual à distância entre j e i . A matriz de distâncias também tem diagonal zero, pois a distância entre uma observação e ela mesma é zero.

20.5 Distribuição de frequência da matriz de distâncias

Por fim, vamos produzir uma distribuição de frequência da matriz de distâncias, mas antes vamos explorar alguns parâmetros básicos da matriz de distâncias, como o intervalo, a média e o desvio padrão. Para isso, usamos as funções `range()`, `mean()` e `sd()` do R.

20.5.1 Calculando alguns parâmetros básicos

```
range(m_dists) # intervalo dos valores da matriz
mean(m_dists)  # média dos valores da matriz
sd(m_dists)    # desvio padrão dos valores da matriz
```

```
## [1] 16.27882 707.32666
## [1] 285.9043
## [1] 172.9708
```

Esses comandos mostram que o menor, maior valores na matriz de distância foram 16.28, 707.33, enquanto que a média foi de 285.9 com um desvio padrão de 172.97.



IMPORTANTE

Lembre que no R e no Excel, a vírgula é usada como separador de decimal e o ponto é apenas indicador de milhar. Por exemplo, 2.500,50 lê-se dois mil e quinhentos e 50 décimos.

Também podemos calcular a assimetria e a curtose da matriz de distâncias, que são medidas que indicam o grau de desvio da normalidade da distribuição. Para isso, precisamos carregar o pacote `moments`, que contém as funções `skewness()` (assimetria) e `kurtosis()` (curtose).

20.5.2 Calculando a assimetria e a curtose

```
library(moments)
sk <- skewness(as.matrix(m_dists)) #calcula a assimetria da
  ↪ matriz
ku <- kurtosis(as.matrix(m_dists)) #calcula a curtose da matriz
sku <- cbind(sk,ku) # junta os dois valores em um vetor
colnames(sku) <- c("assimetria", "curtose") # nomeia as colunas
  ↪ do vetor
sku[1:10, ] # mostra as primeiras 10 linhas desse vetor
summary(sku) # mostra um resumo estatístico do vetor
```

```
##          assimetria    curtose
## S-A-ZA1  1.03617037  3.101029
## S-R-CC1  1.21511849  3.852134
## S-R-CT1  0.91278496  6.263889
## S-R-CP1  1.06839482  3.177206
## S-A-TA1  1.07960546  3.220821
## S-R-CT2  0.05290597  6.265832
## S-R-CP2  1.08571040  3.241712
## S-A-TA2  1.25111833  4.838956
## S-R-CT3 -2.35918827 10.736848
## S-R-CP3  1.06511174  3.178170
##      assimetria      curtose
## Min.      :-3.9660   Min.    : 2.946
## 1st Qu.: 0.1891    1st Qu.: 3.226
```

```
## Median : 1.0531   Median : 3.793
## Mean   : 0.3625   Mean   : 5.248
## 3rd Qu.: 1.1593   3rd Qu.: 5.659
## Max.   : 1.2826   Max.   :18.799
```

20.6 Distribuição de frequências da matriz de distâncias

Agora que temos uma ideia dos parâmetros básicos da matriz de distâncias, vamos entender sua distribuição de frequência usando um histograma e um boxplot. O histograma mostra a frequência relativa de cada intervalo de valores da matriz, enquanto o boxplot mostra a mediana, os quartis e os valores extremos da matriz.

Para fazer os gráficos, usamos as funções `hist()` e `boxplot.default()` do R. Também usamos a função `curve()` para sobrepor uma curva de normalidade ao histograma, e a função `par` para ajustar os parâmetros gráficos.

Nas linhas `xlim = ()`, `# limites dos eixos` do código abaixo, os limites dos eixos do gráfico a ser criado foram definidos entre 0 e 707.3266572. No seu caso, você deve ajustar os valores de `xlim` para que eles sejam os limites dos valores da sua matriz, definidos pela linha `range(dist)` (*primeira linha do código abaixo*).

Em resumo, o código abaixo plota um histograma e um boxplot da distribuição de dados armazenada na matriz de distâncias. Também é adicionada uma curva normal teórica ao histograma utilizando a média e o desvio padrão dos dados (Figura 20.1. As funções `floor(min(m_dists))` e `ceiling(max(m_dists))` definem os limites dos gráficos pelo valores mínimo e máximo do objeto.

```
range(m_dists)
par(mfrow=c(2,1)) # esse comando faz os gráficos aparecerem um
  ↳ acima do outro
hist(m_dists,
     breaks = 20, # determina o número de colunas do histograma
     xlim = range(floor(min(m_dists)), ceiling(max(m_dists))), #
     ↳ limites dos eixos
     xlab = "Distr. de Frequências",
     freq = FALSE, # mostra as frequências relativas em vez das
     ↳ absolutas
     main = "Histograma e boxplot da matriz de distâncias")
curve(dnorm(x, mean=mean(m_dists), sd=sd(m_dists)), add=TRUE) #
  ↳ sobrepõe a curva de normalidade
boxplot.default(m_dists, horizontal = TRUE, frame = FALSE,
               xlab="Distr. de Frequências",
               ylim=c(floor(min(m_dists)),
                     ↳ ceiling(max(m_dists)))) # limites dos eixos
```




Figure 20.1: Distribuições de frequências da matriz de distâncias

```
## [1] 16.27882 707.32666
```

IMPORTANTE [Atenção:] Se você recebeu a mensagem de erro “Error in plot.new() : figure margins too large”, aumente o tamanho da janela do gráfico e execute o bloco de comandos novamente.

O comando abaixo apaga os gráficos.

```
dev.off()
```


20.7 Relativizando e transformando a base de dados

Na sequência de códigos a seguir o R realiza relativizações e transformações em dados biológicos (SOKAL; ROHLF, 1995). Vamos ver passo a passo o que cada seção do código faz. Os códigos para as demais principais relativizações estão nos Apêndices

```
library(vegan)
```

Essa linha carrega o pacote **vegan** no ambiente R, permitindo o uso de suas funções. O pacote **vegan** é um pacote do R para análise de ecologia numérica e comunidades biológicas. Ele fornece uma ampla variedade de funções para análise de dados ecológicos, como análise de diversidade, ordenação de espécies, análise de similaridade, entre outras.

A função `decostand()` é usada para relativizar os dados armazenados na matriz de trabalho (`m_trab`). O parâmetro `method` especifica o método de relativização, neste caso *“total”* (relativização pelo total de cada coluna). Outros métodos disponíveis são *max*, *normalize*, *range* e *rankm* (@ref(tab:(5tbl-rel))). O parâmetro `MARGIN` especifica em qual dimensão os cálculos devem ser feitos (*1 para linhas*, *2 para colunas*). Neste caso, `MARGIN=2` (colunas). A variável `m_relcol` armazena o resultado da relativização. Sokal e Rohlf (SOKAL; ROHLF, 2009) tratam dos diversos tipos de relativizações e transformações em dados ecológicos.

20.7.1 Relativização pelo total

```
m_relcol <- decostand(m_trab,
                      method="total",
                      MARGIN = 2)

#View(m_relcol)
m_relcol
```

```
##          ap-davis    as-bimac    as-fasci    ch-bimac    ci-ocela    ci-orien
## S-A-ZA1 0.0000000 0.0004191115 0.000000000 0.000000000 0.000000000 0.000000000
## S-R-CC1 0.0000000 0.0414920369 0.000000000 0.000000000 0.000000000 0.000000000
## S-R-CT1 0.0000000 0.0813076278 0.348101266 0.000000000 0.000000000 0.03496503
## S-R-CP1 0.0000000 0.0079631182 0.000000000 0.000000000 0.000000000 0.000000000
## S-A-TA1 0.0000000 0.0096395641 0.006329114 0.018439716 0.000000000 0.000000000
```

```

## S-R-CT2 0.0000000 0.0595138307 0.018987342 0.004255319 0.00000000 0.48251748
## S-R-CP2 0.0000000 0.0020955574 0.006329114 0.000000000 0.57142857 0.06293706
## S-A-TA2 0.0000000 0.0192791282 0.000000000 0.252482270 0.00000000 0.00000000
## S-R-CT3 0.0000000 0.0863369656 0.405063291 0.000000000 0.00000000 0.17482517
## S-R-CP3 0.0000000 0.0067057837 0.000000000 0.000000000 0.18571429 0.16783217
## S-A-TA3 0.0000000 0.0980720872 0.044303797 0.337588652 0.00000000 0.00000000
## S-R-CT4 0.0000000 0.000000000 0.006329114 0.000000000 0.00000000 0.03496503
## S-R-CP4 0.0000000 0.000000000 0.000000000 0.000000000 0.15714286 0.04195804
## S-A-TA4 0.0000000 0.1651299246 0.000000000 0.387234043 0.00000000 0.00000000
## B-A-MU1 0.0000000 0.0050293378 0.000000000 0.000000000 0.00000000 0.00000000
## B-R-ET1 0.0000000 0.0012573345 0.000000000 0.000000000 0.00000000 0.00000000
## B-A-GU1 0.0000000 0.0008382230 0.012658228 0.000000000 0.00000000 0.00000000
## B-R-PC2 0.1851852 0.0184409053 0.000000000 0.000000000 0.02857143 0.00000000
## B-A-MU2 0.0000000 0.0414920369 0.000000000 0.000000000 0.00000000 0.00000000
## B-A-GU2 0.0000000 0.000000000 0.000000000 0.000000000 0.00000000 0.00000000
## B-R-PC3 0.8148148 0.0314333613 0.044303797 0.000000000 0.05714286 0.00000000
## B-A-MU3 0.0000000 0.2141659681 0.000000000 0.000000000 0.00000000 0.00000000
## B-A-GU3 0.0000000 0.0025146689 0.000000000 0.000000000 0.00000000 0.00000000
## B-R-PC4 0.0000000 0.0029337804 0.107594937 0.000000000 0.00000000 0.00000000
## B-A-MU4 0.0000000 0.0984911987 0.000000000 0.000000000 0.00000000 0.00000000
## B-A-GU4 0.0000000 0.0054484493 0.000000000 0.000000000 0.00000000 0.00000000
##          co-macro co-heter  cr-menez cu-lepid  cy-gilbe      ge-brasi he-margi
## S-A-ZA1          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-R-CC1          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-R-CT1          0          1 0.50000000          0 0.00000000 0.0029411765          0.0
## S-R-CP1          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-A-TA1          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-R-CT2          0          0 0.14285714          0 0.00000000 0.0000000000          0.5
## S-R-CP2          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-A-TA2          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-R-CT3          0          0 0.28571429          0 0.00000000 0.0009803922          0.0
## S-R-CP3          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-A-TA3          1          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-R-CT4          0          0 0.03571429          0 0.3816794 0.0029411765          0.5
## S-R-CP4          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## S-A-TA4          0          0 0.03571429          0 0.00000000 0.0009803922          0.0
## B-A-MU1          0          0 0.00000000          0 0.00000000 0.1862745098          0.0
## B-R-ET1          0          0 0.00000000          0 0.00000000 0.0000000000          0.0
## B-A-GU1          0          0 0.00000000          0 0.00000000 0.0068627451          0.0
## B-R-PC2          0          0 0.00000000          0 0.00000000 0.0078431373          0.0
## B-A-MU2          0          0 0.00000000          0 0.00000000 0.0656862745          0.0
## B-A-GU2          0          0 0.00000000          0 0.00000000 0.0225490196          0.0
## B-R-PC3          0          0 0.00000000          1 0.00000000 0.0156862745          0.0
## B-A-MU3          0          0 0.00000000          0 0.00000000 0.1421568627          0.0
## B-A-GU3          0          0 0.00000000          0 0.00000000 0.0313725490          0.0
## B-R-PC4          0          0 0.00000000          0 0.6183206 0.0049019608          0.0

```

```

## B-A-MU4      0      0 0.00000000      0 0.00000000 0.4990196078      0.0
## B-A-GU4      0      0 0.00000000      0 0.00000000 0.0098039216      0.0
##           ho-malab  hy-pusar le-melan  le-piau le-taeni mo-costa  mo-lepid
## S-A-ZA1 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## S-R-CC1 0.000000000 0.00000000      0 0.00000000      0      0 0.02439024
## S-R-CT1 0.009174312 0.12676056      0 0.20000000      0      0 0.95121951
## S-R-CP1 0.045871560 0.02816901      0 0.00000000      0      0 0.00000000
## S-A-TA1 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## S-R-CT2 0.155963303 0.60563380      0 0.06666667      0      0 0.02439024
## S-R-CP2 0.091743119 0.02816901      0 0.20000000      0      0 0.00000000
## S-A-TA2 0.018348624 0.00000000      0 0.00000000      0      0 0.00000000
## S-R-CT3 0.284403670 0.15492958      0 0.13333333      0      0 0.00000000
## S-R-CP3 0.036697248 0.00000000      0 0.06666667      0      0 0.00000000
## S-A-TA3 0.183486239 0.00000000      0 0.00000000      0      0 0.00000000
## S-R-CT4 0.036697248 0.04225352      0 0.00000000      0      0 0.00000000
## S-R-CP4 0.018348624 0.00000000      0 0.13333333      0      0 0.00000000
## S-A-TA4 0.082568807 0.00000000      0 0.13333333      0      0 0.00000000
## B-A-MU1 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## B-R-ET1 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## B-A-GU1 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## B-R-PC2 0.000000000 0.00000000      1 0.00000000      1      0 0.00000000
## B-A-MU2 0.009174312 0.00000000      0 0.00000000      0      0 0.00000000
## B-A-GU2 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## B-R-PC3 0.018348624 0.01408451      0 0.00000000      0      1 0.00000000
## B-A-MU3 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## B-A-GU3 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## B-R-PC4 0.009174312 0.00000000      0 0.06666667      0      0 0.00000000
## B-A-MU4 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
## B-A-GU4 0.000000000 0.00000000      0 0.00000000      0      0 0.00000000
##           or-nilot  pa-manag pimel-sp  po-retic  po-vivip  pr-brevi
## S-A-ZA1 0.000000000 0.00000000      0 0.00000000 0.000000000 0.032258065
## S-R-CC1 0.002358491 0.00000000      0 0.00000000 0.000000000 0.000000000
## S-R-CT1 0.042452830 0.00000000      1 0.00000000 0.048057260 0.017921147
## S-R-CP1 0.000000000 0.00000000      0 0.00000000 0.015337423 0.000000000
## S-A-TA1 0.000000000 0.00000000      0 0.00000000 0.000000000 0.003584229
## S-R-CT2 0.090801887 0.00000000      0 0.05249344 0.225971370 0.053763441
## S-R-CP2 0.000000000 0.00000000      0 0.00000000 0.032719836 0.017921147
## S-A-TA2 0.000000000 0.00000000      0 0.00000000 0.000000000 0.007168459
## S-R-CT3 0.162735849 0.00000000      0 0.01312336 0.333333333 0.587813620
## S-R-CP3 0.000000000 0.00000000      0 0.00000000 0.010224949 0.000000000
## S-A-TA3 0.000000000 0.00000000      0 0.00000000 0.000000000 0.000000000
## S-R-CT4 0.086084906 0.00000000      0 0.00000000 0.028629857 0.211469534
## S-R-CP4 0.000000000 0.00000000      0 0.00000000 0.081799591 0.000000000
## S-A-TA4 0.001179245 0.00000000      0 0.00000000 0.000000000 0.010752688
## B-A-MU1 0.007075472 0.00000000      0 0.00000000 0.000000000 0.000000000
## B-R-ET1 0.009433962 0.001805054      0 0.08923885 0.000000000 0.000000000

```

```

## B-A-GU1 0.003537736 0.019855596      0 0.00000000 0.00000000 0.00000000
## B-R-PC2 0.005896226 0.000000000      0 0.00000000 0.00000000 0.032258065
## B-A-MU2 0.001179245 0.000000000      0 0.02624672 0.008179959 0.000000000
## B-A-GU2 0.042452830 0.184115523      0 0.00000000 0.00000000 0.000000000
## B-R-PC3 0.076650943 0.000000000      0 0.00000000 0.00000000 0.021505376
## B-A-MU3 0.012971698 0.000000000      0 0.12073491 0.049079755 0.003584229
## B-A-GU3 0.291273585 0.451263538      0 0.00000000 0.00000000 0.000000000
## B-R-PC4 0.010613208 0.000000000      0 0.00000000 0.00000000 0.000000000
## B-A-MU4 0.001179245 0.000000000      0 0.69816273 0.166666667 0.000000000
## B-A-GU4 0.152122642 0.342960289      0 0.00000000 0.00000000 0.000000000
##          ps-rhomb ps-genise  se-heter se-piaba se-spilo  st-noton sy-marmo
## S-A-ZA1      0          0 0.00000000      0      0 0.00000000      0
## S-R-CC1      0          0 0.00000000      0      0 0.00000000      0
## S-R-CT1      0          0 0.13513514      1      0 0.004878049      0
## S-R-CP1      0          0 0.04729730      0      0 0.000000000      0
## S-A-TA1      0          0 0.01351351      0      0 0.000000000      0
## S-R-CT2      0          0 0.20270270      0      0 0.121951220      0
## S-R-CP2      0          0 0.00000000      0      0 0.000000000      1
## S-A-TA2      0          0 0.00000000      0      0 0.000000000      0
## S-R-CT3      1          1 0.12837838      0      1 0.560975610      0
## S-R-CP3      0          0 0.00000000      0      0 0.000000000      0
## S-A-TA3      0          0 0.00000000      0      0 0.000000000      0
## S-R-CT4      0          0 0.01013514      0      0 0.312195122      0
## S-R-CP4      0          0 0.01013514      0      0 0.000000000      0
## S-A-TA4      0          0 0.00000000      0      0 0.000000000      0
## B-A-MU1      0          0 0.00000000      0      0 0.000000000      0
## B-R-ET1      0          0 0.00000000      0      0 0.000000000      0
## B-A-GU1      0          0 0.00000000      0      0 0.000000000      0
## B-R-PC2      0          0 0.03378378      0      0 0.000000000      0
## B-A-MU2      0          0 0.00000000      0      0 0.000000000      0
## B-A-GU2      0          0 0.00000000      0      0 0.000000000      0
## B-R-PC3      0          0 0.31418919      0      0 0.000000000      0
## B-A-MU3      0          0 0.00000000      0      0 0.000000000      0
## B-A-GU3      0          0 0.00000000      0      0 0.000000000      0
## B-R-PC4      0          0 0.10472973      0      0 0.000000000      0
## B-A-MU4      0          0 0.00000000      0      0 0.000000000      0
## B-A-GU4      0          0 0.00000000      0      0 0.000000000      0
##          te-chalc  tr-signa
## S-A-ZA1 0.0000000 0.00000000
## S-R-CC1 0.0000000 0.00000000
## S-R-CT1 0.0000000 0.08653846
## S-R-CP1 0.0000000 0.00000000
## S-A-TA1 0.0000000 0.00000000
## S-R-CT2 0.0000000 0.07211538
## S-R-CP2 0.0000000 0.00000000
## S-A-TA2 0.0000000 0.00000000

```

```
## S-R-CT3 0.0000000 0.03365385
## S-R-CP3 0.0000000 0.00000000
## S-A-TA3 0.0000000 0.00000000
## S-R-CT4 0.0000000 0.67788462
## S-R-CP4 0.0000000 0.00000000
## S-A-TA4 0.0000000 0.00000000
## B-A-MU1 0.0000000 0.00000000
## B-R-ET1 0.0000000 0.00000000
## B-A-GU1 0.0000000 0.00000000
## B-R-PC2 0.5671642 0.11057692
## B-A-MU2 0.0000000 0.00000000
## B-A-GU2 0.0000000 0.00000000
## B-R-PC3 0.4328358 0.00000000
## B-A-MU3 0.0000000 0.00000000
## B-A-GU3 0.0000000 0.00000000
## B-R-PC4 0.0000000 0.01923077
## B-A-MU4 0.0000000 0.00000000
## B-A-GU4 0.0000000 0.00000000
```

```
#colSums(m_relcol)
#range(m_relcol)
```

20.7.2 Transformação pelo arcoseno da raiz quadrada

A seguir é realizada a transformação pelo arcoseno da raiz quadrada, apropriada para ados em proporção como os ados previamente relativizados. Para cada transformação, a função é aplicada aos dados de interesse e o resultado é armazenado em uma nova variável. A função `View()` é usada para visualizar o resultado de cada transformação na forma de uma tabela. Os códigos para as demais principais transformações estão AQUI

```
m_relcol_asrq <- asin(sqrt(m_relcol))
#View(m_relcol_asrq)
m_relcol_asrqpi <- 2/pi*(asin(sqrt(m_relcol)))
#View(m_relcol_asrqpi)
#colSums(m_relcol_asrqpi)
#range(m_relcol_asrqpi)
```

20.8 REINÍCIO 2

Aqui estabelecemos a matriz transformada depois de ter sido relativizada como `m_trns`.

```
m_trns <- m_relcol_asrqi
#m_dists <- dist(m_trns, method = "euclidian", diag = TRUE, upper
  ↪ = FALSE)
```

Agora é com você...Refaça toda a análise com as relativizações e transformações adequadas para a matriz de dados fornecida.

Apêndices

Relativizações

Total das colunas

```
m_relcol <- decostand(m_bruta,
                      method="total",
                      MARGIN = 2)
View(m_relcol)
m_relcol
```

A função `decostand()` é usada para relativizar os dados armazenados no vetor `m_bruta`. O parâmetro `method` especifica o método de relativização, neste caso “total” (relativização pelo total de cada coluna). Outros métodos disponíveis são `max`, `normalize`, `range` e `rankm` (Figura 20.3). O parâmetro `MARGIN` especifica em qual dimensão os cálculos devem ser feitos (1 para linhas, 2 para colunas). Neste caso, `MARGIN=2` (colunas). A variável `m_relcol` armazena o resultado da relativização. Sokal e Rohlf (1995) tratam dos diversos tipos de relativizações e transformações em dados ecológicos.

```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

Table 20.3: Métodos de relativização da função ‘decostand’

Função	Descrição	Uso adequado
max	Divide cada valor pela maior observação da coluna em que está localizado. Todos os valores resultantes serão menores ou iguais a 1. Adequada para análise em escala relativa	Quando a escala de cada variável é conhecida e a análise deve ser feita em uma escala relativa
normalize	Divide cada valor pelo comprimento do vetor. Isso resulta em valores cujo comprimento é sempre igual a 1. Adequada para análise de dados de frequência	Para análise de dados de frequência
range	Subtrai o valor mínimo da coluna de cada valor e, em seguida, divide pelo intervalo (ou amplitude) dos valores da coluna. Isso resulta em valores entre 0 e 1.	Quando a amplitude dos valores em cada coluna é importante para a análise
rankm	Transforma os valores em suas posições dentro da coluna, em ordem crescente. O menor valor recebe o valor 1 e o maior valor recebe o valor igual ao comprimento da coluna.	Quando a escala absoluta dos valores não é importante, mas a ordem dos valores é significativa.

Transformações

Essa seção mostra as diversas transformações nos dados armazenados no vetor `m_bruta`. Para cada transformação, a função é aplicada aos dados da matriz e o resultado é armazenado em uma nova variável. A função `View()` pode ser usada para visualizar o resultado de cada transformação na forma de uma tabela. Ela mostra o código que realiza diversas transformações na matriz de dados. Para cada transformação, a função é aplicada aos dados e o resultado é armazenado em uma nova variável.

Log10

Não aceita zeros, porque o log de zero é indeterminado. Por isso devemos substituir os valores com erro (infinito negativo) por zero, usando a função `replace()`.

```
m_lg10 <- log10(m_bruta)
#View(m_lg10)
m_lg10 <- replace(m_lg10, is.infinite(m_lg10), 0)
head(m_lg10)
```

Log(x+1)

Desaconselhavel para valores que variam entre 0-1.

```
m_lgx1 <- log(m_bruta+1)
#View(m_lgx1)
```

Exponenciais

“Power transformations”, onde o valor de p estabelece a compressão dos dados.

```
m_bruta_P1 <- m_bruta^1 #p=1
#View(m_bruta_P1)
m_bruta_P05 <- m_bruta^0.5 #p=0,5
#View(m_bruta_P05)
m_bruta_P01 <- m_bruta^0.1 #p=0,1
#View(m_bruta_P01)
```

Presença/Ausência

```
m_pa <- (m_bruta>0)*1L
#View(m_pa)
```

Raiz quadrada

```
m_rq <- sqrt(m_bruta)
#View(m_rq)
```

Arcoseno da raiz quadrada

Os valores de entrada tem que variar entre 0 e 1. Ideal para matrizes relativizadas. Duas formulações estão disponíveis, com e sem a multiplicação por $2/\pi$. A segunda opção costuma ter melhor efeito na normalização dos dados.


```

m_asrq <- asin(sqrt(m_relcol))
#View(m_asrq)
m_asrqpi <- 2/pi*(asin(sqrt(m_relcol)))
View(m_asrqpi)

```

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executa-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

```

## dev.off() #apaga os graficos, se houver algum
## rm(list=ls(all=TRUE)) #limpa a memória
## cat("\014") #limpa o console
## install.packages("openxlsx") #importa arquivos do excel
## install.packages("moments") #calcula assimetria e curtose dos
  ↪ dados
## install.packages("vegan") #estatísticas para ecologia de
  ↪ comunidades
## getwd()
## setwd("C:/Seu/Diretório/De/Trabalho")
library(openxlsx)
#dir <- getwd() #criamos um vetor com o diretório de trbalho
#shell.exec(dir) #abre o diretorio de trabalho no Windows
  ↪ Explorer
m_bruta <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/peixes06.xlsx"
  ↪ ,
                        rowNames = T, colNames = T,
                        sheet = "Sheet1")

str(m_bruta)
#View(m_bruta)
m_bruta[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas de
  ↪ 1 a 5.
## #View(m_bruta)
## print(m_bruta[1:8,1:8])
## m_bruta[1:10,1:10]
## str(m_bruta)
## mode(m_bruta)
## class(m_bruta)
#View(m_bruta)
print(m_bruta)

```

```

head(m_bruta)
range(m_bruta) #menor e maior valores
length(m_bruta) #no. de colunas
ncol(m_bruta) #no. de N colunas
nrow(m_bruta) #no. de M linhas
sum(lengths(m_bruta)) #soma os nos. de colunas
length(as.matrix(m_bruta)) #tamanho da matriz m x n
sum(m_bruta == 0) # número de observações igual a zero
sum(m_bruta > 0) # número de observações maiores que zero
zeros <- (sum(m_bruta == 0)/length(as.matrix(m_bruta)))*100 #
  ↪ proporção de zeros na matriz
zeros
tamanho <- data.frame(
  Função = c("range", "length", "m cols", "n linhas", "Tamanho",
  ↪ "Tamanho",
    "Zeros", "Nao zeros", "% Zeros"),
  Resultado = c(paste(range(m_bruta), collapse = " - "),
  ↪ length(m_bruta), ncol(m_bruta),
    nrow(m_bruta), sum(lengths(m_bruta)),
    ↪ length(as.matrix(m_bruta)), sum(m_bruta ==
    ↪ 0),
    sum(m_bruta > 0), round(zeros, 1)))

tamanho
m_trab <- m_bruta
m_dists <- dist(m_trab, method = "euclidian", diag = TRUE, upper
  ↪ = FALSE)
#m_dists
str(m_dists)
mode(m_dists)
class(m_dists)
length(as.matrix(m_dists))
as.matrix(m_dists)[1:10, 1:10]
range(m_trab)
range(m_dists)
min(m_dists)
max(m_dists)
mean(m_dists) #CENTROIDE!! ou Grand mean
sd(m_dists) #standard deviation
centroide <- mean(m_dists)
centroide
length(m_dists)
m <- nrow(as.matrix(m_dists))
m
m*(m-1)/2
summary(m_dists)

```

```

Sumario1 <- cbind(min(m_dists),
                  max(m_dists),
                  sd(m_dists),
                  mean(m_dists),
                  length(m_dists))
colnames(Sumario1) <- c("Minimo", "Maximo", "Desv.Padr", "Media",
  ↪ "m(m-1)/2")
rownames(Sumario1) <- ("Valores")
Sumario1
dist <- (as.matrix(m_dists))
#View(dist)
str(dist)
mode(dist)
class(dist)
#head(dist)
dist[1:5, 1:5] #mostra as 5 primeiras linhas e colunas da matriz
range(m_dists) # intervalo dos valores da matriz
mean(m_dists) # média dos valores da matriz
sd(m_dists) # desvio padrão dos valores da matriz
library(moments)
sk <- skewness(as.matrix(m_dists)) #calcula a assimetria da
  ↪ matriz
ku <- kurtosis(as.matrix(m_dists)) #calcula a curtose da matriz
sku <- cbind(sk,ku) # junta os dois valores em um vetor
colnames(sku) <- c("assimetria", "curtose") # nomeia as colunas
  ↪ do vetor
sku[1:10, ] # mostra as primeiras 10 linhas desse vetor
summary(sku) # mostra um resumo estatístico do vetor
range(m_dists)
par(mfrow=c(2,1)) # esse comando faz os gráficos aparecerem um
  ↪ acima do outro
hist(m_dists,
     breaks = 20, # determina o número de colunas do histograma
     xlim = range(floor(min(m_dists)), ceiling(max(m_dists))), #
     ↪ limites dos eixos
     xlab = "Distr. de Frequências",
     freq = FALSE, # mostra as frequências relativas em vez das
     ↪ absolutas
     main = "Histograma e boxplot da matriz de distâncias")
curve(dnorm(x, mean=mean(m_dists), sd=sd(m_dists)), add=TRUE) #
  ↪ sobrepõe a curva de normalidade
boxplot.default(m_dists, horizontal = TRUE, frame = FALSE,
                xlab="Distr. de Frequências",
                ylim=c(floor(min(m_dists)),
                ↪ ceiling(max(m_dists)))) # limites dos eixos

```

```

## dev.off()
library(vegan)
m_relcol <- decostand(m_trab,
                     method="total",
                     MARGIN = 2)

#View(m_relcol)
m_relcol
#colSums(m_relcol)
#range(m_relcol)
m_relcol_asrq <- asin(sqrt(m_relcol))
#View(m_relcol_asrq)
m_relcol_asrqpi <- 2/pi*(asin(sqrt(m_relcol)))
#View(m_relcol_asrqpi)
#colSums(m_relcol_asrqpi)
#range(m_relcol_asrqpi)
m_trns <- m_relcol_asrqpi
#m_dists <- dist(m_trns, method = "euclidian", diag = TRUE, upper
  ↪ = FALSE)
## m_relcol <- decostand(m_bruta,
##                       method="total",
##                       MARGIN = 2)
## View(m_relcol)
## m_relcol
## m_lg10 <- log10(m_bruta)
## #View(m_lg10)
## m_lg10 <- replace(m_lg10, is.infinite(m_lg10), 0)
## head(m_lg10)
## m_lgx1 <- log(m_bruta+1)
## #View(m_lgx1)
## m_bruta_P1 <- m_bruta^1 #p=1
## #View(m_bruta_P1)
## m_bruta_P05 <- m_bruta^0.5 #p=0,5
## #View(m_bruta_P05)
## m_bruta_P01 <- m_bruta^0.1 #p=0,1
## #View(m_bruta_P01)
## m_pa <- (m_bruta>0)*1L
## #View(m_pa)
## m_rq <- sqrt(m_bruta)
## #View(m_rq)
## m_asrq <- asin(sqrt(m_relcol))
## #View(m_asrq)
## m_asrqpi <- 2/pi*(asin(sqrt(m_relcol)))
## View(m_asrqpi)

```

Referências

Chapter 21

R Módulo 6 - Análise de outliers baseada no desvio padrão do centróide

Apresentação

A análise de outliers baseada no desvio padrão do centróide em análise multivariada é uma técnica utilizada para identificar valores discrepantes em uma matriz de dados com várias variáveis. Essa técnica consiste em calcular o centróide dos dados (ou seja, a média de cada variável), e então calcular o desvio padrão de cada observação em relação ao centróide. Os valores que estão a uma distância maior que um certo número de desvios padrão do centróide são considerados outliers. Essa técnica é útil para identificar observações que podem estar afetando a análise de dados multivariados, como análise de componentes principais, e que podem precisar ser tratadas de forma especial. No entanto, é importante lembrar que a identificação de outliers é uma questão subjetiva e depende do contexto da análise e do objetivo do estudo.

21.1 Sobre os dados do PPBio

Usaremos para esse tutorial dados coletados no Programa de Pesquisa em Biodiversidade - PPBio (Veja Programa de Pesquisa em Biodiversidade – PPBio). Nesta base de dados estão armazenadas informações sobre diversos grupos taxonômicos distribuídos em diversas unidades amostrais (UA's ou sítios), como peixes, macroinvertebrados bentônicos, quironômídeos e zooplâncton, além de dados do habitat, como variáveis físicas e químicas, morfologia do habitat, composição do substrato, estrutura de habitat marginal, entre outros (Figura 21.1).

	A	B	C	D	E	F	G	H	
1	sitio	ap-davis	as-bimac	as-fasci	ch-bimac	ci-ocela	ci-orien	co-macro	co-
2	S-A-ZA1	0	1	0	0	0	0	0	
3	S-R-CC1	0	99	0	0	0	0	0	
4	S-R-CT1	0	194	55	0	0	5	0	
5	S-R-CP1	0	19	0	0	0	0	0	
6	S-A-TA1	0	23	1	13	0	0	0	
7	S-R-CT2	0	142	3	3	0	69	0	
8	S-R-CP2	0	5	1	0	40	9	0	
9	S-A-TA2	0	46	0	178	0	0	0	
10	S-R-CT3	0	206	64	0	0	25	0	
11	S-R-CP3	0	16	0	0	13	24	0	
12	S-A-TA3	0	234	7	238	0	0	2	
13	S-R-CT4	0	0	1	0	0	5	0	
14	S-R-CP4	0	0	0	0	11	6	0	
15	S-A-TA4	0	394	0	273	0	0	0	
16	B-A-MU1	0	12	0	0	0	0	0	
17	B-R-ET1	0	3	0	0	0	0	0	
18	B-A-GU1	0	2	2	0	0	0	0	
19	B-R-PC2	5	44	0	0	2	0	0	
20	B-A-MU2	0	99	0	0	0	0	0	
21	B-A-GU2	0	0	0	0	0	0	0	
22	B-R-PC3	22	75	7	0	4	0	0	
23	B-A-MU3	0	511	0	0	0	0	0	
24	B-A-GU3	0	6	0	0	0	0	0	
25	B-R-PC4	0	7	17	0	0	0	0	
26	B-A-MU4	0	235	0	0	0	0	0	
27	B-A-GU4	0	13	0	0	0	0	0	

Figure 21.1: Parte da planilha de dados brutos do PPBio.

Essa é a **matriz bruta de dados**, porque os valores ainda não foram ajustados para os valores de Captura Por Unidade de Esforço (CPUE), nem foram relativizados ou transformados (Tabela 21.1). As matrizes disponíveis para análises, com suas descrições e tipos de dados recomendados são mostradas na Tabela 21.1.

```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

A planilha ppbio contém o delineamento amostral de um dos estudos do Projeto PPBio (Figura 21.2). Nas linhas são apresentadas as abreviações dos nomes das unidades amostrais (UA's) e nas colunas são apresentados os nomes abreviados das espécies - temos portando uma matriz comunitária (21.1). No corpo da planilha temos os valores para o tipo de dados amostrado. Quantitativo, semi-quantitativo ou qualitativo.

Qual desses tipos de dados você acha que é apresentado na planilha?

Várias das espécies nessa matriz tem grande importância ecológica, como é o caso de *Astyanax bimaculatus*¹ (Figura 21.3), que é muito comum em rios intermitentes e serve de alimento para predadores maiores como a espécie *Hoplias malabaricus*² (Figura 21.4).

21.2 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) #limpa a memória
cat("\014") #limpa o console
```

Instalando os pacotes necessários para esse módulo

```
install.packages("openxlsx") #importa arquivos do excel
install.packages("moments") #calcula assimetria e curtose dos
  ↳ dados
install.packages("matrixStats") #fornece funções rápidas para a
  ↳ estatística de matrizes
install.packages("gt") #ferramenta para criação de tabelas
  ↳ bonitas e personalizáveis
```

¹A etimologia do gênero *Astyanax* vem da mitologia Grega. Heitor personagem da “Ilíada”, tinha um filho chamado Astíanax.

²Do Grego, *hoplon*, arma ou armadura, em referência aos dentes caniniformes muito desenvolvidos, e forte estrutura óssea na cabeça.

Table 21.1: Exemplos de matrizes disponíveis para análises (PPBio Semiárido), com suas descrições e tipos de dados recomendados.

Arquivo (.xlsx)	Tipo de matriz	Descrição	Tipo de dados
ppbio06c	Matriz comunitária	O arquivo ppbio06 traz os dados brutos que serão usados nas análises. A matriz de dados brutos contendo 26 localidades em estações do ano diferentes (objetos) x 35 espécies (atributos), antes de qualquer modificação.	Contagens de indivíduos com uma alta amplitude de variação, sugerido uso de matriz relativizada.
ppbio06h	Matriz ambiental	O arquivo ppbio06h traz os dados brutos que serão usados nas análises. A matriz de dados brutos contendo 26 localidades em estações diferentes (objetos) x 35 variáveis ambientais (atributos) medidas em diferentes escalas espaciais, antes de qualquer modificação.	Unidades de medição com uma alta amplitude de variação, sugerido uso de matriz transformada e/ou reescalada.
ppbio06	Matriz comunitária	O arquivo ppbio06 traz os dados brutos que serão usados nessa análise. A matriz de dados brutos contendo 26 locais/ocasiões (objetos) x 35 espécies (atributos), antes de qualquer modificação.	Contagens de indivíduos com uma alta amplitude de variação, sugerido uso de matriz relativizada.
ppbio06cpue	Matriz comunitária	O arquivo ppbio06cpue traz os valores depois de terem sido ajustados pela Captura Por Unidade de Esforço (CPUE), onde o número de indivíduos de cada espécie em uma determinada UA é dividido pelo esforço de captura daquela UA. Isso significa que os dados foram relativizados pela CPUE. A matriz de dados brutos contendo 26 localidades em estações do ano diferentes (objetos) x 35 espécies (atributos), antes de qualquer modificação.	Densidades de indivíduos por Unidade de Esforço de Captura com uma alta amplitude de variação, sugerido uso de matriz relativizada.

Salvamento Automático    

Arquivo **Página Inicial** Inserir Layout da Página Fórmulas

Colar  

Área de Transferência 

Fonte

Arial CE 10 A[^] A^v

N *I* S   

B5    0

	A	B	C	D	E	F
1	sitio	ap-davis	as-bimac	as-fasci	ch-bimac	ci-oce
2	S-A-ZA1	0	1	0	0	
3	S-R-CC1	0	99	0	0	
4	S-R-CT1	0	194	55	0	
5	S-R-CP1	0	19	0	0	
6	S-A-TA1	0	23	1	13	
7	S-R-CT2	0	142	3	3	
8	S-R-CP2	0	5	1	0	
9	S-A-TA2	0	46	0	178	
10	S-R-CT3	0	206	64	0	
11	S-R-CP3	0	16	0	0	
12	S-A-TA3	0	234	7	238	
13	S-R-CT4	0	0	1	0	
14	S-R-CP4	0	0	0	0	
15	S-A-TA4	0	394	0	273	
16	B-A-MU1	0	12	0	0	
17	B-R-ET1	0	3	0	0	



Figure 21.3: **Astyanax bimaculatus**, a espécie mais comum da matriz de dados ppbio. Peru, by Eakins, R. Fonte: <<https://www.fishbase.se/summary/Astianax-bimaculatus.html>>



Figure 21.4: *Hoplias malabaricus**, espécie que cresce para se tornar um importante predador. Brazil, by Roselet, F.F.G. Fonte: <<https://www.fishbase.se/summary/Hoplias-malabaricus.html>>

Agora vamos **definir o diretório de trabalho**. Esse código é usado para obter e definir o diretório de trabalho atual no R. O comando `getwd()` retorna o caminho do diretório onde o R está lendo e salvando arquivos. O comando `setwd()` muda esse diretório de trabalho para o caminho especificado entre aspas. No seu caso, você deve ajustar o caminho para o seu próprio diretório de trabalho. **Lembre de usar a barra “/” entre os diretórios. E não a contra-barra “\”.**

Definindo o diretório de trabalho e installando os pacotes necessários:

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

21.2.1 Importando a planilha

Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações.

- Ajuste a primeira linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.
- Ajuste o parâmetro `sheet = "Sheet1"` para refletir a aba correta do arquivo .xlsx a ser importado.

Alternativamente você pode ir na barra de tarefas e escolhes as opções:
SESSION -> SET WORKING DIRECTORY -> CHOOSE DIRECTORY

```
library(openxlsx)
m_bruta <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06c-peixes.xlsx"
  ↪ ,
                                rowNames = T, colNames = T,
                                sheet = "Sheet1")
str(m_bruta)
m_bruta_ma <- as.matrix(m_bruta) #lê m_bruta como uma matriz
str(m_bruta_ma)
#m_bruta
m_bruta_ma[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas
  ↪ de 1 a 5.
```

```
## 'data.frame':    26 obs. of  35 variables:
## $ ap-davis : num  0 0 0 0 0 0 0 0 0 0 ...
## $ as-bimac : num  1 99 194 19 23 142 5 46 206 16 ...
## $ as-fasci : num  0 0 55 0 1 3 1 0 64 0 ...
## $ ch-bimac : num  0 0 0 0 13 3 0 178 0 0 ...
```

```

## $ ci-ocela : num 0 0 0 0 0 0 40 0 0 13 ...
## $ ci-orien : num 0 0 5 0 0 69 9 0 25 24 ...
## $ co-macro : num 0 0 0 0 0 0 0 0 0 0 ...
## $ co-heter : num 0 0 1 0 0 0 0 0 0 0 ...
## $ cr-menez : num 0 0 14 0 0 4 0 0 8 0 ...
## $ cu-lepid : num 0 0 0 0 0 0 0 0 0 0 ...
## $ cy-gilbe : num 0 0 0 0 0 0 0 0 0 0 ...
## $ ge-brasi : num 0 0 3 0 0 0 0 0 1 0 ...
## $ he-margi : num 0 0 0 0 0 1 0 0 0 0 ...
## $ ho-malab : num 0 0 1 5 0 17 10 2 31 4 ...
## $ hy-pusar : num 0 0 9 2 0 43 2 0 11 0 ...
## $ le-melan : num 0 0 0 0 0 0 0 0 0 0 ...
## $ le-piau : num 0 0 3 0 0 1 3 0 2 1 ...
## $ le-taeni : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-costa : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-lepid : num 0 1 39 0 0 1 0 0 0 0 ...
## $ or-nilot : num 0 2 36 0 0 77 0 0 138 0 ...
## $ pa-manag : num 0 0 0 0 0 0 0 0 0 0 ...
## $ pimel-sp : num 0 0 6 0 0 0 0 0 0 0 ...
## $ po-retic : num 0 0 0 0 0 20 0 0 5 0 ...
## $ po-vivip : num 0 0 47 15 0 221 32 0 326 10 ...
## $ pr-brevi : num 9 0 5 0 1 15 5 2 164 0 ...
## $ ps-rhomb : num 0 0 0 0 0 0 0 0 1 0 ...
## $ ps-genise: num 0 0 0 0 0 0 0 0 1 0 ...
## $ se-heter : num 0 0 40 14 4 60 0 0 38 0 ...
## $ se-piaba : num 0 0 68 0 0 0 0 0 0 0 ...
## $ se-spilo : num 0 0 0 0 0 0 0 0 1 0 ...
## $ st-noton : num 0 0 1 0 0 25 0 0 115 0 ...
## $ sy-marmo : num 0 0 0 0 0 0 1 0 0 0 ...
## $ te-chalc : num 0 0 0 0 0 0 0 0 0 0 ...
## $ tr-signa : num 0 0 18 0 0 15 0 0 7 0 ...
## num [1:26, 1:35] 0 0 0 0 0 0 0 0 0 0 ...
## - attr(*, "dimnames")=List of 2
## ..$ : chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## ..$ : chr [1:35] "ap-davis" "as-bimac" "as-fasci" "ch-bimac" ...
##      ap-davis as-bimac as-fasci ch-bimac ci-ocela
## S-A-ZA1      0        1        0        0        0
## S-R-CC1      0       99        0        0        0
## S-R-CT1      0      194       55        0        0
## S-R-CP1      0       19        0        0        0
## S-A-TA1      0       23        1       13        0

```

21.3 Reset point

ATENÇÃO Aqui substitui-se uma nova matriz de dados, relativizada e/ou transformada, pela matriz de trabalho inicial.

```
#m_bruta <- (m_bruta) # <1>
```

1. Aqui usaremos as matrizes relativizadas/transformadas/particionadas, etc

Podemos exibir a planilha depois de ter sido importada para o ambiente R/RStudio usando as funções `View()`, `print()` ou `head()`. Note que essas funções são case-sensitive. A função `ignore.case()` é uma função do pacote `stringr` que modifica um padrão para que ele não considere o caso das letras nas correspondências. Por exemplo, se você quiser encontrar todas as ocorrências da letra “a” em um vetor de caracteres, independente de ser “A” ou “a”, você pode usar essa função.

```
#View(m_bruta)
print(m_bruta)
head(m_bruta)
```

A função `head()` no RStudio é uma forma de ver as primeiras (n=6) linhas de um objeto, como um vetor, uma matriz, um data frame ou uma lista. Ela é útil para ter uma ideia do conteúdo e da estrutura do objeto.

Também podemos explorar as características da planilha usando as funções `str()`, `mode()`, `class()` e `length()`. O número de observações ou tamanho do vetor depende do tipo de dados, se eles são uma `matrix` ou um `data.frame`.

```
str(m_bruta)
mode(m_bruta)
class(m_bruta)
#?str
```

```
## 'data.frame':    26 obs. of  35 variables:
## $ ap-davis : num  0 0 0 0 0 0 0 0 0 0 ...
## $ as-bimac : num  1 99 194 19 23 142 5 46 206 16 ...
## $ as-fasci : num  0 0 55 0 1 3 1 0 64 0 ...
## $ ch-bimac : num  0 0 0 0 13 3 0 178 0 0 ...
## $ ci-ocela : num  0 0 0 0 0 0 40 0 0 13 ...
## $ ci-orien : num  0 0 5 0 0 69 9 0 25 24 ...
```



```
## $ co-macro : num 0 0 0 0 0 0 0 0 0 0 ...
## $ co-heter : num 0 0 1 0 0 0 0 0 0 0 ...
## $ cr-menez : num 0 0 14 0 0 4 0 0 8 0 ...
## $ cu-lepid : num 0 0 0 0 0 0 0 0 0 0 ...
## $ cy-gilbe : num 0 0 0 0 0 0 0 0 0 0 ...
## $ ge-brasi : num 0 0 3 0 0 0 0 0 1 0 ...
## $ he-margi : num 0 0 0 0 0 1 0 0 0 0 ...
## $ ho-malab : num 0 0 1 5 0 17 10 2 31 4 ...
## $ hy-pusar : num 0 0 9 2 0 43 2 0 11 0 ...
## $ le-melan : num 0 0 0 0 0 0 0 0 0 0 ...
## $ le-piau : num 0 0 3 0 0 1 3 0 2 1 ...
## $ le-taeni : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-costa : num 0 0 0 0 0 0 0 0 0 0 ...
## $ mo-lepid : num 0 1 39 0 0 1 0 0 0 0 ...
## $ or-nilot : num 0 2 36 0 0 77 0 0 138 0 ...
## $ pa-manag : num 0 0 0 0 0 0 0 0 0 0 ...
## $ pimel-sp : num 0 0 6 0 0 0 0 0 0 0 ...
## $ po-retic : num 0 0 0 0 0 20 0 0 5 0 ...
## $ po-vivip : num 0 0 47 15 0 221 32 0 326 10 ...
## $ pr-brevi : num 9 0 5 0 1 15 5 2 164 0 ...
## $ ps-rhomb : num 0 0 0 0 0 0 0 0 1 0 ...
## $ ps-genise: num 0 0 0 0 0 0 0 0 1 0 ...
## $ se-heter : num 0 0 40 14 4 60 0 0 38 0 ...
## $ se-piaba : num 0 0 68 0 0 0 0 0 0 0 ...
## $ se-spilo : num 0 0 0 0 0 0 0 0 1 0 ...
## $ st-noton : num 0 0 1 0 0 25 0 0 115 0 ...
## $ sy-marmo : num 0 0 0 0 0 0 1 0 0 0 ...
## $ te-chalc : num 0 0 0 0 0 0 0 0 0 0 ...
## $ tr-signa : num 0 0 18 0 0 15 0 0 7 0 ...
## [1] "list"
## [1] "data.frame"
```

O símbolo `?` é usado para acessar a documentação de uma função ou um pacote no R. Como mostrado acima você pode saber mais sobre a função `str()`, usando o comando `?str`. Isso vai abrir uma página no menu de ajuda com a descrição, os argumentos, os valores de retorno e os exemplos da função `str()`. Você também pode usar o símbolo `?` para obter informações sobre um pacote inteiro. Por exemplo, se você quiser saber mais sobre o pacote `openxlsx`, você pode digitar `?openxlsx`. Isso vai abrir uma página com a visão geral, a instalação, os recursos e as referências do pacote solicitado.

Podemos agora calcular o número e a proporção de zeros na matriz usando as funções `sum()` e `length()` (Você pode pesquisar o que faz a função `length()` usando o comando `?length`).

21.3.1 Tamanho da matriz

```

range(m_bruta) #menor e maior valores
length(m_bruta) #no. de colunas
ncol(m_bruta) #no. de N colunas
nrow(m_bruta) #no. de M linhas
sum(lengths(m_bruta)) #soma os nos. de colunas
length(as.matrix(m_bruta)) #tamanho da matriz m x n
sum(m_bruta == 0) # número de observações igual a zero
sum(m_bruta > 0) # número de observações maiores que zero
zeros <- (sum(m_bruta == 0)/length(as.matrix(m_bruta)))*100 #
  ↪ proporção de zeros na matriz
zeros

```

```

## [1] 0 511
## [1] 35
## [1] 35
## [1] 26
## [1] 910
## [1] 910
## [1] 716
## [1] 194
## [1] 78.68132

```

A matriz de dados apresenta um total de 910 valores que variam entre 0, 511 (menor e maior valores). A matriz $m \times n$ tem 26 linhas e 35 colunas. Existem 716 observações iguais a zero e 194 observações maiores que zero, representando um percentual de 78.7% dos valores sendo zeros.

Essas informações podem ser resumidas na Tabela 21.2 que será gerada abaixo.

```

tamanho <- data.frame(
  Comando = c("range", "length", "m cols", "n linhas", "Tamanho",
    ↪ "Tamanho",
    "Zeros", "Nao zeros", "% Zeros"),
  Resultado = c(paste(range(m_bruta), collapse = " - "),
    ↪ length(m_bruta), ncol(m_bruta),
    nrow(m_bruta), sum(lengths(m_bruta)),
    ↪ length(as.matrix(m_bruta)), sum(m_bruta ==
    ↪ 0),
    sum(m_bruta > 0), round(zeros, 1))
)
tamanho

```

21.4. CÁLCULO DE MATRIZ DE DISTÂNCIAS EUCLIDIANA (EUCLID)551

```
##      Comando Resultado
## 1      range      0 - 511
## 2      lenght      35
## 3      m cols      35
## 4      n linhas      26
## 5      Tamanho      910
## 6      Tamanho      910
## 7      Zeros        716
## 8      Nao zeros     194
## 9      % Zeros       78.7
```

Table 21.2: Resumo das informações sobre o tamanho da matriz

Comando	Resultado
range	0 - 511
length	35
m cols	35
n linhas	26
Tamanho	910
Tamanho	910
Zeros	716
Nao zeros	194
% Zeros	78.7

Ou seja, temos uma matriz de tamanho $m \times n$ igual a 26 objetos por 35 atributos, onde 78.68% dos valores da matriz são iguais a zero!

21.4 Cálculo de matriz de distâncias Euclidiana (euclid)

Agora vamos calcular a matriz de **distâncias euclidianas** (BORCARD; GILLET; LEGENDRE, 2018; LEGENDRE; LEGENDRE, 1998) entre as UA's usando a função `dist()` (pesquise o que faz essa função usando o comando `?dist`).

```
euclid <- dist(m_bruta, method = "euclidian", diag = TRUE, upper
  ↪ = FALSE)
#?dist
```

Pronto, calculamos a matriz de distâncias (Euclidiana). Agora podemos visualizar a matriz.

```

#euclid
str(euclid)
mode(euclid)
class(euclid)
length(as.matrix(euclid))
as.matrix(euclid)[1:6, 1:6] #mostra as 5 primeiras linhas e
  ↪ colunas da matriz

```

```

## 'dist' num [1:325] 98.4 228.5 29.2 27.1 294.1 ...
## - attr(*, "Size")= int 26
## - attr(*, "Labels")= chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## - attr(*, "Diag")= logi TRUE
## - attr(*, "Upper")= logi FALSE
## - attr(*, "method")= chr "euclidean"
## - attr(*, "call")= language dist(x = m_bruta, method = "euclidian", diag = TRUE, up
## [1] "numeric"
## [1] "dist"
## [1] 676
##           S-A-ZA1   S-R-CC1   S-R-CT1   S-R-CP1   S-A-TA1   S-R-CT2
## S-A-ZA1   0.00000   98.43780   228.5235   29.24038   27.09243   294.0629
## S-R-CC1   98.43780   0.00000   154.2433   82.79493   77.25283   261.3905
## S-R-CT1   228.52352   154.24331   0.00000   208.52338   209.69263   224.9133
## S-R-CP1   29.24038   82.79493   208.5234   0.00000   23.25941   271.4922
## S-A-TA1   27.09243   77.25283   209.6926   23.25941   0.00000   283.7869
## S-R-CT2   294.06292   261.39051   224.9133   271.49217   283.78689   0.0000

```

Note que a matriz `euclid` está como uma classe `dist`. Uma matriz do tipo `dist` no R é um objeto que armazena as distâncias entre as linhas de uma matriz ou um data frame. Ela é criada pela função `dist()`, que calcula as distâncias usando diferentes medidas, como “euclidean”, “manhattan”, “canberra”, “binary” ou “minkowski” (HORTON; KLEINMAN, 2015) (Figura 21.3).

Visualizando a matriz de distâncias, observamos que ela:

- é uma matriz quadrada que contém as distâncias entre cada par de elementos do conjunto de dados,
- terá a dimensão $m \times m$ (m =linhas, n =colunas) e,
- e cada elemento da matriz será a distância entre cada par de observações ou objetos.

A **matriz de distâncias é simétrica**, pois a distância entre i e j é igual à distância entre j e i . A matriz de distâncias também tem **diagonal zero**, pois a distância entre uma observação e ela mesma é zero.

21.4. CÁLCULO DE MATRIZ DE DISTÂNCIAS EUCLIDIANA (EUCLID)553

```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

Table 21.3: Medidas de distância disponíveis na função ‘dist()’ para calcular a distância entre dois pontos ou objetos em um espaço multidimensional.

Distância	Descrição
Euclidiana	Mede a distância entre dois pontos no espaço, seguindo o teorema de Pitágoras. É uma medida de distância direta entre dois pontos.
Manhattan	Também conhecida como distância da cidade, mede a distância como se estivesse dirigindo em uma cidade. A distância é a soma das diferenças absolutas de cada coordenada.
Canberra	Leva em consideração a proporção de diferenças em relação ao tamanho total das variáveis.
Binária	Mede a semelhança entre dois objetos. É 0 quando dois valores são iguais e 1 caso contrário.
Minkowski	É uma generalização da distância euclidiana e da distância de Manhattan. A distância é controlada por um parâmetro P, que determina a ordem da distância.

A matriz `euclid` está como uma classe `dist`, mas podemos transformá-la em uma classe `matrix` usando a função `as.matrix()`.

```
euclid_ma <- (as.matrix(euclid))
#View(euclid_ma)
str(euclid_ma)
mode(euclid_ma)
class(euclid_ma)
euclid_ma[1:5, 1:5] #mostra as 5 primeiras linhas e colunas da
↪ matriz
```

```
## num [1:26, 1:26] 0 98.4 228.5 29.2 27.1 ...
## - attr(*, "dimnames")=List of 2
## ..$ : chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## ..$ : chr [1:26] "S-A-ZA1" "S-R-CC1" "S-R-CT1" "S-R-CP1" ...
## [1] "numeric"
## [1] "matrix" "array"
##          S-A-ZA1  S-R-CC1  S-R-CT1  S-R-CP1  S-A-TA1
## S-A-ZA1   0.00000  98.43780 228.5235  29.24038  27.09243
## S-R-CC1  98.43780   0.00000 154.2433  82.79493  77.25283
## S-R-CT1 228.52352 154.24331   0.0000 208.52338 209.69263
## S-R-CP1  29.24038  82.79493 208.5234   0.00000  23.25941
## S-A-TA1  27.09243  77.25283 209.6926  23.25941   0.00000
```

21.5 Calculando o centróide da matriz de distâncias euclid

Primeiro algumas informações básicas da matriz

```
range(m_bruta)
range(euclid)
min(euclid)
max(euclid)
mean(euclid) #CENTROIDE!! OU Grand mean
sd(euclid) #Standard deviation
centroide <- mean(euclid)
centroide
```

```
## [1] 0 511
## [1] 16.27882 707.32666
## [1] 16.27882
## [1] 707.3267
## [1] 285.9043
## [1] 172.9708
## [1] 285.9043
```

A função `mean()` calcula a média de todos os valores da matriz de distâncias, ou seja, a média multivariada, que é o centróide. Nesse caso o **centroide assume o valor de 285.9**.

Usamos agora a fórmula $m*(m-1)/2$, onde m é o no. de objetos sendo comparados, para calcular quantas distâncias temos na nossa matriz.

```
length(euclid)
m <- nrow(m_bruta)
m
m*(m-1)/2
summary(euclid)
```

```
## [1] 325
## [1] 26
## [1] 325
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  16.28  142.70  242.82  285.90  423.64  707.33
```

Temos então que m é **26 objetos** (ou linhas), e portanto, a matriz de distâncias tem **325 valores**.

Fazemos agora um breve sumário do que foi calculado até agora com base na matriz de distâncias `euclid`.

```
Sumario1 <- cbind(min(euclid),
                  max(euclid),
                  sd(euclid),
                  mean(euclid),
                  length(euclid))
colnames(Sumario1) <- c("Minimo", "Maximo", "Desv.Padr", "Media",
  ↪ "m(m-1)/2")
rownames(Sumario1) <- ("Valores")
Sumario1
```

```
##           Minimo   Maximo Desv.Padr   Media m(m-1)/2
## Valores 16.27882 707.3267  172.9708 285.9043     325
```

21.6 Distribuição de frequências da matriz de distâncias euclid

O código abaixo vai plotar um histograma e um boxplot da distribuição de dados armazenada em `euclid`. Também é adicionada uma curva normal teórica ao histograma utilizando a média e o desvio padrão dos dados (Figura 21.5). Atente que o comando `par(mfrow=c(2,1))` define o layout dos gráficos, especificando

que serão plotados 2 gráficos em uma coluna. As funções `floor(min(euclid))`, `ceiling(max(euclid))` definem os limites dos graficos pelo valores mínimo e máximo do objeto (`euclid`).

```
range(euclid)
```

```
## [1] 16.27882 707.32666
```

```
par(mfrow=c(2,1))
hist(euclid,
      breaks = 15, #determina o no. de colunas do histograma
      xlim = range(floor(min(euclid)), ceiling(max(euclid))),
      xlab = "Distr. de Frequências",
      freq = FALSE)
curve(dnorm(x, mean=mean(euclid), sd=sd(euclid)), add=TRUE)
boxplot.default(euclid, horizontal = TRUE, frame = FALSE,
                 xlab="Distr. de Frequências",
                 ylim=c(floor(min(euclid)), ceiling(max(euclid))))
  ↪ #Limites do eixo Y
```

O comando abaixo apaga os gráficos, use-o apenas se necessário.


```
dev.off()
```

21.7 Procurando outliers

21.7.1 Listas de distâncias

Vamos agora criar uma lista com as distâncias em desvio padrão entre cada objeto e o **centróide**, baseada na matriz de distâncias `euclid_ma` (ou outra matriz de distâncias criada a partir de uma matriz relativizada/transformada ou bruta, dependendo do arquivo escolhido). As distâncias médias do centroide, expressas em desvios padrão, também podem ser chamadas de **z-scores**.

Para esse cálculo é necessário que a matriz de distâncias (do tipo `dist`) seja do tipo `matrix`. Por isso usamos o comando `as.matrix` e removemos a diagonal da nova matriz `euclid_ma`. Códigos a seguir.

Figure 21.5: Distribuições de frequências da matriz de distâncias `euclid`

21.7.1.1 Removendo os zeros da matriz de distâncias

```
library(matrixStats)
```

```
## Warning: pacote 'matrixStats' foi compilado no R versão 4.5.3
```

```
##
## Anexando pacote: 'matrixStats'
```

```
## O seguinte objeto é mascarado por 'package:dplyr':
##
##      count
```

```
library(moments)
euclid_ma <- as.matrix(euclid)
euclid_ma
range(euclid_ma) #valor errado
mean(euclid_ma) #valor errado
sd(euclid_ma) #valor errado
is.na(euclid_ma) <- euclid_ma==0 #atribui n.a. aos valores = 0
mean(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↳ calculo
mean(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↳ calculo
sd(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↳ calculo
#colMeans(euclid_ma, na.rm=T) #omite valores n.a. do calculo
#rowMeans(euclid_ma, na.rm=T) #omite valores n.a. do calculo
```

```
##           S-A-ZA1   S-R-CC1 S-R-CT1   S-R-CP1   S-A-TA1   S-R-CT2   S-R-CP2
## S-A-ZA1   0.00000  98.43780 228.5235  29.24038  27.09243 294.0629  53.40412
## S-R-CC1  98.43780   0.00000 154.2433  82.79493  77.25283 261.3905 108.10180
## S-R-CT1 228.52352 154.24331   0.0000 208.52338 209.69263 224.9133 224.09150
## S-R-CP1  29.24038  82.79493 208.5234   0.00000  23.25941 271.4922  49.22398
## S-A-TA1  27.09243  77.25283 209.6926  23.25941   0.00000 283.7869  57.82733
## S-R-CT2 294.06292 261.39051 224.9133 271.49217 283.78689   0.0000 268.95167
## S-R-CP2  53.40412 108.10180 224.0915  49.22398  57.82733 268.9517   0.00000
## S-A-TA2 183.74439 185.75791 261.8301 181.24845 166.66133 326.3327 190.15257
## S-R-CT3 460.42155 428.64437 366.6429 443.90877 453.59674 238.3799 438.54532
## S-R-CP3  34.17601  88.06816 215.2557  31.32092  33.13608 275.0436  40.37326
## S-A-TA3 333.86674 274.45765 269.9444 321.82604 309.19735 360.8213 334.61769
```

```

## S-R-CT4 187.51533 213.67265 273.0769 189.67604 191.60898 298.0084 190.90835
## S-R-CP4 81.58431 127.98437 226.6208 69.86415 85.24084 238.5351 57.30620
## S-A-TA4 478.64601 402.05970 359.7819 464.33932 453.15560 450.2344 478.08995
## B-A-MU1 190.62529 209.01196 287.5257 191.40272 190.90312 344.8086 197.56012
## B-R-ET1 36.13862 102.02941 228.2740 43.89761 42.52058 291.0859 63.79655
## B-A-GU1 16.27882 97.90301 227.0507 30.36445 28.40775 293.4110 55.07268
## B-R-PC2 91.52595 98.07650 204.8560 86.04650 84.49260 282.9558 103.56158
## B-A-MU2 119.74974 68.23489 165.6351 106.08958 103.04368 262.9848 125.71396
## B-A-GU2 110.95495 147.95607 249.2348 114.19282 113.77610 305.9902 122.87799
## B-R-PC3 151.57506 133.59266 183.3085 135.95588 140.16776 259.3260 157.58490
## B-A-MU3 534.53718 441.89592 367.2261 516.37293 513.70809 451.3635 530.43944
## B-A-GU3 353.04249 363.59180 396.0858 353.76829 353.56612 414.4539 356.90195
## B-R-PC4 89.73294 127.93748 229.5801 87.46999 89.97778 295.9341 103.55675
## B-A-MU4 641.28309 612.29405 595.5023 631.36598 633.67026 590.7597 633.81385
## B-A-GU4 230.36059 244.38903 302.0546 230.92640 230.49512 341.1700 236.11438
##          S-A-TA2  S-R-CT3  S-R-CP3  S-A-TA3  S-R-CT4  S-R-CP4  S-A-TA4
## S-A-ZA1 183.7444 460.4215 34.17601 333.8667 187.5153 81.58431 478.6460
## S-R-CC1 185.7579 428.6444 88.06816 274.4576 213.6726 127.98437 402.0597
## S-R-CT1 261.8301 366.6429 215.25566 269.9444 273.0769 226.62083 359.7819
## S-R-CP1 181.2484 443.9088 31.32092 321.8260 189.6760 69.86415 464.3393
## S-A-TA1 166.6613 453.5967 33.13608 309.1973 191.6090 85.24084 453.1556
## S-R-CT2 326.3327 238.3799 275.04363 360.8213 298.0084 238.53511 450.2344
## S-R-CP2 190.1526 438.5453 40.37326 334.6177 190.9084 57.30620 478.0899
## S-A-TA2 0.0000 478.9008 182.86060 198.3053 264.0038 200.93282 360.8130
## S-R-CT3 478.9008 0.0000 449.24826 478.0994 419.5474 411.12529 530.0566
## S-R-CP3 182.8606 449.2483 0.00000 324.5351 190.8612 74.14850 467.2216
## S-A-TA3 198.3053 478.0994 324.53505 0.0000 384.4750 344.01599 164.3624
## S-R-CT4 264.0038 419.5474 190.86121 384.4750 0.0000 195.29977 515.1932
## S-R-CP4 200.9328 411.1253 74.14850 344.0160 195.2998 0.00000 486.2016
## S-A-TA4 360.8130 530.0566 467.22157 164.3624 515.1932 486.20160 0.0000
## B-A-MU1 262.6481 494.5402 192.39023 377.5142 265.3413 207.01208 506.2549
## B-R-ET1 186.4457 461.2114 47.45524 334.1841 190.2735 88.34025 478.2384
## B-A-GU1 183.8777 462.0985 35.22783 333.2807 189.3278 82.22530 477.9676
## B-R-PC2 195.6246 447.5008 90.57041 315.9209 190.5282 122.53571 451.2815
## B-A-MU2 197.8686 427.9603 110.62549 282.7313 222.6971 140.52046 407.6175
## B-A-GU2 214.5623 466.3872 115.52922 352.2528 207.3089 137.12403 491.9075
## B-R-PC3 223.6672 423.6402 147.47542 315.7942 220.0114 170.50220 440.0898
## B-A-MU3 522.9532 505.9802 520.09038 399.2405 563.5140 534.39873 336.9926
## B-A-GU3 397.2719 518.7784 354.25273 483.3363 352.7846 362.13671 590.8849
## B-R-PC4 202.8398 461.7597 94.17006 341.0029 182.5541 119.84991 481.9544
## B-A-MU4 651.0146 647.9599 634.01104 643.0435 659.8833 626.19965 674.7548
## B-A-GU4 292.6124 476.7599 231.75849 398.4708 265.0623 244.09834 521.8716
##          B-A-MU1  B-R-ET1  B-A-GU1  B-R-PC2  B-A-MU2  B-A-GU2  B-R-PC3
## S-A-ZA1 190.6253 36.13862 16.27882 91.52595 119.74974 110.95495 151.5751
## S-R-CC1 209.0120 102.02941 97.90301 98.07650 68.23489 147.95607 133.5927
## S-R-CT1 287.5257 228.27396 227.05066 204.85605 165.63514 249.23483 183.3085

```

```

## S-R-CP1 191.4027 43.89761 30.36445 86.04650 106.08958 114.19282 135.9559
## S-A-TA1 190.9031 42.52058 28.40775 84.49260 103.04368 113.77610 140.1678
## S-R-CT2 344.8086 291.08590 293.41097 282.95583 262.98479 305.99020 259.3260
## S-R-CP2 197.5601 63.79655 55.07268 103.56158 125.71396 122.87799 157.5849
## S-A-TA2 262.6481 186.44570 183.87768 195.62464 197.86864 214.56235 223.6672
## S-R-CT3 494.5402 461.21145 462.09847 447.50084 427.96028 466.38718 423.6402
## S-R-CP3 192.3902 47.45524 35.22783 90.57041 110.62549 115.52922 147.4754
## S-A-TA3 377.5142 334.18408 333.28066 315.92088 282.73132 352.25275 315.7942
## S-R-CT4 265.3413 190.27349 189.32776 190.52821 222.69710 207.30895 220.0114
## S-R-CP4 207.0121 88.34025 82.22530 122.53571 140.52046 137.12403 170.5022
## S-A-TA4 506.2549 478.23843 477.96757 451.28151 407.61747 491.90751 440.0898
## B-A-MU1 0.0000 193.24078 183.63823 201.66556 151.28781 198.33557 225.3242
## B-R-ET1 193.2408 0.00000 36.53765 97.11334 119.98333 112.60107 151.2977
## B-A-GU1 183.6382 36.53765 0.00000 91.72786 115.33863 98.15294 149.6529
## B-R-PC2 201.6656 97.11334 91.72786 0.00000 114.92171 141.58390 114.7606
## B-A-MU2 151.2878 119.98333 115.33863 114.92171 0.00000 153.39817 143.1049
## B-A-GU2 198.3356 112.60107 98.15294 141.58390 153.39817 0.00000 173.1011
## B-R-PC3 225.3242 151.29772 149.65293 114.76062 143.10486 173.10113 0.0000
## B-A-MU3 505.4424 530.61097 531.72831 497.81221 422.87823 539.86572 476.5574
## B-A-GU3 381.5508 348.29729 342.49380 360.00556 364.76705 257.95736 337.1735
## B-R-PC4 205.1536 95.01579 89.16838 122.22520 142.70249 139.05035 150.8211
## B-A-MU4 498.8387 627.17462 635.41089 625.57414 550.83754 632.75193 618.9628
## B-A-GU4 289.1885 227.41592 219.20538 242.81886 251.58299 129.34837 239.0000
##          B-A-MU3 B-A-GU3 B-R-PC4 B-A-MU4 B-A-GU4
## S-A-ZA1 534.5372 353.0425 89.73294 641.2831 230.3606
## S-R-CC1 441.8959 363.5918 127.93748 612.2940 244.3890
## S-R-CT1 367.2261 396.0858 229.58005 595.5023 302.0546
## S-R-CP1 516.3729 353.7683 87.46999 631.3660 230.9264
## S-A-TA1 513.7081 353.5661 89.97778 633.6703 230.4951
## S-R-CT2 451.3635 414.4539 295.93411 590.7597 341.1700
## S-R-CP2 530.4394 356.9019 103.55675 633.8139 236.1144
## S-A-TA2 522.9532 397.2719 202.83984 651.0146 292.6124
## S-R-CT3 505.9802 518.7784 461.75968 647.9599 476.7599
## S-R-CP3 520.0904 354.2527 94.17006 634.0110 231.7585
## S-A-TA3 399.2405 483.3363 341.00293 643.0435 398.4708
## S-R-CT4 563.5140 352.7846 182.55410 659.8833 265.0623
## S-R-CP4 534.3987 362.1367 119.84991 626.1996 244.0983
## S-A-TA4 336.9926 590.8849 481.95435 674.7548 521.8716
## B-A-MU1 505.4424 381.5508 205.15360 498.8387 289.1885
## B-R-ET1 530.6110 348.2973 95.01579 627.1746 227.4159
## B-A-GU1 531.7283 342.4938 89.16838 635.4109 219.2054
## B-R-PC2 497.8122 360.0056 122.22520 625.5741 242.8189
## B-A-MU2 422.8782 364.7670 142.70249 550.8375 251.5830
## B-A-GU2 539.8657 257.9574 139.05035 632.7519 129.3484
## B-R-PC3 476.5574 337.1735 150.82109 618.9628 239.0000
## B-A-MU3 0.0000 624.8288 534.66812 519.9981 566.2808

```

```
## B-A-GU3 624.8288 0.0000 357.35557 707.3267 134.3763
## B-R-PC4 534.6681 357.3556 0.00000 641.2628 241.6402
## B-A-MU4 519.9981 707.3267 641.26282 0.0000 669.3982
## B-A-GU4 566.2808 134.3763 241.64023 669.3982 0.0000
## [1] 0.0000 707.3267
## [1] 274.908
## [1] 178.1842
## [1] 285.9043
## [1] 285.9043
## [1] 172.8375
```

21.7.1.2 Criando uma Lista

```
centroide_ma <- mean(euclid_ma, na.rm=T)
av.dist <- (as.matrix(colMeans(euclid_ma, na.rm=T)))
av.desvpad <- (as.matrix(colSds(euclid_ma, na.rm=T)))
dp.centroide_ma <- (av.dist-centroide_ma)/(colSds(av.dist)) #ou
  ↪ z-scores
list <- as.matrix(cbind(av.dist, av.desvpad, dp.centroide_ma))
list
```

```
##           [,1]      [,2]      [,3]
## S-A-ZA1 202.2608 175.36143 -0.74136373
## S-R-CC1 205.9912 142.40233 -0.70830031
## S-R-CT1 266.3790  93.46194 -0.17306037
## S-R-CP1 195.7828 170.97514 -0.79878039
## S-A-TA1 195.8495 170.39163 -0.79818963
## S-R-CT2 317.0479  82.87727  0.27603716
## S-R-CP2 207.1435 167.09006 -0.69808647
## S-A-TA2 268.5172 124.64348 -0.15410841
## S-R-CT3 455.6678  68.84928  1.50467759
## S-R-CP3 199.1922 170.79087 -0.76856181
## S-A-TA3 347.0119  92.95522  0.54161944
## S-R-CT4 280.9253 131.44373 -0.04413038
## S-R-CP4 217.3521 157.62618 -0.60760370
## S-A-TA4 458.7988  93.50892  1.53242940
## B-A-MU1 278.0482 116.17286 -0.06963167
## B-R-ET1 205.3272 169.74682 -0.71418525
## B-A-GU1 200.2219 174.32564 -0.75943496
## B-R-PC2 215.0274 152.54520 -0.62820821
## B-A-MU2 210.8910 128.79692 -0.66487097
## B-A-GU2 229.0481 151.90782 -0.50393825
## B-R-PC3 235.2979 130.07777 -0.44854354
```

```
## B-A-MU3 499.5754 64.70789 1.89384716
## B-A-GU3 394.6795 116.02951 0.96411611
## B-R-PC4 225.0953 158.58714 -0.53897264
## B-A-MU4 624.1237 45.46670 2.99776610
## B-A-GU4 298.2560 130.86907 0.10947773
```

Ordenamos as distâncias da maior para a menor.

```
colnames(list, do.NULL = FALSE)
colnames(list) <- c("Av.Dist", "Av.StDev", "DP.Centroide")
list2 <- list[order(list[,1], decreasing = TRUE),] #[,1] ou o
  ↪ nome da coluna
list2
```

```
## [1] "col1" "col2" "col3"
##           Av.Dist  Av.StDev DP.Centroide
## B-A-MU4 624.1237 45.46670 2.99776610
## B-A-MU3 499.5754 64.70789 1.89384716
## S-A-TA4 458.7988 93.50892 1.53242940
## S-R-CT3 455.6678 68.84928 1.50467759
## B-A-GU3 394.6795 116.02951 0.96411611
## S-A-TA3 347.0119 92.95522 0.54161944
## S-R-CT2 317.0479 82.87727 0.27603716
## B-A-GU4 298.2560 130.86907 0.10947773
## S-R-CT4 280.9253 131.44373 -0.04413038
## B-A-MU1 278.0482 116.17286 -0.06963167
## S-A-TA2 268.5172 124.64348 -0.15410841
## S-R-CT1 266.3790 93.46194 -0.17306037
## B-R-PC3 235.2979 130.07777 -0.44854354
## B-A-GU2 229.0481 151.90782 -0.50393825
## B-R-PC4 225.0953 158.58714 -0.53897264
## S-R-CP4 217.3521 157.62618 -0.60760370
## B-R-PC2 215.0274 152.54520 -0.62820821
## B-A-MU2 210.8910 128.79692 -0.66487097
## S-R-CP2 207.1435 167.09006 -0.69808647
## S-R-CC1 205.9912 142.40233 -0.70830031
## B-R-ET1 205.3272 169.74682 -0.71418525
## S-A-ZA1 202.2608 175.36143 -0.74136373
## B-A-GU1 200.2219 174.32564 -0.75943496
## S-R-CP3 199.1922 170.79087 -0.76856181
## S-A-TA1 195.8495 170.39163 -0.79818963
## S-R-CP1 195.7828 170.97514 -0.79878039
```

21.7.2 Distribuição de frequências das distâncias médias para o centróide `av.dist`

Observe o valor máximo e mínimo gerados pela função `range()` e substitua nas linhas de código assinaladas com `#`. Aqui o menor valor foi 195.7828431 e o maior valor foi 624.1236964. Use valores maiores para facilitar a visualização no gráfico (Figura 21.6).


```
par(mfrow=c(3,1))
hist(list2[, "Av.Dist"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias (em dp) para o
     ↪ centróide",
     main = "Distribuição de Frequência da distância média para o
     ↪ centróide",
     xlim = range(floor(min(av.dist)), ceiling(max(av.dist))),
     ↪ #substitua aqui o menor e maior valor do `range()`
     freq = T)
hist(list2[, "Av.Dist"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias (em dp) para o
     ↪ centróide",
     main = "Curva de normalidade ajustada para a Distribuição de
     ↪ Frequência",
     xlim = range(floor(min(av.dist)), ceiling(max(av.dist))),
     ↪ #substitua aqui o menor e maior valor do `range()`
     freq = F)
curve(dnorm(x, mean=mean(list2[, "Av.Dist"]), sd=sd(list2[,
     ↪ "Av.Dist"])), add=TRUE)
boxplot.default(list2[, "Av.Dist"], horizontal = TRUE, frame =
     ↪ FALSE,
                xlab="Distr. de Frequências",
                ylim=c(floor(min(av.dist)),
                ↪ ceiling(max(av.dist)))) #substitua aqui o
                ↪ menor e maior valor do `range()`
```

```
par(mfrow=c(1,1))
```



21.7.2.1 Distribuição de frequências dos desvios padrões das distâncias médias para o centróide `DP.Centroide`

Observe o valor máximo e mínimo gerados pela função `range()` e substitua nas linhas de código assinaladas com `#`. Aqui o menor valor foi -0.7987804 e o maior

Distribuição de Frequência da distância média para o centroide



Curva de normalidade ajustada para a Distribuição de Frequência



valor foi 2.9977661. Use valores maiores para facilitar a visualização no gráfico (Figura 21.7).

```
range(dp.centroide_ma)
par(mfrow=c(3,1))
hist(list2[, "DP.Centroide"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias dos desvios
     ↪ padrões para o centroide",
     main = "Distribuição de Frequência dos desvio padrões das
     ↪ distâncias médias para o centroide",
     xlim = range(floor(min(dp.centroide_ma)),
     ↪ ceiling(max(dp.centroide_ma))), #substitua aqui o menor
     ↪ e maior valor do `range()`
     freq = T)
hist(list2[, "DP.Centroide"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias dos desvios
     ↪ padrões das distâncias médias para o centroide",
     main = "Curva de normalidade ajustada para a Distribuição de
     ↪ Frequência",
     xlim = range(floor(min(dp.centroide_ma)),
     ↪ ceiling(max(dp.centroide_ma))), #substitua aqui o menor
     ↪ e maior valor do `range()`
     freq = F)
curve(dnorm(x, mean=mean(list2[, "DP.Centroide"]), sd=sd(list2[,
     ↪ "DP.Centroide"])), add=TRUE)
boxplot.default(list2[, "DP.Centroide"], horizontal = TRUE, frame
     ↪ = FALSE,
                xlab="Distr. de Frequências",
                ylim=c(floor(min(dp.centroide_ma)),
                ↪ ceiling(max(dp.centroide_ma)))) #substitua
                ↪ aqui o menor e maior valor do `range()`
```

```
par(mfrow=c(1,1))
```

```
## [1] -0.7987804 2.9977661
```

Se necessário apague os gráficos




Distribuição de Frequência dos desvio padrões das distâncias médias para o centroide**Curva de normalidade ajustada para a Distribuição de Frequência**

Figure 21.7: Distribuição de frequências dos desvios padrões das distâncias médias para o centroide.

```
dev.off()
```

21.8 Lista final de outliers

Agora fazemos a lista final de distâncias com os outliers baseados em um ‘cutoff’.

```
cutoff <- 2.0
```

Note que o ‘cutoff’ foi estabelecido no código acima no vetor ‘cutoff <-’. Ou seja, o ‘cutoff’ definindo quem serão considerados outliers, foi estabelecido como sendo valores de **+2.0** e **-2.0** desvios padrões da média multivariada ou centroide. Valores acima ou abaixo do ‘cutoff’ definido recebem o nome “OUT”, na coluna “Outliers”. Criada com o código abaixo.

```
library(gt)
format(cutoff, nsmall = 1)
listf <- as.data.frame(list2)
listf$Outliers <- ifelse(listf$DP.Centroide > cutoff #CUTOFF MENOR
  ↳ QUE - 'cutoff'
                        & listf$DP.Centroide < cutoff, #CUTOFF
  ↳ MAIOR QUE 'cutoff'
                        "", "OUT")

listf
gt(cbind(Sitios=rownames(listf), listf))
```

```
## [1] "2.0"
##           Av.Dist  Av.StDev DP.Centroide Outliers
## B-A-MU4  624.1237  45.46670  2.99776610      OUT
## B-A-MU3  499.5754  64.70789  1.89384716
## S-A-TA4  458.7988  93.50892  1.53242940
## S-R-CT3  455.6678  68.84928  1.50467759
## B-A-GU3  394.6795 116.02951  0.96411611
## S-A-TA3  347.0119  92.95522  0.54161944
## S-R-CT2  317.0479  82.87727  0.27603716
## B-A-GU4  298.2560 130.86907  0.10947773
## S-R-CT4  280.9253 131.44373 -0.04413038
## B-A-MU1  278.0482 116.17286 -0.06963167
## S-A-TA2  268.5172 124.64348 -0.15410841
## S-R-CT1  266.3790  93.46194 -0.17306037
```

```
## B-R-PC3 235.2979 130.07777 -0.44854354
## B-A-GU2 229.0481 151.90782 -0.50393825
## B-R-PC4 225.0953 158.58714 -0.53897264
## S-R-CP4 217.3521 157.62618 -0.60760370
## B-R-PC2 215.0274 152.54520 -0.62820821
## B-A-MU2 210.8910 128.79692 -0.66487097
## S-R-CP2 207.1435 167.09006 -0.69808647
## S-R-CC1 205.9912 142.40233 -0.70830031
## B-R-ET1 205.3272 169.74682 -0.71418525
## S-A-ZA1 202.2608 175.36143 -0.74136373
## B-A-GU1 200.2219 174.32564 -0.75943496
## S-R-CP3 199.1922 170.79087 -0.76856181
## S-A-TA1 195.8495 170.39163 -0.79818963
## S-R-CP1 195.7828 170.97514 -0.79878039
```

21.9 Particionando a matriz

Talvez seja necessário particionar a matriz bruta para remover os outliers. Isso pode ser feito com os códigos abaixo. Atente para o **vetor part**. Ele define quais objetos ou UA's serão particionados.

```
part <- c("B-A-MU4", "B-A-MU3", "S-A-TA4", "S-R-CT3")
part
```

```
## [1] "B-A-MU4" "B-A-MU3" "S-A-TA4" "S-R-CT3"
```

```
m_bruta_part <- m_bruta[!(row.names(m_bruta) %in% c(part)),]
#m_bruta_part
```

Criamos uma nova matriz particionada **m_bruta_part** sem **B-A-MU4**, **B-A-MU3**, **S-A-TA4**, **S-R-CT3**, que apresentavam valores acima do cutoff para outliers.

ATENÇÃO

Quando deletamos linhas ou colunas da matriz de dados comunitária, precisamos ver se isso não gerou linhas ou colunas vazias. Observe por exemplo a espécie *Apareiodon davisí*³ (Figura 21.8). Por exemplo, se uma determinada espécie só ocorre em uma UA, e aquela UA foi removida, essa espécie não consta mais

³A etimologia do nome *Apareiodon* vem do Grego, *a*, sem, *pareia*, lateral ou bochecha, e *odous* dentição, em referencia a ausência de tentes laterais no aparato bucal dessa espécie.

em nenhuma UA e por isso a sua soma vai ser igual a zero. Isso aconteceu com a espécie *Pseudancistrus genisetiger*⁴ (Figura 21.9). Essa espécie precisará ser removida.

Use o a função `View(m_bruta_part)` e procure linhas ou colunas na matriz `m_bruta_part` onde todos os valores são zero. Quais espécies você encontrou que deixaram de ocorrer na comunidade depois que as UA's outliers foram removidas?.

Complicado? Os códigos abaixo resolvem isso, e mostram algumas propriedades da nova matriz `m_bruta_part2` depois de particionada pela segunda vez para remover linhas/colunas “zeradas”.

```
sum <- colSums(m_bruta_part)
sum
zero_sum_cols <- names(which(colSums(m_bruta_part) == 0))
zero_sum_cols #nomes das espécies zeradas
m_bruta_part2 <- m_bruta_part[(colSums(m_bruta_part) != 0)] #em
  ↳ != a exclamação inverte o sentido
zero_sum_cols2 <- names(which(colSums(m_bruta_part2) == 0))
zero_sum_cols2 #nomes das espécies zeradas
sum<-colSums(m_bruta_part2)
sum
#m_bruta_part2
#m_bruta_part2 <- as.matrix(m_bruta_part2)
str(m_bruta_part2)
length(as.matrix(m_bruta_part2))
```

```
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
##      27      1040      94      432      70      118      2      1
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
##      19      21      131      364      2      69      60      2
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
##      11      1      1      41      697      554      6      64
## po-vivip pr-brevi ps-rhomb ps-genise se-heter se-piaba se-spilo st-noton
##      441      111      0      0      258      68      0      90
## sy-marmo te-chalc tr-signa
##      1      134      201
## [1] "ps-rhomb" "ps-genise" "se-spilo"
## character(0)
## ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro co-heter
##      27      1040      94      432      70      118      2      1
## cr-menez cu-lepid cy-gilbe ge-brasi he-margi ho-malab hy-pusar le-melan
```

⁴A etimologia do nome *Pseudancistrus* vem do Grego, *pseudes*, falso, e *agkistron*, gancho, em referência a falsos ganchos presentes na cabeça em algumas espécies do gênero.



Figure 21.8: **Apareiodon davisi**, importante espécie bentopelágica das bacias dos rios Jaguaribe e Paraíba. Brazil, by Ramos, T.P.A. Fonte: <<https://www.fishbase.se/summary/Astianax-bimaculatus.html>>



```

##      19      21      131      364      2      69      60      2
## le-piau le-taeni mo-costa mo-lepid or-nilot pa-manag pimel-sp po-retic
##      11      1      1      41      697      554      6      64
## po-vivip pr-brevi se-heter se-piaba st-noton sy-marmo te-chalc tr-signa
##      441      111      258      68      90      1      134      201
## 'data.frame':  22 obs. of  32 variables:
## $ ap-davis: num  0 0 0 0 0 0 0 0 0 0 ...
## $ as-bimac: num  1 99 194 19 23 142 5 46 16 234 ...
## $ as-fasci: num  0 0 55 0 1 3 1 0 0 7 ...
## $ ch-bimac: num  0 0 0 0 13 3 0 178 0 238 ...
## $ ci-ocela: num  0 0 0 0 0 0 40 0 13 0 ...
## $ ci-orien: num  0 0 5 0 0 69 9 0 24 0 ...
## $ co-macro: num  0 0 0 0 0 0 0 0 0 2 ...
## $ co-heter: num  0 0 1 0 0 0 0 0 0 0 ...
## $ cr-menez: num  0 0 14 0 0 4 0 0 0 0 ...
## $ cu-lepid: num  0 0 0 0 0 0 0 0 0 0 ...
## $ cy-gilbe: num  0 0 0 0 0 0 0 0 0 0 ...
## $ ge-brasi: num  0 0 3 0 0 0 0 0 0 0 ...
## $ he-margi: num  0 0 0 0 0 1 0 0 0 0 ...
## $ ho-malab: num  0 0 1 5 0 17 10 2 4 20 ...
## $ hy-pusar: num  0 0 9 2 0 43 2 0 0 0 ...
## $ le-melan: num  0 0 0 0 0 0 0 0 0 0 ...
## $ le-piau : num  0 0 3 0 0 1 3 0 1 0 ...
## $ le-taeni: num  0 0 0 0 0 0 0 0 0 0 ...
## $ mo-costa: num  0 0 0 0 0 0 0 0 0 0 ...
## $ mo-lepid: num  0 1 39 0 0 1 0 0 0 0 ...
## $ or-nilot: num  0 2 36 0 0 77 0 0 0 0 ...
## $ pa-manag: num  0 0 0 0 0 0 0 0 0 0 ...
## $ pimel-sp: num  0 0 6 0 0 0 0 0 0 0 ...
## $ po-retic: num  0 0 0 0 0 20 0 0 0 0 ...
## $ po-vivip: num  0 0 47 15 0 221 32 0 10 0 ...
## $ pr-brevi: num  9 0 5 0 1 15 5 2 0 0 ...
## $ se-heter: num  0 0 40 14 4 60 0 0 0 0 ...
## $ se-piaba: num  0 0 68 0 0 0 0 0 0 0 ...
## $ st-noton: num  0 0 1 0 0 25 0 0 0 0 ...
## $ sy-marmo: num  0 0 0 0 0 0 1 0 0 0 ...
## $ te-chalc: num  0 0 0 0 0 0 0 0 0 0 ...
## $ tr-signa: num  0 0 18 0 0 15 0 0 0 0 ...
## [1] 704

```

21.10 Exportando a matrix final de trabalho

Agora vamos exportar a matrix de trabalho, nesse caso a matrix `m_bruta_part2`, como um arquivo de valores separados por vírgula

(`m_bruta_part2csv.csv`). Na verdade, separado por ";", como definido na função `sep = ";"`. O arquivo será exportado para o diretório de trabalho. Na mesma sequência de códigos, importamos `m_bruta_part2csv.csv` como nossa matriz de trabalho `m_trab`.

```
df <- data.frame(Sites = rownames(m_bruta), m_bruta,
                 row.names = NULL,
                 check.names = FALSE) #add titulo a primeira
                                     ↪ coluna

write.table(m_bruta_part2, "m_trabcsv.csv",
            sep = ";", dec = ".", #"\t",
            row.names = TRUE,
            quote = TRUE,
            append = FALSE)

m_trab <- read.csv("m_trabcsv.csv",
                  sep = ";", dec = ".",
                  row.names = 1,
                  header = TRUE,
                  na.strings = NA,
                  check.names = FALSE, #impede que o R mude os
                                      ↪ nomes das colunas
                  col.names = gsub("(^|_)([a-z])", "\\1\\U\\2",
                                   names(m_trab), perl = TRUE))
```

- Inicial Maiuscula: `col.names = gsub("(^|_)([a-z])", "\\1\\U\\2", names(m_trab), perl = TRUE))`
- Substituição: `col.names = gsub("-", ".", names(m_trab))`
- A função `header=` especifica se o arquivo de entrada contém uma linha de cabeçalho com os nomes das colunas, `row.names` especifica qual coluna no arquivo de entrada deve ser usada como os nomes das linhas, e se `NULL`, os nomes das linhas são gerados como números

Agora é com você...Refaça toda a análise com a matriz bruta particionada `m_bruta_part2`

Apêndices

Outras formas de fazer a partição

```
m_bruta_part2 <- m_bruta_part
               colSums(abs(m_bruta_part), na.rm = F) 0
m_bruta_part2 <- subset(m_bruta_part, colSums != 0) m_bruta_part2 <-
m_bruta_part
               , colSums(m_bruta_part != 0) 0
```

Código

```
range(euclidma) par(mfrow=c(2,1)) hist(euclidma, breaks = 15, #deter-
mina o no. de colunas do histograma xlim = range(floor(min(euclidma)),
ceiling(max(euclidma))), xlab = "Distr. de Frequências", freq = FALSE)
curve(dnorm(x, mean=mean(euclidma), sd=sd(euclidma)), add=TRUE) box-
plot.default(euclidma, horizontal = TRUE, frame = FALSE, xlab="Distr. de
Frequências", ylim=c(floor(min(euclidma)), ceiling(max(euclidma))))
```

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executá-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

```
## dev.off() #apaga os graficos, se houver algum
## rm(list=ls(all=TRUE)) #limpa a memória
## cat("\014") #limpa o console
## install.packages("openxlsx") #importa arquivos do excel
## install.packages("moments") #calcula assimetria e curtose dos
↪ dados
## install.packages("matrixStats") #fornece funções rápidas para
↪ a estatística de matrizes
## install.packages("gt") #ferramenta para criação de tabelas
↪ bonitas e personalizáveis
## getwd()
## setwd("C:/Seu/Diretório/De/Trabalho")
library(openxlsx)
m_bruta <- read.xlsx(
↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/peixes06.xlsx"
↪ ,
```

```

        rowNames = T, colNames = T,
        sheet = "Sheet1")

str(m_bruta)
m_bruta_ma <- as.matrix(m_bruta) #lê m_bruta como uma matriz
str(m_bruta_ma)
#m_bruta
m_bruta_ma[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas
  ↳ de 1 a 5.
#m_bruta <- (m_bruta)    # <1>
#View(m_bruta)
print(m_bruta)
head(m_bruta)
str(m_bruta)
mode(m_bruta)
class(m_bruta)
#?str
range(m_bruta) #menor e maior valores
length(m_bruta) #no. de colunas
ncol(m_bruta) #no. de N colunas
nrow(m_bruta) #no. de M linhas
sum(lengths(m_bruta)) #soma os nos. de colunas
length(as.matrix(m_bruta)) #tamanho da matriz m x n
sum(m_bruta == 0) # número de observações igual a zero
sum(m_bruta > 0) # número de observações maiores que zero
zeros <- (sum(m_bruta == 0)/length(as.matrix(m_bruta)))*100 #
  ↳ proporção de zeros na matriz
zeros
tamanho <- data.frame(
  Função = c("range", "length", "m cols", "n linhas", "Tamanho",
  ↳ "Tamanho",
    "Zeros", "Nao zeros", "% Zeros"),
  Resultado = c(paste(range(m_bruta), collapse = " - "),
  ↳ length(m_bruta), ncol(m_bruta),
    nrow(m_bruta), sum(lengths(m_bruta)),
    ↳ length(as.matrix(m_bruta)), sum(m_bruta ==
    ↳ 0),
    sum(m_bruta > 0), round(zeros, 1))
)
tamanho
knitr::kable(tamanho, format = "markdown", caption = "Resumo das
  ↳ informações sobre o tamanho da matriz")
euclid <- dist(m_bruta, method = "euclidian", diag = TRUE, upper
  ↳ = FALSE)
#?dist
#euclid

```

```

str(euclid)
mode(euclid)
class(euclid)
length(as.matrix(euclid))
as.matrix(euclid)[1:6, 1:6] #mostra as 5 primeiras linhas e
  ↪ 5 primeiras colunas da matriz
euclid_ma <- (as.matrix(euclid))
#View(euclid_ma)
str(euclid_ma)
mode(euclid_ma)
class(euclid_ma)
euclid_ma[1:5, 1:5] #mostra as 5 primeiras linhas e colunas da
  ↪ 5 primeiras colunas da matriz
range(m_bruta)
range(euclid)
min(euclid)
max(euclid)
mean(euclid) #CENTROIDE!! OU Grand mean
sd(euclid) #Standard deviation
centroide <- mean(euclid)
centroide
length(euclid)
m <- nrow(m_bruta)
m
m*(m-1)/2
summary(euclid)
Sumario1 <- cbind(min(euclid),
                  max(euclid),
                  sd(euclid),
                  mean(euclid),
                  length(euclid))
colnames(Sumario1) <- c("Minimo", "Maximo", "Desv.Padr", "Media",
  ↪ "m(m-1)/2")
rownames(Sumario1) <- ("Valores")
Sumario1
range(euclid)
par(mfrow=c(2,1))
hist(euclid,
     breaks = 15, #determina o no. de colunas do histograma
     xlim = range(floor(min(euclid)), ceiling(max(euclid))),
     xlab = "Distr. de Frequências",
     freq = FALSE)
curve(dnorm(x, mean=mean(euclid), sd=sd(euclid)), add=TRUE)
boxplot.default(euclid, horizontal = TRUE, frame = FALSE,
                xlab="Distr. de Frequências",

```

```

        ylim=c(floor(min(euclid)), ceiling(max(euclid)))
        ↪ #Limites do eixo Y

## dev.off()
library(matrixStats)
library(moments)
euclid_ma <- as.matrix(euclid)
euclid_ma
range(euclid_ma) #valor errado
mean(euclid_ma) #valor errado
sd(euclid_ma) #valor errado
is.na(euclid_ma) <- euclid_ma==0 #atribui n.a. aos valores = 0
mean(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↪ calculo
mean(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↪ calculo
sd(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↪ calculo
#colMeans(euclid_ma, na.rm=T) #omite valores n.a. do calculo
#rowMeans(euclid_ma, na.rm=T) #omite valores n.a. do calculo
centroide_ma <- mean(euclid_ma, na.rm=T)
av.dist <- (as.matrix(colMeans(euclid_ma, na.rm=T)))
av.desvpd <- (as.matrix(colSds(euclid_ma, na.rm=T)))
dp.centroide_ma <- (av.dist-centroide_ma)/(colSds(av.dist)) #ou
  ↪ z-scores
list <- as.matrix(cbind(av.dist, av.desvpd, dp.centroide_ma))
list
colnames(list, do.NULL = FALSE)
colnames(list) <- c("Av.Dist", "Av.StDev", "DP.Centroide")
list2 <- list[order(list[,1], decreasing = TRUE),] #[,1] ou o
  ↪ nome da coluna
list2
par(mfrow=c(3,1))
hist(list2[, "Av.Dist"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias (em dp) para o
       ↪ centroide",
     main = "Distribuição de Frequência da distância média para o
       ↪ centroide",
     xlim = range(floor(min(av.dist)), ceiling(max(av.dist))),
       ↪ #substitua aqui o menor e maior valor do `range()`
     freq = T)
hist(list2[, "Av.Dist"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias (em dp) para o
       ↪ centroide",

```

```

    main = "Curva de normalidade ajustada para a Distribuição de
    ↪ Frequência",
    xlim = range(floor(min(av.dist)), ceiling(max(av.dist))),
    ↪ #substitua aqui o menor e maior valor do `range()`
    freq = F)
curve(dnorm(x, mean=mean(list2[, "Av.Dist"]), sd=sd(list2[,
    ↪ "Av.Dist"])), add=TRUE)
boxplot.default(list2[, "Av.Dist"], horizontal = TRUE, frame =
    ↪ FALSE,
                    xlab="Distr. de Frequências",
                    ylim=c(floor(min(av.dist)),
    ↪ ceiling(max(av.dist))) #substitua aqui o
    ↪ menor e maior valor do `range()`
par(mfrow=c(1,1))
range(dp.centroide_ma)
par(mfrow=c(3,1))
hist(list2[, "DP.Centroide"],
    breaks = 15, #determina o no. de colunas do histograma
    xlab = "Distr. de Frequências das Distâncias dos desvios
    ↪ padrões para o centroide",
    main = "Distribuição de Frequência dos desvio padrões das
    ↪ distâncias médias para o centroide",
    xlim = range(floor(min(dp.centroide_ma)),
    ↪ ceiling(max(dp.centroide_ma))), #substitua aqui o menor
    ↪ e maior valor do `range()`
    freq = T)
hist(list2[, "DP.Centroide"],
    breaks = 15, #determina o no. de colunas do histograma
    xlab = "Distr. de Frequências das Distâncias dos desvios
    ↪ padrões das distâncias médias para o centroide",
    main = "Curva de normalidade ajustada para a Distribuição de
    ↪ Frequência",
    xlim = range(floor(min(dp.centroide_ma)),
    ↪ ceiling(max(dp.centroide_ma))), #substitua aqui o menor
    ↪ e maior valor do `range()`
    freq = F)
curve(dnorm(x, mean=mean(list2[, "DP.Centroide"]), sd=sd(list2[,
    ↪ "DP.Centroide"])), add=TRUE)
boxplot.default(list2[, "DP.Centroide"], horizontal = TRUE, frame
    ↪ = FALSE,
                    xlab="Distr. de Frequências",
                    ylim=c(floor(min(dp.centroide_ma)),
    ↪ ceiling(max(dp.centroide_ma))) #substitua
    ↪ aqui o menor e maior valor do `range()`
par(mfrow=c(1,1))

```

```

## dev.off()
cutoff <- 2.0
library(gt)
format(cutoff, nsmall = 1)
listf <- as.data.frame(list2)
listf$Outliers <- ifelse(listf$DP.Centroide>cutoff #CUTOFF MENOR
  ↪ QUE -'cutoff
                                & listf$DP.Centroide<cutoff, #CUTOFF
  ↪ MAIOR QUE 'cutoff'
  "", "OUT")

listf
gt(cbind(Sitios=rownames(listf),listf))
part <- c("B-A-MU4", "B-A-MU3", "S-A-TA4", "S-R-CT3")
part
m_bruta_part <- m_bruta[!(rownames(m_bruta) %in% c(part)),]
#m_bruta_part
sum <- colSums(m_bruta_part)
sum
zero_sum_cols <- names(which(colSums(m_bruta_part) == 0))
zero_sum_cols #nomes das espécies zeradas
m_bruta_part2 <- m_bruta_part[(colSums(m_bruta_part) != 0)] #em
  ↪ != a exclamação inverte o sentido
zero_sum_cols2 <- names(which(colSums(m_bruta_part2) == 0))
zero_sum_cols2 #nomes das espécies zeradas
sum<-colSums(m_bruta_part2)
sum
#m_bruta_part2
#m_bruta_part2 <- as.matrix(m_bruta_part2)
str(m_bruta_part2)
length(as.matrix(m_bruta_part2))
## df <- data.frame(Sites = rownames(m_bruta), m_bruta,
##                  row.names = NULL,
##                  check.names = FALSE) #add titulo a primeira
  ↪ coluna
##
## write.table(m_bruta_part2, "m_trabcsv.csv",
##            sep = ";", dec = ".", #"t",
##            row.names = TRUE,
##            quote = TRUE,
##            append = FALSE)
##
## m_trab <- read.csv("m_trabcsv.csv",
##                  sep = ";", dec = ".",
##                  row.names = 1,
##                  header = TRUE,

```

```
##                               na.strings = NA,  
##                               check.names = FALSE, #impede que o R mude  
↪ os nomes das colunas  
##                               col.names = gsub("(^|_)([a-z])",  
↪ "\\1\\|\\2",  
##                               names(m_trab), perl =  
↪ TRUE))
```

Referências

Sitios	Av.Dist	Av.StDev	DP.Centroide	Outliers
B-A-MU4	624.1237	45.46670	2.99776610	OUT
B-A-MU3	499.5754	64.70789	1.89384716	
S-A-TA4	458.7988	93.50892	1.53242940	
S-R-CT3	455.6678	68.84928	1.50467759	
B-A-GU3	394.6795	116.02951	0.96411611	
S-A-TA3	347.0119	92.95522	0.54161944	
S-R-CT2	317.0479	82.87727	0.27603716	
B-A-GU4	298.2560	130.86907	0.10947773	
S-R-CT4	280.9253	131.44373	-0.04413038	
B-A-MU1	278.0482	116.17286	-0.06963167	
S-A-TA2	268.5172	124.64348	-0.15410841	
S-R-CT1	266.3790	93.46194	-0.17306037	
B-R-PC3	235.2979	130.07777	-0.44854354	
B-A-GU2	229.0481	151.90782	-0.50393825	
B-R-PC4	225.0953	158.58714	-0.53897264	
S-R-CP4	217.3521	157.62618	-0.60760370	
B-R-PC2	215.0274	152.54520	-0.62820821	
B-A-MU2	210.8910	128.79692	-0.66487097	
S-R-CP2	207.1435	167.09006	-0.69808647	
S-R-CC1	205.9912	142.40233	-0.70830031	
B-R-ET1	205.3272	169.74682	-0.71418525	
S-A-ZA1	202.2608	175.36143	-0.74136373	
B-A-GU1	200.2219	174.32564	-0.75943496	
S-R-CP3	199.1922	170.79087	-0.76856181	
S-A-TA1	195.8495	170.39163	-0.79818963	
S-R-CP1	195.7828	170.97514	-0.79878039	

Chapter 22

R Módulo 7 - Análise de Classificação Hierárquica - SAHN

RESUMO

Análise de Classificação Hierárquica (SAHN) é um método de análise de dados utilizado para identificar grupos ou clusters de objetos com base em sua similaridade. É amplamente utilizada em várias áreas, incluindo bioinformática, análise de dados espaciais, agronomia, entre outros. A análise de classificação hierárquica é uma técnica exploratória importante que pode ajudar a identificar padrões e relações em dados não estruturados. No entanto, é importante lembrar que a interpretação dos resultados pode ser subjetiva e depender do contexto da aplicação.

Apresentação

Análise de Classificação Hierárquica (do inglês, “*Hierarchical Agglomerative Clustering Analysis*”, ou simplesmente “SAHN”) é um método de análise de dados utilizado para identificar grupos ou “clusters” de objetos com base em sua similaridade. Nessa análise, os objetos são inicialmente considerados como clusters individuais e, em seguida, os objetos mais similares são agrupados em um cluster maior, e assim por diante, até que todos os objetos estejam em um único cluster. Isso resulta em uma árvore hierárquica, conhecida como dendrograma, que mostra a relação de similaridade entre os objetos.

Existem dois tipos principais de classificação hierárquica: aglomerativa e divisiva. O método aglomerativo é mais comum e começa com cada objeto em seu

próprio cluster, e sucessivamente agrupa os objetos mais próximos, enquanto o método divisivo começa com todos os objetos em um único cluster e sucessivamente divide-os em grupos menores.

Análises de classificação são amplamente utilizadas em várias áreas, incluindo bioinformática, análise de dados espaciais, agronomia, entre outros. Além disso, pode ser utilizada com diferentes medidas de distância e diferentes métodos de agrupamento, como, por exemplo, o método *complete-linkage*, *single-linkage*, *average-linkage*, entre outros.

A **Análise de Classificação Hierárquica** é uma técnica exploratória importante que pode ajudar a identificar padrões e relações em dados não estruturados. No entanto, é importante lembrar que a interpretação dos resultados pode ser subjetiva e depender do contexto da aplicação.

22.1 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) ##LIMPA A MEMORIA
cat("\014") #limpa o console
#rm(list=ls(all=TRUE)); cat("\014"); dev.off() # tudo na mesma
↪ linha
```

22.1.1 Pacotes

Instalando os pacotes necessários para esse módulo

```
install.packages("tidyverse")
install.packages("openxlsx")
install.packages("vegan")
install.packages("dplyr")
install.packages("RColorBrewer")
install.packages("ggplots")
```

```
library(tidyverse)
```

Os códigos acima, são usados para instalar os pacotes necessários para este módulo. Esses códigos são comandos para instalar pacotes no R. Um pacote é uma coleção de funções, dados e documentação que ampliam as capacidades do

R (R CRAN e RStudio). Depois de instalar um pacote, você precisa carregá-lo na sua sessão R com a função `library()`. Por exemplo, no código acima, carregamos o pacote `tidyverse`, usando a função `library(openxlsx)`. Isso irá permitir que você use as funções do pacote na sua sessão R. Você precisa carregar um pacote toda vez que iniciar uma nova sessão R e quiser usar um pacote instalado. Os demais pacotes instalados serão carregados ao longo desse tutorial a medida que cada pacote for sendo necessário.

Agora vamos **definir o diretório de trabalho**. Esse código é usado para obter e definir o diretório de trabalho atual no R. O comando `getwd()` retorna o caminho do diretório onde o R está lendo e salvando arquivos. O comando `setwd()` muda esse diretório de trabalho para o caminho especificado entre aspas. No seu caso, você deve ajustar o caminho para o seu próprio diretório de trabalho. **Lembre de usar a barra “/” entre os diretórios. E não a contra-barra “\”.**

Definindo o diretório de trabalho e instalando os pacotes necessários:

```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

Alternativamente você pode ir na barra de tarefas e escolhes as opções:
SESSION -> SET WORKING DIRECTORY -> CHOOSE DIRECTORY

22.1.2 Sobre os dados do PPBio

A planilha `ppbio` contém os dados de abundância de espécies em diferentes unidades amostrais (UA's) (Figura 22.1 (Veja Programa de Pesquisa em Biodiversidade – PPBio). Essa é a **matriz bruta de dados**, porque os valores ainda não foram ajustados para os valores de Captura Por Unidade de Esforço (CPUE), nem foram relativizados ou transformados.

22.1.3 Importando a planilha de trabalho

Note que o símbolo `#` em programação R significa que o texto que vem depois dele é um comentário e não será executado pelo programa. Isso é útil para explicar o código ou deixar anotações. Ajuste a segunda linha do código abaixo para refletir “C:/Seu/Diretório/De/Trabalho/Planilha.xlsx”.

```
library(openxlsx)
ppbio <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06p-peixes.xlsx"
  ↪ ,
```

	A	B	C	D	E	F	G	H	
1	sitio	ap-davis	as-bimac	as-fasci	ch-bimac	ci-ocela	ci-orien	co-macro	co-
2	S-A-ZA1	0	1	0	0	0	0	0	
3	S-R-CC1	0	99	0	0	0	0	0	
4	S-R-CT1	0	194	55	0	0	5	0	
5	S-R-CP1	0	19	0	0	0	0	0	
6	S-A-TA1	0	23	1	13	0	0	0	
7	S-R-CT2	0	142	3	3	0	69	0	
8	S-R-CP2	0	5	1	0	40	9	0	
9	S-A-TA2	0	46	0	178	0	0	0	
10	S-R-CT3	0	206	64	0	0	25	0	
11	S-R-CP3	0	16	0	0	13	24	0	
12	S-A-TA3	0	234	7	238	0	0	2	
13	S-R-CT4	0	0	1	0	0	5	0	
14	S-R-CP4	0	0	0	0	11	6	0	
15	S-A-TA4	0	394	0	273	0	0	0	
16	B-A-MU1	0	12	0	0	0	0	0	
17	B-R-ET1	0	3	0	0	0	0	0	
18	B-A-GU1	0	2	2	0	0	0	0	
19	B-R-PC2	5	44	0	0	2	0	0	
20	B-A-MU2	0	99	0	0	0	0	0	
21	B-A-GU2	0	0	0	0	0	0	0	
22	B-R-PC3	22	75	7	0	4	0	0	
23	B-A-MU3	0	511	0	0	0	0	0	
24	B-A-GU3	0	6	0	0	0	0	0	
25	B-R-PC4	0	7	17	0	0	0	0	
26	B-A-MU4	0	235	0	0	0	0	0	
27	B-A-GU4	0	13	0	0	0	0	0	

Figure 22.1: Parte da planilha de dados brutos do PPBio.

```

        rowNames = T,
        colNames = T,
        sheet = "Sheet1")
str(ppbio)
ppbio_ma <- as.matrix(ppbio) #lê ppbio como uma matriz
str(ppbio_ma)
#ppbio
#ppbio_ma

```

22.2 REINÍCIO

ATENÇÃO Aqui substitui-se uma nova matriz de dados, relativizada e/ou transformada, pela matriz de trabalho inicial.

Aqui usaremos as matrizes transposta/relativizada/transformada/particionada

```
m_trab <- (ppbio)
```

22.3 Nomenclatura das matrizes em AMD

No tocante aos tipos de atributos e seu tratamento pré-análises, uma matriz de dados pode ser dos tipos apresentados na tabela 22.1, abaixo.

```

## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto

```

22.4 Cluster 1: Piloto automático


ATENÇÃO NÃO RECOMENDADO

Aqui fazemos uma Análise Cluster no piloto automático. Não decidimos nenhum dos parâmetros importantes para uma Classificação.

Table 22.1: Nomenclatura das matrizes em AMD em relação aos atributos das colunas.

Nome	Atributos (colunas)
Matriz comunitaria	Os atributos são táxons (ex. espécies, gêneros, morfotipos)
Matriz ambiental	Os atributos são dados ambientais (ex. pH, condutividade, temperatura)
Matriz bruta	Os atributos ainda não receberam nenhum tipo de tratamento estatístico (valores brutos, como coletados)
Matriz transposta	Os atributos foram transpostos para as linhas
Matriz relativizada	Os atributos foram relativizados por um critério de tamanho ou de variação (ex. dividir os valores de cada coluna pela soma)
Matriz transformada	Foi aplicado um operador matemático a todos os atributos (ex. raiz quadrada, log)


```
cluster1 <- hclust(dist(m_trab))
plot(cluster1, main = "Cluster Dendrogram - Piloto automatico")
rect.hclust(cluster1, k=3, h = NULL)
#?dist
#?hclust
```



É possível definir uma caixa mostrando os principais grupos formados. Isso pode ser feito estabelecendo quantos grupos se quer mostrar, usando a função `k = no. de grupos`. Ou pode-se definir os grupos formados até uma determinada distância, usando a função `h = altura dos grupos` no eixo das distâncias.

22.4.1 Histórico das fusões

```
library(dplyr)
cluster1$merge #mostra o histórico das fusões
idrow <- mutate(m_trab, id = row_number()) #cria um df com os
  ↳ numeros das linhas
idrow %>% relocate(id)
#?relocate
```

```
##      [,1] [,2]
```

```

## [1,] -2 -3
## [2,] -14 1
## [3,] -8 2
## [4,] -5 -11
## [5,] 3 4
## [6,] -15 -18
## [7,] -21 5
## [8,] -17 -23
## [9,] -16 7
## [10,] -9 -12
## [11,] 6 9
## [12,] -10 11
## [13,] -1 -4
## [14,] -20 8
## [15,] -6 -13
## [16,] 12 15
## [17,] 13 16
## [18,] -19 10
## [19,] 14 17
## [20,] -7 19
## [21,] 18 20
## [22,] -22 21
##
## id ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro
## S-R-CT1 1 0 194 55 0 0 5 0
## S-R-CP1 2 0 19 0 0 0 0 0
## S-A-TA1 3 0 23 1 13 0 0 0
## S-R-CT2 4 0 142 3 3 0 69 0
## S-R-CP2 5 0 5 1 0 40 9 0
## S-A-TA2 6 0 46 0 178 0 0 0
## S-R-CT3 7 0 206 64 0 0 25 0
## S-R-CP3 8 0 16 0 0 13 24 0
## S-A-TA3 9 0 234 7 238 0 0 2
## S-R-CT4 10 0 0 1 0 0 5 0
## S-R-CP4 11 0 0 0 0 11 6 0
## S-A-TA4 12 0 394 0 273 0 0 0
## B-A-MU1 13 0 12 0 0 0 0 0
## B-A-GU1 14 0 2 2 0 0 0 0
## B-R-PC2 15 5 44 0 0 2 0 0
## B-A-MU2 16 0 99 0 0 0 0 0
## B-A-GU2 17 0 0 0 0 0 0 0
## B-R-PC3 18 22 75 7 0 4 0 0
## B-A-MU3 19 0 511 0 0 0 0 0
## B-A-GU3 20 0 6 0 0 0 0 0
## B-R-PC4 21 0 7 17 0 0 0 0
## B-A-MU4 22 0 235 0 0 0 0 0
## B-A-GU4 23 0 13 0 0 0 0 0

```

##	co-heter	cr-menez	cu-lepid	cy-gilbe	ge-brasi	he-margi	ho-malab	hy-pusar
## S-R-CT1	1	14	0	0	3	0	1	9
## S-R-CP1	0	0	0	0	0	0	5	2
## S-A-TA1	0	0	0	0	0	0	0	0
## S-R-CT2	0	4	0	0	0	1	17	43
## S-R-CP2	0	0	0	0	0	0	10	2
## S-A-TA2	0	0	0	0	0	0	2	0
## S-R-CT3	0	8	0	0	1	0	31	11
## S-R-CP3	0	0	0	0	0	0	4	0
## S-A-TA3	0	0	0	0	0	0	20	0
## S-R-CT4	0	1	0	50	3	1	4	3
## S-R-CP4	0	0	0	0	0	0	2	0
## S-A-TA4	0	1	0	0	1	0	9	0
## B-A-MU1	0	0	0	0	190	0	0	0
## B-A-GU1	0	0	0	0	7	0	0	0
## B-R-PC2	0	0	0	0	8	0	0	0
## B-A-MU2	0	0	0	0	67	0	1	0
## B-A-GU2	0	0	0	0	23	0	0	0
## B-R-PC3	0	0	21	0	16	0	2	1
## B-A-MU3	0	0	0	0	145	0	0	0
## B-A-GU3	0	0	0	0	32	0	0	0
## B-R-PC4	0	0	0	81	5	0	1	0
## B-A-MU4	0	0	0	0	509	0	0	0
## B-A-GU4	0	0	0	0	10	0	0	0
##	le-melan	le-piau	le-taeni	mo-costa	mo-lepid	or-nilot	pa-manag	pimel-sp
## S-R-CT1	0	3	0	0	39	36	0	6
## S-R-CP1	0	0	0	0	0	0	0	0
## S-A-TA1	0	0	0	0	0	0	0	0
## S-R-CT2	0	1	0	0	1	77	0	0
## S-R-CP2	0	3	0	0	0	0	0	0
## S-A-TA2	0	0	0	0	0	0	0	0
## S-R-CT3	0	2	0	0	0	138	0	0
## S-R-CP3	0	1	0	0	0	0	0	0
## S-A-TA3	0	0	0	0	0	0	0	0
## S-R-CT4	0	0	0	0	0	73	0	0
## S-R-CP4	0	2	0	0	0	0	0	0
## S-A-TA4	0	2	0	0	0	1	0	0
## B-A-MU1	0	0	0	0	0	6	0	0
## B-A-GU1	0	0	0	0	0	3	11	0
## B-R-PC2	2	0	1	0	0	5	0	0
## B-A-MU2	0	0	0	0	0	1	0	0
## B-A-GU2	0	0	0	0	0	36	102	0
## B-R-PC3	0	0	0	1	0	65	0	0
## B-A-MU3	0	0	0	0	0	11	0	0
## B-A-GU3	0	0	0	0	0	247	250	0
## B-R-PC4	0	1	0	0	0	9	0	0

## B-A-MU4	0	0	0	0	0	1	0	0
## B-A-GU4	0	0	0	0	0	129	190	0
##	po-retic	po-vivip	pr-brevi	ps-rhomb	ps-genise	se-heter	se-piaba	
## S-R-CT1	0	47	5	0	0	40	68	
## S-R-CP1	0	15	0	0	0	14	0	
## S-A-TA1	0	0	1	0	0	4	0	
## S-R-CT2	20	221	15	0	0	60	0	
## S-R-CP2	0	32	5	0	0	0	0	
## S-A-TA2	0	0	2	0	0	0	0	
## S-R-CT3	5	326	164	1	1	38	0	
## S-R-CP3	0	10	0	0	0	0	0	
## S-A-TA3	0	0	0	0	0	0	0	
## S-R-CT4	0	28	59	0	0	3	0	
## S-R-CP4	0	80	0	0	0	3	0	
## S-A-TA4	0	0	3	0	0	0	0	
## B-A-MU1	0	0	0	0	0	0	0	
## B-A-GU1	0	0	0	0	0	0	0	
## B-R-PC2	0	0	9	0	0	10	0	
## B-A-MU2	10	8	0	0	0	0	0	
## B-A-GU2	0	0	0	0	0	0	0	
## B-R-PC3	0	0	6	0	0	93	0	
## B-A-MU3	46	48	1	0	0	0	0	
## B-A-GU3	0	0	0	0	0	0	0	
## B-R-PC4	0	0	0	0	0	31	0	
## B-A-MU4	266	163	0	0	0	0	0	
## B-A-GU4	0	0	0	0	0	0	0	
##	se-spilo	st-noton	sy-marmo	te-chalc	tr-signa			
## S-R-CT1	0	1	0	0	18			
## S-R-CP1	0	0	0	0	0			
## S-A-TA1	0	0	0	0	0			
## S-R-CT2	0	25	0	0	15			
## S-R-CP2	0	0	1	0	0			
## S-A-TA2	0	0	0	0	0			
## S-R-CT3	1	115	0	0	7			
## S-R-CP3	0	0	0	0	0			
## S-A-TA3	0	0	0	0	0			
## S-R-CT4	0	64	0	0	141			
## S-R-CP4	0	0	0	0	0			
## S-A-TA4	0	0	0	0	0			
## B-A-MU1	0	0	0	0	0			
## B-A-GU1	0	0	0	0	0			
## B-R-PC2	0	0	0	76	23			
## B-A-MU2	0	0	0	0	0			
## B-A-GU2	0	0	0	0	0			
## B-R-PC3	0	0	0	58	0			
## B-A-MU3	0	0	0	0	0			

## B-A-GU3	0	0	0	0	0
## B-R-PC4	0	0	0	0	4
## B-A-MU4	0	0	0	0	0
## B-A-GU4	0	0	0	0	0

22.4.1.1 Alguns ajustes para melhorar a visualização

```
merge <- as.data.frame(cluster1$merge)
merge[nrow(merge)+1,] = c("0","0")
merge
uas <- as.data.frame(rownames_to_column(m_trab,var = "UAs"))
uas
merges <- cbind(uas[c("UAs")], merge)
merges
```

```
##      V1 V2
## 1   -2 -3
## 2  -14  1
## 3   -8  2
## 4   -5 -11
## 5    3  4
## 6  -15 -18
## 7  -21  5
## 8  -17 -23
## 9  -16  7
## 10  -9 -12
## 11   6  9
## 12 -10 11
## 13  -1 -4
## 14 -20  8
## 15  -6 -13
## 16  12 15
## 17  13 16
## 18 -19 10
## 19  14 17
## 20  -7 19
## 21  18 20
## 22 -22 21
## 23   0  0
##      UAs ap-davis as-bimac as-fasci ch-bimac ci-ocela ci-orien co-macro
## 1 S-R-CT1      0     194     55      0      0      5      0
## 2 S-R-CP1      0      19      0      0      0      0      0
## 3 S-A-TA1      0      23      1     13      0      0      0
```

## 4	S-R-CT2	0	142	3	3	0	69	0
## 5	S-R-CP2	0	5	1	0	40	9	0
## 6	S-A-TA2	0	46	0	178	0	0	0
## 7	S-R-CT3	0	206	64	0	0	25	0
## 8	S-R-CP3	0	16	0	0	13	24	0
## 9	S-A-TA3	0	234	7	238	0	0	2
## 10	S-R-CT4	0	0	1	0	0	5	0
## 11	S-R-CP4	0	0	0	0	11	6	0
## 12	S-A-TA4	0	394	0	273	0	0	0
## 13	B-A-MU1	0	12	0	0	0	0	0
## 14	B-A-GU1	0	2	2	0	0	0	0
## 15	B-R-PC2	5	44	0	0	2	0	0
## 16	B-A-MU2	0	99	0	0	0	0	0
## 17	B-A-GU2	0	0	0	0	0	0	0
## 18	B-R-PC3	22	75	7	0	4	0	0
## 19	B-A-MU3	0	511	0	0	0	0	0
## 20	B-A-GU3	0	6	0	0	0	0	0
## 21	B-R-PC4	0	7	17	0	0	0	0
## 22	B-A-MU4	0	235	0	0	0	0	0
## 23	B-A-GU4	0	13	0	0	0	0	0
##	co-heter	cr-menez	cu-lepid	cy-gilbe	ge-brasi	he-margi	ho-malab	hy-pusar
## 1	1	14	0	0	3	0	1	9
## 2	0	0	0	0	0	0	5	2
## 3	0	0	0	0	0	0	0	0
## 4	0	4	0	0	0	1	17	43
## 5	0	0	0	0	0	0	10	2
## 6	0	0	0	0	0	0	2	0
## 7	0	8	0	0	1	0	31	11
## 8	0	0	0	0	0	0	4	0
## 9	0	0	0	0	0	0	20	0
## 10	0	1	0	50	3	1	4	3
## 11	0	0	0	0	0	0	2	0
## 12	0	1	0	0	1	0	9	0
## 13	0	0	0	0	190	0	0	0
## 14	0	0	0	0	7	0	0	0
## 15	0	0	0	0	8	0	0	0
## 16	0	0	0	0	67	0	1	0
## 17	0	0	0	0	23	0	0	0
## 18	0	0	21	0	16	0	2	1
## 19	0	0	0	0	145	0	0	0
## 20	0	0	0	0	32	0	0	0
## 21	0	0	0	81	5	0	1	0
## 22	0	0	0	0	509	0	0	0
## 23	0	0	0	0	10	0	0	0
##	le-melan	le-piau	le-taeni	mo-costa	mo-lepid	or-nilot	pa-manag	pimel-sp
## 1	0	3	0	0	39	36	0	6

## 2	0	0	0	0	0	0	0	0
## 3	0	0	0	0	0	0	0	0
## 4	0	1	0	0	1	77	0	0
## 5	0	3	0	0	0	0	0	0
## 6	0	0	0	0	0	0	0	0
## 7	0	2	0	0	0	138	0	0
## 8	0	1	0	0	0	0	0	0
## 9	0	0	0	0	0	0	0	0
## 10	0	0	0	0	0	73	0	0
## 11	0	2	0	0	0	0	0	0
## 12	0	2	0	0	0	1	0	0
## 13	0	0	0	0	0	6	0	0
## 14	0	0	0	0	0	3	11	0
## 15	2	0	1	0	0	5	0	0
## 16	0	0	0	0	0	1	0	0
## 17	0	0	0	0	0	36	102	0
## 18	0	0	0	1	0	65	0	0
## 19	0	0	0	0	0	11	0	0
## 20	0	0	0	0	0	247	250	0
## 21	0	1	0	0	0	9	0	0
## 22	0	0	0	0	0	1	0	0
## 23	0	0	0	0	0	129	190	0
##	po-retic	po-vivip	pr-brevi	ps-rhomb	ps-genise	se-heter	se-piaba	se-spilo
## 1	0	47	5	0	0	40	68	0
## 2	0	15	0	0	0	14	0	0
## 3	0	0	1	0	0	4	0	0
## 4	20	221	15	0	0	60	0	0
## 5	0	32	5	0	0	0	0	0
## 6	0	0	2	0	0	0	0	0
## 7	5	326	164	1	1	38	0	1
## 8	0	10	0	0	0	0	0	0
## 9	0	0	0	0	0	0	0	0
## 10	0	28	59	0	0	3	0	0
## 11	0	80	0	0	0	3	0	0
## 12	0	0	3	0	0	0	0	0
## 13	0	0	0	0	0	0	0	0
## 14	0	0	0	0	0	0	0	0
## 15	0	0	9	0	0	10	0	0
## 16	10	8	0	0	0	0	0	0
## 17	0	0	0	0	0	0	0	0
## 18	0	0	6	0	0	93	0	0
## 19	46	48	1	0	0	0	0	0
## 20	0	0	0	0	0	0	0	0
## 21	0	0	0	0	0	31	0	0
## 22	266	163	0	0	0	0	0	0
## 23	0	0	0	0	0	0	0	0

```

##      st-noton sy-marmo te-chalc tr-signa
## 1         1         0         0        18
## 2         0         0         0         0
## 3         0         0         0         0
## 4        25         0         0        15
## 5         0         1         0         0
## 6         0         0         0         0
## 7       115         0         0         7
## 8         0         0         0         0
## 9         0         0         0         0
## 10        64         0         0       141
## 11         0         0         0         0
## 12         0         0         0         0
## 13         0         0         0         0
## 14         0         0         0         0
## 15         0         0        76        23
## 16         0         0         0         0
## 17         0         0         0         0
## 18         0         0        58         0
## 19         0         0         0         0
## 20         0         0         0         0
## 21         0         0         0         4
## 22         0         0         0         0
## 23         0         0         0         0
##      UAs  V1  V2
## 1 S-R-CT1 -2 -3
## 2 S-R-CP1 -14  1
## 3 S-A-TA1 -8  2
## 4 S-R-CT2 -5 -11
## 5 S-R-CP2  3  4
## 6 S-A-TA2 -15 -18
## 7 S-R-CT3 -21  5
## 8 S-R-CP3 -17 -23
## 9 S-A-TA3 -16  7
## 10 S-R-CT4 -9 -12
## 11 S-R-CP4  6  9
## 12 S-A-TA4 -10 11
## 13 B-A-MU1 -1 -4
## 14 B-A-GU1 -20 8
## 15 B-R-PC2 -6 -13
## 16 B-A-MU2 12 15
## 17 B-A-GU2 13 16
## 18 B-R-PC3 -19 10
## 19 B-A-MU3 14 17
## 20 B-A-GU3 -7 19
## 21 B-R-PC4 18 20

```



22.5. CLUSTER 2: CRIANDO A MATRIZ DE DISTÂNCIAS EUCLIDIANA597

```
## 22 B-A-MU4 -22 21
## 23 B-A-GU4 0 0
```

22.5 Cluster 2: Criando a matriz de distâncias Euclidiana

```
m_dists <- dist(m_trab, method = "euclidean",
               diag = TRUE,
               upper = FALSE)

#m_dists
cluster2 <- hclust(m_dists, method = "complete") #método de fusão
plot(cluster2, main = "Cluster Dendrogram - Dist.Euclidiana")
rect.hclust(cluster2, k = 3)
#?dist
#?hclust
```



O significado do argumento `method` = da função `dist()` usada no código acima, depende do contexto em que ela é usada.

- A função `dist()` no R é usada para calcular as distâncias entre as observações em um conjunto de dados. Essa função tem vários métodos de

Table 22.2: Metodos de fusão disponiveis com o argumento ‘method=’ da função ‘hclust’. Lembrando que UPGMA significa ”Unweighted Pairwise Group Method with Arithmetic Mean”

Method=	Método de fusão
ward.D	Método de Ward com variância mínima
ward.D2	Método de Ward com variância mínima ajustada
single	Método de ligação simples (vizinho mais próximo)
complete	Método de ligação completa (vizinho mais distante)
average	Método de ligação baseado na média, equivale ao UPGMA
mcquitty	Método de ligação de McQuitty, equivale ao WPGMA
median	Método de ligação baseado na mediana, ou WPGMC
centroid	Método de ligação baseado no centróide, ou UPGMC

cálculo de distância, que podem ser especificados pelo argumento `method =`, a exemplo de “euclidean”, “manhattan”, “canberra”, entre outras.

- Quando o argumento `method =` é usado em conjunto com a função `hclust()`, como no código acima, para realizar uma análise de classificação (ou cluster) hierárquica, então ela passa a representar um método de fusão, a exemplo de UPGMA, “nearest neighbour”, “furtherst neighbour”, entre outros.

A tabela 22.2 resume os métodos de fusão disponiveis na função `hclust()`.


```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

22.5.1 Comparação dos resultados obtidos até aqui


22.5. CLUSTER 2: CRIANDO A MATRIZ DE DISTÂNCIAS EUCLIDIANA599

```
#dev.off() #limpa os gráficos
par(mfrow = c(2,1))
plot(cluster1, main = "Cluster Dendrogram - Piloto automático")
plot(cluster2, main = "Cluster Dendrogram - Dist. Euclidiana")
par(mfrow = c(1,1))
#dev.off()
```

Cluster Dendrogram – Piloto automático



Cluster Dendrogram – Dist. Euclidiana



22.6 Cluster 3: Relativização pelo total da coluna


```
library(vegan)
m_relcol <- decostand(m_trab,
                      method="total", ### OUTROS METODOS:
                      ↪ total, max, normalize, range, rankm
                      MARGIN = 2) #1-linha, 2-coluna

#View(m_relcol)
#m_relcol
```

22.6.1 Gráfico de *clustering* relativizado

Agora fazemos a classificação da matriz bruta após ter sido relativizada pelo total das colunas.

```
cluster3 <- hclust(dist(m_relcol))
plot(cluster3, main = "Cluster Dendrogram - Rel.Coluna")
rect.hclust(cluster3, k = 3)
```



22.7 *Cluster* 4: Transformação pelo arcoseno da raiz quadrada


Agora aplicaremos a transformação do arcoseno da raiz quadrada na matriz relativizada por colunas. Lembre que em ambas as matrizes entramos dados que variam entre 0 e 1, e os resultados retornados também variam entre 0 e 1, mas em um nível de compressão de valores extremos mais desejável. Usaremos a matriz relativizada/transformada para fazermos a próxima classificação.

```
m_trns <- asin(sqrt(m_relcol)) #valores de entrada tem que ser
  ↪ entre 0-1
#View(m_trns)
#m_trns
```

22.7.1 Gráfico de *clustering* relativizado/transformado

Aqui fazemos uma Análise Cluster no piloto automático, para comparar com os resultados da primeira classificação, que não havia sido relativizada/transformada.


```
cluster4 <- hclust(dist(m_trns))
plot(cluster4, main = "Cluster Dendrogram - ArcSin.SQRT")
rect.hclust(cluster4, k = 3)
```



22.8 Cluster 5: Controle total dos parâmetros

```
vegdist <- vegdist(m_trns, method = "bray",
                  diag = TRUE,
                  upper = FALSE)
as.matrix(vegdist)[1:7, 1:7]
cluster5 <- hclust(vegdist, method = "average")
plot(cluster5, main = "Cluster Dendrogram - Bray-Curtis")
rect.hclust(cluster5, k = 3, h = NULL)
#h = 0.8 fornece os grupos formados na altura h
```

```
##           S-R-CT1  S-R-CP1  S-A-TA1  S-R-CT2  S-R-CP2  S-A-TA2  S-R-CT3
## S-R-CT1  0.0000000  0.8743721  0.9338269  0.6274997  0.8106894  0.9420728  0.6582219
## S-R-CP1  0.8743721  0.0000000  0.6833816  0.7759468  0.7726098  0.7342613  0.8672111
## S-A-TA1  0.9338269  0.6833816  0.0000000  0.8789631  0.9178304  0.5700984  0.9404687
## S-R-CT2  0.6274997  0.7759468  0.8789631  0.0000000  0.7280378  0.8836068  0.5169933
## S-R-CP2  0.8106894  0.7726098  0.9178304  0.7280378  0.0000000  0.8915271  0.8012846
## S-A-TA2  0.9420728  0.7342613  0.5700984  0.8836068  0.8915271  0.0000000  0.9412636
## S-R-CT3  0.6582219  0.8672111  0.9404687  0.5169933  0.8012846  0.9412636  0.0000000
```



Alguns ajustes para melhorar a visualização.

```
cluster5$merge
cluster5$height
idrow <- mutate(m_trns, id = row_number()) #cria um df com os
  ↳ numeros das linhas
idrow %>% relocate(id)
#?relocate
merge <- as.data.frame(cluster5$merge)
merge[nrow(merge)+1,] = c("0", "0")
merge
uas <- as.data.frame(rownames_to_column(m_trab, var = "UAs"))
uas
merges <- cbind(uas[c("UAs")], merge)
merges
```

```
##      [,1] [,2]
## [1,]  -20 -23
## [2,]   -8 -11
## [3,]  -17  1
## [4,]  -19 -22
## [5,]   -6 -12
## [6,]   -4 -10
## [7,]  -16  4
```



```

## [8,] -5 2
## [9,] -13 7
## [10,] -9 5
## [11,] -7 6
## [12,] -14 3
## [13,] -2 -3
## [14,] -1 11
## [15,] -15 -18
## [16,] -21 14
## [17,] 10 13
## [18,] 9 12
## [19,] 8 16
## [20,] 17 19
## [21,] 15 20
## [22,] 18 21
## [1] 0.1402400 0.2637008 0.2827470 0.3726150 0.4095558 0.4631145 0.4766705
## [8] 0.5326053 0.5584043 0.5683644 0.5934519 0.6112108 0.6833816 0.6834576
## [15] 0.6881517 0.7475412 0.7570089 0.7899914 0.8037471 0.8465927 0.8855551
## [22] 0.9099458
##      id ap-davis  as-bimac  as-fasci  ch-bimac  ci-ocela  ci-orien
## S-R-CT1  1 0.000000 0.29580113 0.63106017 0.00000000 0.00000000 0.1880966
## S-R-CP1  2 0.000000 0.09135411 0.00000000 0.00000000 0.00000000 0.0000000
## S-A-TA1  3 0.000000 0.10054093 0.07963989 0.13621375 0.00000000 0.0000000
## S-R-CT2  4 0.000000 0.25205752 0.13823439 0.06527916 0.00000000 0.7679121
## S-R-CP2  5 0.000000 0.04681561 0.07963989 0.00000000 0.8570719 0.2535816
## S-A-TA2  6 0.000000 0.14242797 0.00000000 0.52646034 0.00000000 0.0000000
## S-R-CT3  7 0.000000 0.30509802 0.68988155 0.00000000 0.00000000 0.4313758
## S-R-CP3  8 0.000000 0.08381382 0.00000000 0.00000000 0.4455406 0.4220958
## S-A-TA3  9 0.000000 0.32588896 0.21207071 0.61998604 0.00000000 0.0000000
## S-R-CT4 10 0.000000 0.00000000 0.07963989 0.00000000 0.00000000 0.1880966
## S-R-CP4 11 0.000000 0.00000000 0.00000000 0.00000000 0.4076059 0.2062968
## S-A-TA4 12 0.000000 0.42841263 0.00000000 0.67165367 0.00000000 0.0000000
## B-A-MU1 13 0.000000 0.07256361 0.00000000 0.00000000 0.00000000 0.0000000
## B-A-GU1 14 0.000000 0.02960230 0.11274751 0.00000000 0.00000000 0.0000000
## B-R-PC2 15 0.444860 0.13927667 0.00000000 0.00000000 0.1698463 0.0000000
## B-A-MU2 16 0.000000 0.20977540 0.00000000 0.00000000 0.00000000 0.0000000
## B-A-GU2 17 0.000000 0.00000000 0.00000000 0.00000000 0.00000000 0.0000000
## B-R-PC3 18 1.125936 0.18225721 0.21207071 0.00000000 0.2413830 0.0000000
## B-A-MU3 19 0.000000 0.49281178 0.00000000 0.00000000 0.00000000 0.0000000
## B-A-GU3 20 0.000000 0.05128768 0.00000000 0.00000000 0.00000000 0.0000000
## B-R-PC4 21 0.000000 0.05540108 0.33420332 0.00000000 0.00000000 0.0000000
## B-A-MU4 22 0.000000 0.32661037 0.00000000 0.00000000 0.00000000 0.0000000
## B-A-GU4 23 0.000000 0.07553213 0.00000000 0.00000000 0.00000000 0.0000000
##      co-macro co-heter  cr-menez cu-lepid  cy-gilbe  ge-brasi  he-margi
## S-R-CT1 0.000000 1.570796 0.7853982 0.000000 0.0000000 0.05425923 0.0000000
## S-R-CP1 0.000000 0.000000 0.0000000 0.000000 0.0000000 0.00000000 0.0000000

```

```

## S-A-TA1 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-R-CT2 0.000000 0.000000 0.3875967 0.000000 0.000000 0.000000 0.7853982
## S-R-CP2 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-A-TA2 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-R-CT3 0.000000 0.000000 0.5639426 0.000000 0.000000 0.03131633 0.000000
## S-R-CP3 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-A-TA3 1.570796 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-R-CT4 0.000000 0.000000 0.1901256 0.000000 0.6659445 0.05425923 0.7853982
## S-R-CP4 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-A-TA4 0.000000 0.000000 0.1901256 0.000000 0.000000 0.03131633 0.000000
## B-A-MU1 0.000000 0.000000 0.000000 0.000000 0.000000 0.44626053 0.000000
## B-A-GU1 0.000000 0.000000 0.000000 0.000000 0.000000 0.08293673 0.000000
## B-R-PC2 0.000000 0.000000 0.000000 0.000000 0.000000 0.08867767 0.000000
## B-A-MU2 0.000000 0.000000 0.000000 0.000000 0.000000 0.25918549 0.000000
## B-A-GU2 0.000000 0.000000 0.000000 0.000000 0.000000 0.15073345 0.000000
## B-R-PC3 0.000000 0.000000 0.000000 1.570796 0.000000 0.12557463 0.000000
## B-A-MU3 0.000000 0.000000 0.000000 0.000000 0.000000 0.38659505 0.000000
## B-A-GU3 0.000000 0.000000 0.000000 0.000000 0.000000 0.17806243 0.000000
## B-R-PC4 0.000000 0.000000 0.000000 0.000000 0.9048519 0.07007133 0.000000
## B-A-MU4 0.000000 0.000000 0.000000 0.000000 0.000000 0.78441777 0.000000
## B-A-GU4 0.000000 0.000000 0.000000 0.000000 0.000000 0.09917726 0.000000
##          ho-malab hy-pusar le-melan  le-piau le-taeni mo-costa mo-lepid
## S-R-CT1 0.09592969 0.3640209 0.000000 0.4636476 0.000000 0.000000 1.4120161
## S-R-CP1 0.21584866 0.1686344 0.000000 0.000000 0.000000 0.000000 0.000000
## S-A-TA1 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-R-CT2 0.40598283 0.8918340 0.000000 0.2611574 0.000000 0.000000 0.1587802
## S-R-CP2 0.30772498 0.1686344 0.000000 0.4636476 0.000000 0.000000 0.000000
## S-A-TA2 0.13587479 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-R-CT3 0.56249105 0.4045563 0.000000 0.3737922 0.000000 0.000000 0.000000
## S-R-CP3 0.19275669 0.0000000 0.000000 0.2611574 0.000000 0.000000 0.000000
## S-A-TA3 0.44266923 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## S-R-CT4 0.19275669 0.2070324 0.000000 0.000000 0.000000 0.000000 0.000000
## S-R-CP4 0.13587479 0.0000000 0.000000 0.3737922 0.000000 0.000000 0.000000
## S-A-TA4 0.29145679 0.0000000 0.000000 0.3737922 0.000000 0.000000 0.000000
## B-A-MU1 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## B-A-GU1 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## B-R-PC2 0.00000000 0.0000000 1.570796 0.000000 1.570796 0.000000 0.000000
## B-A-MU2 0.09592969 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## B-A-GU2 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## B-R-PC3 0.13587479 0.1189585 0.000000 0.000000 0.000000 1.570796 0.000000
## B-A-MU3 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## B-A-GU3 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## B-R-PC4 0.09592969 0.0000000 0.000000 0.2611574 0.000000 0.000000 0.000000
## B-A-MU4 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
## B-A-GU4 0.00000000 0.0000000 0.000000 0.000000 0.000000 0.000000 0.000000
##          or-nilot pa-manag pimel-sp po-retic po-vivip pr-brevi ps-rhomb

```

```

## S-R-CT1 0.20878001 0.0000000 1.570796 0.0000000 0.22101460 0.13650631 0.0000000
## S-R-CP1 0.00000000 0.0000000 0.0000000 0.0000000 0.12416313 0.00000000 0.0000000
## S-A-TA1 0.00000000 0.0000000 0.0000000 0.0000000 0.00000000 0.06089569 0.0000000
## S-R-CT2 0.30797141 0.0000000 0.0000000 0.2424450 0.49537824 0.23794112 0.0000000
## S-R-CP2 0.00000000 0.0000000 0.0000000 0.0000000 0.18188749 0.13650631 0.0000000
## S-A-TA2 0.00000000 0.0000000 0.0000000 0.0000000 0.00000000 0.08617291 0.0000000
## S-R-CT3 0.41785958 0.0000000 0.0000000 0.1203286 0.61547971 0.89364927 1.570796
## S-R-CP3 0.00000000 0.0000000 0.0000000 0.0000000 0.10129161 0.00000000 0.0000000
## S-A-TA3 0.00000000 0.0000000 0.0000000 0.0000000 0.00000000 0.00000000 0.0000000
## S-R-CT4 0.29961011 0.0000000 0.0000000 0.0000000 0.17002156 0.48641493 0.0000000
## S-R-CP4 0.00000000 0.0000000 0.0000000 0.0000000 0.29005641 0.00000000 0.0000000
## S-A-TA4 0.03455130 0.0000000 0.0000000 0.0000000 0.00000000 0.10560544 0.0000000
## B-A-MU1 0.08471752 0.0000000 0.0000000 0.0000000 0.00000000 0.00000000 0.0000000
## B-A-GU1 0.05986846 0.1415090 0.0000000 0.0000000 0.00000000 0.00000000 0.0000000
## B-R-PC2 0.07732071 0.0000000 0.0000000 0.0000000 0.00000000 0.18360401 0.0000000
## B-A-MU2 0.03455130 0.0000000 0.0000000 0.1705861 0.09056689 0.00000000 0.0000000
## B-A-GU2 0.20878001 0.4439109 0.0000000 0.0000000 0.00000000 0.00000000 0.0000000
## B-R-PC3 0.28223829 0.0000000 0.0000000 0.0000000 0.00000000 0.14962891 0.0000000
## B-A-MU3 0.11482305 0.0000000 0.0000000 0.3726604 0.22339293 0.06089569 0.0000000
## B-A-GU3 0.57389635 0.7374041 0.0000000 0.0000000 0.00000000 0.00000000 0.0000000
## B-R-PC4 0.10381968 0.0000000 0.0000000 0.0000000 0.00000000 0.00000000 0.0000000
## B-A-MU4 0.03455130 0.0000000 0.0000000 1.0665527 0.42053434 0.00000000 0.0000000
## B-A-GU4 0.40318427 0.6263078 0.0000000 0.0000000 0.00000000 0.00000000 0.0000000
##      ps-genise  se-heter se-piaba se-spilo  st-noton sy-marmo  te-chalc
## S-R-CT1 0.000000 0.3764349 1.570796 0.000000 0.06989994 0.000000 0.0000000
## S-R-CP1 0.000000 0.2192313 0.000000 0.000000 0.00000000 0.000000 0.0000000
## S-A-TA1 0.000000 0.1165111 0.000000 0.000000 0.00000000 0.000000 0.0000000
## S-R-CT2 0.000000 0.4670175 0.000000 0.000000 0.35673339 0.000000 0.0000000
## S-R-CP2 0.000000 0.0000000 0.000000 0.000000 0.00000000 1.570796 0.0000000
## S-A-TA2 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## S-R-CT3 1.570796 0.3664456 0.000000 1.570796 0.84652593 0.000000 0.0000000
## S-R-CP3 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## S-A-TA3 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## S-R-CT4 0.000000 0.1008442 0.000000 0.000000 0.59287085 0.000000 0.0000000
## S-R-CP4 0.000000 0.1008442 0.000000 0.000000 0.00000000 0.000000 0.0000000
## S-A-TA4 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## B-A-MU1 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## B-A-GU1 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## B-R-PC2 0.000000 0.1848546 0.000000 0.000000 0.00000000 0.000000 0.8527660
## B-A-MU2 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## B-A-GU2 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## B-R-PC3 0.000000 0.5950206 0.000000 0.000000 0.00000000 0.000000 0.7180303
## B-A-MU3 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## B-A-GU3 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000
## B-R-PC4 0.000000 0.3295526 0.000000 0.000000 0.00000000 0.000000 0.0000000
## B-A-MU4 0.000000 0.0000000 0.000000 0.000000 0.00000000 0.000000 0.0000000

```

```

## B-A-GU4  0.000000 0.000000 0.000000 0.000000 0.00000000 0.000000 0.000000
##          tr-signa
## S-R-CT1  0.2985914
## S-R-CP1  0.0000000
## S-A-TA1  0.0000000
## S-R-CT2  0.2718802
## S-R-CP2  0.0000000
## S-A-TA2  0.0000000
## S-R-CT3  0.1844947
## S-R-CP3  0.0000000
## S-A-TA3  0.0000000
## S-R-CT4  0.9672667
## S-R-CP4  0.0000000
## S-A-TA4  0.0000000
## B-A-MU1  0.0000000
## B-A-GU1  0.0000000
## B-R-PC2  0.3389861
## B-A-MU2  0.0000000
## B-A-GU2  0.0000000
## B-R-PC3  0.0000000
## B-A-MU3  0.0000000
## B-A-GU3  0.0000000
## B-R-PC4  0.1391234
## B-A-MU4  0.0000000
## B-A-GU4  0.0000000
##          V1  V2
## 1  -20 -23
## 2   -8 -11
## 3  -17  1
## 4  -19 -22
## 5   -6 -12
## 6   -4 -10
## 7  -16  4
## 8   -5  2
## 9  -13  7
## 10  -9  5
## 11  -7  6
## 12 -14  3
## 13  -2 -3
## 14  -1 11
## 15 -15 -18
## 16 -21 14
## 17  10 13
## 18   9 12
## 19   8 16
## 20  17 19

```

##	21	15	20						
##	22	18	21						
##	23	0	0						
##		UAs	ap-davis	as-bimac	as-fasci	ch-bimac	ci-ocela	ci-orien	co-macro
##	1	S-R-CT1	0	194	55	0	0	5	0
##	2	S-R-CP1	0	19	0	0	0	0	0
##	3	S-A-TA1	0	23	1	13	0	0	0
##	4	S-R-CT2	0	142	3	3	0	69	0
##	5	S-R-CP2	0	5	1	0	40	9	0
##	6	S-A-TA2	0	46	0	178	0	0	0
##	7	S-R-CT3	0	206	64	0	0	25	0
##	8	S-R-CP3	0	16	0	0	13	24	0
##	9	S-A-TA3	0	234	7	238	0	0	2
##	10	S-R-CT4	0	0	1	0	0	5	0
##	11	S-R-CP4	0	0	0	0	11	6	0
##	12	S-A-TA4	0	394	0	273	0	0	0
##	13	B-A-MU1	0	12	0	0	0	0	0
##	14	B-A-GU1	0	2	2	0	0	0	0
##	15	B-R-PC2	5	44	0	0	2	0	0
##	16	B-A-MU2	0	99	0	0	0	0	0
##	17	B-A-GU2	0	0	0	0	0	0	0
##	18	B-R-PC3	22	75	7	0	4	0	0
##	19	B-A-MU3	0	511	0	0	0	0	0
##	20	B-A-GU3	0	6	0	0	0	0	0
##	21	B-R-PC4	0	7	17	0	0	0	0
##	22	B-A-MU4	0	235	0	0	0	0	0
##	23	B-A-GU4	0	13	0	0	0	0	0
##		co-heter	cr-menez	cu-lepid	cy-gilbe	ge-brasi	he-margi	ho-malab	hy-pusar
##	1	1	14	0	0	3	0	1	9
##	2	0	0	0	0	0	0	5	2
##	3	0	0	0	0	0	0	0	0
##	4	0	4	0	0	0	1	17	43
##	5	0	0	0	0	0	0	10	2
##	6	0	0	0	0	0	0	2	0
##	7	0	8	0	0	1	0	31	11
##	8	0	0	0	0	0	0	4	0
##	9	0	0	0	0	0	0	20	0
##	10	0	1	0	50	3	1	4	3
##	11	0	0	0	0	0	0	2	0
##	12	0	1	0	0	1	0	9	0
##	13	0	0	0	0	190	0	0	0
##	14	0	0	0	0	7	0	0	0
##	15	0	0	0	0	8	0	0	0
##	16	0	0	0	0	67	0	1	0
##	17	0	0	0	0	23	0	0	0
##	18	0	0	21	0	16	0	2	1

## 19	0	0	0	0	145	0	0	0
## 20	0	0	0	0	32	0	0	0
## 21	0	0	0	81	5	0	1	0
## 22	0	0	0	0	509	0	0	0
## 23	0	0	0	0	10	0	0	0
##	le-melan	le-piau	le-taeni	mo-costa	mo-lepid	or-nilot	pa-manag	pimel-sp
## 1	0	3	0	0	39	36	0	6
## 2	0	0	0	0	0	0	0	0
## 3	0	0	0	0	0	0	0	0
## 4	0	1	0	0	1	77	0	0
## 5	0	3	0	0	0	0	0	0
## 6	0	0	0	0	0	0	0	0
## 7	0	2	0	0	0	138	0	0
## 8	0	1	0	0	0	0	0	0
## 9	0	0	0	0	0	0	0	0
## 10	0	0	0	0	0	73	0	0
## 11	0	2	0	0	0	0	0	0
## 12	0	2	0	0	0	1	0	0
## 13	0	0	0	0	0	6	0	0
## 14	0	0	0	0	0	3	11	0
## 15	2	0	1	0	0	5	0	0
## 16	0	0	0	0	0	1	0	0
## 17	0	0	0	0	0	36	102	0
## 18	0	0	0	1	0	65	0	0
## 19	0	0	0	0	0	11	0	0
## 20	0	0	0	0	0	247	250	0
## 21	0	1	0	0	0	9	0	0
## 22	0	0	0	0	0	1	0	0
## 23	0	0	0	0	0	129	190	0
##	po-retic	po-vivip	pr-brevi	ps-rhomb	ps-genise	se-heter	se-piaba	se-spilo
## 1	0	47	5	0	0	40	68	0
## 2	0	15	0	0	0	14	0	0
## 3	0	0	1	0	0	4	0	0
## 4	20	221	15	0	0	60	0	0
## 5	0	32	5	0	0	0	0	0
## 6	0	0	2	0	0	0	0	0
## 7	5	326	164	1	1	38	0	1
## 8	0	10	0	0	0	0	0	0
## 9	0	0	0	0	0	0	0	0
## 10	0	28	59	0	0	3	0	0
## 11	0	80	0	0	0	3	0	0
## 12	0	0	3	0	0	0	0	0
## 13	0	0	0	0	0	0	0	0
## 14	0	0	0	0	0	0	0	0
## 15	0	0	9	0	0	10	0	0
## 16	10	8	0	0	0	0	0	0


## 17	0	0	0	0	0	0	0	0
## 18	0	0	6	0	0	93	0	0
## 19	46	48	1	0	0	0	0	0
## 20	0	0	0	0	0	0	0	0
## 21	0	0	0	0	0	31	0	0
## 22	266	163	0	0	0	0	0	0
## 23	0	0	0	0	0	0	0	0
##	st-noton	sy-marmo	te-chalc	tr-signa				
## 1	1	0	0	18				
## 2	0	0	0	0				
## 3	0	0	0	0				
## 4	25	0	0	15				
## 5	0	1	0	0				
## 6	0	0	0	0				
## 7	115	0	0	7				
## 8	0	0	0	0				
## 9	0	0	0	0				
## 10	64	0	0	141				
## 11	0	0	0	0				
## 12	0	0	0	0				
## 13	0	0	0	0				
## 14	0	0	0	0				
## 15	0	0	76	23				
## 16	0	0	0	0				
## 17	0	0	0	0				
## 18	0	0	58	0				
## 19	0	0	0	0				
## 20	0	0	0	0				
## 21	0	0	0	4				
## 22	0	0	0	0				
## 23	0	0	0	0				
##	UAs	V1	V2					
## 1	S-R-CT1	-20	-23					
## 2	S-R-CP1	-8	-11					
## 3	S-A-TA1	-17	1					
## 4	S-R-CT2	-19	-22					
## 5	S-R-CP2	-6	-12					
## 6	S-A-TA2	-4	-10					
## 7	S-R-CT3	-16	4					
## 8	S-R-CP3	-5	2					
## 9	S-A-TA3	-13	7					
## 10	S-R-CT4	-9	5					
## 11	S-R-CP4	-7	6					
## 12	S-A-TA4	-14	3					
## 13	B-A-MU1	-2	-3					
## 14	B-A-GU1	-1	11					

```
## 15 B-R-PC2 -15 -18
## 16 B-A-MU2 -21  14
## 17 B-A-GU2  10  13
## 18 B-R-PC3   9  12
## 19 B-A-MU3   8  16
## 20 B-A-GU3  17  19
## 21 B-R-PC4  15  20
## 22 B-A-MU4  18  21
## 23 B-A-GU4   0   0
```

No código acima, `h = 0.8` fornece os grupos formados na altura `h` do eixos das distâncias do dendrograma. Ou seja, no dendrograma, o eixo `y` (*HEIGHT*, “h”) representa o valor da distancia escolhida entre os objetos ou grupos de objetos. Portanto, se dois objetos ou grupos de objetos foram agrupados num dado valor (0.8, por exemplo) no eixo `height`, isso significa que a distancia entre esses objetos é 0.8.

22.9 Construindo uma prancha de gráficos comparativos

```
#dev.off()
par(mfrow = c(2,2))
plot(cluster1, main = "Dist.Euclidiana")
plot(cluster3, main = "Rel.Coluna")
plot(cluster4, main = "ArcSin.SQRT")
plot(cluster5, main = "Bray-Curtis")
par(mfrow=c(1,1))
#dev.off()
```

22.10 Construindo heatmaps

Agora que vimos de forma comparativa a importância de se relativizar e transformar nossos dados, e também de escolher de forma consciente a medida de distância e o método de fusão, podemos avançar um pouco mais na interpretação dos nossos dados.


Um “heatmap”, ou mapa de calor, é uma imagem em cores (basicamente `image(t(x))`) com um dendrograma adicionado ao lado esquerdo e/ou ao topo. Normalmente, é realizado o reordenamento das linhas e colunas de acordo com algum conjunto de valores (médias de linha ou coluna) dentro das restrições

impostas pelo dendrograma.

Primeiro vamos rever o dendrograma final, usando a Distância de Bray-Curtis e o Método de Fusão UPGMA (ou “*group average*”).

```
library("RColorBrewer")
library("gplots")
vegdist <- vegdist(m_trns, method = "bray",
                  diag = TRUE,
                  upper = FALSE)
cluster5 <- hclust(vegdist, method = "average")
plot(cluster5, main = "Cluster Dendrogram - Bray-Curtis")


heatdist <- as.matrix(vegdist)
#heatdist
```



Na sequência fazemos um **heatmap objetos x objetos**, ou seja a comparação bidimensional das clustereds entre unidades amostrais.


```
col <- rev(heat.colors(999)) #rev() reverte as cores do heatmap
heatmap.2(x=(as.matrix(vegdist)), #objetos x objetos
          Rowv = as.dendrogram(cluster5),
          Colv = as.dendrogram(cluster5),
```

```
key = T, tracecol = NA, revC = T,
col = heat.colors, #dissimilaridade = 1 - similaridade
density.info = "none",
xlab = "UA's", ylab = "UA's",
mar = c(6, 6) + 0.2)
```




Agora vamos criar um novo dendrograma, para as espécies, mostrando sua similaridade em termos de em quais UA's elas são mais comuns.

```
cluster6 <- hclust((vegdist(t(m_trns), method = "bray",
                             diag = TRUE,
                             upper = FALSE)), method = "average")
plot(cluster6, main = "Dendrograma dos atributos")
```



Na sequência, fazemos um novo **heatmap objetos x atributos**, com a comparação bidimensional das clustereds formadas entre unidades amostrais em relação as espécies mais comuns que ocorreram em cada unidade amostral.

```
heatmap.2(t(as.matrix(m_trns)), #objetos x atributos
           Colv = as.dendrogram(cluster5),
           Rowv = as.dendrogram(cluster6),
           key = T, tracecol = NA, revC = T,
           col = col,
           density.info = "none",
           xlab = "Unidades amostrais", ylab = "Espécies",
           mar = c(6, 6) + 0.1) # adjust margin size
```




22.10.1 Percentual de encadeamento (% chaining)

Dendrogram Chaining (ou encadeamento) é um termo usado em análises de *cluster* hierárquico para se referir ao processo de adição sequencial de pequenos grupos a um ou poucos grandes grupos. É possível usar a porcentagem de encadeamento para ajudar a avaliar a qualidade do dendrograma. Análises altamente encadeadas provavelmente não valem a pena serem exploradas em maiores detalhes, provavelmente há alguma falha nos passos anteriores da análise. Por outro lado, pequenas diferenças na porcentagem de encadeamento na extremidade inferior da escala são geralmente um critério pobre para selecionar um algoritmo de ligação em relação a outro (MCCUNE; GRACE, 2002).

O método para calcular o grau de encadeamento compara o comprimento médio do caminho do dendrograma com o comprimento mínimo possível (sem encadeamento) e o comprimento máximo possível (encadeamento completo). O comprimento do caminho para cada item no dendrograma é o número de nós que o conectam ao nível mais alto do dendrograma. O encadeamento completo ocorre quando cada fusão envolve a adição de um único item a um único grupo, cada vez maior (MCCUNE; GRACE, 2002).

Com esse código podemos calcular o percentual de encadeamento para cada fusão em `cluster1` e fazer um gráfico simples para observação.

```
# calculate the percent chaining for each merge
h <- cluster1$height
n <- length(h)
pc <- rep(NA, n-1)
for (i in 1:(n-1)) {
  pc[i] <- abs(h[i] - h[i+1]) / h[1] * 100
}
# plot the percent chaining
plot(pc, type = "h", xlab = "Merge", ylab = "Percent chaining")
```



Para calcular o percentual geral de encadeamento em um dendrograma, é necessário calcular a diferença na altura entre cada nó e seus nós filhos e, em seguida, somar essas diferenças. Essa soma representa o comprimento total do dendrograma. Em seguida, é necessário calcular a soma das diferenças na

altura entre cada nó que representa uma fusão e a altura de seus dois nós filhos. Essa soma representa o encadeamento total no dendrograma.

Finalmente, você pode calcular o percentual geral de encadeamento como o encadeamento total dividido pelo comprimento total do dendrograma, multiplicado por 100.

O eixo y do gráfico mostra a percentagem de encadeamento, que é a diferença na altura entre fusões sucessivas dividida pela altura total do dendrograma, multiplicada por 100. É possível que a percentagem de encadeamento seja superior a 100 se a altura das duas fusões comparadas for maior que a altura total do dendrograma. Nesse caso, a percentagem de encadeamento é truncada em 100.


Isso pode acontecer, por exemplo, se a altura de uma fusão for negativa, o que pode ocorrer se a distância entre dois grupos for menor que zero, ou se o dendrograma for escalado ou truncado de alguma forma.

22.10.2 Função loop para comparar os encadeamentos

```
# create a list of the four cluster analyses
cluster_list <- list(cluster1, cluster2, cluster3, cluster4,
  ↪ cluster5)

par(mfrow=c(3,2)) #posicionamento dos gráficos

# loop through the list and calculate percent chaining for each
for (i in 1:5) {
  h <- cluster_list[[i]]$height
  n <- length(h)
  pc <- rep(NA, n-1)
  for (j in 1:(n-1)) {
    pc[j] <- abs(h[j] - h[j+1]) / h[1] * 100
  }
# plot the percent chaining for each cluster analysis
  plot(pc, type = "h", xlab = "Merge", ylab = "Percent chaining",
    ↪ main = paste0("Cluster ", i))
}
```



Apêndices

Sites consultados

<https://copyprogramming.com/howto/how-to-color-labels-of-dendrogram-with-dendextend-and-heatmap-2-using-pre-defined-sample-groups> [https:](https://)

[//www.datacamp.com/tutorial/hierarchical-clustering-R](http://www.datacamp.com/tutorial/hierarchical-clustering-R)

Outras formas de fazer a partição

```
m_bruta_part2 <- m_bruta_part(colSums(abs(m_bruta_part), na.rm = FALSE))
m_bruta_part2 <- subset(m_bruta_part, colSums != 0)
m_bruta_part2 <- m_bruta_part, colSums(m_bruta_part != 0)
```

Script limpo

Aqui apresento o scrip na íntegra sem os textos ou outros comentários. Você pode copiar e colar no R para executa-lo. Lembre de remover os # ou ## caso necessite executar essas linhas.

```
## dev.off() #apaga os graficos, se houver algum
## rm(list=ls(all=TRUE)) #limpa a memória
## cat("\014") #limpa o console
## install.packages("openxlsx") #importa arquivos do excel
## install.packages("moments") #calcula assimetria e curtose dos
  ↪ dados
## install.packages("matrixStats") #fornece funções rápidas para
  ↪ a estatística de matrizes
## install.packages("gt") #ferramenta para criação de tabelas
  ↪ bonitas e personalizáveis
## getwd()
## setwd("C:/Seu/Diretório/De/Trabalho")
library(openxlsx)
m_bruta <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/peixes06.xlsx"
  ↪ ,
  rowNames = T, colNames = T,
  sheet = "Sheet1")

str(m_bruta)
m_bruta_ma <- as.matrix(m_bruta) #lê m_bruta como uma matriz
str(m_bruta_ma)
#m_bruta
m_bruta_ma[1:5,1:5] #[1:5,1:5] mostra apenas as linhas e colunas
  ↪ de 1 a 5.
#m_bruta <- (m_bruta) # <1>
#View(m_bruta)
print(m_bruta)
head(m_bruta)
str(m_bruta)
```

```

mode(m_bruta)
class(m_bruta)
##?str
range(m_bruta) #menor e maior valores
length(m_bruta) #no. de colunas
ncol(m_bruta) #no. de N colunas
nrow(m_bruta) #no. de M linhas
sum(lengths(m_bruta)) #soma os nos. de colunas
length(as.matrix(m_bruta)) #tamanho da matriz m x n
sum(m_bruta == 0) # número de observações igual a zero
sum(m_bruta > 0) # número de observações maiores que zero
zeros <- (sum(m_bruta == 0)/length(as.matrix(m_bruta)))*100 #
  ↪ proporção de zeros na matriz
zeros
tamanho <- data.frame(
  Função = c("range", "length", "m cols", "n linhas", "Tamanho",
  ↪ "Tamanho",
    "Zeros", "Nao zeros", "% Zeros"),
  Resultado = c(paste(range(m_bruta), collapse = " - "),
  ↪ length(m_bruta), ncol(m_bruta),
    nrow(m_bruta), sum(lengths(m_bruta)),
    ↪ length(as.matrix(m_bruta)), sum(m_bruta ==
    ↪ 0),
    sum(m_bruta > 0), round(zeros, 1))
)
tamanho
knitr::kable(tamanho, format = "markdown", caption = "Resumo das
  ↪ informações sobre o tamanho da matriz")
euclid <- dist(m_bruta, method = "euclidian", diag = TRUE, upper
  ↪ = FALSE)
##?dist
#euclid
str(euclid)
mode(euclid)
class(euclid)
length(as.matrix(euclid))
as.matrix(euclid)[1:6, 1:6] #mostra as 5 primeiras linhas e
  ↪ colunas da matriz
euclid_ma <- (as.matrix(euclid))
#View(euclid_ma)
str(euclid_ma)
mode(euclid_ma)
class(euclid_ma)
euclid_ma[1:5, 1:5] #mostra as 5 primeiras linhas e colunas da
  ↪ matriz

```

```

range(m_bruta)
range(euclid)
min(euclid)
max(euclid)
mean(euclid) #CENTROIDE!! OU Grand mean
sd(euclid) #Standard deviation
centroide <- mean(euclid)
centroide
length(euclid)
m <- nrow(m_bruta)
m
m*(m-1)/2
summary(euclid)
Sumario1 <- cbind(min(euclid),
                  max(euclid),
                  sd(euclid),
                  mean(euclid),
                  length(euclid))
colnames(Sumario1) <- c("Minimo", "Maximo", "Desv.Padr", "Media",
  ↪ "m(m-1)/2")
rownames(Sumario1) <- ("Valores")
Sumario1
range(euclid)
par(mfrow=c(2,1))
hist(euclid,
     breaks = 15, #determina o no. de colunas do histograma
     xlim = range(floor(min(euclid)), ceiling(max(euclid))),
     xlab = "Distr. de Frequências",
     freq = FALSE)
curve(dnorm(x, mean=mean(euclid), sd=sd(euclid)), add=TRUE)
boxplot.default(euclid, horizontal = TRUE, frame = FALSE,
                xlab="Distr. de Frequências",
                ylim=c(floor(min(euclid)), ceiling(max(euclid))))
  ↪ #Limites do eixo Y

## dev.off()
library(matrixStats)
library(moments)
euclid_ma <- as.matrix(euclid)
euclid_ma
range(euclid_ma) #valor errado
mean(euclid_ma) #valor errado
sd(euclid_ma) #valor errado
is.na(euclid_ma) <- euclid_ma==0 #atribui n.a. aos valores = 0
mean(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↪ calcula

```

```

mean(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↪ calculo
sd(euclid_ma, na.rm=T) #valor correto, omite valores n.a. do
  ↪ calculo
#colMeans(euclid_ma, na.rm=T) #omite valores n.a. do calculo
#rowMeans(euclid_ma, na.rm=T) #omite valores n.a. do calculo
centroide_ma <- mean(euclid_ma, na.rm=T)
av.dist <- (as.matrix(colMeans(euclid_ma, na.rm=T)))
av.desvpad <- (as.matrix(colSds(euclid_ma, na.rm=T)))
dp.centroide_ma <- (av.dist-centroide_ma)/(colSds(av.dist)) #ou
  ↪ z-scores
list <- as.matrix(cbind(av.dist, av.desvpad, dp.centroide_ma))
list
colnames(list, do.NULL = FALSE)
colnames(list) <- c("Av.Dist", "Av.StDev", "DP.Centroide")
list2 <- list[order(list[,1], decreasing = TRUE),] #[,1] ou o
  ↪ nome da coluna
list2
par(mfrow=c(3,1))
hist(list2[, "Av.Dist"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias (em dp) para o
       ↪ centroide",
     main = "Distribuição de Frequência da distância média para o
       ↪ centroide",
     xlim = range(floor(min(av.dist)), ceiling(max(av.dist))),
       ↪ #substitua aqui o menor e maior valor do `range()`
     freq = T)
hist(list2[, "Av.Dist"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias (em dp) para o
       ↪ centroide",
     main = "Curva de normalidade ajustada para a Distribuição de
       ↪ Frequência",
     xlim = range(floor(min(av.dist)), ceiling(max(av.dist))),
       ↪ #substitua aqui o menor e maior valor do `range()`
     freq = F)
curve(dnorm(x, mean=mean(list2[, "Av.Dist"]), sd=sd(list2[,
  ↪ "Av.Dist"])), add=TRUE)
boxplot.default(list2[, "Av.Dist"], horizontal = TRUE, frame =
  ↪ FALSE,
               xlab="Distr. de Frequências",
               ylim=c(floor(min(av.dist)),
                 ↪ ceiling(max(av.dist)))) #substitua aqui o
                 ↪ menor e maior valor do `range()`

```

```

par(mfrow=c(1,1))
range(dp.centroide_ma)
par(mfrow=c(3,1))
hist(list2[, "DP.Centroide"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias dos desvios
     ↪ padrões para o centroide",
     main = "Distribuição de Frequência dos desvio padrões das
     ↪ distâncias médias para o centroide",
     xlim = range(floor(min(dp.centroide_ma)),
     ↪ ceiling(max(dp.centroide_ma))), #substitua aqui o menor
     ↪ e maior valor do `range()`
     freq = T)
hist(list2[, "DP.Centroide"],
     breaks = 15, #determina o no. de colunas do histograma
     xlab = "Distr. de Frequências das Distâncias dos desvios
     ↪ padrões das distâncias médias para o centroide",
     main = "Curva de normalidade ajustada para a Distribuição de
     ↪ Frequência",
     xlim = range(floor(min(dp.centroide_ma)),
     ↪ ceiling(max(dp.centroide_ma))), #substitua aqui o menor
     ↪ e maior valor do `range()`
     freq = F)
curve(dnorm(x, mean=mean(list2[, "DP.Centroide"]), sd=sd(list2[,
     ↪ "DP.Centroide"])), add=TRUE)
boxplot.default(list2[, "DP.Centroide"], horizontal = TRUE, frame
     ↪ = FALSE,
               xlab="Distr. de Frequências",
               ylim=c(floor(min(dp.centroide_ma)),
               ↪ ceiling(max(dp.centroide_ma)))) #substitua
               ↪ aqui o menor e maior valor do `range()`
par(mfrow=c(1,1))
## dev.off()
cutoff <- 2.0
library(gt)
format(cutoff, nsmall = 1)
listf <- as.data.frame(list2)
listf$Outliers <- ifelse(listf$DP.Centroide>cutoff #CUTOFF MENOR
     ↪ QUE -'cutoff
               & listf$DP.Centroide<cutoff, #CUTOFF
               ↪ MAIOR QUE 'cutoff'
               "", "OUT")

listf
gt(cbind(Sitios=rownames(listf),listf))
part <- c("B-A-MU4", "B-A-MU3", "S-A-TA4", "S-R-CT3")

```

```

part
m_bruta_part <- m_bruta[!(row.names(m_bruta) %in% c(part)),]
#m_bruta_part
sum <- colSums(m_bruta_part)
sum
zero_sum_cols <- names(which(colSums(m_bruta_part) == 0))
zero_sum_cols #nomes das espécies zeradas
m_bruta_part2 <- m_bruta_part[(colSums(m_bruta_part) != 0)] #em
  ↳ != a exclamação inverte o sentido
zero_sum_cols2 <- names(which(colSums(m_bruta_part2) == 0))
zero_sum_cols2 #nomes das espécies zeradas
sum<-colSums(m_bruta_part2)
sum
#m_bruta_part2
#m_bruta_part2 <- as.matrix(m_bruta_part2)
str(m_bruta_part2)
length(as.matrix(m_bruta_part2))
## df <- data.frame(Sites = rownames(m_bruta), m_bruta,
##                  row.names = NULL,
##                  check.names = FALSE) #add titulo a primeira
  ↳ coluna
##
## write.table(m_bruta_part2, "m_trabcsv.csv",
##             sep = ";", dec = ".", #"t",
##             row.names = TRUE,
##             quote = TRUE,
##             append = FALSE)
##
## m_trab <- read.csv("m_trabcsv.csv",
##                   sep = ";", dec = ".",
##                   row.names = 1,
##                   header = TRUE,
##                   na.strings = NA,
##                   check.names = FALSE, #impede que o R mude
  ↳ os nomes das colunas
##                   col.names = gsub("(^|_)([a-z])",
  ↳ "\\1\\U\\2",
##                   names(m_trab), perl =
  ↳ TRUE))

```

Referências

Chapter 23

R Módulo 8 - Análise de Classificação Não-hierárquica - K-Means

RESUMO

O método *k-means* é um algoritmo de aprendizado de máquina não supervisionado utilizado para agrupar dados em *clusters*. Ele é um dos métodos mais populares e amplamente utilizados para tarefas de *clustering* ou agrupamentos. O objetivo do algoritmo *k-means* é particionar um conjunto de dados em **k clusters**, onde **k** é um valor pré-definido pelo usuário e **um cluster é um grupo de objetos**. Cada grupo é representado por seu centróide, que é o ponto médio dos dados pertencentes a esse grupo. O algoritmo busca minimizar a variância *intra-cluster*, ou seja, a soma dos quadrados das distâncias entre os objetos de um *cluster* e o centróide desse *cluster*.

Apresentação

O método *k-means* é um algoritmo de aprendizado de máquina não supervisionado utilizado para agrupar dados em *clusters*. Ele é um dos métodos mais populares e amplamente utilizados para tarefas de *clustering* ou agrupamentos.

O objetivo do algoritmo *k-means* é particionar um conjunto de dados em **k clusters**, onde **k** é um valor pré-definido pelo usuário e **um cluster é um grupo de objetos**. Cada grupo é representado por seu centróide, que é o ponto médio dos dados pertencentes a esse grupo. O algoritmo busca minimizar a variância *intra-cluster*, ou seja, a soma dos quadrados das distâncias entre os objetos de um *cluster* e o centróide desse *cluster*.

O processo de *clustering* pelo *k-means* envolve os seguintes passos:

1. Inicialização: Seleção aleatória de *k* centróides iniciais ou usando outros métodos de inicialização.
2. Atribuição: Cada ponto de dados é atribuído ao *cluster* cujo centróide está mais próximo.
3. Atualização: Recalcula-se o centróide de cada *cluster* com base nos pontos de dados atribuídos a ele.
4. Repetição: Os passos 2 e 3 são repetidos até que os centróides dos *clusters* se estabilizem ou um critério de parada seja atingido.

O algoritmo *k-means* é iterativo e pode convergir para uma solução ótima local. Portanto, é comum executar o algoritmo várias vezes com diferentes inicializações aleatórias para melhorar a qualidade do *clustering*. A escolha do número de clusters (*k*) é um parâmetro importante e pode afetar os resultados.

O *k-means* é amplamente aplicado em diversas áreas, como análise de dados, mineração de dados, reconhecimento de padrões e segmentação de imagens. Ele é eficiente e escalável, tornando-o uma opção popular para *clustering* de grandes conjuntos de dados. No entanto, é importante ressaltar que o *k-means* assume que os *clusters* são esféricos e de tamanho similar, o que nem sempre é o caso em todos os conjuntos de dados.

23.1 Organização básica

```
dev.off() #apaga os graficos, se houver algum
rm(list=ls(all=TRUE)) ##LIMPA A MEMORIA
cat("\014") #limpa o console
```

Instalando os pacotes necessários para esse módulo

```
install.packages("tidyverse")
install.packages("openxlsx")
install.packages("vegan")
```

```
library(tidyverse)
```



```
getwd()
setwd("C:/Seu/Diretório/De/Trabalho")
```

23.1.1 Sobre os dados do PPBio

A planilha `ppbio` contém os dados de abundância de espécies em diferentes unidades amostrais (UA's). A base teórica dos dados do PPBio para o presente estudo pode ser vista em Bases de dados. Dados do PPBio Semiárido. Leia antes de prosseguir.

23.1.2 Importando a planilha de trabalho

```
library(openxlsx)
ppbio <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06p-peixes.xlsx"
  ↪ ,
                                rowNames = T,
                                colNames = T,
                                sheet = "Sheet1")
str(ppbio)
ppbio_ma <- as.matrix(ppbio) # lê ppbio como uma matriz
str(ppbio_ma)
#ppbio
#ppbio_ma
```

23.2 REINÍCIO 1

ATENÇÃO Aqui substitui-se uma nova matriz de dados, caso seja necessário refazer a análise com uma matriz gerada nesse código.

Substitua a nova matriz aqui. Caso seja necessário.

```
m_bruta <- (ppbio) # <1>
```

No interesse de sistematizar o uso das várias matrizes que são comumente usadas em uma AMD, a tabela a seguir (23.1 resume seus tipos e abreviações.

```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

23.3 Classificação


Criando uma classificação baseada na distância Bray-Curtis e UPGMA como método de fusão, criada a partir da matriz de dados relativizada pelo total das colunas e transformada pelo arco seno da raiz quadrada.

```
library(vegan)
m_trns <- asin(sqrt(decostand(m_bruta,
                             method="total", MARGIN = 2)))
vegdist <- vegdist(m_trns, method = "bray",
                  diag = TRUE,
                  upper = FALSE)
cluster <- hclust(vegdist, method = "average")
plot(cluster, main = "Cluster Dendrogram - Bray-Curtis")
rect.hclust(cluster, k = 3, h = NULL)
#h = 0.8 fornece os grupos formados na altura h
as.matrix(vegdist)[1:6, 1:6]
```

```
##           S-R-CT1  S-R-CP1  S-A-TA1  S-R-CT2  S-R-CP2  S-A-TA2
## S-R-CT1 0.0000000 0.8743721 0.9338269 0.6274997 0.8106894 0.9420728
## S-R-CP1 0.8743721 0.0000000 0.6833816 0.7759468 0.7726098 0.7342613
## S-A-TA1 0.9338269 0.6833816 0.0000000 0.8789631 0.9178304 0.5700984
## S-R-CT2 0.6274997 0.7759468 0.8789631 0.0000000 0.7280378 0.8836068
## S-R-CP2 0.8106894 0.7726098 0.9178304 0.7280378 0.0000000 0.8915271
## S-A-TA2 0.9420728 0.7342613 0.5700984 0.8836068 0.8915271 0.0000000
```

Table 23.1: Nomenclatura das matrizes em AMD em relação aos atributos das colunas.

Nome	Atributos (colunas)	Abreviação no R
Matriz comunitaria	Os atributos são táxons ou OTU's (Unidades Taxonômicas Operacionais) (ex. espécies, gêneros, morfotipos)	m_com
Matriz ambiental	Os atributos são dados ambientais e variáveis físicas e químicas (ex. pH, condutividade, temperatura)	m_amb
Matriz de habitat	Os atributos são elementos da estrutura do habitat (ex. macrófitas, algas, pedras, lama, etc)	m_hab
Matriz bruta	Os atributos ainda não receberam nenhum tipo de tratamento estatístico (valores brutos, como coletados)	m_brt
Matriz transposta	Os atributos foram transpostos para as linhas	m_t
Matriz relativizada	Os atributos foram relativizados por um critério de tamanho ou de variação (ex. dividir os valores de cada coluna pela soma)	m_rel
Matriz transformada	Foi aplicado um operador matemático a todos os atributos (ex. raiz quadrada, log)	m_trns
Matriz de trabalho	Qualquer matriz que seja o foco da análise atual (ex. comunitária, relativizada, etc)	m_trab



23.4 Histórico das fusões

Criamos agora o histórico das fusões dos objetos. Na tabela gerada, as duas primeiras colunas (No. e UA) representam o número (No.) atribuído a cada unidade amostral (UA). As duas colunas subsequentes (*Cluster1* e *Cluster2*) representam o par de objetos (indicado pelo sinal de “-”) ou grupo de objetos (indicado pela ausência do sinal de “-”) que foram agrupadas. A coluna *Height*, indica o valor de similaridade na qual um dado par de objetos (ou grupo de objetos) foi agrupado. O valor aproximado de *Height* também pode ser visualizado no eixo do dendrograma. Por último, na coluna *Histórico*, é mostrada a sequência das fusões da primeira até a *n-1* última fusão entre os dois últimos grupos. Nesse caso, 22.

```
merge <- as.data.frame(cluster$merge)
merge[nrow(merge)+1,] = c("0", "0")
height <- as.data.frame(round(cluster$height, 2))
height[nrow(height)+1,] = c("1.0")
fusoes <- data.frame(Cluster = merge, Height = height)
colnames(fusoes) <- c("Cluster1", "Cluster2", "Height")
UA <- rownames_to_column(as.data.frame(m_trns[, 0]))
colnames(UA) <- c("No. e UA")
fusoes <- cbind(UA, fusoes)
```

```
fusoes$Histórico <- 1:nrow(fusoes)
fusoes
```

```
##      No. e UA Cluster1 Cluster2 Height Histórico
## 1   S-R-CT1      -20      -23  0.14         1
## 2   S-R-CP1       -8      -11  0.26         2
## 3   S-A-TA1      -17        1  0.28         3
## 4   S-R-CT2      -19      -22  0.37         4
## 5   S-R-CP2       -6      -12  0.41         5
## 6   S-A-TA2       -4      -10  0.46         6
## 7   S-R-CT3      -16        4  0.48         7
## 8   S-R-CP3       -5        2  0.53         8
## 9   S-A-TA3      -13        7  0.56         9
## 10  S-R-CT4       -9        5  0.57        10
## 11  S-R-CP4       -7        6  0.59        11
## 12  S-A-TA4      -14        3  0.61        12
## 13  B-A-MU1       -2       -3  0.68        13
## 14  B-A-GU1       -1       11  0.68        14
## 15  B-R-PC2      -15      -18  0.69        15
## 16  B-A-MU2      -21       14  0.75        16
## 17  B-A-GU2       10       13  0.76        17
## 18  B-R-PC3        9       12  0.79        18
## 19  B-A-MU3        8       16  0.8         19
## 20  B-A-GU3       17       19  0.85        20
## 21  B-R-PC4       15       20  0.89        21
## 22  B-A-MU4       18       21  0.91        22
## 23  B-A-GU4        0        0  1.0         23
```

No código acima, $h = 0.8$ fornece os grupos formados na altura h do eixos das distâncias do dendrograma. Ou seja, no dendrograma, o eixo y (*HEIGHT*, “h”) representa o valor da distancia escolhida entre os objetos ou grupos de objetos. Portanto, se dois objetos ou grupos de objetos foram agrupados num dado valor (0.8, por exemplo) no eixo *height*, isso significa que a distancia entre esses objetos é 0.8.

23.5 Algoritmo k-means - Versão simplificada

23.5.1 Organização básica primeiro

```
dev.off() #apaga os graficos
```

23.5.2 Instalar pacotes necessários

```
install.packages("factoextra")
install.packages("FactoMineR")
install.packages("cluster")
install.packages("gridExtra")
```

23.5.3 Importando matriz

```
library(openxlsx)
ppbioh <- read.xlsx(
  ↪ "D:/Elvio/OneDrive/Disciplinas/_EcoNumerica/5.Matrizes/ppbio06p-amb.xlsx"
  ↪ ,
  rowNames = T, colNames = T,
  sheet = "ano1")
colnames(ppbioh)
```

```
## [1] "h.macroph"      "h.grass"        "h.subveg"       "h.overhveg"     "h.litter"
## [6] "h.filalgae"     "h.attalgae"     "h.roots"        "h.lrgdeb"       "h.smldeb"
## [11] "s.mud"          "s.sand"         "s.smlgrav"      "s.lrggrav"      "s.cobbles"
## [16] "s.rocks"        "s.bedrock"      "m.elev"         "m.river"        "m.stream"
## [21] "m.distsource"   "m.distmouth"    "m.maxslope"     "m.maxdepth"     "m.habdepth"
## [26] "m.width"        "a.veloc"        "a.temp"         "a.do"           "a.transp"
```

```
ppbioh_part <- subset(ppbioh,
  select = c("s.mud", "s.sand", "s.smlgrav",
  ↪ "s.lrggrav", "s.cobbles", "s.rocks",
  ↪ "s.bedrock"))
names(which(colSums(ppbioh_part) == 0))
```

```
## character(0)
```

23.6 REINÍCIO 2

ATENÇÃO Aqui substitui-se uma nova matriz de dados, caso seja necessário refazer a análise com uma matriz gerada nesse código.

Substitua a nova matriz aqui. Caso seja necessário.


```
m_trab <- (ppbioh_part)
#m_bruta <- (ppbioh)
```

23.6.1 Algumas análises exploratórias

Dados brutos

```
range(m_trab)
boxplot(t(m_trab))
```

```
## [1] 0 98
```




23.6.1.1 Relativização e transformação

Dados transformados pela função expressa em `m_trns`.

```
m_trns <- sqrt(m_trab)
```


```
range(m_trns)
boxplot(t(m_trns))
```

```
## [1] 0.000000 9.899495
```



23.6.1.2 Gráficos comparativos

```
par(mfrow = c(1,2))
boxplot(t(m_trab), log = "", las = 2,
        ylim = c(floor(min(m_trab)), ceiling(max(m_trab))),
        main = "Dados brutos")
boxplot(t(m_trns), log = "", las = 2,
        ylim = c(floor(min(m_trns)), ceiling(max(m_trns))),
        main = "Dados relativizados e transformados")
par(mfrow=c(1,1))
```

```
dev.off() #apaga os graficos
```

23.7 Determinando o número ideal de clusteres

23.7.1 Reescalar os dados primeiro usando a função `scale()`

```
library(factoextra)
```

```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

```
library(gridExtra)
```

```
##
## Anexando pacote: 'gridExtra'
```

```
## O seguinte objeto é mascarado por 'package:dplyr':
##
##      combine
```

```
m_trns_s <- scale(m_trns)

# Definindo uma função que envolve o algoritmo k-means
kmeans_fun <- function(data, k) {
  kmeans(data, centers = k, nstart = 25)
}
methods <- c("silhouette", "wss", "gap_stat")
plots <- list()
for (method in methods) {
  plot_title <- paste("No. de clusters método ", method)

  plot <- fviz_nbclust(m_trns_s, FUNcluster = kmeans_fun, method
    = method) +
    ggtitle(plot_title)

  plots[[method]] <- plot
}
```

No código acima, as funções `scale()`, reescala a matriz, `fviz_` cria um gráfico que sugere o número ideal de clusters para serem usados, e o argumento `method=` indica o método usado para propor o número de clusters, que podem ser “silhouette”, “wss” e “gap_stat” (Veja Métodos de determinação de clusters em k-means nos Apêndices).

Aqui criamos uma figura com os resultados dos gráficos para cada método de proposição para o número de clusters (Figura 23.1).

```
grid.arrange(grobs = plots, nrow = 3)
```

Com os dados reescalados, agora fazemos uma primeira tentativa. A função `set.seed()` estabelece um número inicial de partida de onde serão feitas as permutações aleatórias. Nesse caso, foi usado `centers=n` centros para calcular os agrupamentos K-Means.

```
library(factoextra)
library(gridExtra)
m_trns_s <- scale(m_trns)
set.seed(666)
```





Figure 23.1: Gráficos para cada método de proposição para o número de clusters.

```

kmeans <- kmeans(m_trns_s, centers = 3)
kmeans #resultados descritivos da análise

fviz_cluster(kmeans, data = m_trns_s, outlier.color = "black",
  ↪ outlier.shape = 19,
    ellipse.type = "convex") #ou "confidence"

```



```
## K-means clustering with 3 clusters of sizes 3, 9, 11
```

```
##
```

```
## Cluster means:
```

```
##      s.mud      s.sand s.smlgrav s.lrggrav  s.cobbles    s.rocks
## 1 -0.4981467  0.2643189 -0.8616320 -0.5098978  1.83999539  1.48863931
## 2  0.9046630 -1.0028428 -0.4021210 -0.3097617 -0.58268890 -0.08988163
## 3 -0.6043206  0.7484208  0.5639986  0.3925044 -0.02507146 -0.33245303
```

```
##      s.bedrock
```

```
## 1 -0.2937783
```

```
## 2  0.4569884
```

```
## 3 -0.2937783
```

```
##
```

```
## Clustering vector:
```

```
## S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2 S-R-CT3 S-R-CP3 S-A-TA3 S-R-CT4
##      2      3      2      1      3      3      1      3      3      2
## S-R-CP4 S-A-TA4 B-A-MU1 B-A-GU1 B-R-PC2 B-A-MU2 B-A-GU2 B-R-PC3 B-A-MU3 B-A-GU3
```

```
##      1      3      3      2      3      3      2      3      2      2
## B-R-PC4 B-A-MU4 B-A-GU4
##      3      2      2
##
## Within cluster sum of squares by cluster:
## [1] 12.17309 35.54207 43.97147
## (between_SS / total_SS = 40.5 %)
##
## Available components:
##
## [1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss"
## [6] "betweenss"    "size"         "iter"         "ifault"
```

23.7.1.1 Usando os agrupamentos do `kmeans$cluster`

```
kmeans
kmeans$cluster
grupos <- kmeans$cluster
grupos
grupos2 <- cbind(grupos, m_trab)
grupos2
```

```
## K-means clustering with 3 clusters of sizes 3, 9, 11
##
## Cluster means:
##      s.mud      s.sand s.smlgrav s.lrggrav s.cobbles s.rocks
## 1 -0.4981467  0.2643189 -0.8616320 -0.5098978  1.83999539  1.48863931
## 2  0.9046630 -1.0028428 -0.4021210 -0.3097617 -0.58268890 -0.08988163
## 3 -0.6043206  0.7484208  0.5639986  0.3925044 -0.02507146 -0.33245303
##      s.bedrock
## 1 -0.2937783
## 2  0.4569884
## 3 -0.2937783
##
## Clustering vector:
## S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2 S-R-CT3 S-R-CP3 S-A-TA3 S-R-CT4
##      2      3      2      1      3      3      1      3      3      2
## S-R-CP4 S-A-TA4 B-A-MU1 B-A-GU1 B-R-PC2 B-A-MU2 B-A-GU2 B-R-PC3 B-A-MU3 B-A-GU3
##      1      3      3      2      3      3      2      3      2      2
## B-R-PC4 B-A-MU4 B-A-GU4
##      3      2      2
##
## Within cluster sum of squares by cluster:
```

```

## [1] 12.17309 35.54207 43.97147
## (between_SS / total_SS = 40.5 %)
##
## Available components:
##
## [1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss"
## [6] "betweenss"    "size"         "iter"         "ifault"
## S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2 S-R-CT3 S-R-CP3 S-A-TA3 S-R-CT4
##      2      3      2      1      3      3      1      3      3      2
## S-R-CP4 S-A-TA4 B-A-MU1 B-A-GU1 B-R-PC2 B-A-MU2 B-A-GU2 B-R-PC3 B-A-MU3 B-A-GU3
##      1      3      3      2      3      3      2      3      2      2
## B-R-PC4 B-A-MU4 B-A-GU4
##      3      2      2
## S-R-CT1 S-R-CP1 S-A-TA1 S-R-CT2 S-R-CP2 S-A-TA2 S-R-CT3 S-R-CP3 S-A-TA3 S-R-CT4
##      2      3      2      1      3      3      1      3      3      2
## S-R-CP4 S-A-TA4 B-A-MU1 B-A-GU1 B-R-PC2 B-A-MU2 B-A-GU2 B-R-PC3 B-A-MU3 B-A-GU3
##      1      3      3      2      3      3      2      3      2      2
## B-R-PC4 B-A-MU4 B-A-GU4
##      3      2      2
##      grupos      s.mud      s.sand s.smlgrav      s.lrggrav      s.cobbles      s.rocks
## S-R-CT1      2 65.0000000 30.000000 0.000000 0.00000000 1.6666666 0.000000
## S-R-CP1      3 16.6666660 70.000000 5.000000 5.00000000 3.3333333 0.000000
## S-A-TA1      2 81.6666641  8.333333 1.666667 0.00000000 0.0000000 0.000000
## S-R-CT2      1 40.0000000 40.000000 0.000000 0.00000000 20.0000000 0.000000
## S-R-CP2      3  0.6666667 87.666664 3.333333 3.33333325 5.0000000 0.000000
## S-A-TA2      3  5.0000000 95.000000 0.000000 0.00000000 0.0000000 0.000000
## S-R-CT3      1 65.5555573 23.111111 0.000000 0.00000000 3.0000000 8.333333
## S-R-CP3      3 48.7500000 22.500000 10.000000 10.00000000 8.7500000 0.000000
## S-A-TA3      3 46.6666679 40.000000 6.666667 6.66666651 0.0000000 0.000000
## S-R-CT4      2 95.0000000  1.833333 0.000000 0.00000000 0.3333333 2.833333
## S-R-CP4      1  5.0000000 60.000000 0.000000 0.00000000 25.0000000 10.000000
## S-A-TA4      3 59.1428566 38.714287 2.142857 0.00000000 0.0000000 0.000000
## B-A-MU1      3 33.3333321 65.000000 0.000000 0.00000000 1.6666666 0.000000
## B-A-GU1      2 96.6666641  3.333333 0.000000 0.00000000 0.0000000 0.000000
## B-R-PC2      3 39.0000000 56.000000 3.000000 0.00000000 1.0000000 1.000000
## B-A-MU2      3 20.6000004 77.000000 0.000000 0.00000000 2.4000001 0.000000
## B-A-GU2      2 98.0000000  2.000000 0.000000 0.00000000 0.0000000 0.000000
## B-R-PC3      3 33.6666679 63.000000 3.333333 0.00000000 0.0000000 0.000000
## B-A-MU3      2 65.0000000 35.000000 0.000000 0.00000000 0.0000000 0.000000
## B-A-GU3      2 87.7777786  6.666667 3.333333 2.22222233 0.0000000 0.000000
## B-R-PC4      3 48.8750000 47.875000 1.875000 0.00000000 0.1250000 1.250000
## B-A-MU4      2 91.7777786  3.222222 0.000000 0.00000000 0.0000000 5.000000
## B-A-GU4      2 95.1666641  3.416667 1.333333 0.08333334 0.0000000 0.000000
##      s.bedrock
## S-R-CT1      3.333333
## S-R-CP1      0.000000

```

```
## S-A-TA1 8.333333
## S-R-CT2 0.000000
## S-R-CP2 0.000000
## S-A-TA2 0.000000
## S-R-CT3 0.000000
## S-R-CP3 0.000000
## S-A-TA3 0.000000
## S-R-CT4 0.000000
## S-R-CP4 0.000000
## S-A-TA4 0.000000
## B-A-MU1 0.000000
## B-A-GU1 0.000000
## B-R-PC2 0.000000
## B-A-MU2 0.000000
## B-A-GU2 0.000000
## B-R-PC3 0.000000
## B-A-MU3 0.000000
## B-A-GU3 0.000000
## B-R-PC4 0.000000
## B-A-MU4 0.000000
## B-A-GU4 0.000000
```

23.7.1.1.1 Descendo os nomes das UA's Agora vamos criar duas tabelas cruzadas entre as unidades amostrais e seu pertencimento a um dos agrupamentos criados pela análise de K-Means. Essas tabelas mostram a contagem de ocorrências de cada UA para cada cluster.

```
unid.as <- rownames_to_column(m_trab, var = "UAs")
agrup <- substr(unid.as[, 1], 5, 6)
uas2 <- unid.as %>% mutate(spp=c(agrup), .before=UAs)
table(unid.as$UAs, kmeans$cluster)
table(uas2$spp, kmeans$cluster)
```

```
##
##          1 2 3
## B-A-GU1 0 1 0
## B-A-GU2 0 1 0
## B-A-GU3 0 1 0
## B-A-GU4 0 1 0
## B-A-MU1 0 0 1
## B-A-MU2 0 0 1
## B-A-MU3 0 1 0
## B-A-MU4 0 1 0
## B-R-PC2 0 0 1
```

```
## B-R-PC3 0 0 1
## B-R-PC4 0 0 1
## S-A-TA1 0 1 0
## S-A-TA2 0 0 1
## S-A-TA3 0 0 1
## S-A-TA4 0 0 1
## S-R-CP1 0 0 1
## S-R-CP2 0 0 1
## S-R-CP3 0 0 1
## S-R-CP4 1 0 0
## S-R-CT1 0 1 0
## S-R-CT2 1 0 0
## S-R-CT3 1 0 0
## S-R-CT4 0 1 0
##
##      1 2 3
## CP 1 0 3
## CT 2 2 0
## GU 0 4 0
## MU 0 2 2
## PC 0 0 3
## TA 0 1 3
```

Apêndices

Sites para consulta

Esse vídeo do youtube é um bom exemplo de como fazer uma classificação *k-means*.

23.7.2 Métodos de determinação de clusters em **k-means** {-}

Os métodos “silhouette”, “wss” e “gap_stat” são usados para determinar o número ideal de *clusters* em uma análise de *cluster* utilizando o algoritmo *k-means*.

Método **silhouette**:

- O método **silhouette** avalia a qualidade dos *clusters* formados pelo *k-means*. Ele calcula a medida de **silhouette** para diferentes números de *clusters* e identifica o número de *clusters* com a maior média de

`silhouette`, indicando uma melhor separação e compactação dos clusters.

Método `wss` (*Within-Cluster Sum of Squares*):

- O método `wss` calcula a soma dos quadrados das distâncias dos pontos em cada *cluster* em relação ao centróide desse *cluster*. Ele avalia a variabilidade dentro de cada *cluster*. O objetivo é encontrar o número de *clusters* que minimiza o valor do WSS, indicando uma melhor compactação dos pontos dentro dos *clusters*.

Método `gap_stat` (*Gap statistic*):

- O método `gap_stat` compara a variação da dispersão dos dados dentro dos *clusters* em relação aquela esperada em um conjunto de dados aleatórios (dados de referência sem estrutura de *cluster*). Ele calcula a diferença entre a métrica de dispersão *intra-cluster* dos dados reais e dos dados de referência para diferentes números de *clusters*. O número de *clusters* com o maior valor de lacuna estatística indica um melhor ajuste dos dados reais em relação aos dados aleatórios, sugerindo a presença de estrutura de *cluster*.

Esses métodos ajudam a determinar o número ideal de clusters de forma objetiva, utilizando diferentes critérios de avaliação. Cada método tem suas próprias vantagens e pode ser mais adequado dependendo do conjunto de dados e do objetivo da análise.

Referências

Part VI

**VI. INFORMAÇÕES
GERAIS**

Chapter 24

Nomenclatura das matrizes em AMD

No tocante aos tipos de atributos e seu tratamento pré-análises, uma matriz de dados pode ser dos tipos apresentados na tabela abaixo (Tabela 24.1).

```
## Warning in table_info$align_vector[column] <-  
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a  
## substituir não é um múltiplo do comprimento do substituto
```

24.1 Grupos taxonômicos

Vários grupos taxonômicos foram amostrados, além de variáveis ambientais, análise de conteúdo estomacal de peixes, estrutura de tamanho dos indivíduos e etc. Isso é estabelecido no nome do arquivo .xlsx fornecido, como apresentado na tabela abaixo (Tabela 24.2). O * se indica o tipo de matriz (Tabela 24.3)

```
## Warning in table_info$align_vector[column] <-  
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a  
## substituir não é um múltiplo do comprimento do substituto
```

24.2 Tipos de matrizes

Matrizes disponíveis para análises, com suas descrições e tipos de dados recomendados (Tabela 24.3).

Table 24.1: Nomenclatura das matrizes em AMD em relação aos atributos das colunas.

Nome	Atributos (colunas)
Matriz comunitaria	Os atributos são táxons (ex. espécies, gêneros, morfotipos)
Matriz ambiental	Os atributos são dados ambientais (ex. pH, condutividade, temperatura)
Matriz bruta	Os atributos ainda não receberam nenhum tipo de tratamento estatístico (valores brutos, como coletados)
Matriz transposta	Os atributos foram transpostos para as linhas
Matriz relativizada	Os atributos foram relativizados por um critério de tamanho ou de variação (ex. dividir os valores de cada coluna pela soma)
Matriz transformada	Foi aplicado um operador matemático a todos os atributos (ex. raiz quadrada, log)

Table 24.2: Nomenclatura das matrizes em AMD em relação aos grupos taxonômicos estudados.

Nome	Atributos (colunas)
ppbio*- peixes.xlsx	Os atributos são táxons de peixes, que podem ter sido medidos em contagem, CPUE, etc.
ppbio*- habitat.xlsx	Os atributos são dados ambientais (ex. pH, condutividade, temperatura)
ppbio*- bentos	Os atributos são táxons de macrozoobentos (principalmente, insetos aquáticos e moluscos)
ppbio*- chiron	Os atributos são táxons da família Chironomidae, na sua fase aquática (larva ou pupa)
ppbio*-zoopl	Os atributos são táxons constituintes do zooplâncton (Rotífera, Cladóceras e Copépoda)
ppbio*- conteudo	Os atributos são itens alimentares constituintes do conteúdo alimentar de peixes

```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

24.3 Abreviações

No interesse de sistematizar o código R das várias matrizes que são comumente usadas em uma AMD, a tabela a seguir (24.4) resume seus tipos e abreviações.

```
## Warning in table_info$align_vector[column] <-
## unlist(lapply(table_info$align_vector_origin[column], : número de itens a
## substituir não é um múltiplo do comprimento do substituto
```

24.4 Bases de dados para download

BEASLEY, C. R. **Bioestatística usando R. Apostila de exemplos para o biólogo.** [s.l: s.n.]. Disponível em: <<http://www.ead.unicamp.br/minicurso/bw/texto/fdl.pt.html>>.

BORCARD, D.; GILLET, F.; LEGENDRE, P. **Numerical Ecology with R.** Cham: Springer International Publishing, 2018. Disponível em: <<http://link.springer.com/10.1007/978-3-319-71404-2>>

BRADSTOCK, R. A.; TOZER, M. G.; KEITH, D. A. Effects of high frequency fire on floristic composition and abundance in a fire-prone heathland near Sydney. **Australian Journal of Botany**, [s. l.], v. 45, p. 641–655, 1997.

CÂMARA, M. R.; CHELLAPPA, N. T.; CHELLAPPA, S. Ecologia reprodutiva do *Cicla monocus*, um ciclídeo amazônico no semi-árido do Rio Grande do Norte. **Acta Limnologica Brasiliensia**, [s. l.], v. 14, n. 2, p. 9–16, 2002. Disponível em: <<https://actalb.org/article/627b10d8782aad05cb235d77/pdf/alb-14-2-9.pdf>>

CHAO, A.; GOTELLI, N. J.; HSIEH, T. C.; SANDER, E. L.; MA, K. H.; COLWELL, R. K.; ELLISON, A. M. Rarefaction and extrapolation with Hill numbers: a framework for sampling and estimation in species diversity studies. **Ecological Monographs**, [s. l.], v. 84, n. 1, p. 45–67, 2014. Disponível em: <<https://esajournals.onlinelibrary.wiley.com/doi/10.1890/13-0133.1>>

CLEOPHAS, T. J.; ZWINDERMAN, A. H. **SPSS for Starters and 2nd Levelers.** Cham: Springer International Publishing, 2016. Disponível em: <<https://link.springer.com/10.1007/978-3-319-20600-4>>

Table 24.3: Exemplos de matrizes disponíveis para análises (PPBio Semiárido), com suas descrições e tipos de dados recomendados.

Arquivo (.xlsx)	Tipo de matriz	Descrição	Tipo de dados
ppbio06c	Matriz comunitária	O arquivo ppbio06 traz os dados brutos que serão usados nas análises. A matriz de dados brutos contendo 26 localidades em estações do ano diferentes (objetos) x 35 espécies (atributos), antes de qualquer modificação.	Contagens de indivíduos com alta amplitude de variação, sugerido uso de matriz relativizada.
ppbio06h	Matriz ambiental	O arquivo ppbio06h traz os dados brutos que serão usados nas análises. A matriz de dados brutos contendo 26 localidades em estações diferentes (objetos) x 35 variáveis ambientais (atributos) medidas em diferentes escalas espaciais, antes de qualquer modificação.	Unidades de medição diferentes (cm, m, °C, mg/L, etc.), com uma alta amplitude de variação, sugerido uso de matriz transformada e/ou reescalada.
ppbio06	Matriz comunitária	O arquivo ppbio06 traz os dados brutos que serão usados nessa análise. A matriz de dados brutos contendo 26 locais/ocasiões (objetos) x 35 espécies (atributos), antes de qualquer modificação.	Contagens de indivíduos com alta amplitude de variação, sugerido uso de matriz relativizada.
ppbio06cpue	Matriz comunitária	O arquivo ppbio06cpue traz os valores depois de terem sido ajustados pela Captura Por Unidade de Esforço (CPUE), onde o número de indivíduos de cada espécie em uma determinada UA é dividido pelo esforço de captura daquela UA. Isso significa que os dados foram relativizados pela CPUE. A matriz de dados brutos contendo 26 localidades em estações do ano diferentes (objetos) x 35 espécies (atributos), antes de qualquer modificação.	Densidades de indivíduos (no. de indivíduos por Unidade de Esforço de Captura) com alta amplitude de variação, sugerido uso de matriz relativizada.

Table 24.4: Nomenclatura das matrizes em AMD em relação aos atributos das colunas.

Nome	Atributos (colunas)	Abreviação no R
Matriz comunitaria	Os atributos são táxons ou OTU's (Unidades Taxonômicas Operacionais) (ex. espécies, gêneros, morfotipos)	m_com
Matriz ambiental	Os atributos são dados ambientais e variáveis físicas e químicas (ex. pH, condutividade, temperatura)	m_amb
Matriz de habitat	Os atributos são elementos da estrutura do habitat (ex. macrófitas, algas, pedras, lama, etc)	m_hab
Matriz bruta	Os atributos ainda não receberam nenhum tipo de tratamento estatístico (valores brutos, como coletados)	m_bruta
Matriz transposta	Os atributos foram transpostos para as linhas	m_t
Matriz relativizada	Os atributos foram relativizados por um critério de tamanho ou de variação (ex. dividir os valores de cada coluna pela soma)	m_rel, m_relcol, m_rellin
Matriz transformada	Foi aplicado um operador matemático a todos os atributos (ex. raiz quadrada, log)	m_trns, m_log10, m_asrq
Matriz de distâncias	Matriz de m x m similaridades ou de distâncias (ex. Euclidiana, Manhattan, Bray-Curtis, etc)	m_dists, m_euclid, m_bray
Matriz de trabalho	Qualquer matriz que seja o foco da análise atual (ex. comunitária, relativizada, etc)	m_trab
Matriz particionada	Foram removidas linhas ou colunas (ex. linhas que são outliers e espécies zeradas)	m_part
Base de dados	Arquivo do Excel planilhado a partir de dados de campo ou de laboratório. Será manejada e particionada no R, para criar a Matriz bruta	ppbio06.xlsx, zoore- bio.xlsx, ben- tos06.xlsx

COAKES, S. J.; STEED, L. G. **SPSS: Analysis Without Anguish: version 10.0 for Windows**. Milton, Qld: John Wiley & Sons Australia, Ltd, 2001.

CRAWLEY, M. J. **Statistics: An Introduction using R**. 1. ed. [s.l.] : Wiley, 2005. Disponível em: <<https://onlinelibrary.wiley.com/doi/book/10.1002/9781119941750>>

CRAWLEY, M. J. **Statistics: An Introduction Using R**. 2. ed ed. Chichester: Wiley, 2015.

DIXON, P. VEGAN, a package of R functions for community ecology. **Journal of Vegetation Science**, [s. l.], v. 14, n. 6, p. 927–930, 2003. Disponível em: <<https://onlinelibrary.wiley.com/doi/10.1111/j.1654-1103.2003.tb02228.x>>

DUNN, P. K.; SMYTH, G. K. **Generalized Linear Models With Examples in R**. New York, NY: Springer New York, 2018. Disponível em: <<http://link.springer.com/10.1007/978-1-4419-0118-7>>

FERREIRA, E. B.; OLIVEIRA, M. S. de. **Introdução à Estatística com R**. Alfenas, MG: Editora UNIFAL-MG, 2020.

FIGUEIREDO, B. R. S.; ARAUJO, G. J. M.; SILVA, M. J. D.; MEDEIROS, E. S. F. Implications of low food availability on resource partitioning among three species of Cichlidae (Pisces: Perciformes) in a Brazilian semi-arid reservoir. **Acta Limnologica Brasiliensia**, [s. l.], v. 27, n. 1, p. 93–104, 2015. Disponível em: <http://www.scielo.br/scielo.php?script=sci_arttext&pid=S2179-975X2015000100009&lng=en&tlng=en>

FOX, J.; WEISBERG, S. **An R Companion to Applied Regression**. Third edition ed. Los Angeles: SAGE, 2019. Disponível em: <<https://www.john-fox.ca/Companion/>>

GOMIERO, L. M.; BRAGA, F. M. S. Reproduction of species of the genus *Cichla* in a reservoir in Southeastern Brazil. **Brazilian Journal of Biology**, [s. l.], v. 64, n. 3b, p. 613–624, 2004. Disponível em: <http://www.scielo.br/scielo.php?script=sci_arttext&pid=S1519-69842004000400008&lng=en&tlng=en>

GOTELLI, N. J.; ELLISON, A. M. **Princípios de Estatística em Ecologia**. 1. ed. [s.l.] : Artmed, 2011.

HORTON, N. J.; KLEINMAN, K. **Using R and RStudio for Data Management, Statistical Analysis, and Graphics**. 0. ed. [s.l.] : Chapman; Hall/CRC, 2015. Disponível em: <<https://www.taylorfrancis.com/books/9781482237375>>

HSIEH, T. C.; MA, K. H.; CHAO, A. **iNEXT: Interpolation and Extrapolation for Species Diversity**. [s.l.: s.n.]. Disponível em: <<https://cran.r-project.org/web/packages/iNEXT/index.html>>

HURLBERT, S. H. The nonconcept of species diversity: a critique and alternative parameters. **Ecology**, [s. l.], v. 52, n. 4, p. 577–586, 1971.

HYNDMAN, R. J. The problem with Sturges' rule for constructing histograms. [s. l.], [s.d.].

LEGENDRE, P.; LEGENDRE, L. **Numerical Ecology**. 2nd English ed ed. Amsterdam, The Netherlands ; New York ; Oxford.

LEVIN, J. **Elementary Statistics in Social Research**. 2. ed. New York, NY: Harper & Row Publishers, 1977.

LEVIN, J.; COSTA, S. F. **Estatística Aplicada a Ciências Humanas**. 2. ed. São Paulo, SP: Harbra, 1987.

LUDWIG, J. A.; REYNOLDS, J. F. **Statistical Ecology. A Primer on Methods and Computing**. New York, NY: John Wiley & Sons, 1988. Type: Book.

MACARTHUR, R.; RECHER, H.; CODY, M. On the relation between habitat selection and species diversity. **The American Naturalist**, [s. l.], v. 100, n. 913, p. 319–332, 1966.

MAGURRAN, A. E. **Ecological Diversity and Its Measurement**. [s.l.] : Croom Helm Ltd, 1988. Type: Book.

MCCULLAGH, P.; NELDER, J. A. **Generalized Linear Models**. 2. ed. London, UK: Chapman; Hall, 1989.

MCCUNE, B.; GRACE, J. B. **Analysis of Ecological Communities**. Glenden Beach, Oregon, U.S.A.: MjM Software Design, 2002. Type: Book.

MCDONALD, J. H. **Handbook of Biological Statistics**. Third ed. Baltimore, Maryland, U.S.A.: Sparky House Publishing, 2014. Disponível em: <<https://www.biostathandbook.com/permissions.html>; www.biostathandbook.com/HandbookBioStatThird.pdf>

MEDEIROS, E. S. F.; NOIA, N. P.; ANTUNES, L. C.; MELO, T. X. Zooplankton composition in aquatic systems of semi-arid Brazil: spatial variation and implications of water management. **Pan-American Journal of Aquatic Sciences**, [s. l.], v. 6, n. 4, p. 290–302, 2011.

MEDEIROS, E. S. F.; ROSA, I. L. Reprodução de tucunaré *Cichla ocellaris* (Perciformes: Cichlidae) Bloch & Schneider, 1801 na represa do rio Gramame, Alhandra / PB. **Resumos. II Encontro de Iniciação Científica da UFPB**, [s. l.], p. 82–82, 1994.

MEDEIROS, E. S. F.; SILVA, M. J.; RAMOS, R. T. C. Application of catchment- and local-scale variables for aquatic habitat characterization and assessment in the brazilian semi-arid region. **Neotropical Biology and Conservation**, [s. l.], v. 3, n. 1, p. 13–20, 2008. Disponível em: <<https://revistas.unisinos.br/index.php/neotropical/article/view/5440>>

MEDEIROS, E. S. F.; SILVA, M. J.; RAMOS, T. P. A.; RAMOS, R. T. C. Environmental variables as predictors of fish community composition in semiarid aquatic systems. **Acta Limnologica Brasiliensia**, [s. l.], v. 36, p. e4, 2024. Disponível em: <http://www.scielo.br/scielo.php?script=sci_arttext&pid=S2179-975X2024000100702&tlng=en>

MEDEIROS, E.; SILVA, M.; FIGUEIREDO, B.; RAMOS, T.; RAMOS, R. Effects of fishing technique on assessing species composition in aquatic systems in semi-arid Brazil. **Brazilian Journal of Biology**, [s. l.], v. 70, n. 2, p. 255–262, 2010. Disponível em: <http://www.scielo.br/scielo.php?script=sci_arttext&pid=S1519-69842010000200004&lng=en&tlng=en>

MELO, A. S. **Conversando com o R usando 57 palavras: Introdução à programação com exemplos em Ecologia**. [s.l: s.n.]. Disponível em: <https://ecoevol.ufg.br/adrimelo/prog/Conversando_com_o_R_usando_57_palavras-v13.pdf>.

MOORE, D. S.; MCCABE, G. P.; CRAIG, B. A. **Introduction to the Practice of Statistics**. 9. ed. New York, NY: W.H. Freeman; Company, 2017.

NELDER, J. A.; WEDDERBURN, R. W. M. Generalized Linear Models. **Journal of the Royal Statistical Society. Series A (General)**, [s. l.], v. 135, n. 3, p. 370, 1972. Disponível em: <<https://www.jstor.org/stable/10.2307/2344614?origin=crossref>>

OKSANEN, J.; BLANCHET, F. G.; FRIENDLY, M.; KINDT, R.; LEGENDRE, P.; MCGLINN, D.; MINCHIN, P. R.; O'HARA, R. B.; SIMPSON, G. L.; SOLYMOS, P.; STEVENS, M. H. H.; SZOECS, E.; WAGNER, H. **Vegan: Community Ecology Package. R package version 2.5-7**. [s.l: s.n.]. Disponível em: <<https://cran.r-project.org/web/packages/vegan/vegan.pdf>>.

OLIVEIRA, P. F. de; GUERRA, S.; MCDONNELL, R. **Ciência de dados com R: Introdução**. Brasília, DF: Editora IBPAD, 2018. Type: Book. Disponível em: <<https://cdr.ibpad.com.br/>>

PIELOU, E. C. **Ecological Diversity**. New York, NY: John Wiley & Sons, 1975. Type: Book.

R DEVELOPMENT CORE TEAM. **R: A language and environment for statistical computing**. Austria: R Foundation for Statistical Computing, 2017. Disponível em: <<https://www.r-project.org/>>

R STUDIO TEAM. **RStudio: Integrated Development Environment for R**. Boston, MA: RStudio, PBC, 2022. Type: Book. Disponível em: <<https://posit.co/products/open-source/rstudio/>>

ROYCE, W. F. Standard length versus total length. **Transactions of the American Fisheries Society**, [s. l.], v. 71, n. 1, p. 270–274, 1942. Disponível em: <<https://academic.oup.com/tafs/article/71/1/270/7898954>>

SILVA, E. P.; DUARTE, M. R. N.; MEDEIROS, E. S. F. Length-weight relationship of two fish species from a dryland intermittent river in northeastern Brazil. **Neotropical Biology and Conservation**, [s. l.], v. 13, n. 1, p. 90–93, 2018. Disponível em: <<http://revistas.unisinos.br/index.php/neotropical/article/view/13055>>

SILVA, F. R.; GONÇALVES-SOUZA, T.; PATERNO, G. B.; PROVETE, D. B.; VANCINE, M. H. **Análises Ecológicas no R**. 1. ed. Bauru - SP: Canal 6 Editora. NUPEEA., 2022. Disponível em: <<https://canal6.com.br/livreacesso/livro/analises-ecologicas-no-r/>>

SILVA, M. J.; FIGUEIREDO, B. R. S.; RAMOS, R. T. C.; MEDEIROS, E. S. F. Food resources used by three species of fish in the semi-arid region of Brazil. **Neotropical Ichthyology**, [s. l.], v. 8, n. 4, p. 825–833, 2010.

SILVEIRA, L.; RIBEIRO, N. C.; MELERO, R.; MORA-CAMPOS, A.; PIRAQUIVE-PIRAQUIVE, D. F.; URIBE-TIRADO, A.; SENA, P. M. B.; POLANCO-CORTÉS, J.; SANTILLÁN-ALDANA, J.; SILVA, F. C. C.; ARAÚJO, R. F.; ENCISO-BETANCOURT, A. M.; FACHIN, J. Taxonomia da Ciência Aberta: revisada e ampliada. **Encontros Bibli: revista eletrônica de biblioteconomia e ciência da informação**, [s. l.], v. 28, p. 1–22, 2023. Disponível em: <<https://periodicos.ufsc.br/index.php/eb/article/view/91712>>

SOKAL, R. R.; ROHLF, F. J. **Biometry: The Principles and Practice of Statistics in Biological Research**. 3. ed. New York: W.H. Freeman; Company, 1995. Type: Book.

SOKAL, R. R.; ROHLF, F. J. **Introduction to Biostatistics**. 2nd ed., Dover ed ed. Mineola, N.Y: Dover Publications, 2009.

VALENTIN, J. L. **Ecologia Numérica. Uma Introdução à Análise Mul-**

tivariada de Dados Ecológicos. 1. ed. Rio de Janeiro: Interciência, 2000.
Type: Book.

VENABLES, W. N.; SMITH, D. M.; R CORE TEAM. **An Introduction to R. Notes on R: A Programming Environment for Data Analysis and Graphics Version 4.6.0.** [s.l.: s.n.]. Disponível em: <<https://cran.r-project.org/doc/manuals/r-release/R-intro.html>>.

WICKHAM, H. **ggplot2: Elegant Graphics for Data Analysis.** [s.l.] : Springer-Verlag New York, 2016. Disponível em: <<https://ggplot2.tidyverse.org>>

ZAR, J. H. **Biostatistical Analysis.** 5. ed. Upper Saddle River, NJ: Prentice Hall, 2010.

ZUUR, A. F.; IENO, E. N.; WALKER, N.; SAVELIEV, A. A.; SMITH, G. M. **Mixed Effects Models and Extensions in Ecology with R.** New York, NY: Springer New York, 2009. Disponível em: <<https://link.springer.com/10.1007/978-0-387-87458-6>>